UNIVERSIDADE PRESBITERIANA MACKENZIE
PROGRAMA DE PÓS GRADUAÇÃO EM ADMINISTRAÇÃO DE EMPRESAS

CONCEIÇÃO JACQUELINE XAVIER BARBOSA DE CASTRO

MERCADO DE CAPITAIS ARTIFICIAL: UMA SIMULAÇÃO BASEADA EM AGENTES

São Paulo
2021

CONCEIÇÃO JACQUELINE XAVIER BARBOSA DE CASTRO

MERCADO DE CAPITAIS ARTIFICIAL: UMA SIMULAÇÃO BASEADA EM AGENTES

Dissertação apresentada ao Programa de Pós-Graduação de Administração de Empresas da Universidade Presbiteriana Mackenzie, como requisito parcial necessário à obtenção do título de Mestre em Administração de Empresas, linha “Finanças Estratégicas”.

Orientador: Prof. Dr. Eli Hadad Junior

São Paulo
2021

C355m Castro, Conceição Jacqueline Xavier Barbosa de.
Mercado de capitais artificial : uma simulação baseada em agentes. / Conceição Jacqueline Xavier Barbosa de Castro.
41 f. ; 30 cm

Dissertação (Mestrado em Administração de Empresas) – Universidade Presbiteriana Mackenzie, São Paulo, 2021.
Orientador: Eli Hadad Júnior
Referências bibliográficas: f. 40-41.

1. Modelagem baseada em agentes. 2. Mercado de ações artificial. 3. Netlogo. I. Hadad Junior, Eli, *orientador*. II Título.

CDD 332.6

Bibliotecária Responsável: Jaqueline Bay Inacio Duarte - CRB 8/9509

CONCEIÇÃO JACQUELINE XAVIER BARBOSA DE CASTRO

MERCADO DE CAPITAIS ARTIFICIAL: UMA SIMULAÇÃO BASEADA EM AGENTES

Dissertação apresentada ao Programa de Pós-Graduação em Administração de Empresas da Universidade Presbiteriana Mackenzie, como requisito parcial à obtenção de título de Mestre em Administração de Empresas.

Aprovada em 09 de agosto de 2021.

BANCA EXAMINADORA

Prof. Dr. Eli Hadad Junior
Universidade Presbiteriana Mackenzie

Prof. Dr. Leonardo Fernando Basso
Universidade Presbiteriana Mackenzie

Prof. Dr. Herbert Kimura
Universidade de Brasília

Dedico este trabalho aos meus pais, Vera e José Humberto, apesar da simplicidade, sabem o valor da conquista da educação. Pelos ensinamentos diários: fé e coragem.

Agradecimentos

Meus agradecimentos:

A Deus, pelo dom da vida. É acreditando que é possível e entregando o impossível nas mãos de Deus!

Ao meu marido, Tarcísio, meu eterno incentivador e parceiro de vida. Pelo amor e carinho.

Aos meus pais, Vera e José Humberto, e irmãos, Junio e César, pelos incentivos diários. E ao meu sobrinho, José Augusto, alegria dos meus dias.

Ao meu orientador, Prof. Dr. Eli Hadad Júnior. Por, principalmente, acreditar no meu potencial. Seu apoio e conhecimento foram indispensáveis para realização desse trabalho.

Aos Prof. Dr, Leonardo Basso e Prof. Dr. Herbert Kimura, componentes da banca examinadora, cujas análises, sugestões e opiniões foram essenciais para finalização desse trabalho.

“Eu guardo meus tesouros: meus pensamentos, minha vontade, minha liberdade. E o maior deles é a liberdade.” Ayn Rand.

Resumo

Esta dissertação teve como objetivo comparar e avaliar o poder de predição de um modelo de mercado de ações artificial desenvolvido por técnicas de modelagem baseada em agentes (*Agent-based modelling - ABM*). Foi realizado um estudo empírico de previsão dos valores de determinadas ações da B3, a bolsa de valores do Brasil, através do modelo *Collective Behavior in the Stock Market*, criado por Silva (2014).Os valores gerados foram comparados com os reais coletados entre as datas: 05/06/2019 e da data de fim em 17/08/2020. O ambiente utilizado foi o Netlogo. A amostra de dados para comparação contemplou 299 observações, com simulação de 5400 modelos para cada ação. A análise compreendeu na comparação entre a previsão e o preço de fechamento efetivo dentro de períodos estabelecidos. A seleção dos modelos foi realizada através do teste *Direcional Accuracy* de Pesaran-Timmerman (2006). Os resultados dos modelos foram comparados com um modelo baseado em estatística, utilizando de um algoritmo ARIMA, de Box e Jenkins (1976). Os modelos demonstraram resultados iniciais satisfatórios para o poder preditivo.

Palavras-Chaves: Modelagem baseada em agentes, Mercado de ações artificial, Netlogo.

Abstract

This dissertation aimed to compare and evaluate the predictive power of an artificial stock market model developed by agent-based modeling techniques (ABM). An empirical study was carried out to forecast the values of certain shares of B3, the Brazilian stock exchange, through the model of Collective Behavior in the Stock Market, created by Silva (2014). The values generated were compared with the reais collected between the dates: 06/05/2019 and the end date on 08/17/2020. The environment used was the Netlogo. The sample of data for comparison included 299 observations, with a simulation of 5400 models for each stock. The analysis comprised the comparison between the forecast and the actual closing price within established periods. The selection of models was performed using the Directional Accuracy test of Pesaran-Timmerman (2006). The results of the models were compared with a model based on statistics, using an ARIMA algorithm, by Box and Jenkins (1976). The models showed satisfactory initial results for the predictive power.
Keywords: Agent-based modeling, Artificial stock market, Netlogo.

Lista de ilustrações

Figura 1 – Ambiente Modelagem Baseada em Agentes 18
Figura 2 – Simulação ABM CMIG4 34
Figura 3 – Previsão ARIMA CMIG4 34
Figura 4 – Simulação ABM BRKM5 35
Figura 5 – Previsão ARIMA BRKM5 36
Figura 6 – Simulação ABM EGIE3 36
Figura 7 – Previsão ARIMA EGIE3 37
Figura 8 – Simulação ABM EMBR3 38
Figura 9 – Previsão ARIMA EMBR3 38
Figura 10 – Simulação ABM ITUB4 39
Figura 11 – Previsão ARIMA ITUB4 39

Lista de tabelas

Tabela 1 – Parâmetros de entrada das melhores simulações de ação 31
Tabela 2 – Resultado teste *Direcional Accuracy (DA)* 32

Sumário

1	**Introdução**	**12**
1.1	**Contextualização**	**12**
1.2	**Descrição do Problema**	**13**
1.3	**Objetivos**	**14**
1.3.1	Objetivo	**14**
1.3.2	Objetivos Específicos	**14**
1.4	**Justificativa**	**14**
2	**Revisão da Literatura**	**16**
2.1	**Agentes**	**18**
2.2	**Estudos Relacionados**	**20**
2.3	**Revisão bibliométrica descritiva**	**21**
3	**Metodologia**	**23**
3.1	**NetLogo**	**23**
3.2	**Modelo de Mercado de Ações**	**24**
3.2.1	Premissas do modelo	**25**
3.3	**Análise Comparativa**	**28**
3.4	**Escolha do modelo**	**30**
3.5	**Processo Empírico**	**30**
4	**Resultados**	**33**
4.1	**Simulações realizadas**	**33**
5	**Conclusões**	**40**
	Referências Bibliográficas	**41**

1 Introdução

1.1 Contextualização

No mercado financeiro, onde há várias categorias de agentes com interações entre si, uma das grandes preocupações de seus operadores é tentar acertar as predisposições de determinada ação. Isso é realizado, principalmente, para evitar perdas ou prever o lucro. Para isso, hoje, utilizam-se de vários meios computacionais específicos que auxiliam na tomada de decisão e/ou fazem uma série de análises sobre os dados históricos (séries temporais financeiras), buscando assim uma tendência de mercado.

As previsões são produzidas em várias áreas, pois são ferramentas importantes para a tomada de decisões. A implicação de uma decisão baseada em uma previsão pode ser avaliada por meio do ganho ou perda esperados associados à decisão.

Segundo Wellman (2017), as estratégias computacionais utilizadas respondem às informações dentro de alguns milissegundos ou menos e atualmente são amplamente implantados no mercado financeiro. Estimativas concordam que essas negociações representam mais da metade do comércio volume de ações e mercado de futuros dos EUA (Estados Unidos da América) e é crescente o uso em mercados de câmbio e renda fixa.

A partir disso, as aplicações de técnicas de predição e análise de séries temporais financeiras é um assunto de constante e de elevado interesse na comunidade, tanto para investidores quanto para pesquisadores.

Nas ciências empíricas, uma estratégia comum usada para estudar um sistema real, está em realizar uma modelagem baseada em modelos simplificados que mantêm suas características principais. Através disso, é possível analisá-las de modo a compreender melhor a dinâmica do seu sistema. Este modelo é conhecido como Modelagem Baseada em Agente - Agent-based Modeling (ABM), uma classe de modelos que tem chamado a atenção para a solução de diversos problemas, não apenas de engenharia e ciências sociais, são os modelos baseados em agentes.

ABM é utilizada para simular sistemas complexos criando realidades simplificadas através das interações de seus participantes (agentes). Um dos ambientes utilizado é NetLogo, criado por Wilensky (1999). ABM auxilia a avaliar e solucionar problemas através de modelagem matemática que consiste na aplicação de equações matemáticas para a simulação de processos e interações de agentes. A sua aplicação propicia a previsão e avaliação de cenários, as análises de risco e a tomada de decisão.

Nos últimos anos, a abordagem da análise econômica e financeira baseada em agentes avançou, proporcionando, principalmente, uma ferramenta para a compreensão dos fenômenos complexos observados nos sistemas econômicos. Farmer (2009) ressalta que a modelagem baseada em agente pode lidar com uma gama mais ampla de comportamento não linear do que com modelos de equilíbrio convencionais. Isso demonstra, principalmente

a sua importância em compreender grande parte de problemas sociais.

O presente trabalho consiste em um estudo da predição de séries temporais reproduzidas através da modelagem baseada em agentes de um mercado de ações artificial, em diversas condições de mercado. O escopo deste trabalho foi delimitado ao mercado de ações.

1.2 Descrição do Problema

O mercado de ações se trata de uma área que traz grandes desafios quando se refere a previsão, devido principalmente a relação da complexidade dos eventos e pessoas envolvidos. Mas os grandes benefícios gerados são representados por altos lucros financeiros para as empresas com análise e gerenciamentos de ativos e com negociação automática em bolsa de valores.

O problema tratado neste trabalho é comparar a aplicação de uma modelagem baseada em agentes com os processos utilizados na econometria para a previsão do valor futuro de uma ação negociada na bolsa.

Fazer previsões no sistema financeiro é uma tarefa complexa, devido principalmente aos eventos que não são regulares e são incertos. Grande parte dos modelos clássicos para predição utiliza apenas de equações lineares, deduzidas e especificadas pelo usuário. Em modelos econômicos, podem levar muito tempo para a obtenção de resultados significativos, contudo, com o avanço de tecnologias de informação e dos computadores, tornou-se possível desenvolver métodos mais relevantes.

Para Rossiter et al. (2010), algumas problemáticas envolvendo a modelagem baseada em agentes estão relacionadas com:

1) Complexidade do sistema: quase todos os sistemas sociais são profundamente complexos, envolvendo muitas interações entre diferentes categorias de entidades.

2) Precisão limitada: principalmente devido a esta complexidade e ao fato de que a estrutura e as regras do sistema podem ser voláteis com o tempo, os modelos de sistema social tendem a não ter uma precisão ampla; particularmente precisão preditiva, mas também precisão descritiva quantitativa.

3) Problemas com dados empíricos: os sistemas sociais não são facilmente isoláveis e os mecanismos pelos quais eles operam variam com o tempo (portanto, o cientista social pode ser limitado pelos dados históricos disponíveis).

1.3 Objetivos

1.3.1 Objetivo

O objetivo principal é apresentar a evolução de um preço de ativo desenvolvido por técnicas de modelagem baseada em agentes, de modo a reproduzir séries temporais para análise utilizando de modelos econométricos.

1.3.2 Objetivos Específicos

Como objetivos específicos os seguintes itens:

1) Primeiramente, apresentar uma previsão da evolução de um preço de um ativo através de uma modelagem baseada em agente e explicar em quais casos é útil.

2) Em segundo lugar, validar os resultados produzidos pelo modelo, utilizando cenários diversos e comparando o resultado com o mundo real, além de analisar as características distintas de séries temporais financeiras utilizando de modelos econométricos

1.4 Justificativa

Modelagem Baseada em Agente (ABM) tornou-se uma técnica amplamente utilizada para pesquisa em Ciências Sociais, especialmente para a compreensão dos fenômenos sociais ou para validar de teorias.

Os modelos baseados em agentes oferecem a oportunidade de modelar problemas comportamentais e estudar, desta forma, o efeito do comportamento dos agentes no mercado. Os preços são o resultado da interação dos participantes do mercado, originando assim as séries temporais para análises financeiras. Sendo assim a modelagem oferece a oportunidade de estudar o comportamento dinâmico, heterogêneo e adaptativo do jogo de mercado.

Segundo Wellman et al. (2017), a simulação pode capturar fielmente o mercado complexo e as interações entre seus agentes. O ABM analisa um sistema social complexo por meio de simulações com interações refinadas entre os tomadores de decisão (os agentes), implementados como (geralmente simples) programas de computador. O pesquisador pode programar comportamentos específicos para entidades e, em seguida, assistir a simulação produzir interações entre muitas entidades.

Clarke (2018), evidencia que os modelos baseados em agente são superiores quando há uma base em uma unidade comportamental, como uma pessoa, família, empresa, proprietário ou agricultor (o “agente”), e quando o processo modelado consiste em interações sobre tempo entre um ou mais tipos de agentes que produzem uma forma espacial, como o

uso da terra, escolha da cultura ou tipo de habitat. Essa afirmação se compara ao ambiente do mercado financeiro, onde os investidores são agentes e através do tempo ocorre a relação dentro do ambiente. O ABM replica agentes independentes para estudar suas interdependências, gerando assim informações para os formuladores de políticas, revelando os efeitos da política nas interações dos agentes.

De acordo com Baldwin et al. (2015), os pontos fortes do ABM têm sido aplicados à pesquisa biológica, por exemplo. Os primatas são modelados usando ABM, que resultou em novas explicações para certas estruturas sociais primatas entre machos e fêmeas. Afirma ainda, que o ABM pode ser usada para testar hipóteses sobre as características esperadas e revelar novas hipóteses testáveis, utilizando regras simples.

Macal et al. (2014) classifica o ABM como:

1) Útil: porque é uma abordagem de modelagem apropriada para uma grande classe de problemas e tem vantagens sobre as abordagens de modelagem convencionais.

2) Utilizável: uso através de “software” portátil, extensível e transferível, com melhor desenvolvimento integrado ambientes.

3) Usável: Como os aplicativos ABM estão sendo desenvolvidos para resolver problemas práticos.

Macal e North (2006) defini algumas das razões para a utilização e expansão em diversas áreas do ABM:

1) Os sistemas que há necessidade de análise e modelagem estão se tornando cada vez mais complexos, em termos de suas interdependências.

2) Alguns sistemas, como o mercado financeiro, sempre são extremamente complexos para serem modelados.

3) Atualmente é possível organizar bases de dados num nível fino de granularidade, o que permite realizar micro simulações.

4) O grande avanço do poder computacional.

2 Revisão da Literatura

Comumente, um modelo é uma representação simplificada da realidade. Construir modelos pressupõe na escolha de informações relevantes e na forma como estas serão representadas, além do conhecimento do objeto de estudo. Um modelo busca a especificação da natureza e a importância de relações entre variáveis, constructos e fatores que possam oferecer, com base em teorias científicas, explicações e explanações de um dado sistema. A simulação de um modelo consiste na execução deste modelo.

De acordo com Macal e North (2009), ABM tem suas raízes históricas diretas em sistemas adaptativos complexos e a noção subjacente de que os sistemas são construídos do zero. Sistemas adaptativos complexos se preocupam com a questão de esses comportamentos surgem na natureza, auto agentes nomeados, tendo a capacidade de se auto-organizar e reorganizar dinamicamente seus componentes de maneiras mais adequadas para sobreviver e se destacar em seus ambientes, e essa capacidade adaptativa ocorre, notavelmente, em uma enorme gama de escalas.

A teoria dos sistemas complexos foi originalmente desenvolvida na física e tem origens no trabalho de Lorenz sobre previsão do tempo, que por sua vez reflete a teoria do caos. Lorenz observou que o comportamento de um sistema ao longo do tempo reflete as condições iniciais do sistema, tendo uma dependência dos resultados às condições iniciais da alimentação dos dados. Complexidade é aquela fase de comportamento que não é estática nem determinística. Uma das primeiras demonstrações de complexidade foi em pilhas de areia. Quando a areia é derramada de um bico, forma uma pilha, que cresce de forma linear. No entanto, em algum ponto de seu crescimento, as laterais da pilha estão sujeitas a falhas, sendo impossível dizer quando uma falha ocorrerá e quanto da pilha de areia será removida.

De acordo com MACAL e NORTH (2010), um modelo baseado em agentes é um simulador de um sistema de inteligência artificial distribuída, na qual se usa de um conjunto de componentes com comportamento próprio predefinido, os chamados agentes. Esses agentes são componentes autônomos com comportamentos particulares que se inter-relacionam entre si e com o ambiente. Um sistema multiagente é um conjunto de agentes trabalhando juntos para realizarem tarefas muitas vezes complexas. Os agentes, não conhecem o problema como um todo, somente suas partes, assim o sistema não possui um mecanismo de controle centralizado para resolver a questão.

Para Clarke (2018), a modelagem baseada em agentes representa algumas das estruturas mais simples possíveis para a demonstração do comportamento de sistemas complexos. Um sistema complexo é caracterizado pelo fato de ser definido de diversas maneiras, adaptativo por responder a estímulos ambientais e auto-organizado por apresentar uma tendência em se estabilizar em padrões em sua configuração (FOLEY, 2003; MORIN, 1997).

De acordo com Soussi et al. (2018), o mercado de ações representa um sistema complexo onde vários agentes interagem constantemente. Os modelos analíticos clássicos foram desenvolvidos para estudar e explicar o comportamento do mercado de ações, no entanto, a complexidade do ambiente do sistema financeiro tem incentivado a modelagem de agente. Segundo Bonabeau (2002), situações como: os agentes possuem um comportamento complexo, incluindo aprendizagem e adaptação; as interações entre os agentes são complexas, não-lineares, descontinuas; a topologia das interações é heterogênea e complexa; o sistema é descrito de forma mais natural através de atividades ao invés de processos; são casos potenciais para utilização do ABM.

Modelos baseados em agente (ABM) são modelos computacionais utilizados para simular ações, comportamento e interações de entidades individuais ou coletivas autônomas, com o objetivo de explorar o impacto de um agente ou tipo de comportamento no sistema como um todo. De acordo com Macal et al. (2014), é uma simulação de processos dinâmicos que envolvem agentes autônomos. Um agente autônomo atua por conta própria, sem direção externa em resposta a situações que o agente encontra durante a simulação. Modelando assim, uma população de agentes autônomos, cada um com suas características e comportamentos, sendo o interagir uma característica definidora de um ABM.

A simulação baseada em agente é mais comumente usada para modelo de tomada de decisão individual e comportamento social e organizacional. Segundo Clarke (2014), ABM combinam teoria dos jogos, teoria do complexo de sistemas, programação evolutiva e modelagem estocástica. O modelo deve ser descrito por regras simples e determinísticas baseadas apenas em informações locais. Essas observações têm implicações práticas para desenvolver e interpretar modelos baseados em agentes, como modelos mais complexos do tipo que as pessoas tendem a construir para representar o fenômeno do mundo real também exibiria um comportamento emergente resultante da interação do agente.

Modelagem e simulação usando sistemas multiagentes podem ser aplicadas a qualquer sistema que possa ser quebrado em um conjunto de entidades autônomas (Souissi et al., 2018). Ela abrange sistemas humanos sociais, físicos e biológicos. Segundo Macal e North (2009), as publicações de modelos vão desde a modelagem de civilizações antigas que se foram há centenas de anos até a criação de novos mercados para produtos que não existem agora. Isso demonstra a sua diversidade e confirma a de ideia de que ABM pode incorporar explicitamente a complexidade decorrente de comportamentos individuais e interações que existem no mundo real.

Para Macal et al. (2014), a estrutura do modelo é baseada em três elementos básicos:

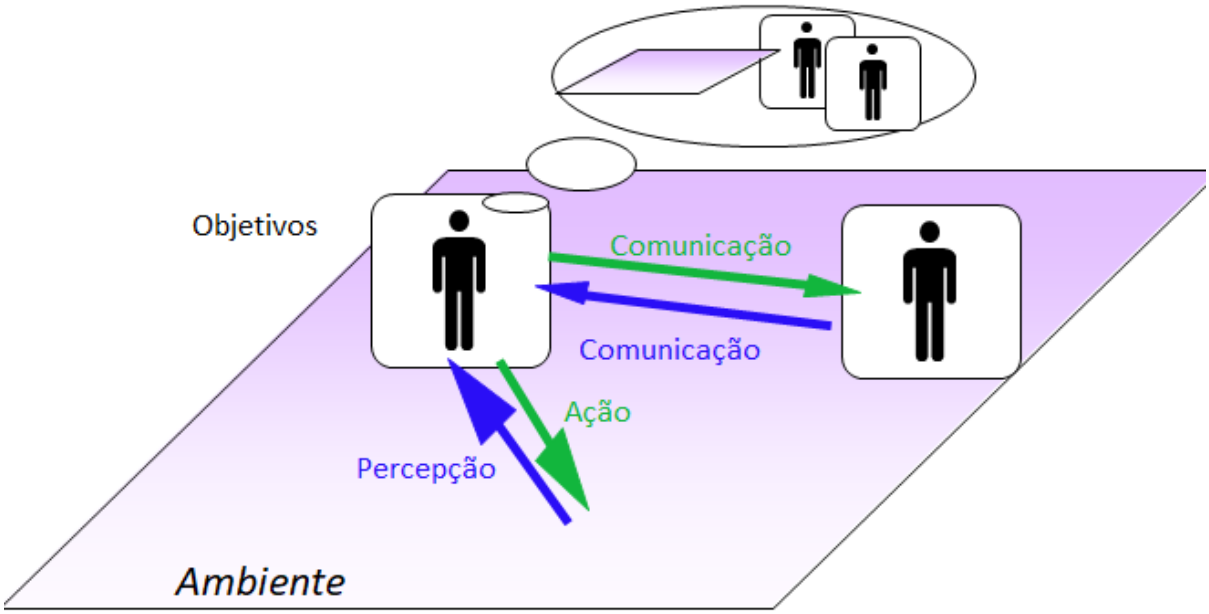
Agentes: A modelagem envolve simulação de processos dinâmicos através de agentes autônomos.

Interação: A modelagem baseada em agente se preocupa com a modelagem de relacionamentos e interações de agentes tanto como acontece com os agentes de modelagem

e os comportamentos dos agentes.

Ambiente: Os agentes vivem e interagem com seu ambiente, além de outros agentes.

Figura 1 – Ambiente Modelagem Baseada em Agentes



Fonte: própria autora

2.1 Agentes

Um agente é qualquer entidade dentro de um ambiente, que pode afetar a si mesma, o ambiente e outros agentes. Eles se comportam de forma independente, mas reagem ao ambiente, ao agregado de propriedades do sistema e outros agentes. As unidades são chamadas de agentes, que inclui dados e métodos comportamentais. Os agentes geralmente representam pessoas ou grupos de pessoas, os seus relacionamentos representam processos de interação social.

Segundo Macal e North (2010), o comportamento singular de um único agente não representa fielmente a realidade, mas que a soma de todos os comportamentos locais corresponde a uma boa representação do comportamento real do grupo. “Os agentes interagem ao longo do processo de convivência no mesmo ambiente, de modo que a configuração final do ambiente se modela de acordo com a qualidade e quantidade de interações individuais, ou seja, é gerado um macro-fenômeno ambiental com base em interações locais simples, em que cada indivíduo interage com seus pares, sem a existência de um controle central a mediar as interações”. (Zimbres, 2006)

Um agente autônomo atua por conta própria, sem direção externa em resposta a situações que o agente encontra durante a simulação. Modelando uma população de agentes autônomos, cada um com suas características e comportamentos, que interagem extensivamente é uma característica definidora de um ABM. O agente "é tudo o que pode ser capaz de perceber seu ambiente, por meio de sensores e de agir sobre esse ambiente por intermédio de atuadores" (RUSSELL e NORVIG, 2004, p. 33). Eles utilizam de sensores para receber os dados do ambiente e de atuadores para interagir com o ambiente e com os agentes.

Executar um modelo baseado em agente é fazer com que os agentes executem repetidamente seus comportamentos e interações. Este processo é frequentemente, mas não necessariamente, modelado para operar ao longo de uma linha do tempo, baseada em atividade ou evento. A estrutura surge das interações dos agentes e pode ser diretamente modelada, com uma dinâmica que muda e se desenvolve através dos agentes.

Segundo Macal et al (2014), os agentes tem as seguintes características:

1) Autonomia: Um agente é autônomo e autodirigido. Um agente pode funcionar independentemente em seu ambiente e em suas interações com outros agentes, geralmente a partir de uma gama limitada de situações que são de interesse e que surgem no modelo. Quando nos referimos ao comportamento de um agente, nos referimos a um processo geral que liga as informações que o agente percebe de seu ambiente e interações com suas decisões e ações.

2) Modularidade: Os agentes são modulares ou independentes. Um agente é uma entidade discreta identificável com um conjunto de características ou atributos, comportamentos e capacidade de tomada de decisão. O requisito de modularidade implica que um agente tem uma fronteira, e pode-se facilmente determinar se algo (ou seja, um elemento do estado do modelo) faz parte de um agente ou não faz parte de um agente, ou é uma característica compartilhada entre agentes.

3) Socialidade: Um agente é social, interagindo com outros agentes. Protocolos de interação de agente comum incluem contenção por espaço e prevenção de colisão, reconhecimento de agente, comunicação e informação troca, influência e outros mecanismos específicos de domínio ou aplicativo.

4) Condicionalidade: Um agente tem um estado que varia com o tempo. Assim como um sistema tem um estado que consiste em coleção de suas variáveis de estado, um agente também tem um estado que representa sua condição, definido pelo variáveis essenciais associadas à sua situação atual. O estado de um agente consiste em um conjunto ou subconjunto de seus atributos e seus comportamentos. O estado de um modelo baseado em agente é o estado coletivo de todos os agentes junto com o estado do meio ambiente. Os comportamentos de um agente são condicionados

ao seu estado. Como tal, o quanto mais rico o conjunto de possíveis estados de um agente, mais rico o conjunto de comportamentos que um agente pode ter.

5) Para Macal e North (2005), o agente se apresenta como ser identificável devido a um conjunto de características e regras que governam seu comportamento e sua capacidade de tomada de decisões; por habitar em um ambiente com o qual interage e também no qual interage com outros agentes; por ser orientado por objetivos; por ser autônomo e por ser flexível e possuir habilidade para aprender e adaptar seu comportamento através do tempo baseado em experiências.

2.2 Estudos Relacionados

Vários trabalhos surgiram usando ABM como o modelo "Santa Fe Artificial Stock" desenvolvido na década de 1990 no Instituto Santa Fé (Palmer et al., 1999; LeBaron, 2002; Ehrentreich, 2003). O Instituto Santa Fé fundado em 1984 e foi o primeiro instituto de pesquisa dedicado ao estudo de sistemas adaptativos complexos. Operando como um centro de educação e pesquisa independente e sem fins lucrativos.

De acordo Le Baron (2002), o modelo de bolsa de valores é idealizado com agentes heterogêneos e com comportamento imperfeitamente racional, com objetivo de maximizar ganhos, fazendo decisões de acordo com a previsão do mercado futuro e de acordo com as suas expectativas ao longo do tempo. No modelo é visto que os comportamentos são similares aos observados no mercado financeiro.

O mercado de valores artificial do Instituto, segundo Palmer et al. (1994), teve como características principais:

1) mapeamento dos estados de possibilidades em decisões de compra e venda;

2) funcionamento de mercado com preço sendo anunciado por agente de mercado (market maker)

3) casamento de ordens de acordo com as condições do mercado

4) atuação dos agentes no mercado com ordem de compra e venda de uma ação.

Em LeBaron et al. (1999), apresenta resultados de uma simulação de mercado de ações. Os algoritmos de inteligência artificial assumem o papel de traders, fazendo previsões sobre o futuro e comprando e vendendo ações conforme suas expectativas de risco futuro e retorno. Foi visto que o mercado simulado é capaz de replicar vários fenômenos, incluindo previsibilidade fundamental e técnica, persistência da volatilidade e leptocurtose. Os agentes também são capazes de aprender coletivamente, fornecendo séries temporais e valores de previsão individuais consistentes com os valores dos parâmetros.

Em Wellman (2017), descreve como uma simulação utilizando a modelagem baseada em agente pode ser combinada com o raciocínio teórico para examinar os efeitos das variáveis de mercado nos resultados de interesse. A abordagem é ilustrada em um modelo básico onde os investidores negociam um único título por meio de um duplo e contínuo no mecanismo de leilão. Os resultados apresentam uma boa viabilidade.

Em Souissi et al (2018),é apresentado um modelo é baseado no caso de um único ativo e três tipos de agentes investidores. Cada investidor pode ser um investidor iniciante, investidor fundamentalista e investidor estruturalista. Notou-se que a estabilidade do mercado é fortemente impactada pela distribuição de tipos de investidores e a introdução de mecanismo de imitação.

2.3 Revisão bibliométrica descritiva

As buscas foram realizadas na base de dados Web of Science, realizadas de 1996 a 2021, usando de uma estratégia de busca com operador “and” e palavras chaves “agent-based modeling” “stock market” em todos os campos. Para padronizar os resultados do banco de dados, a busca restringiu redefinido por tipos de documentos limitaram-se a artigos. Nenhuma restrição foi colocada em campos científicos e de linguagem. Após a realização da pesquisa, os artigos aptos foram selecionados e armazenados.

Os registros foram baixados e importados através da própria base da Web of Science. A análise foi realizada nesse software e no Microsoft Excel, usado para tabular e analisar arquivos de texto gerados. Os autores foram classificados por seu índice h (descreve a produtividade e o impacto do trabalho, (VAN RAAN, 2006)) com base em artigos de pesquisas em bancos de dados.

A busca retornou um total de 70 artigos. O ano que recebeu maior de publicações foi 2015, com 9 artigos. O artigo com mais citações foi de Macal e North (2005) - Tutorial on agent-based modeling and simulation- publicado na Proceedings Of The 2005 Winter Simulation Conference, Vols 1-4. Esse artigo fornece uma breve introdução ao ABMS, ilustra os principais conceitos e fundamentos, discute alguns aplicativos recentes em uma variedade de disciplinas e métodos e kits de ferramentas corrompidos para o desenvolvimento de modelos de agente. Foram 315 citações até junho de 2021.

O segundo artigo mais citado, foi Macal e North (2009) - Agent-based Modeling And Simulation - publicado Proceedings Of The 2009 Winter Simulation Conference (Wsc 2009), Vol 1-4, com 143 citações. Na sequência, do mesmos autores Tutorial on agent-based modeling and simulation part 2: How to model with agents, publicado em Proceedings Of The 2006 Winter Simulation Conference, Vols 1-5, com 139 citações. Entre os 10 artigos mais citados, seis são dos autores Macal e North. Os autores com mais publicações foram, novamente, Macal e North que contemplam 7 artigos, escritos em conjunto e YEH CH também com sete artigos publicados nos anos selecionados.

O índice H, caracteriza a produtividade e o impacto do trabalho de pesquisa, mostra valor de 17. O país com maior número de publicações foi China, seguido por Estados Unidos da América e Taiwan.

3 Metodologia

A metodologia desta dissertação envolve duas etapas:

Simulação de um mercado de ação artificial através do ambiente do Netlogo. Serão definidos parâmetros iniciais para execução do modelo baseado em agentes transformando em um ambiente para interação dos agentes. Um dos objetivos do trabalho é simular o mercado de ações de acordo com o comportamento de investidores. O investidor, ao comprar uma ação, interage com o mercado e seu comportamento no futuro irá depender da evolução do mercado.

Análise do poder preditivo do modelo, através de testes e comparação com modelo de previsão já existente.

Para o estudo, deu-se resultados numéricos usando modelagem multiagente a qual é a mais adequada para um sistema complexo como um mercado de bolsa de valores (Souissi et al., 2018). Modelos analíticos geralmente não permitem considerar vários fatores, especialmente da decisão dos investidores.

Esta pesquisa é identificada como descritiva, a qual tem a função de descrever determinada situação, onde observa, registra, analisa e correlaciona fatos ou fenômenos.

3.1 NetLogo

NetLogo é um ambiente, com recurso da programação, para fazer simulações baseadas em agentes, modelando assim fenômenos que envolvem vários agentes operando de forma independente. Foi criado por Wilensky (1999) e é usado para modelar sistemas complexos e estudar seu comportamento ao longo tempo. Possui linguagem de programação própria e uma interface visual que permite o acompanhamento das simulações.

Para usar a modelagem de vários agentes, temos que modelar diferentes elementos, como:

Condições iniciais do sistema;

Regras comportamentais dos agentes (interações, aprendizado, adaptação);

Regras para o desenvolvimento do meio ambiente;

Diferentes propriedades e características do sistema.

Utiliza-se a expressão ambiente para o lugar onde os agentes permanecem. Os agentes são divididos em 4 tipos dentro do ambiente:

Patches: agentes que não podem se mover e tem coordenadas. O patch nas coordenadas (0, 0) é chamado de origem e o as coordenadas dos outros patches são as distâncias na horizontal e na vertical do patch de origem.

Turtles: são agentes que se movem pelo mundo enquanto seguem as instruções. Eles também têm coordenadas, sendo originadas por patches ou pelo observador.

Links são agentes que conectam dois turtles. Se um turtle morrer, o link morre

também. Eles não têm coordenadas.

O observador é um agente externo. Pode interagir com o mundo criando ou destruindo agentes, atribuindo propriedades para os agentes.

Na guia de Código, através de diversos comandos, pode-se executar comandos ou repórteres como procedimentos para os agentes. Esses comandos podem ser específicos para cada agente ou executados por várias categorias de agentes. Comandos primitivos podem ser encontrados no dicionário do programa.

Comandos são ações que devem ser realizadas por um agente ou conjunto de agentes, resultando em algum efeito. Outro procedimento de condução dos agentes são os repórteres que são instruções para calcular um valor, pode ser usado dentro de um comando como uma condição. Comandos primitivos importantes são aqueles que controlam o fluxo como if, ifelse ou stop e todos os comandos lógicos como and ou or.

As variáveis são lugares para armazenar valores em um agente. Existem variáveis globais, de turtles, de patch ou link, sendo primitivas ou configuradas pelo observador.

3.2 Modelo de Mercado de Ações

O modelo utilizado para gerar a modelagem é o *Collective Behavior in the Stock Market*, criado por Silva (2014). Ele simula a evolução de um único preço de ação através de determinado tempo. Os agentes que são representados por investidores que negociam no mercado de ações com base em suas decisões individuais. A base de criação do modelo foram os seguintes autores: Shiller (2000), Kahneman (1974 e 1992), Couzin (2005).

Em Shiller (2000), apresenta evidências sobre dois tipos investidores com atitudes que mudam de maneiras diversas ao longo do tempo, com consequências importantes para os mercados especulativos. Com base nos resultados dos questionários aplicados no período, o autor desenvolve indicadores de séries temporais específicos para cada um dos seguintes: uma bolha especulativa, uma bolha especulativa negativa e confiança do investidor. Usando os indicadores, o autor produz uma porcentagem média da população em um determinado momento com expectativas de bolha, expectativas de bolha negativas e confiança do investidor, respectivamente.

Em Kahneman e Tversky (1974), é apresentado uma relação dos erros de heurística e em Kahneman e Tversky (1992), é revisada a Teoria do Prospecto que estende a teoria em vários aspectos. Dois princípios, diminuição da sensibilidade e aversão à perda, são invocados para explicar a curvatura característica da função de valor e das funções de ponderação. Resultando assim na aversão ao risco para ganhos e busca de risco para perdas de alta probabilidade; busca de risco por ganhos e aversão ao risco por perdas de baixa probabilidade.

O artigo de Couzin (2005), estabelece um modelo simples que demonstra como as informações podem ser transferidas dentro dos grupos sem sinalização e quando os

membros do grupo não sabem quais entes, se houver, possuem informações. É observado, que quanto maior o grupo, menor a proporção de indivíduos informados é necessário para orientar o grupo, e que apenas uma proporção pequena desses é necessária para atingir grande precisão. Também é observado como os grupos podem tomar decisões em consenso, mesmo que os membros informados não saibam se são maioria ou minoria e como a qualidade de suas informações se compara com a de outros, ou mesmo se existem outros entes com tal capacidade. O modelo fornece novos insights sobre os mecanismos de liderança e tomada de decisão eficazes em sistemas biológicos.

3.2.1 Premissas do modelo

De acordo com o modelo de Silva (2014), o mercado é constituído por dez mil agentes, distribuídos em um grid bidimensional (cem x cem). Cada agente possui uma rede e cada agente tem a oportunidade de inserir uma ordem para comprar ou vender, de uma unidade, uma ação.

Para entrada no mercado, o agente consulta a informação dos investidores que estão ao seu redor. Cada investidor pode fornecer três informações distintas: compre, venda ou não faça nada. Essas informações serão baseadas no último movimento realizado. Por exemplo, se o investidor vizinho realizou uma venda no período anterior ele irá fornecer à informação: venda. O agente ainda utiliza sua própria informação, sendo que a regra é a mesma utilizada na consulta dos vizinhos. A sua rede de informação será de oito agentes na localização geográfica no grid. Após o agente entrar no mercado ele não utiliza sua rede de vizinhos para decidir quando sair.

$$\psi_{it} = \begin{cases} \upsilon_{it}, \text{se possuir ativo} \\ \gamma_{it}, \text{se não possuir ativo} \end{cases} \tag{3.1}$$

Resumindo a equação do modelo de Silva (2014): são duas formas de comportamento dos agentes, uma quando os agentes possuem ações e outra quando os agentes não possuem ações.

O investidor irá realizar sua próxima operação de acordo com sua meta. Cada agente possui uma "meta de rentabilidade". Enquanto que, alguns agentes possuirão uma meta bem pequena, outros irão pretender grandes ganhos. A meta que cada agente irá possuir será representada por x_i, $x_i > 0$, e x_i pode ser tão próxima de zero quanto se queira. Um número elevado de metas é equivalente a um mercado com grande heterogeneidade de expectativa.

O efeito disposição é um comportamento irracional observado nas decisões financeiras, o qual consiste na tendência dos investidores de manter posições perdedoras por muito tempo e vender ganhando posições muito cedo, observado assim na tomada de decisão

sob condições de incerteza e risco na compra e venda de ações. O efeito disposição pode ser explicado pela Teoria do Prospecto.

Kahneman e Tversky (1992), em suas análises de decisão sob incerteza, observram que o comportamento das pessoas é diferente nos domínios dos ganhos e perdas: aversão ao risco prevalece quando há ganhos e enquanto a busca de risco é relacionado principalmente nas perdas. Em Kahneman e Tversky (1974), teve como objetivo criar um modelo onde fosse possível verificar como o processo de tomada de decisão acontecia de fato. Verificaram então, que os investidores eram influenciados por ilusões cognitivas, ou seja, tendência a cometer erro sistemático no processo de decisão, que acaba por interferir no processo decisório. Resumidamente, os investidores tendem a vender rapidamente os investimentos quando estes sobem de preço após a compra e reter por muito tempo quando eles caem após a compra.

$$\upsilon_{it} = \begin{cases} x_i^{\alpha}, \text{se} & x_i \geq 0, ganhos, \\ -\lambda(-x_i)^{\alpha}, \text{se} & x < 0, perdas. \end{cases} \tag{3.2}$$

Essa equação foi proposta por Tversky e Kahneman (1991) e o valor de λ=2.25 foi encontrado empiricamente em $\alpha \in (0, 1)$. De acordo com o modelo de Silva (2014), o investidor através do seu resultado acumulado, irá observar a sua utilidade, ou seja, a partir do valor atual da ação comparada ao valor inicial da operação. Cada agente possuirá um resultado acumulado x_{it} referente à operação corrente. Sempre que $|x_{it}| > |\upsilon_{it}|$o agente estará apto a encerrar sua operação e sair do mercado, ou seja, voltar a ter o saldo de zero ações em sua carteira.

Para modelar este comportamento, no modelo, os agentes influenciados pelo efeito de disposição apenas fecharão uma posição negativa se houver uma variação de preço maior que 2,25 vezes seu valor individual retorno esperado. Uma vez que os agentes fecham posições com lucro quando o resultado excede o retorno esperado independentemente da tendência dos preços. Após atingir o valor que a Equação da Teoria do Prospecto fornece, o agente não negocia de forma determinística, mas entramos na zona de probabilidade em que nosso agente pode negociar. Como falado acima, o valor de 2,25 é a estimativa, com base em experimentos feitos por Tversky e Kahneman (1991) de um parâmetro da função de valor usada na Teoria do Prospecto.

De acordo com Silva (2014), quando o agente possui zero ações, ele possuirá uma probabilidade de entrar e essa probabilidade irá depender de quantos de seus vizinhos estão fornecendo informação de compra (b_{jt}), venda (s_{jt})

$$\gamma_{it} \begin{cases} \gamma_{it}^{b}, \text{probalidade de comprar;} \\ \gamma_{it}^{8}, \text{probalidade de vender,} \end{cases} \tag{3.3}$$

$$\gamma_{it}^{b} = \frac{\sum_{j=1}^{8} b_{jt} + \omega O_{it}^{b}}{8 + \omega}, \tag{3.4}$$

$$\gamma_{it}^{8} = \frac{\sum_{j=1}^{8} s_{jt} + \omega O_{it}^{8}}{8 + \omega}. \tag{3.5}$$

Ainda, o agente possui informação própria de compra será O_{it}^{b}; de venda O_{it}^{8}. O termo que pondera a informação própria do agente ($O\omega, \omega \geq 0$) é discutido no artigo de Couzin et al. (2005). Esse é usado para calcular as probabilidades para fazer uma compra ou uma venda, adicionando um termo que quantifica o mercado global. Como falado anteriormente, Couzin (2005) modelou como a informação é transferida dentro de grupos de animais quando os membros do grupo não sabem quais indivíduos, se houver, possuem informações. Nesse artigo, ele também considerou as preferências dos indivíduos que têm mais informações do que outras, situação comum no mercado de ações.

Para gerar uma demanda (D_t), os agentes fornecem ordens de compra e de venda. Somando todas as ordens de compra (B_t)e todas as vendas (S_t) e dividindo pelo total (N_t) chegamos a uma equação para o excesso de demanda no período t:

$$D_t = \frac{B_t - S_t}{N_t}. \tag{3.6}$$

Para a variação de preço, o Silva (2014) utilizou a proposta de Plerou et al. (2002) através da equação abaixo, onde o preço inicial do ativo é arbitrário. Para o período t = 0, o primeiro da simulação, realizaremos uma distribuição aleatória de ordens de compra e venda para nossos agentes.

$$p_t = p_{t-1}(1 + tanh(D_t)). \tag{3.7}$$

Para a expectativa do mercado (situação de *bull* ou *bear market*), foi definido um índice I. O índice será criado questionando os agentes; em determinado o período t, levantando quantos agente acreditam que o preço irá subir e quantos acreditam que os preços irão cair; caso o agente tenha enviado uma ordem de compra é computado como crença em elevação de preço, se enviou uma ordem de venda o agente expressa opinião de que os preços devem cair:

$$I = \frac{(B - S)}{N} \tag{3.8}$$

O I será calculado a cada cinquenta períodos. Essa expectativa do mercado é absorvida de forma diferente pelos agentes: alguns poderão atribuir elevada importância a essa informação, enquanto que outros darão pouco valor a ela. Quando I for positivo ele irá aumentar a possibilidade do agente ofertar uma ordem de compra e reduzirá a chance dele inserir uma ordem de venda, e vice versa.

Outra questão aplicada ao modelo, é uma ferramenta chamada *stop*. Alguns investidores ao decidirem quando comprar e quando vender procuram seguir um plano e evitar que suas emoções atrapalhem os negócios. O agente que utilizar regras stop irá permanecer

fora do mercado até que o computador dispare sua ordem de compra. Essa ordem será emitida sempre que o último retorno da ação, rt , ultrapassar uma marca limite (δ_i). O x_i representa a meta do agente.

$$P_{it} = \begin{cases} \text{comprar se,} & r_t > \delta_i; \\ \text{não op. se,} & -x_i \leq X_i t \leq \lambda x_i \\ \text{vender se,} & X_{it} < 0 \text{e} X_{it} < -x_i; \\ \text{vender se,} & X_{it} > 0 \text{e} X_{it} > \lambda x_i. \end{cases} \tag{3.9}$$

Para os investidores com a opção de stop, a lógica utilizada foi de proteção das posições acionando uma ordem de mercado se o preço excede um certo nível. As ordens são feitas com base na suposição, de que, se o preço cair ou aumentar em um determinado valor, pode continuar a cair ou aumentar muito mais, então a perda ou ganho é limitado pelo fechamento a posição. A ação tem um valor fixo único como limite, sendo a porcentagem do investimento que esse agente aceitará como perda. O agente se comporta de acordo com a Teoria do Prospecto, então ele sofre mais com as perdas do que com os ganhos.

É possível observar que cada investidor pode ter sua própria estratégia de entrada no mercado, mas supõe-se apenas uma estratégia para todos. Através de uma estratégia de ideia de comportamento coletivo, indicado pelo fator ômega, investidores com tendência a maior ou menor movimentação de compras e vendas.

3.3 Análise Comparativa

Uma série temporal é formada por uma variável a medida sequencialmente no tempo em um intervalo fixo. As principais características de muitas séries temporais são tendências e efeitos sazonais. Se estes padrões são determinísticos, eles podem ser modelados com funções de tempo por modelos.

Série temporal = {y1, y2, y3,. . . yt}

De acordo Morrettin & Toloi (1987), uma série temporal é qualquer conjunto de observações ordenadas no tempo. Sendo compostas por quatro elementos:

1. Tendência: verifica o sentido de deslocamento da série ao longo de vários anos.

2. Ciclo: movimento ondulatório que ao longo de vários anos tende a ser periódico.

3. Sazonalidade: movimento ondulatório de curta duração, em geral, inferior a um ano; associada, na maioria dos casos, a mudanças climáticas.

4. Ruído aleatório ou erro: compreende a variabilidade intrínseca aos dados e não pode ser modelado.

Porém, em alguns casos, suas tendências não podem ser explicadas por uma razão ou ocorrem mudanças imprevisíveis, sendo aleatórios ou estocásticas. Processo estocástico é um conjunto de variáveis aleatórias que, em geral, são utilizadas para estudar

a evolução de fenômenos (ou sistemas) que são observados ao longo do tempo. Isso ocorre principalmente na economia e no mercado de ações.

A análise de série temporal é o grupo de métodos estatísticos usado para entender os processos por trás das séries temporais, fazer um modelo deles e, além disso, prever valores futuros com base nos dados atuais.

Box e Jenkins (1976) usaram uma metodologia para construir modelos ARIMA *(Auto Regressive Integrated Moving Averages)* que se tornou a base da análise de séries temporais. Essa análise observa que cada valor da série pode ser explicado por valores prévios, a partir do uso da estrutura de correlação temporal que geralmente há entre os valores da série.

Segundo Fava (2000), os modelos ARIMA resultam da combinação de três componentes: o componente auto-regressivo (AR), o filtro de integração (I) e o componente de médias móveis (MA). Esses três componentes são denominados “filtros”. Uma série pode ser modelada pelos três filtros ou apenas um subconjunto deles.

Segundo Morretin & Toloi (1987), a construção dos modelos Box-Jenkins é baseada em um ciclo iterativo, no qual a escolha do modelo é feita com base nos próprios dados. Para a construção do modelo, Box e Jenkins (1976) sugeriram as seguintes três etapas principais:

Identificação: consiste na seleção de um modelo que se enquadre uma série de tempo observada. Isso significa descobrir em qual, dentre as várias versões dos modelos de Box-Jenkins, sejam eles sazonais ou não, descreve o comportamento da série. A identificação do modelo a ser estimado ocorre pelo comportamento das funções de autocorrelações (ACF) e das funções de autocorrelações parciais (PACF).

Adaptação: construir um modelo em que é possível calcular a melhor estimativa possível dos parâmetros incluídos no modelo selecionado. Consistindo assim em estimar os parâmetros do componente auto-regressivo, os parâmetros do componente de médias móveis e a variância.

Diagnóstico: avalia a qualidade do modelo que especificamos e estimado e se é adequado para descrever o comportamento dos dados.

Caso o modelo não seja o adequado, o ciclo é repetido, voltando-se à fase de identificação. Um procedimento muito utilizado é identificar não só um único modelo, mas alguns modelos que serão então estimados e verificados. Quando se obtém um modelo satisfatório, passa-se para a última etapa da metodologia de Box-Jenkins, que constitui o objetivo principal da metodologia: realizar previsões.

Validado o modelo, pode-se construir uma função de previsão, proporcionando as previsões prováveis dentro do horizonte de período especificado.

Utilizaremos o programa Stata para análise, com procedimentos necessários para a identificação e ajuste do modelo.

3.4 Escolha do modelo

O teste *Direcional Accuracy (DA),* de Pesaran eTimmermann (1992), é um teste de previsão direcional que foca corretamente prever a direção da mudança nas variáveis consideradas.

$$DA = \frac{1}{n}\sum_{t=1}^{n} a_i \tag{3.10}$$

Em que $ai = 1 \Rightarrow (y_{i+1} - y_i)(\hat{y}_{i+1} - y_i) > 0; a_i = 0$

A hipótese nula é que não há relação entre as mudanças direcionais reais e previstas. O procedimento é com distribuição gratuita e com base na proporção de vezes que a direção da mudança está correta previsto na amostra, conforme especificado em Pesaran e Timmermann, (1992). Há um número de teorias econômicas que sugerem a previsão de mudanças direcionais podem ser eficazes.

Granger e Pesaran (2000) discutem que as relações entre medidas estatísticas e econômicas da precisão da previsão e enfatizam que a escolha da medida de avaliação deve estar relacionada aos objetivos do usuário da previsão. Avaliando a precisão direcional (DA) do previsto instruções podem fornecer informações valiosas sobre a avaliação de previsões.

3.5 Processo Empírico

As séries temporais utilizadas como valores iniciais e comparação para o modelo são ITUB4 – Banco Itaú; EMBR3 – Embraer; CMIG4 – Cia Energética de Minas Gerais; EGIE3 - Engie Brasil e BRKM5 - Braskem. Foram escolhidas aleatoriamente em cotações diárias, com data de início 05/06/2019 e da data de fim: 17/08/2020. Foram feitas 300 observações de acordos com as entradas no programa.

Inicialmente, o usuário na interface Netlogo define estes parâmetros globais (em todas as simulações), foram designadas as seguintes variaveis:

O preço inicial do ativo é arbitrário *["P_initial"]* .

Para o período t = 0, o primeiro da simulação, realizaremos uma distribuição aleatória de ordens de compra e venda para nossos agentes.

Cada agente irá receber: um valor individual para β (será sorteado de uma distribuição uniforme, cada agente possuirá o mesmo β por toda a simulação); um valor individual para δ ; um valor para sua meta *[x_max]* (mais de um agente receberá o mesmo valor); e um valor para o ω *["omega"]* (todos possuirão o mesmo valor).

Os agentes serão distribuídos entre os grupos que utilizarão ordens STOP *["STP"]* e agentes que não utilizarão, de acordo com a proporção desejada. O Index *["Index"]* insere a opção índice de mercado, pode-se usar ou não na equação de nossos agentes a

expectativa de mercado. A função Randon? *["Random?"]* indica o uso ou não de que cada nova simulação as sementes que geram os números pseudo aleatórios.

Tabela 1 – Parâmetros de entrada das melhores simulações de ação

	ITUB4	EMBR3	CMIG4	EGIE3	BRKM5
x_max	0.05	0.15	0.05	0.05	0.05
PTI	0.3	0.3	0.3	0.3	0.3
omega	1	1	10	10	1
Index	false	true	false	true	false
STP	0.1	0.1	0.1	0.1	0.1
P_initial	32.33	18.46	17	44.31	33.17
Random?	true	true	true	true	true

Fonte: Elaboração da autora

Tabela 2 – Resultado teste *Direcional Accuracy (DA)*

	EGIE3	BRKM5	CMIG4	ITUB4	EMBR3
Estatística do Teste	4.0454466	3.5791900	3.2504482	3.1955812	2.8065687
p-value	0.0000261	0.0001723	0.0005761	0.0006977	0.0025036
alpha	0.05	0.05	0.05	0.05	0.05
sig	SIGNIFICATIVO	SIGNIFICATIVO	SIGNIFICATIVO	SIGNIFICATIVO	SIGNIFICATIVO

Fonte: Elaborado pela Autora

Para cada ação foram simulados 5400 modelos, considerando essas condições iniciais diferentes (inputs).

A seleção dos modelos foi feita através do teste Direcional Accuracy de Pesaran-Timmerman (2006), será selecionado o que apresentou menor ρ-value, comparando o valor gerado pelo modelo, contra o valor observado da ação.

Para a melhor simulação encontrada dentro as ações, será realizado o algoritmo ARIMA para comparação.

4 Resultados

Este capitulo apresenta . Foi usado o modelo de mercado de ações descrito no capítulo 3, a fim de obter séries temporais. No capítulo atual, irá aplicar-se as metodologias, os procedimentos e as ferramentas discutidas anteriormente neste trabalho para os dados observado.

A data de início foi 05/06/2019 e da data de fim: 17/08/2020. Foram feitas 299 observações de acordos com as entradas no programa. Para cada ação foram simulados 5400 modelos para cada valor de ação, considerando condições iniciais diferentes. Foi selecionado o modelo que apresentou menor ρ-value (teste 5%) - teste *Direcional Accuracy (DA)* - comparando o valor gerado pelo modelo, contra o valor observado da ação.

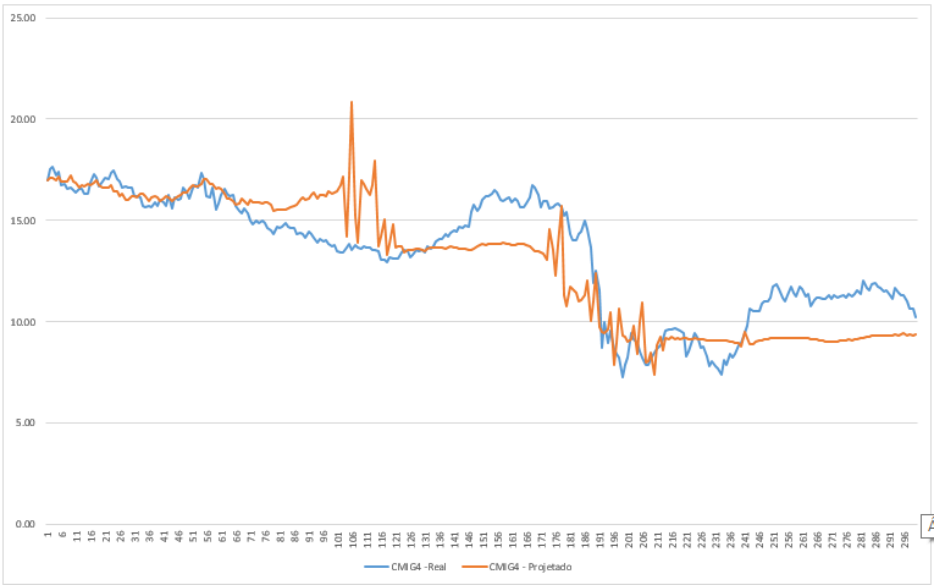
A tabela 1 mostra uma execução representativa do processo de simulação, com n = 10.000 agentes, limite de retorno esperado r max , ω max e e *index*. Além disso, a proporção de investidores afetados pelo efeito de disposição para investidores usando ordens de stop (stp). O preço inicial é definido com valor inicial da ação no dia 05/06/2019, embora não afete o modelo dinâmica.

É observado que, em todos os casos o máximo de agentes que operaram utilizando estratégia de *STOP* são 10%. A função *Index* (opção índice de mercado) foi usada em 3 das 5 simulações, que insere na equação de nossos agentes a expectativa de mercado.

4.1 Simulações realizadas

O gráfico da figura 3 mostra uma execução representativa do processo de simulação da ação CMIG4. A simulação número 3225 apresentou menor p-value comparado aos demais. Os parâmetros utilizados para iniciar são: Limite de retorno esperado x_max = 0,05 e omega = 10. Além disso, a proporção de investidores afetados pelo efeito de disposição para investidores usando ordens de stop são 10%.

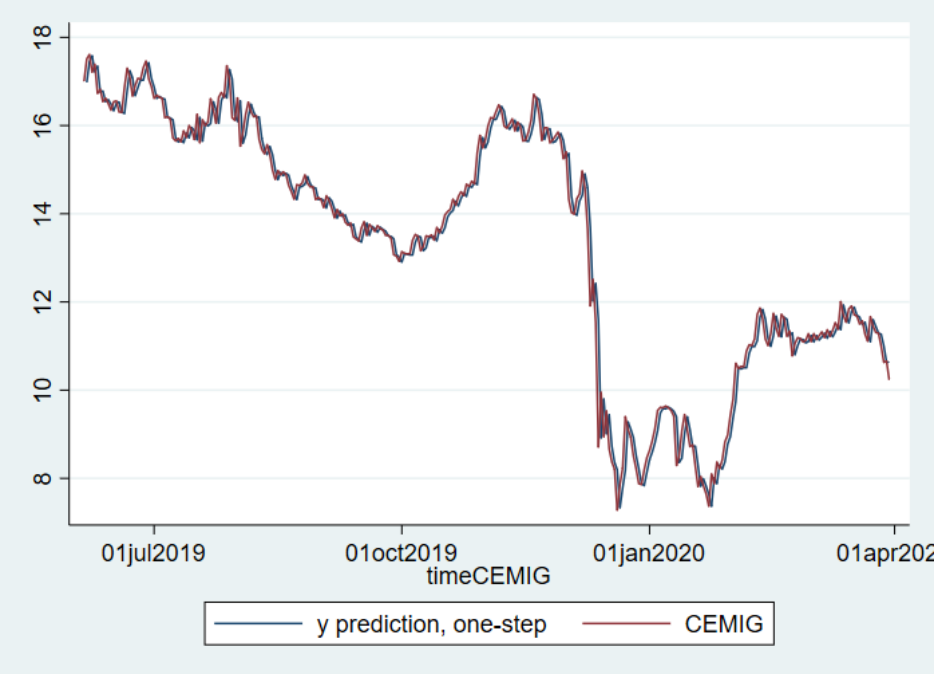
Figura 2 – Simulação ABM CMIG4



Fonte: Elaboração pela autora

Pelo teste DA (5%), apresentou menor p- value, mas ainda é observado alguns pontos um descolamento da tendência, com uma certa volatilidade. O modelo utilizado para comparação é a previsão modelo ARIMA (1,1,1), representado na figura 4.

Figura 3 – Previsão ARIMA CMIG4

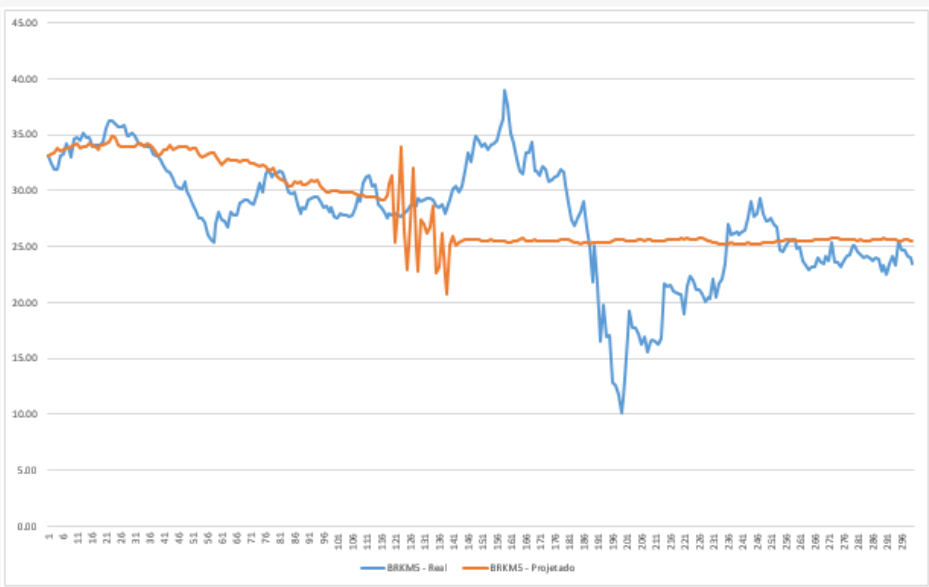


Fonte: Elaboração pela autora

O gráfico na figura 5 mostra uma execução representativa do processo de simulação da ação BRKM5 . A simulação número 2751 apresentou menor p-value comparado aos

demais. Os parâmetros utilizados para iniciar são: Limite de retorno esperado x_max = 0,05 e omega = 1. Além disso, a proporção de investidores afetados pelo efeito de disposição para investidores usando ordens de stop são 10%.

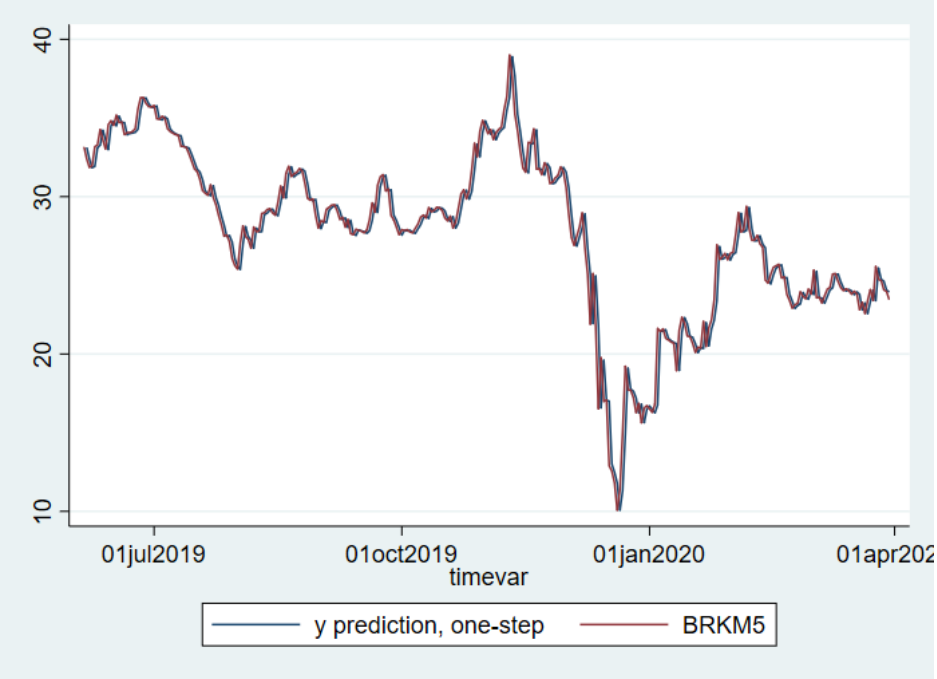
Figura 4 – Simulação ABM BRKM5



Fonte: Elaborada pela autora.

Pelo teste DA (5%), apresentou menor p- value, é observado vários inicalmente , com uma volatilidade no meio da série temporal. O modelo utilizado para comparação é a previsão modelo ARIMA (1,1,1), figura 6.

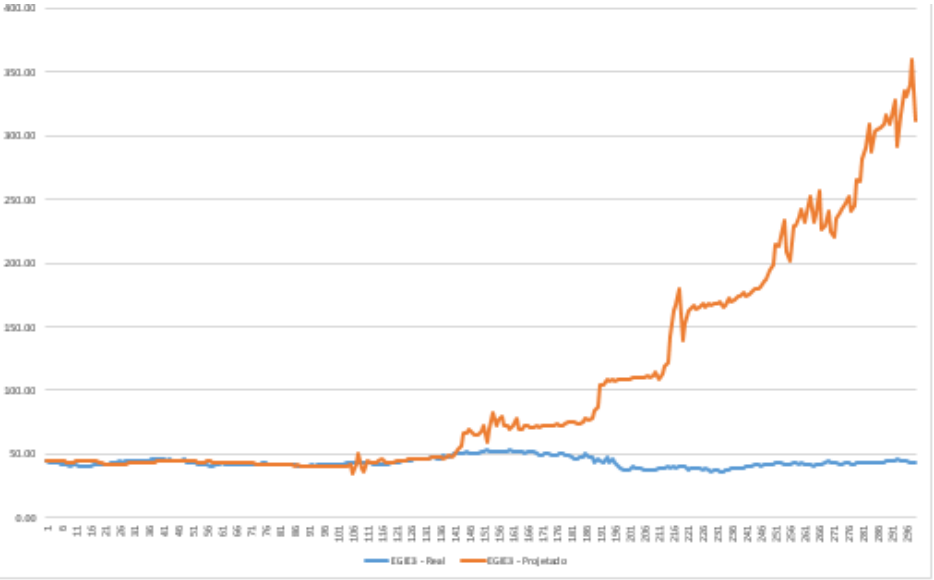
Figura 5 – Previsão ARIMA BRKM5



Fonte: Elaborada pela autora.

O gráfico na figura 7 mostra uma execução representativa do processo de simulação da ação EGIE3 . A simulação número 512 apresentou menor p-value comparado aos demais. Os parâmetros utilizados para iniciar são: Limite de retorno esperado x_max = 0,05 e omega = 10. Além disso, a proporção de investidores afetados pelo efeito de disposição para investidores usando ordens de stop são 10%.

Figura 6 – Simulação ABM EGIE3

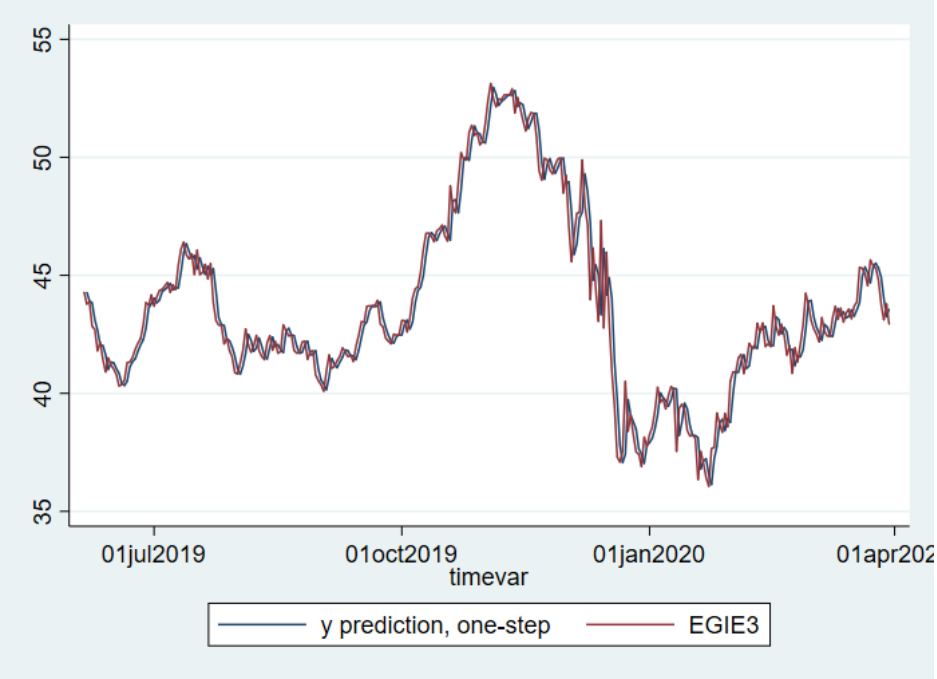


Fonte: Elaborado pela autora

Pelo teste DA (5%), apresentou menor p- value, é observado , inicialmente , com

ótima acuracidade direcional, mas a partir da 170 observação tem um deslocamento ascendente. O modelo utilizado para comparação é a previsão modelo ARIMA (1,1,1), figura 8.

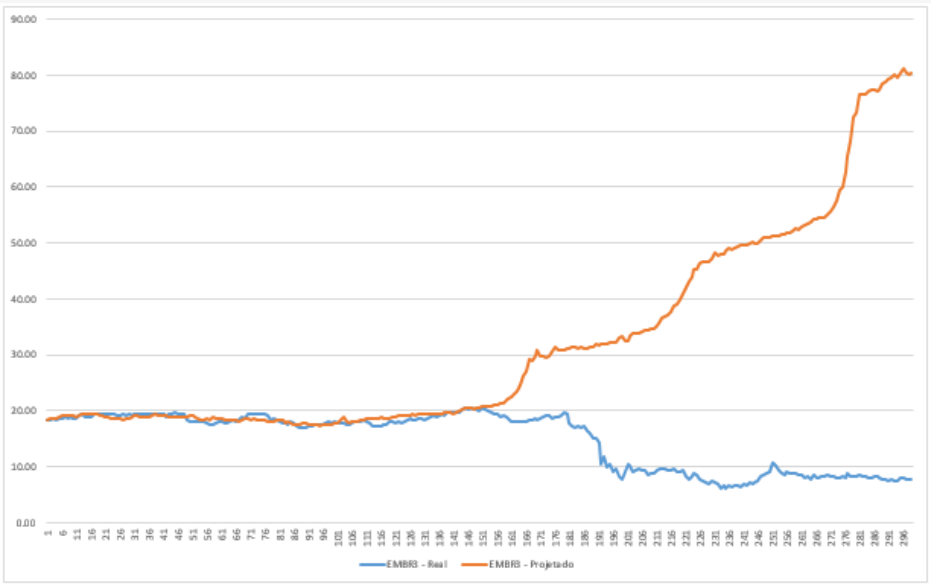
Figura 7 – Previsão ARIMA EGIE3



Fonte: Elaborado pela autora

O gráfico na figura 9 mostra uma execução representativa do processo de simulação da ação EMBR3 . A simulação número 1882 apresentou menor p-value comparado aos demais. Os parâmetros utilizados para iniciar são: Limite de retorno esperado x_max = 0,15 e omega = 1. Além disso, a proporção de investidores afetados pelo efeito de disposição para investidores usando ordens de stop são 10%.

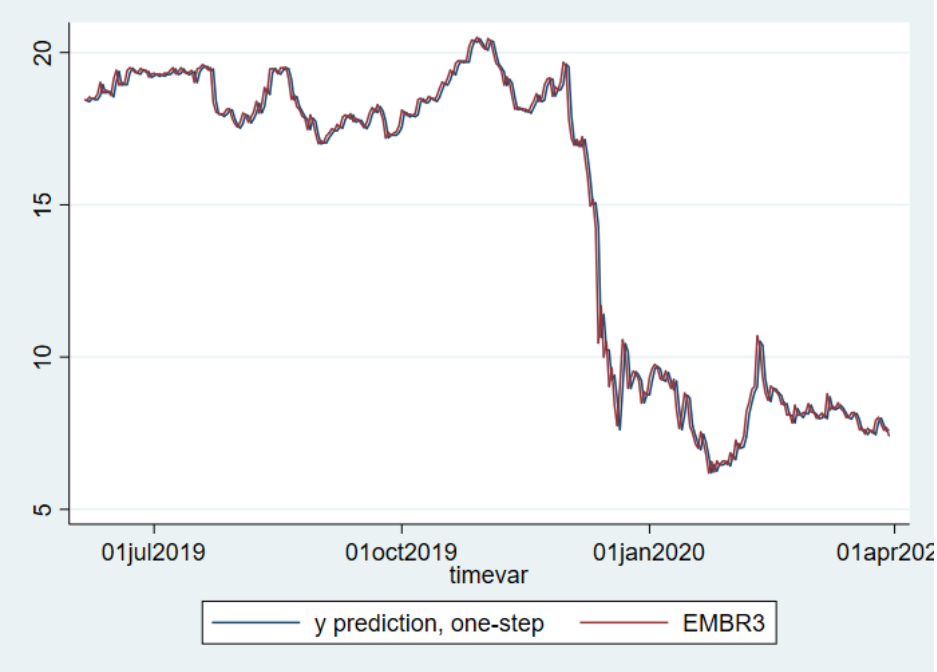
Figura 8 – Simulação ABM EMBR3



Fonte: Elaborado pela autora

Pelo teste DA (5%), apresentou menor p- value, é observado , inicialmente também, com ótima acuracidade direcional, mas a partir da 170 observação tem um deslocamento ascendente. O modelo utilizado para comparação é a previsão modelo ARIMA (1,1,1), figura 10.

Figura 9 – Previsão ARIMA EMBR3

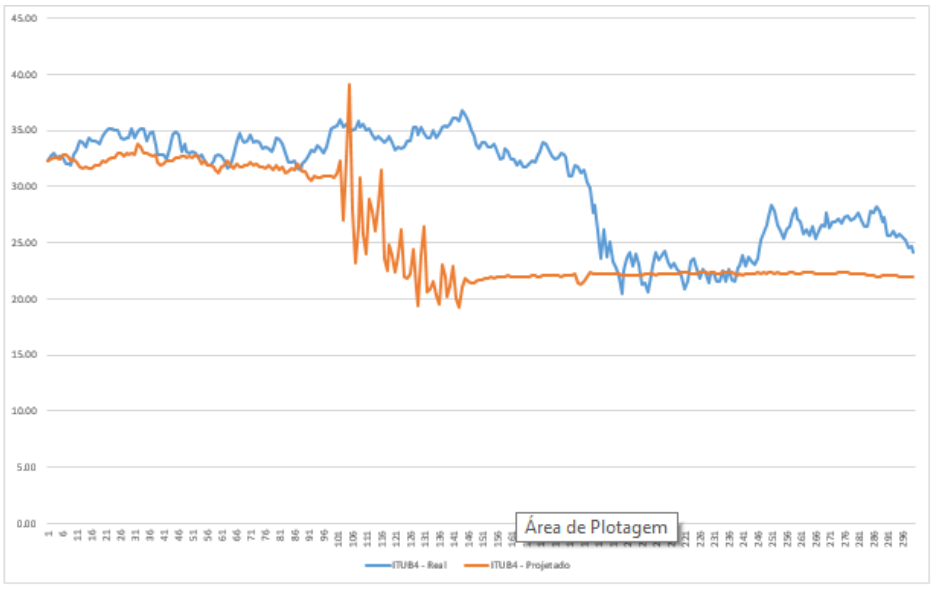


Fonte: Elaborado pela autora

O gráfico na figura 11 mostra uma execução representativa do processo de simulação da ação ITUB4 . A simulação número 2776 apresentou menor p-value comparado aos

demais. Os parâmetros utilizados para iniciar são: Limite de retorno esperado x_max = 0,05 e omega = 1. Além disso, a proporção de investidores afetados pelo efeito de disposição para investidores usando ordens de stop são 10%.

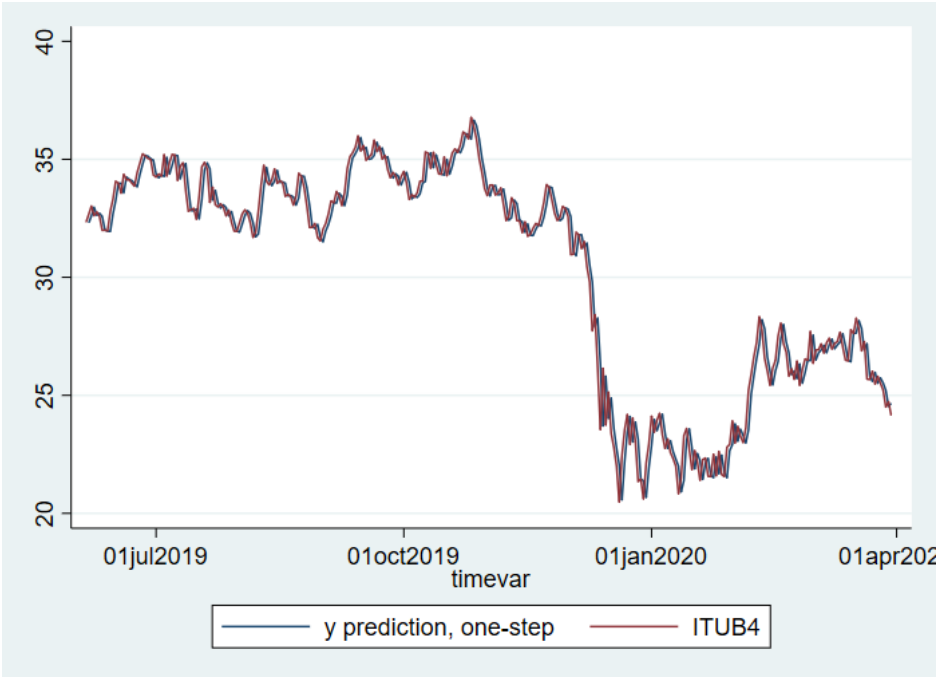
Figura 10 – Simulação ABM ITUB4



Fonte: Elaborado pela autora

Pelo teste DA (5%), apresentou menor p- value, é observado bastante volatilidade durante a série temporal. O modelo utilizado para comparação é a previsão modelo ARIMA (1,1,1), figura 12.

Figura 11 – Previsão ARIMA ITUB4



Fonte: Elaborado pela autora

5 Conclusões

Este trabalho apresentou como um modelo baseado em agentes pode ser desenvolvido e utilizado para a simulação um mercado financeiro através da modelagem de uma única ação. Foi mostrado um modelo desenvolvido em linguagem NetLogo. Sendo foi visto que as simulações baseadas em agentes são úteis para fazer modelos de sistemas complexos, como o mercado de ações, onde comportamento dos investidores, cada um dos quais atuando de forma independente, produz movimentos de preços.

As suposições feitas para a representação do mercado no desenvolvimento do modelo demonstraram-se suficientes para a obtenção de resultados iniciais satisfatórios, em comparação como modelos chamadas ARIMA, mas ainda não alcançaram a devida acuracidade dos modelos ARIMA, principalmente em simulações acima de 150 observações, evidenciando a importância da correta definição de parâmetros no lançamento para o modelo baseado em agentes.

É válido ressaltar que os testes aqui realizados se limitaram aos parâmetros e às condições propostas na Tabela 1 - Parâmetros de entrada das melhores simulações. Assim, nem todos os resultados são definitivos, podendo ainda sofrer variações para outras condições de entrada. Da mesma forma, algumas hipóteses não foram avaliadas ainda no âmbito do estudo, como a modificações do código fonte para melhorias. Essas alternativas serão testadas em trabalhos futuros.

Finalmente, pode-se considerar que o modelo averiguado apresentado neste trabalho cumpre bem o papel como uma ferramenta educacional simples que permite ampliar o entendimento sobre processos da modelagem baseada em agentes em mercados de ações.

Referências Bibliográficas

BALDWIN, W. & SAUSER, BRIAN & CLOUTIER, ROBERT. (2015). Simulation Approaches For System Of Systems: Events-Based Versus Agent Based Modeling. Procedia Computer Science. 44. 10.1016/J.Procs.2015.03.032.

BONABEAU, E. (2002) Agent-Based Modelling: Methods And Techniques For Simulating Human Systems, Proceedings Of The National Academy Of Sciences Of The Usa (Pnas), 99(3): 7280-7287.

BOX, G.; JENKINS, G. (1976) Time Series Analysis, Forecasting And Control. San Francisco: Holden-Day. 575 P.

CLARKE K.C. (2014) Cellular Automata And Agent-Based Models. In: Fischer M., Nijkamp P. (Eds) Handbook Of Regional Science. Springer, Berlin, Heidelberg. Https://Doi.Org/10.1007/978-3-642-23430-9_63

COUZIN, IAIN D., KRAUSE, JENS, FRANKS, NIGEL R., LEVIN, SIMON A. (2005). Nature, Vol. 433, P.513-516.

EHRENTREICH, N. (2003). A Corrected Version Of The Santa Fe Institute Artificial Stock Market Model (Complexity, 23). Retrieved From Https:// Philpapers.Org/Rec/Ehracv.

FARMER, J & FOLEY, DUNCAN. (2009). The Economy Needs Agent-Based Modeling. Nature. 460. 685-6. 10.1038/460685a.

FAVA, V. L.(2000) Manual De Econometria. In: Vasconcelos, M. A. S.; Alves, D. São Paulo: Editora Atlas.

FOLEY, D.K.(2003) Complexity, Self-Organization, And Political Economy. In: Unholy Trinity – Labor, Capital, And Land In The New Economy. London: Routledge.

HASSAN, SAMER & ARROYO, JAVIER & GALÁN, JOSÉ MANUEL & ANTUNES, LUIS & PAVÓN, JUAN. (2013). Asking The Oracle: Introducing Forecasting Principles Into Agent-Based Modelling. Journal Of Artificial Societies And Social Simulation, The. 16. 13. 10.18564/Jasss.2241.

KLÜGL, FRANZISKA & BAZZAN, ANA. (2012). Agent-Based Modeling And Simulation. Ai Magazine. 33. 29-40. 10.1609/Aimag.V33i3.2425.

LEBARON, B. (2002). Building The Santa Fe Artificial Stock Market (Working Paper, Graduate). School Of International Economics And Finance, Brandeis. Retrieved From Http://Citeseerx.Ist.Psu.Edu/Viewdoc/Summary?Doi=10.1.1.130.6439.

MACAL, C. M. & NORTH, M. J. (2006) “Tutorial On Agent-Based Modelling And Simulation Part 2: How To Model With Agents”, In Perrone, L. F., Wieland, F. P. Lawson, B. G., Nicol, D. M. And Fujimoto R. M., J. A. (Eds) Winter Simulation Conference.

MACAL, C. M. & NORTH, M. J. (2010)Tutorial On Agent-Based Modelling And Simulation. Journal Of Simulation, V. 4, P. 151-162.

MACAL, C. M. & NORTH, M. J. (2014) Product And Process Patterns For Agent-Based Modelling And Simulation, Journal Of Simulation, 8:1, 25-36, Doi: 10.1057/Jos.2013.4

MACAL, C. M. & NORTH, M. J.(2015) Introductory Tutorial: Agent-Based Modeling And Simulation. Proceedings - Winter Simulation Conference. 1451-1464. 10.1109/Wsc.2011.6147864.

MORIN, E. (1997) O Método I: A Natureza Da Natureza. Portugal: Europa-América.

MORRETIN, P. A.; TOLOI, C. M. C. (1987)Previsão De Séries Temporais. 2. Ed. São Paulo: Atual Editora.

PALMER, R. G., ARTHUR, W. B., HOLLAND, J. H. ET AL. (1999). An Artificial Stock Market. Artif Life Robotics, 3(1), 27-31. Https://Doi.Org/10.1007/Bf02481484.

SHILLER, R.J.,(2000) Journal Of Psychology And Financial Markets 1,49.

ROSSITER, S. AND NOBLE, J. AND BELL, K.R.W. (2010) Social Simulations: Improving Interdisciplinary Understanding Of Scientific Positioning And Validity. Journal Of Artificial Societies And Social Simulation, 13 (1). Issn 1460-7425.

SILVA, E. (2014). Collective Behavior In The Stock Market, Netlogo Modeling Commons. Http://Modelingcommons.Org.

SOUISSI, MOHAMED AMINE; KHALID BENSAID AND RACHID ELLAIA (2018). Multi-Agent Modeling And Simulation Of A Stock Market. Investment Management And Financial Innovations, 15(4), 123-134. Doi:10.21511/Imfi.15(4).10.

TODD, ANDREW & BELING, PETER & SCHERER, BILL & YANG, STEVE. (2016). Agent-Based Financial Markets: A Review Of The Methodology And Domain. 1-5. 10.1109/Ssci.2016.785

TVERSKY, A; KAHNEMAN, D; (1992) Journal Of Risk And Uncertainty 5 297.

W. CLIFTON BALDWIN, BRIAN SAUSER, ROBERT CLOUTIER. (2015) Simulation Approaches For System Of Systems: Events-Based Versus Agent Based Modeling, Procedia Computer Science, Volume 44, Pages 363-372, Issn 1877-0509, Https://Doi.Org/10.1016/J.Procs.2015.03

WELLMAN, MICHAEL P.; WAH, ELAINE. (2017) Strategic Agent-Based Modeling Of Financial Markets. The Russell Sage Foundation Journal Of The Social Sciences.

WILENSKY, U. (1999). Netlogo. Http://Ccl.Northwestern.Edu/Netlogo/. Center For Connected Learning And Computer-Based Modeling, Northwestern University. Evanston, Il.

ZIMBRES, R. A. (2006) “Modelagem Baseada Em Agentes: Uma Terceira Maneira De Se Fazer Ciência?” Salvador: Enanpad, 2006.