UNIVERSIDADE PRESBITERIANA MACKENZIE
PROGRAMA DE PÓS-GRADUAÇÃO EM ADMINISTRAÇÃO DE EMPRESAS

RICHARD WILLIANS MACEDO JUNIOR

TAIL RISK HEDGING – GESTÃO DE RISCO EM DADOS DE ALTA FREQUÊNCIA

São Paulo
2023

RICHARD WILLIANS MACEDO JUNIOR

TAIL RISK HEDGING – GESTÃO DE RISCO EM DADOS DE ALTA FREQUÊNCIA

Dissertação apresentada ao Programa de Pós-Graduação de Administração de Empresas da Universidade Presbiteriana Mackenzie, como requisito parcial necessário à obtenção do título de Mestre em Administração de Empresas, linha "Finanças Estratégicas".

Orientador: Prof. Dr. Eli Hadad Junior

São Paulo

2023

Elaborado pelo Sistema de Geração Automática de Ficha Catalográfica da Mackenzie
com os dados fornecidos pelo(a) autor(a)

J095t Junior, Richard Willians Macedo.

Tail risk hedging - gestão de risco em dados de alta frequência : [recurso eletrônico] / Richard Willians Macedo Junior.

768 KB ; il.

Dissertação (Mestrado em Administração de Empresas) - Universidade Presbiteriana Mackenzie, São Paulo, 2023.

Orientador(a): Prof(a). Dr(a). Eli Hadad Junior.

Referências Bibliográficas: f. 54-59.

1. Tail-risk Hedging. 2. High-frequency Data. 3. Fat Tail. 4. Value-at-risk. 5. Expected-shortfall. 6. Forecast. I. Hadad Junior, Eli, *orientador(a)*. II. Título.

Bibliotecário(a) Responsável: Jaqueline Bay Inácio Duarte - CRB 8/9509

RICHARD WILLIANS MACEDO JUNIOR

TAIL RISK HEDGING - GESTÃO DE RISCO EM DADOS DE ALTA FREQUÊNCIA

Dissertação apresentada ao Programa de Pós-Graduação em Administração de Empresas da Universidade Presbiteriana Mackenzie, como requisito parcial à obtenção de título de Mestre em Administração de Empresas.

Aprovada em: 09/08/2023

BANCA EXAMINADORA

Eli Hadad Junior

Prof. Dr. Eli Hadad Junior
Universidade Presbiteriana Mackenzie

L. Basso

Prof. Dr. Leonardo Fernando Cruz Basso
Universidade Presbiteriana Mackenzie

Herbert Kimura

Prof. Dr. Herbert Kimura
Universidade de Brasília

“Se enxerguei mais longe, foi por estar em pé sobre os ombros de gigantes.” Isaac Newton.

RESUMO

Este estudo visa ampliar a literatura existente com base em modelos preditivos de gestão de risco para proteger carteiras de investimento contra grandes perdas em situações de mercado estressantes como eventos inesperados, minimizando o acentuado impacto negativo que costumam causar em portfolios no geral. Para isso são utilizados dados em alta frequência, que oferecem maior nível de significância estatística quando comparados a dados de baixa frequência, possibilitando a compreensão da microestrutura e o comportamento dos ativos no mercado acionário brasileiro. Assim os modelos preditivos foram desenvolvidos considerando todas as nuances envolvidas no comportamento do preço dos ativos analisados. A base deste estudo é desenvolvida nas primeiras sessões através da análise bibliométrica e revisão sistemática, base essa definida na lacuna de conhecimento encontrada de mapear e analisar a literatura acadêmica acerca do gerenciamento de risco de cauda através de modelos preditivos. Dessa forma o *Generalized Methods of Moments* (GMM) mostrou-se compatível com as características desejadas para a previsão do *Value-at-Risk* (VaR) e do *Expected-Shortfall* (ES), corroborado pelo fato do modelo ser capaz de lidar com distribuições não normais. As previsões contaram também com ferramentas de *machine learning* com uso de rede neural artificial do tipo *Long Short-Term Memory* (LSTM). Os resultados gerados pelo método dos momentos indicam que é possível através do modelo estimar as perdas dos ativos analisados em cenários de incerteza. Porém, resultados não favoráveis são gerados pela rede LSTM que não foi capaz de prever com exatidão as perdas para o ativo PETR3.

Palavras-chave: *tail-risk hedging, high-frequency data, fat tail, value-at-risk, expected shortfall, forecast*.

ABSTRACT

This study aims to expand the existing literature based on predictive risk management models to protect investment portfolios against large losses in stressful market situations such as unexpected events, minimizing the sharp negative impact that they usually have on portfolios in general. For this, high frequency data are used, which offer a higher level of statistical significance when compared to low frequency data, enabling the understanding of the microstructure and behavior of assets in the Brazilian stock market. Thus, the predictive models were developed considering all the nuances involved in the price behavior of the analyzed assets. The basis of this study is developed in the first sessions through bibliometric analysis and systematic review, which is defined in the knowledge gap found in mapping and analyzing the academic literature about tail risk management through predictive models. Thus, the Generalized Methods of Moments (GMM) proved to be compatible with the desired characteristics for the prediction of Value-at-Risk (VaR) and Expected-Shortfall (ES), corroborated by the fact that the model can deal with distributions not normal. The predictions also relied on machine learning tools using an artificial neural network of the Long Short-Term Memory (LSTM) type. The results generated by the method of moments indicate that it is possible, through the model, to estimate the losses of the assets analyzed in scenarios of uncertainty. However, unfavorable results are generated by the LSTM network, which was not able to accurately predict the losses for the PETR3 asset.

Keywords: *tail-risk hedging, high-frequency data, fat tail, value-at-risk, expected shortfall, forecast*.

Lista de ilustrações

Figura 01 – Distribuição anual dos artigos 18
Figura 02 – Mapa de coocorrências das palavras-chave 19
Figura 03 – Análise de (sub) categorias para identificar lacunas de conhecimento 28
Figura 04 – Categoria 01 – Tema principal/foco do estudo 36
Figura 05 – Categoria 02 – Tipos de dados de alta frequência 37
Figura 06 – Categoria 03 – Métodos de pesquisa 37
Figura 07 – Categoria 04 – Medidas de risco utilizadas 38
Figura 08 – Categoria 05 – Teorias relacionadas aos objetivos dos artigos 38
Figura 09 – Categoria 06 – Tipos de dados utilizados 39
Figura 10 – Categoria 07 – Origem dos dados 39
Figura 11 – Categoria 08 – Período de análise 40
Figura 12 – Categoria 09 – Resultados 41
Figura 13 – Categoria 10 – Conclusão 41
Figura 14 – Categoria 11 – Avenidas para estudos futuros 42
Figura 15 - Expected Shortfall - 7 ativos analisados 48
Figura 16 – Mean Square Error 50
Figura 17 – Variações – IBOV e PETR3 51
Figura 18 – Variação Real – PETR3 51
Figura 19 – Previsão – PETR3 52

Lista de tabelas

Tabela 01 – Evolução da amostra por meio de filtros da WoS 15
Tabela 02 – Matriz de (sub) categorização 16
Tabela 03 – Palavras-chave 18
Tabela 04 – T de Goffman 20
Tabela 05 – Classificação de palavras - Lei de Zipf 21
Tabela 06 – Lei de Bradford sobre os periódicos 22
Tabela 07 – Citações dos artigos 23
Tabela 08 – Aplicação Lei de Lotka 25
Tabela 09 – Principais contribuições dos artigos da amostra 29
Tabela 10 – Codificação das categorias e subcategorias de análise dos artigos 34
Tabela 11 – Value-at-Risk e Expected Shortfall (Sig. 95%) 49
Tabela 12 – Características da rede LSTM 50

Lista de equações

01 20
02 20
03 20
04 24
05 25
06 44
07 45
08 45
09 45
10 45

Sumário

1. INTRODUÇÃO 10

1.1 JUSTIFICATIVA 11

1.2 PROBLEMA DE PESQUISA 11

1.3 OBJETIVOS 11

1.4 HIPÓTESES 12

2. REFERENCIAL TEÓRICO 12

2.1 REVISÃO DA LITERATURA 12

2.2 ANÁLISE BIBLIOMÉTRICA 14

2.3 REVISÃO SISTEMÁTICA 25

3. METODOLOGIA 43

3.1 MEDIDAS E FATORES DE RISCO DE CAUDA 43

3.2 MODELOS DE PREVISÃO 45

3.2.1 *GENERALIZED METHOD OF MOMENTS* (GMM) 45

3.2.2 *LONG SHORT-TERM MEMORY* (LSTM) 45

3.3 BANCO DE DADOS 46

4. RESULTADOS 47

4.1 *GENERALIZED METHOD OF MOMENTS* (GMM) 47

4.2 *LONG SHORT-TERM MEMORY* (LSTM) 49

5. CONCLUSÕES 52

6. REFERÊNCIAS 54

1. INTRODUÇÃO

Diversas crises financeiras ao longo da história como a quebra do mercado de 1987, as crises cambiais dos anos 1990, a bolha das Ponto Com em 2000, a crise financeira global de 2008, causada pelo estouro da bolha imobiliária norte-americana e a pandemia de COVID-19 em 2020, aumentaram as incertezas dos investidores e de formuladores de políticas econômicas, tendo como consequências aumento da volatilidade do mercado financeiro, salientando a importância da gestão de riscos.

As estratégias de proteção de risco de cauda e sua mitigação tem sido amplamente exploradas pela literatura pelo motivo de existirem inúmeras limitações de modelos utilizados para gerenciar o risco em períodos de crise.

Esta pesquisa busca estabelecer medidas que tenham como resultado medir o risco de cauda – que está atrelado às perdas extremas na cauda esquerda da distribuição de retorno de um ativo ou carteira, provocado por eventos raros ou catastróficos.

Segundo Bollerslev e Todorov (2011) os investidores possuem uma aversão particular contra riscos de cauda. Dessa forma é necessária uma medida de risco capaz de mitigar os retornos negativos extremos e ao mesmo tempo, otimizar o benefício do investidor. De acordo com Jorion (2021), o *Value at Risk* (VaR) e o *Expected Shortfall* (ES) são de forma básica as duas medidas de risco negativo mais comuns e comumente utilizadas. Segundo Bodie, Zvi e Kane (2020), o VaR é definido como a medida de risco mais otimista, quando o risco de cauda é examinado avaliando os 5% dos piores cenários, onde é considerado o retorno mais alto, consequentemente a menor perda, em todos os casos.

Dado tal objetivo e tendo como embasamento o maior número disponível de dados de alta frequência, sobre o uso de preços intradiários, para medir e projetar com maior acurácia a volatilidade diária, esta pesquisa busca fazer uso desses dados por meio da adequação de títulos derivados da bolsa de valores brasileira (B3) para cobertura de risco de cauda. Duas motivações surgem para o uso de dados em alta frequência em comparação com dados de baixa frequência. A primeira está ligada ao fato dos dados em alta frequência fornecerem uma quantidade volumosa de observações, o que garante um nível mais alto de significância estatística. O segundo motivo está atrelado a informação contida em dados de alta frequência que refletem o efeito da microestrutura dos mercados de ações.

O modelo preditivo adotado foi introduzido por Hansen (1982), sendo utilizado em pesquisas com séries de tempo financeiras, com resultados promissores desde seu surgimento. O *Generalized Method of Moments* (GMM), apresenta vantagens consideráveis

ao lidar com dados que contêm heterocedasticidade – variações na volatilidade ao longo do período analisado – além de endogeneidade, presente em casos em que a variável explicativa se correlaciona com o erro.

O objetivo deste trabalho é explorar o estudo sobre gerenciamento de risco para mitigar os efeitos de eventos de cauda que impactam negativamente nas carteiras de investimento, utilizando para isso medidas de risco como VaR e ES além da construção de modelos preditivos como redes neurais artificiais do tipo LSTM (*Long Short-Term Memory*).

Em termos concretos, a rede LSTM consiste em três partes, incluindo uma camada de entrada, uma camada de saída e várias camadas ocultas entre elas. As camadas ocultas têm módulos de memória. O núcleo do módulo de memória é a célula de memória auto conectada com três portas, entrada, saída e esquecimento. O valor de cada uma dessas portas controla o fluxo de informações no módulo de memória. Com isso, é possível realizar dois tipos de análises distintas, uma baseada em técnicas econométricas tradicionais e outra utilizando algoritmos de *machine learning* para testes preditivos que podem ser de grande valia para investidores e futuros estudos acadêmicos.

1.1 JUSTIFICATIVA

Esta pesquisa se justifica pela lacuna de conhecimento acerca de novos métodos para lidar com situações extremas no mercado.

1.2 PROBLEMA DE PESQUISA

A partir do exposto, formulou-se o problema de pesquisa: Como mitigar os riscos financeiros relacionados a fatores extremos com o uso de modelos preditivos?

1.3 OBJETIVOS

O presente estudo tem como objetivo geral identificar como é possível mitigar os riscos financeiros relacionados à fatores extremos com o uso de modelos preditivos. Para guiar a busca por este entendimento adotaram-se os objetivos específicos delineados a seguir, sendo o primeiro (1) caracterizar e identificar medidas eficazes de proteção contra eventos extremos e (2) analisar o impacto das previsões de modelos desenvolvidos na gestão de riscos financeiros.

1.4 HIPÓTESES

Considerando o supracitado, a hipótese desta pesquisa é:

H1: O uso do LSTM melhora o gerenciamento do risco de cauda em dados de alta frequência
H2: O gerenciamento de risco de cauda, utilizando VaR e ES são viáveis em dados de alta frequência

2. REFERENCIAL TEÓRICO

Este capítulo analisa os principais estudos desenvolvidos através da revisão da literatura, análise bibliométrica e revisão sistemática.

2.1 REVISÃO DA LITERATURA

Dados de alta frequência possibilitam um nível maior de significância estatística. De acordo com Reboredo et al. (2012) esse tipo de dado é fortemente influenciado por eventos recentes ou então notícias do mercado. Bee et al. (2019) apresentam uma abordagem dinâmica de modelagem extrema baseado em dados de alta frequência. Cai et al. (2019) descobriram que o modelo possui uma melhora significativa em relação a cobertura das previsões diárias do VaR pelo desenvolvimento de um modelo VaR autorregressivo funcional como método para prever a mediada diária com base na estimativa da função de densidade dos retornos intradiários. Sun et al. (2009) utilizam retornos do Deutsche Boerse AG German Stock Index (DAX) na frequência de 1 minuto e obtiveram como resultado previsões de maior acurácia. Resultados como esses indicam que a utilização de dados de alta frequência possuem grandes vantagens quando comparados com dados de baixa frequência.

No que se refere a problemas com dados faltantes, foi utilizado nesta pesquisa a interpolação constante por partes, como corroborado por Fan et al. (2016), artigo esse que apresentou a maior classificação no T de Goffman e Lei de Zipf na análise bibliométrica deste estudo, em que dados faltantes, situação recorrente em séries de tempo financeira com dados em alta frequência, são preenchidos com o último preço apresentado $t - 1$ (“último *tick*”). Bormetti et al. (2015) utilizam também como uma de suas metodologias o preenchimento de valores ausentes com o último preço ao tratar de dados na frequência de 1 minuto.

Atualmente, não existe nenhum modelo ou medida com maior influência no campo

de previsão do que o VaR (Sun et al. (2009), Reboredo et al. (2012), Louzis et al. (2014), Avdulaj e Barunik (2017) e Song et al. (2021)). Com base na extensa literatura sobre como estimar o VaR, o seu domínio pode ser explicado pelo fato de que as outras medidas são propensas a apresentarem incerteza em relação as suas estimativas devido a seus complexos procedimentos. Por essa razão, existem algumas extensões do modelo, como é o caso do VaR condicional, que se adequa de forma promissora em cenários de eventos extremos (Chavez-Demoulin e McGill 2012). Contudo, em abordagens como essa, o estudo de quedas de curto prazo em eventos de cauda não pode ser explorado pois não é considerado parâmetros variáveis no tempo.

Com a crise financeira de 2007-2008, o Basel Commitee on Banking Supervision (2013) sugeriu a transição de VaR com nível de confiança de 99% para o ES com nível de confiança de 97,5%. O Expected Shortfall é considerado como uma alternativa ao VaR em abordagens de gerenciamento de risco de cauda por ser coerente em suas previsões.

Devido a sua importância, uma extensa parte da literatura desenvolve uma abordagem com a utilização do VaR e do ES em conjunto utilizando dados em alta frequência (Chaves-Demoulin e McGill (2012), Bee et al. (2016), Karmakar e Paul (2016), Alexeev et al. (2019), Bee et al. (2019), Cai et al. (2021), Dimitriadis e Halbleib (2022) e Song e Li (2022)).

Assim, estudos indicam uma das técnicas de estimação estatística que pode ser utilizada para estimar o VaR e o ES é o *Generalized Method of Moments* (GMM). Halbleib et al. (2012) propõem um estimador GMM como forma de identificar os pesos ideais de combinação para minimizar o teste de cobertura condicional. Fuertes e Olmo (2013), utilizam um modelo de regressão quantílica inspirado no GMM para combinar previsões de VaR.

Com relação ao desenvolvimento da tecnologia da computação, foram propostos novos métodos de previsão, como as redes neurais artificiais Paluch et al. (2018), cujo objetivo é replicar o funcionamento do cérebro humano. As redes neurais recorrentes Gao e Chai (2018). são um conjunto poderoso de algoritmos de redes neurais artificiais, especialmente úteis para o processamento de dados sequenciais, como som, tempo ou linguagem. Algumas redes neurais recorrentes - RNN tiveram melhor desempenho na previsão de dados financeiros e se tornaram populares, como a *Long Short-Term Memory* (HOCHREITER E SCHMIDHUBER 1997).

Assim, a rede LSTM é um tipo específico de RNN que tem sido amplamente aplicada para resolver problemas de aprendizado supervisionado (LI e TAM 2018). Ela tem células

de memória não lineares e unidades de porta (GREFF et al. 2016), capazes de processar sequências de longo prazo não estacionárias. Além disso, pode extrair as características dos dados financeiros e refletir as características da rede (ZENG e LIU 2018). Ele oferece bom desempenho na previsão de preços no mercado de ações, pois é um algoritmo capaz de identificar relações não lineares e ocultas nos dados, ou seja, é um algoritmo de aprendizado supervisionado, capaz de aprender com um conjunto de dados em treinamento (dado um conjunto de dados, o LSTM pode aprender uma função não linear para regressão).

Maknickiene e Maknickas (2012) melhoraram o desempenho das medições no mercado de câmbio ou usando LSTM; Chen et al. (2015) usaram LSTM para retornos do mercado de *design* chinês e tiveram bom desempenho. Depois disso, foram concluídos vários experimentos com a moderna rede LSTM de forma literária em métodos isolados, híbridos ou combinados com estudos clássicos e de séries financeiras, o que indica que a LSTM é bastante adequada para modelos financeiros de séries temporais (KIM e WON 2018).

Dessa forma se torna possível observar dois tipos de abordagens preditivas que podem ser utilizadas para análises contra perdas em situações de estresse financeiro ou eventos de cauda, uma utilizando o método dos momentos (GMM) e a outra utilizando uma rede LSTM.

2.2 ANÁLISE BIBLIOMÉTRICA

O objetivo desse estudo é responder à pergunta – como mitigar os riscos financeiros relacionados a fatores extremos com o uso da estratégia de *Tail-Risk Hedging*? Para tanto, são implementadas as 7 etapas descritas a seguir. As etapas 1 a 5 atendem tanto à metodologia da análise bibliométrica quanto da revisão sistemática, e as etapas 6 e 7 referem-se à revisão sistemática.

Etapa 1 – Escolha da base de dados. Os artigos da amostra são obtidos a partir da WoS, a base de dados de citações líder no mundo. Ela contém registros de artigos publicados em periódicos científicos de alto fator de impacto, classificados por meio do *Journal Citation Reports* (JCR).

Etapa 2 - Uso de parâmetros iniciais de pesquisa a partir da WoS. Para o período de 1º de janeiro de 1945 a 18 de março de 2023. Inicialmente, são identificados 119 artigos com base em variações das palavras-chave *tail risk AND high-frequency data*. Na sequência, são realizadas exclusões por meio da aplicação de filtros na própria WoS, resultando numa amostra intermediária de 63 artigos, conforme Tabela 1.

Tabela 01 – Evolução da amostra por meio de filtros da WoS

Sinal	Descrição	Número de artigos
(+)	Palavras-chave iguais a: “tail risk AND high-frequency data”	119
(-)	Tipo de documento: diferente de “articles”	09
(-)	Idioma: diferente de “english”	0
(-)	Categotrias da WoS diferentes de “Economics”, “Business Finance”, “Management”, “Business”	47
(=)	Amostra intermediária	63
(-)	Exclusão de artigos não relacionados	34
(=)	**Amostra final**	**29**

Fonte: Elaborada pelo autor

Etapa 3 - Exclusão de artigos não relacionados. Após a leitura inicial do resumo, introdução e conclusão dos artigos – a fim de verificar se eles estão de acordo com o tema definido - são excluídos 34 dos 63 artigos da amostra intermediária. Os motivos para essas exclusões, são não estarem relacionados à previsão do risco de cauda, mas especificamente ao setor bancário (8), taxa de câmbio (5), preços futuros (4), preço de opções (3), comparação entre mercados (3), setor agrícola (1), seguro médico (1), análise empírica de uma única ação (1), taxa de crescimento do PIB (1), preço de ações em baixa frequência (1), retornos imobiliários (1), taxas de frete (1), dados impacto da COVID-19 (1), setor de eletricidade (1), ordens de compra e venda (1) e artigo qualitativo (1).

Etapa 4 - Criação do banco de dados e coleta de artigos. Os 29 artigos da amostra final são obtidos por meio das seguintes bases de pesquisa acadêmica: *Science Direct, Web of Science, Taylor & Francis* e *Google Scholar*. A partir disso, são coletadas as seguintes informações para a captura dos dados gerais do artigo: título, nome do autor, instituição afiliada e país de origem dos autores/pesquisadores, nome do periódico, volume e número da edição, página inicial e final, ano da publicação, país de origem dos dados e número de anos de dados da amostra, palavras-chave, Identificador Digital de Objetos (DOI*), Journal of Economic Literature* (JEL) e número de citações de artigos na base de dados WoS.

Etapa 5 – Análise bibliométrica. Por meio dos *softwares R, RStudio, Biblioshiny* e *VOSviewer*, são analisados os dados dos artigos para a elaboração e a análise das tabelas e mapas de relacionamento / cocitação. As análises realizadas por essas ferramentas são complementadas pela verificação das principais leis da bibliometria, (i) a Lei de Zipf (1949), que se refere à categorização e estimação da frequência das palavras-chave, realizada com o auxílio do *software Rank Words* para o cálculo do ponto T de Goffman, que é o ponto de transição de palavras de baixa para as de alta frequência, região que teoricamente concentra

palavras com alta carga semântica, (ii) a Lei de Bradford (1934), que realiza a verificação dos periódicos que produzem muitos artigos, em contra partida aqueles que produzem poucos sobre um determinado tema, e (iii) a Lei de Lotka (1926), que realiza a identificação dos pesquisadores que possuem maior frequência de produção em determinada área de conhecimento.

Etapa 6 - Leitura e codificação dos artigos. Trata-se da identificação dos objetivos, amostra, métodos e contribuições dos artigos. Além disso, eles são classificados e codificados em categorias e subcategorias estruturadas, conforme a Tabela 2. Cada uma das 11 categorias possui suas próprias subcategorias e um único artigo pode ser classificado em mais de uma subcategoria.

Tabela 02 – Matriz de (sub) categorização

Categorias	Subcategorias	Definição
1.Tema principal/foco do estudo	A – Gerenciamento de risco através de previsão de preços/retornos	Gerenciamento de risco de cauda com base em modelos de previsão do preço ou do retorno de determinado ativo
	B – Gerenciamento para monitorar o risco de cauda	Gerenciamento de risco de cauda com base no controle preditivo de eventos extremos
	C – Gerenciamento de risco para *hedging*	Gerenciamento de risco de cauda com base na proteção com a utilização de algum instrumento que garanta a cobertura
2. Tipos de dados de alta frequência	A – 1 minuto	Dados na frequência de 1 minuto
	B - 5 minutos	Dados na frequência de 5 minutos
	C – 10 minutos	Dados na frequência de 10 minutos
	D – Outros	Outras frequências
3. Métodos de pesquisa	A – Família ARMA	Modelo autorregressivo de médias móveis (ARMA). São modelos que podem ser ajustados aos dados da série temporal para entender melhor os dados ou para prever pontos futuros na série
	B – Família ARCH	Heteroscedasticidade condicional autorregressiva (ARCH) são modelos estatístico usado na análise de dados de séries temporais
	C – GMM	O Generalized Method of Moments é capaz de lidar com séries de tempo financeiras que apresentam heterocedasticidade e endogeneidade.
	D – Outros	Demais metodologias de pesquisa, não relacionadas às subcategorias 3ª
4. Medidas de risco utilizadas	A – VaR	O Value-at_Risk indica o valor máximo que se espera perder na carteira de ativos em uma situação de evento de cauda.
	B – ES	O Expected-Shortfall indica a quantia de perda média que se espera em uma situação de evento de cauda
	C – Quantis	Demais medidas além do VaR e do ES que usa quantis para determinar a perda no portfolio

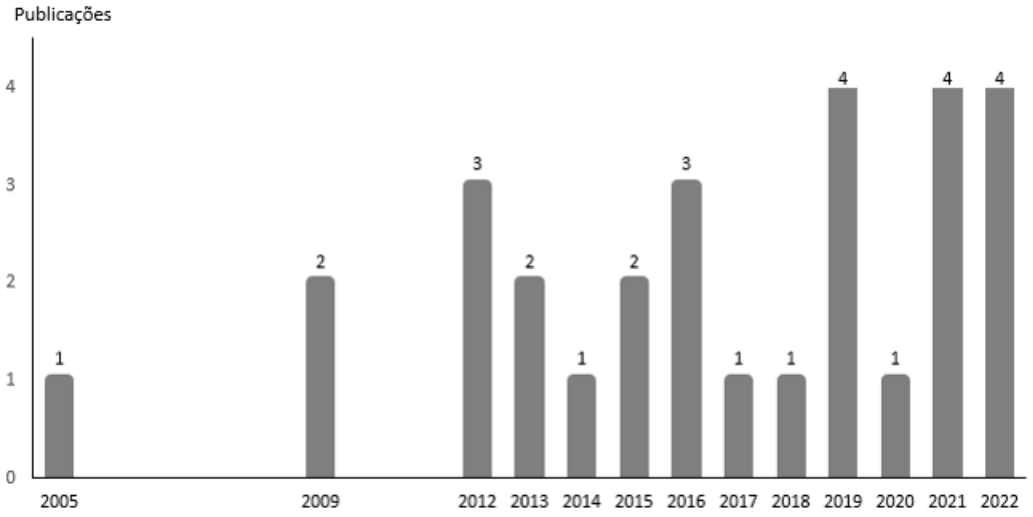
	D – Outros	Outras medidas de risco que não utilizam quantis em sua determinação de risco
5. Teorias relacionadas aos objetivos dos artigos	A – Teoria de Valores Extremos	A Teoria de Valores Extremos tem aplicações práticas na avaliação de riscos e na tomada de decisão em situações de incerteza, indicando a probabilidade de ocorrência de eventos raros
	B – Nenhuma	Não foram utilizadas
6 – Tipos de dados analisados	A – Ações	Análise de ações em alta frequência
	B – Índices de ações	Análise de índices de ações em alta frequência
	C – Títulos	Análise de títulos em alta frequência
	D – Câmbio	Análise de câmbio em alta frequência
	E – Commodity	Análise de commodities em alta frequência
	F – Outros	Análise de outros ativos em alta frequência
7. Origem dos dados	A – Estados Unidos	Dados de operações nos Estados Unidos
	B – Europa	Dados de operações na Europa
	C – Ásia/Oceania	Dados de operações na Ásia e/ou Oceania
	D – América Latina	Dados de operações na América Latina
	E – África	Dados de operações na África
8. Período de análise	A – Até 2 anos	Dados entre 0 e 2 anos
	B – De 3 a 10 anos	Dados entre 3 e 10 anos
	C – De 10 a 20 anos	Dados entre 10 e 20 anos
	D – Mais de 20 anos	Acima de 20 anos
9. Resultados	A – Novas perspectivas ou novas conclusões	Estudo confirma o objetivo principal proposto pelo autor
	B – Conclusões semelhantes a trabalhos anteriormente apresentados	Estudo não confirma o objetivo principal proposto pelo autor
	C – Outros	Estudo apresenta resultado não conclusivo sobre o objetivo principal proposto pelo autor
10. Conclusão	A– Confirmação do objetivo principal	Pesquisas que utilizem MLP, mas com padrões diferentes
	B – Não confirmação do objetivo principal	Pesquisas que se utilizem de outras redes neurais artificiais para esse fim
11. Avenidas para estudos futuros	A – Examinar outras medidas de risco	Pesquisas que utilizem outras medidas além do VaR, ES e quantis
	B – Examinar diferentes dados	Pesquisas que utilizem diferentes tipos de dados do que os utilizados especificamente
	C – Avaliar outros modelos de previsão	Pesquisas que utilizem outros modelos preditivos do que foram utilizados
	D – Analisar através dos resultados outras questões de trabalhos anteriores	Pesquisas que utilizem novas questões abordadas em trabalhos anteriores a partir de seus próprios modelos e abordagens
	E – Não mencionado	Não mencionaram avenidas para estudos futuros

Fonte: Elaborada pelo autor

Etapa 7 – Revisão sistemática. Após a codificação da matriz de (sub) categorização da Tabela 2 a partir dos 29 artigos da amostra final, é realizada a contagem de frequência das subcategorias, de maneira a facilitar a identificação das lacunas de conhecimento. A partir disso, essas lacunas são comparadas com as subcategorias da Categoria 11 - Avenidas para estudos futuros, a fim de se obter hiatos passíveis de novos estudos.

De acordo com o Gráfico 1, a amostra final é composta por 29 artigos, distribuídos entre os anos de 2005 e 2022, obtidos a partir da base WoS, e nesse período identifica-se a publicação de até 4 artigos por ano, que tratam do tema *tail risk* e dados de alta frequência.

Figura 01 – Distribuição anual dos artigos



Fonte: *Biblioshiny*

A Tabela 3 apresenta a frequência das 141 palavras-chave identificadas nos 29 artigos da amostra final do estudo, com destaque para *volatility* (14,9%), *Risk* (10,6%) e *Models* (8,5%).

Tabela 03 – Palavras-chave

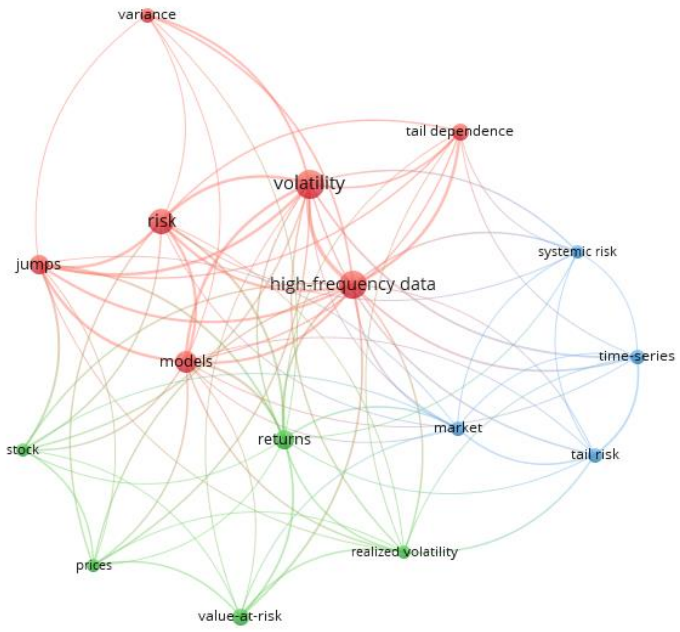
Palavras-chaves	**Quantidade**	**Frequência %**
Volatility	21	14,9%
Risk	15	10,6%
Models	12	8,5%
Returns	11	7,8%
Market	6	4,3%
Prices	6	4,3%
Times-series	6	4,3%
Variance	6	4,3%
Stock	5	3,5%
Forecasts	4	2,8%

Impact	4	2,8%
Jumps	4	2,8%
Model	4	2,8%
Tail Risk	4	2,8%
Tails	4	2,8%
Behavior	3	2,1%
Continuous-time	3	2,1%
Diffusion	3	2,1%
Distributions	3	2,1%
High-frequency data	3	2,1%
Inference	3	2,1%
Markets	3	2,1%
Price	3	2,1%
US	3	2,1%
Announcements	2	1,4%
Total de palavras-chave	**141**	**100%**

Fonte: *Biblioshiny*

A Figura 2 apresenta o mapa de coocorrências das palavras-chave mais utilizadas nos artigos da amostra final. Destacam-se as palavras *high-frequency data*, *volatility e risk*, resultado aderente ao da Tabela 3. O tamanho dos nós indica maior relevância dessas palavras nos artigos e a espessura das linhas indica a força da ligação entre elas, enquanto as cores destacam os grupos.

Figura 02 – Mapa de coocorrências das palavras-chave



Fonte: *VosViewer*

As Leis de Zipf (1949) elucidam se há otimização no uso das palavras-chave, através da sua constância. A primeira lei de Zipf afirma que a série (r) de uma palavra, o produto da

ordem de pela sua frequência de ocorrência (f) é aproximadamente constante (C), conforme demonstra a equação 1:

$$r \times f = C \quad (1)$$

Zipf propôs ainda uma outra lei para as palavras-chave de baixa frequência, que foi revisada e alterada por Booth (1967). Segundo o autor, em um determinado texto, várias palavras com baixa frequência de ocorrência têm a mesma assiduidade. Vide a equação 2:

$$I_n = 2I_1 / n\,(n+1) \quad (2)$$

Em que:
I_1 = número de palavras que têm frequência 1
I_n = número de palavras que têm frequência n
n = ponto de Goffman ou local de transição das palavras de baixa para as de alta frequência

As leis de Zipf definem extremidades em uma lista de palavras. Entre esses pontos extremos, há a região de transição das palavras de alta para as de baixa frequência. De acordo com Goffman (1971), nessa região estão as palavras de maior conteúdo semântico, sendo elas as mais adequadas para a indexação temática de um texto. Pao (1978) apresenta a fórmula do ponto T ou de transição de Goffman, conforme a equação 3.

$$T = \left(-1+\sqrt{1+8I_1}\right) / 2 \quad (3)$$

Em que:
T = ponto de transição de Goffman
I_1 = número de palavras que têm frequência 1

Com base na análise de todos os artigos da amostra final, o software Rank Words fornece uma lista das palavras na ordem decrescente de frequência. A partir dessa base, identifica-se as palavras que se repetem apenas uma única vez para cálculo do ponto T de Goffman. Depois, são localizadas as palavras acima da classificação indicada por esse ponto. A Tabela 4 demostra que para os 29 artigos, esse ponto varia entre 39,65 (Fan et al., 2016) e 25,58 (Cai et al., 2021), sendo sua média é 32,96.

Tabela 04 – T de Goffman

No.	Autor	T de Goffman
1	Fan, Imerman, Dai (2016)	39,65
2	Fuertes, Olmo (2013)	39,50
3	Bormetti, Calcagnile, Treccani, Corsi, Marmi, Lillo (2015)	37,77
4	Alexeev, Urga, Yao (2019)	37,03
5	Song, Tian, Li (2021)	35,31

6	Ferriani, Zoi (2022)	35,17
7	Chavez-Demoulin, McGill (2012)	35,06
8	Karmakar, Paul (2016)	34,94
9	Erdemlioglu, Gradojevic (2021)	34,26
10	Dimitriadis, Halbleib (2022)	34,14
11	Malevergne, Pisarenko, Sornette (2005)	33,68
12	Bee, Dupuis, Trapin (2019)	33,62
13	Louzis, Xanthopoulos-Sisinis, Refenes (2014)	33,47
14	Bollerslev, Todorov, Li (2013)	33,39
15	Reboredo, Matias, Garcia-Rubio (2012)	33,39
16	Mao, Zhang (2018)	32,70
17	Yalaman, Manahov (2022)	32,28
18	Mazzarisi, Zaoli, Campajola, Lillo (2020)	32,06
19	Bee, Dupuis, Trapin (2016)	31,91
20	Penzer, Schmid, Schmidt (2012)	31,60
21	Chen, Ding, Zhao (2019)	31,06
22	Song, Li (2022)	30,78
23	Salvatierra, Patton (2015)	30,46
24	Sun, Rachev, Fabozzi, Kalev (2009)	30,36
25	Sun, Rachev, Fabozzi, (2009)	30,03
26	Avdulaj, Barunik (2017)	29,80
27	Chan, Ng, Ragell (2019)	29,64
28	Lai (2021)	27,11
29	Cai, Wu, Peng (2021)	25,58

Fonte: *Rank Words*

Uma vez calculado o ponto T de Goffman de cada artigo, é possível realizar a análise da região na qual estão as palavras mais aderentes ao tema principal do texto. Na sequência, exclui-se as que não são relevantes ao estudo, como preposições, artigos definidos e indefinidos, pronomes e advérbios e classifica-se as palavras que possuem maior frequência, conforme Tabela 5.

No artigo de Fan, Imerman e Dai (2016), a palavra *volatility* possui a maior frequência, ou seja, ela se repete 341 vezes em um texto com 12.713 palavras. Além disso, verifica-se que a palavra *model* é a mais citada em 07 dos 29 (24%) artigos da amostra final. Palavras como *VaR, dependence, return/returns* também possuem grande frequência nos 8 (27,5%) outros artigos da amostra final.

Tabela 05 – Classificação de palavras - Lei de Zipf

No.	Autor	Palavra	Frequência
1	Fan, Imerman, Dai (2016)	*volatility*	341
2	Yalaman, Manahov (2022)	*crisis*	275
3	Erdemlioglu, Gradojevic (2021)	*risk*	231
4	Chen, Ding, Zhao (2019)	*kurtosis*	165
5	Lai (2021)	*model*	146
6	Bormetti, Calcagnile, Treccani, Corsi, Marmi, Lillo (2015)	*jumps*	138
7	Louzis, Xanthopoulos-Sisinis, Refenes (2014)	*volatility*	129
8	Malevergne, Pisarenko, Sornette (2005)	*distribution*	129

9	Salvatierra, Patton (2015)	*model*	119
10	Mazzarisi, Zaoli, Campajola, Lillo (2020)	*causality*	117
11	Song, Tian, Li (2021)	*return*	114
12	Cai, Wu, Peng (2021)	*GARCH*	113
13	Sun, Rachev, Fabozzi (2009)	*VaR*	113
14	Alexeev, Urga, Yao (2019)	*portfolio*	107
15	Reboredo, Matias, Garcia-Rubio (2012)	*model*	107
16	Bollerslev, Todorov; Li (2013)	*tail*	105
17	Bee, Dupuis, Trapin (2019)	*model*	101
18	Chan, Ng, Ragell (2019)	*model*	98
19	Mao, Zhang (2018)	*model*	97
20	Penzer, Schmid, Schmidt (2012)	*dependence*	97
21	Song, Li (2022)	*returns*	96
22	Fuertes, Olmo (2013)	*VaR*	95
23	Karmakar, Paul (2016)	*VaR*	92
24	Ferriani, Zoi (2022)	*volatility*	79
25	Avdulaj, Barunik (2017)	*quantile*	74
26	Chavez-Demoulin, McGill (2012)	*model*	68
27	Sun, Rachev, Fabozzi, Kalev (2009)	*dependence*	67
28	Bee, Dupuis, Trapin (2016)	*EVT*	65
29	Dimitriadis, Halbleib (2022)	*intraday*	61

Fonte: *Rank Words*

A Lei de Bradford (1934) verifica que há poucos periódicos que produzem muitos artigos, e muitos periódicos que produzem poucos artigos, sobre um determinado tema. Para Brookes (1969), a referida lei estima o grau de relevância de determinados periódicos acadêmicos que atuam em áreas de conhecimento específica. Assim, caso os periódicos sejam classificados por ordem decrescente de produtividade, eles podem ser distribuídos em zonas que possuem uma variação na proporção 1: n: n^2 e assim por diante.

Referidas zonas são formadas ao dividir o total de artigos publicados por dois. A zona A identifica-se como o *core* dos assuntos, composto por periódico com duas publicações, o *Journal of Econometrics Quantitative Finance, Quantitative Finance, International Review of Economics \& Finance, Journal of Forecasting, European Journal of Finance, Journal of Business \& Economic Statistics e Journal of Empirical Finance*. Na zona B apresenta-se os periódicos com apenas uma única publicação.

A Tabela 6 indica que na zona A estão 55% das publicações sobre o tema de *tail risk* e dados de alta frequência, e que esse percentual representa 07 periódicos acadêmicos.

Tabela 06 – Lei de Bradford sobre os periódicos

Zona	Periódicos	Quantidade Individual	Quantidade Acumulada	% Acumulação
A	JOURNAL OF ECONOMETRICS	3	3	10%
	QUANTITATIVE FINANCE	3	6	21%

	INTERNATIONAL REVIEW OF ECONOMICS \& FINANCE	2	8	28%
	JOURNAL OF FORECASTING	2	10	34%
	EUROPEAN JOURNAL OF FINANCE	2	12	41%
	JOURNAL OF BUSINESS \& ECONOMIC STATISTICS	2	14	48%
	JOURNAL OF EMPIRICAL FINANCE	2	16	55%
B	ECONOMIC MODELLING	1	17	59%
	EMPIRICAL ECONOMICS	1	18	62%
	INTERNATIONAL REVIEW OF FINANCIAL ANALYSIS	1	19	66%
	JOURNAL OF BANKING \& FINANCE	1	20	69%
	JOURNAL OF FINANCIAL ECONOMETRICS	1	21	72%
	JOURNAL OF FUTURES MARKETS	1	22	76%
C	APPLIED ECONOMICS	1	23	79%
	COMPUTATIONAL ECONOMICS	1	24	83%
	EUROPEAN FINANCIAL MANAGEMENT	1	25	86%
	INTERNATIONAL JOURNAL OF FINANCE \& ECONOMICS	1	26	90%
	JOURNAL OF ASIAN ECONOMICS	1	27	93%
	JOURNAL OF ECONOMIC DYNAMICS \& CONTROL	1	28	97%
	STUDIES IN NONLINEAR DYNAMICS AND ECONOMETRICS	1	29	100%

Fonte: Elaborada pelo autor

Já a Tabela 7 apresenta os artigos sobre o tema de *tail risk* e dados de alta frequência e suas citações. Entre eles, destaca-se o artigo de Chavez-Demoulin e McGill (2012) com 89 (12%) das citações e média anual de 7,42. O artigo apresenta um modelo que combina os processos de Hawkes para valores excedentes com um modelo de distribuição generalizada de Pareto para que através de uma nova metodologia de VaR seja possível caracterizar o comportamento de curto prazo de séries de tempo financeiras. O segundo e o terceiro artigos mais citados são os de Malevergne, Pisarenko e Sornette (2005) e Bollerslev, Todorov e Li (2013), com 88 (07%) e 68 (10%) citações respectivamente.

Tabela 07 – Citações dos artigos

Autores	DOI do artigo	Total de citações	Média de citações por ano	Concentração das citações
Chavez-Demoulin, McGill (2012)	10.1016/j.jbankfin.2012.08.011	89	7,42	12%
Malevergne, Pisarenko, Sornette (2005)	10.1080/14697680500151343	88	4,63	7%
Bollerslev, Todorov, Li (2013)	10.1016/j.jeconom.2012.08.014	68	6,18	10%
Salvatierra, Patton (2015)	10.1016/j.jempfin.2014.11.008	58	6,44	10%

Bormetti, Calcagnile, Treccani, Corsi, Marmi, Lillo (2015)	10.1080/14697688.2014.996586	43	4,78	8%
Louzis, Xanthopoulos-Sisinis, Refenes (2014)	10.1016/j.econmod.2014.03.025	34	3,40	5%
Sun, Rachev, Fabozzi, Kalev (2009)	10.1007/s00181-008-0192-3	32	2,13	3%
Fuertes, Olmo (2013)	10.1016/j.ijforecast.2012.05.005	28	2,55	4%
Reboredo, Matias, Garcia-Rubio (2012)	10.1007/s10614-011-9288-5	24	2,00	3%
Bee, Dupuis, Trapin (2016)	10.1016/j.jempfin.2016.01.006	23	2,88	5%
Mao, Zhang (2018)	10.1016/j.jeconom.2018.03.019	13	2,17	3%
Karmakar, Paul (2016)	10.1016/j.irfa.2015.11.008	11	1,38	2%
Mazzarisi, Zaoli, Campajola, Lillo (2020)	10.1016/j.jedc.2020.104022	11	2,75	4%
Sun, Rachev, Fabozzi (2009)	10.1111/j.1468-036X.2008.00467.x	10	0,67	1%
Bee, Dupuis, Trapin (2019)	10.1093/jjfinec/nbz003	10	2,00	3%
Chan, Ng, Ragell (2019)	10.1016/j.iref.2019.01.003	8	1,60	3%
Fan, Imerman, Dai (2016)	10.1080/07350015.2016.1152968	7	0,88	1%
Ferriani, Zoi (2022)	10.1080/1351847X.2020.1740288	6	3,00	2,25%
Penzer, Schmid, Schmidt (2012)	10.1080/14697688.2010.495950	4	0,33	1%
Alexeev, Urga, Yao (2019)	10.1016/j.iref.2019.02.014	4	0,80	1%
Erdemlioglu, Gradojevic (2021)	10.1002/ijfe.1807	3	1,00	2%
Chen, Ding, Zhao (2019)	10.1080/00036846.2019.1613510	3	0,60	1%
Song, Tian, Li (2021)	10.1016/j.asieco.2021.101314	3	1,00	2%
Dimitriadis, Halbleib (2022)	10.1080/07350015.2021.1929249	2	1,00	2%
Cai, Wu, Peng (2021)	10.1002/for.2736	1	0,33	1%
Avdulaj, Barunik (2017)	10.1515/snde-2016-0044	1	0,14	0%
Lai (2021)	10.1002/fut.22254	0	0	0%
Yalaman, Manahov (2022)	10.1080/1351847X.2021.1957698	0	0	0%
Song, Li (2022)	10.1002/for.2932	0	0	0%
Total de citações		584		100%

Fonte: *Biblioshiny*

Lotka (1926) afirma que um pequeno número de autores produz muitos artigos e que a produção obtida por esse reduzido número de pesquisadores se iguala em quantidade ao desempenho dos demais. Essa teoria é denominada de Lei do Quadrado Inverso - vide Equação 4.

$$a_n = a_1 / n^2, n = 1, 2, 3 \ldots \quad (4)$$

Em que:
a_n = número de autores que publicaram n artigos
a_1 = número de autores que publicaram um artigo
n = número de artigos publicados por autor

Na Equação 5, Chung e Cox (1990) esclarecem que o número de autores com um único artigo publicado, conforme a Lei de Lotka, seria de:

$$a_1 = 6 / \pi^2 = 0{,}6079 = 60{,}8\% \quad (5)$$

Assim, um autor com dois artigos publicados deveria ter a frequência de 15,2% ($0{,}6079/2^2$), um autor com três artigos publicados seria de 6,8% ($0{,}6079/3^2$), e um autor com quatro artigos publicados seria de 3,8% ($0{,}6079/4^2$).

Verifica-se que os 29 artigos da amostra final são produzidos por 147 autores, e que um autor publica 4 artigos, dois autores publicam 12 artigos, e os demais autores publicam um único artigo. 20% dos autores (incluindo os que mais publicam), são responsáveis por 29% das publicações, contudo não há um número menor de pesquisadores se igualando em quantidade ao desempenho dos demais, impossibilitando a confirmação da Lei de Lotka.

Tabela 08 – Aplicação Lei de Lotka

Número de artigos	Número de autores	% Autores	% Lotka
1	134	91,16%	60,79%
2	12	8,16%	15,20%
3	0	0%	6,80%
4	1	0,68%	3,80%
Total	147	100%	

Fonte: *Biblioshiny*

2.3 REVISÃO SISTEMÁTICA

A revisão sistemática da literatura busca identificar as lacunas do conhecimento relacionadas ao tema deste estudo – *Tail-Risk* - gestão de risco em dados de alta frequência. Para tanto, na Etapa 6 do Item 2.2 – Análise Bibliométrica, é definida uma matriz de (sub) categorização – vide Tabela 2. Para cada um dos 29 artigos da amostra final, há a identificação de até 3 subcategorias por categoria. Assim, a contagem de frequência é feita em relação ao total das subcategorias e não sobre o total dos 29 artigos.

A Figura 7 destaca as subcategorias com maior e menor frequência – aquelas que têm potencial para serem priorizadas em pesquisas futuras. Na categoria 1, o tema de gerenciamento para monitorar o risco de cauda (B) é o centro de 82,8% dos artigos analisados, sendo que essas pesquisas diferem entre si pelos seus modelos preditivos e medidas de risco. Isso ocorre pelo fato de existir uma gama de abordagens e métodos que podem ser utilizados para controlar o risco de cauda para posteriormente poder mitigá-lo na carteira de ativos.

Na mesma categoria é possível observar o gerenciamento de risco para *hedging* (C), tema de 6,9% dos artigos analisados, onde são utilizadas ferramentas financeiras para uma

total proteção contra o risco de cauda. Além disso existe a associação (A+B) em que a subcategoria B é combinada com o gerenciamento de risco através de previsão de preços/retornos dos ativos, representando 10,3% das pesquisas, sendo que o escopo desses artigos é de grande relevância ao proporem análises de maior acurácia com o objetivo de reduzir potenciais perdas em eventos de cauda.

A categoria de número 2 indica que 51,7% dos artigos utilizam dados na frequência de 5 minutos (B), fato explicado pelos autores que alegam a busca por evitar vieses de microestrutura. A frequência de 1 minuto (A), é composta por 13,8% das pesquisas, ou seja, são dados *tick-by-tick* utilizados para a obtenção de uma maior significância estatística na modelo preditivo. Destaca-se também a utilização de diferentes tipos de dados de alta frequência em um mesmo artigo, forma que representa uma ocorrência de 24% das pesquisas estudadas.

Quanto aos métodos de pesquisa, na categoria 3, há um destaque para a subcategoria D – Outros métodos de pesquisa (55,20%), campo onde artigos que não utilizam a exclusivamente de modelos da família de modelos de séries de tempo uni variados ARMA (0%), família ARCH (13,8%) nem o GMM (3,4%) estão concentrados. Contudo, vale destacar que 27,4% dos estudos, fazem o uso de dois ou mais métodos da categoria A e B no mesmo artigo, seja como forma de comparação ou como forma de aprofundamento nos modelos preditivos.

Em relação a categoria 4, medidas de risco utilizadas, o VaR – subcategoria A – possui a maior ocorrência, presente em 27,6% dos casos, visto sua grande influência como medida na área de finanças. Os mesmos percentuais de 24,1% aparecem na subcategoria (A+B), em que o VaR e utilizado junto com o ES e na subcategoria (D) – outras - onde medidas de risco diferentes das mais conhecidas na literatura são utilizadas nas pesquisas. Além do mais, 10,3% dos estudos empregam o uso de quantis para determinar a perda em eventos de cauda.

A respeito das teorias relacionadas aos objetivos dos artigos, presente na categoria 5, 20 ocorrências (69%) das pesquisas, não fazem uso de nenhum tipo de teoria (B), ficando por conta da parcela dos 9 artigos restantes (31%) a utilização da teoria de valores extremos (A), que traz uma contribuição para a estimativa confiável dos quantis e das probabilidades referentes aos valores detectados.

Na categoria 6, tipos de dados analisados, aproximadamente metade dos artigos (48,3%) lidam exclusivamente com índices de ações (B), seguido pelo percentual de 31% de

pesquisas que utilizam somente ações (A) em suas análises preditivas. Combinações entre diferentes tipos de dados representam 20,7% dos estudos.

No tocante a categoria 7, origem dos dados, a maioria dos artigos (51,7%) fazem uso de dados referentes aos Estados Unidos (A), ocorrência essa relativa a um total de 15 pesquisas. Ásia e Oceania (C) representam a segunda localidade de maior percentual 17,2% seguido da Europa (B) que apresenta uma taxa de 6,9% de dados relativos ao continente. Os 24,2% adicionais se devem a estudos que empregam dados de duas ou mais regiões combinadas.

Já na categoria 8, período de análise, 11 artigos (37,9%), adotam o intervalo de tempo, de 3 a 10 anos (B). O segundo maior percentual (27,6%) corresponde ao período, de 10 a 20 anos (C), apresentados em 8 artigos. O terceiro caso de representatividade (20,7%) está atrelado a pesquisas, de até 2 anos (A), presente em 6 estudos. Há também concentrações de pesquisas (13,8%) que utilizam mais de um tipo de intervalo em suas respectivas abordagens.

Com relação a categoria de número 9, resultados, 79,3% dos artigos chegaram a novas perspectivas ou novas conclusões (A). Um percentual de 6,9%, apresentaram conclusões semelhantes a trabalhos anteriormente apresentados (B), além da presença de 10,3% de pesquisas houve uma soma de (A+B) em seus resultados.

A categoria 10, referente a conclusão, mostrou que em 100% dos estudos houve a confirmação do objetivo principal (A).

Por fim, a categoria 11 indica as avenidas para estudos futuros ou lacunas do conhecimento - segundo a perspectiva dos autores dos 26 artigos da amostra final. Obteve-se 34,5% como maior resultado indicando a possibilidade de examinar diferentes tipos de dados (B) dos que foram analisados pelos respectivos artigos desta subcategoria. O mesmo percentual também indicou estudos em que não foi mencionado (E) nenhuma avenida para estudos futuros.

Foi evidenciado também que 13,8% das pesquisas assinalam a perspectiva de estudos envolvendo a avaliação de outros modelos de previsão (C) além dos utilizados pelas pesquisas que destacaram essa lacuna. Com o mesmo percentual de 3,4%, duas subcategorias indicam o exame de outras medidas de risco (A) e a análise através dos resultados de outras questões referentes trabalhos anteriores (D). Foi possível ainda identificar três combinações (A+B), (B+D) e (C+D) com percentual de 3,4%, que indicam possíveis lacunas de conhecimento para serem exploradas e possivelmente obter-se resultados que contribuam com a literatura neste assunto.

Figura 03 – Análise de (sub) categorias para identificar lacunas de conhecimento

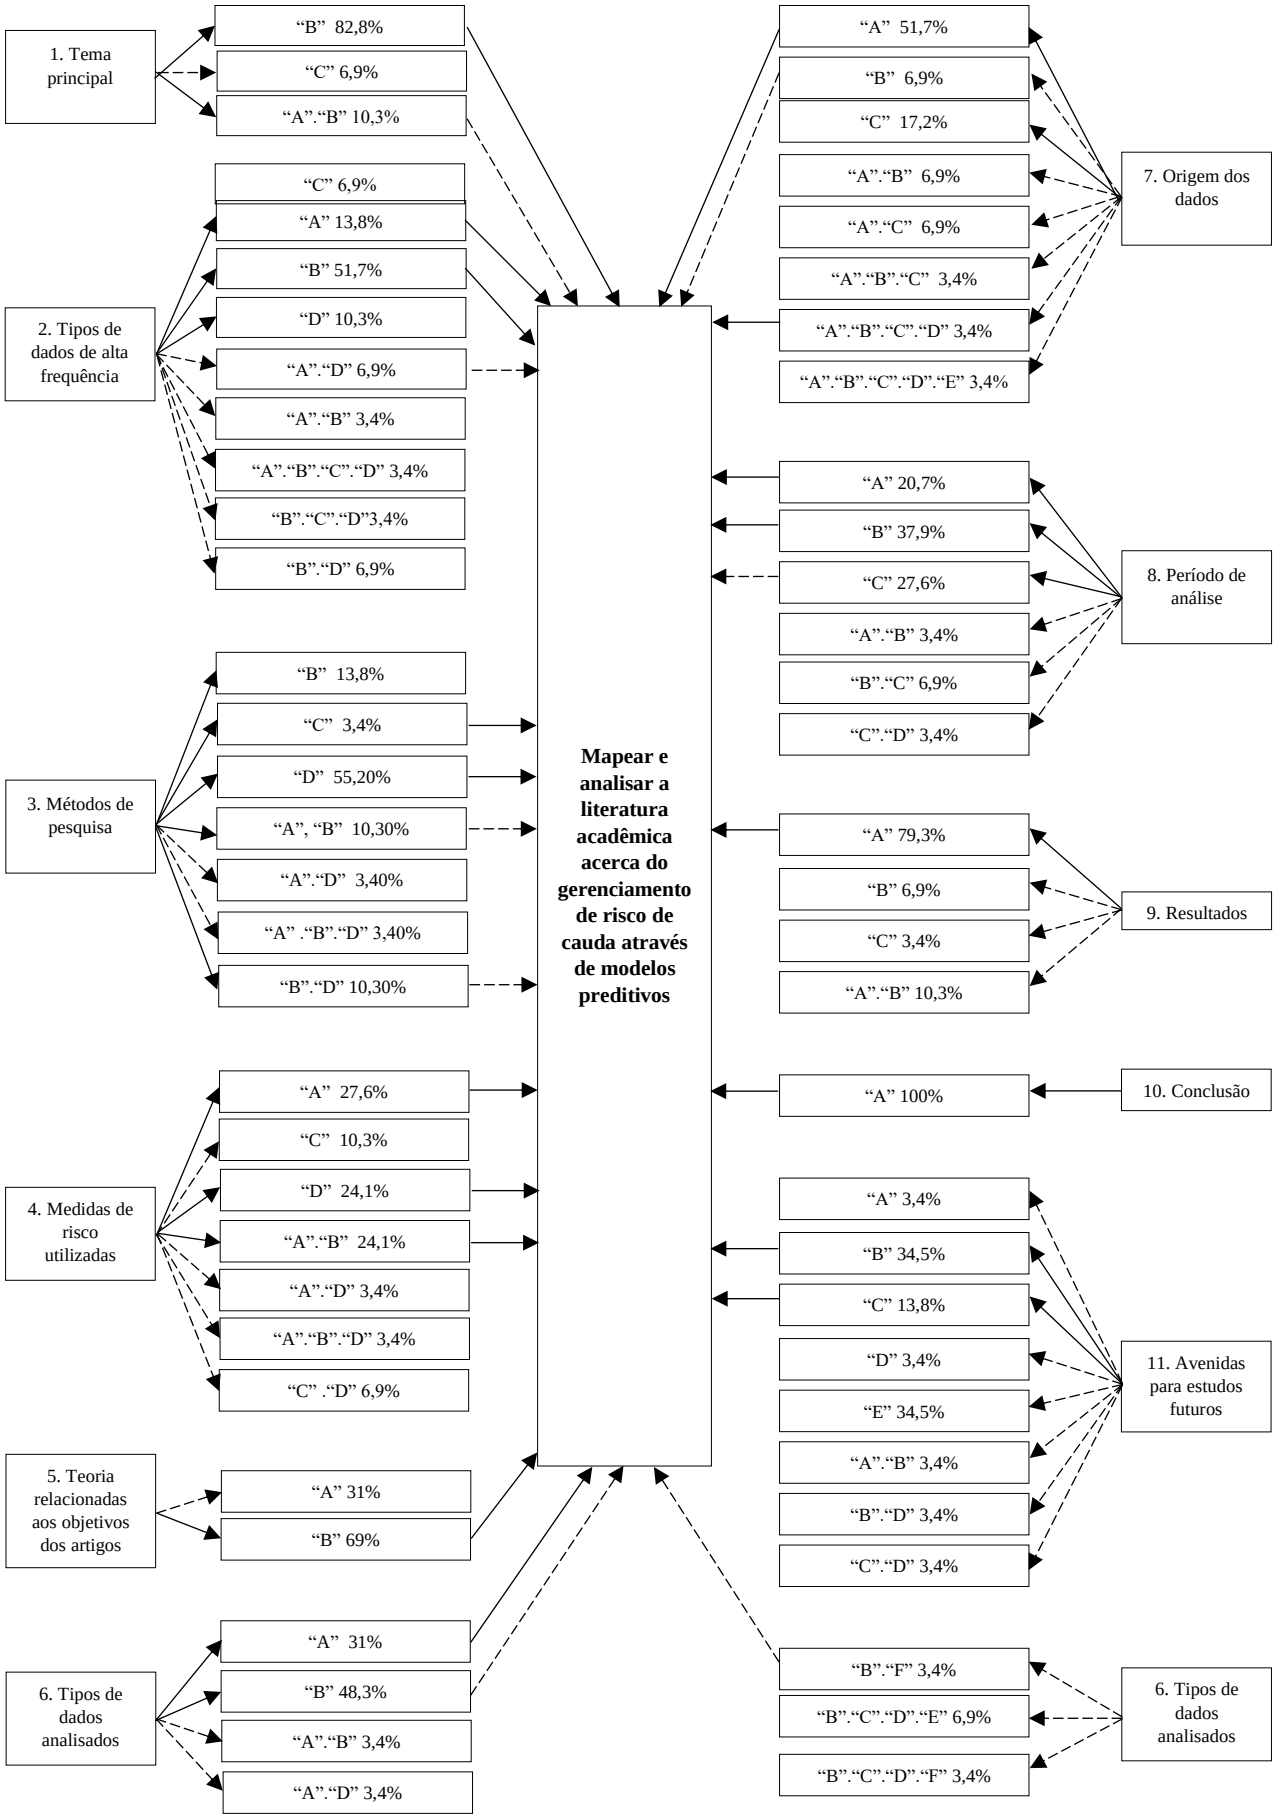


Tabela 09 – Principais contribuições dos artigos da amostra

No	Referência	Métodos de pesquisa	Dados analisados	Contribuições
1	Alexeev, Urga, Yao (2019)	Modelo ARMA e GARCH	501 ações extraídas da lista constituinte do índice S&P500 - Intervalo de 5 minutos	Este artigo fornece orientações importantes sobre a identificação de um tamanho ideal de portfólio de ações para estabilizar os betas de salto do portfólio com base em evidências que sugerem que os betas de cauda históricos são persistentes e capturam o risco sistemático futuro
2	Avdulaj, Barunik (2017)	Modelo semi-paramétrico não-linear de regressão de quantis	21 ações norte americanas - Intervalo de 5 minutos	O uso da volatilidade realizada sob uma estrutura de quantis de cópula é útil, particularmente nos casos em que a dependência de quantis é não-linear. Os modelos propostos capturas e preveem bem a dinâmica dos quantis
3	Bee, Dupuis, Trapin (2016)	RV-EVT (realizada) C-EVT (condicional)	17 índices de ações - Intervalo de 5 minutos	Este artigo questiona se a combinação dos recentes avanços na econometria financeira de alta frequência com os resultados da Teoria do Valor Extremo pode melhorar o ajuste das caudas da distribuição de retornos condicionais
4	Bee, Dupuis, Trapin (2019)	Peaks-over-threshold (POT) e realizada (RPOT)	Índice S&P 500 - Intervalo de 5 minutos	Neste artigo, é proposto uma nova abordagem de valores extremos de HF em que medidas realizadas são usadas para modelar o comportamento variável no tempo de retornos extremos
5	Bollerslev, Todorov, Li (2013)	Variante do método Peaks-Over-Threshold (POT)	50 maiores ações de capitalização incluídas no índice S&P 100 e índice futuro S&P 500 (SPFU) - Intervalo de 5 minutos	Neste estudo é apresentado um novo conjunto de procedimentos estatísticos para dissecar os saltos nos retornos de ativos individuais em componentes idiossincráticos e sistemáticos e para estimar as características distributivas conjuntas das caudas de salto correspondentes
6	Bormetti, Calcagnile, Treccani, Corsi, Marmi, Lillo (2015)	Processos de Hawkes auto-excitantes lineares	20 ações entre as mais líquidas do índice FTSE MIB da bolsa italiana - Intervalo de 1 minuto	A dinâmica desses saltos não é descrita nem por um modelo multivariado de Poisson nem por um modelo Hawkes multivariado. Neste artigo foi desenvolvido um modelo de um fator de Hawkes que é capaz de capturar simultaneamente o agrupamento temporal dos saltos e a alta sincronização dos saltos entre os ativos

7	Cai, Wu, Peng (2021)	Modelo GARCH-AI	Três índices de ações chinesas (SSEC, CSI300 e SZSEC) - Intervalo de 5 minutos	Neste artigo é proposto um modelo GARCH-AI realizado que introduz o método de correção de outliers no GARCH realizado para modelar séries temporais financeiras e prever volatilidade e medidas de risco
8	Chan, Ng, Ragell (2019)	Modelo de intervalo autorregressivo condicional - CARR	Conjunto 1: índice ASX200; conjunto 2: índice DJIA; conjunto 3: S&P500 - Intervalo de 5 minutos e intervalo de 30 minutos	Neste estudo foi demonstrado que o modelo de dois estágios que utiliza preços intradiários de alta frequência fornece uma boa previsão de retornos e preços dentro e fora da amostra com base em várias medidas de ajuste do modelo
9	Chavez-Demoulin, McGill (2012)	Processo Hawkes e modelo GPD	NVDA Corporation - Intervalo de 15 minutos	Propor uma nova metodologia de VaR que caracterize o comportamento de curto prazo de séries financeiras temporais tick-by-tick
10	Chen, Ding, Zhao (2019)	Curtose Realizada, Volatilidade Realizada (RVOL) e Índice de Assimetria Realizado (RSK)	Mercado de ações chinês - Intervalo de 5 minutos	Este artigo contribui para a literatura relacionada, lançando luz sobre este tópico no mercado de ações chinês. A evidência empírica neste artigo revela que há uma relação negativa econômica e estatisticamente significativa entre os retornos esperados das ações e a curtose realizada no mercado de ações chinês, e nos referimos a essa anomalia de preços como o ' enigma da curtose realizada '
11	Dimitriadis, Halbleib (2022)	Quantil diário e o ES dos retornos diários a partir do escalonamento de suas contrapartes	Taxa de câmbio EURUSD (tick data) e 27 ações de grande capitalização da NYSE - Intervalos de 1, 3, 5 e 10 minutos	Este artigo propõe uma nova abordagem para estimar medidas de cauda de retornos diários e prever VaR e ES diários diretamente de dados de HF. O método assume que os processos de preços logarítmicos financeiros são auto-similares, subordinados por uma dimensão de tempo alternativa, denotada como tempo intrínseco
12	Erdemlioglu, Gradojevic (2021)	Risco de salto realizado na variação de preço	Taxa de câmbio, futuros de títulos, VIX, índice de ações S&P 500 e índice Dow Jones - Intervalo de 5 minutos	Neste estudo foi desenvolvida uma nova estrutura empírica para identificar a propagação do risco de salto entre horizontes de investimento curtos e longos. A abordagem permite testar explicitamente a probabilidade de observar um regime de risco de salto realizado em uma determinada escala de tempo condicionada a outra
13	Fan, Imerman, Dai (2016)	Transformação de Fourier	Preços de transação para o SPDR ETF (volatilidade realizada) e VIX diário (volatilidade implícita) - Ultra-Alta Frequência (segundos)	Este artigo fornece uma análise orientada por dados do prêmio de risco de volatilidade, utilizando ferramentas de finanças de alta frequência e análise de grandes dados, gerando resultados que suportam a hipótese de que o sinal do

				prêmio de risco de volatilidade é indicativo de ganhos ou perdas em uma carteira com hedging
14	Ferriani, Zoi (2022)	Processos de Hawkes Multivariados	Índices S&P 500 e Euro Stoxx 50 - Intervalo de 5 minutos	Este é o primeiro artigo que estuda a transmissão de salto nesses mercados com base em dados de alta frequência. A estratégia de identificação de salto baseia-se em técnicas não paramétricas alternativas
15	Fuertes, Olmo (2013)	Previsão de quantil condicional (CQFE) baseado em GMM	Três índices de ações, índice do dólar americano (USDX), Notas do Tesouro dos EUA de 10 anos e preços futuros de ouro - Intervalo de 5 minutos	A principal novidade do trabalho é a proposta de combinação de previsão quantil condicional como um dispositivo eficaz para analisar e agrupar informações interdiárias e intradiárias
16	Karmakar, Paul (2016)	EVT Condicional (ARMA-GARCH-EVT)	16 índices de preços de ações - Intervalo de 5 minutos	A ênfase principal foi dada à metodologia de Valor Extremo e para avaliar o desempenho do modelo EVT Condicional na modelagem das caudas das distribuições e na estimativa e previsão de medidas intradiárias de VaR e ES.
17	Lai (2021)	Modelo de escore autorregressivo generalizado (GAS) e modelo GRAS	3 futuros de índices de ações negociados na Chicago Mercantile Exchange (CME) - Intervalo de 5 minutos	Notavelmente, a mudança do modelo GAS (ou Patton) para o modelo GRAS gera benefícios econômicos, e os hedgers altamente avessos ao risco podem se beneficiar mais
18	Louzis, Xanthopoulos-Sisinis, Refenes (2014)	Modelo HAR, GARCH realizado e GJR-GARCH	S&P 500 (ações), taxa de câmbio EUR/USD (câmbio), futuro de Notas do Tesouro de 10 anos para títulos de renda fixa e preços futuros de ouro para commoditie - Intervalo de 5 minutos	Com base em quatro classes de ativos, ou seja, ações, FOREX, renda fixa e commodities, e um período turbulento fora da amostra de seis anos (2007–2013), foi descoberto que a precisão estatística e a conformidade regulatória são essencialmente aprimoradas quando usamos métodos quantis que explicar as caudas gordas e a assimetria da distribuição das inovações
19	Malevergne, Pisarenko, Sornette (2005)	Modelo log-Weibull	1° amostra - retorno diário do Dow Jones Industrial Average Index (DJ); 2° amostra - retornos de alta frequência (5 min) do índice Nasdaq Composite (ND); 3° amostra - retornos de alta frequência (1 min) do índice Standard & Poor's 500 (SP 500) - Intervalo 5 minutos (NASDAQ) e Intervalo 1 minuto (S&P500)	O presente trabalho deve, portanto, ser avaliado como uma tentativa de fornecer uma descrição simples, eficiente e eficaz das caudas da distribuição de retornos cobrindo a maior parte da gama de interesse para aplicações práticas

20	Mao, Zhang (2018)	Stochastic Tail Index (STI)	Índice SPDR S&P 500 ETF e SHCOMP (China) - Intervalo de 3 minutos intraday e 5 minutos (SHCOMP)	A análise com base nos dois conjuntos de dados mostra que o índice de cauda variável no tempo do modelo STI é uma medida eficaz de risco devido ao fato de que o índice de cauda estimado tende a diminuir à medida que eventos extremos aparecem, refletindo um aumento no risco, e vice-versa
21	Mazzarisi, Zaoli, Campajola, Lillo (2020)	Processo VDAR(p) Autorregressivo Discreto Vetorial	39 ações pertencentes ao índice Russell 3000, negociadas nos mercados de ações dos EUA - Intervalo de 1 minuto	Nova abordagem estatística no espírito original de Granger, para testar se a informação sobre eventos extremos de uma série temporal é estatisticamente significativa na previsão de eventos extremos de uma segunda série temporal, introduzindo a generalização multivariada do processo autorregressivo discreto
22	Penzer, Schmid, Schmidt (2012)	Rho de Spearman condicional multivariado (MCS)	Preços das ações da GM versus IBM (Amostra 1) e também dez preços de ações negociadas na NYSE - BA, GE (Industrial), BAC, C (Financeiro), CVX, XOM (Energia), PG, WMT (Consumidor), T (Comunicações) e IBM (Tecnologia) - (Amostra 2) - Intervalo de 5 minutos	Foi demonstrado que o MCS tem várias vantagens sobre as medidas convencionais de dependência da cauda, tanto na teoria quanto em aplicações práticas.
23	Reboredo, Matias, Garcia-Rubio (2012)	Markov de dois estados (MS), modelo autorregressivo (AR), regressão de suporte vetorial e rede neural artificial feedfoward (ANN)	Índice S&P 500 - Intervalos de 5, 10, 30 e 60 minutos	Neste estudo foi comparado a capacidade de previsão fora da amostra de um modelo RW simples e um modelo de regressão AR, regressão SVM e um modelo de previsão combinado que potencialmente capturam retornos não lineares - em média, nos retornos intraday de ações
24	Salvatierra, Patton (2015)	Modelo de escore autorregressivo generalizado (GAS) e modelos GRAS (realizado) de cópula	3 pares de ações - Microsoft e Apple, Exxon e Chevron, Celgene e Johnson & Johnson - Intervalo de 5 minutos	Uma nova classe de modelos de cópula dinâmica para retornos diários de ativos preenche a lacuna entre os modelos de cópula variantes no tempo existentes, que usaram quase exclusivamente dados de frequência mais baixa, e modelos da literatura de previsão de volatilidade e correlação, que usaram com sucesso dados de alta frequência

25	Song, Li (2022)	Modelo R-Vine-Copula-GAS (RVCGAS)	Todas as ações negociadas na Bolsa de Valores de Xangai (Shanghai Composite Index) e 3 ações individuais dentro do mesmo índice (Banco Agrícola da China Co Ltd, PetroChina Co Ltd e Bank of China Ltd) - Intervalo de 1 minuto (Shanghai Composite Index) e 20, 30 e 40 minutos (3 ações individuais)	Este artigo propõe um novo modelo de medição de risco que incorpora diretamente informações de dados de alta frequência para prever o valor em risco diário e o déficit esperado.
26	Song, Tian, Li (2021)	Modelo Censored-GP (distribuição generalizada de Pareto) - DCS (modelo dinâmico orientado por pontuação condicional) - VaR	Shanghai SE Composite Index (SH000001), o Shenzhen SE Component Index (SZ399001), o Shanghai Pudong Development Bank (SPDB, SH6000000), o China Minsheng Banking (CMBC, SH600016) e o China Merchants Bank (CMB, SH600036) e SPDB, CMBC e CMB (bancos) - Intervalo de 20 minutos, intervalo de 30 minutos e intervalo de 40 minutos	Com a crescente demanda de gerenciar o risco de cauda e abordar a atividade intradiária no mercado financeiro, propomos o modelo censurado GP-DCS-VaR censurado para melhorar a avaliação do VaR diário, que é desenvolvido para gerar uma previsão de retorno diário diretamente da previsão de retorno intradiário
27	Sun, Rachev, Fabozzi (2009)	Modelo ARMA e GARCH com o uso da distribuição estável de Levy	Índice Deutsche Aktien Xchange (DAX) - Intervalo de 1 minuto	Um modelo ARMA-GARCH com resíduos de ruído estáveis de Lévy apresenta desempenho superior na modelagem de retornos de ações de alta frequência
28	Sun, Rachev, Fabozzi, Kalev (2009)	Modelo ARMA-GARCH da cópula	Nove índices de ações internacionais AORD (Austrália), DAX (Alemanha), FCHI (França), FTSE (Reino Unido), HSI (China), KS200 (Coréia do Sul), N225 (Japão), SPX (Estados Unidos) e STOXX (Suíça) - Intervalo de 1 minuto	O modelo proposto pelo artigo é capaz de uma previsão mais precisa para o comovimento simultâneo de vários mercados de ações, além da dependência de longo alcance das caudas pesadas e agrupamentos de volatilidade
29	Yalaman, Manahov (2022)	Movimento browniano	BIST-30 (índice do mercado de ações da Bolsa de Valores de Istambul) e TCELL, VSTEL e SNPAM (ações individuais) - Intervalo de 5 minutos	O estudo é o primeiro a investigar o processo de geração de dados em mercados emergentes, usando dados de alta frequência durante a crise financeira global de 2008 e dois períodos sem crise

Fonte: Elaborada pelo autor

A Tabela 10 apresenta as codificações das (sub) categorias dos 29 artigos examinados neste estudo - ver Tabela 2. Vale ressaltar que uma mesma categoria pode conter várias subcategorias. Logo, a soma da contagem das frequências das subcategorias - para cada categoria - totaliza 100% e não o total de 29 artigos da amostra final.

Tabela 10 – Codificação das categorias e subcategorias de análise dos artigos

No	Título	Categorias (números) e subcategorias (letras)										
		1	**2**	**3**	**4**	**5**	**6**	**7**	**8**	**9**	**10**	**11**
1	A New Approach for Using LEvy Processes for Determining High-Frequency Value-at-Risk Predictions	B	A	A, B	A	B	B	B	A	B	A	E
2	Dynamic copula models and high frequency data	B	B	B	D	B	A	A	B	A	A	C
3	High-frequency financial data modeling using Hawkes processes	B	D	D	A,B	A	A	A	A	A	A	B
4	Generalized autoregressive score model with high-frequency data for optimal futures hedging	C	B	B	D	B	B	A	C	A	A	E
5	Heterogeneous investment horizons, risk regimes, and realized jumps	B	B	D	D	B	B,C, D,F	A,B	B	A	A	D
6	Modelling systemic price cojumps with Hawkes factor models	B	A	D	D	B	A	B	A	A	A	B
7	Stochastic tail index model for high frequency financial data with Bayesian analysis	B	B,D	D	C	A	B	A,C	B	A	A	C,D
8	Realized Peaks over Threshold: A Time-Varying Extreme Value Approach with High-Frequency-Based Measures	B	B,D	D	A,B,D	A	B	A	C	A	A	C
9	Realizing the extremes: Estimation of tail-risk measures from a high-frequency perspective	B	B	B,D	A, B	A	B	A, B, C, D	C	A	A	E
10	What Does the Volatility Risk Premium Say About Liquidity Provision and Demand for Hedging Tail Risk?	C	D	D	D	B	B,F	A	B	A	A	B
11	Realized Quantiles*	B	A,B, C,D	D	A, B	B	A,D	A	B, C	A	A	B, D

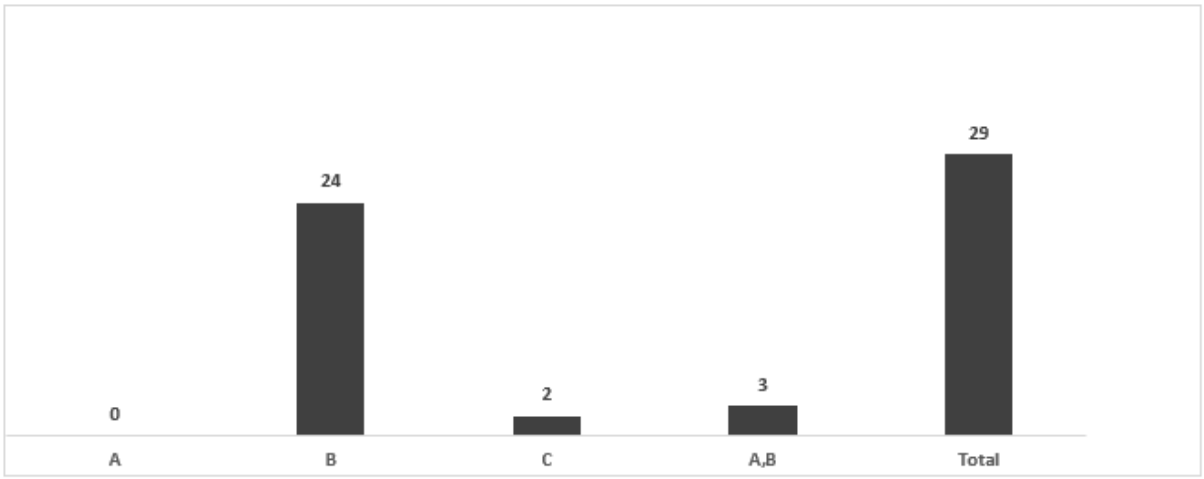
12	Jump tails, extreme dependencies, and the distribution of stock returns	B	B	D	C, D	A	B	A	C	A	A	B
13	Measuring large comovements in financial markets	B	B	D	A, D	A	A	A	A, B	A	A	E
14	Optimally harnessing inter-day and intra-day information for daily value-at-risk prediction	B	B	C	A	B	B,C, D,E	A	C	C	A	B
15	The dynamics of price jumps in the stock market: an empirical study on Europe and US	B	B	D	C, D	B	B	A, B	B	A, B	A	A, B
16	Analysing emerging market returns with high-frequency data during the global financial crisis of 2007-2009	B	B	D	D	B	A,B	C	B	A	A	B
17	Nonlinearity in Forecasting of High-Frequency Stock Returns	A, B	B,C, D	A,B, D	A	B	B	A	A	A, B	A	E
18	A new model for forecasting VaR and ES using intraday returns aggregation	A, B	A,D	D	A, B	B	A	C	B, C	A	A	A
19	Intraday risk management in International stock markets: A conditional EVT approach	A, B	B	A,B	A, B	A	B	A, B, C, D, E	A	A	A	E
20	A lottery-preference-based explanation of realized kurtosis puzzle in Chinese stock market	B	B	D	D	B	A	C	B	A, B	A	E
21	An intraday-return-based Value-at-Risk model driven by dynamic conditional score with censored generalized Pareto distribution	B	D	B,D	A	A	B	C	B	A	A	B
22	Forecasting volatility with outliers in Realized GARCH models	B	B	B	A, B	B	B	C	B	A	A	B
23	A semiparametric nonlinear quantile regression model for financial returns	B	B	D	A	B	A	A	B	A	A	C
24	A new approach to modeling co-movement of international equity markets: evidence of unconditional copula-based simulation of tail dependence	B	A	A,B	C	B	B	A, B, C	A	A	A	E
25	Asymmetric jump beta estimation with implications for portfolio risk management	B	B	D	A, B	B	A	A	C	A	A	B

26	Tail Granger causalities and where to find them: Extreme risk spillovers vs spurious linkages	B	A	A,D	A	B	A	A	C	B	A	E
27	Bayesian return forecasts using realised range and asymmetric CARR model with various distribution assumptions	B	A,D	B	A	B	B	A, C	B	A	A	C
28	Realized volatility models and alternative Value-at-Risk prediction strategies	B	B	B,D	A	A	B,C, D,E	A	C	A	A	B
29	Empirical distributions of stock returns: between the stretched exponential and the power law?	B	A,B	D	C	B	B	A	C, D	A	A	E

Fonte: Elaborado pelo autor

A Figura 4 indica que, com relação ao tema principal / foco do estudo, a subcategoria B – Gerenciamento para monitorar o risco de cauda – possui a maior representatividade, estando presente em 24 artigos (82,76%) das subcategorias analisadas. Gerenciamento de risco para *hedging*, subcategoria C, presente em 02 (6,9%) e Gerenciamento de risco através de previsão de preços/retornos (categoria A) combinado com a categoria B, presente em 03 (10,34%).

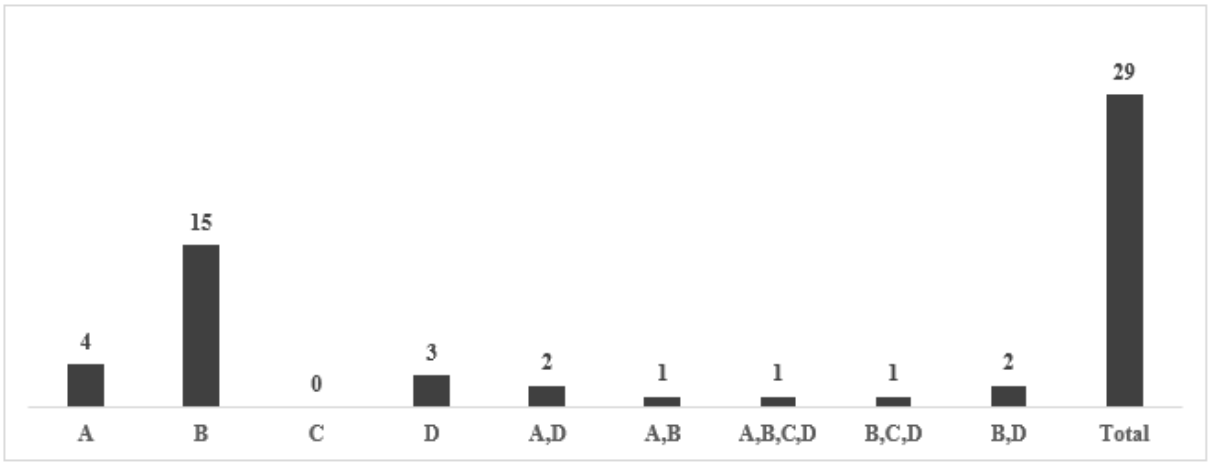
Figura 04 – Categoria 01 – Tema principal/foco do estudo



A – Gerenciamento de risco através de previsão de preços/retornos
B – Gerenciamento para monitorar o risco de cauda
C – Gerenciamento de risco para *hedging*

Sobre a Figura 5, há uma predominância da subcategoria B – 5 minutos (51,72% ou 15 ocorrências) sobre os demais métodos de pesquisa presentes nos artigos da amostra. Os demais artigos também apresentam análises baseadas em outros tipos de dados em alta frequência, como de 1 minuto, presente em 04 artigos (13,79%) e demais combinações de análises 07 (24,14%) da amostra, além de outros tipos de frequência estudados, subcategoria D (10,43% ou 03 ocorrências).

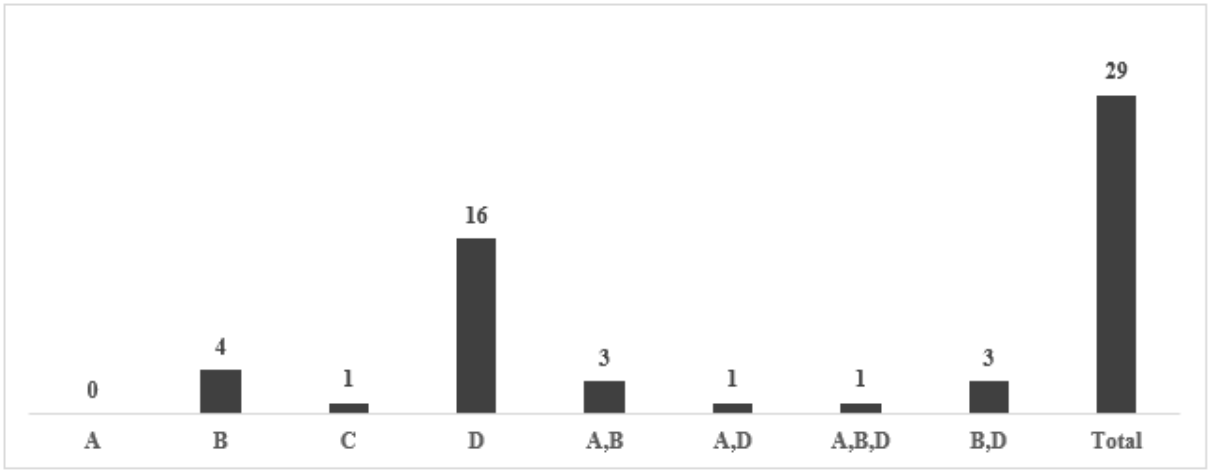
Figura 05 – Categoria 02 – Tipos de dados de alta frequência



A – 1 minuto
B – 5 minutos
C – 10 minutos
D – Outros

A Figura 6 demonstra que a subcategoria D – Outros, é dos métodos utilizados nas pesquisas, o mais presente, ou seja, a maior parte dos artigos (55,17% ou 16 ocorrências) utilizam outros tipos de métodos além dos presentes nas subcategorias A, B e C que representam em conjunto 17,24% dos métodos utilizados, ficando por conta das combinações entre métodos o peso de 27,59%, em 8 dos 29 artigos analisados.

Figura 06 – Categoria 03 – Métodos de pesquisa

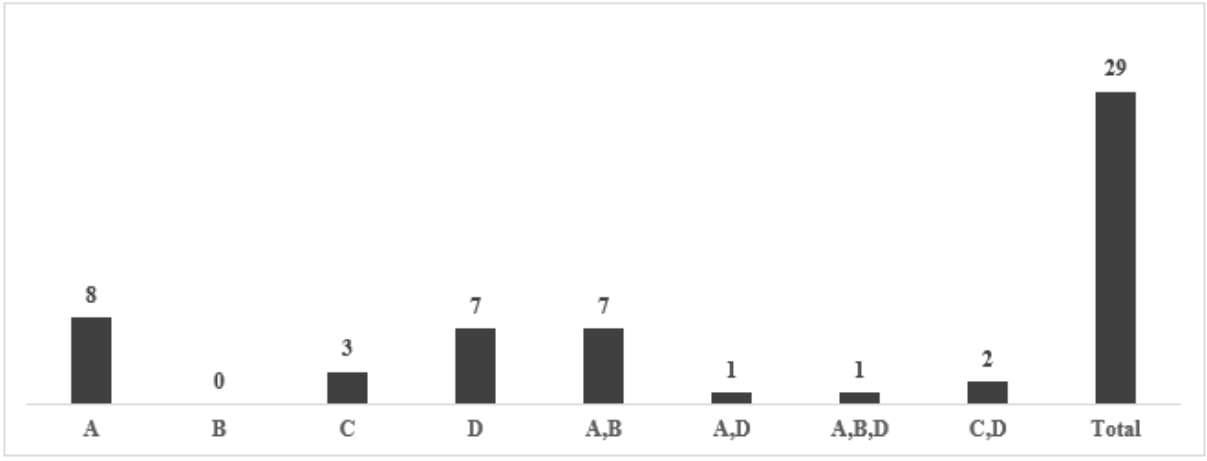


A – Família ARMA
B – Família ARCH
C – GMM
D – Outros

Quanto à Figura 7, as medidas de risco utilizadas, os dados analisados com maior concentração referem-se à subcategoria A, VaR (Value-at-Risk), apresentando 8 ocorrências (27,59%). Em seguida aparece a subcategoria C – Quantis, com o segundo maior peso

isoladamente (24,14%). No que concerne a combinações entre as medidas, existem 4 tipos que aparecem em 37,94% dos artigos, ou seja, VaR e ES (24,14%), VaR e Quantis (3,45%), VaR, ES e Quatis (3,45%) além de Quantis combinado com - Outras (6,90%).

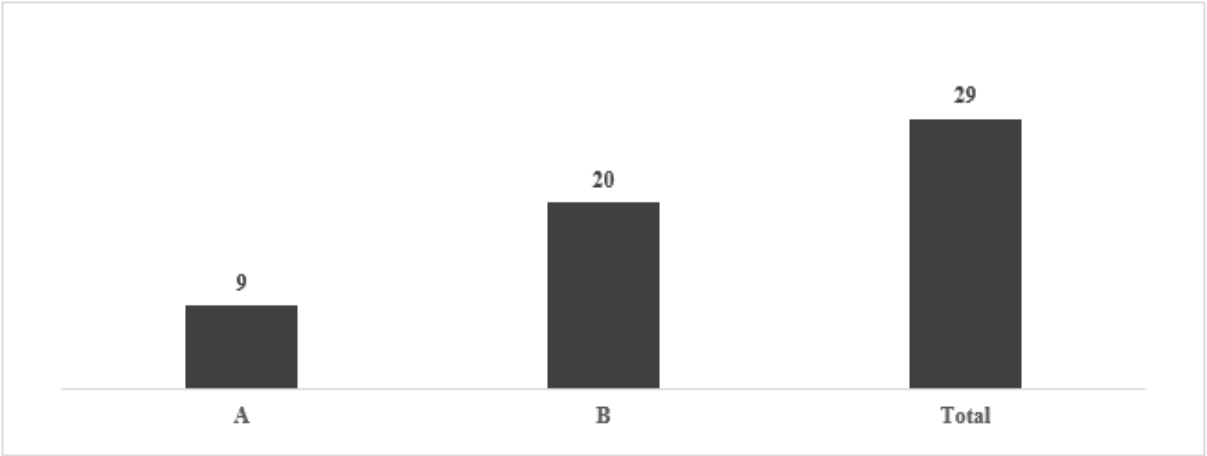
Figura 07 – Categoria 04 – Medidas de risco utilizadas



A – VaR (Value-at-Risk)
B – ES (Expected Shortfall)
C – Quantis
D – Outras

Quanto à Figura 8, as teorias relacionadas aos objetivos dos artigos, é possível notar que a maior parte dos estudos analisados não se utilizam de nenhum tipo de teoria (68,97% ou 20 ocorrências), ficando por conta de somente 9 (31,03%) o uso da Teoria de Valores Extremos.

Figura 08 – Categoria 05 – Teorias relacionadas aos objetivos dos artigos

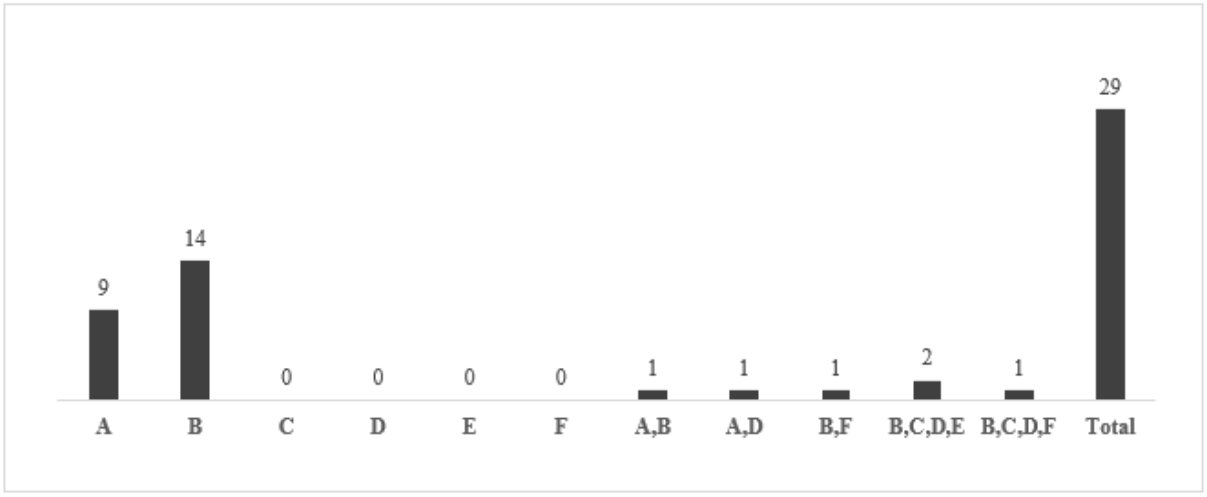


A – Teoria de Valores Extremos
B – Nenhuma

Quanto à Figura 9, os tipos de dados utilizados com maior concentração referem-se à subcategoria B – Índices de ações (48,28%), seguido do uso somente de ações – subcategoria A – que representa 9 ocorrências (31,03%). A parcela de 20,69% (6

ocorrências) é representada por uma série de combinações de diferentes tipos de dados como pode ser observado no gráfico.

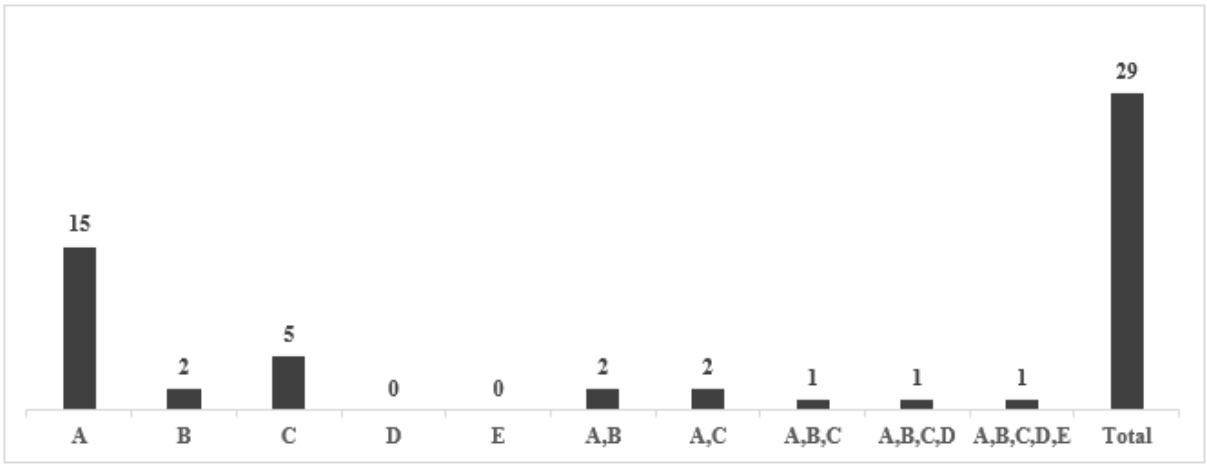
Figura 09 – Categoria 06 – Tipos de dados utilizados



A – Ações
B – Índices de ações
C – Câmbio
D – Commodity
E – Outros

Quanto à Figura 10, os dados têm origem em maior concentração isoladamente nos Estados Unidos (51,72%), seguido por dados oriundos da Ásia/Oceania (17,24%) e da Europa (6,9%). Contudo ressalta-se que há estudos em volume relevante (24,14%), que incluem dados combinados de mais de uma dessas regiões.

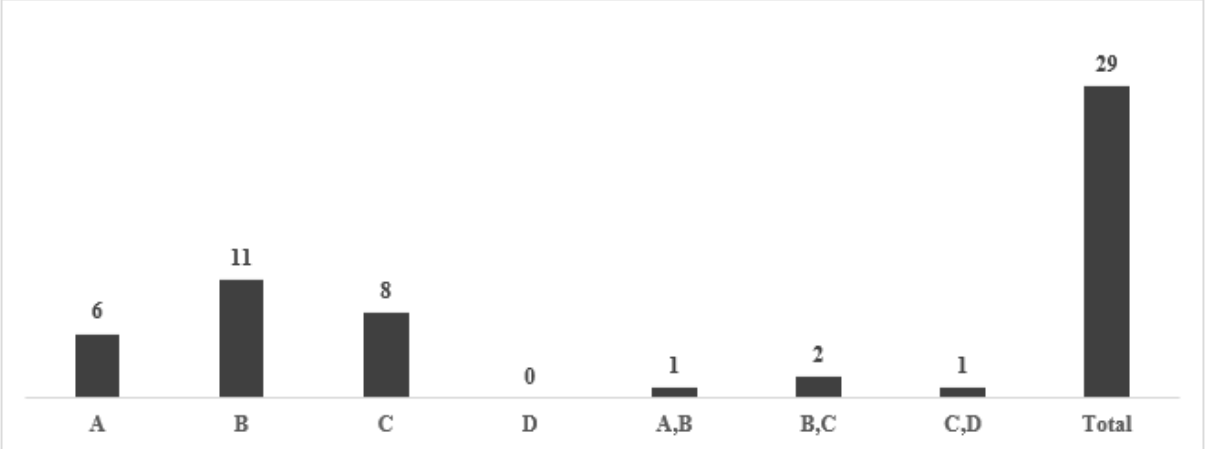
Figura 10 – Categoria 07 – Origem dos dados



A – Estados Unidos
B – Europa
C – Ásia/Oceania
D – América Latina
E – África

Quanto ao período de análise da amostra de dados dos estudos, a Figura 11 aponta que 37,93% dos dados pertencem à subcategoria B – De 3 a 10 anos. A subcategoria seguinte – De 10 a 20 anos, representa 27,59% ou 6 ocorrências. Com 20,69% aparece a subcategoria A – Até 2 anos. Além disso, 13,79% dos artigos, fazem uso de diferentes combinações de períodos.

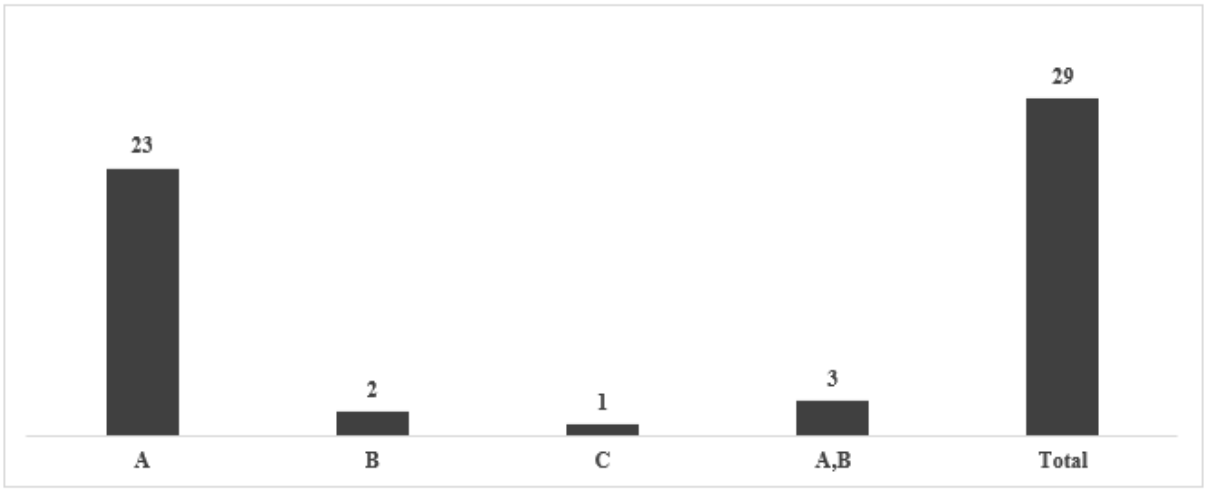
Figura 11 – Categoria 08 – Período de análise



A – Até 2 anos
B – De 3 a 10 anos
C – De 10 a 20 anos
D – Mais de 20 anos

Com relação à análise dos resultados dos estudos, a Figura 12 mostra que a grande maioria, 79,31% dos estudos, estão classificados na subcategoria A – Novas perspectivas ou novas conclusões. Já no que se refere a subcategoria B - Conclusões semelhantes a trabalhos anteriormente apresentados, 2 ocorrências (6,9%) são apresentadas, sendo que existem 3 artigos (10,34%) que fazem uso da combinação de A e B. Por sua vez a subcategoria C – Outros, representa somente 1 artigo (3,45%) que seus resultados diferem dos outros analisados.

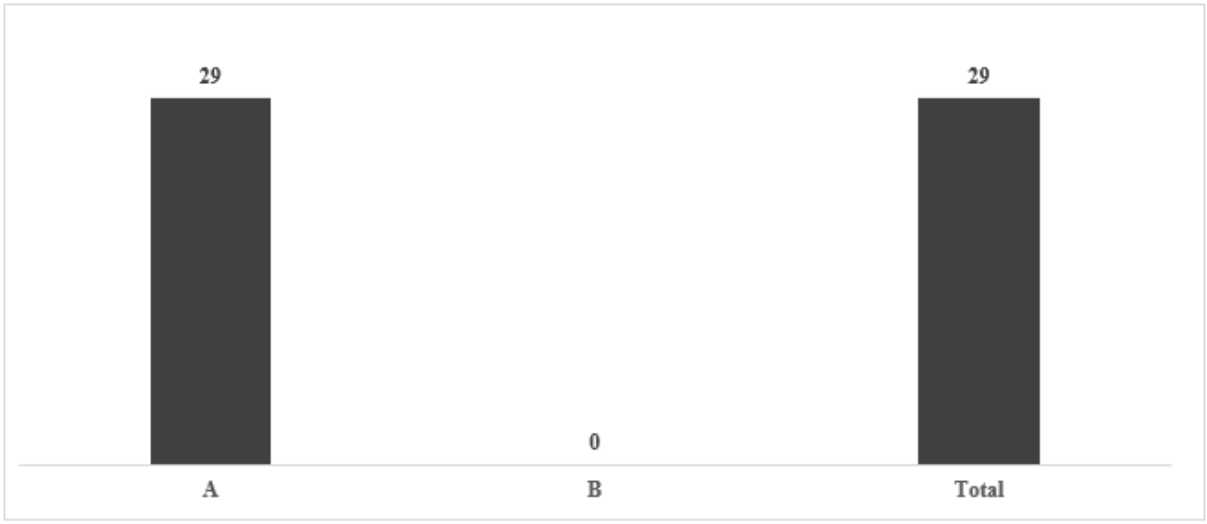
Figura 12 – Categoria 09 – Resultados



A – Novas perspectivas ou novas conclusões
B – Conclusões semelhantes a trabalhos anteriormente apresentados
C – Outros

Por sua vez, a Figura 13 esclarece que 100% dos estudos confirmaram seu objetivo principal.

Figura 13 – Categoria 10 – Conclusão

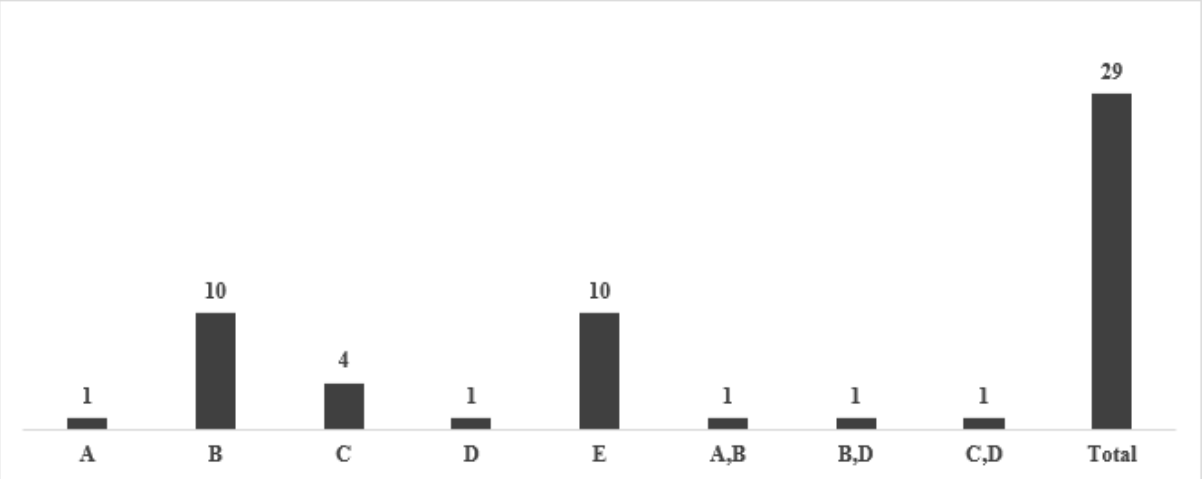


A – Confirmação do objetivo principal
B – Não confirmação do objetivo principal

A Figura 14 analisa as avenidas para estudos futuros. 34,48% dos artigos recomendam exclusivamente o exame de diferentes dados dos utilizados neles e o mesmo percentual (34,48%) não menciona nenhuma avenida para estudos futuros. A representatividade é seguida com 13,79% das pesquisas indicam a avaliação de outros modelos de previsão. Somente 1 ocorrência é encontrada para as categorias A – Examinar outras medidas de risco e para a categoria C – Analisar através dos resultados outras questões

de trabalhos anteriores. Já no que concerne as combinações de subcategorias, é apresentado em três tipos distintos um artigo que combina A e B, um artigo que combina B e D além de um artigo que combina C e D.

Figura 14 – Categoria 11 – Avenidas para estudos futuros



A – Examinar outras medidas de risco

B – Examinar diferentes dados

C – Avaliar outros modelos de previsão

D – Analisar através dos resultados outras questões de trabalhos anteriores

E – Não mencionado

Considerando-se a escassez de pesquisas sobre o tema, este estudo realiza uma análise bibliométrica e a revisão sistemática da literatura, com enfoque em modelos preditivos de gestão de risco para proteger carteiras de investimento contra grandes perdas em situações de mercado estressantes como eventos. Como resultado, há a identificação de lacunas de conhecimento a serem preenchidas por uma proposta de futura agenda de pesquisas relacionadas a esse tema.

A amostra inicial é composta por 119 artigos, que após a adoção dos critérios de exclusão mencionados acima, é reduzida para 29 pesquisas finais, obtidos na base de dados *WoS*. A análise bibliométrica apresenta dados quantitativos por meio de gráficos e mapas de relacionamento. Essas verificações ocorrem através dos *softwares RStudio*, *Biblioshiny*, *VOSviewer* e *Rank Words.* Por sua vez, a revisão sistemática identifica a frequência das (sub) categorias definidas para a amostra final. Sua verificação permite a percepção de quais combinações de subcategorias são viáveis para investigações futuras.

Como é possível verificar através dos resultados obtidos através da análise bibliométrica e revisão sistemática da literatura, este estudo traz resultados pioneiros ao apresentar o gerenciamento de risco com o uso de dados em alta frequência que geram milhões de observações para cada ativo estudado, dados esses de ativos listados na bolsa de valores brasileira. Além disso a pesquisa traz uma técnica de estimação estatística (GMM) que possui grandes vantagens para tratar séries de tempo financeiras que apresentam heterocedasticidade, que ocorre quando a volatilidade apresenta variações ao longo do tempo e endogeneidade, que se baseia em casos em que a variável explicativa apresenta correlação com erro, sendo essas características, muito comuns em séries de dados em alta frequência.

Como complemento para o primeiro modelo utilizado e, ampliando o conhecimento para área de finanças, é desenvolvido um algoritmo de *machine learning* como previsor para proteção de carteiras. Nessa pesquisa, porém, de forma inicial no estudo de conceitos de aprendizagem supervisionado para ativos que será ampliado e explorado de melhor forma em futuros trabalhos.

3. METODOLOGIA

A metodologia desta dissertação está dividida em duas etapas. A primeira é formada constituída pelo método dos momentos (*Generalized Method of Moments* – GMM), onde são aplicadas duas medidas de perda, o *Value-at-Risk* (VaR) e o *Expected Shortfall* (ES). Essas medidas usam distribuição de probabilidade de variáveis aleatórias e caracterizam o risco de mercado, resultando na perda esperada pelos investidores.

Como forma do desenvolvimento de dois modelos preditivos para garantir análises precisas de risco de cauda, além do método dos momentos é apresentada uma rede neural do tipo LSTM (*Long Short-Term Memory*) que utiliza uma parcela dos dados das séries de tempo como aprendizado para garantir previsões resultados que podem ser utilizados em tomadas de decisão em situações de incerteza financeira.

Essa pesquisa é identificada como quantitativa, em que os dados são tratados através de técnicas estatísticas e econométricas, no caso desta, técnicas baseadas em *machine learning* também são utilizadas para corroborar as estimativas propostas.

3.1 MEDIDAS E FATORES DE RISCO DE CAUDA

As principais medidas de modelos multivariados em séries de tempo financeiras são o *Value-at-Risk* (VaR) e o *Expected Shortfall* (ES). O VaR foi a primeira proposta de

estimativa de perdas, criada pelo Banco J.P.Morgan (1996) e sua popularização, se deveu à facilidade de cálculo.

O cálculo sintetiza a maior (ou pior) perda esperada dentro de determinado período e intervalo de confiança, ou descreve o percentil da distribuição de retornos projetada sobre um horizonte estipulado (JORION, 2003).

Perda que não será excedida em um intervalo de confiança especificado, ou um esforço para proporcionar à alta administração números que sumarizem o risco total de um portfólio de ativos financeiros (HULL, 2005).

O ES é usado com frequência para calcular o risco de uma carteira além de medir a perda média sobre o VaR em um determinado nível de confiança α. Na literatura é notada uma carência de métodos que combinem previsões de ES. Tal carência está relacionada ao fato de que o ES não possui elicitabilidade, que é uma propriedade matemática para a seleção de modelo em escala relativa, fazendo com que não exista uma função de perda tal que a correta previsão de ES seja a solução para minimizar a perda esperada (GNEITING, 2011). Uma solução para esse problema foi proposta por Fissler e Ziegel (2016) ao introduzir uma classe de funções de perda que superam a falta de elicitabilidade para o ES ao modelar conjuntamente com o valor em risco (VaR). Sendo o VaR descrito como a perda máxima esperada incorrida ao longo de um horizonte de tempo, no nível de confiança estabelecido em condições normais.

Dessa maneira q%VaR denota o percentil q da distribuição conjunta condicional, e o ES correspondente denota o valor esperado das observações abaixo de seu VaR.

O cálculo escolhido para avaliação das expectativas de perdas em ativos, foram o *Value-at-Risk* e o *Expected Shortfall*.

A perda esperada de um ativo (ou portfolio) em um determinado período pode ser definida como:

$$L_{[t,t+\Delta]} = -\{V(t, t+\Delta) - V(t)\} \quad (6)$$

Na qual:

V(t) = é o valor do ativo na data t

Δ = é o período para calcular a perda esperada

3.2 MODELOS DE PREVISÃO

3.2.1 *GENERALIZED METHOD OF MOMENTS* (GMM)

Para a estimação do VaR, deve-se estimar a média e o desvio-padrão utilizando-se o método *Generalized Method of Moments* (GMM). Assim, primeiro temos que calcular a média e o desvio padrão para os retornos do Ibovespa em estudo utilizando o GMM. Os estimadores GMM são encontrados equacionando os primeiros k momentos da amostra aos k momentos da população correspondentes e resolvendo o sistema resultante de equações simultâneas. O GMM foi utilizado porque permite também obter-se uma estimativa dos erros padrão tanto para a média quanto para a variância e, portanto, possibilitando o cálculo de erros padrão e intervalos de confiança mesmo para as estimativas de VaR. A equação para a média é dada por:

$$E(y) - y = 0 \tag{7}$$

$$\frac{1}{T}\sum_{t=1}^{t}(y_t - \hat{\mu}) = 0 \tag{8}$$

Na qual: $\hat{\mu}$ é o estimador GMM do verdadeiro parâmetro populacional μ.

A equação da variância é dada por:

$$E(y-\mu)^2 - \sigma^2 = 0 \tag{9}$$

$$\frac{1}{T-1}\sum_{t}^{T}(y_t - \hat{\mu})^2 - \sigma^2 \tag{10}$$

Na qual:

γ_t = Observação

$\hat{\mu}$ = Erro estimado do modelo

3.2.2 *LONG SHORT-TERM MEMORY* (LSTM)

Para complementar as propriedades do modelo desenvolvido acima no que se refere a suas respectivas capacidades preditivas, nesta seção são aplicados métodos de aprendizado de máquina recorrentes na previsão de direção, preço ou retorno no mercado de ações a partir de séries temporais financeiras.

Para isso foi adotado um tipo especial de redes neurais artificiais, as redes LSTM (*Long Short-Term Memory*) que possuem grande capacidade de identificar padrões de longo prazo. Esse processo se baseia na estrutura da célula LSTM formada por janelas de entrada e janelas de saída, onde são armazenadas informações valiosas do passado e descartadas as informações que não possuem importância para a rede. Como corroborado por Nelson, Pereira, De Oliveira (2017) que estudaram a previsão de movimentos de ações no intervalo de 15 minutos na Bovespa, as redes LSTM são capazes de gerar resultados altamente promissores quando comparadas a outras abordagens convencionais.

Como é possível observar nas imagens abaixo, as redes LSTM foram aplicadas para prever a perda de 1 ação da B3, a PETR3, onde os dados utilizados foram dispostos de modo a satisfazer a condição de 80% sendo para o treinamento do modelo e os 20% restantes para o teste de previsão.

3.3 BANCO DE DADOS

A análise foi feita através de duas amostras de dados coletadas do *Market Data* da B3 (Bolsa de Valores do Brasil). A primeira amostra é composta pelo preço de sete ativos coletados na frequência de milissegundos que foram submetidos ao tratamento e colapsados para a frequência de 30 segundos, sendo esses ativos: B3SA3 (B3 AS – Brasil, Bolsa, Balcão), BBAS3 (Banco do Brasil SA), BBDC4 (Banco Bradesco SA), ITUB3/ITUB4 (Itaú Unibanco) e PETR3/PETR4 (Petróleo Brasileiro AS Petrobras), sendo que o número 3 representa ações ordinárias e o número 4 ações preferenciais. Essa primeira amostra de dados foi utilizada no primeiro modelo do estudo, o método dos momentos (GMM) e sua escolha foi feita pela disponibilidade dos dados em milissegundos dos ativos listados acima, que foram tratados extraindo sua variação ao longo da série de tempo. O período compreende as datas de 03-01-2022 às 10:09:26 a 29-12-2022 às 18:07:54.

Já para a segunda amostra de dados, foi utilizado um ativo, PETR3 (Petróleo Brasileiro AS Petrobras) junto com as respectivas cotações do Índice Bovespa (IBOV), nesse caso, utilizando-se somente de ações ordinárias. Nessa amostra a frequência é composta por dados listados a cada 30 segundos, que é exatamente o tempo que o Índice Bovespa leva para ser atualizado, além de que esses dois ativos utilizados na segunda amostra foram os que estavam disponíveis para o uso nesta pesquisa. O período analisado inicia-se em 08-04-2019 às 10:04:00 até o dia 30-12-2021 às 18:12:30. O que ponto principal que diferencia essa amostra da primeira é que nessa foi utilizado um índice de ações (IBOV) junto ao ativo e, isso se deve a construção do segundo modelo onde esses dados foram inseridos, que no

caso é a rede LSTM (*Long Short-Term Memory*), sendo que por se tratar de um modelo de previsão de perda, foi utilizado a variação do preço dos dois ativos, resultando em uma variável extremamente pequena como era de se esperar visto resultados da primeira amostra, porém as previsões neste modelo de rede neural artificial ficaram instáveis e, por esse motivo, optou-se por acrescentar uma segunda variável (IBOV) na mesma frequência de 30 segundos para que fosse possível gerar resultados com maior acurácia nas previsões.

Por se tratar de dados de alta frequência, nesta pesquisa foi utilizada a técnica de interpolação constante por partes, onde casos em que aparecem dados faltantes são preenchidos com o último preço apresentado *t-1*. Essa característica é comum em séries de tempo financeira deste tipo, sendo esse o tratamento mais comum encontrado na literatura sobre o assunto.

4. RESULTADOS

Nesta sessão são apresentados os principais resultados gerados pelos dois modelos em questão. No que diz respeito ao método dos momentos, todos os testes estatísticos e econométricos para estimação de VaR e ES, foram feitos utilizando o *software* Stata/SE 17.0. Por outro lado, no segundo modelo, a rede LSTM foi desenvolvida no *Google Colaboratory* utilizando linguagem *python* e processamento com *Graphical Processing Unit* (GPU).

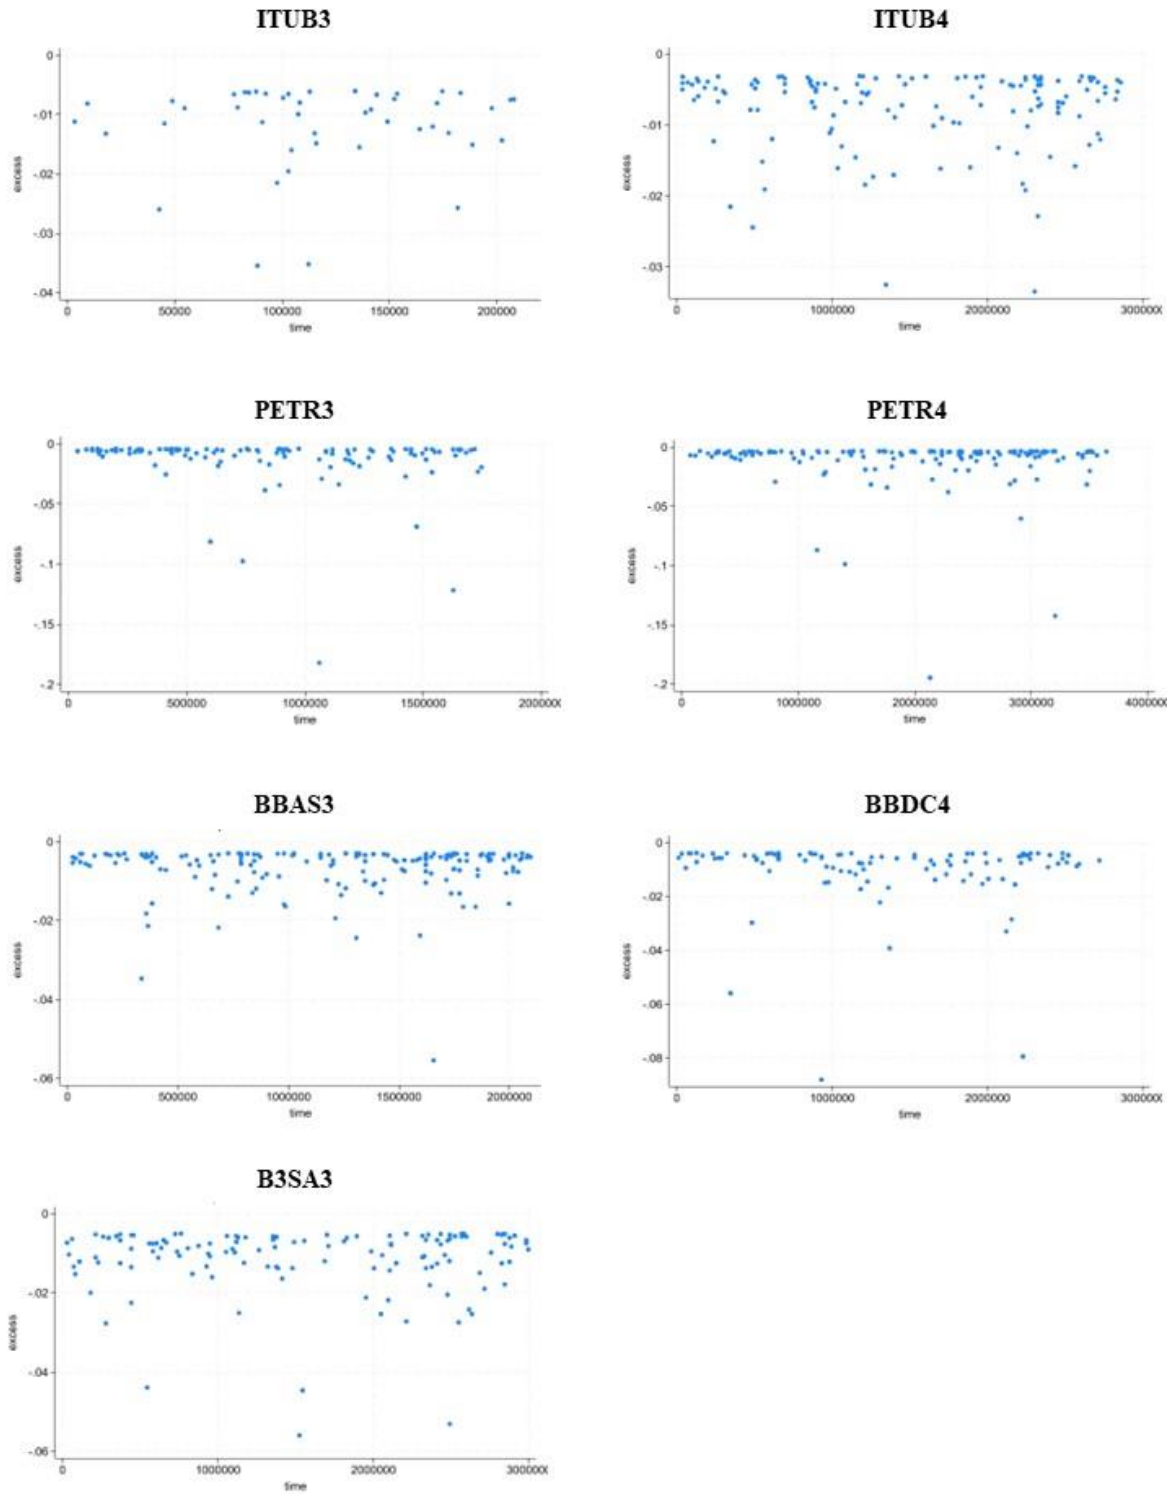
4.1 *GENERALIZED METHOD OF MOMENTS* (GMM)

Este capítulo apresenta os resultados obtidos pelo método dos momentos (GMM) composto por sete ativos no ano de 2022 no qual são utilizadas duas medidas de risco para calcular a perda, o *Value-at-Risk* e o *Expected Shortfall*. Destaca-se que todos os resultados provenientes do modelo tanto para o Var quanto para o ES são resultados negativos visto que são medidas que representam perda. O método GMM foi escolhido pois ele permite a obtenção da estimação dos erros padrão para a média e a variância, e portanto, possibilitando a mesma estimação para o VaR. Segundo Hansen (1982), o GMM é uma forma de estimação, na qual, iguala-se um dos momentos da distribuição a um determinado valor. No processo, o estimador cria a situação das amostras serem muito próximas, quando a suas ortogonalidades tendem a zero.

Nesta situação, não se busca mais os momentos da distribuição, mas sim, os parâmetros decorrentes das condições da amostra. É uma forma de se igualar um dos momentos, por exemplo a média a um determinado valor, satisfazendo as condições necessárias da média amostral. Com base no modelo desenvolvido utilizando GMM os

resultados obtidos foram:

Figura 15 - *Expected Shortfall* - 7 ativos analisados



Fonte: Elaborado pelo autor

Tabela 11 – *Value-at-Risk* e *Expected Shortfall* (Sig. 95%)

	Obs.	VaR	Obs.	ES
B3SA3	2996560	-0.0048	136	-0.01129
BBAS3	2110084	-0.0028	178	-0.00655
BBDC4	2718729	-0.0036	114	-0.00971
ITUB3	217241	-0,0058	46	-0,001172
ITUB4	2867562	-0,0031	143	-0,00737
PETR3	1824490	-0,0038	119	-0,001301
PETR4	3690625	-0,0032	168	-0,01060

Fonte: Elaborada pelo autor

Assim é possível notar que como o cálculo é feito com VaR, ao nível de significância de 95%, para uma janela de 30 observações, o *Expected Shortfall* é o número se observações que supera o valor do VaR. Como a construção do modelo foi feita através do método dos momentos ao longo de todo o período do ano de 2022, é possível depreender através dos resultados que para os sete ativos utilizados, B3SA3, BBAS3, BBDC4, ITUB3, ITUB4, PETR3 e PETR4 existe uma probabilidade de 0,0045%, 0,0084%, 0,0042%, 0,0212%, 0,005%, 0,0065% e 0,0046% respectivamente dos pontos fora da curva representados pelo ES superarem o VAR.

Dessa forma a segunda hipótese de que é possível detectar os riscos de cauda em dados de alta frequência utilizando medidas tradicionais como VaR e ES é confirmada através dos resultados apresentados.

4.2 *LONG SHORT-TERM MEMORY* (LSTM)

Nessa seção é apresentada os resultados obtidos através da rede *Long Short-Term Memory* (LSTM) construída através do *Google Colaboratory*, rede que foi escolhida principalmente pelo fato de possuírem a característica de aprender as dependências da série de longo prazo. Na tabela 22 é possível observar as caracteristicas principais da rede LSTM, mantidas no formato original para não alterar os termos originais.

Se trata de uma rede com duas camadas (Lstm_14 e Lstm_15) e uma camada de *Dropout* (Dropout_7), que está relacionado ao método em que as conexões de entrada são excluídas da ativação e das atualizações de peso no processo de treinamento para reduzir o overfitting e melhorar o poder preditivo do modelo. No que diz respeito ao overfitting, nada

mais é do que a característica do modelo em questão de se adaptar excessivamente ao conjunto de dados de teste de forma a prejudicar seu poder de previsão.

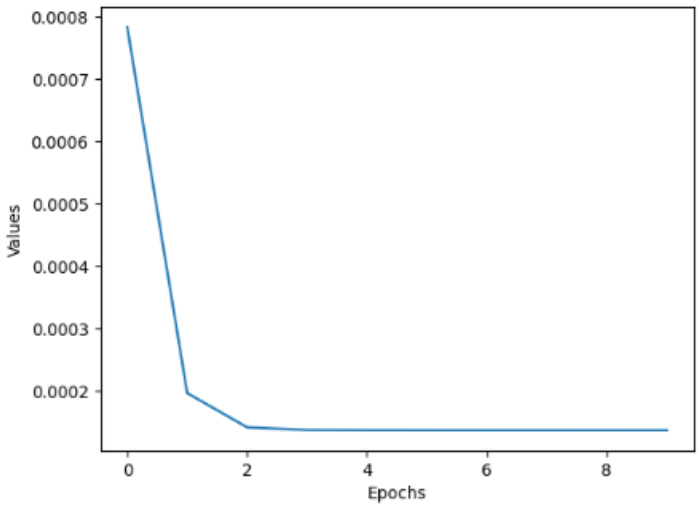
O número 350 observado na rede, se refere as *rolling windows* de tamanho 135, ou seja, são janelas contínuas da série de tempo que garantem a estabilidade do modelo em relação a precisão da previsão.

Tabela 12 – Características da rede LSTM

Layer (type)	Output Shape	Param#
Lstm_14 (LSTM)	(None, 350, 135)	74520
Lstm_15 (LSTM)	(None, 135)	146340
Dropout_7 (Dropout)	(None, 135)	0
Dense_7 (Dense)	(None, 2)	272
Total params: 221,132		
Trainable params: 221,132		
Non-trainable params: 0		

Fonte: Elaborada pelo autor

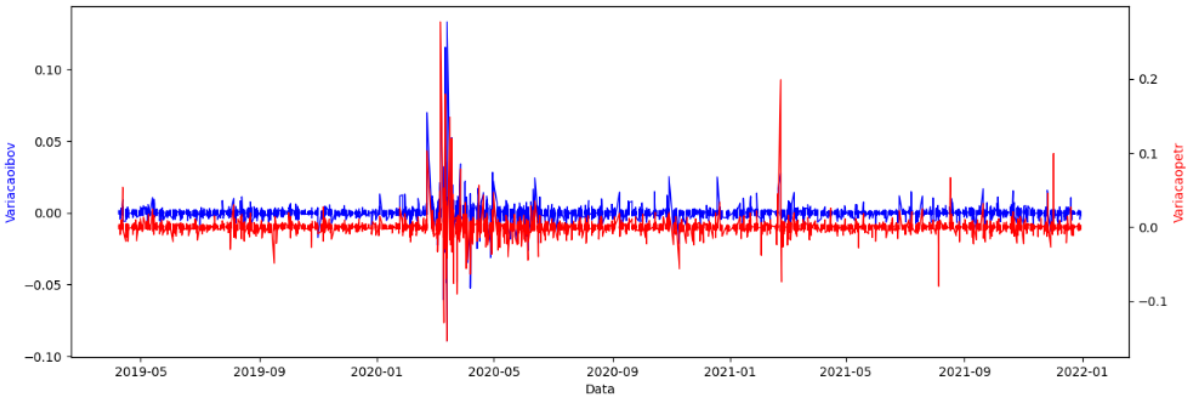
Figura 16 – *Mean Square Error*



Fonte: *Google Colaboratory*

O *Mean Square Error* da rede representado na figura 22, é o erro quadrático médio utilizado para analisar a acurácia do modelo, calculado usando a média das diferenças quadráticas entre os valores previstos e os valores reais. Por essa forma de cálculo, consequentemente, os maiores erros resultam em mais erros em comparação com os erros menores, podendo pela sua característica, causar algum tipo de problema preditivo. No caso da rede LSTM utilizada, é possível perceber que o erro quadrático médio se aproxima de zero ao longo das épocas (*epochs*), que é o número de iterações dos dados de treinamento no processo de aprendizagem da rede.

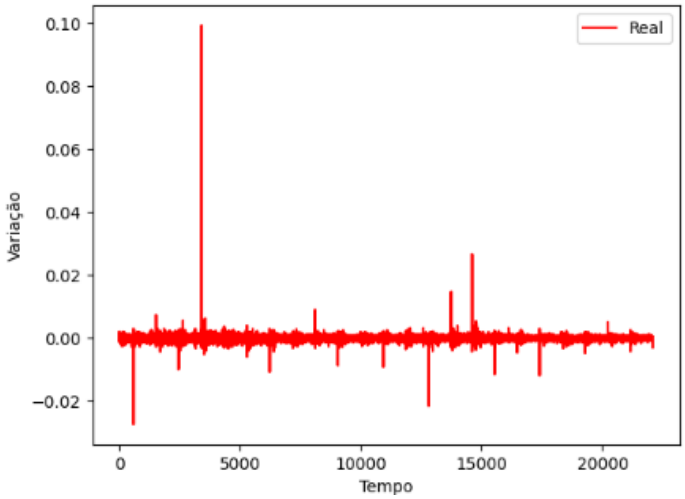
Figura 17 – Variações – IBOV e PETR3



Fonte: *Google Colaboratory*

A figura 23, representa as variações reais do Índice Bovespa (azul) com as variações reais da PETR3 (vermelho) para o período analisado que se inicia em 08-04-2019 às 10:04:00 até o dia 30-12-2021 às 18:12:30. É possível notar a grande quantidade de *outliers* concentrados no período de fevereiro a agosto aproximadamente, devido as grandes oscilações provocadas pela pandemia de COVID-19.

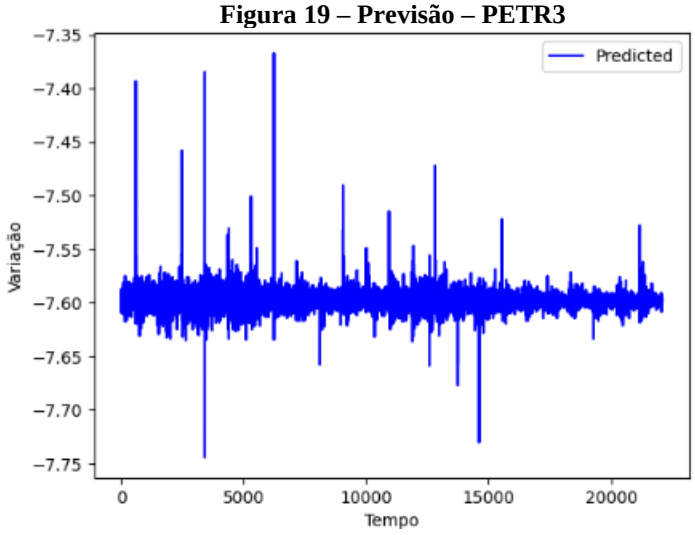
Figura 18 – Variação Real – PETR3



Fonte: *Google Colaboratory*

A figura 24 apresenta a variação (t/t-1) que o ativo PETR3 sofreu ao longo do período utilizado para teste, onde foram utilizados 25% dos dados disponíveis. Vale destacar que por se tratar de um modelo de previsão de perda, não se pode utilizar o preço a cada 30 segundos como variável e sim suas respectivas variações no decorrer da série de tempo.

Figura 19 – Previsão – PETR3



Fonte: *Google Colaboratory*

Como parte final da rede, a figura 25 representa a previsão que o modelo gerou das perdas para o ativo PETR3 dadas as suas variações junto as respectivas variações do Índice Ibovespa que, como mencionado anteriormente, foi utilizado como segunda variável em detrimento de que os números analisados possuem a característica de serem extremamente pequenos.

É possível notar que os valores previstos pela rede LSTM não são significativos, o que acaba por invalidar a primeira hipótese de que é possível gerenciar o risco de cauda em dados de alta frequência utilizando LSTM. Porém destaca-se que uma das razões para a rede não ser capaz de gerar previsões confiáveis, é o fato de a série apresentar uma sequência significativa de *outliers*, como pode ser observado na figura 24, o que acabou por prejudicar seu poder preditivo. Razão essa que será explorada de forma mais abrangente em trabalhos futuros, visto que a rede desenvolvida apresenta propriedades de grande importância para análises utilizando outros tipos de dados.

5. CONCLUSÕES

Esta pesquisa apresentou a análise de dois modelos que podem ser utilizados para a previsão do risco de eventos de cauda. Antes de qualquer análise preditiva, foi feito um trabalho de revisão da literatura, análise bibliométrica e revisão sistemática.

A sessão específica sobre a análise bibliométrica, apresentou sete etapas que são consideradas o alicerce desta pesquisa, formada primeiramente pela escolha da base de dados onde foram coletados os artigos que compuseram grande parte da revisão da literatura, a Web of Science (WoS) foi escolhida unicamente por ser a base de dados de citações líder no

mundo. Após o processo de escolha da base, foi feito o uso dos parâmetros iniciais de pesquisa a partir da WoS, com base em variações das palavras-chave *tail risk AND high-frequency data,* onde foram identificados 119 artigos. Deste total, houve a exclusão de 34 artigos não relacionados com os objetivos desta pesquisa, ou seja, artigos que utilizavam dados ou abordagens distintas das que são aqui discutidas. Seguiu-se então para a criação do banco de dados e coleta dos artigos que compõe a amostra final, constituída de 29 artigos.

Com isso, foi possível a aplicação das três leis principais da análise bibliométrica, a Lei de Zipf (1949) que diz respeito a estimação e frequência das palavras-chave, gerando resultados que dão origem ao T de Goffman, que nada mais é do que o ponto de transição entre as palavras de baixa e as de alta frequência, a Lei de Bradford (1934), que está atrelada a verificação dos periódicos que produzem muitos e os que produzem poucos artigos. A sessão é finalizada com a Lei de Lotka (1926) que identifica os pesquisadores que possuem maior frequência de produção em determinada área de conhecimento.

Assim foi possível ser feito a leitura e codificação dos artigos para o desenvolvimento da revisão sistemática com o propósito de encontrar lacunas de conhecimento que resultaram em mapear e analisar literatura acadêmica acerca do gerenciamento de risco de cauda através de modelos preditivos.

Os resultados gerados pelo método dos momentos (GMM) indicam que é possível detectar o risco de cauda em dados de alta frequência utilizando medidas tradicionais como *Value-at-Risk* e *Expected Shortfall* – calculado através dos *outliers* que superaram o VaR – com um nível de significância de 95%, confirmando a segunda hipótese, onde foi possível prever pontos fora da curva para os sete ativos - B3SA3 (B3 AS – Brasil, Bolsa, Balcão), BBAS3 (Banco do Brasil SA), BBDC4 (Banco Bradesco SA), ITUB3/ITUB4 (Itaú Unibanco) e PETR3/PETR4 (Petróleo Brasileiro AS Petrobras) - analisados no ano de 2022.

No que compete a parte da análise desenvolvida através do modelo LSTM, com resultados obtidos por diferentes técnicas, ficou evidenciado a possibilidade de utilização de *machine learning* para estimação. Entretanto, estes são modelo básicos de *machine learning* (LSTM) e ficam abertas possibilidades para estimações com arquiteturas mais complexas. Como destacado no item 3.3, os dados utilizados nos dois modelos se seguiram pela disponibilidade, visto a dificuldade de obtenção de dados nesse tipo de frequência.

6. REFERÊNCIAS

ALEXEEV, Vitali; URGA, Giovanni; YAO, Wenying. Asymmetric jump beta estimation with implications for portfolio risk management. International Review of Economics & Finance, v. 62, p. 20-40, 2019. DOI: https://doi.org/10.1016/j.iref.2019.02.014

AVDULAJ, Krenar; BARUNIK, Jozef. A semiparametric nonlinear quantile regression model for financial returns. Studies in Nonlinear Dynamics & Econometrics, v. 21, n. 1, p. 81-97, 2017. DOI: https://doi.org/10.1515/snde-2016-0044

Banco J.P. Morgan. Risk Metrics. New York, J.P. Morgan/ Reuters. [Technical Document], 1996.

Basel Committee on Banking Supervision. The regulatory framework: balancing risk sensitivity, simplicity and comparability. [online] Bank for International Settlements, p.7, 2013. Available at: <https://www.bis.org/publ/bcbs258.pdf> [Acessado em 2 de Abril 2023].

BEE, Marco; DUPUIS, Debbie J.; TRAPIN, Luca. Realizing the extremes: Estimation of tail-risk measures from a high-frequency perspective. Journal of Empirical Finance, v. 36, p. 86-99, 2016. DOI: https://doi.org/10.1016/j.jempfin.2016.01.006

BEE, Marco; DUPUIS, Debbie J.; TRAPIN, Luca. Realized peaks over threshold: A time-varying extreme value approach with high-frequency-based measures. Journal of Financial Econometrics, v. 17, n. 2, p. 254-283, 2019. DOI: https://doi.org/10.1093/jjfinec/nbz003

BODIE, Zvi; KANE, Alex. Investments. 2020.

BOLLERSLEV, Tim; TODOROV, Viktor. Tails, fears, and risk premia. The Journal of Finance, v. 66, n. 6, p. 2165-2211, 2011. DOI: https://doi.org/10.1111/j.1540-6261.2011.01695.x

BOLLERSLEV, Tim; TODOROV, Viktor; LI, Sophia Zhengzi. Jump tails, extreme dependencies, and the distribution of stock returns. Journal of Econometrics, v. 172, n. 2, p. 307-324, 2013. DOI: https://doi.org/10.1016/j.jeconom.2012.08.014

BOOTH, Andrew D. A “Law” of occurrences for words of low frequency. Information and control, v. 10, n. 4, p. 386-393, 1967. DOI: 10.1016/S0019-9958(67)90201-X

BORMETTI, Giacomo et al. Modelling systemic price cojumps with Hawkes factor models. Quantitative Finance, v. 15, n. 7, p. 1137-1156, 2015. DOI: https://doi.org/10.1080/14697688.2014.996586

BRADFORD, Samuel C. Sources of information on scientific subjects. *Engineering: An Illustrated Weekly Journal*, *137*, 85-86, 1934. DOI: 10.1177/016555158501000407

BROOKES, Bertram C. Bradford's law and the bibliography of science. Nature, v. 224, p. 953-956, 1969. DOI: 10.1038/224953a0

CAI, Charlie X. et al. FARVaR: functional autoregressive value-at-risk. Journal of Financial Econometrics, v. 17, n. 2, p. 284-337, 2019. DOI: https://doi.org/10.1093/jjfinec/nby031

CAI, Guanghui; WU, Zhimin; PENG, Lei. Forecasting volatility with outliers in Realized GARCH models. Journal of Forecasting, v. 40, n. 4, p. 667-685, 2021. DOI: https://doi.org/10.1002/for.2736

CHAN, Jennifer So-Kuen; NG, Kok-Haur; RAGELL, Rachel. Bayesian return forecasts using realised range and asymmetric CARR model with various distribution assumptions. International Review of Economics & Finance, v. 61, p. 188-212, 2019. DOI: https://doi.org/10.1016/j.iref.2019.01.003

CHAVEZ-DEMOULIN, Valérie; MCGILL, J. A. High-frequency financial data modeling using Hawkes processes. Journal of Banking & Finance, v. 36, n. 12, p. 3415-3426, 2012. DOI: https://doi.org/10.1016/j.jbankfin.2012.08.011

CHEN, Guojin; DING, Jie; ZHAO, Xiangqin. A lottery-preference-based explanation of realized kurtosis puzzle in Chinese stock market. Applied Economics, v. 51, n. 50, p. 5466-5481, 2019. DOI: https://doi.org/10.1080/00036846.2019.1613510

CHEN, Kai; ZHOU, Yi; DAI, Fangyan. A LSTM-based method for stock returns prediction: A case study of China stock market. In: 2015 IEEE international conference on big data (big data). IEEE, 2015. p. 2823-2824. DOI: 10.1109/BigData.2015.7364089

CHUNG, Kee H.; COX, Raymond AK. Patterns of productivity in the finance literature: a study of the bibliometric distributions. the Journal of Finance, v. 45, n. 1, p. 301-309, 1990. DOI: https://doi.org/10.1111/j.1540-6261.1990.tb05095.x

DIMITRIADIS, Timo; HALBLEIB, Roxana. Realized quantiles. Journal of Business & Economic Statistics, v. 40, n. 3, p. 1346-1361, 2022. DOI: https://doi.org/10.1080/07350015.2021.1929249

ERDEMLIOGLU, Deniz; GRADOJEVIC, Nikola. Heterogeneous investment horizons, risk regimes, and realized jumps. International Journal of Finance & Economics, v. 26, n. 1, p. 617-643, 2021. DOI: https://doi.org/10.1002/ijfe.1807

FAN, Jianqing; IMERMAN, Michael B.; DAI, Wei. What does the volatility risk premium say about liquidity provision and demand for hedging tail risk?. Journal of Business &

Economic Statistics, v. 34, n. 4, p. 519-535, 2016. DOI: https://doi.org/10.1080/07350015.2016.1152968

FERRIANI, Fabrizio; ZOI, Patrick. The dynamics of price jumps in the stock market: an empirical study on Europe and US. The European Journal of Finance, v. 28, n. 7, p. 718-742, 2022. DOI: https://doi.org/10.1080/1351847X.2020.1740288

FISSLER, Tobias; ZIEGEL, Johanna F. Higher order elicitability and Osband's principle. 2016. DOI: https://doi.org/10.1214/16-AOS1439

FUERTES, Ana-Maria; OLMO, Jose. Optimally harnessing inter-day and intra-day information for daily value-at-risk prediction. International Journal of Forecasting, v. 29, n. 1, p. 28-42, 2013. DOI: https://doi.org/10.1016/j.ijforecast.2012.05.005

GAO, Tingwei; CHAI, Yueting. Improving stock closing price prediction using recurrent neural network and technical indicators. Neural computation, v. 30, n. 10, p. 2833-2854, 2018. DOI 10.1162/neco_a_01124

GNEITING, Tilmann. Making and evaluating point forecasts. Journal of the American Statistical Association, v. 106, n. 494, p. 746-762, 2011. DOI: https://doi.org/10.1198/jasa.2011.r10138

GOFFMAN, William. A mathematical method for analyzing the growth of a scientific discipline. Journal of the ACM (JACM), v. 18, n. 2, p. 173-185, 1971. DOI: 10.1145/321637.321640

GREFF, Klaus et al. LSTM: A search space odyssey. IEEE transactions on neural networks and learning systems, v. 28, n. 10, p. 2222-2232, 2016. DOI: 10.1109/TNNLS.2016.2582924

HALBLEIB, R., POHLMEIER, W. (2012). Improving the value at risk forecasts: Theory and evidence from the financial crisis. *Journal of Economic Dynamics and Control*, *36*(8), 1212-1228. DOI: https://doi.org/10.1016/j.jedc.2011.10.005

HALBLEIB, Roxana; POHLMEIER, Winfried. Improving the value at risk forecasts: Theory and evidence from the financial crisis. Journal of Economic Dynamics and Control, v. 36, n. 8, p. 1212-1228, 2012. DOI: https://doi.org/10.1016/j.jedc.2011.10.005

HANSEN, Lars Peter. Large sample properties of generalized method of moments estimators. Econometrica: Journal of the econometric society, p. 1029-1054, 1982. DOI: https://doi.org/10.2307/1912775

HOCHREITER, Sepp; SCHMIDHUBER, Jürgen. Long short-term memory. Neural computation, v. 9, n. 8, p. 1735-1780, 1997. DOI: https://doi.org/10.1162/neco.1997.9.8.1735

HULL, John C.; PREDESCU, Mirela; WHITE, Alan. The valuation of correlation-dependent credit derivatives using a structural model. Available at SSRN 686481, 2005. DOI: http://dx.doi.org/10.2139/ssrn.686481

JORION, Philippe. Hedge funds vs. alternative risk premia. Financial Analysts Journal, v. 77, n. 4, p. 65-81, 2021. DOI: https://doi.org/10.1080/0015198X.2021.1960133

JORION, Philippe. Portfolio optimization with tracking-error constraints. Financial Analysts Journal, v. 59, n. 5, p. 70-82, 2003. DOI: https://doi.org/10.2469/faj.v59.n5.2565

KARMAKAR, Madhusudan; PAUL, Samit. Intraday risk management in International stock markets: A conditional EVT approach. International Review of Financial Analysis, v. 44, p. 34-55, 2016. DOI: https://doi.org/10.1016/j.irfa.2015.11.008

KIM, Ha Young; WON, Chang Hyun. Forecasting the volatility of stock price index: A hybrid model integrating LSTM with multiple GARCH-type models. Expert Systems with Applications, v. 103, p. 25-37, 2018. DOI: https://doi.org/10.1016/j.eswa.2018.03.002 0957-41

LAI, Yu-Sheng. Generalized autoregressive score model with high-frequency data for optimal futures hedging. Journal of Futures Markets, v. 41, n. 12, p. 2023-2045, 2021. DOI: https://doi.org/10.1002/fut.22254

LEI, Bolin; LIU, Zhengdi; SONG, Yuping. On stock volatility forecasting based on text mining and deep learning under high-frequency data. Journal of Forecasting, v. 40, n. 8, p. 1596-1610, 2021. DOI: https://doi.org/10.1002/for.2794

LI, Zhixi; TAM, Vincent. A machine learning view on momentum and reversal trading. Algorithms, v. 11, n. 11, p. 170, 2018. DOI:10.3390/a11110170

LOTKA, Alfred J. The frequency distribution of scientific productivity. Journal of the Washington academy of sciences, v. 16, n. 12, p. 317-323, 1926.

LOUZIS, Dimitrios P.; XANTHOPOULOS-SISINIS, Spyros; REFENES, Apostolos P. Realized volatility models and alternative Value-at-Risk prediction strategies. Economic Modelling, v. 40, p. 101-116, 2014. DOI: https://doi.org/10.1016/j.econmod.2014.03.025

MAKNICKIENĖ, Nijolė; MAKNICKAS, Algirdas. Application of neural network for forecasting of exchange rates and forex trading. In: The 7th international scientific conference" Business and Management. 2012. p. 10-11. DOI: 103846/BM.2012.017

MALEVERGNE*, Yannick; PISARENKO, Vladilen; SORNETTE, Didier. Empirical distributions of stock returns: between the stretched exponential and the power

law? Quantitative Finance, v. 5, n. 4, p. 379-401, 2005. DOI: https://doi.org/10.1080/14697680500151343

MAO, Guangyu; ZHANG, Zhengjun. Stochastic tail index model for high frequency financial data with Bayesian analysis. Journal of Econometrics, v. 205, n. 2, p. 470-487, 2018. DOI: https://doi.org/10.1016/j.jeconom.2018.03.019

MAZZARISI, Piero et al. Tail Granger causalities and where to find them: Extreme risk spillovers vs spurious linkages. Journal of Economic Dynamics and Control, v. 121, p. 104022, 2020. DOI: https://doi.org/10.1016/j.jedc.2020.104022

NELSON, David MQ; PEREIRA, Adriano CM; DE OLIVEIRA, Renato A. Stock market's price movement prediction with LSTM neural networks. In: 2017 International joint conference on neural networks (IJCNN). Ieee, 2017. p. 1419-1426. DOI: 10.1109/IJCNN.2017.7966019

PALUCH, Michał; JACKOWSKA-STRUMIŁŁO, Lidia. Hybrid models combining technical and fractal analysis with ANN for short-term prediction of close values on the warsaw stock exchange. Applied Sciences, v. 8, n. 12, p. 2473, 2018. DOI: 10.3390/ app8122473

PENZER, Jeremy; SCHMID, Friedrich; SCHMIDT, Rafael. Measuring large comovements in financial markets. Quantitative Finance, v. 12, n. 7, p. 1037-1049, 2012. DOI: https://doi.org/10.1080/14697688.2010.495950

REBOREDO, Juan C.; MATÍAS, José M.; GARCIA-RUBIO, Raquel. Nonlinearity in forecasting of high-frequency stock returns. Computational Economics, v. 40, p. 245-264, 2012. DOI: https://doi.org/10.1007/s10614-011-9288-5

SALVATIERRA, Irving De Lira; PATTON, Andrew J. Dynamic copula models and high frequency data. Journal of Empirical Finance, v. 30, p. 120-135, 2015. DOI: https://doi.org/10.1016/j.jempfin.2014.11.008

SONG, Shijia; TIAN, Fei; LI, Handong. An intraday-return-based Value-at-Risk model driven by dynamic conditional score with censored generalized Pareto distribution. Journal of Asian Economics, v. 74, p. 101314, 2021. DOI: https://doi.org/10.1016/j.asieco.2021.101314

SONG, Shijia; LI, Handong. A new model for forecasting VaR and ES using intraday returns aggregation. Journal of Forecasting, 2022. DOI: https://doi.org/10.1002/for.2932

SUN, Wei; RACHEV, Svetlozar; FABOZZI, Frank J. A new approach for using Lévy processes for determining high-frequency value-at-risk predictions. European

Financial Management, v. 15, n. 2, p. 340-361, 2009. DOI: https://doi.org/10.1111/j.1468-036X.2008.00467.x

YALAMAN, Abdullah; MANAHOV, Viktor. Analysing emerging market returns with high-frequency data during the global financial crisis of 2007–2009. The European Journal of Finance, v. 28, n. 10, p. 1019-1051, 2022. DOI: https://doi.org/10.1080/1351847X.2021.1957698

ZENG, Yawen; LIU, Xing. A-stock price fluctuation forecast model based on LSTM. In: 2018 14th International Conference on Semantics, Knowledge and Grids (SKG). IEEE, 2018. p. 261-264. DOI: 10.1109/SKG.2018.00044

ZIPF, George Kingsley. Human behavior and the principle of least effort: An introduction to human ecology. Ravenio Books, 2016.