UNIVERSIDADE PRESBITERIANA MACKENZIE

PEDRO PAULO GALINDO FRANCISCO

ALTERNATIVAS PARA A PREVISÃO DA TAXA DE CÂMBIO: A EFICÁCIA DOS MODELOS DE DEEP LEARNING

São Paulo

2024

PEDRO PAULO GALINDO FRANCISCO

ALTERNATIVAS PARA A PREVISÃO DA TAXA DE CÂMBIO: A EFICÁCIA DOS MODELOS DE DEEP LEARNING

Dissertação apresentada ao Programa de Pós-Graduação em Administração de Empresas da Universidade Presbiteriana Mackenzie, como requisito parcial à obtenção de título de Mestre em Administração de Empresas.

ORIENTADOR: Prof. Dr. Eli Haddad Junior

São Paulo

2024

F819a Francisco, Pedro Paulo Galindo.
Alternativas para a previsão da taxa de câmbio: a eficácia dos modelos de deep learning [recurso eletrônico] / Pedro Paulo Galindo Francisco.
2 KB ; il.

Dissertação (Mestrado em Administração de Empresas) – Universidade Presbiteriana Mackenzie, São Paulo, 2025.
Orientador: Prof. Dr. Eli Haddad Junior
Bibliografia: p. 39-42

1. Taxa de câmbio. 2. Séries temporais. 3. Machine learning. 4. Deep learning. I. Haddad Junior, Eli, *orientador*. II. Título.

1. Taxa de câmbio. 2. Séries temporais. 3. Machine learning. 4. Deep learning. I. Haddad Junior, Eli, *orientador*. II. Título.

Bibliotecária Responsável: Aline Amarante Pereira - CRB 8/9549

Folha de Identificação da Agência de Financiamento

Autor: Pedro Paulo Galindo Francisco

Programa de Pós-Graduação *Stricto Sensu* em Administração de Empresas

Título do Trabalho: Alternativas para a previsão da taxa de câmbio: a eficácia dos modelos de Deep Learning

O presente trabalho foi realizado com o apoio de [1]:

- ☒ CAPES - Coordenação de Aperfeiçoamento de Pessoal de Nível Superior
- ☐ CNPq - Conselho Nacional de Desenvolvimento Científico e Tecnológico
- ☐ FAPESP - Fundação de Amparo à Pesquisa do Estado de São Paulo
- ☐ Instituto Presbiteriano Mackenzie/Isenção integral de Mensalidades e Taxas
- ☐ MACKPESQUISA - Fundo Mackenzie de Pesquisa
- ☐ Empresa/Indústria:
- ☐ Outro:

[1] **Observação**: caso tenha usufruído mais de um apoio ou benefício, selecione-os.

PEDRO PAULO GALINDO FRANCISCO

ALTERNATIVAS PARA A PREVISÃO DA TAXA DE CÂMBIO: A EFICÁCIA DOS MODELOS DE DEEP LEARNING

Dissertação apresentada ao Programa de Pós-Graduação em Administração de Empresas da Universidade Presbiteriana Mackenzie, como requisito parcial à obtenção de título de Mestre em Administração de Empresas.

Aprovado em: 24 de março de 2025

BANCA EXAMINADORA

L. Basso

Prof. Dr. Leonardo Fernando Cruz Basso
Universidade Presbiteriana Mackenzie

Paulo Andre Lima de Castro

Prof. Dr. Paulo André de Castro
Instituto Tecnológico de Aeronáutica

Eli Hadad Junior

Prof. Dr. Eli Hadad Junior
Universidade Presbiteriana Mackenzie

AGRADECIMENTOS

Gostaria de expressar minha gratidão a todos que contribuíram para a realização desta dissertação de mestrado. Primeiramente, agradeço à Deus pela saúde e capacitação para escrever e concluir esse trabalho. Agradeço ao Prof. Dr. Eli Hadad Junior pela dedicação e paciência em guiar e elucidar nas mais diversas questões intrínsecas a esta pesquisa. Seu compromisso e conselhos foram fundamentais para o desenvolvimento desta dissertação.

Agradeço aos demais professores do programa de Administração de Empresas da universidade Presbiteriana Mackenzie pelo valiosos ensinamentos e contribuições durante as aulas e os seminários que levaram ao aprimoramento deste trabalho. Agradeço também aos membros da banca de qualificação, ao Prof. Dr. Leonardo Fernando Cruz Basso e ao Prof. Dr. Paulo André de Castro que elevaram o trabalho com suas sugestões e críticas durante a avaliação deste.

Aos meus colegas e amigos de curso, pela companhia, apoio e troca constante de ideias. As discussões dentro e fora de sala certamente contribuíram para a elevação dos meus conhecimentos em finanças e na consolidação dos conceitos transmitidos em aula.

Sou grato aos meus familiares pelo amor, paciência e incentivo. Sem a compreensão deles, não teria sido possível superar os desafios e concluir esta etapa de minha vida acadêmica.

"*O coração do homem pode fazer planos, mas*
a resposta certa dos lábios vem do SENHOR."
Provérbios 16:1

RESUMO

Este estudo aborda o quebra-cabeça de Meese-Rogoff introduzindo algumas das mais recentes técnicas de *Deep Learning* como alternativas para a predição da taxa de câmbio. Utilizando o RMSE como métrica de comparação, Meese e Rogoff descobriram que modelos econômicos são incapazes de superar o modelo de *Random Walk* como preditores do câmbio no curto prazo. Décadas após este estudo, nenhuma técnica de predição estatística se mostrou eficaz para vencer este obstáculo; ainda que houvesse resultados positivos, eles não se aplicavam para todas as moedas e períodos específicos. No entanto, o avanço recente de tecnologias envolvendo inteligência artificial, abriram o caminho para uma nova abordagem na predição do câmbio. Provendo-se dessa tecnologia, aplicamos seis técnicas de *Deep Learning* visando superar o quebra-cabeça de Meese e Rogoff. Consideramos o período diário para as moedas do real, iene, libra esterlina, euro e o yuhan chinês contra o dolar americano, em um horizonte de tempo de 2010 a 2023. Nossos resultados mostraram que nenhuma das técnicas apresentadas conseguiu produzir resultados melhores que os modelos de *Random Walk*, entretanto, parte dos modelos foram capazes de superar o ARIMA, além de apresentar um poder de previsão da direção do preço superior ao *Random Walk*. Essa conclusão sugere que modelos de *Deep Learning* possuem um potencial inexplorado, representando, no longo prazo, uma possibilidade eficaz na previsão da taxa de câmbio.

Palavras-Chave: Taxa de Câmbio, Séries Temporais, Machine Learning, Deep Learning

ABSTRACT

This study addresses the Meese-Rogoff puzzle by introducing some of the latest Deep Learning techniques as alternatives for exchange rate prediction. Using RMSE as a comparison metric, Meese and Rogoff found that economic models are unable to outperform the Random Walk model as predictors of exchange rates in the short term. Decades after this study, no statistical prediction technique has proven effective in overcoming this hustle; even when positive results were achieved, they did not apply to all currencies or specific periods. However, recent advancements in artificial intelligence technologies have paved the way for a new approach to exchange rate prediction. Leveraging this technology, we applied six Deep Learning techniques aimed at overcoming the Meese-Rogoff puzzle. We analyzed daily exchange rates for the Brazilian real, Japanese yen, British pound, euro, and Chinese yuan against the US dollar, over a time horizon from 2010 to 2023. Our results showed that none of the presented techniques outperformed the Random Walk models; however, some models were able to surpass ARIMA and demonstrated a superior ability to predict price direction compared to Random Walk. This conclusion suggests that Deep Learning models have untapped potential, representing a promising long-term possibility for effective exchange rate forecasting.

Keywords: Exchange Rate, Time Series, Machine Learning, Deep Learning

LISTA DE TABELAS

Tabela 1 - Análise Descritiva 19
Tabela 2 - Modelos de Benchmark 23
Tabela 3 - Paramêtros por Modelo 24
Tabela 4 - Modelos de Deep Learning 31
Tabela 5 - Resultados USDBRL 34
Tabela 6 - Resultados USDCNH 34
Tabela 7 - Resultados USDEUR 35
Tabela 8 – Resultados USDGBP 35
Tabela 9 - Resultados USDJPY 35

LISTA DE FIGURAS

Figura 1- USDBRL de jan/2010 a dez/2023 20
Figura 2 - USDCNH de jan/2010 a dez/2023 20
Figura 3 - USDEUR de jan/2010 a dez/2023 20
Figura 4 - USDGBP de jan/2010 a dez/2023 20
Figura 5 - USDJPY de jan/2010 a dez/2023 20
Figura 6 - GAN 25
Figura 7- N-BEATS 26
Figura 8 - N-HiTs 27
Figura 9 - Prophet 29
Figura 10 - Transformer 30
Figura 11- USDBRL - Real x Previsto 37
Figura 12 - USDCNH - Real x Previsto 37
Figura 13- USDEUR - Real x Previsto 37
Figura 14 - USDGBP - Real x Previsto 37
Figura 15 - USDJPY - Real x Previsto 38

LISTA DE EQUAÇÕES

Equação 1 – Random Walk 21
Equação 2 - ARIMA 22
Equação 3 - Modelo de Harvey e Peters 28
Equação 4 - Root Mean Squared Error 32
Equação 5 - Mean Absolute Error 32
Equação 6 - Mean Absolute Percentage Error 33
Equação 7 - Mean Directional Accuracy 34

LISTA DE ABREVIATURA E SIGLAS

ARIMA	Autoregressive integrated moving average
CNN	Convolutional Neural Network
DL	Deep Learning
GAM	Generalized Additive Model
GAN	Generative Adversarial Network
HME	Hipotese de Mercado Eficiente
IA	Intelgência Artificial
LSTM	Long Short-Term Memory
MAE	Mean Absolute Error
MAPE	Mean Absolute Percentage Error
MDA	Mean Directional Accuracy
ML	Machine Learning
MLP	Multilayer Perceptron
N-BEATS	Neural Basis Expansion Analysis for Interpretable Time Series Forecasting
N-HiTs	Neural Hierarchical Interpolation for Time Series Forecasting
RMSE	Root-Mean Squared Error
RNN	Recurrent Neural Network
SVR	Support Vector Regression

SUMÁRIO

1. INTRODUÇÃO 12

1.1 Contextualização 12

1.2 Justificativa 13

1.3 Objetivos e Hipóteses 13

1.4 Contribuições 14

2. REVISÃO DA LITERATURA 15

2.1 Hipotese de Mercado Eficiente e o Random Walk 15

2.2 Quebra-Cabeça de Meese e Rogoff 15

2.3 Divergência Empírica 16

2.4 Machine Learning e Deep Learning 17

3. METODOLOGIA 18

3.1 Amostras 19

3.2 Modelo de Benchmark 21

3.2.1 Random Walk 21

3.2.2 ARIMA 21

3.2.3 Long Short-Term Memory 22

3.3 Modelos de Deep Learning 23

3.3.1 Time-series Generative Adversarial Network (TimeGAN) 24

3.3.2 Neural Basis Expansion Analysis for Interpretable Time Series Forecasting (N-BEATS) 25

3.3.3 Neural Hierarchical Interpolation for Time Series Forecasting (N-HiTs) 27

3.3.4 Prophet 28

3.3.5 Transformer 29

3.4 Critérios de Avaliação 31

3.4.1 RMSE (Root Mean Squared Error) 31

3.4.2 MAE (Mean Absolute Error) 32

3.4.3 MAPE (Mean Absolute Percentage Error) 33

3.4.4 MDA (Mean Directional Accuracy) 33

4. RESULTADOS 34

5. CONCLUSÃO 38

1. INTRODUÇÃO

Nesta secção são apresentados o contexto ─ no qual o presente trabalho está inserido ─ problema de pesquisa e justificativa que delimitam os objetivos e hipóteses testadas.

1.1 Contextualização

Na literatura econômica, estabeleceu-se a ideia de que, em um mercado eficiente, todas as informações referentes ao valor de um ativo estão contidas em seu preço (Fama, 1970). Dessa forma, modelos teóricos seriam ineficazes para prever quaisquer movimentos de preço utilizando variáveis empíricas, sendo o valor histórico o melhor preditor do valor futuro. Por conseguinte, o modelo de *Random Walk* deve apresentar a melhor performance em relação a quaisquer outros modelos, quando avaliados em termos de erro.

Em seu trabalho, Meese e Rogoff (1983) confirmaram essa hipótese ao comparar os modelos teóricos mais robustos da época e verificar que estes foram incapazes de superar o modelo de *Random Walk* em um horizonte de um a doze meses. Esses resultados ficaram conhecidos na literatura como o *puzzle* de Messe e Rogoff, estabelecendo o conceito de que nenhum modelo econométrico conseguiria superar o modelo histórico. Mesmo após décadas de publicação deste estudo e de diversos trabalhos produzidos sobre o tema, o quebra-cabeça ainda carece de uma solução, com alguns autores reafirmando a impossibilidade de alcançar tal feito, enquanto outros discutem se, de fato, esse deveria ser o padrão para determinar a eficácia de um modelo de previsão.

Os avanços no campo da inteligência artificial lançaram uma nova luz sobre o tema, oferecendo um caminho alternativo para pesquisadores trilharem na busca de resolver o puzzle de Meese e Rogoff. Estes permitiram o desenvolvimento de técnicas inovadoras que, ao invés da abordagem clássica de criação de algoritmos pré-definidos executados por computadores, uma máquina aprende a reconhecer padrões e tendências através do erro. Essa nova tecnologia, chamada de *Machine Learning* (ML), tem ampliado os limites na área de previsão de dados, permitindo pesquisadores irem além do método tradicional de definição de variáveis dependentes e independentes. O ML assimila a variação histórica de preços de um ativo e determina seu valor futuro, facilitando a criação de modelos mais robustos para tarefas específicas. Intrínseco ao conceito de *Machine Learning*, o *Deep Learning* (DL) representa uma solução para problemas que exigem maior poder de aprendizado por parte de uma máquina, uma ramificação do ML capaz de assimilar um maior número de camadas no treinamento dos

modelos, sendo as técnicas mais indicadas para a previsão de dados em séries temporais devido a importância do comportamento histórico do preço para determinar seu valor futuro.

Neste estudo, introduziremos algumas das mais recentes técnicas de DL comparando-as contra o *Random Walk* e demais modelos de benchmark para verificar se estas são capazes de superar o puzzle de Meese e Rogoff.

1.2 Justificativa

O câmbio desempenha um papel central em quase todas as esferas da economia, estando intrinsecamente ligado à estabilidade econômica de um país. Seu impacto abrange famílias, empresas e governos, influenciando desde o poder de compra até a competitividade internacional e a formulação de políticas públicas. Dada a sua natureza altamente dinâmica e interdependente das variáveis macroeconômicas, o desenvolvimento de um modelo capaz de prever com precisão a taxa de câmbio futura representa um dos maiores desafios no campo econômico.

A criação de um modelo preditivo eficaz traria benefícios significativos. Para formuladores de políticas públicas, permitiria antecipar os impactos econômicos de suas decisões sobre o câmbio, promovendo maior estabilidade e eficácia em suas ações. Pesquisadores, por sua vez, poderiam desenvolver teorias e métricas com maior precisão, baseando-se em valores predefinidos de moedas internacionais. Empresas, ao contar com previsões mais confiáveis, teriam maior segurança em negociações de contratos futuros e planejamento financeiro. Por fim, arbitradores seriam mais eficientes ao negociar ativos em diferentes mercados globais, contribuindo para uma melhor alocação de recursos e ajuste dos preços ao seu valor justo.

1.3 Objetivos e Hipóteses

O principal objetivo deste estudo se concentra em responder a seguinte pergunta: podem os modelos de *Deep Learning* superar o puzzle de Meese-Rogoff? Para atingir este objetivo, definiram-se as moedas, parâmetros e métricas a serem utilizados para a criação de cada um dos modelos comparando-os com o Random Walk utilizando dados de séries temporais para o período de um dia. Alternativamente, verificamos se as técnicas mais recentes de DL apresentam performance melhor que os modelos de benchmark estabelecidos neste estudo.

Neste sentido, o Long Short-Term Memory (LSTM), como um dos modelos mais antigos de *Deep Learning*, desempenha uma dupla função como um modelo capaz de superar o Random Walk e como benchmark a ser superado por metodologias mais recentes.

1.4 Contribuições

Esse estudo impacta o estado da arte da literatura de previsão da taxa de câmbio de três formas distintas: a primeira, demonstrando que o puzzle de Meese e Rogoff ainda persiste, com o Random Walk apresentando o menor erro quadrático médio em relação ao valor previsto. Essa conclusão fortalece a hipótese de Fama sobre a eficiência de mercado e reafirma o conceito de que não existem informações externas ao preço de um ativo que possam influenciar seu valor.

A segunda contribuição envolve identificar a efetividade das técnicas mais recentes de *Deep Learning* em relação aos modelos de benchmark. O LSTM sendo um dos modelos mais antigos e robustos em se tratando de redes neurais, representa o modelo a ser superado pelas técnicas mais recentes de *Deep Learning*. Os resultados demonstram que o LSTM se mantém como a metodologia mais eficaz de DL para a previsão de séries temporais, pois dentre os modelos estudados foi o que apresentou o menor RMSE. Entretanto, o N-BEATS foi capaz de produzir um erro próximo ao LSTM e menor do que o ARIMA, indicando que dos modelos mais recentes, este apresenta o maior potencial para futuros estudos relacionados ao tema. Levando em consideração que para este estudo utilizamos os parâmetros padrão de cada um dos modelos de DL, um ajuste mais refinado e preciso destes pode levar a um incremento de performance do N-BEATS e a resultados próximos ou superiores ao LSTM.

A terceira contribuição envolve a discussão sobre o alvo de previsão da taxa de câmbio. A décadas, os estudos sobre previsão do câmbio têm como objetivo principal superar o Random Walk, avaliando os modelos propostos em termos de seus erros. Porém alguns autores criticam essa abordagem afirmando que apresentar uma performance melhor que o Random Walk representa um alvo inalcançável, e que prever a direção do preço ao invés de seu valor exato é um critério mais justo. Este trabalho contribuí para a discussão demonstrando que os modelos de Deep Learning são capazes de prever a direção do câmbio de forma mais eficaz que o Random Walk, reafirmando essa alternativa para a solução deste quebra-cabeça. Este tópico também se mostra relevante para a ação prática envolvendo arbitragem, negociação de contratos de hedge, formulação de políticas públicas e demais negociações relacionadas ao preço do

câmbio. Uma vez que prever a direção do câmbio representa um grande valor em atividades desse tipo, adaptar os esforços de previsão dos modelos de DL para este tipo de métrica, pode representar grandes avanços na modelagem do câmbio e ganho financeiro para seus utilizadores.

2. REVISÃO DA LITERATURA

Apresenta-se nesta secção, as principais teorias que tem por objetivo suportar as hipóteses desse estudo.

1.1 Hipotese de Mercado Eficiente e o Random Walk

Uma das teorias mais importantes no campo econômico-financeiro, é a Hipótese de Mercado Eficiente (HME) descrita por Fama (1970) em seu trabalho seminal sobre a eficiência dos mercados de capitais. A HME estabelece que, em um mercado onde a qualquer momento os preços refletem completamente todas as informações disponíveis, é considerado "eficiente", e dessa forma, empresas e investidores podem tomar decisões assertivas acerca dos valores de ativos negociados no mercado. Uma vez que os preços desses ativos são ajustados em direção ao equilíbrio de acordo com seu retorno esperado, prever seu valor futuro utilizando um modelo teórico se mostra uma tarefa árdua. Como consequência, o valor histórico de um ativo é considerado como o melhor preditor de seu valor futuro.

O modelo que melhor traduz esse conceito é o modelo de Random Walk. Apresentado também no artigo de Fama, reflete a ideia de que as mudanças sucessivas de preço são independentes e distribuídas de forma idêntica, e representa o benchmark a ser superado quando busca-se prever qualquer ativo no mercado. Ambos os conceitos estão conectados ao modelo de retorno esperado geral, determinado pela evolução do sentimento dos investidores e o processo gerador de novas informações, em que a distribuição dos retornos se repete no tempo.

2.2 Quebra-Cabeça de Meese e Rogoff

Buscando avaliar o poder de previsão dos modelos teóricos mais relevantes da época, Meese e Rogoff (1983a) compararam três deles: o modelo monetário de preço flexível, o modelo monetário de preço rígido e o modelo de Hooper-Morton; para os preços do dólar americano em relação ao iene, à libra e ao marco alemão; e descobriram que nenhum dos modelos alcança uma raiz de erro quadrático médio (RMSE) menor do que o modelo de

Random Walk em um horizonte de um a doze meses, ou seja, nenhum dos modelos foi capaz de produzir um valor de câmbio próximo ao seu valor real. Subsequente a este primeiro artigo e visando ampliar a discussão anteriormente apresentada, Meese e Rogoff (1983b) produziram um segundo artigo onde afirmam que o fraco desempenho desses modelos teóricos não é devido a inconsistência dos parâmetros, pois ao aplicar técnicas autorregressivas esses modelos persistem em produzir um desempenho inferior ao modelo de Random Walk. Eles concluem que mesmo com técnicas mais eficientes, a probabilidade de um modelo teórico gerar uma performance superior ao Random Walk é mínima, e que, portanto, dificilmente se poderá obter um resultado diferente do apresentado.

O resultado deste estudo ficou conhecido na literatura como o quebra cabeça de Meese e Rogoff, pois estabelece o princípio da impossibilidade de prever o câmbio utilizando dados fora da amostra. Décadas após a sua publicação, O quebra-cabeça de Meese e Rogoff persiste como desafio a ser superado, e apesar de desfrutar de uma ampla gama de novas metodologias e técnicas, pesquisadores ainda não foram capazes de encontrar uma resposta definitiva à essa problemática. Os resultados apresentados de estudos que obtiveram sucesso em superar o Random Walk são inconclusivos em sua maioria, pois o fazem apenas em situações específicas. Abaixo exploramos mais dessa questão em diferentes trabalhos.

2.3 Divergência Empírica

Nos estudos envolvendo a predição da taxa de câmbio, observamos conclusões contraditórias. Enquanto alguns autores apontam para um alto e largo muro, ressaltando a impossibilidade estatística de prever o câmbio, outros sugerem que esse alvo não é totalmente descartado revelando descobertas promissoras quando diferentes fundamentos econômicos são aplicados. Seguindo o mesmo caminho feito por Meese e Rogoff, Cheung et al (2005) desenvolveram um estudo comparando diversos modelos teóricos baseados em produtividade e taxa de juros com base em diferentes critérios, e concluíram que nenhum deles foi capaz de apresentar um resultado satisfatórios, porém alguns deles produziram uma performance melhor em determinado critério ou para uma determinada moeda. Contrário a uma visão mais pessimista sobre os modelos teóricos, e tentando provar que estes possuem certa capacidade de previsão, Engel et al. (2007) demonstram que os modelos não foram refutados pelos dados, na verdade, eles encontraram evidências de que eles ajudam a prever mudanças cambiais quando se utilizam dados em painel. Seus resultados mostraram que este tipo de modelo, geralmente produz uma previsão melhor do que o Random Walk em horizontes longos.

De semelhante modo, o trabalho de Molodtsova e Papell (2009) também apresentaram resultados positivos em prever o câmbio. Eles encontraram evidência estatística significante ao utilizar modelos baseados na regra de Taylor para período de 1 mês em 12 países da OCDE e concluíram que a performance destes modelos sugere um forte poder de previsão quando comparado aos demais modelos convencionais. Essa divergência de resultados entre trabalhos ao longo do tempo é abordada na revisão da literatura de Rossi. Rossi (2013) explica que cada modelo apresenta uma performance diferente dependendo do horizonte e da moeda estudados. Alguns modelos apresentam menores erros em horizontes curtos, enquanto outros em horizontes longos, outros performam melhor em determinada métrica do que outra, também entre moedas há diferença de resultados; porém nenhum modelo é capaz de superar o modelo de *Random Walk* em todos os aspectos.

Apesar dessa conclusão parecer desanimadora à primeira vista, Rossi (2005) afirma que modelos teóricos fornecem uma melhor descrição dos dados do que o modelo de Random Walk. Confirmando essa conclusão de Rossi, Moosa e Burns (2014) demonstram que estes modelos não conseguem superar o modelo de RW em termos de RMSE, porém são melhores em apontar a direção e a magnitude do movimento dos preços. Bacchetta et al. (2009) propõem uma explicação para o desempenho inferior dos modelos econômicos. Segundo eles, a incapacidade de previsão se deve à relação instável entre a taxa de câmbio e os fundamentos, essa relação aumenta os erros de estimação dos parâmetros, implicando que o comportamento passado é improvável de ser útil para prever o futuro. Além disso, eles descobriram que, ao adicionar parâmetros variáveis no tempo, o efeito líquido no desempenho da previsão fora da amostra é inexistente.

2.4 Machine Learning e Deep Learning

Mesmo como o histórico de resultados negativos, uma nova esperança tem impulsionado alternativas aos modelos teóricos para previsão do câmbio. Recentemente, o avanço exponencial da inteligência artificial (IA), permitiu que pesquisadores explorassem seu potencial visando superar o quebra-cabeça de Meese e Rogoff. Dentro do escopo de IA, a tecnologia que mais tem se destacado para esse fim é o Machine Learning (ML), que, diferente da programação tradicional, onde se faz necessário o desenvolvimento de algoritmos a serem executado por um computador, permite que este aprenda dinamicamente como realizar tarefas e identificar padrões (Russel e Norvig, 2021).

O ML engloba técnicas diferentes para soluções heterogêneas além da previsão de dados, seu uso envolve a criação de imagens, a geração de textos, a composição de áudio, entre diversos outros. Em meio a uma miríade de aplicações, algumas delas exigem mais complexidade e abstração por parte das máquinas para executá-las adequadamente. Técnicas de machine learning envolvendo maior robustez para a resolução de problemas complexos são conhecidas como *Deep Learning*. LeCun et al (2015) definem *Deep Learning* como o processo em que a máquina descobre estruturas intrincadas em grandes conjuntos de dados utilizando o algoritmo de retropropagação para indicar como alterar seus parâmetros internos usados para calcular a representação de cada camada. Modelos que utilizam DL são capazes de treinar longos caminhos computacionais com interações abstratas e são mais adequados para modelos de previsão de séries temporais.

2.5 Inovação Metodológica

Estudos recentes têm explorado os limites pré-estabelecidos sobre a estimação do valor do câmbio. Ultrapassando barreiras teóricas que envolvem a definição do preço de uma moeda, pesquisadores são capazes de identificar padrões e movimentos que compõe seu preço utilizando a capacidade de aprendizado do Deep Learning. Um dos modelos mais populares de DL utilizados por autores ─ e que também será utilizado nesse estudo ─ é o Long Short-Term Memory (LSTM). Cao et al (2020) propuseram diferentes abordagens para o LSTM com o objetivo de prever o valor yuan chinês, eles descobriram que todas essas abordagens foram capazes de superar o ARIMA, tendo o valor mais baixo de RMSE de 0.0189.

De igual modo, Wang et al (2021) propuseram a aplicação de um modelo híbrido entre o LSTM e o CNN, outra técnica comum de Deep Learning. Seus resultados demonstram que o LSTM foi capaz de superar o MLP, o CNN e o RNN, modelos tradicionais de Deep Learning, apresentando o menor valor de MAPE. Apesar do LSTM ainda se mostrar como uma das técnicas mais robustas para a previsão de dados de séries temporais, sua criação não é recente e novas metodologias tem emergido ano após ano. Neste estudo, comparamos o LSTM com algumas das mais recentes técnicas de Deep Learning e verificamos como estas performam em comparação àquele e aos modelos de benchmark Random Walk e ARIMA.

3. METODOLOGIA

Nesta seção, apresenta-se as amostras e métodos utilizados para a criação dos modelos estudados.

3.1 Amostras

Em busca de testar a eficácia dos modelo em diferentes mercados, 5 moedas foram comparadas contra o dólar americano: o real brasileiro, o euro, o yuan chinês, a libra esterlina e o iene japonês. Para cada uma delas, foram extraídos dados diários entre janeiro de 2010 a dezembro de 2023 utilizando a plataforma Bloomberg.

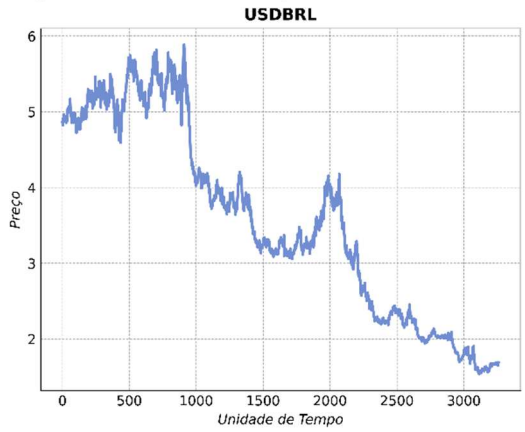
Os modelos foram desenvolvidos utilizando linguagem de programação Python com o uso das bíbliotecas Tensorflow e Darts, sendo a primeira dedicada a criação de modelos de *Deep Learning* e a segunda a criação de modelos utilizando dados de séries temporais.

Tabela 1 - Análise Descritiva

Varíaveis	Amostras	Média	Desvio Padrão	Mínimo	Máximo	Curtose	Assimetria	Variância
USDBRL	3,260	3.570	1.278	1.539	5.887	-0.413	0.495	0.022
USDCNH	3,482	6.579	0.325	6.020	7.365	-0.856	0.364	0.105
USDEUR	3,392	0.849	0.076	0.674	1.042	-0.828	-0.311	0.006
USDGBP	3,393	0.718	0.077	0.583	0.936	-1.254	-0.033	0.006
USDJPY	3,393	108.683	17.078	75.820	151.720	0.110	0.103	291.670

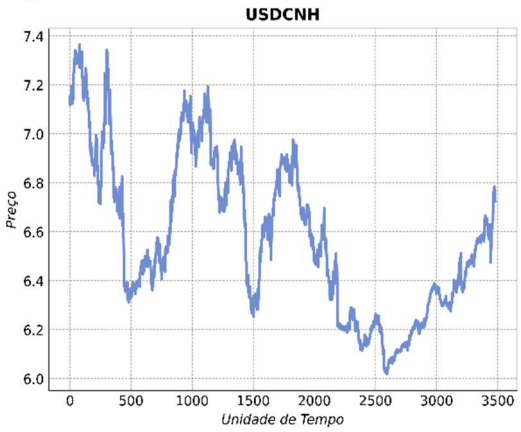
Fonte: Elaboração Própria

Figura 1- USDBRL de jan/2010 a dez/2023



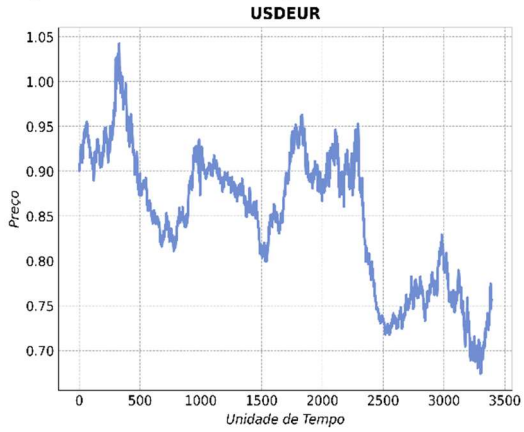
Fonte: Elaboração Própria

Figura 2 - USDCNH de jan/2010 a dez/2023



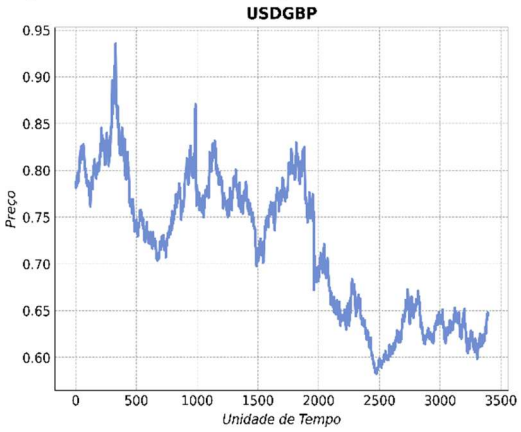
Fonte: Elaboração Própria

Figura 3 - USDEUR de jan/2010 a dez/2023



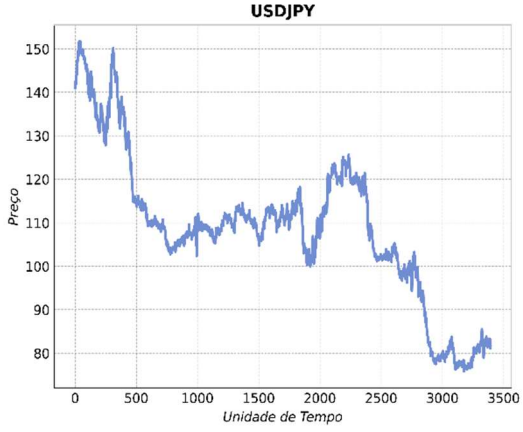
Fonte: Elaboração Própria

Figura 4 - USDGBP de jan/2010 a dez/2023



Fonte: Elaboração Própria

Figura 5 - USDJPY de jan/2010 a dez/2023



Fonte: Elaboração Própria

3.2 Modelo de Benchmark

3.2.1 Random Walk

O Random Walk pode ser compreendido como um modelo onde, uma partícula, em uma reta, se move para a esquerda ou para a direita com probabilidade de 50% durante uma unidade de tempo. No tempo seguinte, ela se move ou para a esquerda ou para a direita com probabilidade idêntica e independente de sua localização anterior (Révész, 2013).

Buscando determinar se a taxa de câmbio realmente segue o comportamento de um modelo de Random Walk, Hakkio (1986) testou quatro hipóteses propostas na literatura e demonstrou que o câmbio segue o mesmo processo temporal que o diferencial da taxa de juros real, como este segue o modelo de Random Walk, conclui-se que o câmbio também segue o mesmo padrão. Por esta razão, o Random Walk representa o principal benchmark a ser superado, tanto para modelos teóricos quanto para modelos de Deep Learning.

$$y_t = y_{t-1} + \varepsilon_t \quad (1)$$

Onde y_t representa o valor da variável no tempo t, y_{t-1} representa o valor da variável no tempo t-1, e ε_t o termo de erro no tempo t.

3.2.2 ARIMA

Quando lidamos com dados em séries temporais, como no caso da taxa de câmbio, técnicas clássicas de regressão linear são insuficientes para explicar o comportamento dos dados. No modelo tradicional de regressão linear, deseja-se que a variável dependente seja influenciada pelo valor presente das variáveis independentes, porém, em se tratando de séries temporais, deseja-se que a variável dependente seja influenciada pelos valores passados das variáveis independentes e de si própria, fazendo-se necessário o uso de modelos autoregressivos (Shumway e Stoffer, 2010).

O modelo *Auto-Regressive Integrated Moving Average* (ARIMA) representa uma das técnicas mais robustas para a previsão de dados em séries temporais e é amplamente usado na literatura econômica como ferramenta para a previsão do câmbio. Ngan (2013) verificou a capacidade do ARIMA em prever o valor do câmbio do Vietnam, seus resultados demonstram

que o modelo foi capaz de prever eficazmente a direção do movimento do câmbio, indicando seu potencial como ferramenta de previsão e sua importância como benchmark para este estudo.

$$y_t = \beta_1 y_{t-1} + \beta_2 y_{t-2} + \cdots + \beta_n y_{t-n} + \varepsilon_t \qquad (2)$$

Onde y_t representa a variável independente estacionaria, β o coeficiente da variável com atraso, y_{t-1} a variável com atraso e ε_t o termo de erro.

3.2.3 Long Short-Term Memory

Similar ao que ocorre com o *Machine Learning*, também encontramos limitações quando utilizamos redes muito longas e complexas de Deep Learning. Isto foi confirmado no estudo feito por Bengio et al. (1994) onde verificou-se que, ao treinar uma rede neural recorrente, à medida que o alcance temporal aumenta o *Gradient Descent* se torna cada vez mais ineficiente e o modelo se mostra incapaz de reter a informação fornecida. Uma solução para estre problema foi proposta em Hochreiter e Schmidhuber (1997) com o modelo LSTM. Esse tipo de modelo pode cobrir defasagens temporais ao longo de mais de 1000 passos discretos de tempo, resolvendo os problemas clássicos de desaparecimento de redes recorrentes anteriores.

Ao se avaliar a performance de modelos de *Machine Learning*, adotam-se aqueles já estabelecidos na literatura como benchmark para modelos mais recentes. As técnicas comumente adotadas como benchmark são o Support Vector Regression (SVR) e o Convolutional Neural Network (CNN), ambas introduzidas a mais de duas décadas e amplamente reconhecidas no treinamento de máquinas. Cao et al (2020) compararam estes modelos com o LSTM para a taxa de câmbio do USDCNY, e verificaram que este apresenta melhor performance que ambos o SVR e o CNN.

Por se tratar de um dos modelos mais robustos e comumente utilizados na literatura, utilizamos o LSTM tanto como uma alternativa metodologia para superar o puzzle de Meese e Rogoff, como um modelo de benchmark para as técnicas mais recentes de Deep Learning introduzidas neste estudo.

Tabela 2 - Modelos de Benchmark

Modelo	Descrição	Principais Referências
Random Walk	Modelo onde uma partícula se move em qualquer direção com probabilidade de 50%. No tempo seguinte, ela se move aleatoriamente com probabilidade idêntica e independente de sua localização anterior.	Fama (1970); Révész (2013); Hakkio (1986)
ARIMA	Este modelo representa uma das técnicas mais robustas para a previsão de dados em séries temporais e é amplamente usado na literatura econômica como ferramenta para a previsão do câmbio.	(Shumway & Stoffer, 2010)
LSTM	Solução criada para o problema de *desaparecimento* de redes neurais recorrentes, sendo capaz de cobrir defasagens temporais ao longo de mais de 1000 passos discretos de tempo.	Hochreiter & Schmidhuber (1997)

Fonte: Elaboração Própria

3.3 Modelos de Deep Learning

Ao se desenvolver um modelo de ML, é necessário definir um grupo de valores para os pesos de todas as camadas de uma rede neural, de forma que esta rede consiga mapear corretamente os inputs para os alvos desejados (Chollet, 2021).

Para cada um dos modelos utilizados foram adotados os parâmetros padrão definidos pelas suas respectivas bibliotecas. A Tabela 3 mostra os parâmetros (pesos) para cinco técnicas de machine learning aplicadas.

Tabela 3 - Paramêtros por Modelo

		USDBRL	**USDCNH**	**USDEUR**	**USDGBP**	**USDJPY**
LSTM	*Layers*	4	4	4	4	8
	Learning Rate	0.01	0.01	0.01	0.01	0.0001
	Epochs	200	200	200	200	600
GAN	*Layers*	128	128	128	128	128
	Learning Rate	0.01	0.01	0.01	0.01	0.01
	Epochs	200	200	200	200	200
N-BEATS	*Layers*	4	4	4	4	4
	Learning Rate	0.001	0.001	0.001	0.001	0.001
	Epochs	100	100	100	100	100
N-HiTS	*Layers*	2	2	2	2	2
	Learning Rate	0.001	0.001	0.001	0.001	0.001
	Epochs	200	200	200	200	200
Prophet	*Layers*	N/A	N/A	N/A	N/A	N/A
	Learning Rate	N/A	N/A	N/A	N/A	N/A
	Epochs	N/A	N/A	N/A	N/A	N/A
Transformer	*Layers*	3	3	3	3	3
	Learning Rate	0.001	0.001	0.001	0.001	0.001
	Epochs	200	200	200	200	200

Fonte: Elaboração Própria

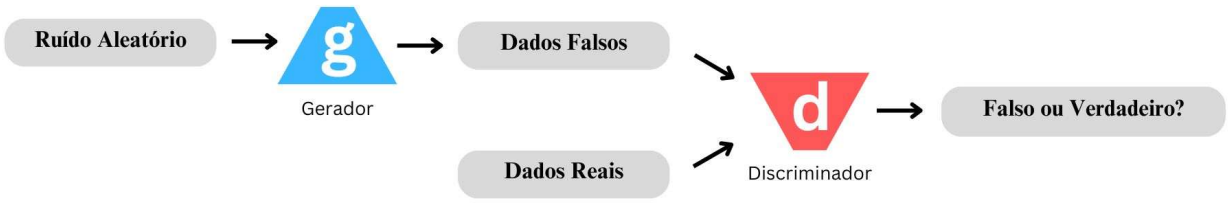
3.3.1 Time-series Generative Adversarial Network (TimeGAN)

A primeira técnica aplicada é a *Generative Adversarial Network* (GAN). Esse modelo funciona com base na aplicação da teoria dos jogos entre duas redes neurais: o gerador e o discriminador (Goodfellow et al., 2020). O primeiro tenta replicar os dados das amostras a partir de um ruído aleatório, enquanto o último compara os dados sintéticos criados pelo primeiro

com os valores reais de treinamento, tentando identificar qual dos dois é o valor verdadeiro. Em determinado momento, as cópias criadas pelo gerador apresentam características tão próximas às reais que o discriminador já não é mais capaz de diferenciá-las, concluindo assim o desenvolvimento do modelo.

Essa técnica é normalmente utilizada para a geração de imagens, onde sua performance demonstra ser mais eficaz. Entretanto, reconhecendo seu potencial para diferentes aplicações, Yoon et al (2019) desenvolveram uma variação dessa técnica chamada de TimeGAN, específica para o treinamento de modelos envolvendo dados de séries temporais. Em seus testes, eles compararam o TimeGAN com outros métodos de aplicação de modelos GAN e descobriram que aquele apresentou performance superior aos demais em diferentes tipos de dados de séries temporais.

Figura 6 - GAN



Fonte: Adaptado de Goodfellow et al., 2020

Santoro e Grilli (2021) verificaram a utilização do TimeGAN como ferramenta para avaliar a quantidade de informação presente nos preços disponíveis no mercado financeiro. Eles descobriram que o TimeGAN foi capaz de identificar quais instrumentos financeiros continham um nível de informação relevante e a característica do preço em relação ao seu poder preditivo e discriminatório, demonstrando sua capacidade em lidar com ativos financeiros.

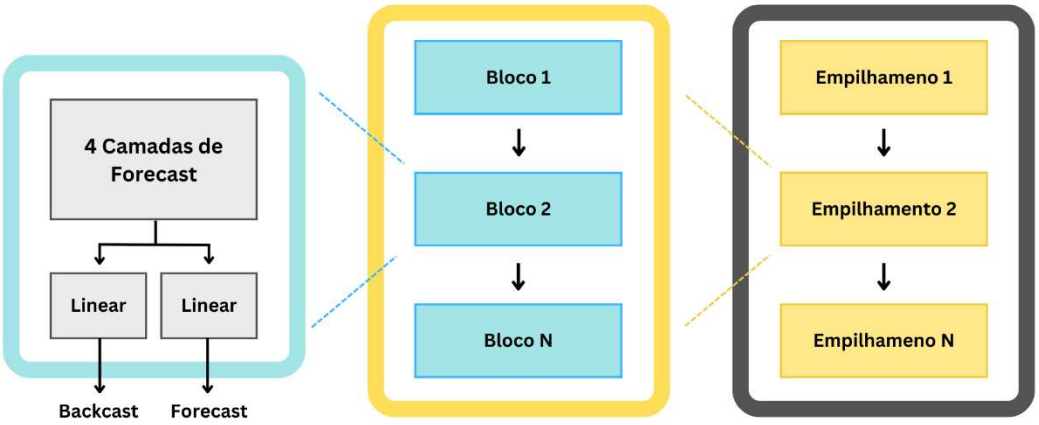
3.3.2 Neural Basis Expansion Analysis for Interpretable Time Series Forecasting (N-BEATS)

A segunda técnica é chamada de *Neural Basis Expansion Analysis for Interpretable Time Series Forecasting* (N-BEATS). É uma arquitetura inovadora criada para resolver o

problema de previsão de pontos de séries temporais univariadas, com base em links residuais anteriores e posteriores em camadas profundas totalmente conectadas (Oreshkin et al., 2019).

Esta arquitetura foi desenvolvida visando contrapor o conceito, presente na literatura de previsão com machine learning, de que somente através da combinação de metodologias hibridas seria possível avançar na previsão de dados de séries temporais. Por isso, os autores desenvolveram um modelo puramente baseado em *Deep Learning* com uma arquitetura genérica, porém profunda, e independente de ferramentas de engenharia específica para séries temporais.

Figura 7- N-BEATS



Fonte: Adaptado de Oreshkin et al., 2019

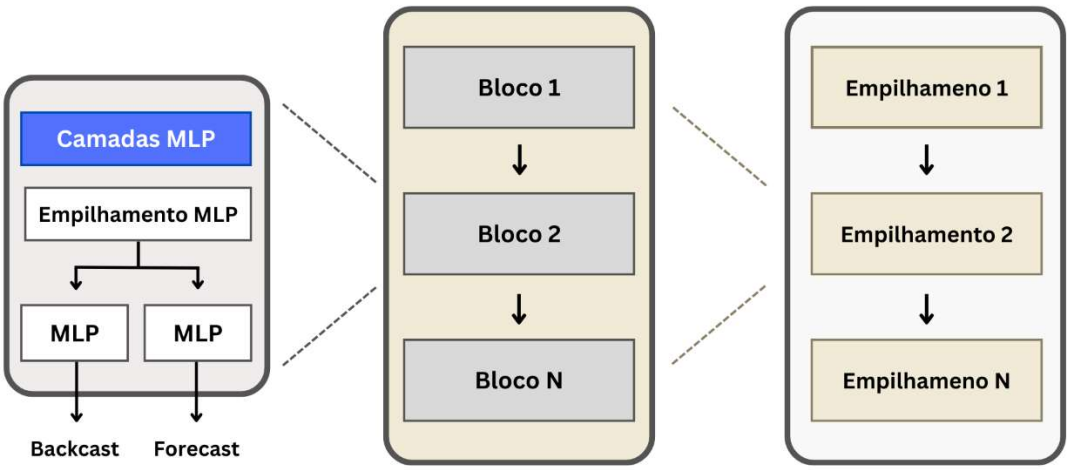
Oreshin et al (2021) testou a aplicação deste modelo para a previsão da demanda de eletricidade de médio prazo, comparando com outros modelos estatísticos e de DL, incluindo o ARIMA e o LSTM, e verificou que o N-BEATS apresentou melhores resultados que todos os demais modelos e para todas as métricas analisadas (RMSE, MAPE, MPE). Esta conclusão indica que o uso do N-BEATS pode trazer um avanço significante na tentativa de superar o quebra-cabeça de Meese e Rogoff e, portanto, se mostra um candidato importante na relação de modelos capazes de prever o câmbio.

3.3.3 Neural Hierarchical Interpolation for Time Series Forecasting (N-HiTs)

A terceira técnica conhecida como *Neural Hierarchical Interpolation for Time Series Forecasting* (N-HiTs) utiliza múltipla amostragem e sintetização em múltipla escala para a previsão de dados em série temporal, resultando em uma arquitetura hierárquica que reduz o requerimento de capacidade computacional, e aumenta o poder de precisão do modelo (Challu et al., 2022).

O N-HiTs foi desenvolvido como uma extensão do N-BEATS proposto por Oreshkin, ambas arquiteturas são estruturadas por blocos compostos por camadas empilhadas e conectadas que executam a previsão futura e a retropropagação. Entretanto, o N-HiTs se diferencia pela utilização de *Multilayer Perceptrons* (MLP) nas camadas, proporcionando múltipla abordagem no treinamento dos dados.

Figura 8 - N-HiTs



Fonte: Adaptado de Challu et al., 2022

Testando a efetividade de ambos os modelos na previsão de preços de ações, Apte e Haribhakta (2024) verificaram que o N-HiTS e o N-BEATS foram capazes de superar o benchmark SARIMA (ARIMA com sazonalidade), utilizando as métricas MAE, MSE, RMSE, MAPE e SMAPE, e demonstraram o potencial destes modelos para o uso de ativos financeiros e consequentemente para a previsão do câmbio.

3.3.4 Prophet

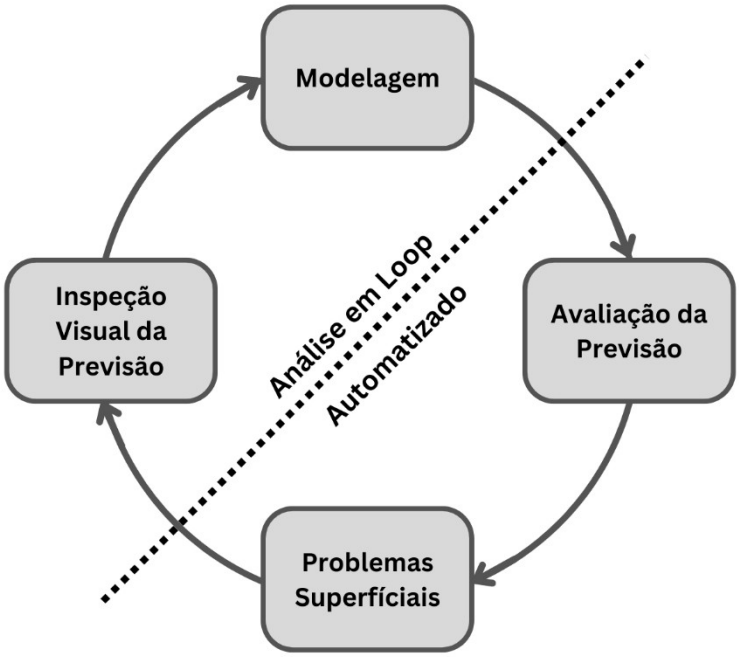
A quarta técnica é chamada de Prophet, desenvolvido por Taylor e Letham este algoritmo é formado por dois componentes: o primeiro contém um modelo de regressão modular que permite ao usuário selecionar os componentes relevantes para o processo de previsão, o segundo é um sistema para medir e avaliar a precisão do modelo, e criar alertas caso haja necessidade de ajustes manuais (Taylor e Letham, 2018).

Esta técnica é baseada no modelo de três components de Harvey e Peters, composta pela equação descrita abaixo:

$$y(t) = g(t) + s(t) + h(t) + \epsilon_t \qquad (3)$$

Onde $g(t)$ representa a função de tendência que modela as mudanças não-periódicas, $s(t)$ representa as mudanças periódicas e h(t) representa os efeitos de feriados em datas irregulares. Segundo os autores, essa especificação é similar ao modelo aditivo generalizado (GAM), uma classe de modelos de regressão composta de suavizadores não lineares. Taylor e Letham também indicam algumas vantagens desse método em relação ao ARIMA, como a flexibilidade em acomodar sazonalidade, o não requerimento de tratamento de valores faltantes ou outliers dos dados e a velocidade de geração de resultados do modelo.

Figura 9 - Prophet



Fonte: Adaptado de Taylor e Letham, 2018

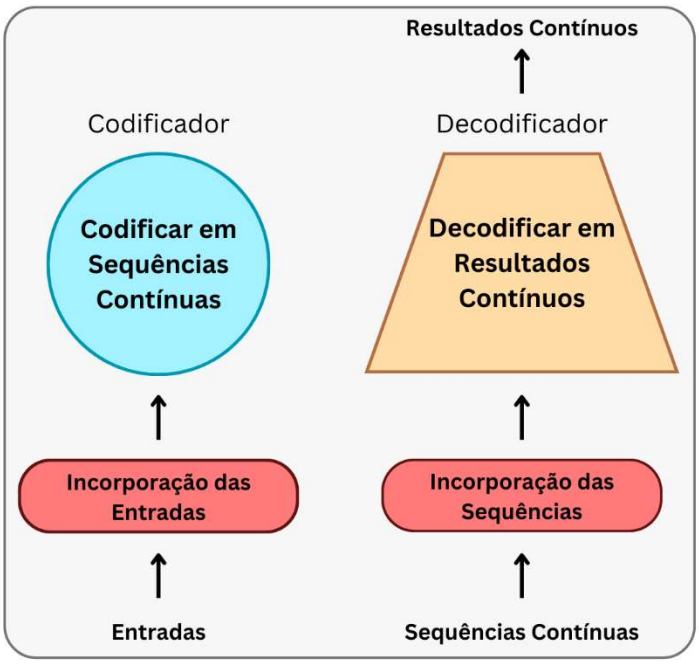
Em um estudo feito por Yenidogan et al (2018), comparou-se a performance do Prophet com o ARIMA em relação ao preço do Bitcoin de Maio de 2016 a Março de 2018. Os autores verificaram que o primeiro apresentou valor previstos com 94,5% de proximidade aos valores reais, enquanto o último obteve 68% de previsão. Essa conclusão fortalece o potencial do Prophet e aponta para a sua importância neste estudo.

3.3.5 Transformer

A quinta técnica proposta por Vaswani et al (2017), representa um novo tipo de arquitetura baseada no mecanismo de atenção, operando sem a necessidade de redes convulsionais ou recorrentes. O Transformer tem sua estrutura composta por um codificador e um decodificador, o primeiro converte as sequencias de dados inseridas em sequencias contínuas, o segundo, utilizando-se das sequencias produzidas pelo primeiro, gera um resultando sequencial para cada elemento por vez (Vaswani et al. ,2017).

De maneira semelhante ao N-BEATS e ao N-HiTs, o Transformer segue uma estrutura de blocos empilhados e interconectados, tanto para o codificador como para o decodificador, como podemos observar na Figura 3.

Figura 10 - Transformer



Fonte: Adaptado de Vaswani et al., 2017

No trabalho de Mao et al (2024), testou-se a efetividade de um modelo híbrido entre o Transformer e uma rede CNN em comparação ao modelo híbrido entre LSTM e CNN para a previsão da taxa de câmbio. Treinando os modelos para três moedas diferentes (USD, EUR e GBP), os autores descobriram que o CNN-LSTM performa melhor que o CNN-Transformer quando comparados pelo MSE. Entretanto, os resultados para o EUR e o GBP foram muito próximos (0.078 / 0.077 e 0.069 / 0.051), o que indica que um possível tratamento nos hiperparamêtros podem levar a uma melhora na performance.

Como o Transformer possui uma estrutura diferenciada dos demais modelos, utilizando o mecanismo de atenção como estrutura, sua adição neste estudo incrementa a análise de comparação de técnicas heterogêneas de Deep Learning, possibilitando um ponto de partida para pesquisas futuras.

Tabela 4 - Modelos de Deep Learning

Modelo	Descrição	Principais Referências
TimeGAN	Modelo composto por duas redes neurais: o gerador e o discriminador. O primeiro busca replicar a amostra a partir de um ruído aleatório, enquanto o último compara os dados sintéticos criados pelo primeiro.	Goodfellow et al (2020); Yoon et al (2019)
N-BEATS	Arquitetura baseada em links residuais anteriores e posteriores em camadas profundas totalmente conectadas	Oreshkin et al (2019)
N-HiTs	Técnica com arquitetura similar ao N-BEATS, porém baseada em múltipla amostragem e sintetização em múltipla escala para a previsão de dados em série temporal.	Challu et al (2022)
Prophet	Algoritmo formado por dois componentes: um modelo de regressão modular, e um sistema para medir e avaliar a precisão do modelo.	Taylor e Letham (2018).
Transformer	Arquitetura baseada no mecanismo de atenção, composto por um codificador e um decodificador. O primeiro converte as sequencias os dados em sequencias contínuas; o segundo gera um resultando sequencial para cada elemento.	Vaswani el al (2017)

Fonte: Elaboração Própria

3.4 Critérios de Avaliação

3.4.1 RMSE (Root Mean Squared Error)

O RMSE é uma métrica padronizada para a avaliação de modelos que mensura o erro pelo cálculo da raiz quadrada média das diferenças entre o valor estimado e o valor real (Apte, 2024). Partindo do pressuposto que os erros de determinado modelo não são enviesados, e que seguem uma distribuição normal, o RMSE provém uma imagem completa da distribuição do erro (Chai, 2014).

$$RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2} \qquad (4)$$

Onde y_i representa o valor real do câmbio e $\hat{y}_i$ o valor estimado previsto pelo modelo. Essa métrica é amplamente utilizada em análises envolvendo séries temporais, especialmente para ativos financeiro-econômicos. Como mencionado acima, essa foi a métrica utilizada por Meese e Rogoff para determinarem se os modelos teóricos apresentaram resultados satisfatório em relação ao modelo de Random Walk, e tem sido até hoje uma das métricas mais utilizadas em toda a literatura.

3.4.2 MAE (Mean Absolute Error)

Similar ao RMSE, o MAE é uma métrica comumente adotada para avaliação de modelos de previsão. Porém, ao invés de utilizar a raiz quadrada média das diferenças, este calcula o erro pelo valor médio das diferenças em modulo, sendo mais fácil de calcular e interpretar do que o RMSE. Dessa forma, um modelo que minimiza o MAE tende a prever a mediana, enquanto um modelo que minimiza o RMSE tende a prever a média (Hyndman e Athanasopoulos, 2018).

$$MAE = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i| \qquad (5)$$

Apesar de ambas as métricas se mostrarem adequadas para a comparação de diferentes modelos, discute-se na literatura quais das duas representa a melhor opção. Chai e Draxler (2014) sugerem que o RMSE é mais apropriado quando os erros apresentam uma distribuição normal, além de satisfazer a desigualdade triangular exigida para uma métrica de distância, este evita o uso de valores absolutos, algo desejável para cálculos matemáticos. Entretanto, o RMSE

se mostra sensível a presença de outliers, sendo que se a ordem de grandeza destes for muito maior que a dos demais dados, obtêm-se um resultado distorcido.

Os autores concluem dizendo que cada métrica enfatiza apenas um aspecto das características do erro, sendo necessário o uso de uma combinação métricas para analisar a performance de um modelo.

3.4.3 MAPE (Mean Absolute Percentage Error)

O MAPE, diferente das duas métricas anteriores, calcula o erro de forma percentual, o que facilita a comparação de previsões entre conjuntos de dados (Hyndman e Athanasopoulos, 2018). O MAPE possui a vantagem de fornecer uma interpretação intuitiva do erro, além de ser relevante para mensurações econômico-financeiras, uma vez que neste campo de estudo geralmente se avalia ganhos e perdas de maneira percentual (De Myttenaere et al, 2017).

$$MAPE = \frac{1}{n}\sum_{i=1}^{n}\frac{|y_i - \hat{y}_i|}{y_i} \qquad (6)$$

No entanto, o MAPE só apresenta um resultado significativo caso a escala dos dados também seja significativa (Makridakis, 1997). Um exemplo que se destaca é o da temperatura, que em sua escala, o valor de 0 representa uma informação arbitrária, e nesse caso o MAPE não seria a métrica mais adequada para o cálculo do erro. Como no caso do câmbio os valores permanecem acima de 0, não se apresentam problemas em utiliza-lo para avaliação da performance dos modelos.

3.4.4 MDA (Mean Directional Accuracy)

O MDA mensura o nível que um modelo é capaz de prever corretamente a direção do valor estimado (Bergmeir et al, 2014). Rossi (2005) e Mossa e Burns (2013) sugerem que essa métrica é a melhor alternativa para a previsão do câmbio, uma vez que superar o Random Walk em termos de erro tem se mostrado um obstáculo persistente por décadas. Os modelos teóricos

são capazes de prover uma descrição mais acurada dos dados, por isso o MDA revela-se como uma métrica alternativa para medir a eficácia de previsão de um modelo em comparação ao Random Walk.

$$MDA = \frac{1}{n}\sum_{i=1}^{n} \mathbf{1}_{sign(y_i - y_{i-1}) = si \quad (\hat{y}_i - \hat{y}_{i-1})} \qquad (7)$$

4. RESULTADOS

Tabela 5 - Resultados USDBRL

		Random Walk	LSTM	N-BEATS	Prophet	Transformer	ARIMA	N-HiTs	TimeGAN
USDBRL	RMSE	**0.016**	0.019	0.168	0.363	0.457	0.460	0.535	1.556
	MAE	**0.011**	0.014	0.147	0.296	0.412	0.416	0.466	1.527
	MAPE	**0.006**	0.008	0.080	0.171	0.234	0.236	0.266	0.814
	MDA	0.008	0.523	**0.548**	0.470	0.462	0.459	0.472	0.535

Tabela 6 - Resultados USDCNH

		Random Walk	LSTM	ARIMA	N-BEATS	N-HiTs	Transformer	Prophet	TimeGAN
USDCNH	RMSE	**0.011**	0.012	0.273	0.351	0.487	0.531	0.640	6.063
	MAE	**0.007**	0.008	0.232	0.312	0.425	0.511	0.532	6.061
	MAPE	**0.001**	**0.001**	0.036	0.048	0.066	0.080	0.084	0.947
	MDA	0.050	0.449	0.405	0.404	0.404	**0.546**	0.521	0.404

Tabela 7 - Resultados USDEUR

		Random Walk	LSTM	ARIMA	Prophet	Transformer	N-BEATS	N-HiTs	TimeGAN
USDEUR	RMSE	**0.005**	0.006	0.033	0.034	0.040	0.049	0.059	0.161
	MAE	**0.003**	0.005	0.027	0.029	0.034	0.042	0.044	0.157
	MAPE	**0.005**	0.007	0.036	0.040	0.045	0.055	0.061	0.208
	MDA	0.016	0.517	0.521	0.533	0.518	0.500	**0.549**	0.476

Tabela 8 – Resultados USDGBP

		Random Walk	LSTM	ARIMA	N-BEATS	N-HiTs	Transformer	Prophet	TimeGAN
USDGBP	RMSE	**0.003**	0.004	0.024	0.041	0.047	0.050	0.061	0.323
	MAE	**0.002**	0.003	0.021	0.038	0.043	0.047	0.055	0.238
	MAPE	**0.004**	0.005	0.033	0.060	0.068	0.074	0.087	0.377
	MDA	0.018	0.487	**0.501**	0.485	**0.501**	0.485	0.493	0.485

Tabela 9 - Resultados USDJPY

		Random Walk	LSTM	Prophet	N-BEATS	ARIMA	N-HiTs	Transformer	TimeGAN
USDJPY	RMSE	**0.530**	5.234	13.015	14.488	15.999	18.992	33.541	83.795
	MAE	0.368	4.801	12.132	13.234	14.610	17.497	32.705	83.464
	MAPE	0.004	0.060	0.145	0.165	0.182	0.218	0.402	0.999
	MDA	0.006	0.526	**0.536**	0.537	0.534	0.528	0.525	0.469

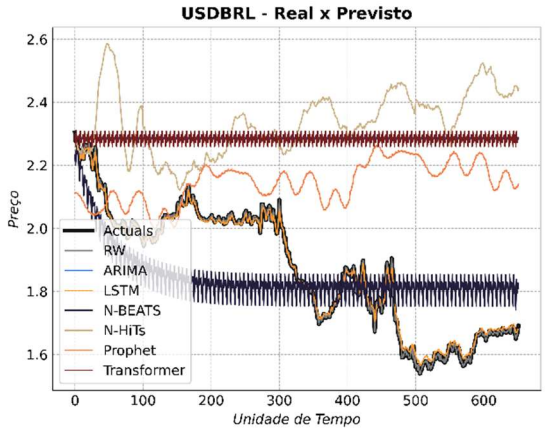
As tabelas acima estão ordenadas de acordo com o RMSE do menor para o maior, indicando a ordem de eficiência de cada modelo de previsão. Podemos observar que os valores entre o RMSE, o MAE e o MAPE são semelhantes entre as diferentes taxas de câmbio, o modelo com menor RMSE também possui o menor MAE. Portanto, podemos concluir que os erros possuem distribuição homogênea, ou seja, sem a presença de outliers significantes na amostra, confirmando a robustez de previsão dos modelos apresentados. Os modelos recentes de Deep Learning introduzidos neste estudo não apresentaram performance superior ao LSTM, modelo que mais se aproximou do valor de erro prozudido pelo *Random Walk*, confirmando sua eficácia e robustez. Apesar disso, os modelos N-BEATS e Prophet se destacaram por superar o ARIMA, para as moedas USDCNH e USDJPY. Além disso, o primeiro se mostrou consistentemente mais eficaz que os demais em prever o comportamento do câmbio, um refinamento mais sensível de seus parâmetros pode ocasionar em uma performance similar ou superior ao LSTM.

Ao contrário dos modelos mencionados acima, o TimeGAN apresentou a pior performance para todas as moedas e métricas. Por se tratar de uma técnica originalmente desenvolvida para a geração de imagens, sua adaptação para dados de séries temporais se mostrou ineficaz quando utilizada para prever o câmbio. Os modelos Transformer e N-HiTs tiveram grandes variações de performance, ora performando acima da média dos modelos, ora abaixo. O N-HiTs representa uma evolução tecnológica em relação ao N-BEATS, prometendo mais acurácia por menos necessidade de poder computacional. Entretanto, os resultados apresentados demonstram que este modelo não é eficaz quando utilizado para a previsão do câmbio, e uma vez que a diferença entre o N-HiTS e o N-BEATS se concentra na estrutura do primeiro em utilizar amostragem de dados em múltiplas taxas e interpolação em múltiplas escalas, podemos compreender que a previsão do câmbio é mais eficaz em abordagens lineares e univariadas.

Os resultados também reafirmam as descobertas de Rossi (2005) e Moosa e Burns (2014) nas quais os modelos de previsão são capazes de antever a direção do preço do câmbio melhor que o Random Walk. Essa descoberta representa um impacto significativo para a negociação do preço de ativos econômico-financeiros, pois como Moosa e Burns argumentam, prever a direção do preço de maneira correta é mais importante do que prever a magnitude do erro quando se busca obter lucros financeiros. Essa conclusão oferece uma alternativa real para os modelos de previsão, como Engel et al (2007) afirmam, superar o Random Walk é um critério muito rigoroso para se aceitar um modelo. Ao invés disso, deveria-se escolher aqueles modelos

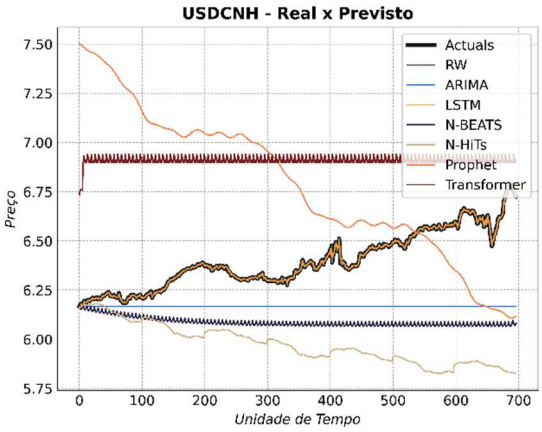
que oferecem uma descrição do comportamento do câmbio de maneira consistente e com o menor erro possível.

Figura 11- USDBRL - Real x Previsto



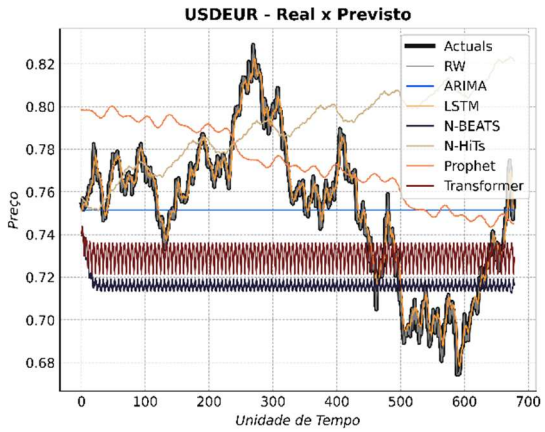
Fonte: Elaboração Própria

Figura 12 - USDCNH - Real x Previsto



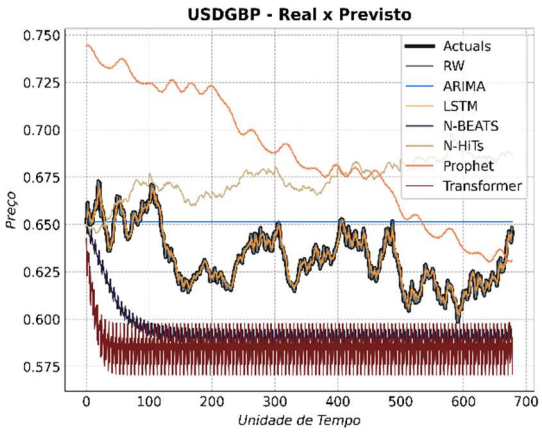
Fonte: Elaboração Própria

Figura 13- USDEUR - Real x Previsto



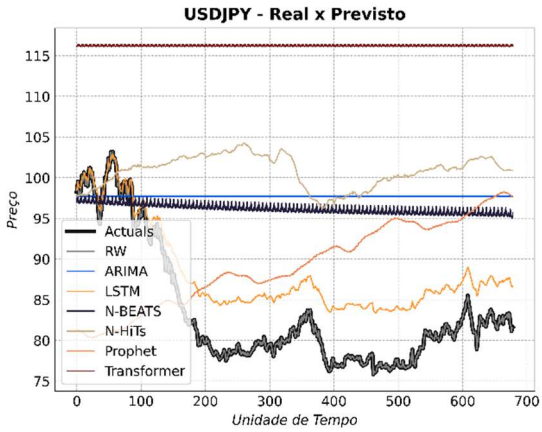
Fonte: Elaboração Própria

Figura 14 - USDGBP - Real x Previsto



Fonte: Elaboração Própria

Figura 15 - USDJPY - Real x Previsto



Fonte: Elaboração Própria

5. CONCLUSÃO

O Meese-Rogoff puzzle permanece como o maior desafio na literatura sobre previsão de taxas de câmbio, este estudo introduziu seis técnicas de machine learning com o objetivo de superar essa barreira. Embora nenhum dos modelos apresentados tenha superado o desempenho do modelo de Random Walk, os resultados apontam que parte das técnicas se destacam como alternativas promissoras demonstrando desempenho superior ao ARIMA para a maioria das moedas analisadas. Dentre os modelos recentes, o N-BEATS apresentou a melhor performance, indicando sua robustez em se tratando de previsão de séries temporais e, especialmente, do câmbio.

Para pesquisas futuras, recomenda-se a exploração de diferentes configurações de parâmetros e o aumento do conjunto de dados analisados para potencializar a performance destes modelos. Alternativamente, o uso de modelos híbridos se utilizando da combinação de diferentes técnicas, também pode produzir melhores resultados. Além disso, considerando o avanço exponencial das tecnologias de inteligência artificial, é razoável esperar que esses métodos sejam aprimorados em um futuro próximo, possibilitando resultados mais satisfatórios.

Nossos resultados demonstraram que os modelos de *Deep Learning* são capazes de prever a direção do câmbio de maneira mais eficiente que o Random Walk, esta conclusão representa um caminho a ser explorado e uma solução alternativa ao quebra-cabeça de Meese e Rogoff.

REFERÊNCIAS

APTE, M.; HARIBHAKTA, Y. Advancing Financial Forecasting: A Comparative Analysis of Neural Forecasting Models N-HiTS and N-BEATS. **arXiv preprint**, arXiv:2409.00480, 2024. Disponível em: https://doi.org/10.48550/arXiv.2409.00480

BACCHETTA, P.; VAN WINCOOP, E.; BEUTLER, T. Can Parameter Instability Explain the Meese-Rogoff Puzzle? **NBER International Seminar on Macroeconomics**, v. 6, n. 1, p. 125–173, 2009. Disponível em: https://www.jstor.org/stable/10.1086/648702.

BENGIO, Y.; SIMARD, P.; FRASCONI, P. Learning Long-Term Dependencies with Gradient Descent is Difficult. **IEEE Transactions On Neural Networks**, v. 5, n. 2, p. 157–166, 1994. Disponível em: https://doi.org/10.1109/72.279181.

BERGMEIR, C.; COSTANTINI, M.; BENÍTEZ, J. M. On the usefulness of cross-validation for directional forecast evaluation. **Computational Statistics & Data Analysis**, v. 76, p. 132-143, 2014. Disponível em: https://doi.org/10.1016/j.csda.2014.02.001

CAO, W.; ZHU, W.; WANG, W.; DEMAZEAU, Y.; ZHANG, C. A deep coupled LSTM approach for USD/CNY exchange rate forecasting. **IEEE Intelligent Systems**, v. 35, n. 2, p. 43-53, 2020. Disponível em: https://doi.org/10.1109/MIS.2020.2977283

CHAI, T.; DRAXLER, R. R. Root mean square error (RMSE) or mean absolute error (MAE)? – Arguments against avoiding RMSE in the literature. **Geoscientific Model Development**, v. 7, n. 3, p. 1247-1250, 2014. Disponível em: https://doi.org/10.5194/gmd-7-1247-2014.

CHALLU, C.; OLIVARES, K. G.; ORESHKIN, B. N.; RAMIREZ, F. G.; CANSECO, M. M.; DUBRAWSKI, A. NHITS: Neural hierarchical interpolation for time series forecasting. **Proceedings of the AAAI Conference on Artificial Intelligence**, v. 37, n. 6, p. 6989-6997, 2023. Disponível em: https://doi.org/10.1609/aaai.v37i6.25854

CHEUNG, Y. W.; CHINN, M. D.; PASCUAL, A. G. Empirical exchange rate models of the nineties: are any fit to survive? **Journal of International Money and Finance**, v. 24, n. 7, p. 1150-1175, 2005. Disponível em: https://doi.org/10.1016/j.jimonfin.2005.08.002

CHOLLET, Francois. **Deep learning with Python**. 2. ed. Simon and Schuster, 2021.

DE MYTTENAERE, A.; GOLDEN, B.; LE GRAND, B.; ROSSI, F. Mean absolute percentage error for regression models. **Neurocomputing**, v. 192, p. 38-48, 2016. Disponível em: https://doi.org/10.1016/j.neucom.2015.12.114

ENGEL, C.; MARK, N. C.; WEST, K. D.; ROGOFF, K.; ROSSI, B. Exchange rate models are not as bad as you think. **NBER Macroeconomics Annual**, v. 22, p. 381-473, 2007. Disponível em: https://doi.org/10.1086/ma.22.25554969

FAMA, E. F. Efficient capital markets: a review of theory and empirical work. **The Journal of Finance**, v. 25, n. 2, p. 383–417, 1970. Disponível em: https://doi.org/10.2307/2325486

GOODFELLOW, I.; POUGET-ABADIE, J.; MIRZA, M.; XU, B.; WARDE-FARLEY, D.; OZAIR, S.; COURVILLE, A.; BENGIO, Y. Generative adversarial networks. **Communications of the ACM**, v. 63, n. 11, p. 139–144, 2020. Disponível em: https://doi.org/10.1145/3422622

HAKKIO, C. Does the exchange rate follow a random walk? A Monte Carlo study of four tests for a random walk. **Journal of International Money and Finance**, v. 5, n. 2, p. 221-229, 1986. Disponível em: https://doi.org/10.1016/0261-5606(86)90043-4

HOCHREITER, S.; SCHMIDHUBER, J. Long Short-Term Memory. **Neural Computation**, v. 9, n. 8, p. 1735–1780, 1997. Disponível em: https://doi.org/10.1162/neco.1997.9.8.1735.

HYNDMAN, R. J. **Forecasting: principles and practice**. Melbourne: OTexts, 2018.

LECUN, Y.; BENGIO, Y.; HINTON, G. Deep learning. **Nature**, v. 521, n. 7553, p. 436-444, 2015. Disponível em: https://doi.org/10.1038/nature14539

MAKRIDAKIS, S.; WHEELWRIGHT, S. C.; HYNDMAN, R. J. **Forecasting methods and applications**. 3. ed. Hoboken: John Wiley & Sons, 1997.

MAO, Y.; CHEN, Z.; LIU, S.; LI, Y. Unveiling the potential: Exploring the predictability of complex exchange rate trends. **Engineering Applications of Artificial Intelligence**, v. 133, p. 108112, 2024. Disponível em: https://doi.org/10.1016/j.engappai.2024.108112.

MESEE, R. A.; ROGOFF, K. Empirical Exchange Rate Models Of The Seventies: Do They Fit Out Of Sample? **Journal of International Economics**, v. 14, p. 3–24, 1983. Disponível em: https://doi.org/10.1016/0022-1996(83)90017-X

MEESE, R.; ROGOFF, K.; FRENKEL, J. The out-of-sample failure of empirical exchange rate models: sampling error or misspecification? **Exchange Rates and International Macroeconomic**, p. 67-105, 1983.

MOOSA, I.; BURNS, K. A reappraisal of the Meese–Rogoff puzzle. **Applied Economics**, v. 46, n. 1, p. 30–40, 2014. Disponível em: https://doi.org/10.1080/00036846.2013.829202.

MOLODTSOVA, T.; PAPELL, D. H. Out-of-sample exchange rate predictability with Taylor rule fundamentals. **Journal of International Economics**, v. 77, n. 2, p. 167-180, 2009. Disponíbel em: https://doi.org/10.1016/j.jinteco.2008.11.001

NGAN, T. M. U. Forecasting foreign exchange rate by using ARIMA model: a case of VND/USD exchange rate. **Research Journal of Finance and Accounting**, v. 7, n. 2, p. 38-44, 2016.

ORESHKIN, B. N.; CARPOV, D.; CHAPADOS, N.; BENGIO, Y. N-BEATS: Neural basis expansion analysis for interpretable time series forecasting. **arXiv preprint arXiv**, 2019. https://doi.org/10.48550/arXiv.1905.10437

ORESHKIN, B. N.; DUDEK, G.; PEŁKA, P.; TURKINA, E. N-BEATS neural network for mid-term electricity load forecasting. **Applied Energy**, v. 293, p. 116918, 2021. Disponível em: https://doi.org/10.1016/j.apenergy.2021.116918

RÉVÉSZ, P. **Random Walk in random and non-random environments**. Singapore: World Scientific, 2013.

ROSSI, B. Testing Long-Horizon Predictive Ability With High Persistence, And The Meese–Rogoff Puzzle. **International Economic Review**, v. 46, n. 1, p. 61–92, 2005. Disponível em: https://doi.org/10.1111/j.0020-6598.2005.00310.x

ROSSI, B. (2013). Exchange rate predictability. **Journal of economic literature**, 51(4), 1063-1119. Disponível em: https://doi.org/ 10.1257/jel.51.4.1063

RUSSEL, S.; NORVIG, P. Artificial Intelligence: A Modern Approach. 4. ed. **Pearson Education**, 2021.

SANTORO, D.; GRILLI, L. Generative adversarial network to evaluate quantity of information in financial markets. **Neural Computing and Applications**, v. 34, n. 20, p. 17473-17490, 2022. Disponivel em: https://doi.org/10.1007/s00521-022-07401-3

SHUMWAY, R. H.; STOFFER, D. S. **Time series analysis and its applications**. 3. ed. New York: Springer, 2010

TAYLOR, Sean J.; LETHAM, Benjamin. Forecasting at scale. **The American Statistician**, v. 72, n. 1, p. 37-45, 2018. Disponível em: https://doi.org/10.1080/00031305.2017.1380080

VASWANI, A. Attention is all you need. In: ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS. 2017. Long Beach. **Anais eletrônicos** [...]. Long Beach: 31st Conference on Neural Information Processing Systems (NIPS 2017), 2017. Disponível em: https://user.phil.hhu.de/~cwurm/wp-content/uploads/2020/01/7181-attention-is-all-you-need.pdf. Acesso em: 18 de setembro. 2024.

YENIDOĞAN, I.; ÇAYIR, A.; KOZAN, O.; DAĞ, T.; ARSLAN, Ç. Bitcoin forecasting using ARIMA and PROPHET. In: INTERNATIONAL CONFERENCE ON COMPUTER SCIENCE AND ENGINEERING, 3., 2018, Sarajevo. **Anais eletrônicos** [...]. Sarajevo: IEEE, 2018. p. 621-624. Disponível em: https://doi.org/10.1109/UBMK.2018.8566476. Acesso em: 16 de setembro. 2024.

YOON, J.; JARRETT, D.; VAN DER SCHAAR, M. Time-series generative adversarial networks. **Advances in Neural Information Processing Systems**, v. 32, 2019