UNIVERSIDADE PRESBITERIANA MACKENZIE
Centro de Ciências Sociais e Aplicadas
Programa de Pós-Graduação em Administração de Empresas

Marisa Gomes da Costa

ENSAIOS SOBRE O USO DE REDES NEURAIS NA PREVISÃO DE TAXA DE CÂMBIO

SÃO PAULO

2020

MARISA GOMES DA COSTA

ENSAIOS SOBRE O USO DE REDES NEURAIS NA PREVISÃO DA TAXA DE CÂMBIO

Tese de doutorado submetida ao Programa de Pós-Graduação em Administração de Empresas da Universidade Presbiteriana Mackenzie como requisito parcial à obtenção do título de Doutor(a) em Administração de Empresas, Linha "Finanças Estratégicas".

Orientador: Prof. Dr. Leonardo Fernando Cruz Basso

SÃO PAULO

2020

C837e Costa, Marisa Gomes da
Ensaios sobre o uso de redes neurais na previsão de taxa de câmbio / Marisa Gomes da Costa.
92 f.: il. ; 30 cm

Tese (doutorado em Administração de Empresas) – Universidade Presbiteriana Mackenzie, São Paulo, 2020.
Orientador: Leonardo Fernando Cruz Basso
Bibliografia: f. 62-68.

1. Confidence Set Model 2. Inteligência Artificial 3.LSTM 4.Redes Neurais Recorrentes 5.Temas Emergentes. I. Basso, Leonardo Fernando Cruz orientador. II. Título.

CDD 332

Bibliotecária Responsável: Maria Gabriela Brandi Teixeira CRB-8/6339

Folha de Identificação da Agência de Financiamento

Autor: Marisa Gomes da Costa

Programa de Pós-Graduação *Stricto Sensu* em Administração de Empresas

Título do Trabalho: ENSAIOS SOBRE O USO DE REDES NEURAIS NA PREVISÃO DE TAXA DE CÂMBIO

O presente trabalho foi realizado com o apoio de [1]:

☒ CAPES - Coordenação de Aperfeiçoamento de Pessoal de Nível Superior

☐ CNPq - Conselho Nacional de Desenvolvimento Científico e Tecnológico

☐ FAPESP - Fundação de Amparo à Pesquisa do Estado de São Paulo

☐ Instituto Presbiteriano Mackenzie/Isenção integral de Mensalidades e Taxas

☐ MACKPESQUISA - Fundo Mackenzie de Pesquisa

☐ Empresa/Indústria:

☐ Outro:

[1] **Observação**: caso tenha usufruído mais de um apoio ou benefício, selecione-os.

MARISA GOMES DA COSTA

ENSAIOS SOBRE O USO DE REDES NEURAIS NA PREVISÃO DE TAXA DE CÂMBIO

Tese apresentada ao Programa de Pós-Graduação em Administração de Empresas da Universidade Presbiteriana Mackenzie, como requisito parcial à obtenção de título de Doutor em Administração de Empresas.

Aprovado em 24 de Abril de 2020.

BANCA EXAMINADORA

Prof. Dr. Leonardo Fernando Cruz Basso
Universidade Presbiteriana Mackenzie

Prof. Dr. Eli Hadad Junior
Universidade Presbiteriana Mackenzie

Prof.ª Dr.ª Michele Nascimento Jucá
Universidade Presbiteriana Mackenzie

Prof. Dr. Diogo de Prince Mendonça
Universidade Federal de São Paulo (Campus Osasco)

Prof. Dr. Herbert Kimura
Universidade de Brasília

Aos meus queridos esposo, Jonas e filho, João Marcos, pelo incentivo de todos os dias. Pelo amor, carinho e compreensão de todas as horas; A minha mãe, Cleuza, por seus grandes ensinamentos em minha vida: simplicidade, fé e coragem!

AGRADECIMENTOS

Meus agradecimentos mais sinceros:

A Deus, o Pai maior, que alimenta, sustenta e renova o espírito humano todos os dias e de todas as formas. O Senhor abençoou todas as sementes plantadas em minha vida e, regadas com lágrimas e suor, sempre me permitiu colher seus frutos. Que o nome do Senhor seja louvado!

Desejo agradecer especialmente ao meu orientador, Prof. Leonardo Fernando Cruz Basso, pelo acompanhamento e convivência neste longo trajeto acadêmico. Seu apoio e conhecimento foram indispensáveis nos momentos de dúvida. Sua confiança e incentivo foram decisivos para o alcance dos objetivos.

Aos prezados, Prof. Dr. Denis Forte, Prof. Dr. Wilson Toshiro Nakamura e Prof. Dr. Emerson Fernandes Marçal, Prof. Dr. Walter Bataglia e Profª. Dra. Maria Luisa Mendes Teixeira, pelo grande privilégio de desfrutar de sua convivência, pelo acolhimento sempre caloroso, gentil e atencioso.

Aos Prof. Dr. Eli Hadad Junior, Profª. Dra. Michele Nascimento Jucá, Prof. Dr. Diogo de Prince Mendonça e Prof. Dr. Herbert Kimura, componentes da banca examinadora, cujas opiniões, sugestões e análises, contribuíram decisivamente para que os objetivos deste trabalho fossem efetivamente alcançados.

Agradeço a Tatiane Domingues Goncales, secretária do PPGA, pela sua inesgotável paciência e enorme profissionalismo.

Agradeço profundamente aos colegas do curso de Doutorado em Administração de Empresas: Luís Fernando Corrêa da Costa, Rina Xavier Pereira, Wagner Oliveira Monteiro e Samuel de Paiva Naves Mamede, pela oportunidade em compartilhar nossas ansiedades, incertezas, dificuldades, mas também as descobertas e conquistas. Somos todos vencedores!!!

RESUMO

Este estudo objetiva comparar e avaliar o poder preditivo dos modelos de rede neural artificial sobre taxas de câmbio. Inicialmente é realizado um estudo bibliométrico e de revisão de literatura a fim de identificar o atual *status* de pesquisa na área. Em seguida, é realizado um estudo empírico de previsão de taxas de câmbio utilizando dados de abertura, fechamento, máximo e mínimo em frequência diária. A amostra de dados contempla as taxas de câmbio (BRL/USD, EUR/USD e GBP/USD) no período de janeiro de 2014 a dezembro de 2019. As previsões são realizadas para um horizonte de um período à frente. Foram testadas diferentes arquiteturas do modelo de rede neural recorrente LSTM. Para ranquear os modelos em termos de poder preditivo, os resultados das previsões são comparados à previsão do modelo de passeio aleatório, utilizando-o como *benchmark*, bem como ARIMA. A seleção de modelos é feita pelo *Model Confidence Set* (MCS), de Hansen, Lunde e Nason (2011). Os resultados indicaram que o modelo LSTM é superior ao passeio aleatório e ARIMA para todas as moedas analisadas.

Palavras-chave: *Confidence Set Model*, Aprendizagem de máquina, LSTM, Redes neurais recorrentes, Temas emergentes.

ABSTRACT

This study aims to compare and evaluate the predictive power of artificial neural network models on exchange rates. Initially, a bibliometric study and literature review is carried out in order to identify the current research *status* in the area. Then, an empirical study is proposed to forecast various exchange rates using data of opening, closing, high and low in daily frequency. The data sample includes exchange rates ((BRL/USD, EUR/USD e GBP/USD) from January 2014 to December 2019. Forecasts are made for a period ahead. Different architectures of the LSTM recurrent neural network model were tested. To rank the models in terms of predictive power, the results of the predictions are compared to the prediction of the random walk model, using it as a benchmark, as well as ARIMA. The selection of models is made by the Model Confidence Set (MCS), by Hansen, Lunde and Nason. The results indicated that the LSTM model is superior to the random walk and ARIMA for all analyzed currencies.

Keywords: Confidence set model; Machine learning; LSTM; Neural networks; Hot topics.

LISTA DE ILUSTRAÇÕES

Figura 2.1 - Gráfico de Pareto - Produção Científica 1990-2019 10
Figura 2.2 - Rede de Cooperação dos países 11
Figura 2.3 - Produção Científica dos 10 autores mais produtivos ao longo do tempo 14
Figura 2.4 - Gráficos de Estudos mais Influentes (Outliers) 16
Figura 2-5 - *Hot Topics* em Previsão de Câmbio com Redes Neurais 28
Figura 3-1 - Rede neural feedforward típica para previsão de séries temporais 33
Figura 3-2 - Desdobramento de uma rede neural recorrente 36
Figura 3-3 - Arquitetura de uma célula de memória 37
Figura 3-4 - Arquitetura rede neural LSTM 38
Figura 3-5 – Gráfico: Previsão da taxa de câmbio (BRL/USD) 47
Figura 3-6 – Gráfico Box-plot MSE (BRL/USD) 48
Figura 3-7 – Gráfico: Previsão da taxa de câmbio (EUR/USD) 52
Figura 3-8 – Gráfico Box-plot MSE (EUR/USD) 52
Figura 3-9 - Previsão da taxa de câmbio (GBP/USD) 56
Figura 3-10 – Gráfico Box-plot MSE (GBP/USD) 57
Figura A-1 - Taxa de BRL/USD: Fechamento (4 de jan.2014 a 30 de dez.2019) 69
Figura A-2 - Taxa de BRL/USD: Abertura (4 de jan.2014 a 30 de dez.2019) 69
Figura A-3 - Taxa de câmbio BRL/USD: Máxima (4 de jan.2014 a 30 de dez.2019) 70
Figura A-4 - Taxa de câmbio BRL/USD: Mínima (4 de jan.2014 a 30 de dez.2019) 70
Figura A-5 - Taxa de câmbio BRL/USD: Média (4 de jan.2014 a 30 de dez.2019) 71
Figura A-6 - Taxa de câmbio BRL/USD: Autocorrelação (4 de jan.2014 a 30 de dez.2019) .. 71
Figura A-7 - Taxa de câmbio EUR/USD: Fechamento (4 de jan.2014 a 30 de dez.2019) 72
Figura A-8 - Taxa de câmbio EUR/USD: Abertura (4 de jan.2014 a 30 de dez.2019) 72
Figura A-9 - Taxa de câmbio EUR/USD: Máxima (4 de jan.2014 a 30 de dez.2019) 73
Figura A-10 - Taxa de câmbio EUR/USD: Mínima (4 de jan.2014 a 30 de dez.2019) 73
Figura A-11 - Taxa de câmbio EUR/USD: Média (4 de jan.2014 a 30 de dez.2019) 74
Figura A-12 - Taxa de câmbio EUR/USD: Autocorrelação (4 de jan.2014 a 30 de dez.2019) 74
Figura A-13 - Taxa de câmbio GBP/USD: Fechamento (4 de jan.2014 a 30 de dez.2019) 75
Figura A-14 - Taxa de câmbio GBP/USD: Abertura (4 de jan.2014 a 30 de dez.2019) 75
Figura A-15 - Taxa de câmbio GBP/USD: Mínima (4 de jan.2014 a 30 de dez.2019) 76
Figura A-16 - Taxa de câmbio GBP/USD: Máxima (4 de jan.2014 a 30 de dez.2019) 76
Figura A-17 - Taxa de câmbio GBP/USD: Média (4 de jan.2014 a 30 de dez.2019) 77
Figura A-18 - Taxa de câmbio GBP/USD: Autocorrelação (4 de jan.2014 a 30 de dez.2019) 77

LISTA DE TABELAS

Tabela 2.1 - Termos utilizados na busca das publicações 7
Tabela 2.2 - Principais informações sobre dados 8
Tabela 2.3 - Produção Científica Anual 9
Tabela 2.4 - Países com maior produção científica 11
Tabela 2.6 – Os 10 periódicos mais produtivos 12
Tabela 2.7 - Produtividade dos Autores 13
Tabela 2.8 - Os 10 Autores mais produtivos 14
Tabela 2.9 - Artigos mais citados por AIF 17
Tabela 2.10 - Modelos propostos e seus concorrentes nos estudos selecionados 25
Tabela 2.10 - Modelos propostos e seus concorrentes nos estudos selecionados 26
Tabela 3.1 - Model Confidence Set Estimation (BRL/USD) 46
Tabela 3.2 - Model Confidence Set $\mathcal{M}90\% *$: BRL/USD 47
Tabela 3.3 - Estatística Descritiva MSE: BRL/USD 49
Tabela 3.4 - Precisão da previsão da direção (DA): BRL/USD 49
Tabela 3.5 - Model Confidence Set Estimation: EUR/USD 50
Tabela 3.6 - Model Confidence Set $\mathcal{M}90\% *$: EUR/USD 51
Tabela 3.7 - Estatística Descritiva do MSE (EUR/USD) 53
Tabela 3.8 - Precisão da previsão da direção (DA): EUR/USD 54
Tabela 3.9 - Model Confidence Set Estimation: GBP/USD 55
Tabela 3.10 - Model Confidence Set $\mathcal{M}90\% *$: (GBP/USD) 55
Tabela 3.11 - Estatística Descritiva do MSE (GBP/USD) 57
Tabela 3.12 - Precisão da previsão da direção – DA (GBP/USD) 58

LISTA DE ABREVIATURAS E SIGLAS

AFLS	*Adaptive fuzzy logic system*
AIC	*Akaike information criterion*
AIF	*Article impact factor*
ARBF	*Adaptative radial basis function*
ARIMA	Autoregressivo integrado de médias móveis
ARMA	Autoregressivo de medias móveis
AUD	Dólar australiano
BIC	*Bayesiano information criterion*
BRL	Real
BTC	Bitcoin
CAD	Dólar canadense
CART	*Classification and regression trees*
CART-EB	CART e*nsembles and bagger*
CFLANN	*Cascaded functional link artificial neural network*
CHF	Franco suíço
CORR	Correlação
DA	*Direction accuracy*
DBN	*Deep belief network*
DEM	Marco alemão
ECB	*European central bank*
EGARCH	*Exponential generalized autoregressive conditional heteroscedastic*
EMD	*Empirical mode decomposition*
EUR	Euro
EvRBF	*Evolutionary radial basis function*
FFNN	*Feedforward neural network*
FLANN	*Functional link artificial neural network*
FNN	*Fuzzy neural network*
FNN-PS	*Fuzzy neural network + particle swarm*
FOREX	*Foreign Exchange*
GA	*Genetic algorithm*
GARCH	*Generalized autoregressive conditional heteroskedasticity*
GBP	Libra esterlina
GLAR	General linear autoregressive regression
GMDH	Group Method of Data Handling
GRNN	Generalized regression neural network
INR	Rupia indiana
JPY	Iene japonês
K-NN	*k-nearest neighbors algorithm*
LASSO	*Least absolute shrinkage and selection operator*
LMS	*Least mean square (LMS) algorithm*
LPS	*Laplace particle swarm*

LSE	*Least square error*
LSTM	*Long short-term memory*
MACD	*Moving average convergence/divergence model*
MAE	*Mean Absolute Error*
MAPE	*Mean absolute percentage error*
MARS	*Multivariate adaptive regression splines*
MCS	*Model confidence set*
MLFN	*Multilayer feedforward neural networ*
MLP	*Multilayer perceptron*
MOPSO	*Multi-objective particle swarm optimization*
NMSE	*Normalized mean squared error*
NSGA	*Non-Dominated Sorting Genetic Algorithm*
PCA	*Principal Component Analysis (PCA)*
PRE	*Percent Relative Error*
OS	*Particle swarm*
PSO	*Particle swarm optimization*
PSOQRNN	*Particle swarm optimization + Quantile regression neural network*
QRNN	*Quantile Regression Neural Network*
QRRF	*Quantile Regression Random Forest*
RBF	*Radial basis function*
RBFNN	*Radial basis function neural network*
RF	*Random forest*
RFTE	*Random forest tree ensemble*
RMSE	*Root Mean Square Error*
RNA	*Rede neural artificial*
RW	*Random walk*
SED	*Standard error deviation*
VMD	*Variational mode decomposition*

SUMÁRIO

1. INTRODUÇÃO 1
1.1. Contextualização 1
1.2. Estrutura da Tese 3
2. ANÁLISE BIBLIOMÉTRICA E REVISÃO DE LITERATURA 5
2.1. Contextualização 5
2.2. Procedimentos metodológicos e análise descritiva dos dados 7
2.3. Análise bibliométrica 8
2.3.1. Tendência de Crescimento da Produção Científica 9
2.3.2. Produção Científica por país 10
2.3.3. Fontes de publicação 12
2.3.4. Produtividade dos Autores 13
2.3.5. Estudos mais influentes 15
2.4. Revisão da literatura selecionada 18
2.4.1. Especificação da estrutura do modelo 18
2.4.2. Modelos propostos pelos estudos selecionados 20
2.5. *Hot Topics* 27
2.6. Conclusões Parciais 29
3. PREVISÃO DE TAXA DE CÂMBIO COM REDE NEURAL RECORRENTE LSTM E INDICADORES TÉCNICOS 31
3.1. Introdução 31
3.2. Modelos de Rede Neural 33
3.2.1. Rede Neural *Feedforward* 33
3.2.2. Rede Neural Recorrente 35
3.2.3. Rede Neural LSTM 37
3.3. Modelos de Referência 39
3.3.1. Passeio aleatório 39
3.3.2. ARIMA 40
3.4. Seleção de Modelos 41
3.5. Medidas da precisão da previsão 42
3.5.1. Medidas tradicionais 42
3.5.2. Medidas de precisão da direção da previsão 43
3.6. Estratégia Empírica 44
3.7. Resultados 45
3.7.1. BRL/USD 45

3.7.2. EUR/USD 50
3.7.3. GBP/USD 54
3.8. Conclusões Parciais 59
4. Considerações Finais 60
REFERÊNCIAS 62
ANEXO A: Gráficos das séries temporais estudadas 69

1. INTRODUÇÃO

1.1. Contextualização

Desde o abandono do sistema de Bretton Woods e a adoção do sistema de taxas de câmbio flutuantes em 1971, indicador de grande importância, a taxa de câmbio tem despertado o profundo interesse de agentes atentos, tão díspares entre si como, agentes implementadores de políticas econômicas, profissionais atuantes no mercado ou pesquisadores e acadêmicos. Estes diversos interessados têm se debruçado, em especial, sobre os fatores que possam influenciar sua previsibilidade. Sob a ótica macroeconômica, a previsibilidade das flutuações das taxas de câmbio é indispensável por se considerar que estas sejam responsáveis por influir sobre o nível de comércio de um país, bem como sobre sua competitividade e sobre o peso de sua dívida externa. Já pelo ângulo microeconômico, os movimentos da taxa de câmbio geram exposição de risco para um rendimento da carteira do investidor ou daqueles que possuem seus ativos e passivos denominados em moeda estrangeira.

O estudo seminal de Meese e Rogoff (1983a) afirma que as taxas de câmbio dificilmente podem oferecer previsibilidade a partir de modelos econômicos estruturais. Denominado *de Meese e Rogoff puzzle*, este estudo considera que um modelo simplificado como o passeio aleatório proporciona melhores estimativas de taxas de câmbio. Meese e Rogoff (1983b) atribuem essa dificuldade a problemas econométricos como por exemplo, viés de equações simultâneas, erros de amostragem, movimentos estocásticos dos verdadeiros parâmetros subjacentes, erros de especificação e não linearidades. Entretanto, as taxas de câmbio são afetadas por fatores econômicos, políticos e até mesmo psicológicos, altamente correlacionados. Este fato, faz com que a tarefa de previsão dos movimentos da taxa de câmbio ainda seja dificultada, pois tais fatores interagem de maneira altamente complexa. Ademais, as taxas de câmbio exibem alta volatilidade, complexidade e ruído, resultantes de um mecanismo de mercado elusivo que gera observações diárias (THEODOSSIOU, 1994; HUANG; LAI; NAKAMORI, 2007).

Passados mais de 30 anos da publicação do estudo realizado por Meese e Rogoff (1983), essa discussão ainda permanece. Enquanto alguns estudos posteriores encontram evidências de que as taxas de câmbio são previsíveis (YU, WANG e LAI, 2007; PERDOMO e BOTELHO, 2007), outros identificam que a previsão das taxas de câmbio, usando modelos econômicos, dificilmente supera o desempenho do passeio aleatório (MEESE e ROGOFF, 1983a, 1983b; ROSSI, 2013; MARÇAL e HADAD, 2016; entre outros). Assim, identificar os modelos de

previsão das taxas de câmbio que superam as previsões de passeio aleatório ainda é um desafio, devido ao fato de que as evidências que apoiam ou refutam a previsibilidade da taxa de câmbio parecerem plausíveis.

Na atualidade, o uso dos algoritmos tem sido decisivo para redefinir a capacidade de precisão dos modelos. Isto se deve à possibilidade de seu contínuo aprendizado (inteligência artificial), ao lidar com padrões não lineares complexos destes modelos, explorando relacionamentos não estruturados. O aprendizado dos algoritmos não se restringe a suposições ou processos de geração de dados predefinidos, o que permite que os dados falem por si (SMYL, 2020). No mundo atual, a aplicação da inteligência artificial é altamente difundida (segurança contra fraudes corporativas, processamento do genoma humano, exploração espacial, veículos autônomos, entre outros) (MAKRIDAKIS, 2017; SMYL, 2020).

Entre os algoritmos de inteligência artificial aplicáveis a séries de tempo, as redes neurais são particularmente atraentes para encontrar soluções precisas em um ambiente caracterizado por informações complexas, ruidosas, irrelevantes ou parciais. Nos campos de finanças e economia, muitos comportamentos de preço têm memória e podem ser modelados com maior precisão com técnicas diferentes dos métodos tradicionais de estatística linear. Alguns métodos não-lineares emergentes, em particular redes neurais, estão sendo cada vez mais aplicados em finanças e economia, já que as redes neurais têm formas funcionais mais gerais do que aquelas que podem ser efetivamente tratadas por métodos estatísticos bem desenvolvidos. A aplicação envolve a interação de diversas variáveis que são altamente correlacionadas, frequentemente consideradas não-lineares, não relacionadas de forma clara e muito complexas para serem descritas por um modelo matemático (HUANG, LAI e NAKAMORI, 2007).

As redes neurais artificiais (RNA) são um candidato viável a vários modelos tradicionais de séries temporais. Esta abordagem apresenta algumas vantagens em relação a outros modelos lineares e não lineares que a tornam atraente na modelagem em finanças. Em primeiro lugar, a RNA possui capacidade flexível de mapeamento de funções não-lineares que pode aproximar qualquer função mensurável contínua com precisão arbitrariamente desejada (PANDA e NARASIMHAN, 2007; YU, WANG e LAI, 2010), enquanto a maioria dos modelos de séries temporais não lineares comumente usados não tem essa propriedade. Em segundo lugar, sendo modelo não paramétrico e orientado a dados, a RNA impõe algumas suposições sobre o processo subjacente do qual os dados são gerados. Devido a essa propriedade, é menos suscetível ao problema de especificação indevida do modelo do que a maioria dos métodos não lineares paramétricos. Esta é uma vantagem importante, uma vez que a taxa de câmbio não

exibe um padrão não linear específico (PANDA e NARASIMHAN, 2007; YU, WANG e LAI, 2010). Em terceiro lugar, a rede neural é de natureza adaptativa. A adaptabilidade implica que os recursos de generalização da rede permanecem precisos e robustos em um ambiente não-estacionário cujas características podem mudar com o tempo (PANDA e NARASIMHAN, 2007; YU, WANG e LAI, 2010). Quarto, o modelo de rede neural usa apenas linearmente muitos parâmetros, enquanto as expansões tradicionais de polinômios, *splines* e trigonométricas usam muitos parâmetros não lineares para atingir a mesma taxa de aproximação (PANDA e NARASIMHAN, 2007), ou seja, as expansões tradicionais aumentam a complexidade dos modelos. Por fim, a abordagem de rede neural é capaz de lidar com interações não-lineares e multicolinearidade sem qualquer tratamento especial da variável e a seleção cuidadosa de entradas pode melhorar significativamente o desempenho da rede neural (ZHANG; HU,1998; CRONE e KOURENTZES, 2010).

As redes neurais *feedforward* e recorrente são empregadas há muito tempo para fins de previsão de taxa de câmbio (KUAN; LIU, 1995; HANN; STEURER, 1996; LISI; SCHIAVO, 1999; LEUNG; CHEN; DAOUK, 2000; ZHANG, 2003; KHASHEI; BIJARI; ARDALI, 2013; GALESHCHUK, 2016). Entretanto, os resultados mostram que estes modelos possuem significativa capacidade de *timing* de mercado e, algumas vezes, apresentam RMSE significativamente menor do que o modelo de passeio aleatório. No entanto, não apresentam um desempenho sistematicamente melhor em todos os estudos avaliados. A maioria dos estudos utiliza a taxa de câmbio defasada como variável explicativa (entradas).

Contudo, o uso da taxa de câmbio defasada encontra algumas dificuldades em sua operacionalização, entre as quais se pode destacar, a definição do número ideal de defasagens, ou seja, quantos períodos anteriores devem ser considerados; eventos atuais podem influenciar, modificar ou mesmo, anular a relevância destes períodos anteriores; existe uma dinâmica subjetiva a cada moeda trabalhada o que impede uma simples generalização do modelo.

1.2. Estrutura da Tese

Em acordo à contextualização apresentada, o Capítulo 2, “Análise Bibliométrica e Revisão de Literatura” objetiva identificar o atual *status* da produção científica na área de previsão de câmbio em redes neurais, discriminando sua tendência de crescimento, a participação proporcional por país, as fontes de publicação, o nível de produtividade dos autores, os artigos mais influentes e as oportunidades para a realização de pesquisas futuras. A

metodologia de revisão de literatura combinada com análise bibliométrica é utilizada para avaliar de modo abrangente as pesquisas sobre previsão de taxa de câmbio e os modelos de rede neural.

Considerando os dados colhidos e os resultados apurados, o Capítulo 3, “previsão de taxa de câmbio com redes neural recorrente LSTM e Indicadores Técnicos”, tem como propósito estudar a capacidade preditiva do modelo de rede neural recorrente LSTM na previsão de taxa de câmbio utilizando os indicadores técnicos (preços de abertura, fechamento, máximo e mínimo) como variável de entrada (explicativa). Para a seleção de modelos, é aplicado o Model Confidence Set (MCS) de Hansen, Lunde e Nason (2002,2011). Devido às críticas ao uso de métricas estatísticas baseadas na magnitude do erro de previsão, adicionalmente, é verificada a capacidade preditiva do modelo em termos de precisão da direção.

Finalmente, apresenta-se as conclusões gerais do estudo fundamentadas em toda a pesquisa realizada conforme as metodologias definidas e aplicadas.

2. ANÁLISE BIBLIOMÉTRICA E REVISÃO DE LITERATURA

2.1. Contextualização

Após mais de três décadas desde a publicação do artigo seminal de Meese e Rogoff (1983) a respeito da previsibilidade das taxas de câmbio, o objetivo de explorar modelos de previsão de taxas de câmbio capazes de superar as previsões de passeio aleatório, ainda permanece inalcançado, uma vez que, evidências que apoiam ou refutam a previsibilidade da taxa de câmbio parecem plausíveis.

Em virtude da importância prática e teórica dos modelos de previsão da taxa de câmbio, inúmeros métodos e técnicas, tanto lineares como não lineares, foram introduzidos para prevalecer sobre o modelo de passeio aleatório no mercado de câmbio e, considerando o crescente desenvolvimento tecnológico, espera-se que estes modelos de previsão sejam mais eficientes. Efetivamente, nas últimas décadas, instrumentos de inteligência artificial (algoritmos) alcançaram um sucesso notável em várias áreas, incluindo reconhecimento de imagem e fala, processamento de linguagem natural, veículos autônomos e jogos (MAKRIDAKIS, 2017; SMYL, 2020). Tal sucesso se deve ao fato de os algoritmos conseguirem aprender a identificar padrões não lineares complexos e a explorar relacionamentos não estruturados, partindo de um conjunto representativo de dados. Estes algoritmos não são limitados por suposições ou processos de geração de dados predefinidos, o que permite que os dados falem por si (SMYL, 2020). Entretanto, a maior parte dos algoritmos tradicionais não são adequados para a previsão de séries temporais, por não levar em consideração a dimensão temporal dos dados (SMYL, 2020). Ao contrário de muitos métodos de previsão, as redes neurais são auto adaptativas, baseadas em dados e com poucas suposições restritivas para problemas em estudo, característica desejável quando o mecanismo de geração dos dados é desconhecido (QI; ZHANG, 2001; YU; WANG; LAI, 2007). Adicionalmente, as redes neurais artificiais são aproximadores funcionais universais (HORNIK; STINCHCOMBE; WHITE, 1989; YU; WANG; LAI, 2007), constituindo uma classe de modelo não linear (ZHANG; PATUWO; HU, 1998; YU; WANG; LAI, 2007).

Estudos de revisão acerca das pesquisas desenvolvidas sobre modelos de redes neurais, apresentam diferentes abordagens, tais como: aplicabilidade de modelos na área de negócios (TKAC; VERNER, 2016), comparabilidade de desempenho entre diferentes modelos (PRADEEPKUMAR; RAVI, 2018; PANDEY; JAGADEV; DEHURI; CHO, 2018) e

aplicabilidade dos modelos de aprendizagem profunda na previsão de séries temporais financeiras (SEZER et al., 2020). Apesar destas diferentes abordagens, os referidos estudos não avaliam especificamente previsões sobre a taxa de câmbio com redes neurais. É esta a lacuna que este artigo propõe preencher na literatura. Desta forma, para a compreensão adequada dos diferentes aspectos que envolvem a previsão de taxa de câmbio com modelos de rede neural, este estudo pretende identificar o atual *status* de produção científica na área, sobretudo quanto aos diversos aspectos relacionados como: tendência de crescimento, produção científica por país, fontes de publicação, produtividade dos autores, bem como organizar, integrar e avaliar os artigos influentes e indicar oportunidades para pesquisas futuras. Espera-se, portanto, que o presente estudo contribua efetivamente para referendar as próximas pesquisas nesta área de interesse.

Neste sentido, foram selecionados na base de dados Scopus em 30 de abr./2020, 245 artigos relacionados à previsão de taxa de câmbio com redes neurais. Neste estudo adota-se uma metodologia de revisão de literatura (TRANFIELD; DENYER; SMART, 2003; XU *et al.*, 2018) combinada com análise bibliométrica (ARIA; CUCCURULLO, 2017) para uma avaliação abrangente das pesquisas sobre previsão de taxa de câmbio e os modelos de rede neural. O fator de impacto dos artigos (HOMRICH *et al.*, 2018) é usado como proxy para a identificação dos estudos mais influentes.

Ao longo dos últimos 27 anos de pesquisas desenvolvidas acerca da previsão de taxa de câmbio com redes neurais, esta área oferece oportunidades de pesquisa ativa, com aumento de 32% no volume de publicações, observado no último triênio (2017-2019). No ranking destas publicações, a Índia tem se mantido na vanguarda das pesquisas. Observa-se, adicionalmente, que a maior parte dos canais de publicação é representada por periódicos do segmento da computação, o que acaba por resultar na aplicabilidade de algoritmos nesta área de interesse. Logo, o enfoque no segmento financeiro e econômico ainda é incipiente.

Os artigos influentes podem ser categorizados em: aqueles que objetivam estabelecer procedimentos sistemáticos de configuração das redes neurais; outros que comparam o desempenho da previsão entre modelos. Em relação aos últimos, é indispensável que nos procedimentos de comparação sejam utilizados os modelos ingênuos, como o RW. Entretanto, alguns estudos não realizam esta comparação. Tão importante quanto realizar esta comparação, é estabelecer um modelo de referência em redes neurais a ser superado.

Este capítulo está subdividido nas seguintes seções: introdução ao tema e à área de interesse; seção 2.2, apresentação dos procedimentos metodológicos utilizados e a análise descritiva dos dados; seção 2.3, apresentação da análise bibliométrica relativa aos estudos

selecionados; seção 2.4, apresentação a revisão e a discussão dos estudos selecionados; conclusões parciais.

2.2. Procedimentos metodológicos e análise descritiva dos dados

Neste estudo, adota-se uma metodologia de revisão de literatura combinada com a análise bibliométrica. A revisão da literatura objetiva mapeá-la e avaliá-la, identificando possíveis lacunas de pesquisa, ampliando as fronteiras atuais do conhecimento nesta área (TRANFIELD; DENYER; SMART, 2003; XU *et al.*, 2018). As revisões estruturadas da literatura são realizadas por meio da identificação de palavras-chave e termos de pesquisa apropriadas, além do seu levantamento e análise (SAUNDERS; LEWIS; THORNHILL, 2016; XU *et al.*, 2018). A análise bibliométrica, por sua vez, oferece estatísticas adicionais dos dados, incluindo autor, afiliação e palavras-chave (XU *et al.*, 2018).

A base de dados *Scopus*, devido a sua grande aceitabilidade no meio científico e por conter os metadados adequados para a pesquisa bibliométrica, foi utilizada para identificar a literatura mais relevante acerca da previsão de taxa de câmbio e redes neurais. A seleção dos artigos foi realizada em 30 de abr.2020, utilizando-se as combinações dos termos (Tabela 2.1), na busca por título, resumo ou palavras-chave dos trabalhos pesquisados. Além disso, o fator de impacto do *Journal Citation Reports (JCR)* é adotado para fins de revisão do periódico.

Tabela 2.1 - Termos utilizados na busca das publicações

Subtópico	**Termos de busca**
Taxa de câmbio	FOREX, foreign exchange, foreign-exchange, currency exchange, exchange rate(s) ou exchange-rate.
Previsão	Forecast ou predict.
Rede neural artificial	neural network(s), neural-network(s), deep learn(ing) network(s), long short term memory, long short-term memory, recurrent neural network(s), multilayer perceptron, multi-layer perceptron ou gated recurrent unit.

Fonte: Elaborado pela autora.

A pesquisa inicial resultou no conjunto de 783 documentos, contendo artigos, *working papers*, livros, entre outros. Deste total, foram selecionados os artigos publicados em inglês,

inclusive de revisão, que tratam a previsão da taxa de câmbio com redes neurais. Consequentemente, foram selecionados 387 artigos para este trabalho bibliométrico. Os títulos e resumos foram analisados. Os artigos foram excluídos quando: 1) se concentraram principalmente na previsão de taxa de câmbio, mas não nos modelos de redes neurais; ou 2) se concentraram principalmente no modelo de rede neural, mas não na previsão de taxa de câmbio. Assim, 245 artigos foram selecionados. Uma descrição desta base de dados de artigos selecionados é apresentada na Tabela 2.2.

Tabela 2.2 - Principais informações sobre dados

Descrição	**Resultado**
Número de artigos	245
Número de periódicos	156
Número de palavras-chave plus (ID)	907
Número de palavras-chave do autor (DE)	567
Período	1993 – 2020
Média de citações por artigo	21.7
Número de Autores	506
Nº Autores de artigos de autoria única	27
Nº Autores de artigos de múltipla autoria	479
Nº de artigos de autoria única	30
Nº de artigos por autor	0.5
Nº de autores por artigo	2.1
Nº de Coautores por artigo	2.6
Índice de Colaboração	2.2

Fonte: Elaborado pela autora.

2.3. Análise bibliométrica

O *status* atual de produtividade é subdividido nos seguintes componentes: tendência de crescimento da produção científica, produção científica por país, fontes de publicação, produtividade dos autores e artigos influentes. Estes componentes são analisados a seguir.

2.3.1. Tendência de Crescimento da Produção Científica

No que diz respeito à tendência de crescimento da produção científica a respeito da previsão de taxa de câmbio com redes neurais, a Tabela 2.3 mostra que os estudos têm início em 1993.

A Figura 2.1 permite visualizar e compreender os dados contidos e ordenados na Tabela 2.3, com a evolução temporal da pesquisa sobre o tópico relacionado. Assim, as barras no eixo horizontal, ordenadas da maior para a menor ocorrência, representam os atributos de interesse, a saber, o número de publicações por quinquênio. A linha percentual cumulativa ajuda a avaliar a contribuição adicional de cada categoria. Considerando os estudos disponíveis na base de dados Scopus, é perceptível que: as primeiras publicações ocorrem no quinquênio 1991-1995; ocorre um aumento no número de publicações no período de 1996-2000, seguido de um enfraquecimento no período seguinte, de 2001-2005; o interesse pelo tema é retomado com um novo crescimento no volume de publicações entre 2006 até abril/2020.

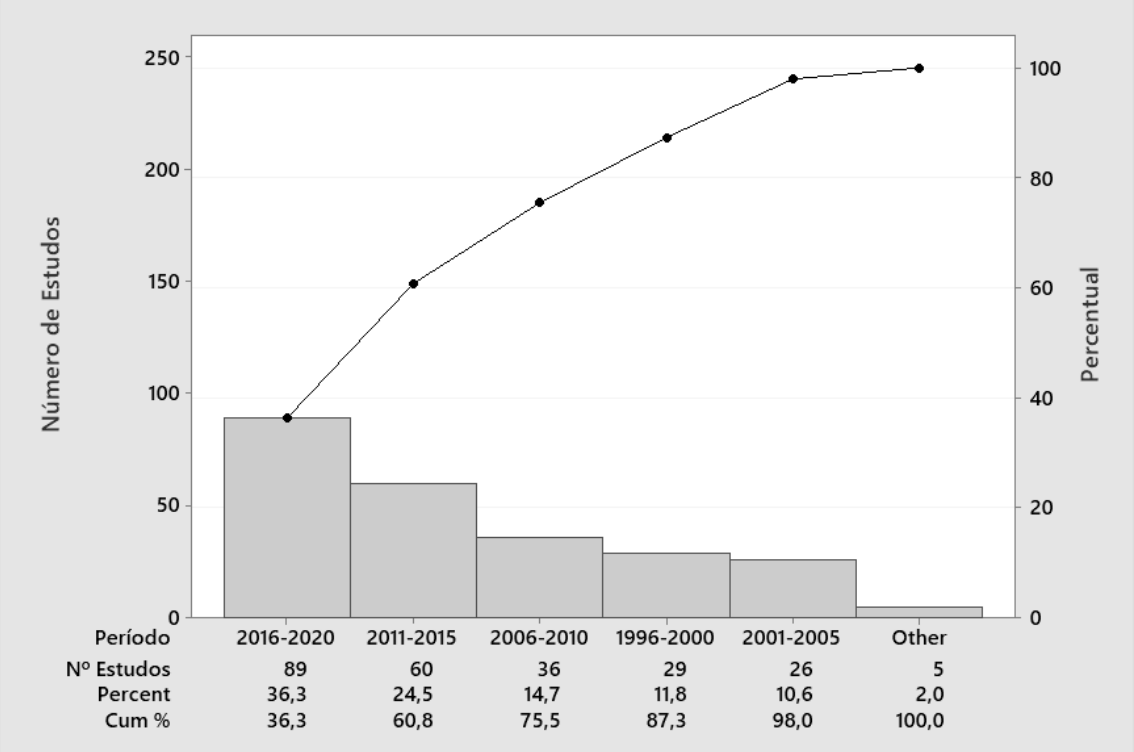
Tabela 2.3 - Produção Científica Anual

Ano	Número de estudos	%	% Cumulativo	Ano	Número de estudos	%	% Cumulativo
1993	1	0.408	0.408	2007	9	3.673	29.388
1994	2	0.816	1.224	2008	8	3.265	32.653
1995	2	0.816	2.041	2009	10	4.082	36.735
1996	7	2.857	4.898	2010	6	2.449	39.184
1997	5	2.041	6.939	2011	9	3.673	42.857
1998	8	3.265	10.204	2012	13	5.306	48.163
1999	4	1.633	11.837	2013	12	4.898	53.061
2000	5	2.041	13.878	2014	12	4.898	57.959
2001	6	2.449	16.327	2015	14	5.714	63.673
2002	5	2.041	18.367	2016	19	7.755	71.429
2003	4	1.633	20.000	2017	13	5.306	76.735
2004	4	1.633	21.633	2018	11	4.490	81.224
2005	7	2.857	24.490	2019	32	13.061	94.286
2006	3	1.224	25.714	2020(1)	14	5.714	100.000

Nota: (1) Artigos publicados até abril/2020.

Fonte: Elaborado pela autora.

Figura 2.1 - Gráfico de Pareto - Produção Científica 1990-2019



Nota: (1) Artigos publicados até abril/2020.

Fonte: Elaborado pela autora.

Neste período, diversos eventos econômicos impulsionam os estudos acerca do tema: Crise do México nos anos de 1994 e 1995; Crise dos Tigres Asiáticos em 1997; Crise Imobiliária dos EUA, denominada *Subprime* entre 2007 e 2009; Crise da Grécia em 2010; Processo de saída do Reino Unido da União Europeia, denominado *Brexit*, iniciado em 2016.

2.3.2. Produção Científica por país

Baseado nas estatísticas de produção científica por país (Tabela 2.4), a Índia ocupa a liderança, respondendo por 16,7% do total de artigos produzidos, seguidos pelo Reino Unido (15,1%), China (14,7%) e EUA (14,2%).

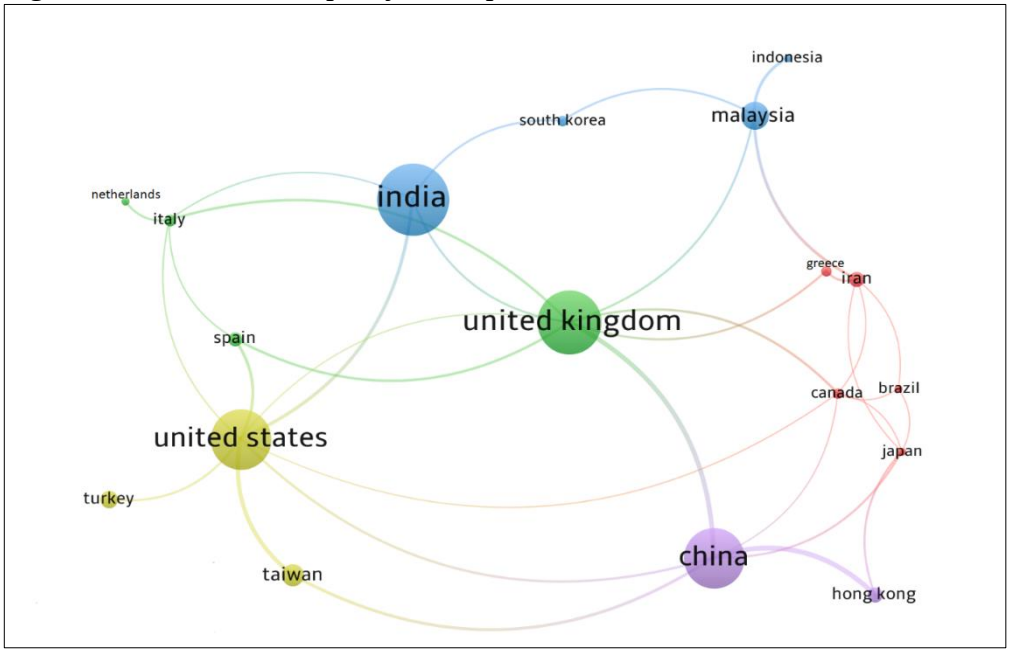
Tabela 2.4 - Países com maior produção científica

País	Nº de publicações	País	Nº de publicações
INDIA	41	SPAIN	8
UNITED KINGDOM	37	ITALY	7
CHINA	36	CANADA	6
UNITED STATES	35	GREECE	6
MALAYSIA	16	SOUTH KOREA	6
TAIWAN	13	BRAZIL	5
TURKEY	10	INDONESIA	5
HONG KONG	9	NETHERLANDS	5
IRAN	9	JAPAN	5

Fonte: Elaborado pela autora.

A Figura 2.2 apresenta as relações que formam uma rede de coautoria entre diferentes países, quanto às pesquisas de taxa de câmbio com redes neurais. Esta rede é composta por cinco grupos de países; o primeiro agrupa a Índia, Indonésia, Malásia e Korea do Sul. O segundo *cluster* agrupa Estados Unidos, Taiwan e Turquia; o terceiro, Reino Unido, Espanha, Itália e Holanda; o quarto, China e Hong Kong; e o quinto, Iran, Canada, Grécia, Japão e Brasil. Na elaboração da figura utiliza-se o *software* VosViewer versão 1.6.13 (VAN ECK; WALTMAN, 2019).

Figura 2.2 - Rede de Cooperação dos países



Fonte: Elaborado pela autora.

Nota: Esta rede foi elaborada com critérios de limite de pelo menos cinco artigos em coautoria pelo software *VosViewer*, usando informações do banco de dados secundário, formado a partir do banco de dados primário da Scopus. O tamanho dos símbolos corresponde ao número de publicações e a cor, ao número de ocorrências de coautoria nas publicações.

2.3.3. Fontes de publicação

Com relação aos periódicos onde os artigos são publicados, suas respectivas áreas de conhecimento e aplicação estão assim distribuídas: Ciência da Computação (33,0%), Economia, Econometria e Finanças (12,8%), Matemática (12,1%), Engenharia (11,2%), Negócios, Gestão e Contabilidade (9,7%), Neurociência (5,5%) e Outras (15,7%).

Um aspecto comumente analisado em um estudo bibliométrico, refere-se à proporção entre os artigos e os periódicos onde são publicados. Observa-se na tabela 2.5 que, do total de 245 estudos e 156 periódicos, 73,7% publicam apenas um estudo e 18,6%, dois estudos; enquanto os dois mais produtivos, contribuem com 14 e 11 artigos. Em conformidade com a lei de dispersão de periódicos de Bradford (1934), é possível observar que poucos periódicos publicam mais artigos voltados para este tema, e muitos periódicos publicam poucos artigos.

Tabela 2.5 – Produtividade dos periódicos

Número de Estudos	Número de periódicos	Proporção de periódicos
1	115	0.737
2	29	0.186
3	3	0.019
4	3	0.019
5	1	0.006
7	3	0.019
11	1	0.006
14	1	0.006

Fonte: Elaborado pela autora.

Tabela 2.5 – Os 10 periódicos mais produtivos

Periódicos	Nº de estudos	Acum.	%Acum.
Neurocomputing	14	14	5.7
Expert Systems with Applications	11	25	10.2
Applied Soft Computing Journal	7	32	13.1
Journal of Forecasting	7	39	15.9
Neural Computing and Applications	7	46	18.8
Neural Neural Network World	5	51	20.8
Computational Economics	4	55	22.4
Computers and Operations Research	4	59	24.1
Intelligent Systems in Accounting, Finance and Management	4	63	25.7
International Journal of Electronic Finance	3	66	26.9

Fonte: Elaborado pela autora.

A Tabela 2.6 apresenta, os 10 periódicos mais produtivos na área de previsão de taxa de câmbio com os modelos de redes neurais. Desta forma, os periódicos mais produtivos são: *Neurocomputing* (14 artigos) e *Expert Systems with Applications* (11 artigos). Observa-se também que os 10 periódicos mais produtivos são responsáveis por 26.9% das publicações sobre previsão de câmbio com redes neurais.

2.3.4. Produtividade dos Autores

A Tabela 2.7 trata da produtividade dos autores na área de previsão de taxa de câmbio com os modelos de redes neurais, relacionando o número de estudos publicados ao número de autores e a proporção resultante. Existe um total de 245 estudos e 506 autores. Observa-se que destes autores, 84,6% publicam apenas um estudo, enquanto os mais produtivos, contribuem com oito artigos. Em conformidade com a Lei de Lotka, observa-se que a maioria dos autores possui baixa produtividade e a minoria, alta produtividade.

Tabela 2.6 - Produtividade dos Autores

Número de Estudos	Número de autores	Proporção de autores
1	428	0.846
2	53	0.105
3	15	0.030
4	3	0.006
5	2	0.004
6	2	0.004
7	1	0.002
8	2	0.004

Fonte: Elaborado pela autora.

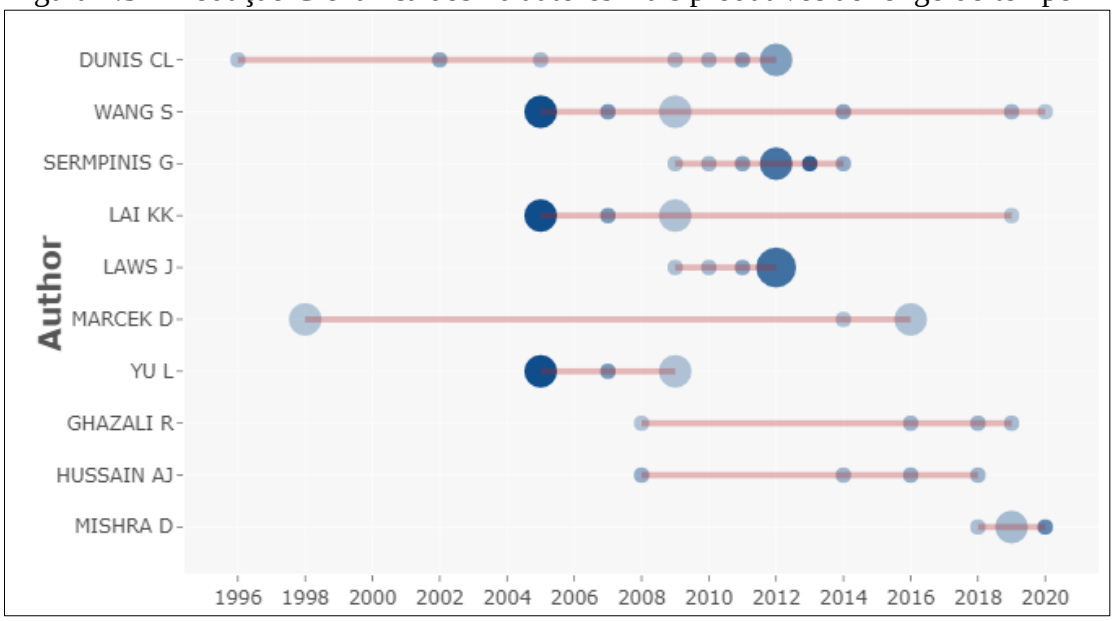
A Tabela 2.8 apresenta nominalmente, os 10 autores mais produtivos na área de previsão de taxa de câmbio com os modelos de redes neurais, ressaltando que todos eles desenvolvem estudos com outros autores. Decorrente desta iniciativa, estes autores tornam-se influenciadores no assunto (BERGH; PERRY; HANKE, 2006; CUCCURULLO; ARIA; SARTO, 2016), determinando as direções futuras de pesquisa. Desta forma, os autores mais produtivos são: Dunis, C.L.; 8 artigos e índice de artigo fracionado de 3.4; Wang, S., 8 artigos e índice fracionado de 2.5; Sermpinis, G., 7 artigos e índice fracionado de 2.0; e Marcek, D., 5 artigos e índice fracionado de 3.3.

Tabela 2.7 - Os 10 Autores mais produtivos

Nº	Autores	Nº Artigos	Autores	Nº Artigos Fracionados
1	Dunis, C.L.	8	Dunis, C.L.	3.4
3	Wang, S.	8	Marcek, D.	3.3
2	Sermpinis, G.	7	Galeshchuk, S.	2.5
4	Lai, K.K.	6	Wang, S.	2.5
5	Laws, J.	6	Sermpinis, G.	2.0
6	Marcek, D.	5	Lahmiri, S.	2.0
7	Yu, L.	5	Laws, J.	1.8
8	Ghazali, R.	4	Lai, K.K.	1.8
9	Hussain, A.J.	4	Dash, R.	1.7
10	Mishra, D.	4	Mishra, D.	1.7

Fonte: Elaborado pela autora.

Figura 2.3 - Produção Científica dos 10 autores mais produtivos ao longo do tempo



Fonte: Elaborado pela autora.

Nota: A intensidade da cor é proporcional à citação total por ano. A linha representa uma linha do tempo dos autores. O tamanho do círculo é proporcional ao número de documentos.

A Figura 2.3 apresenta em perspectiva temporal, o nível de produtividade dos 10 maiores autores na área de estudos da previsão de taxa de câmbio com os modelos de redes neurais.

2.3.5. Estudos mais influentes

Nas diversas áreas de conhecimento e estudo científico, algumas publicações assumem papéis seminais, sendo determinantes para a evolução e aceleração do respectivo campo de estudo, influenciando e inspirando os demais autores (BERRY; PARASURAMAN, 1993; CUCCURULLO; ARIA; SARTO, 2016). Desta forma, para melhor compreender o *status* atual do entendimento sobre a previsão de taxa de câmbio com redes neurais, torna-se indispensável identificar quais artigos publicados entre 1993 e abr./2020, são os mais influentes, e qual é a relação estabelecida entre os autores e os estudos.

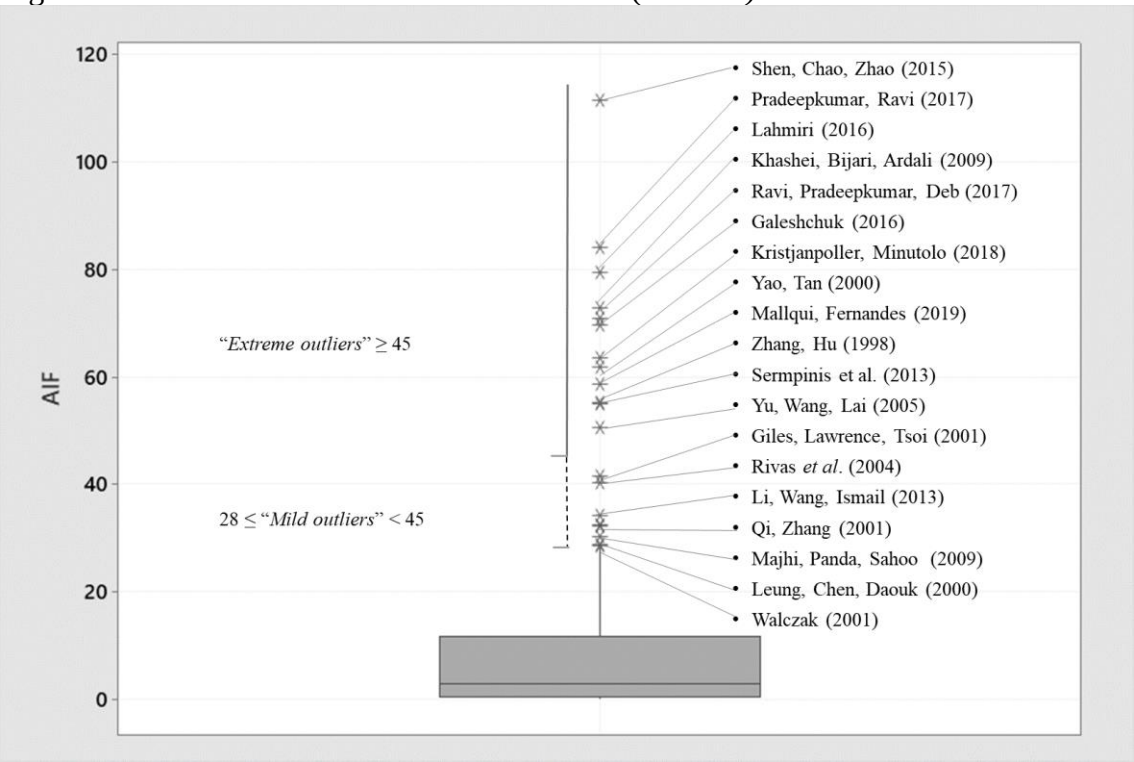
Os documentos centrais são identificados a partir da análise de citações e co-citações, como uma técnica quantitativa aplicada para capturar o nível de influência de um autor ou de um artigo (GARFIELD; MERTON, 1979; HOMRICH *et al.*, 2018). Entretanto, esta avaliação deve também considerar o impacto do periódico, bem como o número de citações (citação total ou média anual), o que pode influenciar e definir a posição de um artigo no ranking de citações (CARVALHO, FLEURY, LOPES, 2013; HOMRICH et al., 2018).

A Equação 2.1, fator de impacto do artigo (*article impact fator* – AIF), conduz à análise adicional para definir os artigos mais influentes pelo critério de número de citação anual e a relevância do periódico (*Journal Citation Reports - Impact factor* – JCR/IF). O fator de impacto e as citações variam ao longo do tempo e por este motivo, o resultado obtido utilizando-se a citação média anual, é menos sensível a estas variações do que aquele obtido pelas citações totais (HOMRICH *et al.*, 2018).

$$\text{AIF} = \text{citação média anual} * (1 + \text{JCR/IF}) \tag{2.1}$$

A Figura 2.4 apresenta os artigos mais influentes, medidos pelo indicador AIF, em um gráfico *boxplot*. Os valores de citação identificados representam trabalhos cujos índices de impacto são *outliers* extremos, ou seja, AIF maior ou igual a 45. Evidencia também os valores extremos médios, cujos AIF varia entre 28 e 45. Diante do fator de impacto do periódico *Applied Soft Computing*, por exemplo, o artigo de Pradeepkumar e Ravi (2017), a previsão da volatilidade de séries temporais financeiras usando a regressão quantílica de rede neural treinada pela otimização de enxame de partículas, torna-se o segundo no ranking AIF, ao invés da quarta posição em relação à citação média anual e 32º no ranking citação total.

Figura 2.4 - Gráficos de Estudos mais Influentes (*Outliers)*



Fonte: Elaborado pela autora.

A Tabela 2.9 destaca os principais artigos, considerando-se o fator de impacto combinado como *proxy* de relevância das pesquisas sobre previsão de câmbio com redes neurais, enfatizando seus temas de pesquisa e periódicos.

Tabela 2.8 - Artigos mais citados por AIF

Autores	Título do artigo	Periódico	Citação média anual	JCR/IF	AIF
Shen, Chao, Zhao (2015)	Forecasting exchange rate using deep belief networks and conjugate gradient method	Neurocomputing	22.0	4.072	111.6
Pradeepkumar, Ravi (2017)	Forecasting financial time series volatility using Particle Swarm Optimization Trained Quantile Regression Neural Network	Applied Soft Computing	14.3	4.873	84.2
Lahmiri (2016)	A variational mode decomposition approach for analysis and forecasting of economic and financial time series	Expert Systems with Applications	15.0	4.292	79.4
Khashei, Bijari, Ardali (2009)	Improvement of Auto-Regressive Integrated Moving Average models using Fuzzy logic and Artificial Neural Networks (ANNs)	Neurocomputing	14.4	4.072	72.9
Ravi, Pradeepkumar, Deb (2017)	Financial time series prediction using hybrids of chaos theory, multi-layer perceptron and multi-objective evolutionary algorithms	Swarm and Evolutionary Computation	9.7	6.330	70.9
Galeshchuk (2016)	Neural networks performance in exchange rate prediction	Neurocomputing	13.8	4.072	69.7
Kristjanpoller, Minutolo (2018)	A hybrid volatility forecasting framework integrating GARCH, artificial neural network, technical analysis and principal components analysis	Expert Systems with Applications	12.0	4.292	63.5
Yao, Tan (2000)	A case study on using neural networks to perform technical forecasting of forex	Neurocomputing	12.2	4.072	61.9
Mallqui, Fernandes (2019)	Predicting the direction, maximum, minimum and closing prices of daily Bitcoin exchange rate using machine learning techniques	Applied Soft Computing Journal	10.0	4.9	58.7
Zhang, Hu (1998)	Neural network forecasting of the British pound/US dollar exchange rate	Omega	8.7	5.341	55.3
Sermpinis *et al.* (2013)	Forecasting foreign exchange rates with adaptive neural networks using radial-basis functions and Particle Swarm Optimization	European Journal of Operational Research	11.4	3.806	54.9
Yu, Wang, Lai (2005)	A novel nonlinear ensemble forecasting model incorporating GLAR and ANN for foreign exchange rates	Computers & Operations Research	12.7	3.002	50.7
Giles, Lawrence, Tsoi (2001)	Noisy time series prediction using recurrent neural networks and grammatical inference	Machine Learning	10.9	2.809	41.5
Rivas *et al.* (2004)	Evolving RBF neural networks for time-series forecasting with EvRBF	Information Sciences	6.2	5.524	40.4
Li, Wang, Ismail (2013)	Fuzzy neural network technique for system state forecasting	IEEE Transactions on Cybernetics	3.0	10.387	34.2
Qi, Zhang (2001)	An investigation of model selection criteria for neural network time series forecasting	European Journal of Operational Research	6.7	3.806	32.4
Majhi, Panda, Sahoo (2009)	Efficient prediction of exchange rates with low complexity artificial neural network models	Expert Systems with Applications	6.1	4.292	32.2
Leung, Chen, Daouk (2000)	Forecasting exchange rates using general regression neural networks	Computers & Operations Research	7.6	3.002	30.2
Walczak (2001)	An empirical analysis of data requirements for financial forecasting with neural networks	Journal of Management Information Systems	7.2	3.013	28.7

Fonte: Elaborado pela autora.

2.4. Revisão da literatura selecionada

A partir da análise dos estudos mais influentes selecionados (Tabela 2.9), procede-se à sua divisão em dois grupos. O primeiro, estuda os problemas relacionados à especificação dos modelos, como por exemplo: a definição das variáveis explicativas, a quantidade de camadas ocultas e neurônios, o tamanho das amostras (treinamento, validação e teste), bem como, a questão do ajuste excessivo do modelo aos dados (*overfitting*). O segundo, compara a capacidade de previsão dos modelos de redes neurais aos diversos modelos concorrentes.

2.4.1. Especificação da estrutura do modelo

A resolução de problemas que envolvam a previsão de séries temporais tem sido bem-sucedida com a utilização de modelos de redes neurais. Entretanto, torna-se uma tarefa de maior complexidade, selecionar a arquitetura de rede neural apropriada para um problema de previsão de taxa de câmbio, quando se considera a quantidade de parâmetros a serem estimados empiricamente.

O primeiro desafio é determinar as variáveis explicativas (entradas). Para tanto, dois tipos de análises têm sido utilizados na previsão da taxa de câmbio com redes neurais: fundamental e técnica. A análise fundamental considera os dados econômicos (taxas de juros, volumes de importação/exportação, PIB, reservas de moedas, índices de inflação, entre outros) como representantes das variáveis explicativas ou entradas na rede neural (ABU-MOSTAFA; ATIYA, 1996). A análise técnica, por sua vez, baseia-se na análise de padrões dos valores passados da própria série temporal, volumes de negociação, quantidade de contratos futuros em aberto, volatilidade, entre outros (ABU-MOSTAFA; ATIYA, 1996). Por esta ótica, dados econômicos e quaisquer outros fatos noticiados no ambiente econômico são desconsiderados, por serem empregados de forma indireta, uma vez que seriam refletidos no padrão de preços passados. Assim, o padrão recente de preços, em certa medida, poderá determinar a direção futura dos preços (HUANG *et al.*, 2004). Uma provável causa da inconsistência de resultados relatados na literatura poderia recair sobre a incapacidade preditiva da variável utilizada.

A análise univariada de séries temporais depende da capacidade preditiva da própria série temporal, correspondendo a uma análise técnica ao invés de análise fundamental. Para um problema univariado de previsão de séries temporais, os nós de entrada na rede neural correspondem às observações passadas da própria série, enquanto a saída, ao seu valor futuro. Cada padrão de entrada é composto por uma janela móvel de comprimento fixo ao longo da

série. Neste contexto, a principal dificuldade é determinar o comprimento desta janela, ou seja, o número de defasagens a serem incluídas no modelo (HUANG *et al*., 2004).

Três fatores são determinantes na modelagem e desempenho em uma rede neural univariada: (a) o número de nós de entrada; (b) a quantidade de camadas ocultas e neurônios e (c) o tamanho das amostras (treinamento, validação e teste). O número de nós de entrada apresenta maior influência sobre o desempenho do modelo do que o número de camadas ocultas (ZHANG; HU, 1998; HUANG *et al*.; 2004), desempenho da rede neural se mostra insensível com relação ao número de neurônios (ZHANG; HU, 1998) e um número maior de observações reduz os erros de previsão (ZHANG, HU; 1998). É desejável reduzir o número de nós de entrada para um mínimo absoluto de nós essenciais (HUANG *et al*.; 2004). Assim, outra explicação provável para a inconsistência nos resultados relatados na literatura seria a falta de abordagens sistemáticas para a construção de modelos de redes neurais (HUANG *et al*.; 2004).

As redes neurais superam os modelos lineares, particularmente quando o horizonte de previsão é curto (ZHANG; HU, 1998; GALESHCHUK, 2016), mas não para horizontes de previsão mais longos, sugerindo possíveis mudanças na estrutura dos dados de taxa de câmbio (ZHANG; HU, 1998). Portanto, à medida que mais observações estiverem disponíveis, elas devem ser adicionadas para revisar o modelo de rede neural para melhor refletir a mudança dos padrões subjacentes (ZHANG; HU, 1998). Entretanto, embora exista a heurística de que a quantidade de observações é diretamente proporcional à qualidade da previsão, ao examinar o efeito qualitativo do tamanho do conjunto de treinamento nos modelos de previsão de taxa de câmbio da rede neural, Walczak (2001) demonstra que para a maioria das previsões de taxas de câmbio, o máximo de dois anos de dados de treinamento (frequência diária) produzem melhor desempenho do modelo de previsão de redes neurais. O tamanho do conjunto de dados de treinamento menores que o esperado, que produzem o desempenho ideal de previsão da rede neural, levam à indução do efeito de recência de séries temporais (*Time Series Recency Effect*). Neste efeito, a construção de modelos com dados mais próximos no tempo daqueles a serem previstos, resulta em projeções mais precisas (WALCZAK, 2001). Tal efeito refuta a heurística da necessidade do uso da maior quantidade de dados disponíveis na modelagem de séries temporais com redes neurais. Assim, seria possível modelar modelos de previsão com quantidades menores de dados (WALCZAK, 2001).

As redes neurais artificiais estão sujeitas ao problema de ajuste excessivo do modelo aos dados (*overfitting*), o que proporciona um excelente desempenho dentro da amostra, e, ao contrário, péssimo fora da amostra. Para amenizar este problema, duas abordagens são usadas (QI; ZHANG, 2001). A primeira, denominada validação cruzada, consiste em dividir os dados

em três partes: treinamento, validação e teste. As duas primeiras partes (treinamento e validação) são usadas para construir o modelo, e a última (teste), para a avaliação fora da amostra. O conjunto de treinamento é usado para a estimativa de parâmetros e a rede aprendida é avaliada com o conjunto de validação. A rede que apresenta o melhor desempenho no conjunto de validação é selecionada como o modelo final de previsão. A validade e a utilidade do modelo são verificadas usando o conjunto de testes. A segunda abordagem consiste no uso dos critérios de seleção de modelo da literatura convencional de séries temporais. Critérios baseados em informações, como Akaike (AIC) e o bayesiano (BIC), que penalizam modelos grandes, que geralmente tendem ao *overfitting*, são os critérios de seleção de modelo mais utilizados. Qi e Zhang (2001) investigam o potencial destes critérios de seleção, na modelagem de séries de tempo em redes neurais. Eles verificam que os referidos critérios de seleção, comumente utilizados dentro da amostra, não são capazes de identificar o melhor modelo de rede neural para a previsão fora da amostra.

Os analistas usam um procedimento de aprendizado para associar a direção do mercado a padrões de preços passados e outras informações técnicas e fundamentais, descobrindo os relacionamentos subjacentes (GILES, 2001). No entanto, devido à enorme quantidade de ruído e à variedade de padrões de preços, são necessárias técnicas para orientar o processo de aprendizado e para pré-processar adequadamente os dados (GILES, 2001), visto que o ruído destes dados enfraquece a capacidade preditiva do modelo (YU; WANG; LAI, 2007). Assim, são utilizadas técnicas de regularização como decaimento de peso (*weight decay*), eliminação de peso e parada antecipada (*early stopping*), para controlar o ajuste excessivo (WEIGEND *et al.*, 1992; GILES, 2001).

2.4.2. Modelos propostos pelos estudos selecionados

Para solucionar o problema de dissipação/explosão dos gradientes, Shen, Chao e Zhao (2015) propõem aprimorar o modelo clássico de rede neural de crenças profunda (DBN) usando máquinas de Boltzmann restritas contínuas e o método de gradiente conjugado para acelerar o aprendizado. Nestes experimentos, três séries de taxas de câmbio e uma série de retornos da taxa de câmbio em frequência semanal são testadas. Seis critérios de avaliação são adotados para avaliar o desempenho do método proposto. A comparação com métodos de previsão típicos, como a rede neural *feedforward*, demostra que a avaliação do método proposto supera

a dos métodos tradicionais, quando avaliados pelo coeficiente de correlação e pela precisão da direção. Porém, não é possível distinguir os melhores e piores modelos em todos os casos, quando são avaliados pelas medidas de erro (RMSE, MAE e MAPE).

Uma rede neural de função da base radial (*radial basis function neural network* – RBFNN) pode aproximar qualquer função contínua multivariada (LIGHT,1992). Desta forma, seus parâmetros (centros e os raios, os pesos dos elos entre as camadas oculta e de saída) podem ser calculados analiticamente com o uso de qualquer algoritmo que resolva equações algébricas lineares. Rivas *et al.* (2004) propõe determinar os parâmetros da RBFNN automaticamente, com o algoritmo evolutivo.

Nos últimos anos, pesquisadores têm estudado modelos híbridos que combinam redes neurais com outros modelos (CAVALCANTE et al., 2016). Tais modelos híbridos têm como objetivo melhorar o desempenho da previsão, combinando estrategicamente vários algoritmos (CAVALCANTE et al., 2016). Por exemplo, a fim de superar as limitações lineares e de dados do modelo ARIMA, Khashei, Bijari e Ardali (2009) integram os modelos ARIMA, Redes Neurais Artificiais e lógica Fuzzy. Yu, Wang, Lai (2005) propõe um modelo híbrido que combina os modelos GLAR de séries temporais e RNN para prever taxas de câmbio. Por sua vez, Lahmiri (2016) apresenta um modelo de previsão de séries temporais que integra a decomposição de modo variacional (*variational mode decomposition* – VMD) e rede neural de regressão geral (GRNN). Os resultados da análise das previsões demonstram a superioridade do modelo VMD-GRNN sobre os modelos concorrentes, em especial, para grandes conjuntos de dados e, em presença de ruídos.

Ainda com relação à especificação da estrutura, objetivando superar as dificuldades de ajuste dos parâmetros das redes neurais, Sermpinis *et al*. (2013) apresentam uma arquitetura de rede neural híbrida da optimização por enxame de partículas (*particle swarm optimization)* e função de base radial adaptativa (ARBF-PSO). A arquitetura proposta é adaptável, reduzindo o número de parâmetros a serem experimentados, aumentando a capacidade de previsão da rede e eliminando o risco da dissipação/explosão dos gradientes (SERMPINIS *et al.*, 2013). O desempenho de todos os modelos é investigado em uma simulação de previsão das séries temporais do BCE. O modelo proposto supera seus concorrentes em termos de precisão estatística e eficiência de negociação para todas as taxas de câmbio. De modo similar, Pradeepkumar e Ravi (2017) também usam a otimização por enxame de partículas (PSO), propondo, porém, um modelo integrado de Rede Neural de Regressão Quantílica (QRNN), denominado PSOQRNN, com o objetivo de prever a volatilidade a partir de séries temporais

financeiras. Os resultados indicam que o modelo proposto também supera os modelos concorrentes.

A otimização por enxame de partículas também é utilizada por Ravi, Pradeepkumar e Deb (2017) que, por sua vez, propõem um modelo híbrido de previsão de três estágios (Caos + MLP+ NSGA-II[1]). A eficácia do modelo proposto é testada em conjuntos de dados financeiros, incluindo os dados de taxas de câmbio. A partir dos resultados, conclui que o híbrido proposto apresenta melhores previsões em termos de erro quadrático médio (MSE), estatística de mudança direcional (Dstat) e o teste de Diebold-Mariano.

O mercado de criptomoedas oferece um novo campo de estudo de previsibilidade, por seu tamanho e a necessidade de compreensão de suas especificidades. Nesta perspectiva, Kristjanpoller e Minutolo (2018) oferecem um modelo híbrido RNA-GARCH com análise dos principais componentes para prever a volatilidade dos preços da bitcoin, considerando a série altamente volátil quando comparada às moedas tradicionais. Neste estudo, sete indicadores de análise técnica são introduzidos como variáveis para melhorar a previsão e todas as variáveis exógenas são derivadas da série de preços de fechamento da bitcoin. Mallqui e Fernandes (2019) analisam o comportamento das redes neurais artificiais (RNA), máquinas de vetores de suporte (SVM) e algoritmos conjuntos baseados em redes neurais recorrentes e no método k-Means. Assim, obtém previsões de direção, preços máximos, mínimos e de fechamento do Bitcoin. Os resultados mostraram que os atributos selecionados e o melhor modelo de aprendizado de máquina, obtiveram 62.9% de precisão nas previsões de direção de preços e erros percentuais absolutos médios, entre 1% e 2%.

Em estudos seminais, Reid (1968) e Bates e Granger (1969) demostram que uma combinação linear de previsões resultaria uma variação de erro menor que em qualquer um dos métodos individuais. No entanto, os modelos de previsão híbrida e os modelos de previsão combinados linearmente não são adequados em todas circunstâncias (YU, WANG, LAI, 2005). É necessário escolher um método apropriado para determinar o número de modelos individuais para combinar a previsão (YU, WANG, LAI, 2005). Em vista destas dificuldades, Yu, Wang e Lai (2005) propõem um modelo de previsão conjunto não linear, utilizando a rede neural artificial e a análise de componentes principais (PCA) para escolher o número de modelos de previsão individuais. O modelo proposto integra a auto regressão linear generalizada (GLAR) com redes neurais artificiais (RNA), a fim de obter resultados precisos, aprimorando o desempenho. Este desempenho do modelo proposto é comparado com os dois modelos de

[11] Algoritmo Genético de Classificação Não Dominado elitista (NSGA)

previsão individuais (GLAR e RNA), com o modelo híbrido e o com o modelo de combinação linear. Os resultados empíricos obtidos revelam que a previsão usando o modelo conjunto não linear é melhor do que aquelas obtidas usando os outros modelos apresentados neste estudo em termos das mesmas medidas de avaliação.

Para extrair informações de múltiplos conjuntos de dados e melhorar a precisão da previsão, Li, Wang e Ismail (2013) sugerem uma rede neural fuzzy (FNN) composto por: (1) nós autoregressivos (AR), utilizados para capturar a correlação linear dos conjuntos de dados; (2) nós não lineares que captam a correlação não linear dos conjuntos de dados. Adicionalmente, o método de enxame de partículas de Laplace (LPS) é usado para facilitar a estimativa de parâmetros. Os resultados dos testes demostram que o modelo FNN proposto e o método LPS podem capturar a dinâmica de múltiplos conjuntos de dados de forma eficaz. Por sua vez, Kodogiannis, Lolis (2002) realizam uma análise comparativa dos modelos baseados em redes neurais e sistemas fuzzy para uma previsão de um passo à frente da taxa de câmbio. Várias arquiteturas de rede neurais foram testadas (MLP, rede neural fuzzy, função de base radial e neuro-fuzzy). A introdução de algoritmos híbridos de aprendizado impõe uma nova dimensão na previsão da taxa de câmbio.

A rede neural artificial de link funcional (*functional link artificial neural network* - FLANN) apresenta uma entrada não linear e um único neurônio na saída. Essa rede é estruturalmente simples e envolve menos cálculos quando comparada ao modelo MLP (MAJHI, PANDA, SAHOO, 2009). Majhi, Panda, Sahoo (2009) indicam dois modelos de previsão baseados em redes neurais de baixa complexidade para a previsão de taxa de câmbio. O primeiro modelo é simples, com uma camada e um único neurônio, mas com recursos de entrada não linearmente mapeados. O segundo, consiste em rede neural artificial de link funcional em cadeia (CFLANN). A primeira saída passa por uma expansão não-linear e, em seguida, é enviada à segunda FLANN para prever a taxa de câmbio. O estudo de simulação de ambos os modelos revela que o modelo CFLANN apresenta o melhor desempenho.

Leung, Chen, Daouk (2000) estudam a previsibilidade de uma arquitetura de rede neural específica denominada rede neural de regressão geral (*general regression neural network* - GRNN) e comparam o seu desempenho com uma variedade de técnicas de previsão, incluindo rede *feedforward* de múltiplas camadas (MLFN), função de transferência multivariada e passeio aleatório (RW). A comparação com MLFN fornece uma medida do desempenho do GRNN em relação ao tipo mais convencional de redes neurais, enquanto a comparação com modelos de funções de transferência examina a diferença de força preditiva entre as técnicas não paramétricas e paramétricas. O modelo difícil de superar, o passeio aleatório (RW) é usado para

comparação de benchmark. Os resultados mostram que o GRNN possui maior grau de precisão de previsão, também apresentando um desempenho estatisticamente superior ao de outros modelos avaliados para diferentes moedas.

Em todos os estudos analisados, os modelos propostos são considerados mais precisos quando comparados aos seus modelos concorrentes. Entretanto, observada a Tabela 2.10, conclui-se que não existem argumentos suficientemente robustos que permitam considerar a superioridade de modelos mais complexos sobre o passeio aleatório, uma vez que em apenas duas oportunidades foram realizadas efetivas comparações. Outro aspecto de grande importância cuja discussão é oportuna consiste no fato de a maioria dos trabalhos, em seus modelos preferencialmente se ocuparem avaliar o desempenho da previsão usando medidas baseadas na magnitude do erro de precisão (RMSE, MSE, MAE, etc.) quando mais representativo seria determinar a o grau de precisão da direção.

Tabela 2.9 - Modelos propostos e seus concorrentes nos estudos selecionados

(Continua)

Autores	**Modelo Principal**	**Modelos Concorrentes**	**Moedas**	**Frequência**	**Medida de desempenho**
Shen, Chao, Zhao (2015)	Deep belief network (DBN)	RW, ARMA, FFNN.	GBP/USD, INR/USD e BRL/USD	Semanal	MAE, MAPE, RMSE, DA e CORR
Pradeepkumar, Ravi (2017)	Quantile Regression Neural Network (QRNN)	GARCH, MLP, GRNN, GMDH, RF, QRRF e QRNN	USD/JPY, USD/GBP, USD/EUR e USD/INR	Diária	MSE, D_{stat} e U de Theil
Lahmiri (2016)	General regression neural network (GRNN)	VMD-GRNN, EMD-GRNN, FFNN e ARMA	CAD/USD	Diária	MAE, MAPE e RMSE
Khashei, Bijari, Ardali (2009)	Feedforward Neural Network (FFNN)	ARIMA+FFNN+lógica Fuzzy, ARIMA + Fuzzy, RNA + Fuzzy, ARIMA, RNA, Chen's fuzzy time series (primeira e segunda ordens), Yu's fuzzy time series e Adaptive Neuro-Fuzzy Inference System.	USD/IRR e EUR/IRR	Diária	MAE e MSE
Ravi, Pradeepkumar, Deb (2017)	*Multilayer perceptron* (MLP) e General regression neural network (GRNN)	Chaos+MLP+PSO, Chaos+MLP+MOPSO, Chaos+MLP+NSGA-II, Chaos+MLP, Chaos+PSO, Chaos+MOPSO, Chaos+NSGA-II, Chaos+GRNN, Chaos+GMDH, Chaos+CART, Chaos+CART-EB, Chaos+MARS, Chaos+TreeNet, Chaos+LASSO e Chaos+RFTE	JPY/USD, GBP/USD, e EUR/USD	Diária	MSE, D_{stat} e U de Theil
Galeshchuk (2016)	*Multilayer perceptron* (MLP)	MLP	EUR/USD, GBP/USD, USD/JPY	Diária, mensal e trimestral	
Kristjanpoller, Minutolo (2018)	Feedforward Neural Network (FFNN)	FFNN-GARCH, GARCH e EGARCH	USD/BTC	Diária	MSE e MCS
Yao, Tan (2000)	Feedforward Neural Network (FFNN)	FFNN, ARIMA, b*uy-and-hold* e t*rend-follow*	AUD/USD,CHF/USD, DEM/USD, GBP/USD e JPY/USD	Semanal	NMSE gradiente e retorno
Mallqui, Fernandes (2019)	*Multilayer perceptron* (MLP)	MLP, Support vector machine, ensemble models (RNN+tree classifier, RNN+ k-Means, ANN, RNN and SVM)	Bitcoin	Diária	MAE, MAPE, RMSE
Sermpinis et al. (2013)	Adaptive Radial basis function Network (ARBF)	ARBF–PSO, k-NN, ARMA, MACD e RW	EUR/USD, EUR/GBP e EUR/JPY	Diária	MAE, MAPE, RMSE, U de Theil, PT_{stat}
Yu, Wang, Lai (2005)	Feedforward Neural Network (FFNN)	GLAR+RNA, GLAR, RNA, EW (equal weights), ME (minimum error) e NE (nonlinear ensemble)	DEM/USD, GBP/USD e JPY/USD	Mensal	NMSE, D_{stat} e Retorno Anual
Giles, Lawrence, Tsoi (2001)	Recurrent Neural Networks (RNN)	RW	DEM, JPY, CHF, GBP e CAD	Diária	percentage of correct sign predictions
Rivas et al. (2004)	Radial basis function Network (RBF)	RBFNN + EvRBF, RBF + GA e RBF + LSE	GBP/USD	Mensal	MSE

Tabela 2.10 - Modelos propostos e seus concorrentes nos estudos selecionados

(Conclusão)

Autores	Modelo Principal	Modelos Concorrentes	Moedas	Frequência	Medida de desempenho
Li, Wang, Ismail (2013)	Fuzzy Neural Network (FNN)	RBF e FNN-PS	USD/CAD	Diária	MSE
Qi, Zhang (2001)	Feedforward Neural Network (FFNN)	Feedforward Neural Network (FFNN)	GBP/USD	Semanal	MAE, MAPE, RMSE, ME, Sign, DA
Majhi, Panda, Sahoo (2009)	Functional link artificial neural network (FLANN) e cascaded functional link artificial neural network (CFLANN)	FLANN, CFLANN, LMS	USD/GBP, USD/INR e USD/JPY	Mensal	MSE
Leung, Chen, Daouk (2000)	General regression neural network (GRNN)	MLP, multivariate transfer function e RW	CAD, JPY e GBP	Mensal	MAE, RMSE U_{stat}, Bias e Proportion coefficients
Walczak (2001)	AFLS	MLP, RBF, ARNN, Elman Network e FNN	USD/GBP	Diária	RMSE, SED, PRE

Fonte: Elaborado pela autora.

2.5. *Hot Topics*

Para identificar os assuntos de maior relevância (*hot topics*) relacionados a estudos sobre previsão de taxa de câmbio com redes neurais foi realizada inicialmente, uma varredura na amostra selecionada de 245 artigos, utilizando o software Bibliometrix (ARIA; CUCCURULLO, 2017). Esta varredura investiga a distribuição e a frequência da dinâmica das palavras contidas nos títulos de artigos, nas palavras-chave e nos resumos, para obter os tópicos de pesquisa mais promissores e as tendências futuras (HOMRICH *et al.*, 2018). Dessa forma, após a realização da revisão de literatura dos artigos mais influenciadores (*outliers*) tornou-se possível propor os assuntos a serem analisados como possíveis *hot topics*.

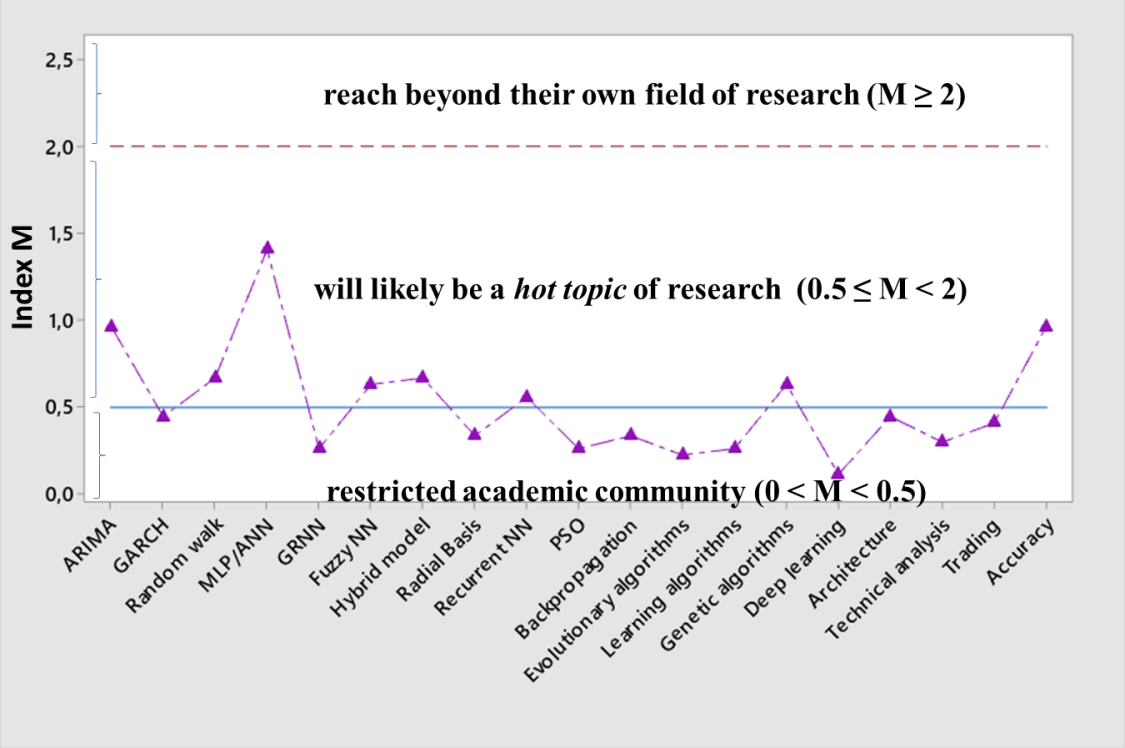
Para mensurar o impacto de um tópico científico (ou composto), Banks (2006) propõe uma métrica similar ao índice H. Esta métrica, denominada índice H-B, tem por objetivo revelar e separar os tópicos interessantes da pesquisa científica (*hot topics*) daqueles de nenhum interesse científico ou já exaustivamente pesquisados. Para se obter índice H-B, no campo de pesquisa da base de dados (*Web of Science*, *Scopus*, entre outras), insere-se o tópico científico de interesse, listando-se as publicações selecionadas em ordem decrescente de número de citações. O índice H-B significa que existem h-b artigos citados ao menos h-b vezes.

Os assuntos propostos são avaliados a partir de uma análise complementar, combinando os tópicos recorrentes da Figura 2.5, o índice H-B (HIRSCH, 2005; HOMRICH et al., 2018) e o índice M (BANKS, 2006, HOMRICH et al., 2018). O índice M, por sua vez, é calculado (HOMRICH *et al*., 2018) de acordo com a Equação 2.2:

$$\text{Índice M} \sim \text{Índice H-B} / n \tag{2.2}$$

Em que n é o número de anos decorridos desde a primeira publicação identificada sobre o assunto em questão.

Figura 2-5 - *Hot Topics* em Previsão de Câmbio com Redes Neurais



Fonte: Elaborado pela autora.

A Figura 2.5 apresenta o índice M, proposto por Banks (2006). Observa-se que, em relação aos estudos sobre previsão de câmbio com redes neurais, os modelos de Rede Neural Recorrente, *Fuzzy* e Híbridos, se destacam por apresentarem o índice M próximos a 0,5, representando potencias *hot topics*. Por outro lado, termo como MLP/ANN (perceptron de múltiplas camadas) já pode ser considerado um tópico altamente pesquisado e com recorrente discussão.

Adicionalmente, os tópicos apresentados na Figura 2.5 podem ser categorizados em grupos: modelos de previsão (corresponde aos principais modelos propostos e seus concorrentes: ARIMA, GARCH, RW, MPL/RNN, GRNN, *Fuzzy* NN, *Recurrent* NN, *Radial basis* NN e *hybrids*), variáveis explicativas (technical analysis), medidas de precisão (accuracy); estratégias de negociação (*trading strategies*) e algoritmos para otimização e arquitetura das redes neurais (PSO, *backpropagation*, *evolutionary*, *learning*, e *genetic*, *architecture*, *deep learning*).

Em relação aos modelos de previsão e às medidas de precisão, observa-se uma tendência de proposição de modelos híbridos e previsão em conjunto. No entanto, em sua maioria, a avaliação do desempenho da previsão de modelos de taxa de câmbio usa métricas estatísticas com base na magnitude do erro de previsão, como RMSE e MAE. Essas métricas estão sujeitas

a críticas quanto à sua relevância para o valor econômico das previsões. Os erros nos valores previstos podem ser aleatórios (causados por fatores que não podem ser explicados pelas variáveis de entrada) ou sistemáticos (causados por erro de especificação do modelo, processamento ou amostragem). Portanto, conhecer a natureza do erro e as situações em que certos algoritmos funcionam melhor, bem como a identificação de modelos a serem utilizados em estratégias de negociação e mitigação de riscos, constitui-se em uma lacuna de conhecimento.

Em relação às variáveis, observa-se que a maioria dos estudos utilizam a própria variável defasada. Utilizando somente esta variável, existe a possibilidade de os modelos repetirem a previsão do RW. É preciso identificar outras variáveis que auxiliem a previsão.

Devido ao avanço tecnológico, a questão dos algoritmos de otimização como retropropagação e evolucionário ("*backprogagation*" e "*evolutionary*") parece ser um tópico restrito a certas comunidades, como por exemplo, na área de computação; ao contrário, dos algoritmos genéticos e de aprendizagem ("*genetic* e "*learning*"). Uma lacuna a ser explorada é representada pela necessidade do desenvolvimento ou aprimoramento de algoritmos de aprendizagem que auxiliem a selecionar a arquitetura de rede neural apropriada para a previsão da taxa de câmbio.

2.6. Conclusões Parciais

Embora o estudo da previsão de câmbio com redes neurais, na amostra analisada composta por 245 artigos, evidencie 27 anos de estudo sobre o tema, constitui-se uma área de pesquisa ativa. Este fato é observado pelo aumento de 32% no número de publicações no último triênio (2017-2019) (Gráfico 2.1).

Com relação à produção científica por país, observa-se (Tabela 2.4) que Índia, Reino Unido e China encontram-se à frente dos demais países no ranking de publicações. Por outro lado, o Brasil está na 15ª colocação. Este fato demonstra que o campo nacional de estudos sobre o tema encontra-se ainda pouco explorado e evidencia a necessidade de realização de um maior número de pesquisa com inserção internacional.

Observa-se, conforme a Tabela 2.6 que maior parte das fontes de publicação é representada por periódicos da área de computação, consequentemente resultando em aplicabilidade dos algoritmos nesta área de interesse, distanciada, portanto, do enfoque

financeiro e econômico. Caberia aos pesquisadores da área financeira e econômica, determinar quais variáveis seriam adequadas aos modelos.

Em relação à produtividade dos autores é possível observar que Dunis, C.L destaca-se com 8 artigos (Tabela 2.8). Entretanto, este número é representa apenas 3,4% do total de publicações (245 artigos). Este fato indica que apontar um pesquisador ou um grupo como referência nas discussões sobre o tema, ainda não é possível.

Os artigos influentes podem ser categorizados em dois grupos: os que objetivam estabelecer procedimentos sistemáticos de configuração das redes neurais; os que comparam o desempenho da previsão entre modelos. É indispensável que nos procedimentos de comparação sejam utilizados os modelos ingênuos, como o RW. Entretanto, alguns estudos não realizam esta comparação. Tão importante quanto realizar esta comparação, é estabelecer um modelo de referência em redes neurais a ser superado.

Este estudo tem como limitação o fato de os estudos foram selecionados a partir da base de dados da Scopus. Como sugestão de trabalhos futuros indica-se adicionar artigos de outras bases como Web of Science, Proquest e Ebsco.

3. PREVISÃO DE TAXA DE CÂMBIO COM REDE NEURAL RECORRENTE LSTM E INDICADORES TÉCNICOS

3.1. Introdução

As redes neurais *feedforward* e recorrente são empregadas há muito tempo para fins de previsão de taxa de câmbio (KUAN; LIU, 1995; HANN; STEURER, 1996; LISI; SCHIAVO, 1999; LEUNG *et al.*, 2000; ZHANG, 2003; KHASHEI *et al.*; 2013; GALESHCHUK, 2016; entre outros). Embora os resultados mostrem que estes modelos possuem significativa capacidade de *timing* de mercado e, algumas vezes, apresentem RMSE significativamente menor do que o modelo de passeio aleatório, eles não apresentam um desempenho sistematicamente melhor em todos os estudos avaliados.

Observa-se que os estudos de previsão de câmbio com redes neurais, em sua maioria, utilizam como entrada na rede neural, as observações passadas da própria série, enquanto a saída, seu valor futuro. Cada padrão de entrada é composto por uma janela móvel de comprimento fixo ao longo da série. Entretanto, a principal dificuldade é determinar o comprimento desta janela, ou seja, o número de defasagens a serem incluídas no modelo (HUANG, 2004). Ressalta-se que o desempenho de qualquer modelo de previsão depende da adequada identificação das variáveis de entrada.

Uma alternativa seria o uso de uma classe diferente de indicadores técnicos, amplamente utilizada entre os operadores de câmbio, que explora o fato de que certos valores para uma série de preços parecem ter um conteúdo informativo mais alto do que outros (FIESS; MacDONALD, 2002). Estes valores correspondem aos limites de duas diferentes dimensões: o preço máximo e o mínimo do dia; o preço de abertura e fechamento do mercado. A diferença entre o preço máximo e o mínimo representa o intervalo de negociação e fornece informações sobre a atividade de negociação de um determinado período correspondendo a uma medida de volatilidade (TAYLOR, 1987; FIESS; MacDONALD, 1999, 2002). A diferença entre os preços de abertura e fechamento, por sua vez, é a medida da direção e da extensão das tendências intradiárias. Assim, a interação entre tendência e volatilidade contém informação sobre a evolução futura dos preços (FIESS; MacDONALD, 2002). Portanto, podem ser utilizadas para a previsão da taxa de câmbio.

Ressalta-se que os modelos de rede neural recorrente (RNN), diferentemente das redes neurais *feedforward* utilizada na maioria dos estudos, têm conexões de *feedback* interna para aprender padrões temporais, portanto, são adequados para a modelagem de séries temporais. Neste estudo, é utilizada a rede neural recorrente *long short-term memory* (LSTM), devido ao fato deste modelo ser considerado mais geral e eficaz na captura de dependências temporais de longo prazo e não apresentar os problemas de otimização que atingem as redes neurais recorrentes simples (WANG; HUANG; WANG, 2012; GUO et al., 2014; BAO; YUE; RAO, 2017). Gu, Kelly e Xiu (2020) realizam uma análise comparativa dos métodos de aprendizado de máquina e concluem que estes métodos podem ajudar a melhorar o entendimento empírico dos preços dos ativos. De acordo com este estudo, as redes neurais são os métodos com melhor desempenho.

O modelo de rede neural recorrente LSTM tem sido utilizado na previsão de séries financeiras. Fisher e Kraus (2018) comparam redes neurais LSTM com *Random Forest*, Rede Neural Profunda (DNN) e Regressão Logística para previsão de preços do S&P500. O modelo LSTM obteve melhor precisão e retornos diários. Lahmiri e Bekiros (2019) aplicam os modelos de rede neural LSTM e GRNN na previsão de preços de criptomoedas (Dash, Ripple e Bitcoin). A rede neural LSTM tem um desempenho melhor que o modelo GRNN em termos de RMSE. Henríquez e Kristjanpoller (2019) propõe um modelo híbrido para prever as variações de cinco taxas de câmbio relacionadas ao dólar americano: euro, libra britânica, iene japonês, franco suíço e dólar canadense. O modelo proposto é comparado ao passeio aleatório, ARMA-GARCH, as redes neurais *feedforward*, recorrente tradicional (RNN) e LSTM, utilizando o MSE e aplicando-se o Model Confidence Set (MCS) de Hansen, Lunde e Nason (2002, 2011). Entretanto, a 10% de significância, não é possível afirmar que o modelo LSTM tem capacidade preditiva inferior aos demais modelos.

Este estudo propõe-se a verificar a capacidade preditiva do modelo de rede neural recorrente LSTM na previsão de taxa de câmbio. Em alinhamento ao estudo de Henríquez e Kristjanpoller (2019), para a seleção de modelos, é aplicado o MCS de Hansen, Lunde e Nason (2002, 2011). Devido às críticas ao uso de métricas estatísticas com base na magnitude do erro de previsão (LEITCH; TANNER, 1991; INCE; BURNS; MOOSA, 2017; CEBECI; IMAMOGLU, 2019), adicionalmente, é verificada a capacidade preditiva em termos de precisão da direção. Além disto, são usados os indicadores técnicos (preços de abertura, fechamento, máximo e mínimo) como variável de entrada (explicativa).

Este capítulo está subdividido nas seguintes seções: introdução ao tema e à área de interesse; seção 3.2, Modelos de Rede Neural; seção 3.3, Modelos de Referência; seção 3.4,

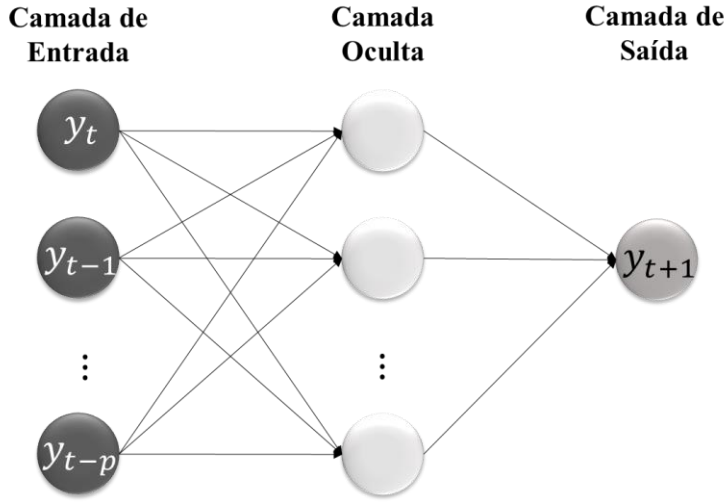
Seleção de Modelos; seção 3.5, Medidas de Precisão da Previsão; seção 3.6, Estratégia Empírica; seção 3.7, Apresentação dos resultados, e seção 3.8, conclusões parciais.

3.2. Modelos de Rede Neural

3.2.1. Rede Neural *Feedforward*

Os métodos de previsão de rede neural fornecem um conjunto flexível de ferramentas de previsão não linear. Os métodos podem ser usados para previsão de série temporal extrapolativa, modelagem causal ou classificação. Ao longo dos anos, diferentes tipos de redes neurais têm surgido. O tipo mais comum em aplicativos de previsão é a rede neural *feedforward* (ORD, FILDES e KOURENTZES, 2017). Este modelo é composto por várias camadas de unidades básicas de processamento chamadas neurônios ou nós. A Figura 3.1, apresenta uma rede neural *feedforward* típica para previsão de séries temporais. É uma rede básica com apenas uma camada de entrada, uma camada oculta e uma camada de saída.

Figura 3-1 - Rede neural *feedforward* típica para previsão de séries temporais



Fonte: Adaptado de Bao, Yue e Rao (2017)

Os nós, na camada de entrada, são usados para receber informações dos dados. Para um problema de previsão de séries temporais, a variável defasada (y_t, y_{t-1}, ..., y_{t-p}) é usada como entrada. A camada oculta, parte mais importante de uma rede, é composta por nós conectados

à camada de entrada e saída. Com funções de transferência não lineares, nós ocultos podem processar as informações recebidas pelos nós de entrada. A saída da rede é usada para prever os valores futuros de uma série temporal. Se o foco estiver na previsão um passo à frente, será necessário apenas um nó de saída. Se a previsão de várias etapas à frente for necessária, os vários nós poderão ser empregados na camada de saída. Em uma rede de *feedforward*, a informação é unidirecional. Ou seja, ela passa pelos nós de entrada para os nós ocultos e para os nós de saída, e não há *feedback* da saída da rede (ZHANG, 2012; ORD; FILDES; KOURENTZES, 2017). A rede neural ilustrada na Figura 3.1 é funcionalmente equivalente a um modelo autorregressivo não linear.

$$y_{t+1} = f\left(y_t + y_{t-1} + \cdots + y_{t-p}\right) + \varepsilon_{t+1} \tag{3.1}$$

Em que y_t é o valor observado da variável y no tempo t e ε_{t+1} é o termo de erro no tempo t + 1. Este modelo sugere que um valor futuro de série temporal, y_{t+1}, é uma função autorregressiva de suas observações anteriores, y_t, y_{t-1}, ..., y_{t-p} mais um erro aleatório. Como qualquer modelo de previsão de séries temporais pressupõe que exista uma relação funcional entre o valor futuro e as observações passadas, as redes neurais podem ser úteis na identificação dessa relação (ZHANG, 2012).

O modelo de rede neural artificial amplamente utilizado é o perceptron de múltiplas camadas (*multiplayer perceptron* - MLP) representado por (MA *et al*., 2015):

$$\boldsymbol{y} = h\left(\varphi_0 + \sum_{j=1}^{N} \varphi_j g\left(\theta_0 + \sum_{i=1}^{M} \theta_i \boldsymbol{x}_i\right)\right) + \varepsilon_{t+1} \tag{3.2}$$

Em que M e N representam, respectivamente, o número de neurônios nas camadas de entrada e oculta. *g* e *h* são as funções de transferência para as camadas de entrada e oculta. As matrizes vetoriais θ e φ se referem respectivamente aos valores de peso das camadas de entrada e oculta (MA *et al*., 2015). Antes que uma rede neural possa ser usada para previsão, ela deve ser treinada. O treinamento em rede neural refere-se à estimativa de pesos de conexão. Embora o processo de estimativa seja semelhante ao da modelagem de regressão, em que se minimiza a soma dos quadrados dos erros, o processo de treinamento da rede neural é mais complicado devido à natureza do processo de otimização não linear (ZHANG, 2012). Existem vários

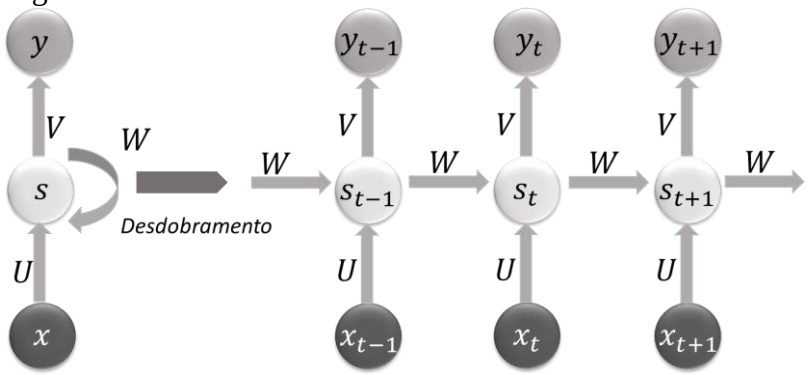
algoritmos de treinamento como retropropagação (WERBOS, 1974, 1990; RUMELHART; HINTON; WILLIAMS, 1986; REFENES *et al*., 1993; ZHANG; HU, 1998;), Levenberg-Marquardt (MORÉ, 1978; KUAN; LIU, 1995), Genético (HOLLAND, 1992; ARIFOVIC; GENCAY, 2000; LAWRENZ; WESTERHOFF, 2003), entre outros. Entretanto, o mais utilizado é o algoritmo de retropropagação. A ideia básica do treinamento de retropropagação é usar uma abordagem gradiente decrescente para ajustar e determinar pesos, de modo que uma função de erro geral como a soma dos quadrados dos erros, possa ser minimizada (ZHANG, 2012).

Diversas redes neurais *feedforward* tem sido propostas, como a Rede Neural Modular (que divide a entrada em várias sub-redes, nas quais são tratadas várias tarefas específicas) (GRADOJEVIC; GENÇAY; KUKOLJ, 2009), a Rede Neural de Base Radial (a qual utiliza funções de base radial como funções de ativação) (SERMPINIS et al, 2013), a Rede Neuro-Fuzzy (onde são aplicadas regras da teoria *fuzzy* para o aprimoramento do desempenho da previsão) (KHASHEI; BIJARI; ARDALI, 2009). Entretanto, estes modelos não são adequados para modelagem de séries temporais, pois negligenciam a dependência temporal das variáveis explicativas (MA et al., 2015).

3.2.2. Rede Neural Recorrente

Além das redes neurais *feedforward*, outros tipos de redes neurais também podem ser usados para fins de previsão de séries temporais, entre as quais, destacam-se as redes neurais recorrentes. Em uma rede neural recorrente, existem ciclos ou conexões de *feedback* entre os neurônios. As saídas de uma rede recorrente podem ser retornadas diretamente às entradas, gerando *feedbacks* dinâmicos sobre erros de padrões passados. Neste sentido, as redes recorrentes podem modelar dinâmicas mais ricas do que as redes de *feedforward*. Isto é feito com a adição de um estado oculto gerado pelas informações sequenciais de uma série temporal, com a saída dependente do estado oculto. A Figura 3.2 mostra um modelo de rede neural recorrente (RNN) desdobrado em uma rede completa.

Figura 3-2 - Desdobramento de uma rede neural recorrente



Fonte: Adaptado de Bao, Yue e Rao (2017)

A notação matemática utilizada é a seguinte (BAO; YUE; BAO, 2017; FISHER; KRAUSS, 2018):

a) x_t é o vetor de entrada para a célula de memória no tempo t.

b) s_t é o estado oculto no tempo t; calculado de acordo com o vetor de entrada e o estado oculto do período anterior:

$$s_t = f(Ux_t + Ws_{t-1}) \tag{3.2}$$

Em que f é a função de ativação, usualmente a função sigmoide ou ReLU. O estado oculto inicial s_0 para calcular o primeiro estado oculto é normalmente inicializado como zero.

c) y_té a saída no tempo t, que pode ser formulada como:

$$y_t = f(Vs_t) \tag{3.3}$$

d) U e V são os pesos da camada oculta e da camada de saída, respectivamente. W são os pesos de transição do estado oculto.

Ressalta-se que o modelo de RNN, diferentemente das redes neurais *feedforward*, tem conexões de *feedback* dentro da rede neural para aprender padrões temporais; portanto, pode ser usada para modelagem de dados sequenciais e análises de séries temporais. Embora a RNN seja eficaz na modelagem de problemas não lineares, ainda apresenta algumas limitações (HOCHREITER; SCHMIDHUBER, 1997; HOCHREITER, 1998; ZHANG, 2012; MA et al, 2015), entre as quais, destaca-se: (a) elas não são capazes de treinar as séries temporais com prolongadas defasagens; (b) elas podem assumir arquiteturas muito diferentes, dificultando a

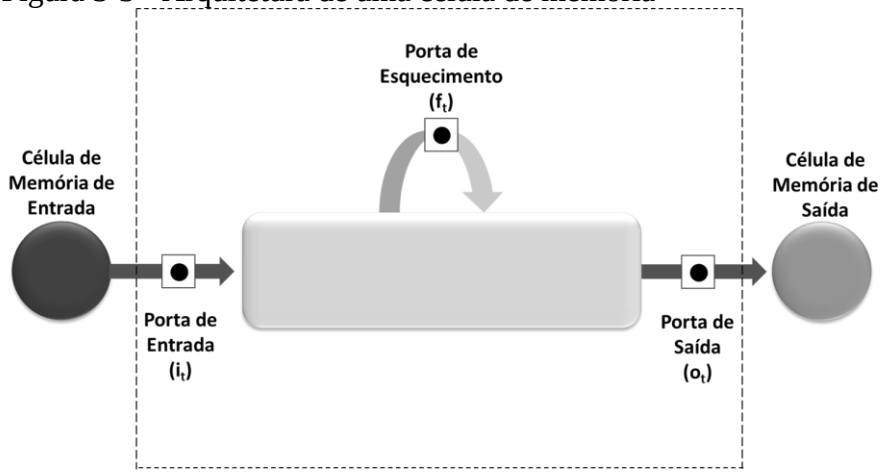
especificação da estrutura adequada do modelo; (c) a dificuldade de treinamento devido à natureza instável dos algoritmos causada pelo problema de dissipação/explosão dos gradientes.

3.2.3. Rede Neural LSTM

A rede neural recorrente *Long Short-Term Memory* (LSTM), uma variação do modelo de rede neural recorrente, proposta por Hochreiter e Schmidhuber (1997) propõe uma solução para combater o problema da instabilidade decorrente da dissipação dos gradientes usando células de memória, sendo, eficaz para a resolução de vários problemas de aprendizagem relacionados a dados sequenciais. Os modelos LSTM são gerais e eficazes na captura de dependências temporais de longo prazo e não apresentam os problemas de otimização que atingem as redes neurais recorrentes simples (WANG; HUANG; WANG, 2012; GUO et al., 2014; BAO; YUE; RAO, 2017).

A rede neural recorrente LSTM é composta de uma camada de entrada, uma ou mais camadas ocultas e uma camada de saída. O número de neurônios na camada de entrada é igual ao número de variáveis explicativas (x_{t-1}, x_{t-2}, ..., x_{t-n}). O neurônio na camada de saída reflete a variável dependente y em t + 1. A principal característica da rede LSTM são as células de memória contidas nas camadas ocultas. Cada uma das células de memória tem três portas que mantém e ajustam o estado de célula s_t: uma porta de esquecimento (f_t), uma porta de entrada (i_t) e uma porta de saída (o_t) (BAO; YUE; RAO, 2017). A estrutura de uma célula de memória é ilustrada na Figura 3.3.

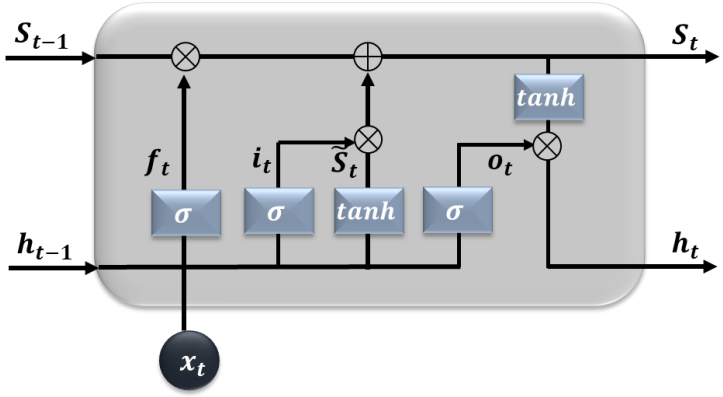
Figura 3-3 - Arquitetura de uma célula de memória



Fonte: Adaptado de Bao, Yue e Rao (2017)

A Figura 3.4 apresenta um modelo LSTM completo, o qual descreve como o valor de cada porta é atualizado.

Figura 3-4 - Arquitetura rede neural LSTM



Fonte: Adaptado de Bao, Yue e Rao (2017)

A notação matemática utilizada é a seguinte (BAO; YUE; BAO, 2017; FISHER; KRAUSS, 2018):

a) x_t é o vetor de entrada para a célula de memória no tempo t.
b) W_i, W_f, W_s, W_o, U_i, U_f, U_s, U_o e V_o são as matrizes de pesos.
c) b_i, b_f, b_s and b_o são os vetores de viés (constantes do modelo).
d) h_t é o valor da célula de memória no tempo t.
e) i_t e $\tilde{S}_t$ são os valores da porta de entrada e o candidato a célula de estado de memória no momento *t*:

Inicialmente, são calculados da porta de esquecimento (f_t) e da célula de estado de memória S_t no momento t. Para tanto, utiliza a função de ativação sigmoide (σ), o valor da célula de memória h_{t-1} e x_t, produzindo um número entre 0 e 1 para cada número no estado da célula S_{t-1}. O número 1 representa "manter ", e zero (0) representa "esquecer".

$$f_t = \sigma(W_f x_t + U_f h_{t-1} + b_f) \tag{3.4}$$

Em seguida, a função de ativação sigmoide atualiza o valor da porta de entrada i_t. A função de ativação tangente hiperbólica (*tanh*) cria um vetor de novos valores candidatos, $\tilde{S}_t$ que podem ser adicionados a célula de estado.

$$i_t = \sigma(W_i x_t + U_i h_{t-1} + b_i) \quad (3.5)$$

$$\tilde{S}_t = tanh(W_s x_t + U_s h_{t-1} + b_s) \quad (3.6)$$

Posteriormente, a célula de estado antiga (S_{t-1}) é atualizada para a nova célula de estado (S_t) da seguinte forma:

$$S_t = i_t \times \tilde{S}_t + f_t \times S_{t-1} \quad (3.7)$$

Por fim, são calculados o valor da porta de saída (o_t) e a célula de estado de memória (h_t) no momento *t*:

$$o_t = \sigma(W_o x_t + U_o h_{t-1} + V_o S_t + b_o) \quad (3.8)$$

$$h_t = o_t \times \tanh(S_t) \quad (3.9)$$

Neste estudo, o algoritmo de retropropagação é usado para treinar o modelo LSTM. A taxa de aprendizagem, o tamanho do lote e o número de épocas são 0,001, 60 e 10.000, respectivamente. A velocidade da convergência é controlada pela taxa de aprendizado, que é uma função decrescente do tempo. O resultado experimental se torna estável quando a convergência é alcançada (MA, et al., 2015). Adicionalmente, são utilizadas técnicas de regularização como decaimento de peso (*weight decay*), eliminação de peso e parada antecipada (*early stopping*), para controlar o ajuste excessivo (WEIGEND *et al.*, 1992; GILES, 2001).

3.3. Modelos de Referência

3.3.1. Passeio aleatório

A previsão da taxa de câmbio constitui-se uma área de pesquisa ativa, uma vez que apresenta uma série de questões de interesse para acadêmicos e profissionais de mercado. No passado, a crença econômica baseava-se essencialmente na hipótese do mercado eficiente

(FAMA, 1965), cuja forma fraca alegava que os preços dos ativos atuais refletem todas as informações contidas em sua história passada. Isso leva à formulação da hipótese de passeio aleatório, segundo a qual o preço de um ativo é descrito da seguinte forma:

$$y_{t+1} = y_t + \xi_t \tag{3.10}$$

Em que y_t é o preço do ativo no momento t e ξ_t representa um processo de ruído branco. Assim, a estratégia ingênua assume que a melhor previsão é a taxa de câmbio mais recente:

$$\hat{y}_{t+1} = y_t \tag{3.11}$$

Em que y_t é a taxa de câmbio no momento t (atual) e $\hat{y}_{t+1}$, a taxa de câmbio prevista para o momento t+1.

3.3.2. ARIMA

Para fins de comparação da precisão preditiva dos modelos de rede neural LSTM a um modelo baseado em estatística, utiliza-se o algoritmo ARIMA (modelos autorregressivos integrados de médias móveis) de Box e Jenkins (1976). Este algoritmo modelo é implementado usando a biblioteca *Statsmodels* (SEABOLD; PERKTOLD, 2010; SAGHEER; KOTB, 2019) no software Python. De modo interativo, são testadas diferentes combinações dos parâmetros ARIMA (p, d, q), em que p é a ordem, ou seja, o número de defasagens do modelo autorregressivo (AR); d indica o grau de diferenciação (I) e q, a ordem do modelo de média móvel (MA) (BOX; JENKINS, 1976).

Para cada combinação desses parâmetros, ajusta-se o modelo ARIMA e utiliza-se o critério de informação Akaike (AIC) para escolher a melhor combinação destes parâmetros. Este critério de informação mede quão bem um modelo se ajusta aos dados, levando em consideração a complexidade geral do modelo.

3.4. Seleção de Modelos

O *Model Confidence Set* (MCS), proposto por Hansen, Lunde e Nason (2003, 2011), aplica o conceito de intervalo de confiança para rejeitar ou não modelos. O MCS objetiva comparar um conjunto de modelos de previsão $\mathcal{M}^0$, e reduzi-los a um conjunto menor $\mathcal{M}^*$ (um conjunto de confiança) que contenha o(s) melhor(es) modelo(s) com um nível de confiança α e critério de seleção determinado pelo pesquisador.

A seleção do conjunto de modelos baseia-se em informações de amostra sobre o desempenho preditivo dos modelos em $\mathcal{M}^0$. Essas informações da amostra direcionam o MCS a criar um conjunto aleatório de modelos dependentes dos dados, $\mathcal{M}^*$. Este conjunto $\mathcal{M}^*$ inclui o(s) melhor(es) modelo(s), com uma certa probabilidade e em um intervalo de confiança que abranja o parâmetro populacional (HANSEN; LUNDE; NASON, 2003, 2011).

Esta abordagem reconhece as limitações dos dados e corrige efeitos de *data snooping* por meio da realização de um procedimento *bootstrap*. Este procedimento permite a obtenção de um conjunto de modelos equiparáveis em previsão para um dado nível descritivo. Dados informativos tanto poderão resultar em um subconjunto com os melhores modelos, quanto, ao contrário, demonstrar que todos os modelos são indistintamente bons ou ruins. Desta forma, o MCS apresenta algumas vantagens sobre os métodos de seleção existentes, destacando-se que: (a) ele difere dos critérios de seleção de modelos tradicionais que escolhem um modelo único sem considerar o conteúdo das informações dos dados, (b) seu procedimento torna possível fazer declarações sobre significâncias válidas no sentido tradicional ao reportar os p-valores a partir de múltiplas comparações pareadas (uma propriedade que não é satisfeita pela abordagem comumente usada); (c) ele considera a possibilidade de mais de um modelo ser o melhor, caso em que o $\mathcal{M}^*$contém mais de um modelo (HANSEN; LUNDE; NASON, 2003, 2011).

O método de seleção pelo MCS baseia-se em um teste de equivalência ($\delta_{\mathcal{M}}$) e uma regra de eliminação ($e_{\mathcal{M}}$). O teste de equivalência é aplicado para o conjunto $\mathcal{M} = \mathcal{M}^0$. Se a hipótese de equivalência $\delta_{\mathcal{M}}$ for rejeitada, então há evidência de que os modelos não apresentam o mesmo poder preditivo. Então a regra de eliminação $e_{\mathcal{M}}$ é utilizada para eliminar com desempenho inferior. Esse procedimento é repetido até que a hipótese de equivalência $\delta_{\mathcal{M}}$ não seja rejeitada. Então, o $\mathcal{M}^*$ é definido para um conjunto dos melhores modelos. Utilizando um nível de significância α, é possível assegurar que $\lim_{n\to\infty}\left(\mathcal{M}^* \subset \widehat{\mathcal{M}}^*_{1-\alpha}\right) \geq 1-\alpha$. Se houver um modelo mais expressivo, tem-se o caso em que $\lim_{n\to\infty}\left(\mathcal{M}^* = \widehat{\mathcal{M}}^*_{1-\alpha}\right) = 1$. O MCS gera um p-valor para cada modelo. Assim, um dado modelo $i \in \mathcal{M}^0$ que tenha um p-valor menor α, não

pertencerá ao subconjunto dos melhores modelos $\mathcal{M}^*$, ou seja, o p-valor do MCS, $\hat{p}_i$, é o limite em que $i \in \widehat{\mathcal{M}}^*_{1-\alpha}$, se somente se, $\hat{p}_i \geq \alpha$.

A estatística proposta é (HANSEN, LUNDE; NASON, 2011):

$$T_{max,M} = \max t_{i.,} \; i \epsilon M \tag{3.12}$$

Em que $t_{i.,} = \frac{\bar{d}_{i.}}{\sqrt{\widehat{var}(\bar{d}_{i.})}}$, $\bar{d}_{i.}$ é a perda simples do i-ésimo modelo em relação às perdas médias entre os modelos no conjunto e, $\widehat{var}(\bar{d}_{i.})$ é a variância das estimativas bootstrapped da $var(\bar{d}_{i.})$.

O algoritmo do MCS, proposto por Hansen, Lunde e Nason (2003, 2011), foi implementado no software OxMetrics (pacote MULCOM). Esse algoritmo é aplicado neste estudo para a seleção do(s) melhor(es) modelo(s) de previsão da taxa de câmbio.

Neste estudo, é estabelecido um processo de comparação entre as previsões, em busca da melhor, utilizando-se o algoritmo MCS com a função de perda MSE. Para testar a significância estatística dos resultados, o MCS é aplicado para encontrar o melhor modelo de previsão para cada taxa de câmbio. Os intervalos de confiança considerados são α = 10% e α = 25%. Este teste é usado para determinar se um modelo específico ou um conjunto de modelos é superior entre os modelos testados. Para o procedimento de *bootstrap* são realizadas 10.000 reamostragens.

3.5. Medidas da precisão da previsão

3.5.1. Medidas tradicionais

Para avaliar os modelos, duas medidas tradicionais são utilizadas. As medidas de precisão da previsão são as seguintes: erro quadrático médio (*mean square error - MSE*) e raiz do erro quadrático médio (*root mean square error - RMSE*) para os quais, os menores valores indicam um desempenho de previsão melhor. Esses índices são definidos das seguintes maneiras:

$$MSE = \frac{1}{T}\sum_{t=1}^{T}\left(p^{verdadeiro} - p^{previsto}\right)^2 \tag{3.13}$$

$$RMSE = \sqrt{\frac{1}{T}\sum_{t=1}^{T}(p^{verdadeiro} - p^{previsto})^2} \tag{3.14}$$

No qual $p^{verdadeiro}$ é o valor observado para o período de tempo t e $p^{previsto}$ é o valor previsto para o período correspondente. O RMSE mede o desvio geral entre os valores previstos e observados, com a vantagem de que sua unidade de medida é a mesma da variável observada.

3.5.2. Medidas de precisão da direção da previsão

Embora as medidas MSE e RMSE sejam amplamente utilizadas, elas podem não ser adequadas quando a correta direção da taxa de câmbio for mais relevante que a magnitude do erro (BURNS; MOOSA, 2017; INCE; CEBECI; IMAMOGLU, 2019). Leitch e Tanner (1991), por exemplo, argumentam que a precisão da direção é mais relevante para a lucratividade. Para estes autores, a relação entre a precisão de direção e a lucratividade é quase tão definitiva quanto a relação entre a raiz do erro quadrático médio e do erro absoluto médio. Eles sugerem ainda que, se os lucros não são observáveis, a precisão da direção das previsões pode ser usada como critério de avaliação do desempenho da previsão. Por sua vez, Cumby e Modest (1987) sugerem que a precisão da direção também está relacionada à capacidade de *timing* do mercado. Do ponto de vista do investidor, a direção da previsão é um dos critérios de avaliação mais importantes, caso ele se preocupe mais com a mudança de direção da taxa de câmbio no futuro, do que com os seus valores exatos (YU; WANG; LAI, 2007; BURNS; MOOSA, 2017; INCE; CEBECI; IMAMOGLU, 2019). Entretanto, essa medida de desempenho tem sido menos explorado como observado na Tabela 2.10.

Assim, uma medida adicional de avaliação de desempenho é a precisão da direção (*direction accuracy* - DA) expressa por:

$$DA = \frac{1}{n}\sum_{t=1}^{n} a_i \tag{3.15}$$

Em que $a_i = 1$, se $(y_{i+1} - y_i)(\hat{y}_{i+1} - y_i) > 0$; caso contrário, $a_i = 0$.

Um teste convencional da significância de uma proporção é aplicado para se determinar a precisão da direção. A rejeição de H0: DA ≤ "Taxa de não informação (NIR)" significa que o modelo subjacente é superior ao RW na previsão da direção dos movimentos da taxa de câmbio (DINOV, 2018). A taxa de não informação é a maior proporção das classes observadas (0 e 1). O teste binomial é aplicado utilizando-se o *R Caret Package Confusion Matrix*.

3.6. Estratégia Empírica

As três séries temporais de taxas de câmbio utilizadas são: Real (BRL/USD), Euro (EUR/USD) e Libra Esterlina (GBP/USD) todas em relação ao dólar dos EUA. Estas séries foram coletadas na base de dados dos respectivos bancos centrais (Brasil, União Europeia e Reino Unido). As variáveis independentes são as taxas de câmbio de abertura, máxima, mínima e de fechamento defasadas, publicadas pela *Bloomberg* para o mesmo período**.** As séries diárias correspondem ao período de 04 de dezembro de 2014 a 30 de dezembro de 2019.

O pré-processamento de três etapas é realizado para o tratamento dos dados brutos.

Etapa 1: Dividir a amostra em dois subconjuntos

Os dados são divididos nos seguintes subconjuntos: 80% para treinamento e validação e 20% para teste, mantendo-se nesta divisão a ordem temporal.

Etapa 2: Normalizar os dados

Nesta etapa, os dados de cada subconjunto são normalizados entre 0 e 1, da seguinte forma:

$$VN = (Valor\ Atual - Valor\ Mínimo)/(Valor\ Máximo - Valor\ Mínimo) \quad (3.16)$$

Etapa 3: Transformar os dados em aprendizado supervisionado

A série é dividida em entradas (x), ou seja, variáveis independentes; e saída (y), variável dependente.

Inicialmente, são realizadas as estimações utilizando diferentes arquiteturas do modelo de rede neural LSTM. Nesta arquitetura, combina-se: (a) uma defasagem das taxas de câmbio na camada de entrada (taxa máxima, mínima e fechamento), (b) uma camada oculta e duas

camadas ocultas e (c) de 1 a 5 neurônios em cada camada oculta. A previsão da taxa de câmbio é realizada para um passo à frente.

3.7. Resultados

Nesta seção, são apresentados os resultados do exercício de previsão juntamente com os modelos de referência. Os resultados mostrados em todas as tabelas indicam o desempenho dos modelos nos dados de teste. Isso foi feito em concordância com o fato de que a avaliação relevante do desempenho de previsão deve estar fundamentada nos dados ainda não visualizados, ao invés daqueles de treinamento (histórico), já visualizados pelo modelo.

3.7.1. BRL/USD

A amostra utilizada para treinamento da rede neural contém 1266 observações, das quais 1006 são utilizadas para treinamento e validação, e o restante, 260 observações, para previsão fora da amostra (teste). Assim, o período de 4 de janeiro de 2014 a 18 de dezembro de 2018, é usado para treinamento e validação, e o período de 19 de dezembro de 2018 a 30 de dezembro de 2019, para teste do modelo.

Os modelos tradicionalmente usados para previsão da taxa de câmbio são passeio aleatório (RW) e ARIMA. De modo interativo, são testadas as combinações dos parâmetros de 1 a 5 para: o número de defasagens do modelo autorregressivo (AR); o grau de diferenciação (I) e, a ordem do modelo de média móvel (MA). O critério de informação Akaike (AIC) é usado para escolher a melhor configuração, sendo o modelo ARIMA (2,1,1) selecionado.

A arquitetura da rede neural dos modelos testados (quantidade de *camadas ocultas e neurônios por camada*), bem como as medidas de avaliação do desempenho da previsão MSE, RMSE, Ranking RMSE e p-valor do MCS para a previsão fora de amostra da taxa de câmbio diária (BRL/USD) são apresentados na Tabela 3.1.

Tabela 3.1 - *Model Confidence Set Estimation* (BRL/USD)

Modelos	**Nº de Camadas**	**Nº de Neurônios**	**MSE (*10^3)**	**RMSE**	**Ranking RMSE**	**MCS p-valor**
RW	NA	NA	0.75765	0.02753	20	0.0000
ARIMA	NA	NA	0.79900	0.02827	21	0.0000
LSTM1	1	[1]	0.63774	0.02525	19	0.0000
LSTM2	1	[2]	0.49194	0.02218	12	0.0751
LSTM3	1	[3]	0.45820	0.02141	1	1.0000
LSTM4	1	[4]	0.46554	0.02158	3	0.2263
LSTM5	1	[5]	0.46276	0.02151	2	0.2812
LSTM6	2	[2,1]	0.52569	0.02293	18	0.0091
LSTM7	2	[2,2]	0.52071	0.02282	17	0.0039
LSTM8	2	[3,1]	0.47301	0.02175	6	0.2100
LSTM9	2	[3,2]	0.47017	0.02168	5	0.2100
LSTM10	2	[3,3]	0.47833	0.02187	7	0.2100
LSTM11	2	[4,1]	0.48860	0.02210	10	0.0562
LSTM12	2	[4,2]	0.46678	0.02160	4	0.2812
LSTM13	2	[4,3]	0.51077	0.02260	14	0.0304
LSTM14	2	[4,4]	0.50620	0.02250	13	0.0277
LSTM15	2	[5,1]	0.51274	0.02264	16	0.0077
LSTM16	2	[5,2]	0.48088	0.02193	8	0.2100
LSTM17	2	[5,3]	0.49050	0.02215	11	0.1908
LSTM18	2	[5,4]	0.51206	0.02263	15	0.0274
LSTM19	2	[5,5]	0.48584	0.02204	9	0.0751

Fonte: Elaborado pela autora.

Observa-se que todos os modelos de rede neural LSTM apresentam MSE e RMSE menores que os modelos tradicionais, ARIMA e RW. Além disto, o modelo ARIMA apresenta maior RMSE quando comparados aos demais modelos.

Para testar a significância estatística dos resultados, o MCS, com a função de perda MSE, é aplicado para encontrar o melhor modelo (ou conjunto de modelos) para previsão da taxa de câmbio. O teste $T_{max,M}$ (Equação 3.12) é aplicado para determinar se é possível afirmar que um modelo em particular é superior aos demais modelos. Os resultados obtidos com a aplicação deste teste são resumidos nas Tabela 3.1. A hipótese de equivalência, para os modelos RW e ARIMA, é rejeitada. Isto indica que há evidência de que estes modelos não apresentam o mesmo poder preditivo dos modelos LSTM apresentados na Tabela 3.2.

Com base nestes resultados, é possível concluir que os modelos LSTM3, LSTM5 e LSTM12 pertencem ao conjunto $\widehat{\mathcal{M}}^{*}_{75\%}$, o que indica a sua superioridade sobre os demais modelos para a previsão da taxa de câmbio BRL/USD para o grau de significância (α) de 25%. Para α = 10%; é possível determinar a superioridade preditiva do conjunto de modelos apresentados na Tabela 3.2. Assim, dos 21 modelos testados utilizando-se a série em frequência diária, 9 configurações do modelo LSTM pertencem ao conjunto dos melhores modelos $\widehat{\mathcal{M}}^{*}_{90\%}$.

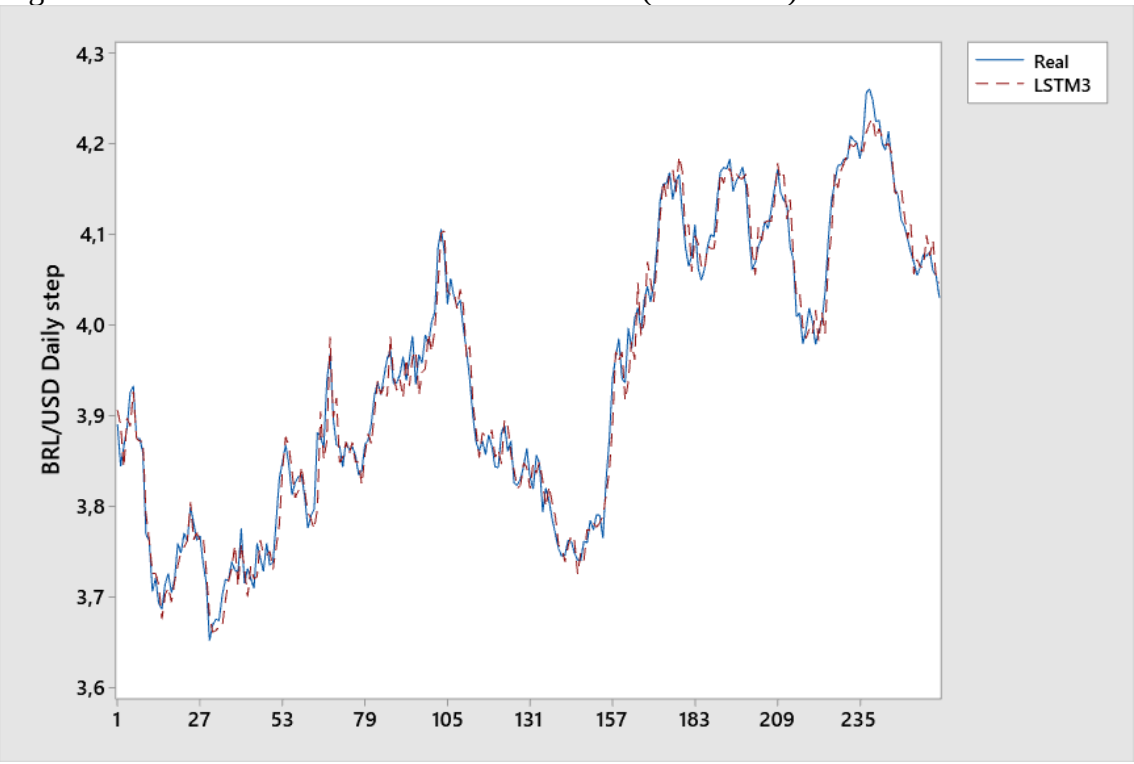
Tabela 3.2 - *Model Confidence Set* $\widehat{\mathcal{M}}^{*}_{90\%}$: BRL/USD

Modelos	**RMSE**	**MCS p-valor**	**Redução % do RMSE em relação ao RW**	**Redução % do RMSE em relação ao ARIMA**
LSTM3	0.02141	1.0000	22.2%	24.3%
LSTM4	0.02158	0.2263	21.6%	23.7%
LSTM5	0.02151	0.2812	21.9%	23.9%
LSTM8	0.02175	0.2100	21.0%	23.1%
LSTM9	0.02168	0.2100	21.2%	23.3%
LSTM10	0.02187	0.2100	20.6%	22.6%
LSTM12	0.02160	0.2812	21.5%	23.6%
LSTM16	0.02193	0.2100	20.3%	22.4%
LSTM17	0.02215	0.1908	19.5%	21.6%

Fonte: Elaborado pela autora.

Entre os modelos selecionados, o LSTM3 de uma camada e três neurônios destaca-se por apresentar o menor RMSE de 0,02141, contra 0,02753, do modelo RW. Isto representa uma redução no erro de previsão de 22,2% quando comparado ao modelo passeio aleatório e, 24,3% em relação ao ARIMA. Quando comparado o modelo que apresenta maior RMSE, ou seja, LSTM17, a redução no erro de previsão é de 19,5% e 21,6%, respectivamente. A previsão realizada pelo modelo LSTM3 e o valor observado da taxa de câmbio BRL/USD são visualizados na Figura 3.5.

Figura 3-5 – Gráfico: Previsão da taxa de câmbio (BRL/USD)

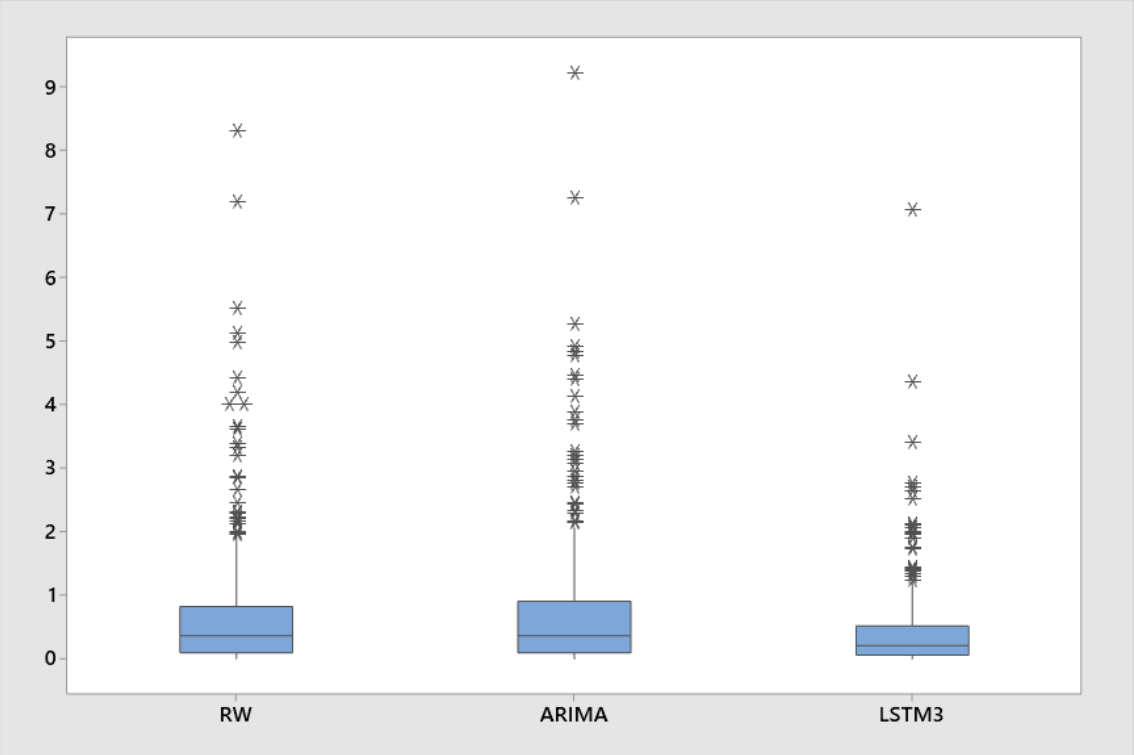


Fonte: Elaborado pela autora.

Outro aspecto importante observado pela comparação visual, Figura 3.6, dos modelos RW, ARIMA e LSTM3, relaciona-se à variabilidade e aos valores extremos do MSE. Os modelos RW e ARIMA possuem uma maior dispersão e valores extremos quando comparados ao melhor modelo selecionado pelo MCS (LSTM3).

A Tabela 3.3 apresenta as estatísticas descritivas do MSE de todos os modelos. Os modelos RW e ARIMA destacam-se por apresentarem maiores MSE (valores medianos, primeiro e terceiro quartil). E o modelo LSTM1, de uma camada e um neurônio, apresenta maior MSE máximo.

Figura 3-6 – Gráfico Box-plot MSE (BRL/USD)



Fonte: Elaborado pela autora.

Em relação ao desempenho dos modelos em detectar a direção do movimento da taxa de câmbio, observa-se, na Tabela 3.4, que a acurácia de direção (DA), H0 somente não é rejeitada para o modelo ARIMA. Isto significa que todos os modelos de rede neural LSTM são superiores ao modelo ARIMA e RW neste quesito, sendo que a acurácia geral dos modelos de rede neural analisados varia de 67.6% a 72,2%. O modelo LSTM8 apresenta maior acurácia quando comparado aos demais modelos. Embora não seja o modelo que apresenta o menor RMSE, pertence ao conjunto dos melhores modelos selecionados pelo algoritmo MCS (Tabela 3.2).

Tabela 3.3 - Estatística Descritiva MSE: BRL/USD

Modelos	MSE (*10^3)	Mínimo	Q1	Mediana	Q3	Máximo
RW	0.75765	0.00000	0.09025	0.35911	0.82226	8.31744
ARIMA	0.79900	0.00001	0.09252	0.36091	0.90500	9.22518
LSTM1	0.63774	0.00004	0.06241	0.30801	0.79524	10.14049
LSTM2	0.49194	0.00004	0.05187	0.20022	0.60393	6.46416
LSTM3	0.45820	0.00001	0.05551	0.20737	0.51644	7.05600
LSTM4	0.46554	0.00001	0.05077	0.22053	0.49618	7.19104
LSTM5	0.46276	0.00000	0.05625	0.21904	0.52557	7.05600
LSTM6	0.52569	0.00000	0.04423	0.23717	0.70228	7.39600
LSTM7	0.52071	0.00000	0.04693	0.22653	0.64771	7.48225
LSTM8	0.47301	0.00001	0.05513	0.22053	0.54756	6.06841
LSTM9	0.47017	0.00000	0.06241	0.22500	0.54756	6.98896
LSTM10	0.47833	0.00001	0.06889	0.21462	0.56055	7.07281
LSTM11	0.48860	0.00000	0.05366	0.20449	0.58329	6.69124
LSTM12	0.46678	0.00001	0.05853	0.20881	0.52900	7.37881
LSTM13	0.51077	0.00001	0.04796	0.23564	0.65793	6.87241
LSTM14	0.50620	0.00001	0.06013	0.22805	0.60393	6.85584
LSTM15	0.51274	0.00004	0.05476	0.22500	0.64389	7.24201
LSTM16	0.48088	0.00000	0.04523	0.21026	0.60886	6.93889
LSTM17	0.49050	0.00001	0.05184	0.22352	0.60886	6.97225
LSTM18	0.51206	0.00000	0.04658	0.22202	0.55461	7.07281
LSTM19	0.48584	0.00000	0.05077	0.20164	0.57121	6.83929

Fonte: Elaborado pela autora.

Tabela 3.4 - Precisão da previsão da direção (DA): BRL/USD

Modelo	Acurácia (DA)	Taxa de Não Informação (NIR)	95% CI	p-valor [DA > NIR]
ARIMA	0.4710	0.5058	(0.4090, 0.5338)	0.8811
LSTM1	0.6757	0.5058	(0.6150, 0.7323)	2.32E-08
LSTM2	0.7143	0.5058	(0.6551, 0.7685)	6.94E-12
LSTM3	0.7104	0.5058	(0.6511, 0.7649)	1.69E-11
LSTM4	0.7069	0.5058	(0.6470, 0.7613)	4.06E-11
LSTM5	0.7027	0.5058	(0.6430, 0.7577)	9.55E-11
LSTM6	0.7027	0.5058	(0.6430, 0.7577)	9.55E-11
LSTM7	0.6988	0.5058	(0.6390, 0.7541)	2.21E-10
LSTM8	0.7220	0.5058	(0.6632, 0.7757)	1.10E-12
LSTM9	0.6988	0.5058	(0.6390, 0.7541)	2.21E-10
LSTM10	0.6873	0.5058	(0.6270, 0.7432)	2.45E-09
LSTM11	0.7066	0.5058	(0.6470, 0.7613)	4.06E-11
LSTM12	0.7066	0.5058	(0.6470, 0.7613)	4.06E-11
LSTM13	0.6988	0.5058	(0.6390, 0.7541)	2.21E-10
LSTM14	0.7027	0.5058	(0.6430, 0.7577)	9.55E-11
LSTM15	0.7027	0.5058	(0.6430, 0.7577)	9.55E-11
LSTM16	0.7027	0.5058	(0.6430, 0.7577)	9.55E-11
LSTM17	0.7027	0.5058	(0.6430, 0.7577)	9.55E-11
LSTM18	0.7181	0.5058	(0.6591, 0.7721)	2.79E-12
LSTM19	0.7066	0.5058	(0.6470, 0.7613)	4.06E-11

Fonte: Elaborado pela autora.

3.7.2. EUR/USD

A amostra utilizada para treinamento da rede neural contém 1295 observações, das quais 1035 são utilizadas para treinamento e validação e o restante, 260 observações, usadas para previsão fora da amostra (teste). Assim, o período de 4 de dezembro de 2014 a 19 de dezembro de 2018 é usado para treinamento e validação e o período de 20 de dezembro de 2018 a 30 de dezembro de 2019, para teste do modelo.

Os modelos usados para comparação da previsão da taxa de câmbio são RW e ARIMA. Assim, são testadas as combinações dos parâmetros de 1 a 5 para: o número de defasagens do modelo autorregressivo (AR); o grau de diferenciação (I) e, a ordem do modelo de média móvel (MA). O critério de informação Akaike (AIC) é usado para escolher a melhor configuração, sendo o modelo ARIMA (2,1,1) selecionado.

Tabela 3.5 - *Model Confidence Set Estimation*: EUR/USD

Modelo	**Nº de Camadas**	**Nº de Neurônios**	**MSE (*10^3)**	**RMSE**	**Ranking RMSE**	**MCS p-valor**
RW	NA	NA	0.01250	0.00354	21	0.0000
ARIMA	NA	NA	0.01242	0.00352	20	0.0000
LSTM1	1	[1]	0.00703	0.00265	19	0.0035
LSTM2	1	[2]	0.00681	0.00261	18	0.0025
LSTM3	1	[3]	0.00639	0.00253	13	0.0341
LSTM4	1	[4]	0.00621	0.00249	6	0.1114
LSTM5	1	[5]	0.00647	0.00254	16	0.0332
LSTM6	2	[2,1]	0.00654	0.00256	17	0.0033
LSTM7	2	[2,2]	0.00635	0.00252	10	0.0483
LSTM8	2	[3,1]	0.00638	0.00253	12	0.0341
LSTM9	2	[3,2]	0.00637	0.00252	11	0.0332
LSTM10	2	[3,3]	0.00616	0.00248	5	0.1114
LSTM11	2	[4,1]	0.00642	0.00253	15	0.0341
LSTM12	2	[4,2]	0.00641	0.00253	14	0.0341
LSTM13	2	[4,3]	0.00605	0.00246	2	0.7473
LSTM14	2	[4,4]	0.00608	0.00247	3	0.7082
LSTM15	2	[5,1]	0.00633	0.00252	8	0.0341
LSTM16	2	[5,2]	0.00627	0.00250	7	0.0483
LSTM17	2	[5,3]	0.00602	0.00245	1	1.0000
LSTM18	2	[5,4]	0.00633	0.00252	9	0.0341
LSTM19	2	[5,5]	0.00615	0.00248	4	0.2252

Fonte: Elaborado pela autora.

Tabela 3.6 - *Model Confidence Set* $\widehat{\mathcal{M}}^{*}_{90\%}$*:* EUR/USD

Modelos	**RMSE**	**MCS p-valor**	**Redução % do RMSE em relação ao RW**	**Redução % do RMSE em relação ao ARIMA**
LSTM4	0.00249	0.1114	29.7%	29.3%
LSTM10	0.00248	0.1114	29.9%	29.5%
LSTM13	0.00246	0.7473	30.5%	30.1%
LSTM14	0.00247	0.7082	30.2%	29.8%
LSTM17	0.00245	1.0000	30.8%	30.4%
LSTM19	0.00248	0.2252	29.9%	29.5%

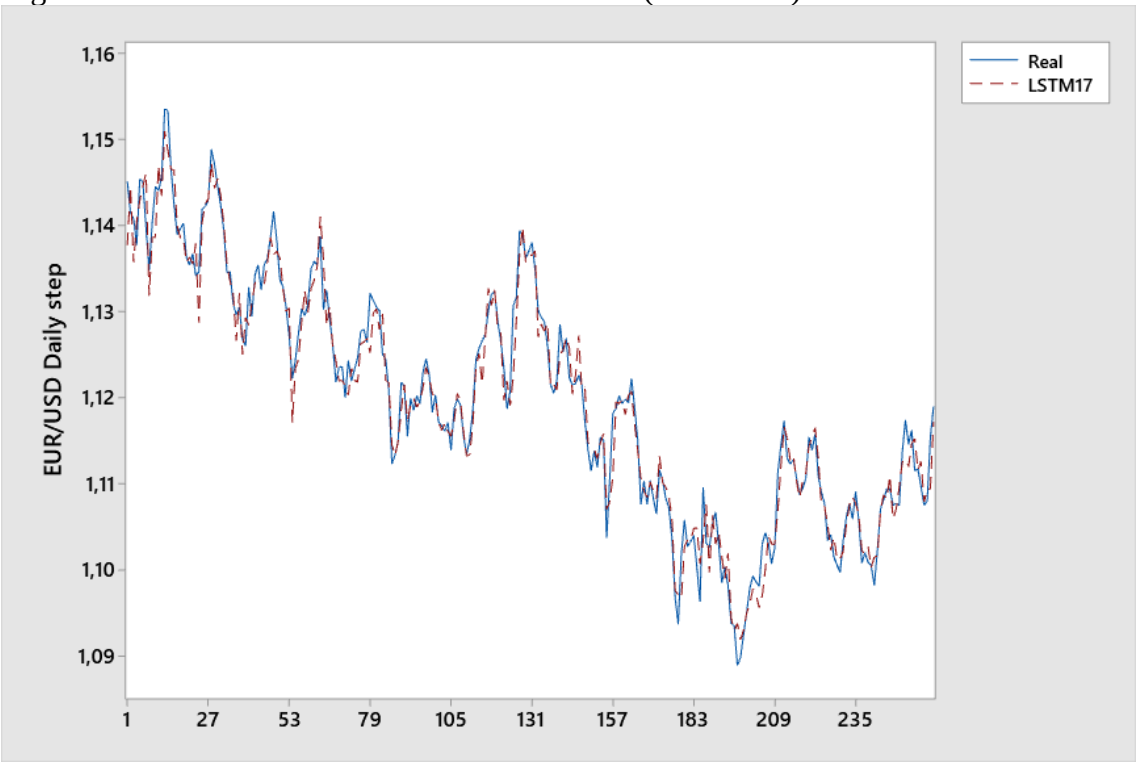
Fonte: Elaborado pela autora.

As medidas de avaliação do desempenho da previsão MSE, RMSE, ranking RMSE e p-valor do MCS para a previsão fora de amostra da taxa de câmbio diária (EUR/USD) e a arquitetura dos modelos testados são apresentados na Tabela 3.5.

A partir dos resultados obtidos com a aplicação do MCS, apresentados na Tabela 3.6, é possível concluir que os modelos LSTM13, LSTM14 e LSTM17 pertencem ao conjunto $\widehat{\mathcal{M}}^{*}_{75\%}$, o que indica a sua superioridade sobre os demais modelos para a previsão da taxa de câmbio (EUR/USD) para $\alpha = 25\%$. Para $\alpha = 10\%$; é possível determinar a superioridade preditiva do conjunto de modelos apresentados na Tabela 3.6. Assim, dos 21 modelos testados utilizando-se a série em frequência diária, 6 configurações do modelo LSTM pertencem ao conjunto dos melhores modelos $\widehat{\mathcal{M}}^{*}_{90\%}$.

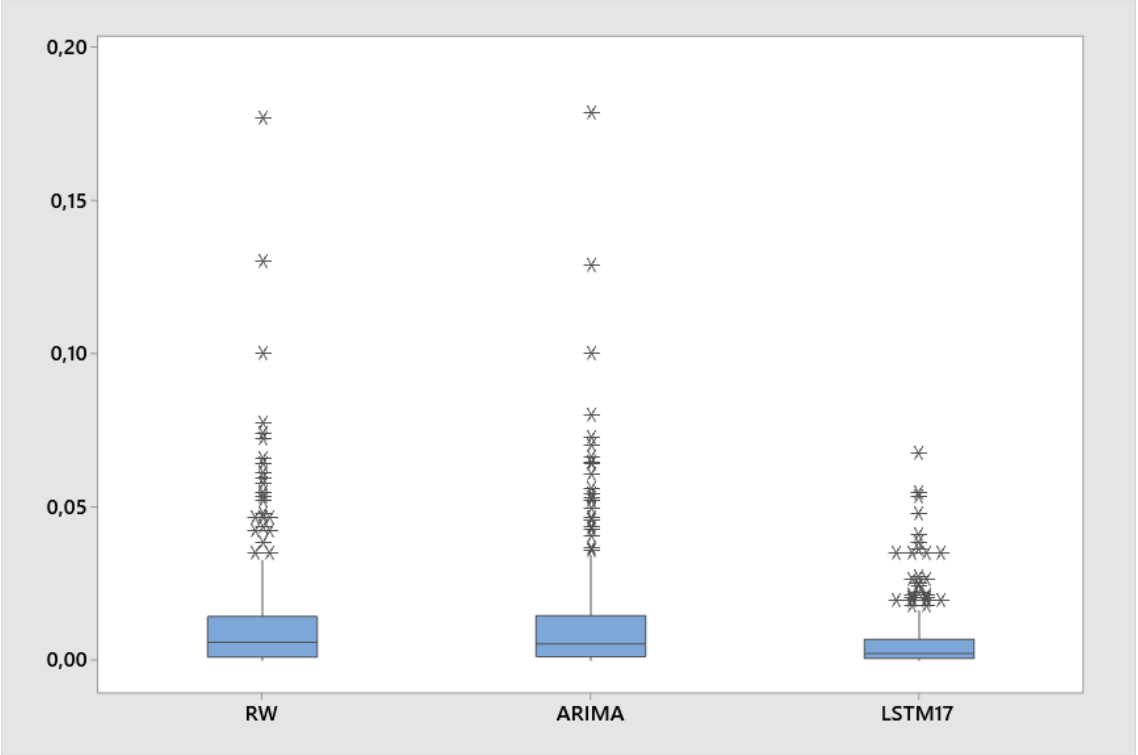
Entre os modelos selecionados, o LSTM17 (duas camadas, sendo cinco neurônios na primeira e três na segunda) destaca-se por apresentar o menor RMSE de 0.00245, contra 0.00354, do modelo RW. Em termos percentuais, representa uma redução no erro de previsão de 30,8% quando comparado ao modelo RW e, 30,4% em relação ao ARIMA. Quando comparado ao modelo que apresenta maior RMSE, ou seja, LSTM4, a redução no erro de previsão é de 29,7% e 29,3%, respectivamente. A previsão realizada pelo modelo LSTM17 e o valor observado da taxa de câmbio EUR/USD são visualizados na Figura 3.7.

Figura 3-7 – Gráfico: Previsão da taxa de câmbio (EUR/USD)



Fonte: Elaborado pela autora.

Figura 3-8 – Gráfico *Box-plot* MSE (EUR/USD)



Fonte: Elaborado pela autora.

Tabela 3.7 - Estatística Descritiva do MSE (EUR/USD)

Modelos	MSE(*10^3)	Mínimo	Q1	Mediana	Q3	Máximo
RW	0.01250	0.00000	0.00100	0.00576	0.01425	0.17689
ARIMA	0.01242	0.00000	0.00106	0.00520	0.01449	0.17864
LSTM1	0.00703	0.00000	0.00049	0.00289	0.00784	0.08836
LSTM2	0.00681	0.00000	0.00064	0.00256	0.00716	0.08649
LSTM3	0.00639	0.00000	0.00049	0.00225	0.00676	0.08100
LSTM4	0.00621	0.00000	0.00049	0.00225	0.00676	0.07744
LSTM5	0.00647	0.00000	0.00053	0.00196	0.00716	0.07569
LSTM6	0.00654	0.00000	0.00049	0.00225	0.00716	0.07744
LSTM7	0.00635	0.00000	0.00064	0.00225	0.00784	0.07396
LSTM8	0.00638	0.00000	0.00064	0.00225	0.00770	0.07225
LSTM8	0.00638	0.00000	0.00064	0.00225	0.00770	0.07225
LSTM9	0.00637	0.00000	0.00064	0.00225	0.00716	0.07225
LSTM10	0.00616	0.00000	0.00064	0.00196	0.00716	0.06889
LSTM11	0.00642	0.00000	0.00053	0.00225	0.00676	0.07744
LSTM12	0.00641	0.00000	0.00049	0.00196	0.00729	0.06889
LSTM13	0.00605	0.00000	0.00049	0.00196	0.00676	0.07056
LSTM14	0.00608	0.00000	0.00049	0.00196	0.00676	0.06889
LSTM15	0.00633	0.00000	0.00064	0.00196	0.00784	0.07569
LSTM16	0.00627	0.00000	0.00064	0.00196	0.00729	0.06889
LSTM17	0.00602	0.00000	0.00049	0.00210	0.00676	0.06724
LSTM18	0.00633	0.00000	0.00049	0.00225	0.00676	0.06561
LSTM19	0.00615	0.00000	0.00049	0.00225	0.00676	0.06561

Fonte: Elaborado pela autora.

Adicionalmente, outro fato importante observado pela comparação visual, Figura 3.8, dos modelos RW, ARIMA e LSTM17, relaciona-se à variabilidade e aos valores extremos do MSE. Os modelos RW e ARIMA possuem uma maior dispersão e valores extremos quando comparado ao melhor modelo selecionado pelo MCS (LSTM17). A Tabela 3.7 apresenta as estatísticas descritivas do MSE de todos os modelos. Os modelos RW e ARIMA destacam-se por apresentar maiores MSE (valores medianos, primeiro, terceiro quartil e máximo).

Em relação à precisão em detectar a direção do movimento da taxa de câmbio, observa-se, na Tabela 3.8, que a H0 é rejeitada para o modelo ARIMA. Entretanto, a H0 não é rejeitada para os modelos de rede neural LSTM. Desta forma, é possível afirmar que a previsão (DA) dos modelos LSTM é superior ao modelo ARIMA e RW, uma vez que a acurácia geral dos modelos de rede neural analisados, varia de 76.5% a 80.3%, destacando-se os modelos LSTM10, LSTM17 e LSTM18, que apresentam maior acurácia quando comparados aos demais modelos. Entre estes modelos somente o LSTM18 não faz parte do conjunto selecionado pelo MCS (Tabela 3.6).

Tabela 3.8 - Precisão da previsão da direção (DA): EUR/USD

Modelo	Acurácia (DA)	Taxa de Não Informação (NIR)	95% CI	p-valor [DA > NIR]
ARIMA	0.5405	0.5290	(0.4778, 0.6024)	0.3783
LSTM1	0.7683	0.5290	(0.7121, 0.8183)	1.49E-15
LSTM2	0.7645	0.5290	(0.7080, 0.8148)	4.37E-15
LSTM3	0.7683	0.5290	(0.7121, 0.8183)	1.49E-15
LSTM4	0.7683	0.5290	(0.7121, 0.8183)	1.49E-15
LSTM5	0.7838	0.5290	(0.7286, 0.8323)	2.00E-16
LSTM6	0.7876	0.5290	(0.7327, 0.8358)	2.00E-16
LSTM7	0.7761	0.5290	(0.7203, 0.8253)	2.00E-16
LSTM8	0.7799	0.5290	(0.7245, 0.8288)	2.00E-16
LSTM9	0.7915	0.5290	(0.7369, 0.8393)	2.00E-16
LSTM10	0.7992	0.5290	(0.7452, 0.8463)	2.00E-16
LSTM11	0.7954	0.5290	(0.7410, 0.8428)	2.00E-16
LSTM12	0.7915	0.5290	(0.7369, 0.8393)	2.00E-16
LSTM13	0.7876	0.5290	(0.7327, 0.8358)	2.00E-16
LSTM14	0.7838	0.5290	(0.7286, 0.8323)	2.00E-16
LSTM15	0.7799	0.5290	(0.7245, 0.8288)	2.00E-16
LSTM16	0.7838	0.5290	(0.7286, 0.8323)	2.00E-16
LSTM17	0.7992	0.5290	(0.7452, 0.8463)	2.00E-16
LSTM18	0.8031	0.5290	(0.7494, 0.8497)	2.00E-16
LSTM19	0.7954	0.5290	(0.7410, 0.8428)	2.00E-16

Fonte: Elaborado pela autora.

3.7.3. GBP/USD

A amostra utilizada para treinamento da rede neural contém 1295 observações, das quais 1035 são utilizadas para treinamento e validação e o restante, 260 observações para previsão fora da amostra (teste). Assim, o período de 4 de dezembro de 2014 a 19 de dezembro de 2018 é usado para treinamento e validação e o período de 20 de dezembro de 2018 a 30 de dezembro de 2019 para teste do modelo.

Os modelos usados para comparação da previsão da taxa de câmbio são RW e ARIMA. Assim, são testadas as combinações dos parâmetros de 1 a 5 para: o número de defasagens do modelo autorregressivo (AR); o grau de diferenciação (I) e a ordem do modelo de média móvel (MA). O critério de informação Akaike (AIC) é usado para escolher a melhor configuração, sendo o modelo ARIMA (1,1,1) selecionado.

As medidas de avaliação do desempenho da previsão MSE, RMSE, o ranking RMSE e p-valor do MCS para a previsão fora de amostra da taxa de câmbio diária (GBP/USD) e a arquitetura dos modelos testados são apresentados na Tabela 3.9.

Tabela 3.9 - *Model Confidence Set Estimation*: GBP/USD

Modelo	**Nº de Camadas**	**Nº de Neurônios**	**MSE (*10^3)**	**RMSE**	**Ranking RMSE**	**MCS p-valor**
RW	NA	NA	0.04848	0.00696	20	0.0323
ARIMA	NA	NA	0.04911	0.00701	21	0.0075
LSTM1	1	[1]	0.04741	0.00689	19	0.0075
LSTM2	1	[2]	0.03690	0.00607	2	0.4943
LSTM3	1	[3]	0.03642	0.00603	1	1.0000
LSTM4	1	[4]	0.03784	0.00615	7	0.1379
LSTM5	1	[5]	0.03700	0.00608	3	0.4943
LSTM6	2	[2,1]	0.03729	0.00611	5	0.4943
LSTM7	2	[2,2]	0.03926	0.00627	11	0.1379
LSTM8	2	[3,1]	0.04708	0.00686	18	0.0003
LSTM9	2	[3,2]	0.04177	0.00646	13	0.0457
LSTM10	2	[3,3]	0.04477	0.00669	15	0.0017
LSTM11	2	[4,1]	0.04043	0.00636	12	0.1196
LSTM12	2	[4,2]	0.03759	0.00613	6	0.2179
LSTM13	2	[4,3]	0.03838	0.00620	9	0.1196
LSTM14	2	[4,4]	0.04547	0.00674	17	0.0004
LSTM15	2	[5,1]	0.03865	0.00622	10	0.1196
LSTM16	2	[5,2]	0.03721	0.00610	4	0.4430
LSTM17	2	[5,3]	0.04503	0.00671	16	0.0253
LSTM18	2	[5,4]	0.04227	0.00650	14	0.0813
LSTM19	2	[5,5]	0.03815	0.00618	8	0.1196

Fonte: Elaborado pela autora.

Tabela 3.10 - *Model Confidence Set* $\widehat{\mathcal{M}}^{*}_{90\%}$*:* (GBP/USD)

Modelos	**RMSE**	**MCS p-valor**	**Redução % do RMSE em relação ao RW**	**Redução % do RMSE em relação ao ARIMA**
LSTM2	0.00607	0.4943	12.8%	13.4%
LSTM3	0.00603	1.0000	13.4%	14.0%
LSTM4	0.00615	0.1379	11.6%	12.3%
LSTM5	0.00608	0.4943	12.6%	13.3%
LSTM6	0.00611	0.4943	12.2%	12.8%
LSTM7	0.00627	0.1379	9.9%	10.6%
LSTM11	0.00636	0.1196	8.6%	9.3%
LSTM12	0.00613	0.2179	11.9%	12.6%
LSTM13	0.00620	0.1196	10.9%	11.6%
LSTM15	0.00622	0.1196	10.6%	11.3%
LSTM16	0.00610	0.4430	12.4%	13.0%
LSTM19	0.00618	0.1196	11.2%	11.8%

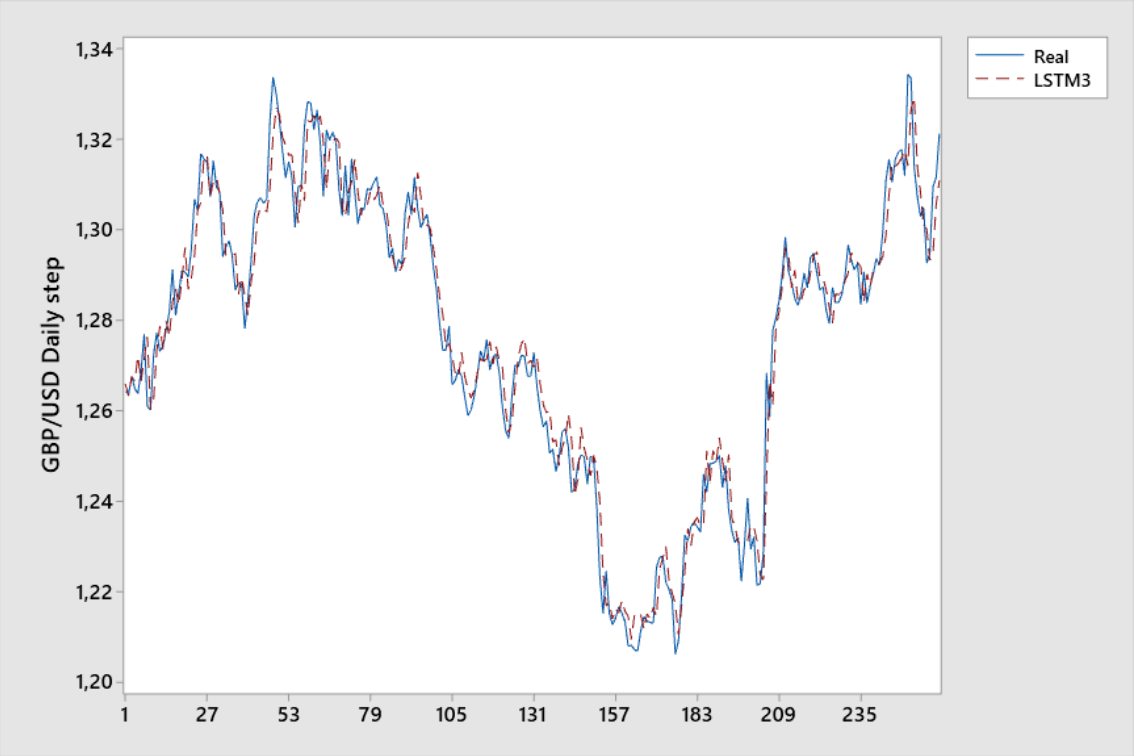
Fonte: Elaborado pela autora.

Observa-se que os modelos LSTM2, LSTM3, LSTM5, LSTM6 e LSTM16 pertencem ao conjunto $\widehat{\mathcal{M}}^{*}_{75\%}$, o que indica a sua superioridade sobre os demais modelos para a previsão

da taxa de câmbio EUR/USD para α = 25%. Para α = 10%; é possível determinar a superioridade preditiva do conjunto de modelos apresentados na Tabela 3.10. Assim, dos 21 modelos testados utilizando-se a série em frequência diária, 12 configurações do modelo LSTM pertencem ao conjunto dos melhores modelos $\widehat{\mathcal{M}}^{*}_{90\%}$.

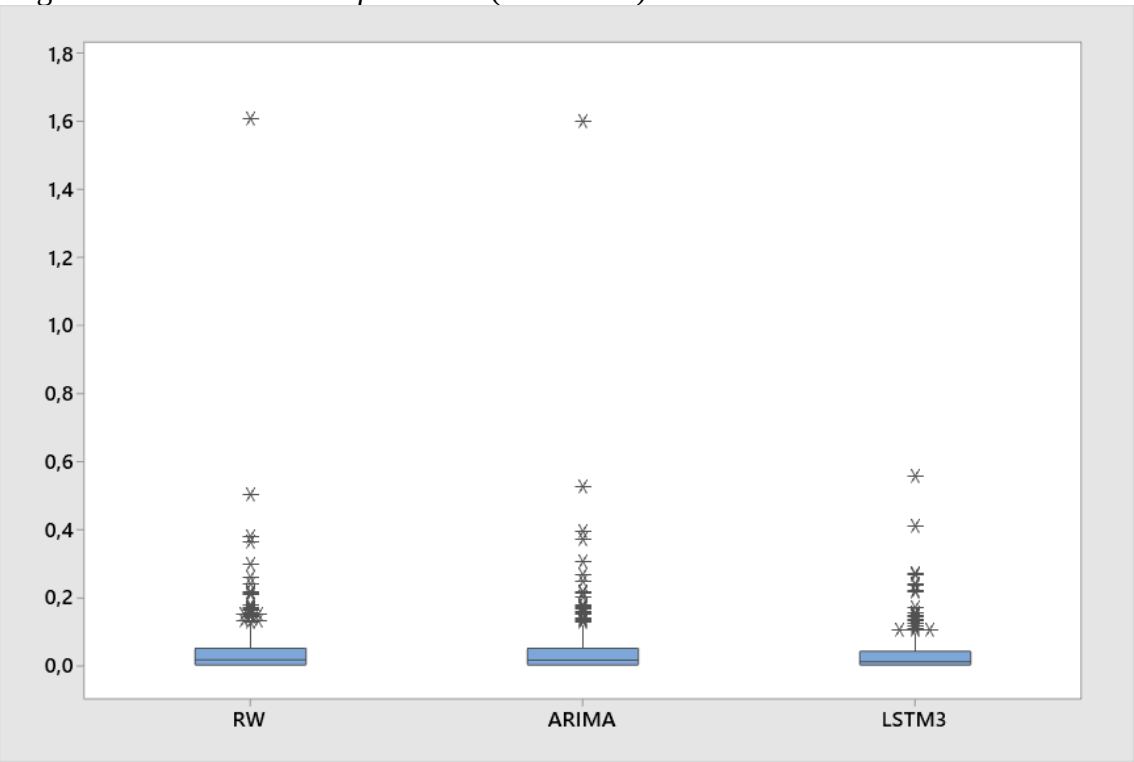
Entre os modelos selecionados, o LSTM3 (uma camada e três neurônios) destaca-se por apresentar o menor RMSE de 0.00603, contra 0.00696, do modelo RW. Isto representa uma redução no erro de previsão de 13,4% quando comparado ao modelo passeio aleatório e, 14,0% em relação ao ARIMA. Quando comparado ao modelo que apresenta maior RMSE, ou seja, LSTM7, a redução no erro de previsão é de 9,9% e 10,6%, respectivamente. A previsão realizada pelo modelo LSTM3 e o valor observado da taxa de câmbio GBP/USD são visualizados na Figura 3.9.

Figura 3-9 - Previsão da taxa de câmbio (GBP/USD)



Fonte: Elaborado pela autora.

Figura 3-10 – Gráfico *Box-plot* MSE (GBP/USD)



Fonte: Elaborado pela autora.

Tabela 3.11 - Estatística Descritiva do MSE (GBP/USD)

Modelo	**MSE**	**Mínimo**	**Q1**	**Mediana**	**Q3**	**Máximo**
RW	0.04848	0.00000	0.00256	0.01849	0.05184	1.60801
ARIMA	0.04911	0.00000	0.00307	0.01746	0.05160	1.60005
LSTM1	0.04741	0.00000	0.00400	0.01937	0.06807	0.82944
LSTM2	0.03690	0.00000	0.00324	0.01226	0.04624	0.45796
LSTM3	0.03642	0.00000	0.00289	0.01225	0.04323	0.55696
LSTM4	0.03784	0.00000	0.00324	0.01483	0.04356	0.55225
LSTM5	0.03700	0.00000	0.00264	0.01089	0.05041	0.56169
LSTM6	0.03729	0.00000	0.00264	0.01333	0.05041	0.77841
LSTM7	0.03926	0.00000	0.00264	0.01156	0.04423	1.10224
LSTM8	0.04708	0.00000	0.00441	0.01681	0.04865	0.91204
LSTM8	0.04708	0.00000	0.00441	0.01681	0.04865	0.91204
LSTM9	0.04177	0.00000	0.00333	0.01483	0.04900	0.69696
LSTM10	0.04477	0.00000	0.00324	0.01483	0.04489	0.78961
LSTM11	0.04043	0.00001	0.00256	0.01444	0.04831	1.04976
LSTM12	0.03759	0.00000	0.00289	0.01261	0.03969	0.58081
LSTM13	0.03838	0.00000	0.00289	0.01369	0.03721	0.66564
LSTM14	0.04547	0.00000	0.00361	0.01640	0.04727	0.79524
LSTM15	0.03865	0.00000	0.00256	0.01483	0.04356	0.80656
LSTM16	0.03721	0.00000	0.00289	0.01296	0.04323	0.58564
LSTM17	0.04503	0.00000	0.00333	0.01521	0.04900	1.08900
LSTM18	0.04227	0.00001	0.00324	0.01332	0.04727	1.00489
LSTM19	0.03815	0.00000	0.00256	0.01444	0.04064	0.72900

Fonte: Elaborado pela autora.

Adicionalmente, outros fatores observados pela comparação visual do Gráfico *Box-plot* (Figura 3.10) dos modelos RW, ARIMA e LSTM3, consistem na variabilidade e nos valores extremos do MSE. Os modelos RW e ARIMA possuem uma maior dispersão e valores extremos quando comparados ao melhor modelo selecionado pelo MCS (LSTM3). A Tabela 3.11 apresenta as estatísticas descritivas do MSE (em valores mil) de todos os modelos.

Em relação à precisão em detectar a direção do movimento da taxa de câmbio, observa-se, na Tabela 3.12, que a H0 é rejeitada para o modelo ARIMA. Entretanto, a H0 não é rejeitada para os modelos de rede neural LSTM. Assim, pode-se afirmar que a previsão dos modelos LSTM é superior ao modelo ARIMA e RW, sendo que a acurácia geral (DA) dos modelos de rede neural analisados varia de 56.0% a 66.8%. Os modelos LSTM3 e LSTM6 apresentam maior acurácia quando comparados aos demais modelos. Estes modelos fazem parte do conjunto selecionado pelo MCS (Tabela 3.10).

Tabela 3.12 - Precisão da previsão da direção – DA (GBP/USD)

Modelo	**Acurácia**	**No Information Rate (NIR)**	**95% CI**	**P-Value [Acc > NIR]**
ARIMA	0.46720	0.5019	(0.4052, 0.5299)	0.8811
LSTM1	0.61780	0.5019	(0.5556, 0.6772)	1.16E-04
LSTM2	0.65640	0.5019	(0.5951, 0.7141)	3.74E-07
LSTM3	0.66800	0.5019	(0.6070, 0.7250)	4.87E-08
LSTM4	0.64090	0.5019	(0.5792, 0.6994)	4.49E-06
LSTM5	0.65250	0.5019	(0.5911, 0.7104)	7.13E-07
LSTM6	0.66800	0.5019	(0.6070, 0.7250)	4.87E-08
LSTM7	0.64090	0.5019	(0.5792, 0.6994)	4.49E-06
LSTM8	0.55980	0.5019	(0.4971, 0.6212)	3.57E-02
LSTM9	0.60620	0.5019	(0.5438, 0.6661)	4.75E-04
LSTM10	0.59070	0.5019	(0.5282, 0.6512)	2.53E-03
LSTM11	0.59460	0.5019	(0.5321, 0.6549)	1.70E-03
LSTM12	0.64480	0.5019	(0.5832, 0.7030)	2.47E-06
LSTM13	0.62160	0.5019	(0.5595, 0.6809)	7.00E-05
LSTM14	0.56760	0.5019	(0.5048, 0.6288)	2.00E-02
LSTM15	0.65640	0.5019	(0.5951, 0.7141)	3.74E-07
LSTM16	0.62930	0.5019	(0.5951, 0.7141)	2.45E-05
LSTM17	0.58300	0.5019	(0.5204, 0.6437)	5.35E-03
LSTM18	0.61000	0.5019	(0.5477, 0.6698)	3.01E-04
LSTM19	0.62930	0.5019	(0.5674, 0.6883)	2.45E-05

Fonte: Elaborado pela autora.

3.8. Conclusões Parciais

Este estudo propõe-se a verificar a capacidade preditiva do modelo de rede neural recorrente LSTM na previsão de taxa de câmbio utilizando os indicadores técnicos (preços de abertura, fechamento, máximo e mínimo) como variável de entrada (explicativa). Para a seleção de modelos, é aplicado o *Model Confidence Set* (MCS) de Hansen, Lunde e Nason (2002,2011). Devido às críticas ao uso de métricas estatísticas com base na magnitude do erro de previsão (LEITCH; TANNER, 1991; INCE; BURNS; MOOSA, 2017; CEBECI; IMAMOGLU, 2019), adicionalmente, é verificada a capacidade preditiva em termos de precisão da direção.

Observa-se que o modelo RW supera o modelo ARIMA, em termos de RMSE, para as taxas de câmbio para a libra esterlina (GBP/USD) e real (BRL/USD). Em relação ao desempenho do modelo de rede neural recorrente LSTM, observa-se que uma arquitetura mais simples (uma ou duas camadas) é suficiente para captar a dinâmica de todas as moedas, visto que os valores de MSE são inferiores aos dos modelos ARIMA e RW.

Por meio da aplicação do MCS, é possível confirmar que o modelo de rede neural recorrente LSTM apresentado neste estudo pertence ao subconjunto do modelo estatisticamente superior. Este modelo supera as abordagens tradicionais, ARIMA e RW, em termos da magnitude do erro, para todas as moedas testadas (BRL/USD, EUR/USD e GBP/USD), ao se utilizar uma defasagem dos indicadores técnicos (preço de abertura, máximo, mínimo e de fechamento). Isto identifica as variáveis de entrada a serem utilizadas, uma vez que este modelo é capaz de lidar com interações não-lineares e multicolinearidade sem qualquer tratamento especial da variável. A seleção cuidadosa de entradas pode melhorar significativamente o desempenho da rede neural (ZHANG; HU,1998; CRONE e KOURENTZES, 2010). Os modelos selecionados pelo MCS, apresentam em média uma redução do RMSE em relação aos modelos RW, entre 22.2% e 19.5% (BRL/USD), 30.8% e 29.7% (EUR/USD) e 13.4% e 9.9% (GBP/USD). Cabe ressaltar que ao aplicar o modelo LSTM na previsão da GBP/USD e EUR/USD, Henríquez e Kristjanpoller (2019), reportam a redução do erro de previsão inferior a 0.5% ao utilizar como entrada, uma defasagem das taxas de câmbio.

Os resultados também mostram que todas as configurações testadas do modelo de rede neural recorrente LSTM superam os modelos RW e ARIMA em todos os casos em termos de precisão da direção, pois a hipótese nula de "taxa de não informação" é rejeitada para todas as taxas de câmbio testadas (Tabelas 3.4, 3.8 e 3.12). Os modelos LSTM apresentam a precisão de direção, entre 72.2% e 67.6% (BRL/USD), 80.3% e 76.5% (EUR/USD) e 66.8% e 56.0% (GBP/USD).

4. Considerações Finais

Em 27 anos de estudo sobre a previsão de taxa de câmbio com redes neurais, esta ainda é uma área de pesquisa ativa, na qual se observa um aumento de 32% no número de publicações no último triênio. Os Estados Unidos, a Índia e o Reino Unido encontram-se à frente dos demais países no ranking de publicações. O Brasil, na 7ª colocação, demonstra que o campo nacional de estudos sobre o tema encontra-se ainda pouco explorado e evidencia a necessidade de realização de um maior número de pesquisa com inserção internacional.

Verifica-se, também, que a maior parte das fontes de publicação é representada por periódicos da área de computação, consequentemente resultando em aplicabilidade dos algoritmos nesta área de interesse, distanciada, portanto, do enfoque financeiro e econômico. Cabe aos pesquisadores da área financeira e econômica determinar quais variáveis seriam adequadas aos seus modelos. Além disto, apontar um pesquisador ou um grupo como referência nas discussões sobre o tema, ainda não é possível devido a baixa produtividade dos autores.

Os artigos influentes podem ser categorizados em: aqueles que objetivam estabelecer procedimentos sistemáticos de configuração das redes neurais; outros que comparam o desempenho da previsão entre modelos. Em relação aos últimos, é indispensável que nos procedimentos de comparação sejam utilizados os modelos ingênuos, como o RW. Entretanto, alguns estudos não realizam esta comparação. Tão importante quanto realizar esta comparação, é estabelecer um modelo de referência em redes neurais a ser superado.

Entre os modelos de rede neural, o LSTM poderia ser considerado o modelo de referência, visto que considera a dimensão temporal dos dados e propõe uma solução para o problema da instabilidade apresentados pelo modelo de rede neural recorrente tradicional. Assim, o presente estudo propõe-se a verificar a capacidade preditiva do modelo de rede neural recorrente LSTM na previsão de taxa de câmbio utilizando os indicadores técnicos (preços de abertura, fechamento, máximo e mínimo) como variável de entrada. Estas variáveis representam a interação entre tendência e volatilidade, contendo assim, informação sobre a evolução futura dos preços. Portanto, podem ser utilizadas para a previsão da taxa de câmbio.

Por meio da aplicação do MCS, é possível confirmar que o modelo de rede neural recorrente LSTM apresentado neste estudo pertence ao subconjunto do modelo estatisticamente superior, superando as abordagens tradicionais, ARIMA e RW, em termos da magnitude do erro e de precisão da direção (DA), para todas as moedas testadas (BRL/USD, EUR/USD e

GBP/USD), ao se utilizar uma defasagem dos indicadores técnicos (preço abertura, máximo, mínimo e fechamento).

REFERÊNCIAS

ABU-MOSTAFA, Y.S.; ATIYA, A.F. Introduction to financial forecasting. *Applied Intelligence*, v. 6, n. 3, p. 205-213, 1996.

ANDRÉS, A. Measuring academic research: How to undertake a bibliometric study. Elsevier, 2009.

ALVAREZ-DIAZ, M. Exchange rates forecasting: local or global methods? *Applied Economics*, v. 40, n. 15, p. 1969-1984, 2008.

ARIA, M.; CUCCURULLO, C. bibliometrix: An R-tool for comprehensive science mapping analysis. *Journal of Informetrics*, v. 1, n. 4, p. 959-975, 2017.

ARIFOVIC, J.; GENCAY, R. Statistical properties of genetic learning in a model of exchange rate. *Journal of Economic Dynamics and Control*, v. 24, n. 5-7, p. 981-1005, 2000.

AZEVEDO, J. V.; PEREIRA, A. Macroeconomic Forecasting using Low-frequency Filters. *Oxford Bulletin of Economics and Statistics*, v. 80, n. 1, p. 39-64, 2018.

BANKS, M. G. An extension of the Hirsch index: Indexing scientific topics and compounds. *Scientometrics*, v. 69, n.1, p.161-168, 2006.

BAO, W.; YUE, J.; RAO, Y. A deep learning framework for financial time series using stacked autoencoders and long-short term memory. *PloS one*, v. 12, n. 7, p. e0180944, 2017.

BATES, J.M.; GRANGER, C.W.J. The combination of forecasts. *Journal of the Operational Research Society*, v. 20, n. 4, p. 451-468, 1969.

BERGH, D. D.; PERRY, J.; HANKE, R. Some predictors of SMJ article impact. *Strategic Management Journal*, v.27, n1, p. 81-100, 2006.

BERRY, L.L.; PARASURAMAN, A. Building a new academic field-the case of services marketing. *Journal of Retailing*, v. 69, n.1, p. 13-60, 1993.

BOUKTIF, S.; FIAZ, A.; OUNI, A.; SERHANI, M. Optimal deep learning lstm model for electric load forecasting using feature selection and genetic algorithm: Comparison with machine learning approaches. *Energies*, v. 11, n. 7, p. 1636, 2018.

BOX, G. E. P.; JENKINS, G. M. *Time series analysis forecasting and control*. San Francisco: Holden- Day, 1976. Edição revisada.

BROOKES, B. C. Bradford's law and the bibliography of science. Nature, *v. 224, p. 953-956, 1969.*

CARVALHO, M.M.; FLEURY, A.; LOPES, A. P. An overview of the literature on technology roadmapping (TRM): Contributions and trends. *Technological Forecasting and Social Change*, v.80, n.7, p.1418-1437, 2013.

CAVALCANTE, R.C.; BRASILEIRO, R.C; SOUZA, V.L.; NOBREGA, J.P.; OLIVEIRA, A.L. Computational intelligence and financial markets: A survey and future directions. *Expert Systems with Applications*, v. 55, n.1, p. 194-211, 2016.

CHAKRA, N. C.; SONG, K.Y; GUPTA, M.M.; SARAF, D.N. An innovative neural forecast of cumulative oil production from a petroleum reservoir employing higher-order neural networks (HONNs). *Journal of Petroleum Science and Engineering*, v. 106, n.1, p. 18-33, 2013.

CHEN, A; LEUNG, M. T. Performance evaluation of neural network architectures: the case of predicting foreign exchange correlations. *Journal of Forecasting*, v. 24, n.6, p. 403-420, 2005.

CHEN, J.; ZENG, G.Q.; ZHOU, W.; DU, W.; LU, K.D. Wind speed forecasting using nonlinear-learning ensemble of deep learning time series prediction and extremal optimization. *Energy Conversion and Management*, v. 165, n.1, p. 681-695, 2018.

CRONE, S. F.; KOURENTZES, N. Feature selection for time series prediction–A combined filter and wrapper approach for neural networks. *Neurocomputing*, v.73, n. 10.12, p. 1923-1936, 2010

CUCCURULLO, C.; ARIA, M.; SARTO, F. Foundations and trends in performance management. A twenty-five years bibliometric analysis in business and public administration domains. *Scientometrics*, v. 108, n. 2, p. 595-611, 2016.

FIESS, N. M.; MacDONALD, R. Technical analysis in the foreign exchange market: A cointegration-based approach. *Multinational Finance Journal*, v. 3, n.3, p.147-172, 1999.

FIESS, N. M.; MacDONALD, R. Towards the fundamentals of technical analysis: analysing the information content of high, low and close prices. *Economic Modelling*, v.19, n.3, p.353-374, 2002.

FISCHER, T.; KRAUSS, C. Deep learning with long short-term memory networks for financial market predictions. *European Journal of Operational Research*, v. 270, n. 2, p. 654-669, 2018.

GALESHCHUK, S. Neural networks performance in exchange rate prediction. *Neurocomputing*, v.172, n.1, p.446-452, 2016

GARFIELD, E.; MERTON, R. K. *Citation indexing: Its theory and application in science, technology, and humanities*. New York: Wiley, 1979.

GILES, C. L.; LAWRENCE, S.; TSOI, A. C. Noisy time series prediction using recurrent neural networks and grammatical inference. *Machine learning*, v.44, n. 1-2, p. 61-183, 2001.

GRADOJEVIC, N.; GENÇAY, R.; KUKOLJ, D. Option pricing with modular neural networks. *IEEE transactions on neural networks*, v.20, n.4, p. 626-637, 2009.

GU, S.; KELLY, B.; XIU, D. Empirical asset pricing via machine learning. *The Review of Financial Studies*, v. 33, n. 5, p. 2223-2273, 2020.

GUO, Z.; WANG, H.; LIU, Q.; YANG, J. A feature fusion based forecasting model for financial time series. *PloS one*, v. 9, n. 6, p. e101113, 2014.

HANN, T. H.; STEURER, E. Much ado about nothing? Exchange rate forecasting: Neural networks vs. linear models using monthly and weekly data. *Neurocomputing*, v. 10, n.4, p. 323-339, 1996.
HANSEN, P. R.; LUNDE, A.; NASON, J.M. Choosing the best volatility models: the model confidence set approach. **Oxford Bulletin of Economics and Statistics**, v. 65, n.1, p. 839-861, 2003.

HANSEN, P.R.; LUNDE, A.; NASON, J. M. The model confidence set. *Econometrica*, v. 79, n. 2, p. 453-497, 2011.

HIRSCH, J.E. An index to quantify an individual's scientific research output. *Proceedings of the National academy of Sciences*, v. 102, n. 46, p. 16569-16572, 2005.

HOCHREITER, S. The vanishing gradient problem during learning recurrent neural nets and problem solutions. *International Journal of Uncertainty, Fuzziness and Knowledge-Based Systems*, v. 6, n.2, p. 107-116, 1998.

HOCHREITER, S.; SCHMIDHUBER, J. Long short-term memory. *Neural Computation*, v. 9, n. 8, p. 1735-1780, 1997.

HOLLAND, J. H. Genetic algorithms. *Scientific american*, v. 267, n. 1, p. 66-73, 1992.

HOMRICH, A. S.; GALVÃO, G., ABADIA, L. G.; CARVALHO, M. M. The circular economy umbrella: Trends and gaps on integrating pathways. *Journal of Cleaner Production*, v.175, n.1, p. 525-543, 2018.

HORNIK, K.; STINCHCOMBR, M.; WHITE, H. Multilayer feedforward networks are universal approximators. *Neural Networks*, v2, n.5, p. 359-366, 1989.

HUANG, W.; LAI, K.; NAKAMORI, Y.; WANG, S. Forecasting foreign exchange rates with artificial neural networks: a review. *International Journal of Information Technology & Decision Making*, v. 3, n. 1, p. 145-165, 2004.

HYNDMAN, R. J.; ATHANASOPOULOS, G. *Forecasting: principles and practice*. OTexts, 2018.

KHASHEI, M.; BIJARI, M.; ARDALI, G. A. R. Improvement of auto-regressive integrated moving average models using fuzzy logic and artificial neural networks (ANNs). *Neurocomputing*, v.72.; n. 4-6, p. 956-967, 2009.

KILIAN, L.; TAYLOR, M. P. Why is it so difficult to beat the random walk forecast of exchange rates? *Journal of International Economics*, v. 60, n. 1, p. 85-107, 2003.

KIM, H. Y.; WON, C. H. Forecasting the volatility of stock price index: A hybrid model integrating LSTM with multiple GARCH-type models. *Expert Systems with Applications*, v. 103, n.1, p. 25-37, 2018.

KODOGIANNIS, V.; LOLIS, A. Forecasting financial time series using neural network and fuzzy system-based techniques. *Neural Computing & Applications*, v. 11, n. 2, p. 90-102, 2002.

KRISTJANPOLLER, W.; MINUTOLO, M.C. A hybrid volatility forecasting framework integrating GARCH, artificial neural network, technical analysis and principal components analysis. *Expert Systems with Applications*, v. 109, n.1, p. 1-11, 2018.
KUAN, C. M.; LIU, T. Forecasting exchange rates using feedforward and recurrent neural networks. *Journal of applied econometrics*, v.10, n.4, p. 347-364, 1995.

LAHMIRI, S. A variational mode decomposition approach for analysis and forecasting of economic and financial time series. *Expert Systems with Applications*, v.55, n.1, p. 268-273, 2016.

LAWRENZ, C.; WESTERHOFF, F. Modeling exchange rate behavior with a genetic algorithm. *Computational Economics*, v. 21, n. 3, p. 209-229, 2003.

LEUNG, M. T.; CHEN, A.; DAOUK, H. Forecasting exchange rates using general regression neural networks. *Computers & Operations Research*, v. 27, n. 11-12, p. 1093-1110, 2000.

LI, D.; WANG, W.; ISMAIL, F. Fuzzy neural network technique for system state forecasting. *IEEE Transactions on Cybernetics*, v. 43, n. 5, p. 1484-1494, 2013.

LI, Y.; WU, H.; LIU, H. Multi-step wind speed forecasting using EWT decomposition, LSTM principal computing, RELM subordinate computing and IEWT reconstruction. *Energy Conversion and Management*, v. 167, n.1, p. 203-219, 2018.

LIGHT, W. A. Some aspects of radial basis function approximation. In: SINGH, S. P. *Approximation Theory, Spline Functions and Applications*. Dordrecht: Springer, p. 163-190, 1992.

LISI, F.; SCHIAVO, R. A. A comparison between neural networks and chaotic models for exchange rate prediction. *Computational Statistics & Data Analysis*, v.30, n.1, p. 87-102, 1999.

MA, X.; TAO, Z.; WANG, Y.; YU, H.; WANG, Y. Long short-term memory neural network for traffic speed prediction using remote microwave sensor data. *Transportation Research Part C: Emerging Technologies*, v. 54, n.1, p. 187-197, 2015.

MAJHI, R.; PANDA, G.; SAHOO, G. Efficient prediction of exchange rates with low complexity artificial neural network models. *Expert Systems with Applications*, v. 36, n. 1, p. 181-189, 2009.

MAKRIDAKIS, S. The forthcoming Artificial Intelligence (AI) revolution: Its impact on society and firms. *Futures*, v.90, n.1, p. 46-60, 2017.

MARÇAL, E.; HADAD JUNIOR, E. Is It Possible to Beat the Random Walk Model in Exchange Rate Forecasting? More Evidence for Brazilian Case. *Brazilian Review of Finance*, v. 14, n. 1, p. 65-88, 2016.

MEESE, R. A.; ROGOFF, K. Empirical exchange rate models of the seventies: Do they fit out of sample? *Journal of international economics*, v. 14, n. 1, p. 3-24, 1983a.

MEESE, R.; ROGOFF, K. The out-of-sample failure of empirical exchange rate models: sampling error or misspecification? In: *Exchange rates and international macroeconomics*. University of Chicago Press, p. 67-112, 1983b.

MORÉ, J.J. The Levenberg-Marquardt algorithm: implementation and theory. In: *Numerical analysis*. Springer, Berlin, Heidelberg, p. 105-116, 1978.

MOURA, M. L.; LIMA, A. R. S; MENDONÇA, Rodrigo M. Exchange rate and fundamentals: the case of Brazil. *Economia Aplicada*, v. 12, n. 3, p. 395-416, 2008.

NISBET, R.; MINER, G.; YALE, K. *Handbook of Statistical Analysis and Data Mining Applications*. 2nd Edition. Elsevier, 2018.

ORD, K.; FILDES, R.; KORENTZES, N. *Principles of business forecasting*. New York: Wessex Press, 2017.

PANDA, C.; NARASIMHAN, V. Forecasting exchange rate better with artificial neural network. *Journal of Policy Modeling*, v. 29, n. 2, p. 227-236, 2007.

PENG, L.; LIU, S.; LIU, R.; WANG, L. Effective long short-term memory with differential evolution algorithm for electricity price prediction. *Energy*, v. 162, n.1, p. 1301-1314, 2018.

PERDOMO, J. P. J.; BOTELHO, F. B. Messe-Rogoff revisitados: uma análise empírica das projeções para a taxa de câmbio no Brasil. **Encontro Nacional de Economia da Associação Nacional dos Centros de Pós-Graduação em Economia–ANPEC**, v. 35, 2007.

PRADEEPKUMAR, D.; RAVI, V. Forecasting financial time series volatility using particle swarm optimization trained quantile regression neural network. *Applied Soft Computing*, v. 58, n.1, p. 35-52, 2017.

QI, M.; ZHANG, G. P. An investigation of model selection criteria for neural network time series forecasting. *European Journal of Operational Research*, v. 132, n.3, p. 666-680, 2001.

RAVI, V.; PRADEEPKUMAR, D.; DEB, K. Financial time series prediction using hybrids of chaos theory, multi-layer perceptron and multi-objective evolutionary algorithms. *Swarm and Evolutionary Computation*, v.36, n.1, p.136-149, 2017.

REFENES, A. N.; AZEMA-BARAC, M.; CHEN, L.; KAROUSSOS, S. Currency exchange rate prediction and neural network design strategies. *Neural Computing & Applications*, v. 1, n. 1, p. 46-58, 1993.

REFENES, A. N.; ZAPRANIS, A.; FRANCIS, G. Stock performance modeling using neural networks: a comparative study with regression models. *Neural networks*, v. 7, n. 2, p. 375-388, 1994.

REID, David J. Combining three estimates of gross domestic product. *Economica*, v. 35, n. 140, p. 431-444, 1968.

RIVAS, V.; MERELO, J.J.; CASTILHO, P.A.; ARENAS, M.G.; CASTELLANO, J.G. Evolving RBF neural networks for time-series forecasting with EvRBF. *Information Sciences*, v. 165, n. 3-4, p. 207-220, 2004.

ROSSI, B. Exchange rate predictability. *Journal of economic literature,* v. 51, n. 4, p. 1063-1119, 2013.
RUMELHART, David E.; HINTON, Geoffrey E.; WILLIAMS, Ronald J. Learning representations by back-propagating errors. *Nature*, v. 323, n. 6088, p. 533, 1986.

SAGHEER, A.; KOTB, M. Time series forecasting of petroleum production using deep LSTM recurrent networks. *Neurocomputing*, v. 323, n.1, p. 203-213, 2019.

SARNO, L.; TAYLOR, M. P. *The economics of exchange rates*. Cambridge University Press, 2002.

SAUNDERS, M.; LEWIS, P.; THORNHILL, A. *Research methods for business students*. Harlow: Pearson, 2016.

SEABOLD, Skipper; PERKTOLD, Josef. Statsmodels: Econometric and statistical modeling with python. In: *Proceedings of the 9th Python in Science Conference*. Scipy, p. 61, 2010.

SERMPINIS, G.; THEOFILATOS, K.; KARATHANASOPOULOS, A.; GEORGOPOULOS, E.F.; DUNIS, C. Forecasting foreign exchange rates with adaptive neural networks using radial-basis functions and particle swarm optimization. *European Journal of Operational Research*, v. 225, n.3, p. 528-540, 2013.

SHEN, Furao; CHAO, Jing; ZHAO, Jinxi. Forecasting exchange rate using deep belief networks and conjugate gradient method. *Neurocomputing*, v.167, n.1, p. 243-253, 2015.

SMYL, Slawek. A hybrid method of exponential smoothing and recurrent neural networks for time series forecasting. *International Journal of Forecasting*, v.36, n.1, p. 75-85, 2020.

TAYLOR, M. P. The economics of exchange rates. *Journal of Economic literature*, v.33, n.1, p. 13-47, 1995.

TAYLOR, S. J. Forecasting the volatility of currency exchange rates. *International Journal of Forecasting*, v. 3, n.1, p.159-170, 1987.

THEODOSSIOU, P. The stochastic properties of major Canadian exchange rates. *Financial Review*, v. 29, n. 2, p. 193-221, 1994.

TRANFIELD, D.; DENYER, D.; SMART, P. Towards a methodology for developing evidence-informed management knowledge by means of systematic review. *British Journal of Management*, v. 14, n.3, p. 207-222, 2003.

VAN ECK, N. J.; WALTMAN, L. VOSviewer (Version 1.6. 13). 2019.

WALCZAK, S. An empirical analysis of data requirements for financial forecasting with neural networks. *Journal of management information systems*, v.17, n.4, p.203-222, 2001.

WANG, Baohua; HUANG, Hejiao; WANG, Xiaolong. A novel text mining approach to financial time series forecasting. *Neurocomputing*, v. 83, n.1, p. 136-145, 2012.

WEIGEND, A. Predicting sunspots and exchange rates with connectionist networks. *Nonlinear Model. Forecasting J.*, p. 395-432, 1992.

WERBOS, P. J. Backpropagation through time: what it does and how to do it. *Proceedings of the IEEE*, v. 78, n. 10, p. 1550-1560, 1990.

WERBOS, P. J. Beyond Regression: New Tools for Prediction and Analysis in the Behavioral Sciences. Ph. D. dissertation, Harvard University, 1974.

XU, X.; CHEN, X., JIA, F., BROWN, S., GONG, Y., XU, Y. Supply chain finance: A systematic literature review and bibliometric analysis. *International Journal of Production Economics*, v. 204, n.1, p. 160-173, 2018.

YAO, J.; TAN, C. L. A case study on using neural networks to perform technical forecasting of forex. *Neurocomputing*, v. 34, n.1-4, p.79-98, 2000.

YU, L.; WANG, S.; LAI, K. Are Foreign Exchange Rates Predictable? A Literature Review from Artificial Neural Networks Perspective. *Foreign-Exchange-Rate Forecasting with Artificial Neural Networks*, p. 3-23, 2007.

YU, L.; WANG, S.; LAI, K. K. A novel nonlinear ensemble forecasting model incorporating GLAR and ANN for foreign exchange rates. *Computers & Operations Research*, v.32, n. 10, p. 2523-2541, 2005.

YU, L.; WANG, S.; LAI, K. K. *Foreign-exchange-rate forecasting with artificial neural networks*. Springer Science & Business Media, 2010.

ZHANG, G. P. Neural Networks for time-series forecasting. *Handbook of natural computing*, p. 461-477, 2012.

ZHANG, G.; HU, M.Y. Neural network forecasting of the British pound/US dollar exchange rate. *Omega*, v. 26, n.4, p. 495-506, 1998.

ZHANG, G.; PATUWO, B. E.; HU, M.Y. Forecasting with artificial neural networks: The state of the art. *International Journal of Forecasting*, v. 14, n.1, p. 35-62, 1998.

ANEXO A: Gráficos das séries temporais estudadas

Figura A-1 - Taxa de BRL/USD: Fechamento (4 de jan.2014 a 30 de dez.2019)

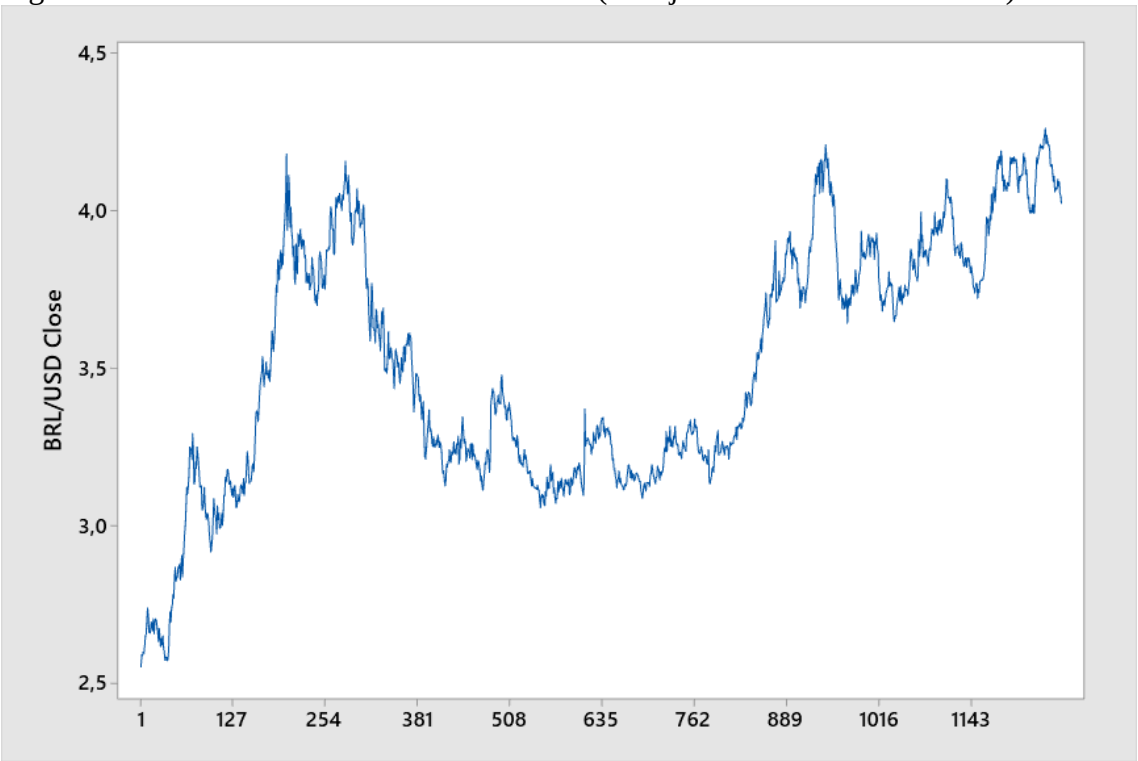


Figura A-2 - Taxa de BRL/USD: Abertura (4 de jan.2014 a 30 de dez.2019)

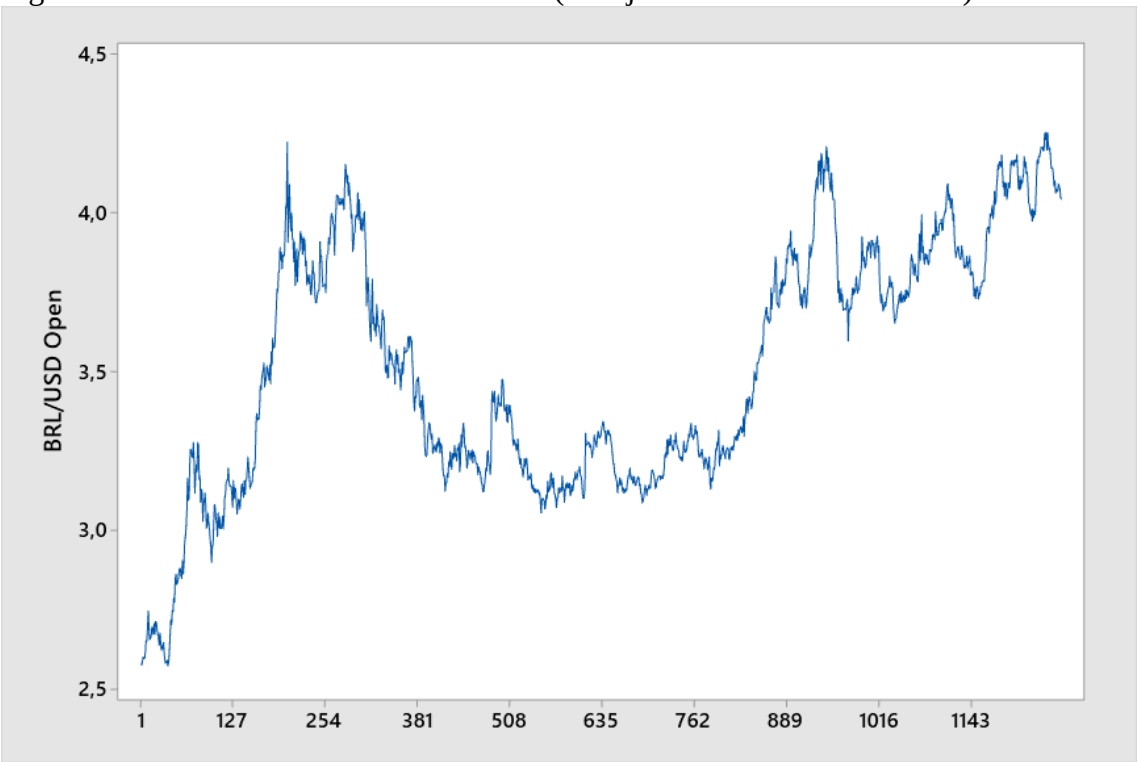


Figura A-3 - Taxa de câmbio BRL/USD: Máxima (4 de jan.2014 a 30 de dez.2019)

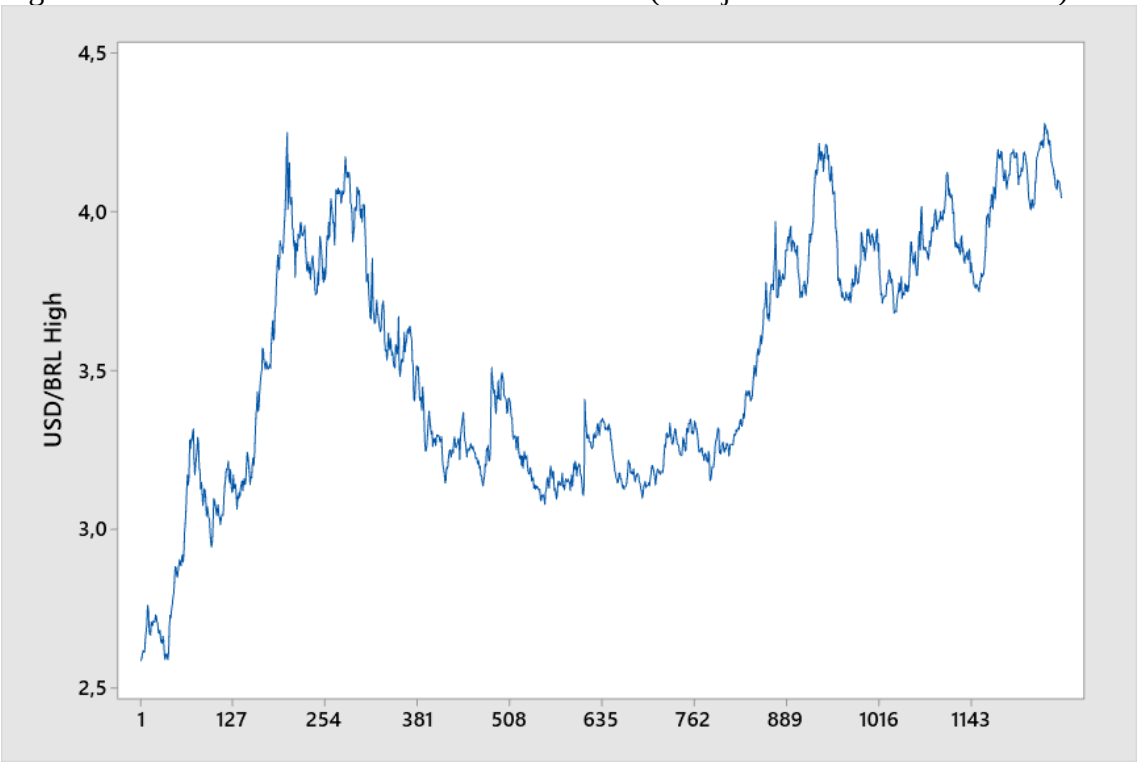


Figura A-4 - Taxa de câmbio BRL/USD: Mínima (4 de jan.2014 a 30 de dez.2019)

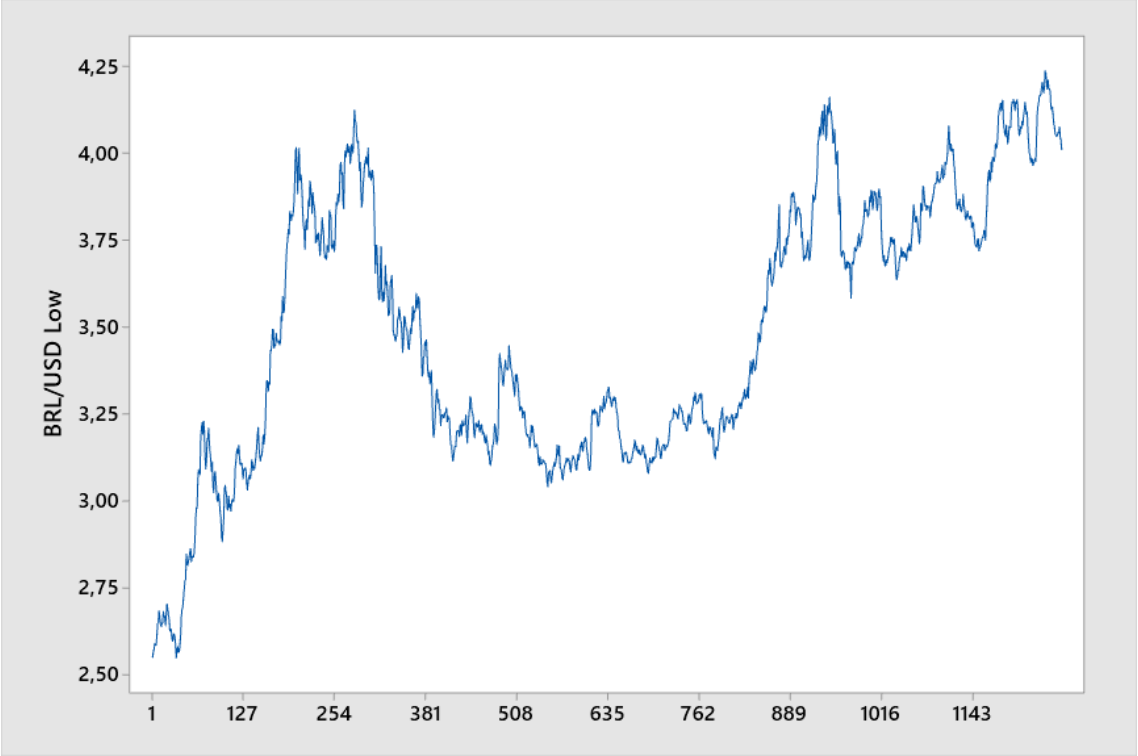


Figura A-5 - Taxa de câmbio BRL/USD: Média (4 de jan.2014 a 30 de dez.2019)

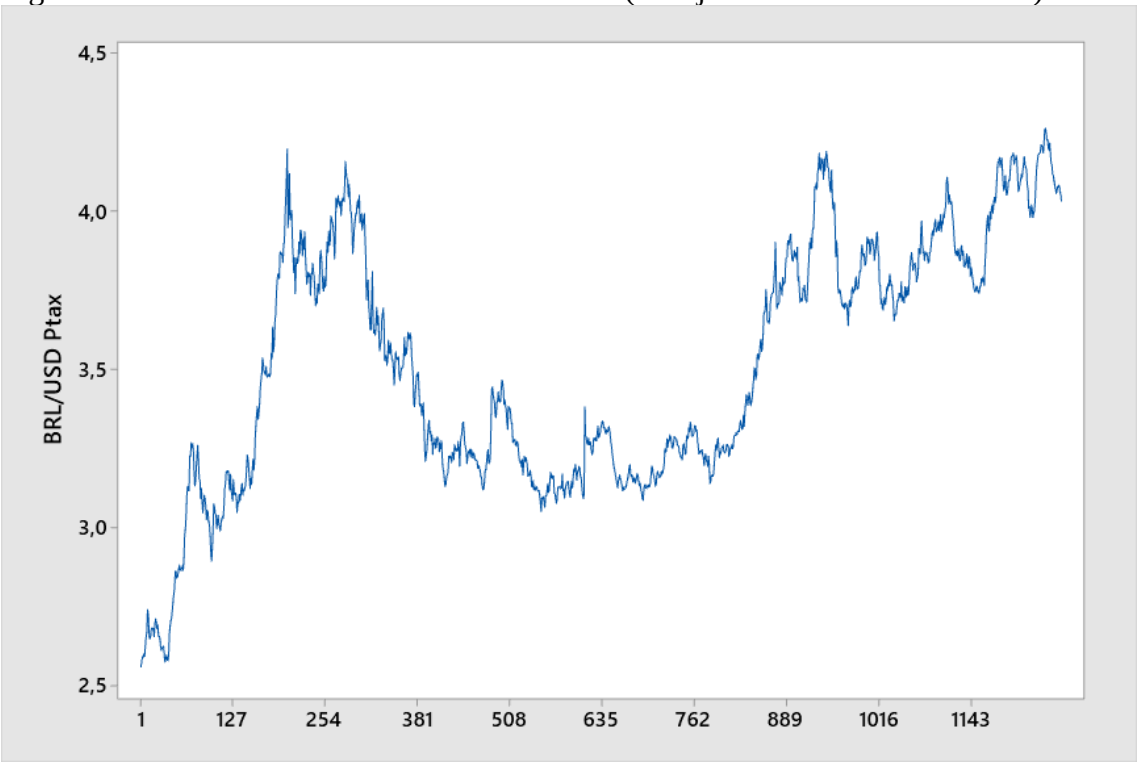


Figura A-6 - Taxa de câmbio BRL/USD: Autocorrelação (4 de jan.2014 a 30 de dez.2019)

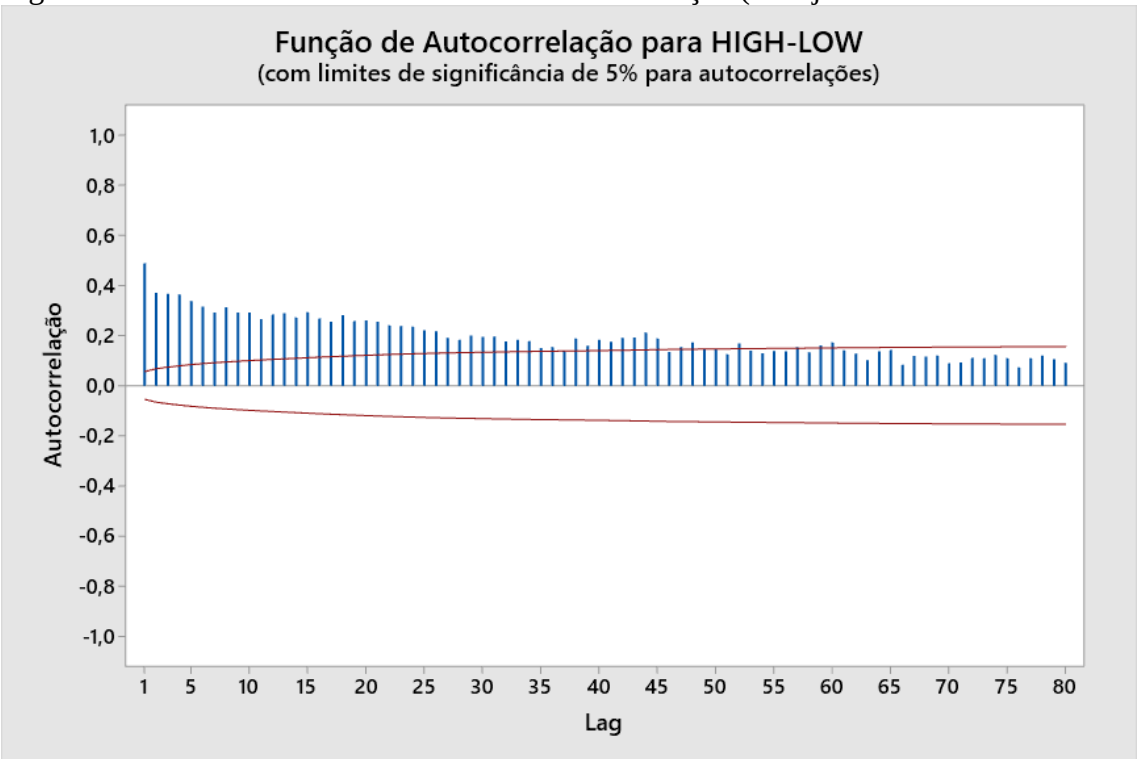


Figura A-7 - Taxa de câmbio EUR/USD: Fechamento (4 de jan.2014 a 30 de dez.2019)

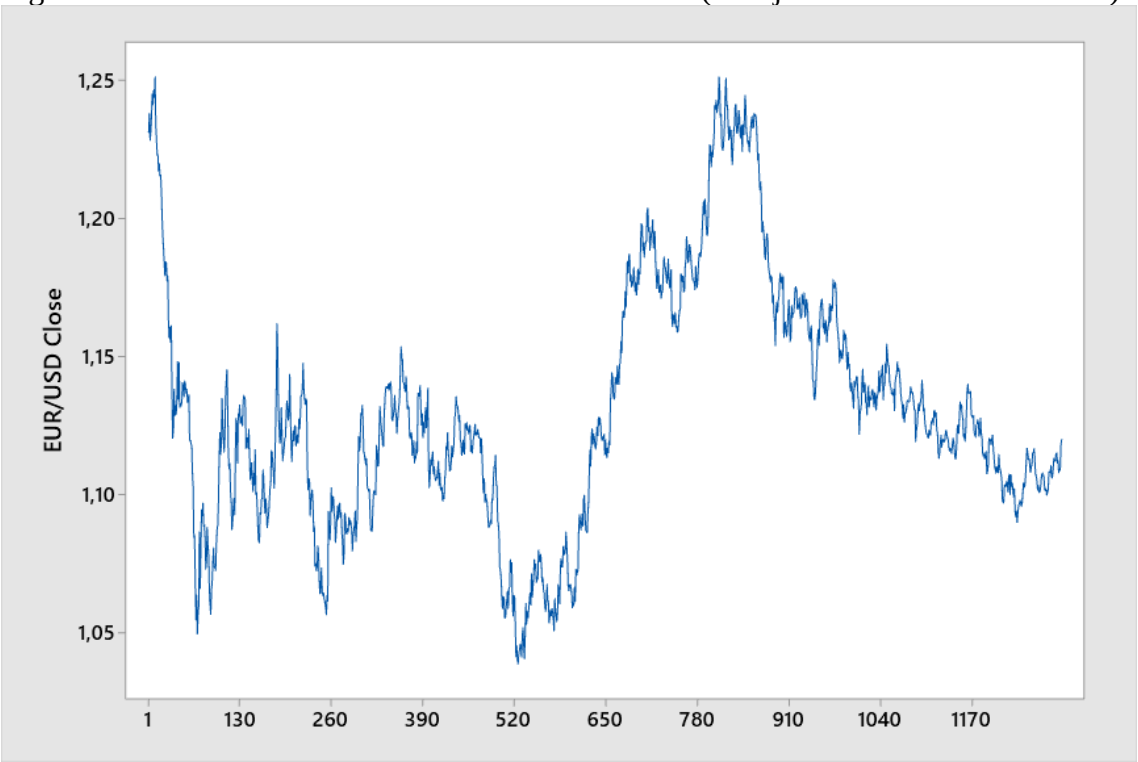


Figura A-8 - Taxa de câmbio EUR/USD: Abertura (4 de jan.2014 a 30 de dez.2019)

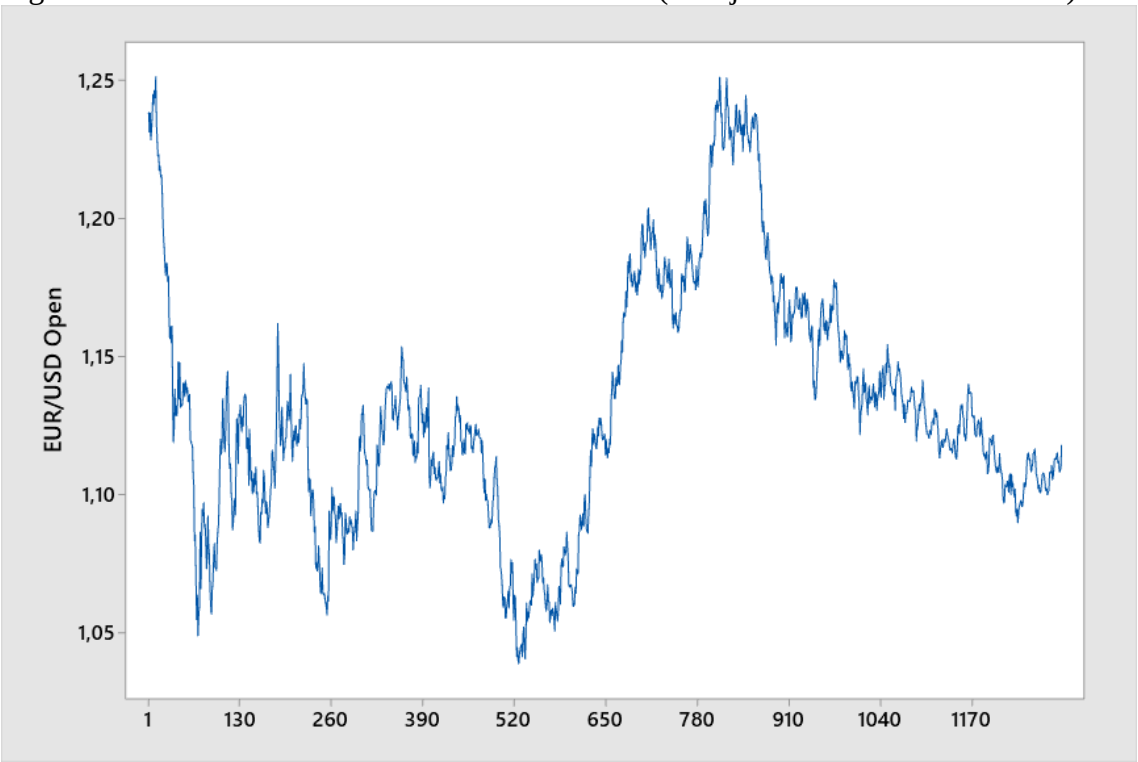


Figura A-9 - Taxa de câmbio EUR/USD: Máxima (4 de jan.2014 a 30 de dez.2019)

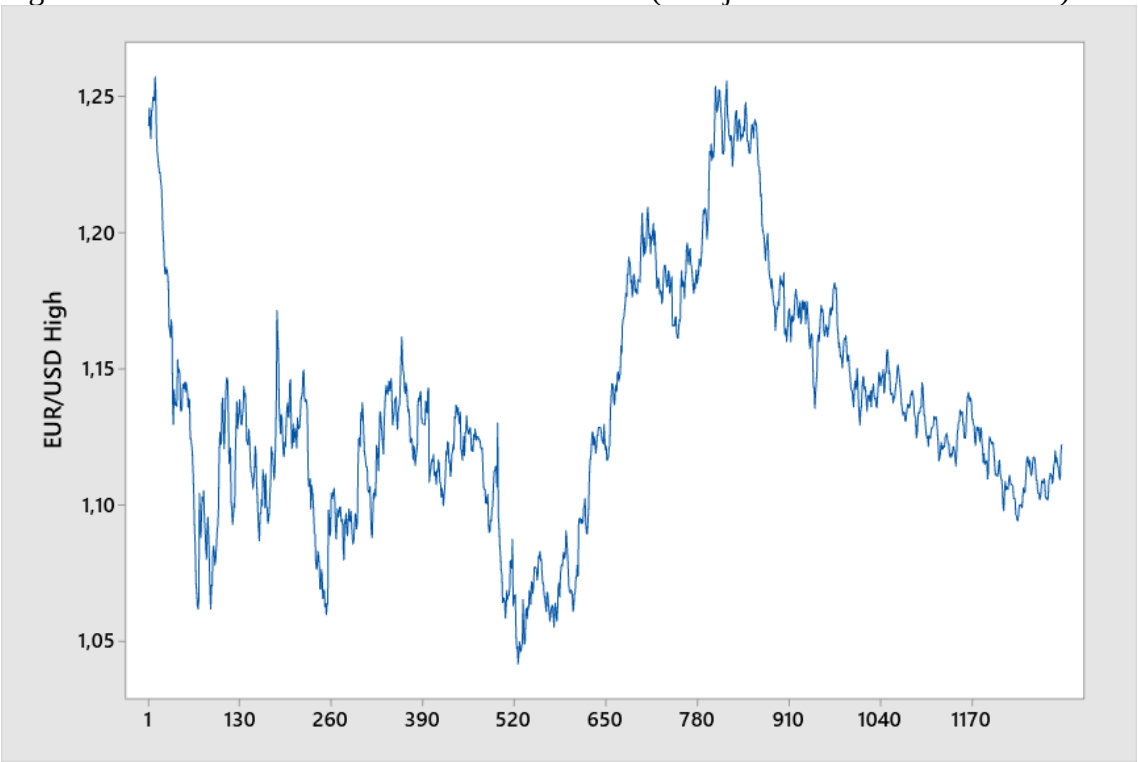


Figura A-10 - Taxa de câmbio EUR/USD: Mínima (4 de jan.2014 a 30 de dez.2019)

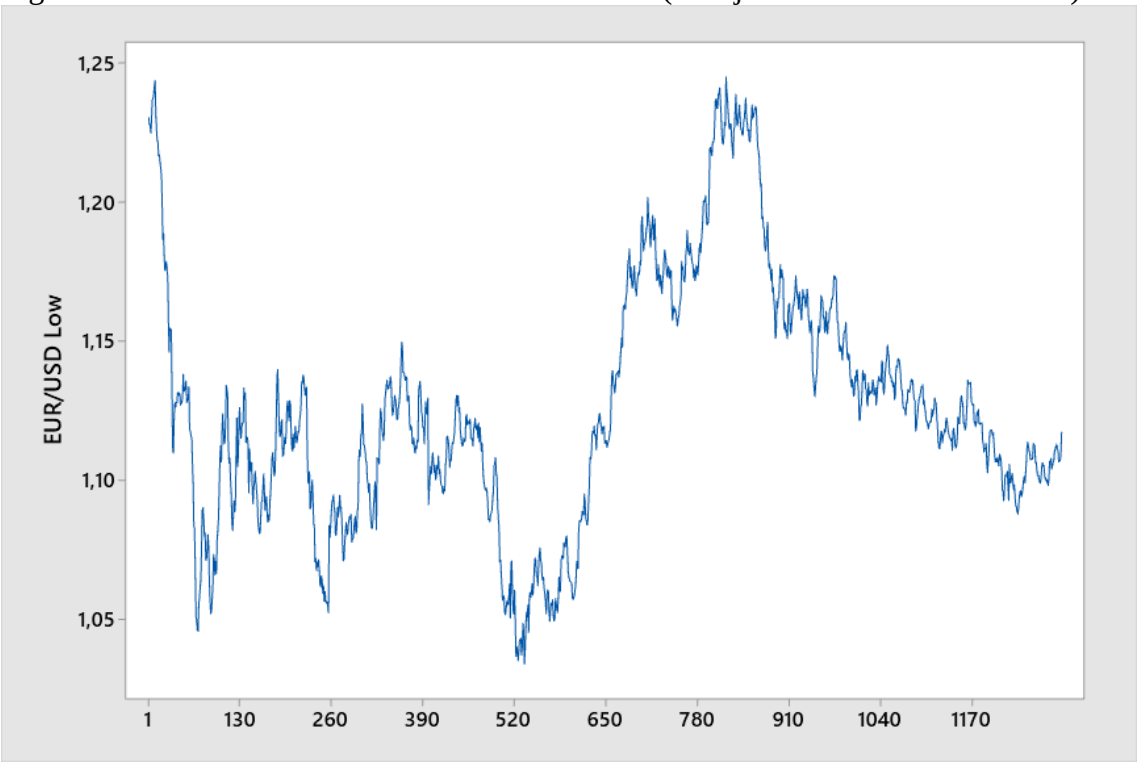


Figura A-11 - Taxa de câmbio EUR/USD: Média (4 de jan.2014 a 30 de dez.2019)

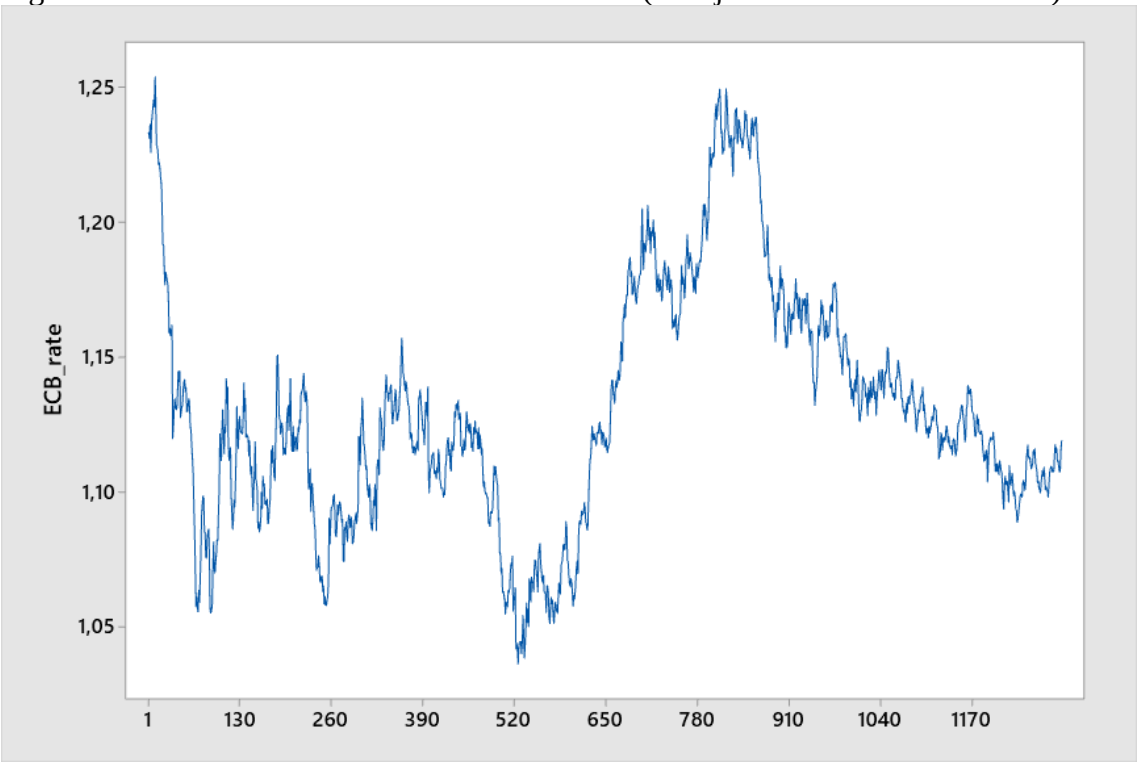


Figura A-12 - Taxa de câmbio EUR/USD: Autocorrelação (4 de jan.2014 a 30 de dez.2019)

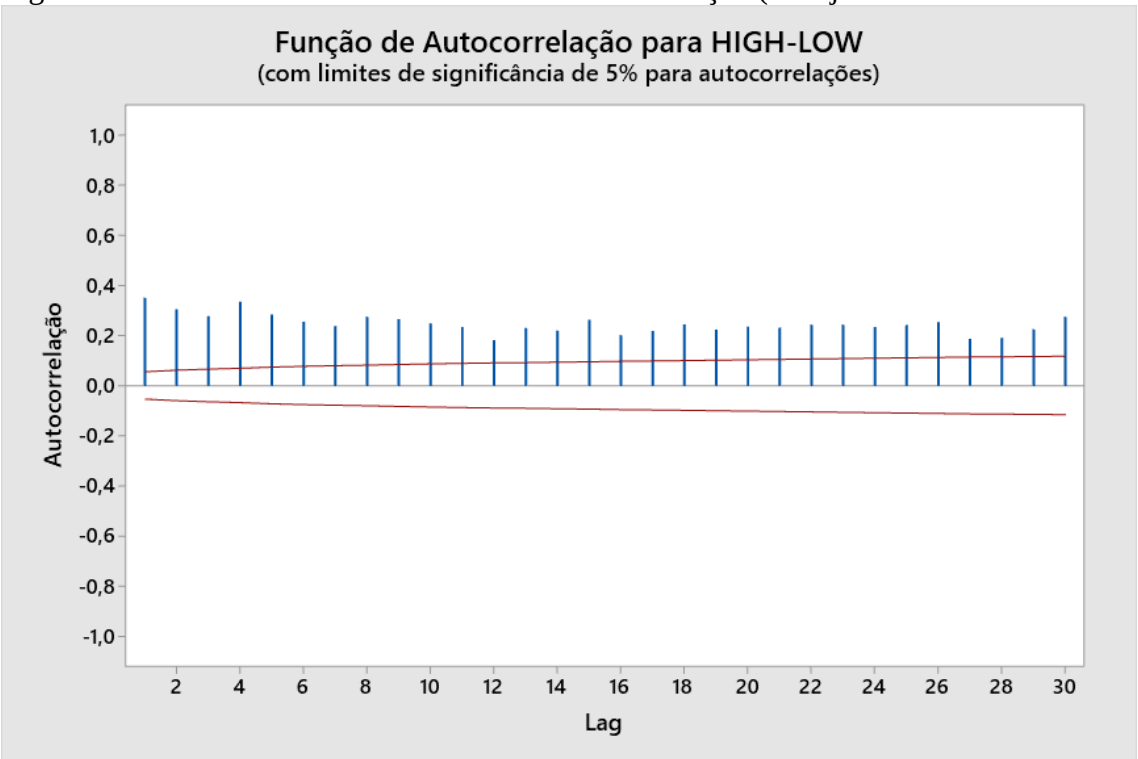


Figura A-13 - Taxa de câmbio GBP/USD: Fechamento (4 de jan.2014 a 30 de dez.2019)

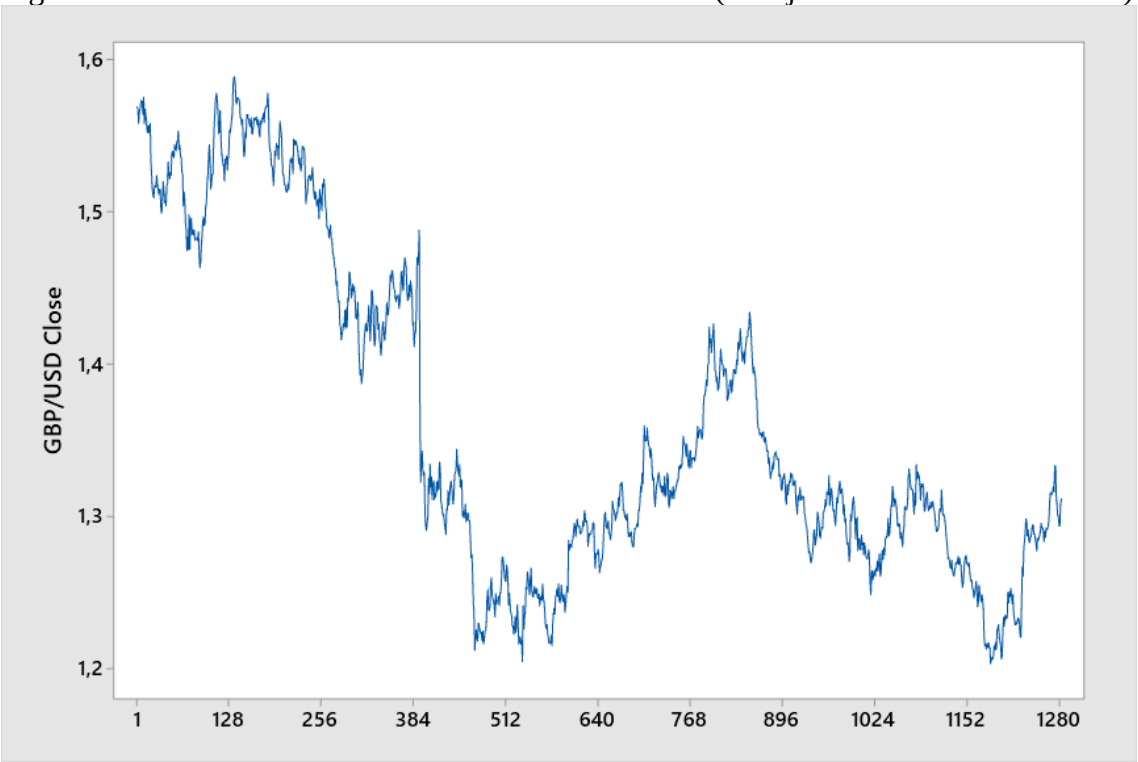


Figura A-14 - Taxa de câmbio GBP/USD: Abertura (4 de jan.2014 a 30 de dez.2019)

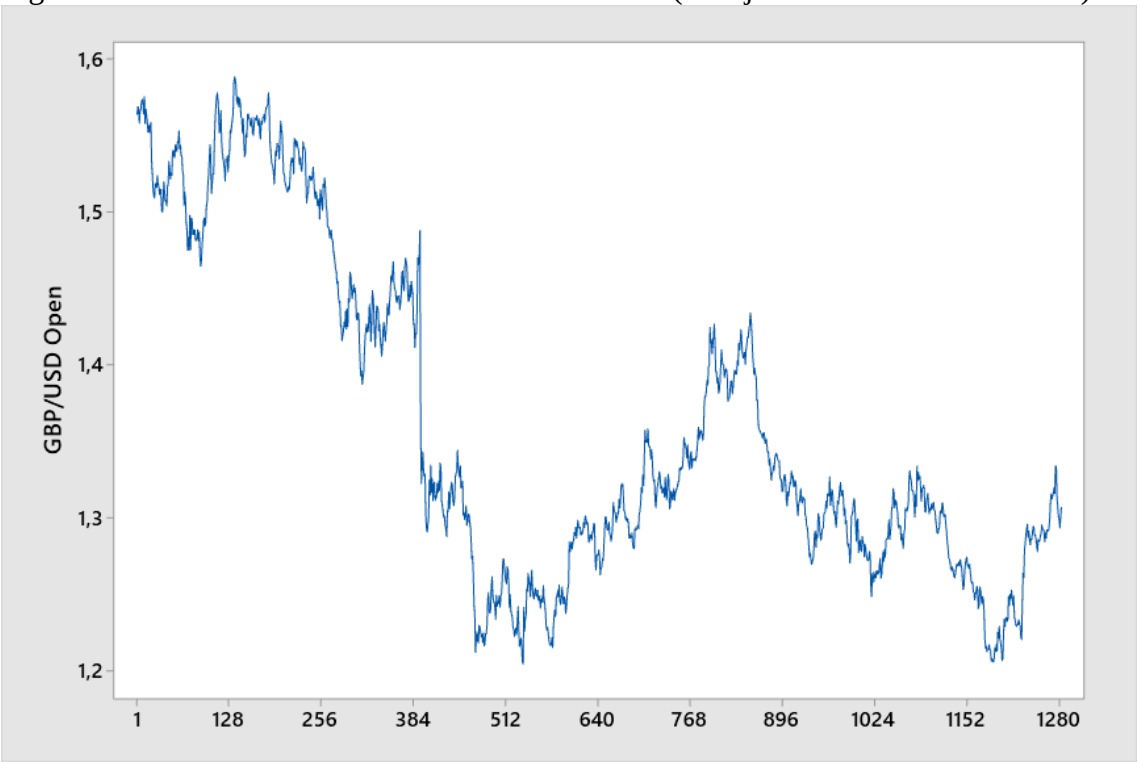


Figura A-15 - Taxa de câmbio GBP/USD: Mínima (4 de jan.2014 a 30 de dez.2019)

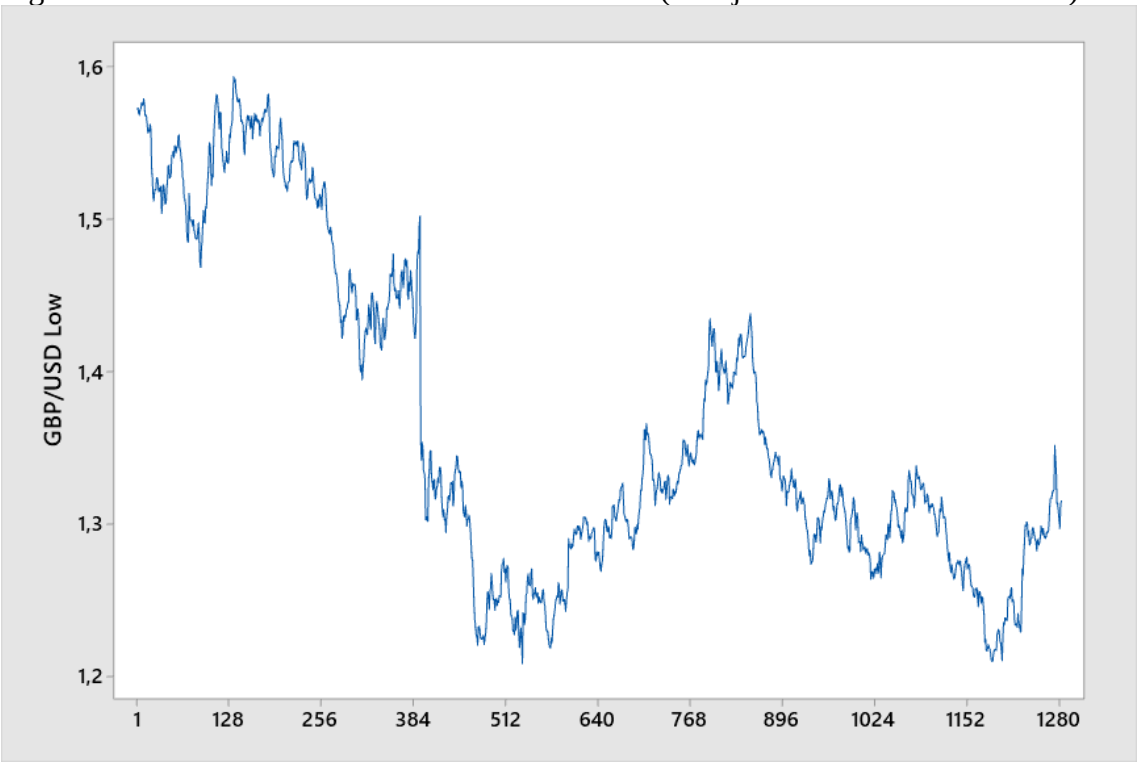


Figura A-16 - Taxa de câmbio GBP/USD: Máxima (4 de jan.2014 a 30 de dez.2019)

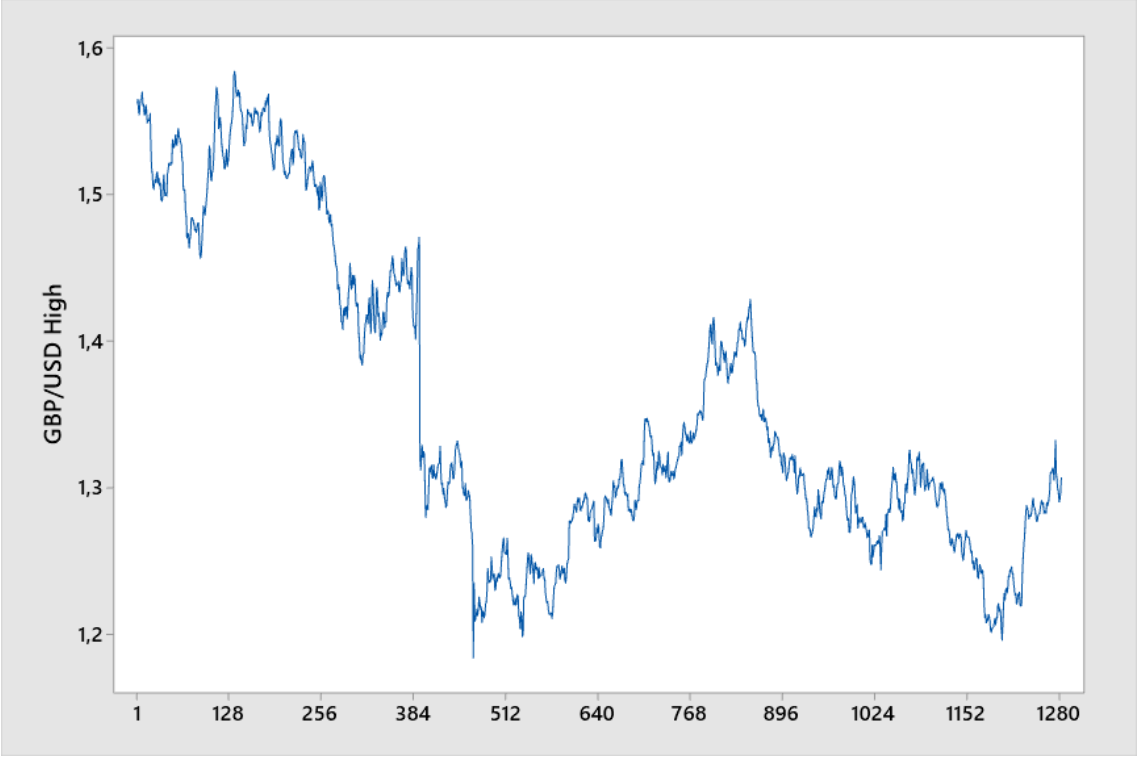


Figura A-17 - Taxa de câmbio GBP/USD: Média (4 de jan.2014 a 30 de dez.2019)

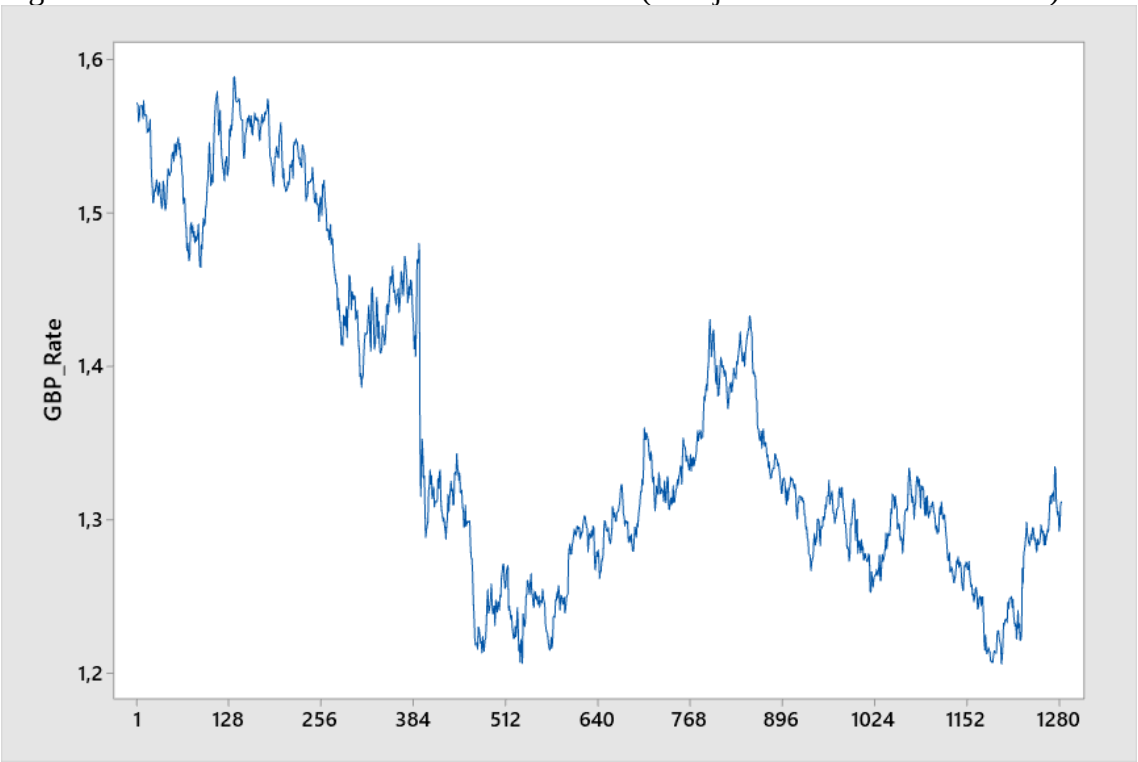


Figura A-18 - Taxa de câmbio GBP/USD: Autocorrelação (4 de jan.2014 a 30 de dez.2019)

