Universidade Presbiteriana Mackenzie

Centro de Ciências Sociais e Aplicadas
Programa de Pós-Graduação em Administração
Linha de pesquisa em Finanças

Projeção de Preços de Ações com Redes Neurais Artificiais *Multi Layer Perceptron* e *Long Short Term Memory*

Cristiane Orquisa Fantin

São Paulo
2022

Cristiane Orquisa Fantin

Projeção de Preços de Ações com Redes Neurais Artificiais *Multi Layer Perceptron* e *Long Short Term Memory*

Defesa de Tese apresentada ao Programa de Pós-Graduação em Administração da Universidade Presbiteriana Mackenzie para a obtenção do título de Doutora em Finanças.

Orientador: Prof. Dr. Eli Hadad Junior.

São Paulo

2022

Elaborado pelo Sistema de Geração Automática de Ficha Catalográfica da Mackenzie
com os dados fornecidos pelo(a) autor(a)

F216p Fantin, Cristiane Orquisa.

Projeção de Preços de Ações com Redes Neurais Artificiais Multi Layer Perceptron e Long Short Term Memory : [recurso eletrônico] / Cristiane Orquisa Fantin.

1800 KB ; il.

Tese (Doutorado em Administração de Empresas) - Universidade Presbiteriana Mackenzie, São Paulo, 2023.

Orientador(a): Prof(a). Dr(a). Eli Hadad Junior.

Referências Bibliográficas: f. 95-107.

1. Pprevisão Do Preço De Ações; Multi Layer Perceptron; Long Short Term Memory. I. Hadad Junior, Eli, *orientador(a)*. II. Título.

Bibliotecário(a) Responsável: Jaqueline Bay Inácio Duarte - CRB 8/9509

CRISTIANE ORQUISA FANTIN

PROJEÇÃO DE PREÇOS DE AÇÕES COM REDES NEURAIS ARTIFICIAIS MULTI LAYER PERCEPTRON E LONG SHORT TERM MEMORY

Tese apresentada ao Programa de Pós-Graduação em Administração da Universidade Presbiteriana Mackenzie, como requisito parcial à obtenção de título de Doutora em Finanças.

Aprovado em 15 de fevereiro de 2023

BANCA EXAMINADORA

Prof. Dr. Eli Hadad Junior

Universidade Presbiteriana Mackenzie

Prof. Dr. Wilson Toshiro Nakamura

Universidade Presbiteriana Mackenzie

Prof. Dr. Leonardo Fernando Cruz Basso

Universidade Presbiteriana Mackenzie

Prof. Dr. Diogo de Prince Mendonça

Universidade Federal de São Paulo

Prof. Dr. Alexandre Ripamonti

Escola Superior de Propaganda e Marketing

RESUMO

O objetivo deste trabalho é o de investigar o poder preditivo de modelos de projeção de preços de ações com redes neurais *multi layer perceptron* e *long short term Memory,* em ativos negociados em bolsas de valores brasileira, a B3 S.A. A relevância do estudo está na real aplicabilidade dos modelos desenvolvidos sobre os portfólios dos investidores, dando a oportunidade de se anteciparem aos movimentos dos preços do mercado acionário, minimizando suas perdas ou maximizando seus lucros.

Possibilidades de estudos futuros, envolvem a utilização de outras arquiteturas de rede, tais como as classes *deep learning.*

Palavras-chave: Previsão do preço de ações; *Multi Layer Perceptron; Long Short Term Memory*

SUMÁRIO

1 INTRODUÇÃO 10

2. PRIMEIRO ENSAIO: REVISÃO BIBLIOMÉTRICA E SISTEMÁTICA DE9 PREVISÃO DO PREÇO DE AÇÕES COM REDES NEURAIS MULTI LAYER PERCEPTRON 12

2.1 Introdução 12

2.2 Revisão da Literatura 12

2.3 Metodologia 15

2.4 Análise dos Resultados 20

2.4.1 Análise Bibliométrica 21

2.4.2 Revisão Sistemática 30

2.5 Conclusão 46

3. SEGUNDO ENSAIO: REVISÃO BIBLIOMÉTRICA E SISTEMÁTICA DE PREVISÃO DO PREÇO DE AÇÕES COM REDES NEURAIS LONG SHORT TERM MEMORY 48

3.1 Introdução 48

3.2 Revisão da Literatura 48

3.3 Metodologia 51

3.4.1 Análise Bibliométrica 54

3.4.2 Revisão Sistemática 61

3.6 Conclusão 77

4. TERCEIRO ENSAIO: PROJEÇÃO DE VALORES DE AÇÕES COM REDES NEURAIS MLP E LSTM –ATIVOS DA B3 S/A. 79

4.1 Introdução 79

4.2 Revisão da Literatura 79

4.2 Amostra de dados 81

4.3 Metodologia 82

4.4 Resultados 84

4.5 Conclusão 86

5. QUARTO ENSAIO: PROJEÇÃO DO PREÇO DE AÇÕES COM RNA E DADOS DE ALTA FREQUÊNCIA 87

5.1 Introdução 87

5.2 Revisão da Literatura 87

5.3 Amostra de dados 88

5.4 Metodologia 88

5.5 Resultados 88

5.6 Conclusão 91

6. CONCLUSÃO 92

REFERÊNCIAS 93

LISTA DE QUADROS

Quadro 1 – Evolução da amostra por meio de filtros da WoS.....16
Quadro 2 – Matriz de (sub) categorização..... 17
Quadro 3 - Palavras-chave..... 2121
Quadro 4 – T de Goffman..... 23
Quadro 5 – Classificação de palavras - Lei de Zipf 24
Quadro 6 –Lei de Bradford sobre os periódicos..... 27
Quadro 7 – Citações dos artigos..... 29
Quadro 8 – Aplicação Lei de Lotka..... 30
Quadro 9 – Principais contribuições dos artigos da amostra..... 35
Quadro 10 – Codificação das categorias e subcategorias de análise dos artigos 39
Quadro 11 - Evolução da amostra usando filtros WoS..... 51
Quadro 12 - Categorias e Subcategorias..... 53
Quadro 13 - Palavras-chave..... 55
Quadro 14 - Lei de Bradford sobre Diários..... 58
Quadro 15 - Os 10 artigos mais citados..... 60
Quadro 16 – Principais contribuições dos artigos da amostra..... 62
Quadro 17 – Codificação das categorias e subcategorias de análise dos artigos..... 69
Quadro 18 – 50 maiores empresas por ativo imobilizado listadas na B3..... 81
Quadro 19 – Configuração das redes..... 83
Quadro 20 – Melhores modelos..... 84
Quadro 21 – Melhores Modelos - Erros Quadráticos Médios..... 89

LISTA DE FIGURAS

Figura 1 – Estrutura básica das RNAs MLP 13
Figura 2 – Distribuição Anual dos Artigos..... 21
Figura 3 – Mapa de coocorrências das palavras-chave 22
Figura 4 – Frequência dos artigos dos países das instituições às quais os autores estão associados (número de artigos versus país da instituição) 25
Figura 5 – Frequência das citações dos artigos dos países das instituições às quais os autores estão associados (citações por país da instituição)..... 26
Figura 6 – Mapa de cocitações entre periódicos 28
Figura 7 – Análise de (sub) categorias para identificar lacunas de conhecimento..... 34
Figura 8 – Categoria 1 – Tema principal / foco do estudo 41
Figura 9 – Categoria 2 – Métodos de pesquisa..... 41
Figura 10 – Categoria 3 – Redes Neurais utilizadas na pesquisa 42
Figura 11 – Categoria 4 – Teorias relacionadas aos objetivos dos artigos..... 42
Figura 12 – Categoria 5 – Tipos de dados analisados 43
Figura 13 – Categoria 6 – Origem dos dados 43
Figura 14 – Categoria 7 – Período de análise..... 44
Figura 15 – Categoria 8 – Resultados..... 44
Figura 16 – Categoria 9 – Conclusões sobre o objetivo dos estudos 45
Figura 17 – Categoria 10 – Avenidas para estudos futuros..... 45
Figura 18 - Distribuição anual de artigos 55
Figura 19 - Mapa de coocorrência de palavas-chave..... 56
Figura 20 - Publicação de artigos por país a que os autores estão associados..... 56
Figura 21 - Frequência de citações de artigos nos países das instituições às quais os autores estão vinculados..... 57
Figura 22 - Mapa de cocitações entre os Journals 59
Figura 23 - Rede Neural Multi Layer Perceptron..... 79
Figura 24 - Rede Neural Long Short-Term Memory..... 80

1 INTRODUÇÃO

O mercado financeiro é caracterizado por ser um sistema dinâmico, complexo e não linear, caracterizado pela intensidade de dados, ruídos, natureza não estacionária, não estruturada e com elevado grau de incertezas (Lunga e Marwala, 2006). Por tantos fatores interagirem simultaneamente, como eventos políticos, condições macro e microeconômicas e expectativas dos investidores, prever esses movimentos é uma tarefa bastante desafiadora.

O papel crescente que o mercado acionário desempenha na economia mundial, estimula o desenvolvimento de pesquisas centradas na construção de teorias, envolvendo o tema previsão de preços de ações, e métodos precisos são cruciais para o gerenciamento do portfólio dos investidores.

Avaliar os retornos esperados em relação à exposição total, pressupõe que os administradores dos portfólios entendam a distribuição da carteira. Especialistas podem modelar a influência dos ativos tangíveis em relação ao valor de mercado, mas não os dos ativos intangíveis, como direitos, experiências ou valor das marcas.

Importante aliada na busca da minimização do risco em relação à exposição, a inteligência artificial e a aprendizagem de máquina com suas redes neurais, deram um grande saldo de qualidade nas últimas décadas, melhorando a detecção, o diagnóstico, a previsão e a resolução de problemas (Belciug e Sandita, 2017); isso porque nesse mercado, os eventos futuros são ao menos parcialmente dependentes de eventos e dados passados (Demirel, Cam e Unlu, 2021), e não totalmente aleatórios.

De acordo com Makinen et al. (2019), talvez o tipo mais comum de rede neural seja a *multi layer perceptron* (MLP), que é uma rede neural *feed-forward* formada por duas ou mais camadas de neurônios. Trata-se de um tipo de rede neural artificial (RNA) aplicada em diversos campos e que tem obtido resultados bem-sucedidos em previsões.

A razão pela qual este modelo é escolhido para o presente estudo perante outros tantos disponíveis, é que de acordo com as conclusões dos recentes estudos de Demirel, Cam e Unlu (2021), o MLP é um método de RNA que fornece resultados flexíveis e consistentes.

O modelo escolhido para a comparação dos resultados obtidos com a RNA MLP, é o Long Short Term Memory (LSTM). Isso se deu em decorrência das conclusões da revisão sistemática da literatura das próprias projeções de preços com ações com RNA MLP, que apurou a existência de estudos nesse sentido que devem ser aprofundados (JuHyok et al., 2010; Li e Tam, 2018; Makinen et al., 2019; Ding e Qin, 2020; Lu et al., 2020; Chandar, 2021; Demirel, Cam e Unlu, 2021). Corrobora com essa opção o fato de a revisão sistemática da literatura com RNA LSTM, em curso, indicar que este tipo de rede neural contém características particularmente apropriadas para esse tipo de estimação.

A pesquisa é desenvolvida em quatro ensaios, sendo o primeiro, a revisão bibliométrica e sistemática da literatura das redes neurais MLP, aplicadas à previsão de preços de ações.

O segundo ensaio é a revisão bibliométrica e sistemática da literatura das redes neurais LSTM, aplicadas à previsão de preços de ações.

O terceiro ensaio é a utilização das duas arquiteturas de redes neurais, MLP e LSTM, na projeção de preços de ações da bolsa de valores brasileira, a B3 S.A.

O quarto ensaio trata da projeção dos preços de três ações com movimentação relevante da B3 as ações, utilizando modelagem econométrica de dados de alta frequência.

2. PRIMEIRO ENSAIO: REVISÃO BIBLIOMÉTRICA E SISTEMÁTICA DA LITERATURA: PREVISÃO DO PREÇO DE AÇÕES COM REDES NEURAIS ARTIFICIAIS MULTI LAYER PERCEPTRON

2.1 Introdução

O objetivo deste capítulo é mapear e analisar a literatura acadêmica publicada a respeito da previsão dos preços de ações utilizando redes neurais artificiais *multi layer perceptron.* Para tanto, realiza-se a análise bibliométrica e a revisão sistemática da literatura a respeito do tema, durante o período de 1º de janeiro de 1945 a 28 de março de 2021, com amostra final de 26 artigos. A análise bibliométrica refere-se à análise quantitativa, que se desenvolve em meio à contagem de frequências e cocitações. A revisão sistemática, uma análise qualitativa, considera a correlação entre temas mais significativos, mas ainda pouco estudados pela academia. A base de pesquisa utilizada é originária da base de dados da Web of Science (WoS), e tanto a análise bibliométrica quanto a revisão sistemática, prescindem da utilização dos softwares R, Rstudio, Biblioshiny, VOSViewer e Rank Words. Na análise bibliométrica, adota-se a verificação das principais leis: Lotka (1926), Bradford (1934) e Zipf (1949).

A revisão da literatura é apresentada no item 2.1, com a identificação das teorias e métodos para a previsão do preço de ações com redes neurais artificiais *multi layer perceptron* mencionados nos artigos da amostra final. As metodologias de análise bibliométrica e revisão sistemática são descritas no item 2.2, e no item 2.3, relatados os resultados de ambas as metodologias, com a estatística descritiva das características mais relevantes dos artigos da amostra final, e as lacunas do conhecimento sobre esse tema. O item 2.4 apresenta as conclusões, avenidas para estudos futuros e limitações desta pesquisa.

2.2 Revisão da Literatura

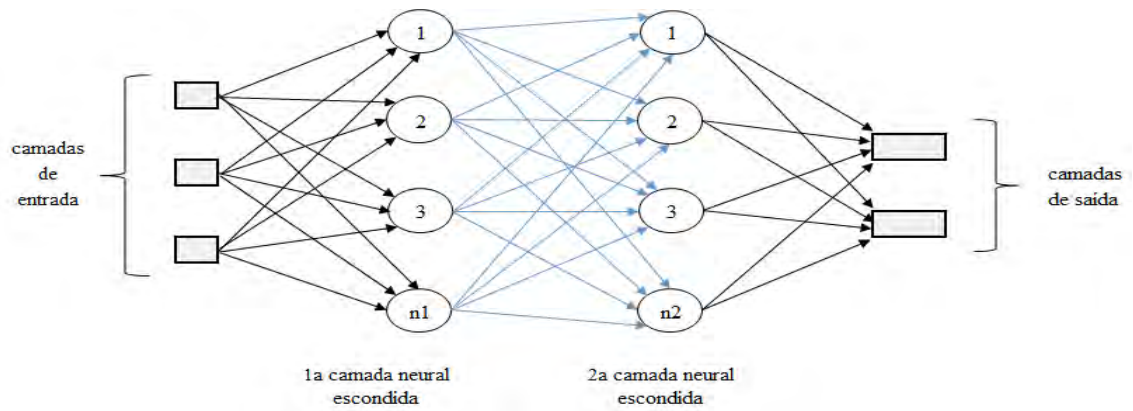
O ambiente em que se debruça esse estudo, o do mercado acionário, é bastante ruidoso e não linear, mas de movimentos não totalmente aleatórios (McNelis, 2005). A flutuação dos preços de fechamento diários das ações de uma empresa, é fortemente influenciada por certos preditores registrados ao longo do tempo, como o volume de transações, o número de ações, a faixa dos preços ou a taxa de câmbio diária, por exemplo

(Pardoe, 2006). Nesse contexto, pesquisas com RNA e algoritmos de aprendizagem são bastante adequadas, pois eles demonstram capacidade de reter as informações previamente aprendidas e adquirir conhecimentos adicionais, quando novos dados são introduzidos (Lunga e Marwala, 2006).

As redes neurais imitam a maneira como o cérebro humano funciona. O MLP é um algoritmo de aprendizado supervisionado, capaz de aprender com um conjunto de dados em treinamento. Dado um conjunto de recursos e uma saída de destino, o MLP pode aprender uma função não linear para regressão. A diferença entre a regressão linear múltipla clássica e o MLP para regressão, consiste no número de camadas não lineares, também conhecidas como camadas ocultas (Belciug e Sandita, 2017).

As RNA MLP têm sido amplamente aplicadas a problemas de aprendizagem supervisionada (Li e Tam, 2018), e em especial, oferecem excelente desempenho na previsão dos valores dos índices do mercado de ações (Wang et al., 2016). Isso porque se trata de um algoritmo cuja característica mais marcante, é extrair relações não lineares e ocultas dos dados. RNA MLP são redes neurais que se retroalimentam (*feed-forward*), com unidades entre si conectadas, os chamados neurônios. Essas unidades sensoriais são organizadas em camadas de entrada, um número arbitrário de camadas ocultas de unidades de processamento (*perceptrons*) e camada de saída (Demirel, Cam e Unlu, 2021). A camada de entrada é alimentada por informações externas, e as transfere por meio de conexões, para as unidades da primeira camada oculta. Estas calculam suas ativações sobre as informações, e repassam os resultados para as unidades (neurônios) das camadas seguintes (Riedmiller, 1994). A Figura 1 apresenta a topologia básica de uma RNA MLP.

Figura 1 – Estrutura básica das RNAs MLP



A rede tem que ser treinada para produzir a saída correta com erro mínimo, de acordo com Mostafa (2010). O treinamento propriamente dito, consiste em duas fases, o passe do cálculo para a frente e para trás. No passe para a frente, as informações externas (os chamados vetores de treinamento), são introduzidas na rede e suas respostas são obtidas. Essas respostas são combinadas com as informações fornecidas (isto é, os vetores alvo indicam a resposta ótima para cada vetor de treinamento), a fim de definir o erro da rede em relação a uma função de perda. Este erro é então propagado de volta para a rede neural e usado no sentido de passe inverso, para atualizar os pesos, os parâmetros da rede, ou seja, o ciclo se repete e os pesos são ajustados continuamente até que o erro seja minimizado (Mostafa, 2010), ou seja, reduzido o erro quadrático médio entre a saída de predição da rede e a saída alvo.

Isso é conseguido explorando-se a propriedade diferenciável das funções de ativação dos neurônios, seguindo uma abordagem de aprendizagem gradiente descendente, chamada retropropagação de erro (Makinen et al.,2019), sendo a informação acumulada propagada pela rede até a camada de saída. Em suma, o modelo é treinado para aprender as correlações entre *inputs* e *outputs* e capacitado para ajustar os parâmetros, pesos e bases de tempos em tempos, a fim de minimizar os erros do processo de treinamento (Li e Tam, 2018). Se a curva de aprendizado se estabiliza após muitas iterações em um nível de erro não considerado aceitável, é o momento de se repensar a topologia da rede (mais camadas ocultas ou uma topologia totalmente diferente) ou o procedimento de treinamento (outra pesquisa de gradiente com técnicas mais sofisticadas).

Nesse contexto, projetar uma boa arquitetura de rede para o problema estudado, não é uma tarefa simplista. O número de camadas, de neurônios por cada camada, e a seleção das funções de ativação, afetam diretamente o desempenho do modelo. Swicegood e Clark (2001) afirmam que o processo de refinamento pode ser demorado, pois não existe um método formal de derivar uma configuração de rede MLP para uma dada tarefa de classificação, nem um método direto para encontrar a estrutura final mais adequada ao processo de modelagem. Isso se dá necessariamente através da realização de testes iterativos com diversos parâmetros, diferentes arquiteturas, em que se mantém apenas a estrutura de maior assertividade.

A qualidade das informações com que a rede é alimentada, tanto ou mais, é refletida na precisão da resposta da camada de saída. A seleção das informações que são prestadas à camada de entrada é fator chave no projeto de um sistema de decisão inteligente, pois mesmo que o modelo seja o melhor, ele terá um desempenho pobre se os recursos não forem bem escolhidos. Deve-se fazer uso de métodos específicos na seleção das informações realmente relevantes. (Belciug e Sandita, 2017).

2.3 Metodologia

O objetivo desse estudo é responder à pergunta – utilizando-se redes neurais artificiais *multi layer perceptron*, poderemos auferir predições confiáveis de preços de ações? Para tanto, são implementadas as 7 etapas descritas a seguir. As etapas 1 a 5 atendem tanto à metodologia da análise bibliométrica quanto da revisão sistemática, e as etapas 6 e 7 referem-se à revisão sistemática.

Etapa 1 – Escolha da base de dados. Os artigos da amostra são obtidos a partir da WoS, a base de dados de citações líder no mundo. Ela contém registros de artigos publicados em periódicos científicos de alto fator de impacto, classificados por meio do Journal Citation Reports (JCR).

Etapa 2 – Uso de parâmetros iniciais de pesquisa a partir da WoS. Para o período de 1º de janeiro de 1945 a 27 de março de 2021. Inicialmente, são identificados 86 artigos com base em variações das palavras-chave *stock, market, multi layer perceptron, forecast, predictive, regression, supervised, sentiment* e *backpropagation.* Na sequência, são realizadas exclusões por meio da aplicação de filtros na própria WoS, como "diferente de *articles*", diferente de "*english*" e categorias diferentes de "*computer science artificial intelligence", "computer science theory methods", "computer science information systems", "computer science interdisciplinary applications", "computer science hardware architecture", "computer science software engineering", "multidisciplinary sciences", "economics", "business finance", "mathematics interdisciplinary applications", "operations research management science", "management", "mathematics", "social sciences mathematical methods", "engineering multidisciplinary*"resultando numa amostra intermediária de 35 artigos, conforme Tabela 1.

Etapa 3 – Exclusão de artigos não relacionados. Após a leitura inicial do resumo, introdução e conclusão dos artigos – a fim de verificar se eles estão de acordo com o tema definido – são excluídos 09 dos 35 artigos da amostra intermediária. Os motivos para essas exclusões são não estarem relacionados à previsão do preço de ações, mas à previsão de falência de empresas (02), à previsão do preço de Bitcoins (01), à previsão de taxas de câmbio (01), ao cálculo sigmóide (01), a análises temporais físicas (01), à aprendizagem supervisionada avançada em *perceptrons* multicamadas (01), ou não estarem disponíveis nas fontes pesquisadas (02). Assim, a amostra final é composta por 26 artigos.

Quadro 1 – Evolução da amostra por meio de filtros da WoS

Sinal	Descrição	Número de artigos
(+)	Palavras-chave iguais a: "stock* market*" and "MLP" or "stock* market*" and "multi-layer perceptron" or "stock* market*" and "multi layer perceptron" or "sentiment* stock*" and "MLP" or "sentiment* stock*" and "multi-layer perceptron" or "sentiment* stock*" and "multi layer perceptron" or "sentiment* regression*" and "MLP" or "sentiment* regression*" and "multi-layer perceptron" OR "sentiment* regression*" and "multi layer perceptron" OR "supervis* learn*"and "multi-layer perceptron*" and "backpropagation"	86
(-)	Tipo de documento: diferente de "articles"	44
(-)	Idioma: diferente de "english"	1
(-)	Categorias da WoS diferentes de "computer science artificial intelligence", "computer science theory methods", "computer science information systems", "computer science interdisciplinary applications", "computer science hardware architecture", "computer science software engineering", "multidisciplinary sciences", "economics", "business finance", "mathematics interdisciplinary applications", "operations research management science", "management", "mathematics", "social sciences mathematical methods", "engineering multidisciplinary"	6
(=)	Amostra intermediária	35

Fonte: elaborado pela autora

Etapa 4 – Criação de banco de dados e coleta de artigos. Os 26 artigos da amostra final são obtidos por meio das seguintes bases de pesquisa acadêmica: Science Direct, Web of Science e Google Scholar. A partir disso, são coletadas as seguintes informações para a captura dos dados gerais do artigo: título, nome do autor, instituição afiliada e país

de origem dos autores/pesquisadores, nome do periódico, volume e número da edição, página inicial e final, ano da publicação, país de origem dos dados e número de anos de dados da amostra, palavras-chave, Identificador Digital de Objetos (DOI), Journal of Economic Literature (JEL) e número de citações de artigos na base de dados WoS.

Etapa 5 – Análise bibliométrica. Por meio dos *softwares* R, Rstudio, Biblioshiny e VOSviewer, são analisados os dados dos artigos para a elaboração e a análise das tabelas e mapas de relacionamento / cocitação. As análises realizadas por essas ferramentas são complementadas pela verificação das principais leis da bibliometria, (i) a Lei de Zipf (1949), que se refere à categorização e estimação da frequência das palavras-chave, realizada com o auxílio do *software* Rank Words para o cálculo do ponto T de Goffman, que é o ponto de transição de palavras de baixa para as de alta frequência, região que teoricamente concentra palavras com alta carga semântica, (ii) a Lei de Bradford (1934), que realiza a verificação dos periódicos que produzem muitos artigos, em contra partida aqueles que produzem poucos sobre um determinado tema, e (iii) a Lei de Lotka (1926), que realiza a identificação dos pesquisadores que possuem maior frequência de produção em determinada área de conhecimento.

Quadro 2 – Matriz de (sub) categorização

Categorias	Subcategorias	Definição
1.Tema principal/foco do estudo	A – Previsão do preço de ações com *multi layer perceptron*	Previsão do preço de ações com a RNA *Multi Layer Perceptron* (ou *Perceptron* Multicamadas), que é uma rede neural com uma ou mais camadas ocultas.
	B – Previsão do preço de ações com outras redes neurais artificiais, e resultados comparados às RNA MLP	Pesquisa de previsão do preço de ações com outras Redes Neurais Artificiais, cujos resultados obtidos são comparados aos resultados com MLP
	C – Prever os preços de ações com redes neurais combinadas, incluindo MLP	Previsão do preço de ações com modelos híbridos entre redes neurais artificiais MLP e outras redes neurais
	D – Outros	Demais temas não relacionados às subcategorias 1ª a 1C
2. Métodos de pesquisa	A – Redes Neurais Artificiais	Técnicas computacionais que apresentam um modelo matemático inspirado na estrutura neural de organismos inteligentes. São capazes de realizar o aprendizado de máquina bem como o reconhecimento de padrões.

Categorias	Subcategorias	Definição
2. Métodos de pesquisa	B- Modelos estatísticos para séries temporais (ARMA, ARIMA, GARCH)	Em análise de séries temporais, um modelo auto-regressivo integrado de médias móveis (*autoregressive integrated 18entim average* ou ARIMA) é uma generalização de um modelo auto-regressivo de médias móveis (ARMA). Ambos os modelos são ajustados aos dados da série temporal para entender melhor os dados ou para prever pontos futuros na série. Heteroscedasticidade condicional auto-regressiva generalizada (GARCH) é um modelo estatístico usado na análise de dados de série temporal em que se acredita que o erro de variância seja serialmente autocorrelacionado. Os modelos GARCH assumem que a variância do termo de erro segue um processo de média móvel auto-regressivo.
	C – Outros	Demais metodologias de pesquisa, não relacionadas à subcategoria 2ª e 2B
3. Redes neurais utilizadas nas pesquisas	A – MLP	*Multi Layer Perceptron* (ou Perceptron Multicamadas) é uma rede neural com uma ou mais camadas ocultas e um número indeterminado de neurônios.
	B – LSTM	*Long short-term 18entim* (LSTM) é uma rede neural recorrente artificial, usada no campo do aprendizado profundo. Ele pode não apenas processar pontos de dados individuais, mas também sequências inteiras de dados
	C – HONN	*Higher Order Neural Networks* (HONN) podem simular negócios não lineares de alta frequência e lidar com descontinuidades na entrada conjunto de dados de treinamento
	D – CNN	A rede neural *convolucional* (CNN ou ConvNet) é uma classe de redes neurais profundas, mais comumente aplicada à análise de imagens visuais. Eles têm aplicações em reconhecimento de imagem e vídeo, processamento de linguagem natural, interfaces cérebro-computador e séries temporais financeiras.
	E – Outros	Demais métodos não relacionados à subcategoria 3ª a 3D
4. Teorias relacionadas aos objetivos dos artigos	A – Teoria dilema do passeio aleatório	As previsões geradas pelos modelos mostram um atraso característico de uma etapa em relação aos dados da série temporal original. Este comportamento tem sido visto como um dilema em relação à representação financeira das séries temporais, onde foi colocado que as séries seguem um modelo de passeio aleatório e não podem, portanto, ser previstas. A principal razão por trás dessa teoria é que os pesquisadores acreditam que os preços das ações foram afetados principalmente por notícias e política.
	B – Teorias sobre a volatilidade do mercado de ações	Diversos estudos discorrem sobre a relação preço x volume, e sua volatilidade.
	C – Não mencionadas	Não foram mencionadas

Categorias	Subcategorias	Definição
5 – Tipos de dados analisados	A – Preços diários do fechamento de ações	Trata-se da cotação do último negócio fechado no dia para determinada ação no pregão.
	B – Preços de abertura e preços de fechamento diários de ações	A cotação de abertura representa o preço pelo qual foi executado o primeiro negócio com um determinado ativo no pregão em questão. Já o de fechamento, qual foi o preço no qual o último negócio foi executado no pregão em questão.
	C – Preços de abertura, de fechamento, mais alto, mais baixo e volume negociado	A cotação de abertura representa o preço pelo qual foi executado o primeiro negócio com um determinado ativo no pregão em questão. Já o de fechamento, qual foi o preço no qual o último negócio foi executado no pregão em questão. O preço mais alto é mais elevado no qual as ações foram negociadas em um determinado pregão, ou seja, o melhor ponto do dia para o vendedor e, consequentemente, o pior para o comprador. O mínimo, o menor preço em que foi fechado um negócio. No conceito de volume, qual o total de recursos transacionados.
	D – Fechamento diário de Índice de Preços de Ações	Trata-se da última cotação do dia para determinado índice de preços de ações
	E – Outras associações	Demais métodos não relacionados à subcategoria 5ª a 5D
6 – Origem dos dados	A – Estados Unidos e Canadá	Dados de operações nos Estados Unidos e / ou no Canadá.
	B – Europa	Dados de operações na Europa
	C – Ásia / Oceania	Dados de operações na Ásia e/ou Oceania.
	D – América Latina	Dados de operações na América Latina.
	E – África	Dados de operações na África.
	F – Não mencionado	Dados de origem não mencionada
7. Período de análise	A – Até 5 anos	Dados entre 0 e 5 anos.
	B – De 6 a 10 anos	Dados entre 6 e 10 anos
	C – Mais de 10 anos	Acima de 10 anos
	D – Não se aplica / não informado	Estudos que não informam o período de análise
8. Resultados	A – Novas perspectivas ou novas conclusões	Apresentação de uma nova teoria novas conclusões sobre temas já discutidos anteriormente.
	B – Conclusões semelhantes a trabalhos anteriormente apresentados	Estudos que não apresentam novas perspectivas, nem novas conclusões
	C – Outros	Demais resultados não relacionados às subcategorias 8ª a 8B

Categorias	Subcategorias	Definição
9. Conclusões sobre objetivos dos estudos	A – Confirmação do objetivo principal	Estudo confirma o objetivo principal proposto pelo autor
	B – Não confirmação do objetivo principal	Estudo não confirma o objetivo principal proposto pelo autor
	C – Resultado não conclusivo em relação ao objetivo principal	Estudo apresenta resultado não conclusivo sobre o objetivo principal proposto pelo autor
	D – Não se aplica	Demais conclusões não relacionadas às subcategorias 9ª a 9C
10. Avenidas para estudos futuros	A– Examinar outros modelos utilizando MLP	Pesquisas que utilizem MLP, mas com padrões diferentes
	B – Examinar diferentes modelos de redes neurais artificiais	Pesquisas que se utilizem de outras redes neurais artificiais para esse fim
	C – Avaliar outros modelos de previsão do preço de ações	Pesquisas que considerem outros modelos de previsões de preços de ações, além das redes neurais artificiais
	D – Não mencionadas	Não mencionaram avenidas para estudos futuros.

Etapa 6 – Leitura e codificação dos artigos. Trata-se da identificação dos objetivos, amostra, métodos e contribuições dos artigos. Além disso, eles são classificados e codificados em categorias e subcategorias estruturadas, conforme a Tabela 2. Cada uma das 10 categorias possui suas próprias subcategorias e um único artigo pode ser classificado em mais de uma subcategoria.

Etapa 7 – Revisão sistemática. Após a codificação da matriz de (sub) categorização da Tabela 2 a partir dos 26 artigos da amostra final, é realizada a contagem de frequência das subcategorias, de maneira a facilitar a identificação das lacunas de conhecimento. A partir disso, essas lacunas são comparadas com as subcategorias da Categoria 10 – Avenidas para estudos futuros, a fim de se obter hiatos passíveis de novos estudos.

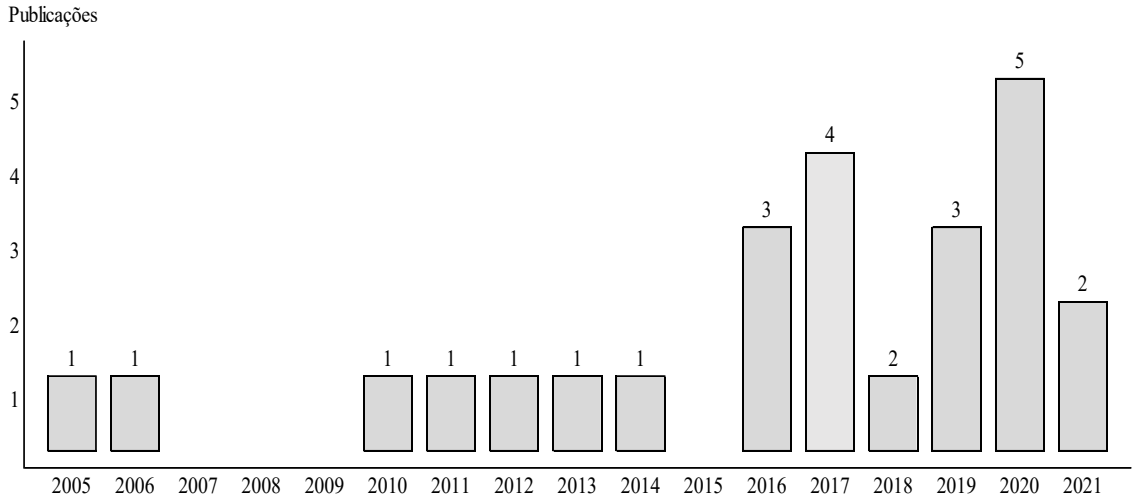
2.4 Análise dos Resultados

Os resultados da análise bibliométrica são apresentados no item 2.4.1, mencionado na Etapa 5 da Metodologia. No item 2.4.2 estão os resultados da revisão sistemática, com passos descritos das Etapas 6 e 7 do item 2.3.

2.4.1 Análise Bibliométrica

De acordo com a Figura 2, a amostra final é composta por 26 artigos, distribuídos entre os anos de 2005 e 2021, obtidos a partir da base WoS, e nesse período identifica-se a publicação de até 5 artigos por ano, que tratam do tema previsão de preços de ações utilizando RNA MLP.

Figura 2 – Distribuição Anual dos Artigos



Fonte: Biblioshiny

A Tabela 3 apresenta a frequência das 69 palavras-chave identificadas nos 26 artigos da amostra final do estudo, com destaque para *prediction* (10,1%), *model / models* (7,2%) e *neural-network* (5,8%).

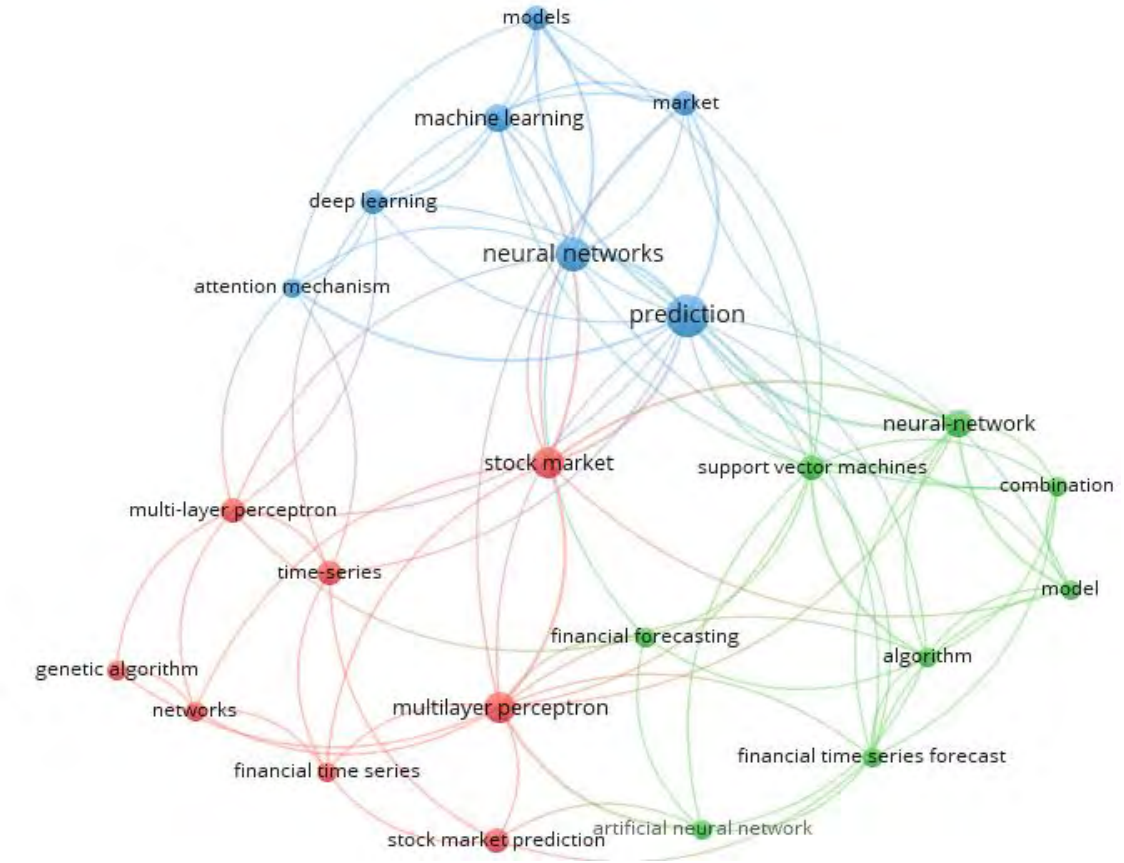
Quadro 3 – Palavras-chave

Palavras-chaves	Quantidade	Frequência %
Prediction	7	10,1%
Model / models	5	7,2%
Neural-network	4	5,8%
Market	3	4,3%
Support vector machines	3	4,3%
Time-serie	3	4,3%
Algorithm	2	2,9%
Combination	2	2,9%
Hybrid	2	2,9%
Suport	2	2,9%
Networks	2	2,9%
Outras palavras-chave com menos de 2 ocorrências	34	49,3%
Total de palavras-chave	69	100%

Fonte: Biblioshiny

A Figura 3 apresenta o mapa de coocorrências das palavras-chave mais utilizadas nos artigos da amostra final. O tamanho dos nós indica maior relevância dessas palavras nos artigos e a espessura das linhas indica a força da ligação entre elas, enquanto as cores destacam os grupos. Destacam-se as palavras *prediction, neural-networks e support vector machines*, resultado aderente ao da Tabela 3.

Figura 3 – Mapa de coocorrências das palavras-chave



Fonte: VosViewer

As Leis de Zipf (1949) indicam que há uma otimização no seu uso. Assim, elas não se dispersam. Ao contrário, há uma tendência de uso mínimo das palavras-chave, possuindo alta frequência de ocorrência. A primeira lei de Zipf afirma que série (r) de uma palavra o produto da ordem de pela sua frequência de ocorrência (f) é aproximadamente constante (C), resultando na Equação 2:

$$r \times f = C \quad (1)$$

Para palavras com baixa frequência, Zipf propôs uma segunda lei, sendo revisada e modificada por Booth (1967). Segundo o autor, em um determinado texto, várias palavras com baixa frequência de ocorrência têm a mesma assiduidade – vide Equação 2:

$$I_n = 2I_1 / n\,(n+1) \quad (2)$$

Em que:
I_1 = número de palavras que têm frequência 1
I_n = número de palavras que têm frequência n
n = ponto de Goffman ou local de transição das palavras de baixa para as de alta frequência

As leis de Zipf definem extremidades em uma lista de palavras. Entre esses pontos extremos, há a região de transição das palavras de alta para as de baixa frequência. De acordo com Goffman (1971), nessa região estão as palavras de maior conteúdo semântico, sendo elas as mais adequadas para a indexação temática de um texto. Pao (1978) apresenta a fórmula do ponto T ou de transição de Goffman, conforme a equação 3.

$$T = \left(-1+\sqrt{1+8I_1}\right) / 2 \quad (3)$$

Em que:
T = ponto de transição de Goffman
I_1 = número de palavras que têm frequência 1

Quadro 4 – T de Goffman

No.	Autor	T de Goffman
1	Belciug e Sandita, 2017	43,75
2	Al-Shboul e Alsharari, 2019	42,86
3	Araujo e Ferreira, 2013	41,36
4	Chandar, 2021	40,66
5	Nayak, Misra e Behera, 2017	39,88
6	Makinen *et al.*, 2019	39,80
7	Bildirici e Ersin, 2014	37,82
8	Demirel, Cam e Unlu, 2021	36,54
9	Chen, Zhang e Lou, 2020	35,86
10	Li e Tam, 2018	35,70
11	Hammed, Hussein e Tolba, 2012	35,59
12	Nayak, Misra e Behera, 2018	35,48
13	Maia e de Carvalho, 2011	34,97
14	JuHyok *et al.,* 2010	34,77
15	Mostafa, 2010	34,35
16	Tufekci, 2016	34,20
17	Eiamkanitchat, Moontuy e Ramingwong, 2017	33,91
18	Vochozka, Horak e Krulicky, 2020	33,68
19	Nayak, Misra e Behera, 2016	32,91
20	Ding e Qin, 2020	32,85
21	Nayak (2019)	32,73
22	Kashei e Hajirahimi, 2017	31,69
23	Lunga e Marwala, 2006	31,66
24	Karathanasopoulos, 2016	30,49
25	Lu *et al.,* 2020	29,40
26	Michalak e Lipinski, 2005	25,08

A identificação do ponto T de Goffman ocorre mediante ordenamento decrescente das palavras pelo software Rank Words. Na sequência, são identificadas aquelas que se repetem apenas uma única vez para cálculo do ponto T. Depois, são localizadas aquelas palavras acima da classificação indicada por esse ponto. A Tabela 4 indica que - para os 26 artigos da amostra final - o ponto de transição das palavras de baixa para as de alta frequência varia entre 25,08 (Michalak e Lipinski, 2005) e 43,75 (Belciug e Sandita, 2017), sendo que sua média é de 35,31.

Uma vez calculado o ponto T de Goffman de cada artigo, é possível realizar a análise da região na qual estão as palavras mais aderentes ao tema principal do texto. Na sequência, exclui-se as que não são relevantes ao estudo, como preposições, artigos definidos e indefinidos, pronomes e advérbios e classifica-se as palavras que possuem maior frequência, conforme Tabela 5.

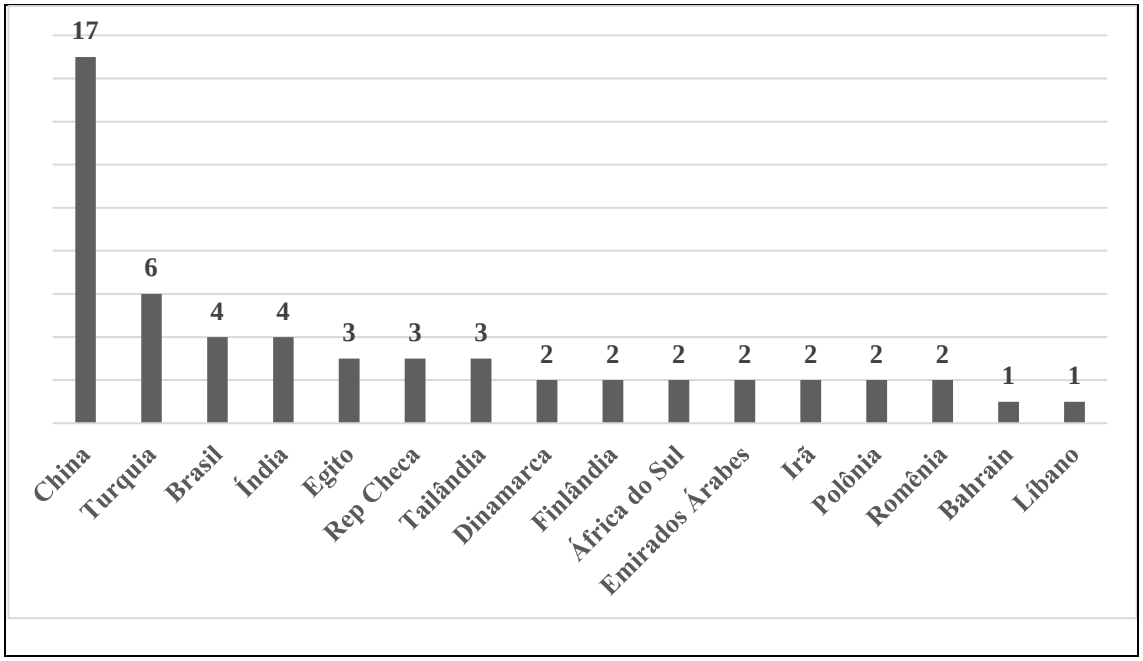
Quadro 5 – Classificação de palavras – Lei de Zipf

No.	Autor	Palavra	Frequência
1	Bildirici e Ersin, 2014	*model*	295
2	Al-Shboul e Alsharari, 2019	*efficiency*	194
3	Kashei e Hajirahimi, 2017	*model*	155
4	JuHyok et al., 2010	*prediction*	126
5	Makinen et al., 2019	*data*	121
6	Araujo e Ferreira, 2013	*series*	117
7	Eiamkanitchat, Moontuy e Ramingwong, 2017	*stock*	115
8	Maia e de Carvalho, 2011	*interval*	106
9	Nayak, Misra e Behera, 2018	*data*	105
10	Ding e Qin, 2020	*model*	104
11	Vochozka, Horak e Krulicky, 2020	*networks*	101
12	Nayak, Misra e Behera, 2017	*forecasting*	94
13	Chen, Zhang e Lou, 2020	*model*	92
14	Demirel, Cam e Unlu, 2021	*stock*	88
15	Lu et al., 2020	*data*	82
16	Tufekci, 2016	*index*	79
17	Hammed,Hussein e Tolba, 2012	*Stock*	76
18	Chandar, 2021	*model*	70
19	Nayak, 2019	*forecasting*	66
20	Li e Tam, 2018	*market*	63
21	Mostafa, 2010	*neural*	62
22	Nayak, Misra e Behera, 2016	*model*	57
23	Michalak e Lipinski, 2005	*data*	55
24	Lunga e Marwala, 2006	*algorithm*	45
25	Karathanasopoulos, 2016	*trading*	43
26	Belciug e Sandita, 2017	*regression*	28

No artigo de Bildirici e Ersin (2014), a palavra *model* possui a maior frequência, ou seja, ela se repete 295 vezes num texto com 12.315 palavras. Além disso, verifica-se que a palavra *model* é a mais citada em 06 dos 26 (23%) artigos da amostra final. Palavras como *stock, data, forecasting, trading, regression, prediction, neural, networks, market, interval, index, efficiency* e *algorithm* também possuem alta frequência nos 20 (77%) outros artigos da amostra final.

Também são identificados 56 autores para a amostra final de 26 artigos, e desses, apenas 5 publicam individualmente. A Figura 4 demonstra que esses 56 autores estão associados a instituições de 16 países, sendo que 17 deles (30%) estão associados a instituições localizadas na China, 6 (11%) a instituições turcas, 4 (7%) brasileiras, 4 (7%) indianas, e as demais distribuídas entre o Egito, a República Checa, Tailândia, Dinamarca, Finlândia, África do Sul, Emirados Árabes, Irã, Polônia, Romênia, Bahrain e Líbano.

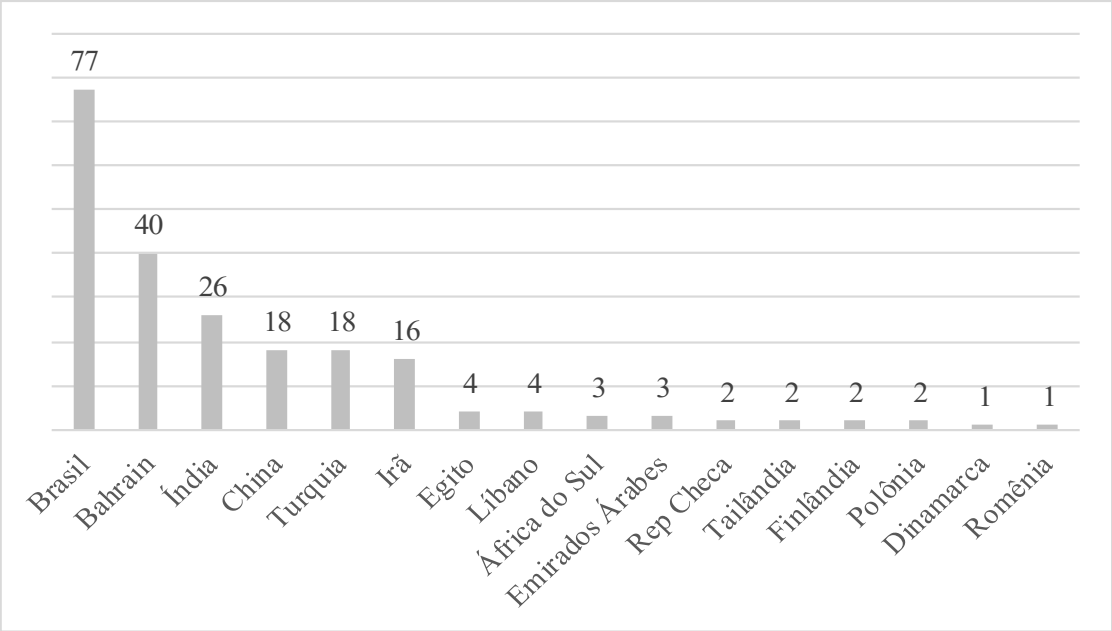
Figura 4 – Frequência dos artigos dos países das instituições às quais os autores estão associados (número de artigos versus país da instituição)



A Figura 5 indica que das 219 citações totais, 77 (35%) são de artigos elaborados por autores associados a instituições localizadas no Brasil. As demais citações são de autores que estão associados aos seguintes países: Bahrain 40 (18%) Índia 26 (12%), China 18 (8%), Turquia 18 (8%), Irã 16 (7%), Egito 4 (2%), Líbano 4 (2%) África do Sul 3 (1,4%), Emirados Árabes Unidos 3 (1,4%), República Checa 2 (0,9%), Tailândia 2

(0,9%), Finlândia 2 (0,9%) e Polônia 2 (0,9%), Dinamarca 1 (0,5%) e Romênia 1 (0,5%).

Figura 5 – Frequência das citações dos artigos dos países das instituições às quais os autores estão associados (citações por país da instituição)



A Lei de Bradford (1934) verifica que há poucos periódicos que produzem muitos artigos, e muitos periódicos que produzem poucos artigos, sobre um determinado tema. Para Brookes (1969), a referida lei estima o grau de relevância de determinados periódicos acadêmicos que atuam em áreas de conhecimento específica. Assim, caso os periódicos sejam classificados por ordem decrescente de produtividade, eles podem ser distribuídos em zonas que possuem uma variação na proporção 1: n: n^2 e assim por diante.

Referidas zonas são formadas ao dividir o total de artigos publicados por dois. A zona A identifica-se como o *core* dos assuntos, composto por periódico com duas publicações, o Ain Shams Engineering Journal. Na zona B apresenta-se os periódicos com apenas uma única publicação.

O Quadro 6 indica que na zona A estão 8% das publicações sobre o tema de projeção de preços de ações com redes neurais *multi layer perceptron*, e que esse percentual limita-se a apenas um periódico acadêmico.

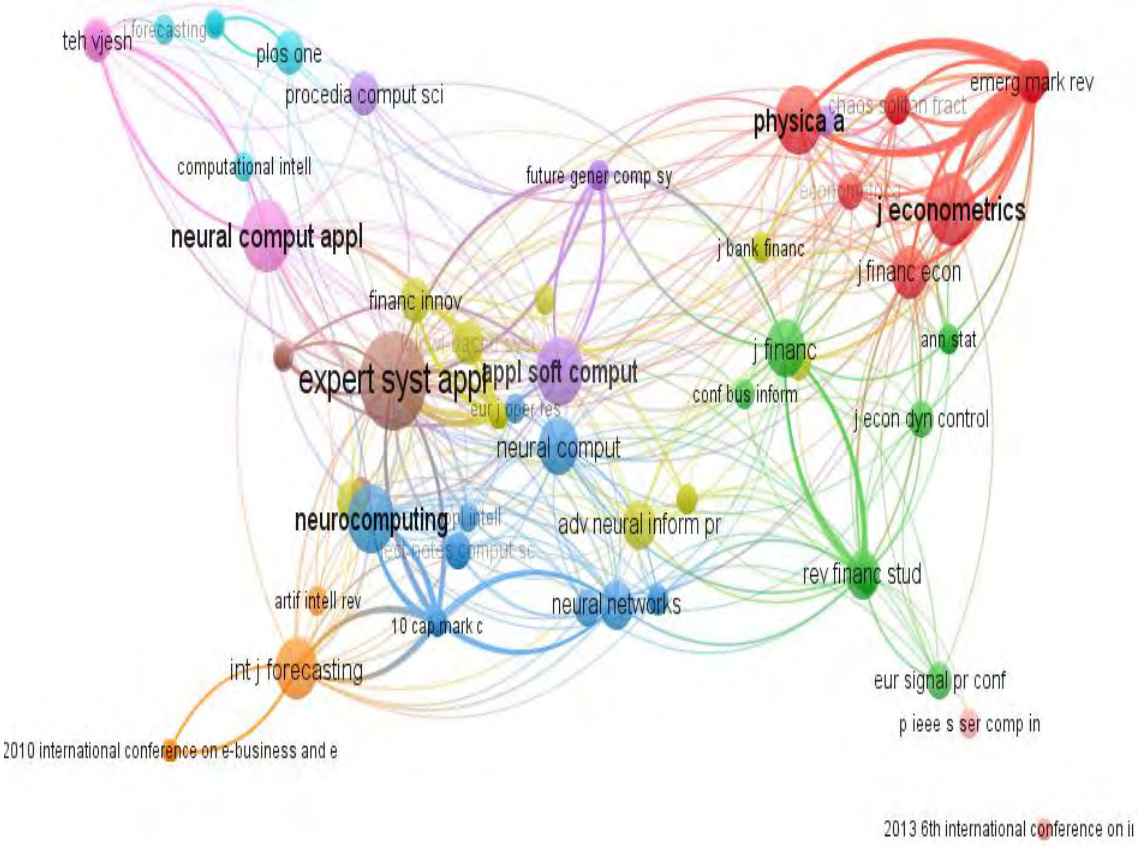
Quadro 6 –Lei de Bradford sobre os periódicos

Zona	Periódicos	Quantidade Individual	Quantidade Acumulada	% Acumulação
A	Ain Shams Engineering Journal	2	2	8%
B	Algorithms	1	3	12%
	Annals of the University of Craiova-mathematics and Computer Science Series	1	4	15%
	Chaos Solitons & Fractals	1	5	19%
	Cluster Computing the Journal of Netsworks Software Tools and Applications	1	6	23%
	Complexity	1	7	27%
	EAI Endorsed Transactions on Scalable Information Systems	1	8	31%
	Economics and Business Letters	1	9	35%
	Expert Systems With Applications	1	10	38%
	Financial Innovation	1	11	42%
	Gazi University Journal of Science	1	12	46%
	IEEE Access	1	13	50%
	Information Sciences	1	14	54%
	Intelligent Data Analysis	1	15	58%
	International Journal of Applied Metaheuristic Computing	1	16	62%
	International Journal of Computational Intelligence Systems	1	17	65%
	International Journal of Forecasting	1	18	69%
	International Journal of Machine Learning and Cybernetics	1	19	73%
	Marketing and Management of Innovations	1	20	77%
	Neural Information Processing	1	21	81%
	Neural Network World	1	22	85%
	Quantitative Finance	1	23	88%
	Quarterly Review of Economics and Finance	1	24	92%
	Scientific World Journal	1	25	96%
	Soft Computing	1	26	100%

A Figura 5 apresenta a rede de cocitação entre os periódicos da amostra final de 26 artigos. Os mais citados são os periódicos Expert Systems With Applications com 20 cocitações; Econometrics e Neural Computing and Applications com 11 cocitações cada;

Physica A, Neurocomputing e Applied Soft Computing, com 10 cocitações cada. Destes, nenhum se destaca no Quadro 6. Tal fato demonstra que os periódicos que mais publicam sobre um determinado tema não são necessariamente os mais citados, enfatizando a importância dos artigos. O tamanho dos nós indica a relevância dessas palavras nos artigos, a espessura das linhas está relacionada à força de ligação entre elas, e as cores separam os grupos.

Figura 6 – Mapa de cocitações entre periódicos



Fonte: VOSviewer.

Já a Tabela 7 apresenta os artigos sobre o tema de previsão do preço de ações com redes neurais *multi lyer perceptron* e suas citações. Entre eles, destaca-se o artigo de Maia e Carvalho (2011) com 51 (23%) das citações e média anual de 4,636. O artigo apresenta a três abordagens para a previsão de séries temporais, sendo que se baseiam em redes neurais MLP, métodos de suavização exponencial de Holt, e em uma metodologia híbrida que combina os modelos MLP e Holt, respectivamente. O segundo e o terceiro artigos mais citados são os de Mostafa (2010) e Araujo e Ferreira (2013), com 40 (18%) e 26 (12%) citações respectivamente.

Quadro 7 – Citações dos artigos

Autores	DOI do artigo	Total de citações	Média de citações por ano	Concentração das citações
Maia e de Carvalho (2011)	10.1016/j.ijforecast.2010.02.012	51	4,636	23%
Mostafa (2010)	10.1016/j.eswa.2010.02.091	40	3,333	18%
Araujo e Ferreira (2013)	10.1016/j.ins.2009.07.007	26	2,889	12%
Kashei e Hajirahimi (2017)	10.1186/s40854-017-0074-9	16	3,200	7%
Nayak, Misra e Behera (2017)	10.1016/j.asej.2015.07.015	14	2,800	6%
Bildirici e Ersin (2014)	10.1155/2014/497941	14	1,750	6%
JuHyok *et al*. (2010)	10.1016/j.chaos.2019.109559	7	3,500	3%
Nayak, Misra e Behera (2016)	10.4018/IJAMC.2016040103	7	1,167	3%
Ding e Qin (2020)	10.1007/s13042-019-01041-1	6	3.000	3%
Nayak, Misra e Behera (2018)	10.1016/j.asej.2016.10.009	4	1,000	2%
Li e Tam (2018)	10.3390/a11110170	4	1,000	2%
Karathanasopoulos (2016)	10.17811/ebl.5.2.2016.50-57	4	0,667	2%
Tufekci (2016)	10.3233/IDA-160809	4	0,667	2%
Hammed, Hussein e Tolba (2012)	10.1080/18756891.2012.718108	4	0,400	2%
Al-Shboul e Alsharari (2019)	10.1016/j.qref.2018.05.007	3	1,000	1%
Makinen *et al.* (2019)	10.1080/14697688.2019.1634277	3	1,000	1%
Lunga e Marwala, 2006	NA	3	0,188	1%
Vochozka, Horak e Krulicky (2020)	10.21272/mmi.2020.2-24	2	1,000	1%
Eiamkanitchat, Moontuy e Ramingwong (2017)	10.1007/s10586-016-0694-2	2	0,400	1%
Michalak e Lipinski (2005)	NA	2	0,118	1%
Chen, Zhang e Lou (2020)	10.1109/ACCESS.2020.3004284	1		0%
Nayak (2019)	10.4108/eai.10-6-2019.159345	1		0%
Belciug e Sandita (2017)	NA	1		0%
Demirel, Cam e Unlu (2021)	10.35378/gujs.679103	0		0%
Lu et al. (2020)	10.1155/2020/6622927	0		0%
Chandar (2021)	10.1007/s00500-020-05174-2	0		0%
Total de citações		219		100%

Fonte: Biblioshiny

Lotka (1926) afirma que um pequeno número de autores produz muitos artigos e que a produção obtida por esse reduzido número de pesquisadores se iguala em quantidade ao desempenho dos demais. Essa teoria é denominada de Lei do Quadrado Inverso – vide Equação 4.

$$Na = a_1 / n^2, n = 1, 2, 3 \ldots \quad (4)$$

Em que:
na = número de autores que publicaram n artigos
a_1 = número de autores que publicaram um artigo
n = número de artigos publicados por autor

Na Equação 5, Chung e Cox (1990) esclarecem que o número de autores com um único artigo publicado, conforme a Lei de Lotka, seria de:

$$a_1 = 6 / \pi^2 = 0{,}6079 = 60{,}8\% \quad (5)$$

Assim, um autor com dois artigos publicados deveria ter a frequência de 15,2% ($0{,}6079/2^2$), um autor com três artigos publicados seria de 6,8% ($0{,}6079/3^2$), e um autor com quatro artigos publicados seria de 6,8% ($0{,}6079/4^2$).

Verifica-se que os 26 artigos da amostra final são produzidos por 56 autores, e que um autor publica 4 artigos, dois autores publicam 3 artigos, e os demais autores publicam um único artigo. 20% dos autores (incluindo aí os que mais publicam), são responsáveis por 29% das publicações, contudo não há um número menor de pesquisadores se igualando em quantidade ao desempenho dos demais, impossibilitando a confirmação da Lei de Lotka.

Quadro 8 – Aplicação Lei de Lotka

Número de artigos	Número de autores	% Autores	% Lotka
1	53	94,6%	60,79%
2	0	0%	15,20%
3	2	3,6%	6,80%
4	1	1,8%	3,80%
Total	56	100%	

Fonte: Biblioshiny

2.4.2 Revisão Sistemática

A revisão sistemática da literatura busca identificar as lacunas do conhecimento relacionadas ao tema deste estudo – previsão do preço de ações com redes neurais *multi layer perceptron*. Para tanto, na Etapa 6 do Item 3 – Metodologia, é definida uma matriz de (sub) categorização – vide Tabela 2. Para cada um dos 26 artigos da amostra final, há a identificação de até 3 subcategorias por categoria. Assim, a contagem de frequência é feita em relação ao total das subcategorias e não sobre o total dos 26 artigos.

A Figura 7 destaca as subcategorias com maior e menor frequência – aquelas que têm potencial para serem priorizadas em pesquisas futuras. Na categoria 1, o tema de previsão do preço de ações com RNA MLP (A) é o centro de 23% dos artigos analisados, sendo que essas pesquisas diferem entre si pelos seus métodos de refinamento e arquiteturas. Isso ocorre porque não existe um método padrão para se encontrar a estrutura final mais adequada ao processo de modelagem, então são realizados testes iterativos com diferentes quantidades e qualidades de informações de entrada, pois ainda que a arquitetura seja a melhor, o desempenho será comprometido se os recursos de entrada não forem bem selecionados. Além disso o número de camadas e de neurônios por camada também variam, e tudo isso se reflete diretamente na assertividade das respostas das camadas de saída.

A previsão do preço de ações com outras RNA e resultados comparados às RNA MLP (B), é o tema de 35% dos artigos e constam ainda outros 12% adicionais, que estudam tanto a previsão do preço de ações com RNA MLP, como com outras RNA e as comparam esses resultados (A+B). Há ainda a oportunidade de estudo da previsão dos preços de ações através de modelos híbridos, entre redes neurais artificiais MLP e outras redes neurais, como demonstram 19% dos estudos.

A categoria 2 indica que 35% dos artigos concentram seus métodos de pesquisa em RNA, que são técnicas computacionais que apresentam um modelo matemático inspirado na estrutura neural de organismos inteligentes (A), outros 35% aliam como método de pesquisa ao RNA, modelos estatísticos para séries temporais (B), como ARMA, ARIMA, GARCH, e 23% utilizam-se de outros métodos de pesquisa (C). Ainda constam 8% que aliam RNA, modelos estatísticos para séries temporais e ainda outros métodos de pesquisa (A+B+C).

Quanto às redes neurais utilizadas na pesquisa, a categoria 3 também apresenta subcategorias combinadas. Assim, 58% dos artigos utilizam-se de redes neurais artificiais MLP (A), 15% utilizam-se além de RNA MLP, a LSTM (A+B), que é uma rede neural recorrente artificial, usada no campo do aprendizado profundo, que pode não apenas processar pontos de dados individuais, mas também sequências inteiras de dados. 8% aliam às RNA outras redes neurais (A+E), e 8% combinam MLP, LSTM e CNN (A+B+D).

Quanto às teorias que suportam a previsão do preço de ações com RNA MLP, categoria 4, destacam-se a teoria do dilema do passeio aleatório (A), mencionada em 3 artigos (12%) e a sua associação com teorias acerca da volatilidade do mercado de ações, mencionada em um artigo (4%, A+B). Os demais artigos não mencionaram teorias associadas aos seus objetivos ou hipóteses.

A teoria do dilema do passeio aleatório, ou hipótese do passeio aleatório, mencionada em 3 artigos, é um fenômeno estatístico segundo o qual as variáveis movem-se ao acaso. A teoria do passeio aleatório aplicada aos negócios foi apresentada por Burton Gordon Malkiel, em seu livro A Random Walk Down Wall Street, em 1973, e afirma que os preços das ações movem-se ao acaso, e por isso, qualquer tentativa de prever seus preços, é inútil.

Ying (1966) estuda a volatilidade do mercado de ações, em especial a relação entre preço e volume negociados, mencionada em um artigo. Ele destaca que são resultado de um mecanismo único no mercado. A partir de seus resultados, Crouch (1970) conclui que é questionável afirmar que a teoria de oferta e a demanda é útil na análise do mercado de ações.

Já na categoria 5, tipos de dados analisados, 62% dos artigos enquadram-se na subcategoria que se utiliza dos preços diários de fechamentos das ações como a principal fonte de dados dos estudos, 15% utilizam-se dos preços de abertura, de fechamento, mais alto, mais baixo e volume negociado, 8% preços de abertura e preços de fechamento diários de ações e 4% fechamento diário de Índice de Preços de Ações. As variações nos tipos de dados analisados estão diretamente relacionadas à origem, aos objetivos e à profundidade de cada uma das pesquisas.

Com relação à origem dos dados, a categoria 6 demonstra pulverização em suas subcategorias. 23% dos dados são originários da Ásia / Oceania NA, 15% originários do Estados Unidos e Canadá (A), e esse percentual se repete para Europa (B), e Estados Unidos, Canadá, Europa, Ásia e Oceania (A+B+C), demonstrando que os estudos se concentram especialmente em países desenvolvidos. Assim, há larga oportunidade para investigações com dados oriundos da América Latina e da África.

Quanto ao período das análises, categoria 7, temos que as subcategorias até 5 anos (A), de 06 a 10 anos (B) e mais de 10 anos (C), distribuem-se igualitariamente, com frequência de 31% cada.

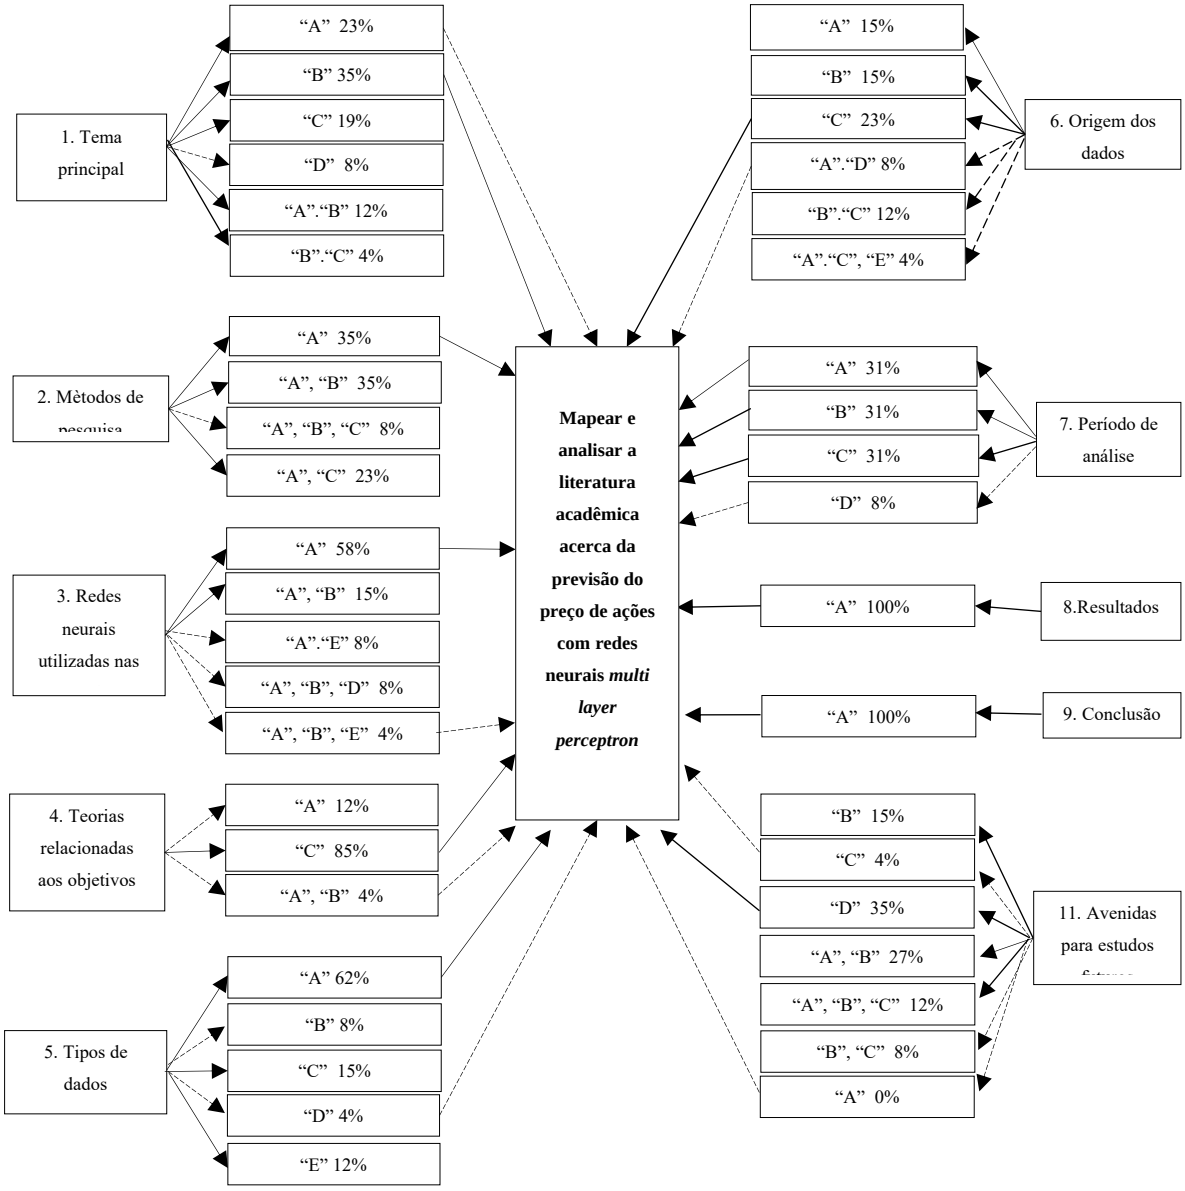
A categoria 8 conclui que 100% dos artigos apresentam novas perspectivas ou novas conclusões, nenhum artigo apresenta conclusões semelhantes a trabalhos anteriormente apresentados. Além disso, de acordo com a categoria 9, 100% dos artigos confirmaram o objetivo principal de seus estudos.

Por fim, a categoria 10 indica as avenidas para estudos futuros ou lacunas do conhecimento – segundo a perspectiva dos autores dos 26 artigos da amostra final.

Em 15% das subcategorias, os autores sugerem a realização de estudos a respeito da previsão do preço de ações, com outros modelos de RNA (B). 27% sugerem a realização de testes com outras modelagens de RNA MLP, somados a outros modelos de RNA (A+B). 12% sugerem que a isso se somem ainda a avaliação de outros modelos de previsão do preço de ações (A+B+C).

Pelo exposto, destacam-se os principais aspectos a serem investigados em estudos futuros relacionados ao tema de previsão do preço de ações com RNA MLP: a) diferentes arquiteturas e processos de mineração de dados em MLP, ou seja, qualidade dos dados de entrada, dos número de camadas, de neurônios por camada e de camadas de saída diversos dos já pesquisados; b) a soma dos resultados das RNA MLP a outros modelos de RNA e/ou a outros modelos de previsão do preço de ações; c) aliar ao estudo dos preços de fechamento diário das ações, o das variações e as relações entre os de abertura, os mais altos, os mais baixos, os volumes negociados e os índices de preços das ações; e d) dados oriundos dos mercados da América Latina e da África.

Figura 7 – Análise de (sub) categorias para identificar lacunas de conhecimento



Observação:

Subcategoria com maior frequência em cada categoria
Subcategoria a ser priorizada nas pesquisas

Quadro 9 – Principais contribuições dos artigos da amostra

No	Referência	Principal recurso de pesquisa	Dados analisados	Contribuições
1	Al-Shboul e Alsharari (2019)	MLP	Preços diários de fechamento das ações, do Mercado Financeiro de Dubai e da Bolsa de Valores de Abu Dhabi	O comportamento dinâmico da eficiência em evolução: i) a volatilidade é altamente persistente; mas ii) o grau de persistência da volatilidade não responde ao movimento dos preços assimétricos das ações
2	Araújo e Ferreira (2013)	EMRLF (MRL + MGA), comparado ao MLP e TAEF	Preços diários de fechamento das ações Petrobras (B3 S.A.), Microsoft, Yahoo e Directv (Nasdaq)	Um método evolutivo Morphological-Rank-Linear para a previsão do mercado de ações: o modelo proposto obteve um desempenho muito melhor do que um modelo de passeio aleatório para as séries temporais financeiras
3	Belciug e Sandita (2017)	MLP	Preços diários de fechamento das ações, da Bolsa de Valores da Romênia	O MLP apresentou desempenho bastante satisfatório em 6 das 10 empresas analisadas, mas considerar que usaram uma arquitetura padrão de MLP sem ajustar os seus parâmetros, pois não era esse o propósito deste estudo. É esperado que uma otimização da arquitetura MLP levará a um aumento na porcentagem de empresas para as quais o preço de fechamento do dia pode ser previsto
4	Bildirici e Ersin (2014)	MLP e Recurrent-NN, o MS-ARMA-FIAPGARCH-Hybrid MLP e MS-ARMA-FIAPGARCH-RNN	Preços diários de fechamento do Índice de Ações de Istambul – ISE 100	Os resultados sugerem que o modelo MS-GARCH fornece resultados promissores, enquanto os melhores resultados são obtidos em rede neural. Além disso, os modelos baseados no Hybrid-MLP e Recurrent-NN, no MS-ARMA-FIAPGARCH-HybridMLP e no MS-ARMA-FIAPGARCH-RNN fornece melhores desempenhos de previsão
5	Chandar (2021)	ENN, FPA-ELM, PSO-MLP, PSOElman, CSO-ARMA e GA-LSTM	Preços diários de fechamento das ações AAPL, BAC, CTSH, GS, HAL, MSFT, IOS e ORCL (NASDAQ e NYSE)	O resultado experimental e medidas estatísticas indicam claramente que ENN otimizados pelo algoritmo GWO fornecem melhores resultados. Além disso, os resultados comprovam que o desempenho do GWO-ENN substitui outros modelos de RNAs otimizados por algoritmos como PSO, FPA.
6	Chen (Zhang e Lou (2020)	MLP e memória bidirecional de longo-prazo	Preços de abertura, mais alto, mais baixo e de fechamento dos índices de ações S&P 500, NASDAQ, Russell 2000 e Dow Jones	Um novo modelo híbrido de aprendizado profundo, MLP e BiLSTM foi proposto. Os resultados demonstraram o bom desempenho de previsão do modelo.

No	Referência	Principal recurso de pesquisa	Dados analisados	Contribuições
7	Demirel (Cam e Unlu (2021)	MLP, SVM, LSTM	Preços diários de abertura e fechamento de ações de 42 empresas listadas no Índice Nacional 100 da Bolsa de Valores de Istambul (ISE-100)	O modelo comparou os desempenhos de previsão de MLP, SVM e LSTM. Os resultados mostram que os modelos MLP e LSTM tornam-se vantajosos ao estimar os preços de abertura e fechamento das ações em comparação com o SVM
8	Ding e Qin (2020)	MLP, RNC, Bayes, LSTM	Preços diários de abertura e fechamento das ações, do Índice composto de Xangai 01, e das ações da PetroChina nas Bolsas de valores de Xangai e Shenzhen.	Os experimentos mostram que na precisão do modelo associado é superior aos outros dois modelos na previsão de vários valores ao mesmo tempo, e suaa precisão da previsão é superior a 95% novas perspectivas
9	Eiamkanitchat, Moontuy e Ramingwong (2017)	MLP	Preços diários de fechamento das ações da Bolsa de Valores da Tailândia – Ásia	Os modelos obtidos pelas redes neurais Hybrid-MLP e Recurrent-NN, no MS-ARMA-FIAPGARCH-Hybrid MLP e no MS-ARMA-FIAPGARCH-RNN para aplicações econômicas, foram melhores que os obtidos por GARCH
10	Hammed, Hussein e Tolba (2012)	MLP com KLD	Preços de abertura, de fechamento, mais alto, mais baixo e volume de 04 ações da Bolsa de Valores do Egito e da Microsoft, na Nasdak	Apresentou uma nova previsão do mercado de ações modelo baseado na separação cega da fonte para estoque previsão de sinais de mercado, usando Redes Neurais MLP com algoritmo KLD
11	JuHyok et al. (2010)	SVM, MLP e CNN	Preços diários de fechamento de 10 ações com mais de 2.500 dias de negociação, selecionados aleatoriamente do mercado chinês e americano	Um novo modelo de previsão de ponto de reversão de preço de ações baseado em LSTM foi proposto, com resultados melhores que os obtidos com SVM, MLP e CNN
12	Karathanaso poulos (2016)	PSO RBF, MACD, ARMA,o ARMA-PSO e Buy and Hold, HONN, RNN e RBF PSO	Fechamento diário do Índice inglês FTSE100 – Bolsa de Londres	A relevância dos critérios pré-seleção de entrada de dados antes de treinar cada uma das redes neurais
13	Kashei e Hajirahimi (2017)	ARIMA, ARIMA-MLP, MLP-ARIMA	Preços diários de fechamento do Índice Integrado de Shenzhen (SZII) e da S&P 500	Os modelos híbridos de predição têm um desempenho melhor que os individuais, nos modelos ARIMA e MLP na forma como estudados

No	Referência	Principal recurso de pesquisa	Dados analisados	Contribuições
14	Li e Tam (2018)	MLP, SVM, DT, LSTM	Preço de abertura, de fechamento, média móvel, volume de negócios e outros dados, de 300 ações listadas nas Bolsas de Valores da China	Os resultados experimentais demonstraram que as redes neurais, em especial a SVM, são benéficas para capturar o momento de reversão do preço das ações e possivelmente construir estratégias de negociação lucrativas
15	Lu et al. (2020)	CNN-LSTM., MLP, CNN, RNN, LSTM, CNN-RNN	Preço de abertura, preço mais alto, preço mais baixo, preço de fechamento, volume e giro, do Índice Composto de Xangai	Os resultados mostram que o CNN-LSTM tem maior precisão e melhor desempenho em comparação com o MLP, CNN, RNN, LSTM e CNN-RNN.
16	Lunga e Marwala (2006)	MLP e algoritmo Learn++	Valor médio de fechamento do Índice Dow Jones	O Algoritmo *Learn* ++, associado a MLP, apresentou a dados classificados corretamente, estimativas de confiança elevadas, enquanto valores de confiança baixos, foram associados a erros de classificação de dados
17	Maia e de Carvalho (2011)	Holt e modelo híbrido Holt e MLP	Preços diários de fechamento das ações de 15 empresas (B3 S.A. e Nasdaq)	Os experimentos sugerem que os modelos MLP, Holt e um modelo híbrido, podem ser usados com sucesso para a previsão de séries temporais financeiras
18	Makinen et al. (2019)	*Convolucional Long Short Term,* MLP, LTSM	Preços diários de fechamento das ações de 05 empresas negociadas na Nasdaq	Em entrada de dados desequilibradas, o CNN – LSTM – *Attention* atinge o melhor resultado, o 2º melhor é o LSTM puro, seguido pelo CNN e CNN-LSTM-v. O MLP alcançou resultado inferior, possivelmente devido à sua incapacidade de lidar com dados de entrada de séries temporais grandes, sem aprendizado, mas ainda é claramente melhor do que a escolha aleatória
19	Michalak e Lipinski (2005)	*Perceptron feed-forward* de duas camadas	preços diários de fechamento das ações, Bolsa de Valores de Varsóvia – Polônia	A previsão dos preços das ações pode ser realizada usando redes neurais de relativamente pequeno tamanho, com cerca de 100 unidades de neurônios na camada oculta. Além disso, embora as séries temporais financeiras do mercado de ações sejam caóticas, a eficiência de tal previsão excede a média esperada.
20	Mostafa (2010)	MLP e regressão generalizada	Preços diários de fechamento das ações, todas as empresas listadas negociadas na KSE. (Kuwait)	Os resultados deste estudo mostram que os modelos neuro-computacionais são ferramentas úteis na previsão de movimentos da bolsa de valores em mercados emergentes. Devido à sua robustez e flexibilidade de algoritmos de modelagem, modelos neuro-computacionais são esperados para superar técnicas estatísticas tradicionais, como ARIMA

No	Referência	Principal recurso de pesquisa	Dados analisados	Contribuições
21	Nayak (2019)	ARIMA, RBFNN, SVM, MLP e FLANN	Preços diários de ações, taxas de câmbio, e índices de fechamento diários da DJIA, BSE, TAIEX, NASDAQ e FTSE	Cinco modelos de última geração, como ARIMA, RBFNN, MLP, SVM e FLANN são usados, observa-se que os métodos combinados são mais precisos que os modelos individuais, porém o máximo cuidado deve ser tomado ao selecionar uma combinação de métodos.
22	Nayak, Misra e Behera (2017)	ACRNN, ACRO e MLP	Preços de fechamentos diários de ações de 07e bancos de dados de índices de ações: BSE, DJIA, NASDAQ, TAIEX, FTSE, S&P 500e LSE	A técnica proposta usa um subconjunto anterior de VDPs e o conjunto de treinamento para explorar uma nova posição virtual que se espera que seja capaz de prever a tendência de mudanças. O modelo exige muito pouca iteração para ser treinado, o que diminui a sobrecarga computacional no sistema em uma extensão substancial.
23	Nayak, Misra e Behera (2016)	ASONN-GA, MLP e RNN	Preços diários de fechamentos de ações da BSE, DJIA, FTSE e Nasdaq	Uma rede neural de segunda ordem (ASONN), foi proposta. Para efeito de comparação, duas Redes baseadas em abordagem multicamadas, como MLP e RNN com uma camada oculta, foram desenvolvidas. Pode-se estabelecer que o modelo ASONN-GA requer menos tempo de treinamento e dá melhor precisão geral de previsão em relação a outros dois modelos.
24	Nayak, Misra e Behera (2018)	CROVDP, MLP	Preços de fechamento diários de 10 empresas da BSE, S & P500, FTSE, NASDAQ, DJIA, TAIEX, AUX, NIKKEI, SSE e LSE	Este artigo apresenta uma rede neural artificial de reação química (ACRNN), que usa otimização de reação química artificial (ACRO) para treinar os modelos de MLP e prever os índices do mercado de ações.
25	Tufekci (2016)	MLP, LR e BLR	Indicadores macroeconômicos, preços do ouro, preços do petróleo, preços de câmbio, índices de preços de ações em vários países, e os dados do Índice ISE *National* 100 do Banco Central da República da Turquia (CBRT)	Os desempenhos de previsão mostraram que o uso de conjuntos de dados reduzidos consistindo nas características mais importantes, induziram um modelo preditivo de cada conjunto de dados para modelagem de classificação com uma melhor precisão preditiva do que usar conjuntos de dados originais.
26	Vochozka, Horak e Krulicky (2020)	MLP, RBF, SVR e backpropa-gation	Preço de fechamento das ações da Bolsa de Valores de Praga, República Checa	As redes MLP fornecem desempenho equilibrado em todos os testes, e o desempenho é sempre melhor do que o desempenho das redes SVR e BPNN.

O Quadro 10 apresenta as codificações das (sub) categorias dos 26 artigos examinados neste estudo – ver Tabela 2. Vale ressaltar que uma mesma categoria pode

conter várias subcategorias. Logo, a soma da contagem das frequências das subcategorias – para cada categoria – totaliza 100% e não o total de 26 artigos da amostra final.

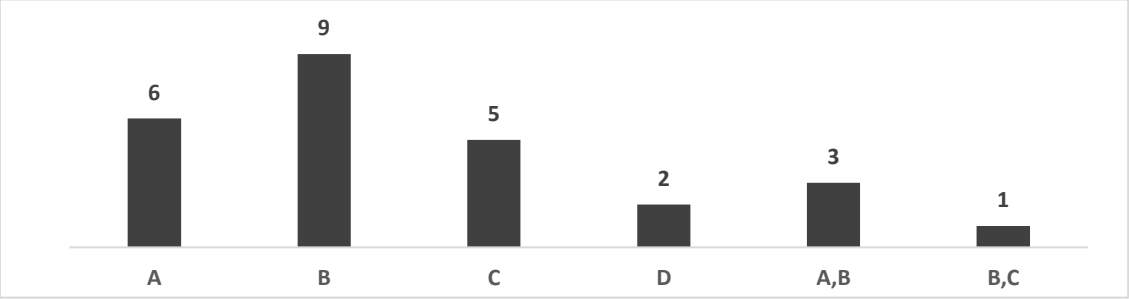
Quadro 10 – Codificação das categorias e subcategorias de análise dos artigos

No	Título	Categorias (números) e subcategorias (letras)									
		1	2	3	4	5	6	7	8	9	10
1	The dynamic behavior of evolving efficiency: Evidence from the UAE stock markets	A	A,B	A	A,B	A	C	B	A	A	E
2	A Morphological-Rank-Linear evolutionary method for stock market prediction	B	A,C	A,E	A	A	A,D	C	A	A	B
3	Business Intelligence: Statistics in predicting stock market	C	A	A	C	A	B	E	A	A	A,B
4	Modeling Markov Switching ARMA-GARCH Neural Networks Models and an Application to Forecasting Stock Returns	B	A,B	A,E	C	A	B,C	C	A	A	B
5	Grey Wolf optimization-Elman neural network model for stock price prediction	B	A,B	A,B, E	C	A	A	B	A	A	E
6	Forecasting Stock Prices Using a Hybrid Deep Learning Model Integrating Attention Mechanism, Multi-Layer Perceptron, and Bidirectional Long-Short Term Memory Neural Network	C	A	A	A	E	A	C	A	A	B
7	Predicting Stock Prices Using Machine Learning Methods and Deep Learning Algorithms: The Sample of the Istanbul Stock Exchange	B	A,C	A,B	C	B	B, C	B	A	A	B
8	Study on the prediction of stock price based on the associated network model of LSTM	D	A	A,B	C	B	C	E	A	A	B
9	Fundamental analysis and technical analysis integrated system for stock filtration	A	A	A	C	A	C	B	A	A	E
10	An Intelligent Model for Stock Market Prediction	A	A	A	C	C	A, C,E	B	A	A	B
11	A new LSTM based reversal point prediction method using upward/downward reversal point feature sets	B	A,C	A,B, D	C	A	A,C	C	A	A	E
12	Modelling and trading the English stock market with new forecasting techniques	D	A,B,C	C,E	C	D	B	C	A	A	E

No	Título	Categorias (números) e subcategorias (letras)									
		1	2	3	4	5	6	7	8	9	10
13	Performance evaluation of series and parallel strategies for financial time series forecasting	C	A,B	A	C	A	A,C	C	A	A	A,B
14	A Machine Learning View on Momentum and Reversal Trading	B	A,B	A,B	C	C	C	A	A	A	B,C
15	A CNN-LSTM-Based Model to Forecast Stock Prices	B	A,B,C	A,B, D	C	C	C	C	A	A	B,C
16	Online forecasting of stock market movement direction using the improved incremental algorithm	C	A	A	C	E	A	B	A	A	E
17	Holt's exponential smoothing and neural network models for forecasting interval-valued time series	B,C	A	A	C	A	A,D	C	A	A	E
18	Forecasting jump arrivals in stock prices: new attention-based network architecture using limit order book data	B	A	A,B	C	A	A	A	A	A	A,B, C
19	Prediction of high increases in stock prices using neural networks	A	A	A	C	A	B	B	A	A	B,C
20	Forecasting stock exchange movements using neural networks: Empirical evidence from Kuwait	A,B	A,B	A	C	A	C	A	A	A	B
21	Escalation of Forecasting Accuracy through Linear Combiners of Predictive Models	C	A,B	A	C	E	A,B, C	C	A	A	B
22	Artificial chemical reaction optimization of neural networks for efficient prediction of stock market indices	A	A,C	A	C	A	A,B, C	C	A	A	B
23	An Adaptive Second Order Neural Network with Genetic-Algorithm-based Training (ASONN-GA) to Forecast the Closing Prices of the Stock Market	B	A,C	A,C	A	A	A,B, C	A	A	A	B
24	Artificial chemical reaction optimization based neural net for virtual data position exploration for efficient financial time series forecasting	A	A,C	A	C	A	A,B, C	C	A	A	E
25	Classification-based prediction models for stock price index movement	A,B	A	A	C	C	B,C	A	A	A	C
26	Innovations in Management forecast: time development of stock prices with neural networks	A,B	A,B	A	C	A	B	B	A	A	E

A Figura 8 indica que, com relação ao tema principal / foco do estudo, a subcategoria A – Previsão do preço de ações com *multi layer perceptron* – está presente em 23% das subcategorias analisadas. Previsão do preço de ações com outras redes neurais artificiais, e resultados comparados às RNA MLP, categoria B, presente em 09 (34,6%), Previsão dos preços de ações com redes neurais combinadas, incluindo MLP, categoria C, presente em 05 (19,2%) e demais combinações de análises, 06 (23,1%) da amostra.

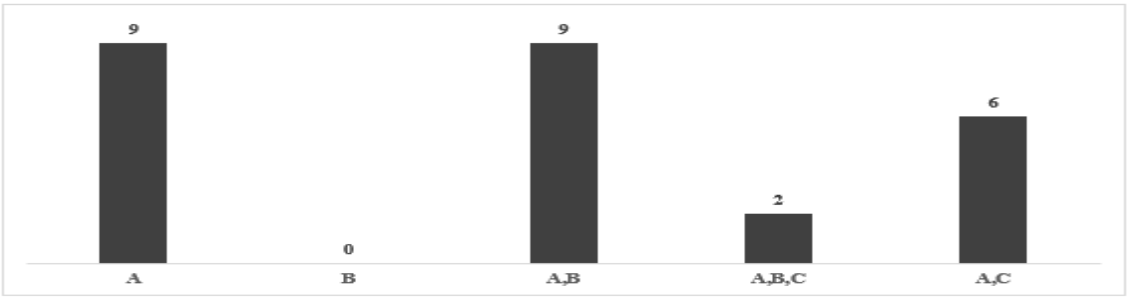
Figura 8 – Categoria 1 – Tema principal / foco do estudo



A – Previsão do preço de ações com *multi layer perceptron*
B – Previsão do preço de ações com outras redes neurais artificiais, e resultados comparados às RNA MLP
C – Prever os preços de ações com redes neurais combinadas, incluindo MLP
D – Outros

Sobre a Figura 9, há uma predominância da subcategoria A – Redes neurais (34,6% ou 09 ocorrências) sobre os demais métodos de pesquisa presentes nos artigos da amostra. Os demais artigos também apresentam análises baseadas em redes neurais, mas conjugadas com análises estatísticas de séries temporais (A, B: 34,6% ou 9 ocorrências), ou ainda a outros métodos de pesquisa.

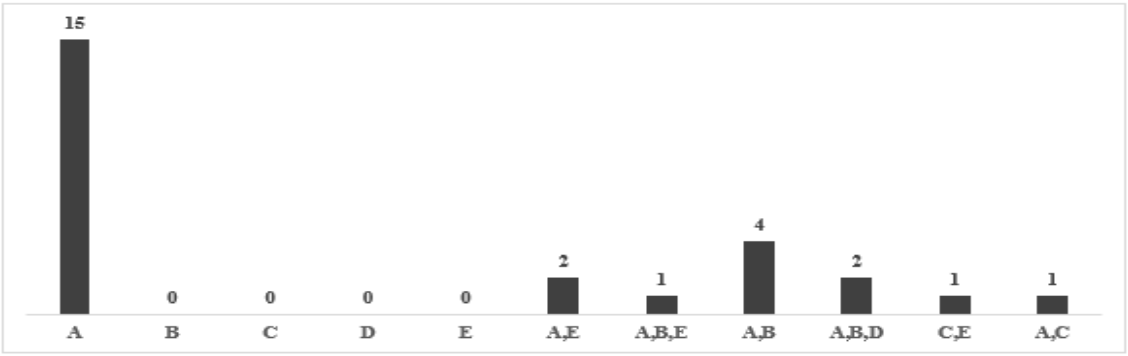
Figura 9 – Categoria 2 – Métodos de pesquisa



A – Redes neurais
B – Análises estatísticas de séries temporais
C – Outros métodos de pesquisa

A Figura 10 demonstra que a subcategoria A – MLP é, das redes neurais utilizadas nas pesquisas, a mais presente, ocorrendo isoladamente em 15 (57,7%) das amostras, e em conjunto, em outras 10 (38,5%).

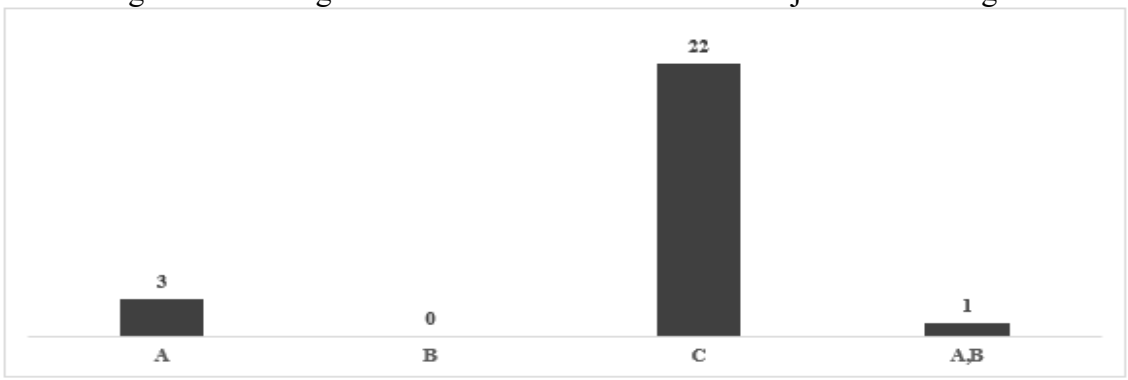
Figura 10 – Categoria 3 – Redes Neurais utilizadas na pesquisa



A – MLP
B – LSTM
C – HONN
D – CNN
E – Outras

Quanto à Figura 11, as teorias relacionadas aos objetivos dos artigos, os dados analisados com maior concentração referem-se à subcategoria A – Teoria dilema do passeio, tendo 03 ocorrências isoladas e 01 ocorrência em conjunto com a subcategoria B – Teoria de combinação. Os demais 22 artigos da amostra não mencionaram teorias relacionadas aos seus objetivos.

Figura 11 – Categoria 4 – Teorias relacionadas aos objetivos dos artigos

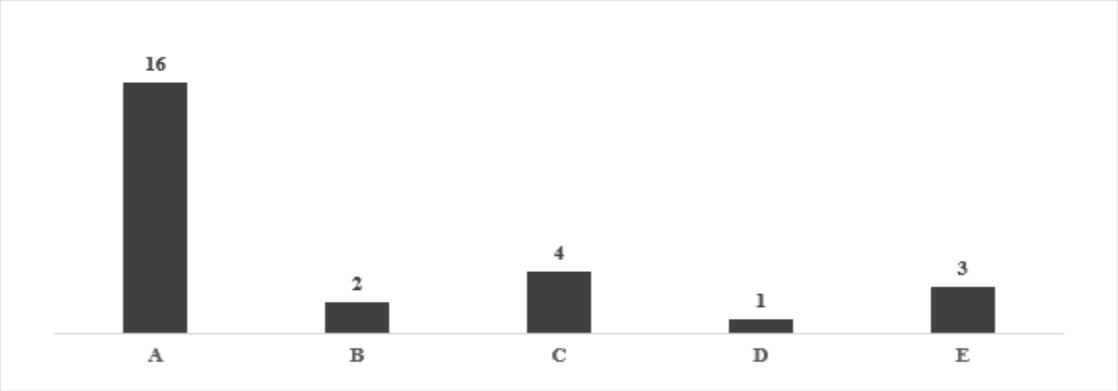


A – Teoria dilema do passeio
B – Teoria de combinação
C – Não mencionadas

Quanto à Figura 12, os tipos de dados analisados com maior concentração referem-se à subcategoria A – Preços diários do fechamento de ações (61,5%), C – Preços

de abertura, de fechamento, mais alto, mais baixo e volume negociado (15,4%). As subcategorias B, D e E, concentram os outros tipos de dados analisados.

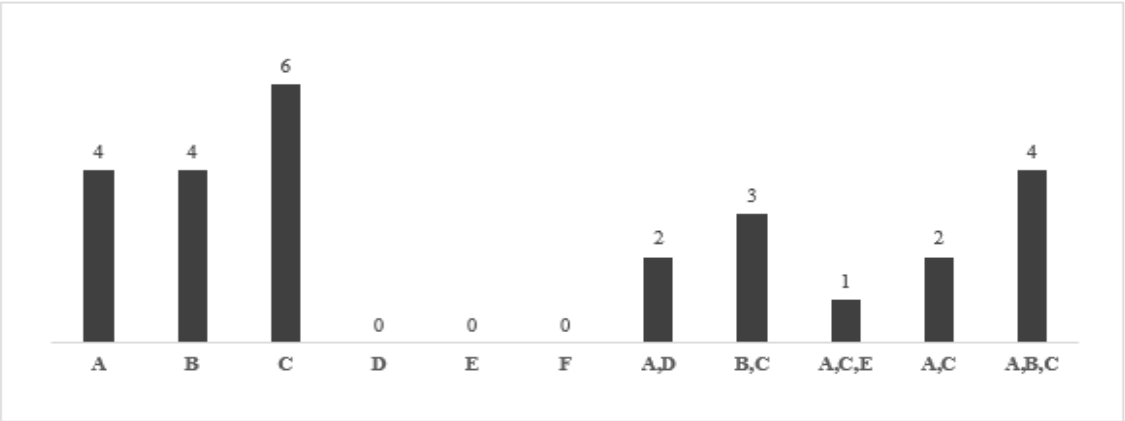
Figura 12 – Categoria 5 – Tipos de dados analisados



A – Preços diários do fechamento de ações
B – Preços de abertura e preços de fechamento diários de ações
C – Preços de abertura, de fechamento, mais alto, mais baixo e volume negociado
D – Fechamento diário de Índice de Preços de Ações
E – Outras associações

Quanto à Figura 13, os dados têm origem em maior concentração isoladamente na Ásia / Oceania (23,1%), seguido por dados oriundos dos Estados Unidos / Canadá (15,4%) e da Europa (15,4%). Contudo ressalta-se que há estudos em volume relevante (46,2%), que incluem dados combinados de mais de uma dessas regiões.

Figura 13 – Categoria 6 – Origem dos dados

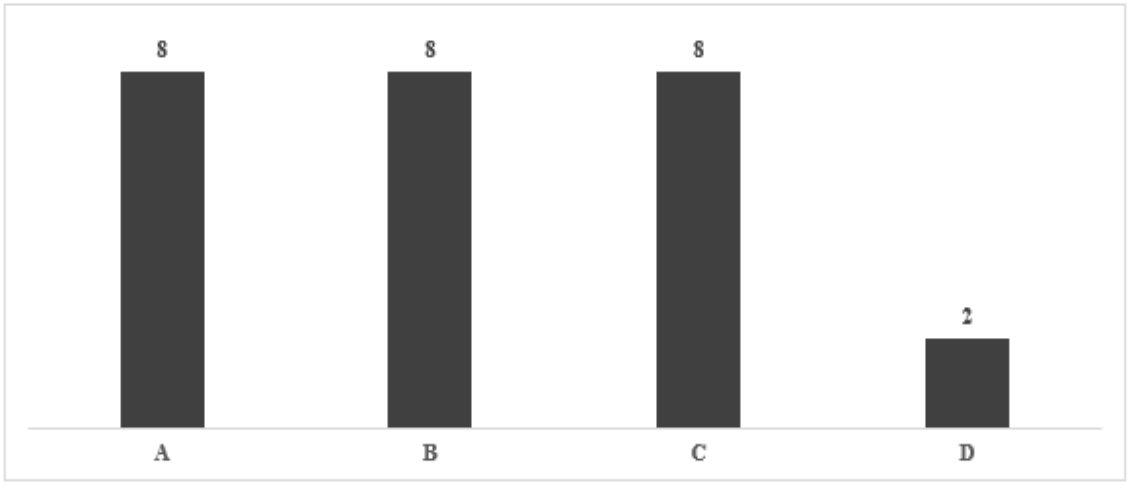


A – Estados Unidos e Canadá
B – Europa
C – Ásia / Oceania
D – América Latina
E – África
F – Não mencionado

Quanto ao período de análise da amostra de dados dos estudos, a Figura 14 aponta que 30,8% dos dados pertencem à subcategoria A – Até 5 anos, o mesmo percentual para

as categorias B – De 06 a 10 anos e para a categoria C – Mais de 10 anos. Apenas 7,7% não indicaram o período dos dados analisados.

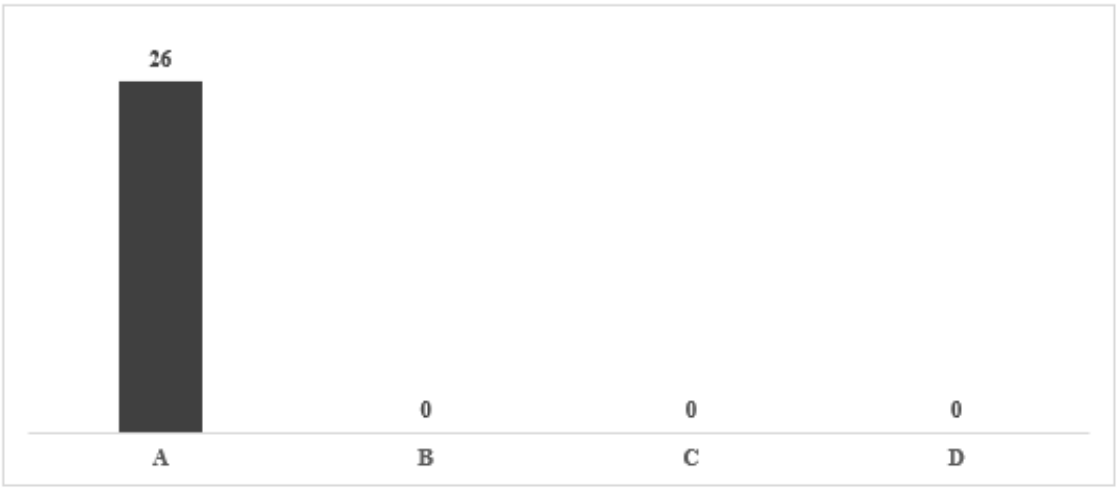
Figura 14 – Categoria 7 – Período de análise



A – Até 5 anos
B – De 6 a 10 anos
C – Mais de 10 anos
D – Não se aplica / não informado

Com relação à análise dos resultados dos estudos, a Figura 15 mostra que 100% dos estudos estão classificados na subcategoria A – Novas perspectivas ou novas conclusões.

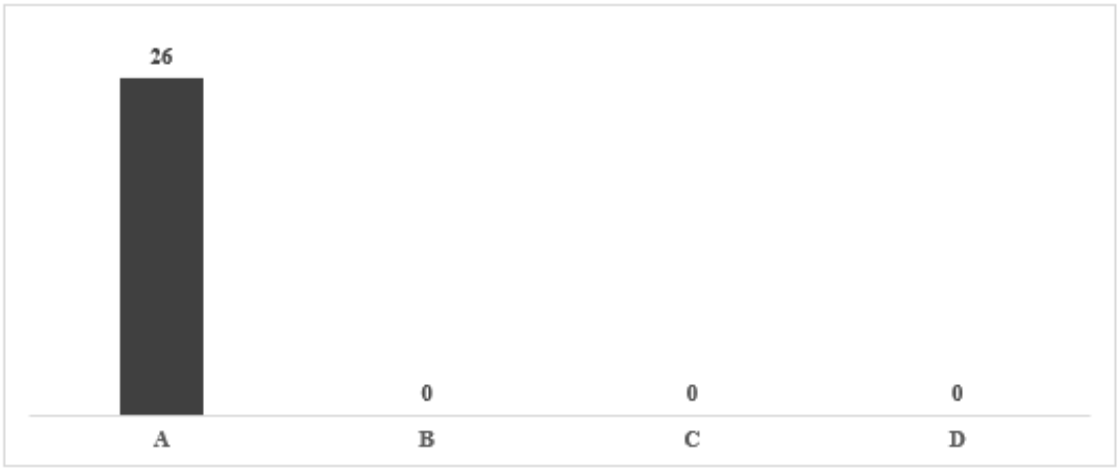
Figura 15 – Categoria 8 – Resultados



A – Novas perspectivas ou novas conclusões
B – Conclusões semelhantes a trabalhos anteriormente apresentados
C – Outros

Por sua vez, a Figura 16 esclarece que 100% dos estudos confirmaram seu objetivo principal.

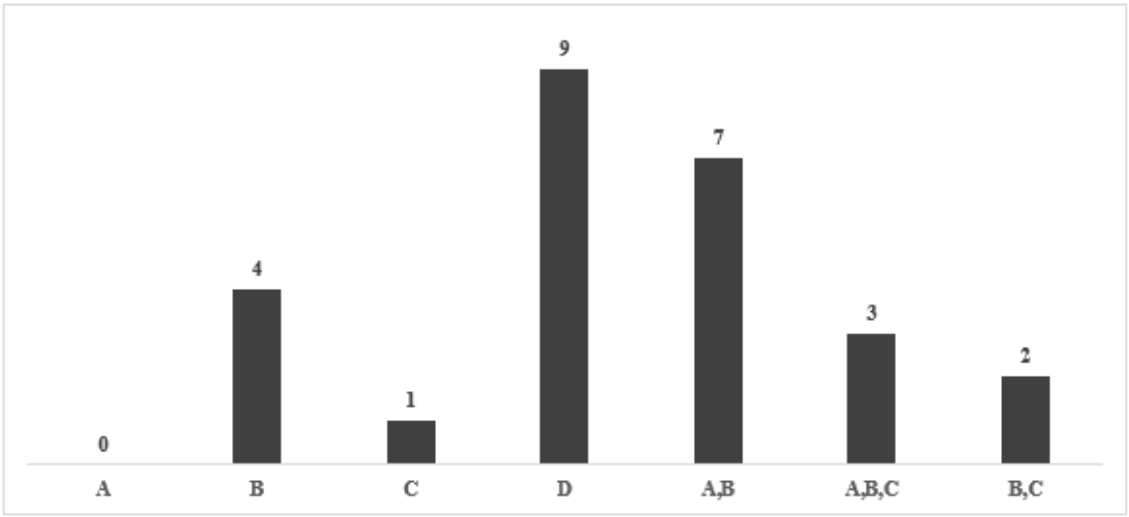
Figura 16 – Categoria 9 – Conclusões sobre o objetivo dos estudos



A – Confirmação do objetivo principal
B – Não confirmação do objetivo principal
C – Resultado não conclusivo em relação ao objetivo principal
D – Não se aplica

A Figura 17 analisa as avenidas para os estudos futuros. 38,5% dos artigos recomendam exclusivamente o exame de diferentes métodos de treinamento de RNA, 11,5% recomendam associar a diferentes métodos de treinamento de RNA, a avaliação de diferentes modelos de pré e pós processamento de dados, 7,7% recomendam associar a diferentes métodos de treinamento de RNA outros modelos estatísticos e inteligentes, e 34,6% não mencionam avenidas para estudos futuros.

Figura 17 – Categoria 10 – Avenidas para estudos futuros



A – Examinar outros modelos utilizando MLP
B – Examinar diferentes modelos de redes neurais artificiais
C – Avaliar outros modelos de previsão do preço de ações
D – Não mencionadas

2.5 Conclusão

O MLP é um método de RNA que fornece resultados flexíveis e consistentes, e principalmente, é bem-sucedido em previsões. A complexidade nesse processo está inserida na identificação da arquitetura e das variáveis mais adequadas, para que a curva de aprendizagem se estabilize após as iterações, em um nível de erro considerado aceitável, ou então é o momento de se repensar a topologia da rede (mais camadas ocultas ou uma arquitetura totalmente diferente) ou no procedimento de treinamento (outra pesquisa de gradiente com técnicas mais sofisticadas).

Considerando-se a escassez de pesquisas sobre o tema, este estudo realiza uma análise bibliométrica e a revisão sistemática da literatura, a respeito da previsão do preço de ações com RNA MLP. Como resultado, há a identificação de lacunas de conhecimento a serem preenchidas por uma proposta de futura agenda de pesquisas relacionadas a esse tema.

A amostra inicial é composta por 86 artigos, que após a adoção dos critérios de exclusão mencionados no item 3, Metodologia, é reduzida para 26 estudos finais, obtidos na base de dados WoS. A análise bibliométrica apresenta dados quantitativos por meio de gráficos, mapas de relacionamento e tabelas sobre as principais dimensões e leis da bibliometria, a saber: palavras-chave - lei de Zipf (1949), periódicos - lei de Bradford (1934) e autores - lei de Lotka (1926). Essas verificações ocorrem através dos softwares RStudio, Biblioshiny, VOSviewer e Rank Words. Por sua vez, a revisão sistemática identifica a frequência das (sub) categorias definidas para a amostra final. Sua verificação permite a percepção de quais combinações de subcategorias são viáveis para investigações futuras.

Como resultado da análise bibliométrica, temos que as palavras previsão, modelo(s), rede neural e mercado, são as mais utilizadas. 56 autores são responsáveis pelos 26 artigos analisados, e 17 deles (30%) são associados a instituições sediadas na China. O periódico que mais se destaca na amostra final é o Ain Shams Engineering Journal, e o artigo mais citado é o de Maia e Carvalho (2011) com 51 citações, média anual de 4,636. Nele os autores investigam empiricamente os preços diários de fechamento das ações de 15 empresas negociadas nas bolsas de valores B3 S.A. – Bolsa, Brasil, Balcão e Nasdaq (Estados Unidos), e seus experimentos sugerem que os modelos

MLP, Holt e um modelo híbrido, podem ser usados com sucesso para a previsão de séries temporais financeiras. Por fim, verifica-se que 20% dos autores são responsáveis por 29% das publicações, impossibilitando a confirmação da Lei de Lotka.

No que diz respeito à revisão sistemática, a análise é feita por meio da identificação da frequência das subcategorias descritas na Tabela 2, resumida na Figura 7. Para previsão dos preços de ações com RNA MLP, pesquisas sobre os diferentes métodos de treinamento, bem como os diferentes modelos de pré e pós-processamento de dados são urgentes, visto que podem dirimir os riscos e maximizar os retornos dos investidores. Outra preocupação refere-se à obtenção de dados para insumos nos modelos de avaliação. A escassez de dados confiáveis fora das bolsas de valores dos países desenvolvidos, leva à restrição de estudos para além desses mercados. Em relação aos caminhos para pesquisas futuras, os autores enfatizam a recomendação do exame de diferentes métodos de treinamento de RNA MLP, e suas associações a outros modelos estatísticos e inteligentes.

No que se refere às limitações deste estudo, os resultados obtidos são restritos aos critérios de seleção definidos no item 3, Metodologia, e aos artigos disponibilizados pela WoS. Assim, para a evolução desta pesquisa, sugere-se estudos mais detalhados da previsão do preço de ações com RNA MLP, sob o âmbito de seus diferentes modelos de arquitetura, das associações a outros modelos estatísticos e inteligentes, e pesquisas que se debrucem sobre segmentos específicos de mercado, como indústria, energia e construção civil.

3. SEGUNDO ENSAIO: REVISÃO BIBLIOMÉTRICA E SISTEMÁTICA DE PREVISÃO DO PREÇO DE AÇÕES COM REDES NEURAIS LONG SHORT TERM MEMORY

3.1 Introdução

O objetivo deste estudo é mapear e analisar a literatura acadêmica publicada sobre previsão de preços de ações usando Redes Neurais Artificiais – RNA LSTM. Para isso, uma análise bibliométrica e uma revisão sistemática da literatura sobre o assunto são realizadas, durante o período de 1º de janeiro de 2000 a 31 de março de 2022, com uma amostra final de 99 artigos.

A análise bibliométrica refere-se à análise quantitativa, que é desenvolvida por contagem de frequências e cocitações. A revisão sistemática, de análise qualitativa, considera a correlação entre os temas mais significativos, mas ainda pouco estudado pela academia. A base de pesquisa utilizada vem da Web of Science —Base de dados WoS, e tanto a análise bibliométrica quanto a revisão sistemática não dispensa o uso dos softwares R, Rstudio, Biblioshiny e VOSViewer. Na análise bibliométrica, adota-se a verificação das principais leis: Lotka [4] e Bradford [5].

A revisão da literatura é apresentada no item 3.2, com a identificação das teorias e métodos de previsão de preços de ações com as redes neurais artificiais LSTM, mencionadas nos artigos da amostra final. A bibliometria, as metodologias de análise e a revisão sistemática estão descritas no item 3.3, e no item 3.4 são relatados os resultados de ambas as metodologias, com estatística descritiva das características mais relevantes dos artigos da amostra final e lacunas de conhecimento sobre o tema. O item 5 apresenta as conclusões, caminhos para futuras estudos e limitações desta pesquisa.

3.2 Revisão da Literatura

O preço de hoje das ações de uma empresa de capital aberto reflete a operação passada da empresa, o momento atual e as perspectivas futuras de lucratividade. Para obter uma projeção mais precisa do preço das ações, diversos tipos de estudos já foram realizados. Os mais clássicos enfocam os dados financeiros das empresas-alvo, somados aos aspectos micro e macroeconômicos. No entanto, as características não lineares e não

estacionárias das sequências de dados financeiros tornam as previsões mais desafiadoras (Fransconi, Gori, & Soda, 1992). Em 1969, Akaike usou o modelo autorregressivo (AR) para predição. Em seguida, foi proposta a combinação do modelo autorregressivo (AR) com o modelo de média móvel (MA), formando o modelo ARMA. Em 1970, Box e Pierce propuseram o modelo Autoregressive Integrated Moving Average System (ARIMA), que corrige algumas desvantagens do modelo ARMA para lidar com sequências não estacionárias. Em 1982, Engle propôs o modelo de heterocedasticidade condicional autorregressiva (ARCH) para processar a volatilidade de séries temporais, em 1986 Bollerslev propôs o modelo de heterocedasticidade condicional autorregressiva generalizada (GARCH). Em 1987, Hull e White propuseram um modelo para resolver o problema estocástico da volatilidade de séries temporais (SV). Todos esses métodos estabelecem as bases para o desenvolvimento de previsões de séries temporais.

Com o desenvolvimento da tecnologia computacional, novos métodos de predição foram propostos, como as redes neurais artificiais (Paluch & Jackowska-Strumillo, 2018), cujo objetivo é replicar a forma como o cérebro humano funciona. As redes neurais recorrentes (Gao & Chai, 2018) são um poderoso conjunto de algoritmos de redes neurais artificiais, especialmente úteis para o processamento de dados sequenciais, como som, temporal ou linguagem. Algumas redes neurais recorrentes (RNN) tiveram melhor desempenho na previsão de dados financeiros e se tornaram populares, como Long Short-Term Memory (Hochreiter & Schmidhuber, 1997).

Assim, o LSTM é um tipo específico de RNN que tem sido amplamente aplicado para resolver problemas de aprendizado supervisionado (Li & Tam, 2018). Possui memória não linear de células e unidades de porta (Greff et al., 2016), capazes de processar sequências não estacionárias de longo prazo. Além disso, o LSTM pode extrair as características dos dados financeiros e refletir as características da rede (Zeng e Liu, 2018), oferece bom desempenho na previsão de preços no mercado de ações, sendo um algoritmo capaz de identificar relações não lineares e ocultas nos dados, ou seja, é um algoritmo de aprendizado supervisionado, capaz de aprender a partir de um conjunto de dados em treinamento (dado um conjunto de dados, o LSTM pode aprender uma função não linear para regressão).

Maknickiene e Maknickas (2012) melhoraram o desempenho das medições no mercado de câmbio ou usando TM; Chen, Zhou e Dai (2015) usaram LSTM para retornos

do mercado de design chinês e tiveram um bom desempenho. Depois disso, vários experimentos com a rede LSTM moderna de forma literária em métodos isolados, híbridos ou combinados com clássicos e estudos de séries financeiras foram concluídos, A indica que o LSTM é bastante adequado para modelos financeiros de séries temporais (Kim & Won, 2018).

Concretamente, a rede LSTM consiste em três partes, incluindo uma camada de entrada, uma camada de saída e várias camadas ocultas entre elas. As camadas ocultas possuem módulos de memória. O núcleo do módulo de memória é a célula de memória autoconectada com três portas, entrada, saída e esquecimento. O valor de cada uma dessas portas controla o fluxo de informações no módulo de memória.

A informação é retida por células e as manipulações de memória são feitas por portas. Porta de entrada: onde são adicionadas informações úteis. Porta de esquecimento: onde as informações que não são mais úteis são removidas. Porta de saída: a tarefa de extrair informações úteis do estado atual da célula para serem exibidas como resultado. Um vetor é gerado e as informações são reguladas usando a função que filtra os valores a serem lembrados. Valores vetoriais e valores regulados são multiplicados para serem enviados como saída e entrada para a próxima célula (Liu et al., 2020).

Entretanto, projetar uma boa arquitetura de rede para o problema estudado não é uma tarefa simplista. A arquitetura do modelo interfere diretamente em seu desempenho. O processo de refinamento pode ser demorado, pois não existe um método formal para realizar essa tarefa de classificação, isso se dá necessariamente através da realização de testes iterativos com diversos parâmetros, nos quais apenas a estrutura de maior assertividade é mantida.

A qualidade da informação em que a rede é alimentada, tanto ou mais, é refletida na precisão da resposta da camada de saída. A seleção das informações que serão fornecidas à camada de entrada é um fator chave no projeto de um sistema de decisão inteligente, pois mesmo que o modelo seja o melhor, ele terá um desempenho ruim se as características não forem bem escolhidas. Métodos específicos devem ser usados na seleção de informações relevantes.

3.3 Metodologia

O objetivo deste estudo é responder à pergunta – usando redes neurais artificiais LSTM, podemos obter previsões confiáveis dos preços das ações? Para isso, são implementadas as 7 etapas descritas abaixo. As etapas 1 a 5 abordam tanto a metodologia de análise bibliométrica quanto a revisão sistemática, e as etapas 6 e 7 referem-se à revisão sistemática.

Etapa 1 – Escolhendo o banco de dados. Exemplos de artigos vêm do Web of Science (WoS), o principal banco de dados de citações do mundo. Contém registros de artigos publicados em periódicos científicos com alto fator de impacto, classificados através do Journal Citation Reports (JCR).

Etapa 2 – Usando os parâmetros de pesquisa inicial do WoS. Para o período de 1º de janeiro de 2000 a 31 de março de 2022. Inicialmente, 276 artigos são identificados com base nas variações dos termos *stock, market, LSTM, forecast, predictive regression, supervision learning* e *backpropagation.* Posteriormente, são realizadas exclusões por meio da aplicação de filtros no próprio WoS, resultando em uma amostra intermediária de 127 artigos, conforme Tabela 1.

Quadro 11 – Evolução da amostra usando filtros WoS

Sinal	Descrição	Número de artigos
(+)	Palavras-chave: iguais a "stock* market*" e "LSTM" ou "stock* market*" e "long short-term memory" ou "forecas* stock*" e "LSTM" ou "forecas* stock*" e "long short-term memory" ou "predictive regression*" e "LSTM" ou "predictive regression*" e "long short-term memory" ou "supervision *learning*" e "long short-term memory" e "backpropagation"	276
(-)	Tipo de documento: diferente de "article" ou "early access" ou "data document"	106
(-)	Categorias da Web of Science: igual a "computer science artificial intelligence", "computer science theory methods", "computer science information systems", "interdisciplinary applications of computer science", "hardware architecture of computer science", "computer science software engineering", "economics", "business", "business finance", "operations research management science", "management"	43
(-)	Área de Pesquisa: igual a "computer science", "business economics", "operations research management science"	0
(-)	Linguagem: diferente de "English"	0
(=)	Amostra Intermediária	127

Etapa 3 – Exclusão de 19 dos 127 artigos por não estarem disponíveis nas fontes pesquisadas (Google Acadêmico, Science Direct e Web of Science) e outros 09 por não estarem diretamente relacionados ao tema de nossa pesquisa, a saber: 01 e-commerce, 02

criptomoedas, 01 detecção de bolhas de preços imobiliários, 01 memória temporal hierárquica, 01 conjuntos de dados de visão neuromórfica, 01 otimização Gray Wolf-Elman, 01 movimentação de ações durante a pandemia de Covid-19 e 01 previsão de preços de ações com base em grupos de similaridade morfológica e memória hierárquica temporal. Assim, a amostra final é composta por 99 artigos.

Etapa 4 – Criação de um banco de dados e coleta de artigos. Os 99 artigos da amostra final são obtidos das seguintes bases de dados de pesquisa acadêmica: Web of Science, Science Direct e Google Scholar. A partir de sua análise, as seguintes informações são coletadas para capturar os dados gerais do artigo: título, nome do autor, instituição afiliada e país de origem dos autores/pesquisadores, nome do periódico, volume e número do fascículo, homepage e página final, ano de publicação, país de origem dos dados e número de anos dos dados da amostra, palavras-chave, Digital Object Identifier (DOI), Journal of Economic Literature (JEL) e número de citações de artigos na base de dados WoS.

Etapa 5 – Análise bibliométrica. Através dos softwares R, Rstudio, Biblioshiny e VOSviewer, são analisados dados objetivos dos artigos – países, autores, palavras-chave, instituições, etc. – para a elaboração e análise de tabelas e mapas de relação/cocitação. As análises realizadas por ambas as ferramentas são complementadas pela verificação das principais leis da bibliometria, a saber: a) Lei de Bradford (1934) – verificação de periódicos que produzem muitos artigos em contraste com aqueles que produzem poucos sobre um determinado tema, e b) Law de Lotka (1926) – identificação dos pesquisadores com maior frequência de produção em determinada área do conhecimento.

Etapa 06 – Leitura e codificação dos artigos. Identificação dos objetivos, amostra, métodos e contribuições dos artigos. Além disso, são classificadas e codificadas em categorias e subcategorias estruturadas conforme a Tabela 2. Cada uma das 08 categorias possui subcategorias não exclusivas. Isso significa que um mesmo artigo pode ser classificado em mais de uma subcategoria. Assim, a soma da contagem de frequência das subcategorias – para cada categoria – é a que totaliza 100%. No processo de codificação, são atribuídas até 3 subcategorias por artigo para cada categoria.

Quadro 12 – Categorias e Subcategorias

Categorias		Definição
1. Redes Neurais / Algoritmos usados em pesquisas	A – LSTM	Projeção de preços de ações com ANN LSTM.
	B – Comparado ao LSTM	Previsão de preço de ações com outras redes neurais artificiais e resultados em comparação com ANN LSTM
	C – Combinado ao LSTM	Preveja os preços das ações com redes neurais combinadas, incluindo LSTM
	D – Outros	Outros tópicos não relacionados às subcategorias 1ª a 1C.
2. Tipos de dados analisados	A – Fechamento preços	Preços diários de fechamento de ações
	B – Preços de abertura	Preços diários de abertura de ações
	C – Preços mais altos e mais baixos	Preços diários de ações mais altos e mais baixos
	D – Volumes	Volumes de negociação de ações
	E – Índice	Fechamento diário do Índice de Preços das Ações
	F – Outros resultados	Outros tópicos não relacionados às subcategorias 2ª a 2E
3. Origem dos dados	A – NYSE, NASDAQ, DJI, S&P, CBOE, FTSE	Bolsas de Valores dos EUA
	B – CSI, SSE, NSE, HS, SH, SZSE	Bolsas de Valores da China e Hong Kong
	C – B3	Bolsa de Valores do Brasil
	D – TWSE	Bolsa de Valores da Tailândia
	E – IMKB	Bolsa de Valores da Turquia
	F-TSE	Bolsa de Valores de Teerã
	G – GSE	Bolsa de Valores de Gana
	H – ASX	Bolsa de Valores da Austrália
	I – DAX	Bolsa de Valores da Alemanha
	J – KOSPI, KOSDAQ	Bolsas de Valores da Coreia
	K – NSE	Bolsa de Valores da Índia
	N – NIKKEI	Bolsa de Valores do Japão
	O – IDX	Bolsa de Valores da Indonésia
	P – FTSE	Bolsa de Valores do Reino Unido
	L – Textos	Agências de notícias/sites, para análise de sentimentos
	M– Sem informações ou outros	Não há identificação de informações que possam ser consideradas como insumos para os modelos de avaliação.
4. Período de análise	A – Até 5 anos	Dados de 0 a 5 anos.
	B – Mais de 5 a 10 anos	Dados de 5,1 a 10 anos.
	C – Mais de 10 anos	Mais de 10 anos.
	D – Não aplicável/não informado	Estudos que não informam o período de análise.
5. Objetivos	A – Testes com novos modelos de ANN	Precisão aprimorada do preço das ações testada com algoritmos de RNA e/ou modelos híbridos
	B – Testes com outros ativos	Verifica se o uso de preços e índices de volatilidade de outros ativos (exceto ações) pode ajudar a prever os preços das ações
	C – Análise de Sentimentos	Maior precisão na projeção do preço das ações com análise de sentimentos
	D – Outros	Outros tópicos não relacionados às subcategorias 7ª a 7C.
6. Resultados	A – Supera os métodos comparados	Os resultados do modelo proposto superam os resultados do(s) modelo(s) comparado(s).
	B – Modelo promissor	Os resultados do modelo proposto são promissores
	C – Outros	Outros resultados não relacionados às subcategorias 8ª a 8B.

7. Conclusões	A – Novas conclusões	Apresentação de novas conclusões – ajuste a modelos de ANN já testados, melhoria na qualidade das informações de entrada, e outras inovações aos modelos já existentes.
	B – Novas perspectivas	Apresentação de uma nova teoria, novos modelos de projeções, com modelos de ANNs isolados, híbridos ou combinados
	C – Conclusões semelhantes a trabalhos apresentados anteriormente	Estudos que não apresentam novas perspectivas nem novas conclusões.
	D – Outros	Outros resultados não relacionados às subcategorias 9ª a 9C.
8. Caminhos para estudos futuros	A – Modelos híbridos com LSTM	Estudos com outros modelos híbridos usando LSMT
	B – Outras RNAs	Estudos com outro RNA, puro ou híbrido
	C – Outros tipos de dados	Além de dados de abertura, fechamento, alta, baixa e volume de negociação, testes de análise de sentimento com outros tipos de notícias e dados de ações, em períodos como intradiário
	D – Dados de outras fontes	Estude o desempenho do modelo em outras Bolsas de Valores
	E – Outros períodos de análise	Estudar e testar dados de diferentes períodos
	F – Nenhum caminho comentado pelo(s) autor(es)	Nenhum caminho futuro detalhado pelo(s) autor(es).

Etapa 7 – Revisão sistemática. Após a codificação da matriz de (sub)categorização na Tabela 2 – para a amostra final – é realizada uma contagem de frequência das subcategorias para permitir a identificação de lacunas de conhecimento. Tais lacunas são então comparadas com as subcategorias da categoria 08 – caminhos para estudos futuros, a fim de obter aspectos que possam ser objeto de estudos posteriores sobre o tema.

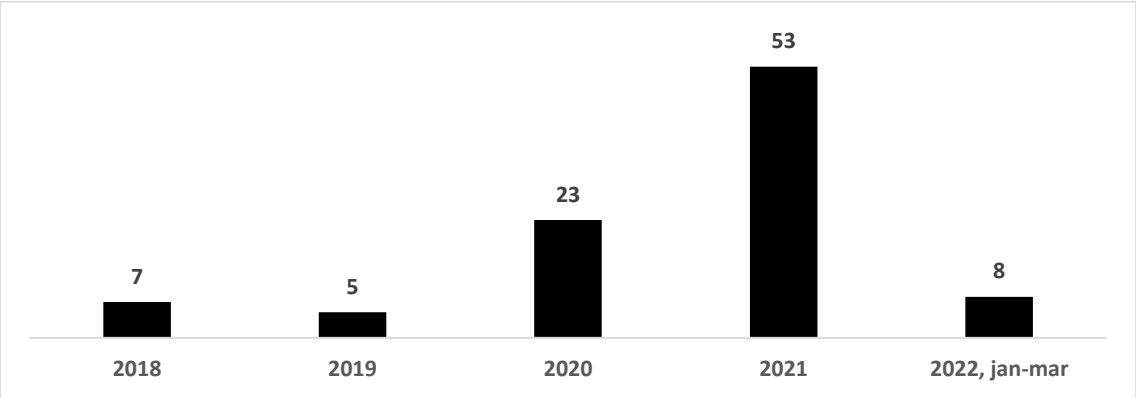
3.4. Análise dos resultados

O item 3.3.1 apresenta os resultados da análise bibliométrica, mencionada na Etapa 5 da Metodologia. Por sua vez, o item 3.3.2 contém os resultados da revisão sistemática, cujas etapas estão descritas nas Etapas 6 e 7 do item 3 deste estudo.

3.4.1 Análise Bibliométrica

A amostra final é composta por 99 artigos, distribuídos entre os anos de 2000 e 2021, obtidos da base de dados WoS – vide Figura 18. Neste período, são identificados pelo menos 5 artigos sobre previsão de preços de ações utilizando LSTM por ano.

Figura 18. Distribuição anual de artigos



O Quadro 13 apresenta a frequência das 151 principais palavras-chave do estudo, destacando modelo (18 ocorrências), predição (14 ocorrências), redes neurais (15 ocorrências), série temporal (13 ocorrências), índice (11 ocorrências), máquina (10 ocorrências), LSTM e rede neural (com 09 ocorrências cada). Essas palavras também podem ser vistas na Figura 2.

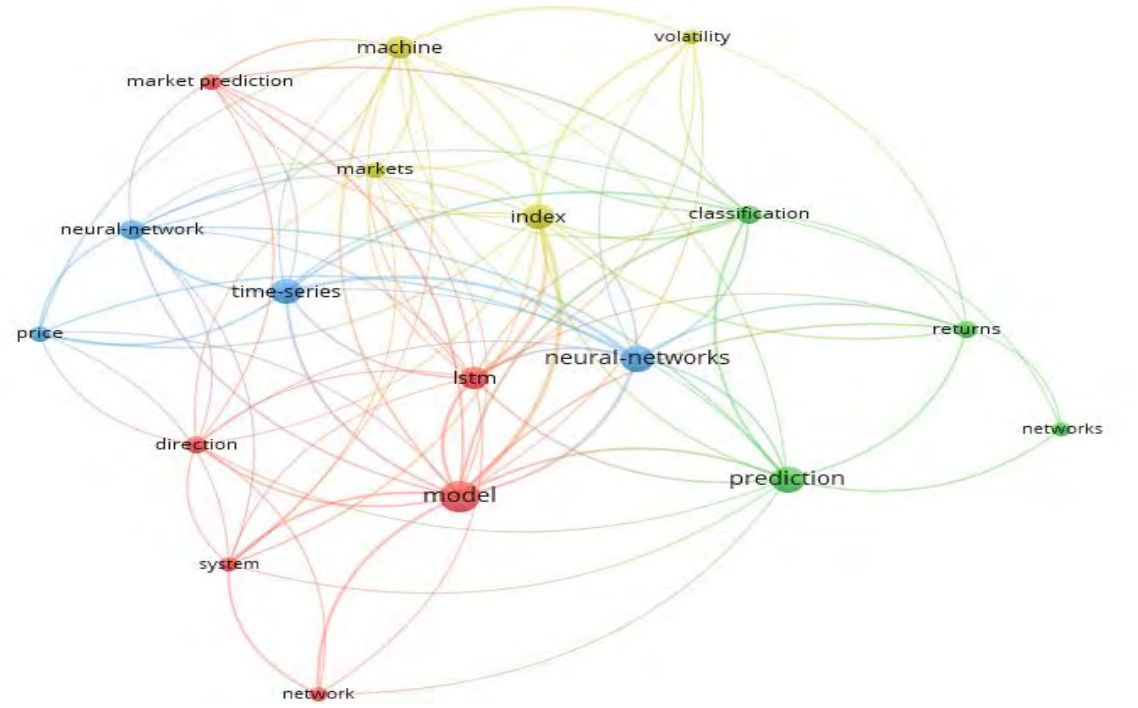
Quadro 13 – Palavras-chave

Palavras-chave	Quantidade	Frequência %
Model	18	12%
Neural networks	15	10%
Prediction	14	9%
time series	13	9%
Index	11	7%
Machine	10	7%
LSTM	9	6%
neural network	9	6%
Volatility	7	5%
Classification	6	4%
Others	39	26%
Total	151	100%

Fonte: Elaborado pela Autora

A Figura 19 apresenta o mapa de coocorrência das palavras-chave mais utilizadas nos artigos. Novamente, destacam-se as palavras modelo e redes neurais, além de predição e séries temporais.

Figura 19 - Mapa de coocorrência de palavras-chave

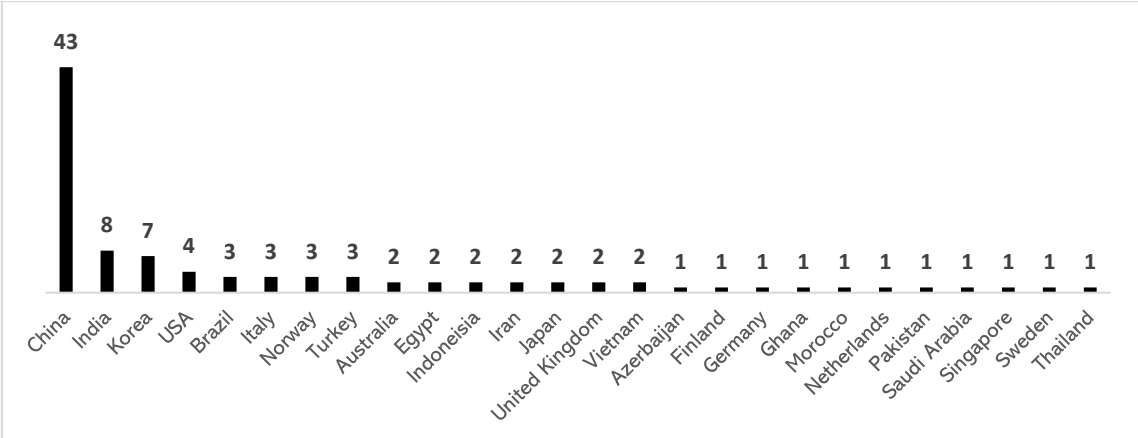


Fonte: VOSviewer

Nota: o tamanho dos nós representa a relevância dos termos nos artigos. A espessura das linhas significa a força da conexão entre elas. Finalmente, as cores indicam o número de grupos.

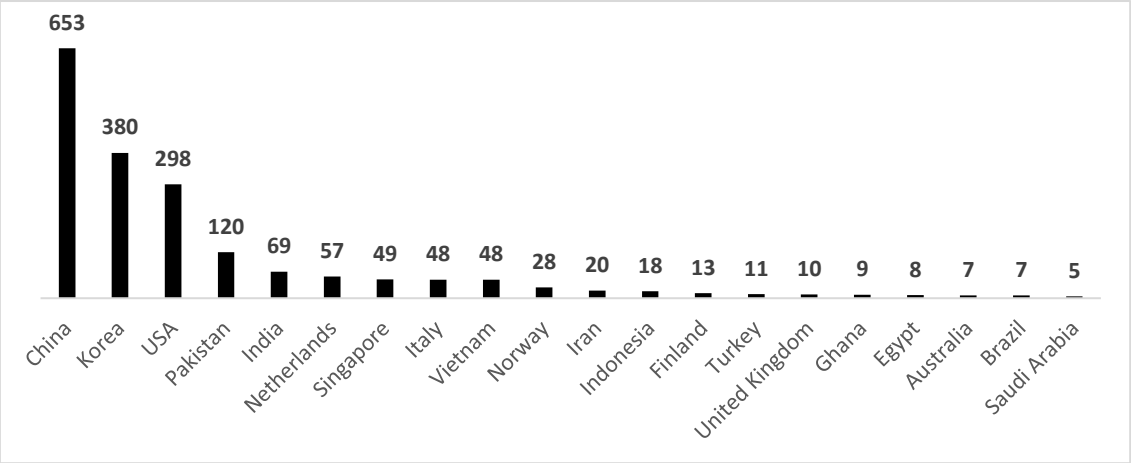
Quanto à autoria dos trabalhos, foram identificados 333 autores. A Figura 20 apresenta a classificação em ordem decrescente dos 26 países-sede das instituições às quais esses autores estão vinculados. De acordo com o software Rstudio, dos 99 artigos, 77 (78%) são classificados como artigos de autores vinculados a instituições do mesmo país (SCP) e 22 (22%) são artigos de autores vinculados a instituições de diferentes países. Países (MCP).

Figura 20 - Publicação de artigos por país a que os autores estão associados



A Figura 21 indica que 653 citações estão relacionadas a artigos escritos por autores associados a instituições localizadas na China. As demais citações são de autores vinculados a instituições das seguintes na Coréia (380), EUA (298), Paquistão (120), Índia (69), e as demais citações, espalhadas por outros 21 países.

Figura 21. Frequência de citações de artigos nos países das instituições às quais os autores estão vinculados



O Quadro 14 indica os periódicos em que são publicados os 99 artigos da amostra final, por meio da aplicação da Lei de Bradford (1934). A lei estabelece que existem poucos periódicos produzindo muitos artigos e muitos periódicos produzindo poucos artigos sobre um determinado tema. Para Brookes (1969), essa lei estima o grau de relevância de determinados periódicos acadêmicos que trabalham em áreas específicas do conhecimento. Assim, se os periódicos forem classificados em ordem decrescente de produtividade, podem ser distribuídos em zonas com variação na proporção $1:n:n^2$, e assim sucessivamente.

A Zona A é identificada como o núcleo das disciplinas, sendo composta por periódicos com 5 referências ou mais, destacando-se Expert Systems with Applications, IEEE Access, Big Data Journal e Neural Computing and Applications. A Zona B apresenta periódicos com 2 a 4 publicações, e a Zona C, periódicos com uma única publicação.

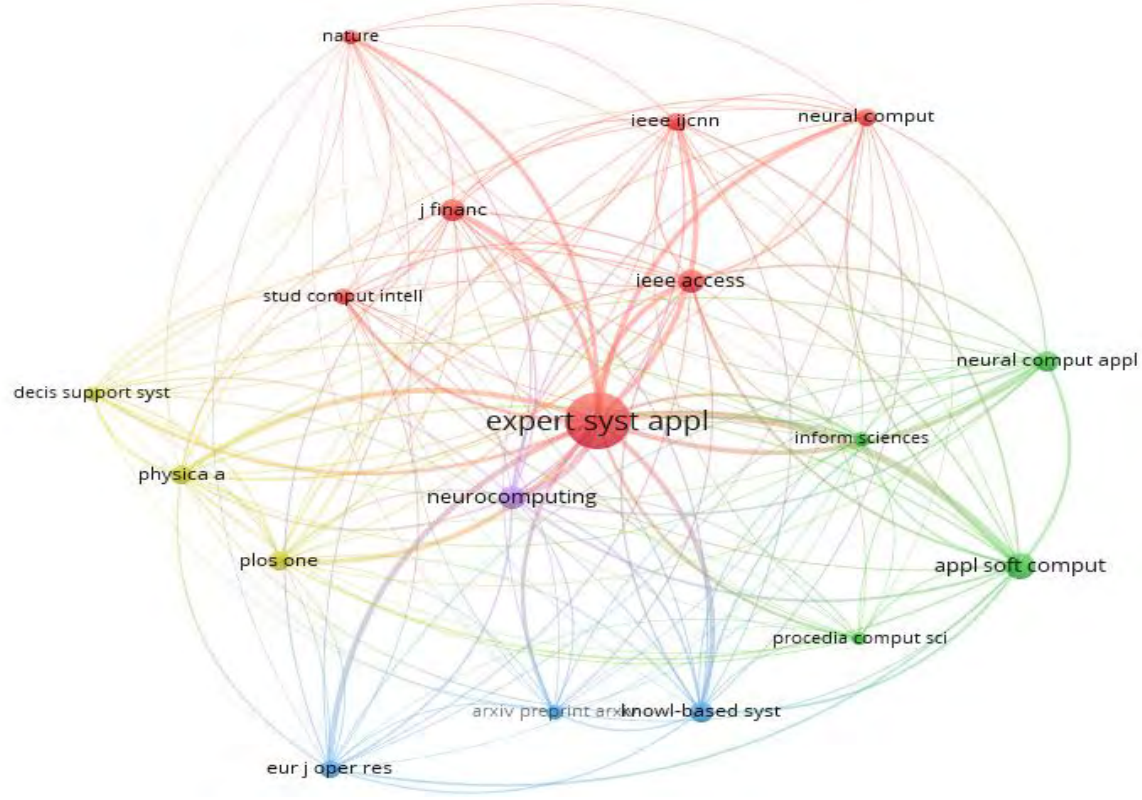
Quadro 14 – Lei de Bradford sobre Diários

Zona	Diários	Quantidade Individual	Total Acumulado	Percentual Acumulado
Zona A	Expert Systems With Applications	12	12	12.1%
	IEEE Access	11	23	23.2%
	Big Data Journal	5	28	28.3%
	Neural Computing and Applications	5	33	33.3%
Zona B	Applied Smooth Computing	4	37	37.4%
	Multimedia Tools and Applications	4	41	41.4%
	Scientific Programming	4	45	45.5%
	Smooth Computing	4	49	49.5%
	Forecast Diary	3	52	52.5%
	Neurocomputing	3	55	55.6%
	PEERJ Computer Science	3	58	58.6%
	Algorithms	2	60	60.6%
	Big Data	2	62	62.6%
	Computational Economics	2	64	64.6%
	Studies and Res in Ec Comp and Economic Cyber	2	66	66.7%
	Quantitative finance	2	68	68.7%
Zona C	CMC-Computers Materials & Continuous	1	69	69.7%
	Computer Science and Information Systems	1	70	70.7%
	Simult and Computing – Practice and Experience	1	71	71.7%
	Data Engineering	1	72	72.7%
	Specialized Systems	1	73	73.7%
	Financial Innovation	1	74	74.7%
	Next Generation Computing Systems – The International Journal of Science	1	75	75.8%
	Journal of Computational Intelligence IEEE	1	76	76.8%
	IEEE Transactions in Social Computational Systems	1	77	77.8%
	IEEE Transactions in Industrial Computing	1	78	78.8%
	IEEE Trans in Knowledge and Data Engineering	1	79	79.8%
	Training Computer	1	80	80.8%
	Information Science	1	81	81.8%
	International Journal of Finance and Economics	1	82	82.8%
	International Journal of Financial Engineering	1	83	83.8%
	International Forecast Journal	1	84	84.8%
	Journal of Machine Learning and Cybernetics	1	85	85.9%
	Journal of Advanced Comp Int and IntComputing	1	86	86.9%
	Journal Of Ambient Intel and Humanized Computing	1	87	87.9%
	Journal of Behavioral Finance	1	88	88.9%
	Journal of Financial Econometrics	1	89	89.9%
	Supercomputing Journal	1	90	90.9%
	Knowledge-based Systems	1	91	91.9%
	Mobile Information Systems	1	92	92.9%
	Networks and Mobile Apps	1	93	93.9%
	Multimedia Systems	1	94	94.9%
	New Generation Computing	1	95	96.0%
	North American Journal of Economics and Finance	1	96	97.0%
	Progress in Artificial Intelligence	1	97	98.0%
	Review of Social Media Strategies	1	98	99.0%
	Wireless Communications and Mobile Computing	1	99	100.0%

A Figura 22 apresenta a rede de cocitação entre os periódicos da amostra final de artigos. Os mais citados são os periódicos Expert Systems With Applications, com 12 citações; IEEE Access com 11 e os demais periódicos com 05 ou mentos citações. Tal fato demonstra que os periódicos que mais publicam sobre um determinado tema não são necessariamente os mais citados, enfatizando a importância dos artigos.

O tamanho dos nós indica a relevância dessas palavras nos artigos, a espessura das linhas está relacionada à força de ligação entre elas, e as cores separam os grupos.

Figura 22 - Mapa de Cocitação entre os Journals



Fonte: VOSviewer

Nota: O tamanho dos nós representa a relevância dos termos nos artigos. A espessura das linhas significa a força da conexão entre elas. As cores indicam o número de grupos.

O Quadro 15 apresenta os dez trabalhos mais citados sobre o tema Redes Neurais Artificiais LSTM. Dentre eles, destaca-se o trabalho de Kim e Won (2018), com 235 (20,8%) das citações e média anual de 47,0. O artigo se concentra em prever a volatilidade do índice de preços de ações, usando um modelo que integra o LSTM com vários modelos Autorregressivos Gerais. Heterocedasticidade condicional – GARCH. Em segundo e

terceiro lugares estão os artigos de Long et al. (2019) com 133 citações, média de 33,3 por ano, e Kudugunta e Ferrara (2018) com 132 citações, média de 26,4 por ano.

Quadro 15 – Os 10 artigos mais citados

Referências	Número de Citações	Frequência de Citações	Total de Citações por Ano
Kim and Won (2018)	235	20.8%	47.0
Long *et al*. (2019)	133	11.7%	33.3
Kudugunta and Ferrara (2018)	132	11.7%	26.4
Baek and Kim (2018)	123	10.9%	24.6
Bukhari *et al.* (2020)	120	10.6%	40.0
Pang *et al*. (2020)	120	10.6%	40.0
Sohangir *et al.* (2018)	93	8.2%	19.6
Jin *et al.* (2020)	70	6.2%	23.3
Borovkova and Tsiamas (2019)	57	5.0%	14.3
Xing *et al*. (2018)	49	4.3%	9.8
Total	1,132	100.0%	

Elaborado pela Autora

Por sua vez, Lotka (1926) afirma que um pequeno número de autores produz muitos artigos e que a produção obtida por esse reduzido número de pesquisadores se iguala em quantidade ao desempenho dos demais. Essa lei é denominada de lei do quadrado inverso - vide Equação 4.

$$a_n = a_1 / n^2, n = 1, 2, 3 \ldots \quad (4)$$

Em que:
a_n = número de autores que publicaram n artigos
a_1 = número de autores que publicaram um artigo
n = número de artigos publicados por autor

Na Equação 5, Chung e Cox (1990) esclarecem que o número de autores com um único artigo publicado, conforme a Lei de Lotka, seria de:

$$a_1 = 6 / \pi^2 = 0{,}6079 = 60{,}8\% \quad (5)$$

Assim, um autor com dois artigos publicados deveria ter a frequência de 15,2% ($0{,}6079/2^2$). Já um autor com três artigos publicados seria de 6,8% ($0{,}6079/3^2$).

Verifica-se que os 99 artigos da amostra final são produzidos por 333 autores, sendo que um autor publicou 4 artigos, seis autores publicaram 3 artigos, vinte autores publicaram 2 artigos e trezentos e trinta e três autores publicaram um único artigo. 27 autores (08%), incluindo apenas os que mais publicam, são responsáveis por 62 (18,2%)

publicações. Dito isso, não há um número menor de pesquisadores igualando o desempenho dos demais, impossibilitando a confirmação da Lei de Lotka.

3.4.2 Revisão Sistemática

Uma revisão sistemática da literatura busca identificar lacunas de conhecimento relacionadas ao tema deste estudo. Para isso, no Passo 6 do Item 3.2 – Metodologia, é definida uma matriz de (sub)categorização – ver Quadro 12. São identificadas categorias e subcategorias para cada um dos 99 artigos da amostra final.

Dessa forma, a contagem de frequência é feita em relação ao total das subcategorias e não ao total dos 99 artigos. As subcategorias que têm potencial para serem priorizadas em pesquisas futuras são destacadas. Na categoria 1, Redes Neurais/Algoritmos Utilizados na Pesquisa, o tema "Previsão de preços de ações com outras redes neurais artificiais e resultados comparados com RNN LSTM" é o mais relevante (65%), seguido de "Previsão de preços de ações com redes neurais combinadas, incluindo LSTM" (22%) e Projeção de Preço de Ações com RNN LSTM (23%).

Em relação à categoria 2 "Tipo de Dados Analisados", o preço de fechamento foi o dado mais utilizado nas pesquisas, isoladamente (22%) ou associado a outros dados (61%).

A categoria 3 indica que 21% dos artigos são baseados exclusivamente em dados das bolsas americanas, 20% utilizam exclusivamente dados das bolsas chinesas, 08% utilizam conjuntamente dados das bolsas americana e chinesa e outras associações. 38% dos artigos não usam dados das bolsas de valores dos EUA ou da China, mas das bolsas de valores do Brasil, Tailândia, Turquia, Teerã, Gana, Austrália, Alemanha, Coréia, Índia, Japão, Indonésia ou Reino Unido, em associação ou isoladamente. Assim, percebe-se que há muito espaço para estudos baseados em Bolsas de Valores em outros países desenvolvidos e/ou em desenvolvimento. 08% realizam análise de sentimento, ou seja, utilizam textos expostos na mídia, e não dados de Bolsas de Valores.

Quanto ao período de análise, categoria 4, 37% dos artigos concentraram-se em períodos de até 05 anos, 37% em períodos de 05 a 10 anos, 16% em períodos superiores a 10 anos e 09% não informaram, na categoria 5, destacam-se os objetivos dos artigos. 74% deles projetam o preço das ações com LSTM isoladamente ou associado às mais

variadas RNN (sem concentrações relevantes); 19% testam redes neurais híbridas e modelos de análise de sentimentos.

Por sua vez, a categoria 6 apresenta os resultados dos estudos realizados. Em 57% deles, os modelos propostos superam os resultados dos modelos com os quais foram comparados; em 42% os resultados são definidos como promissores, indicando que podem ser melhorados.

De acordo com a categoria 7, 57% dos estudos apresentam ajustes em modelos de redes neurais já testados, com melhoria na qualidade das informações de entrada e/ou outras inovações em modelos existentes. 42% dos artigos apresentam novas teorias ou novos modelos de projeções, utilizando redes neurais simples, híbridas ou combinadas.

Por fim, a categoria 08 indica caminhos para estudos futuros, ou seja, lacunas de conhecimento segundo os autores dos 99 artigos da amostra final. Em 27% dos artigos, os autores sugerem o uso de dados inovadores, como outras fontes de notícias e/ou dados de ações, em diferentes períodos de tempo, como o intradiário. 22% sugerem estudos com modelos híbridos de LSTM ainda não testados, associados ou não a outras redes neurais, outros tipos de dados, outras fontes e outros períodos. 10% sugerem estudos com outros tipos de redes neurais, puras ou híbridas.

Quadro 16 – Principais contribuições dos artigos da amostra

Arquivo no.	Autores	Ano da publicação	Tema principal / foco do estudo
1	Huang, YS; Gao, YL; Gan, Y; Ye, M	2021	Modelo baseado em VMD, o modelo GVL. Em comparação com os algoritmos de linha de base, os modelos propostos são de alta precisão de previsão
2	Chen, YC; Huang, WC	2021	Modelo baseado em 8 recursos de entrada diferentes, incluindo indicadores de tecnologia financeira, preços do ouro, índice de volatilidade do preço do ouro, preço do petróleo bruto, índice de volatilidade do preço do petróleo bruto e outros dados característicos. Resultados positivos.
3	Dong, ST; Wang, JX; Luo, HZ; Wang, HD; Wu, FX	2021	Algoritmo de seleção de preditores dinâmicos (DPSA) que avalia e seleciona dinamicamente o modelo de predição (preditor) para previsão de tendência de movimento diário de ações.

Arquivo no.	Autores	Ano da publicação	Tema principal / foco do estudo
4	Rezaei, H; Faaljou, H; Mansourfar, G	2021	Até que ponto a precisão dos modelos de previsão de aprendizado profundo afeta a alocação de ativos usando o modelo BlackLitterman e, em seguida, compara com outras estratégias de portfólio, como métodos de média-variância e ponderação igual.
5	Carosia, AED; Coelho, GP; da Silva, AEA	2021	Propõe estratégias de investimento baseadas na Análise de Sentimentos realizada com Redes Neurais Artificiais, e sua utilização no mercado financeiro brasileiro.
6	Yang, SG	2021	Propõe um framework de aprendizado profundo baseado em modelo para prever os valores dos indicadores financeiros. O framework proposto emprega o modelo de memória de longo prazo (LSTM) como um modelo de previsão de referência
7	Zolfaghari, M; Gholami, S	2021	Abordagem híbrida de transformação wavelet adaptativa, memória de longo prazo e modelos da família ARIMA-GARCH para a previsão de índices de ações
8	Han, JJ; Kim, HJ	2021	Modelo de memória bidirecional de longo prazo para prever tendências de negociação com base em tópicos específicos de investidores estatisticamente significativos de conjuntos de dados de notícias financeiras.
9	He, BT; Kita, E	2021	A Aplicação do Adversarial Generativo Sequencial Redes para previsão de preço de ações
10	Ray, P; Ganguli, B; Chakrabarti, A	2021	Abordagem Híbrida do Tempo Estrutural Bayesiano Série com LSTM para identificar a influência de Sentimento de notícias sobre a previsão de curto prazo do preço das ações
11	Li, Q; Tan, JH; Wang, J; Chen, H	2021	Modelo LSTM Multimodal Orientado a Eventos para previsão de ações usando notícias on-line
12	Nobre, RA; do Nascimento, KC; Vargas, PA; Valejo, ADB; Pessin, G; Villas, LA; Rocha, GP	2022	Desenvolvimento de um modelo de negociação deações híbrido, orientado a agentes autônomos
13	Touzani, Y; Douzi, K	2021	Uma estratégia de negociação baseada em LSTM e GRU adaptada ao mercado marroquino
14	Liu, YZ; Yu, XL; Wu, YH; Song, SH	2021	Previsão de tendências de variação de ações por meio de LSTM
15	Zhao, YZ	2021	Algoritmo de previsão de estoque de rede neural profunda guiado pela atenção. Este artigo sintetiza o índice diário de emoção de texto de mídia social de ações e o índice de tecnologia de ações como fonte de dados e os aplica ao modelo de rede neural de memória de longo e curto prazo (LSTM) para prever o mercado de ações
16	Wang, WJ; Tang, Y; Xiong, J; Zhang, YC	2021	Um novo modelo de aprendizado de máquina de computação de reservatório é desenvolvido para prever índices do mercado de ações
17	Jing, N; Wu, Z; Wang, HF	2021	Modelo de pesquisa híbrido aplicando a abordagem de Rede Neural Long ShortTerm Memory (LSTM) para analisar os indicadores técnicos do mercado de ações e os resultados da análise de sentimento da primeira etapa

Arquivo no.	Autores	Ano da publicação	Tema principal / foco do estudo
18	Yang, YJ; Yang, YM; Zhou, W	2021	Pesquisa sobre um modelo híbrido de previsão de preço de ações baseado em memória de longo prazo e decomposição
19	Gu, WT; Zhang, LH; Xi, HJ; Zheng, SH	2021	Previsão de ações com base na análise de texto de notícias
20	Sharma, S; Elvira, V; Chouzenoux, E; Majumdar, A	2021	Aprendizado de dicionário recorrente para modelos de espaço de estados com aplicação em previsão de ações
21	Ma, C; Zhang, JS; Liu, JM; Ji, LZ; Gao, F	2021	Desenvolvimento um algoritmo de aprendizado de reforço profundo (DRL) multimódulo paralelo para negociação de ações
22	Hansun, S; Young, JC	2021	Previsão de índices do setor financeiro LQ45 usando RNN-LSTM
23	Wu, JMT; Sun, LY; Srivastava, G; Lin, JCW	2021	Um Novo Sistema Sinergético de Sugestão de Negociação de Ações LSTM-GA em Internet das Coisas
24	Khalil, F; Pipa, G	2021	Este estudo tenta desvendar o quebra-cabeça de previsão do mercado de ações usando a análise textual com a ajuda de técnicas de processamento de linguagem natural (NLP) e modelo recorrente de aprendizado profundo chamado memória de longo prazo e curto prazo (LSTM)
25	Wu, JMT; Sun, LY; Srivastava, G; Lin, JCW	2021	Entender se o modelo LSTMLI treinado no conjunto de dados com indicadores antecedentes melhora a precisão da previsão
26	Chen, Y; Fang, RX; Liang, T; Sha, ZY; Li, SC; Yi, YG; Zhou, W; Song, HL	2021	Previsão do preço das ações com base no modelo CNN-BiLSTM-ECA
27	Lin, Y; Yan, Y; Xu, JL; Liao, Y; Ma, F	2021	Previsão de preço de índice de ações usando o modelo CEEMDAN-LSTM
28	Nguyen, HT; Tran, TB; Bui, PHD		Uma maneira eficaz de prever o preço das ações de Taiwan: aumentando o desempenho com técnicas de aprendizado de máquina
29	Prachyachuwong, K; Vateekul, P	2021	Previsão de tendências de ações usando abordagem de aprendizado profundo em Indicador Técnico e Informações Industriais Específicas
30	Kumar, R; Kumar, P; Kumar, Y	2021	Integrando polaridade de sentimentos orientada por *big data* e LSTM otimizado, para ABC para previsão de séries temporais
31	Zhang, WG; Gong, X; Wang, C; Ye, X	2021	Investigar os impactos do sentimento do investidor, medido pelo sentimento textual extraído de uma comunidade de investidores, na previsão de volatilidade das ações do mercado chinês
32	Gunduz, H	2021	Prever as direções de oito ações bancárias em Borsa Istanbul
33	Mehta, P; Pandya, S; Kotecha, K	2021	avaliar a precisão dos LSTMs na previsão da indústria de ações

Arquivo no.	Autores	Ano da publicação	Tema principal / foco do estudo
34	Lee, MC; Chang, JW; Hung, JSC; Chen, BL	2021	explorar a viabilidade e a eficiência do uso de indicadores de rede profunda e análise técnica para estimar movimentos de preços de ações de curto prazo
35	Serrano, W	2022	Este artigo propõe a rede neural aleatória (RNN) em uma configuração recorrente para a 4ª revolução industrial em uma aplicação Fintech: a previsão em dados de séries temporais, especificamente, preços
36	Budiharto, W	2021	propõe um modelo de ciência de dados para previsão de preços de ações na bolsa da Indonésia com base na computação estatística baseada na linguagem R e Long Short Term Memory (LSTM).
37	Ko, CR; Chang, HT	2021	Análise de sentimento baseada em LSTM para previsão de preços de ações.
38	Dami, S; Esterabi, M	2021	Previsão de retornos de ações da bolsa de Teerã usando Rede neural LSTM e técnica de engenharia de recursos
39	Ma, YL; Han, RZ; Wang, WZ	2021	A integração da previsão de retorno de modelos tradicionais de séries temporais na formação de portfólio pode melhorar o desempenho do modelo original de otimização de portfólio.
40	Wu, JMT; Li, ZC; Herencsar, N; Vo, B; Lin, JCW	2021	Um algoritmo de previsão de preços de ações CNN LSTM baseado em gráficos com indicadores principais
41	Sharaf, M; Hemdan, EE; El-Sayed, A; El-Bahnasawy, NA	2021	Estrutura para previsão de preços de ações
42	Gite, S; Khatavkar, H; Kotecha, K; Srivastava, S; Maheshwari, P; Pandey, N	2021	Previsão de preços de ações explicável de artigos de notícias financeiras usando análise de sentimento.
43	Nti, IK; Adekoya, AF; Weyori, BA	2021	Uma nova estrutura preditiva de fusão de informações de várias fontes baseada em redes neurais profundas para aprimoramento da precisão na previsão do mercado de ações
44	AbdelKawy, R; Abdelmoez, WM; Shoukry, A	2021	Um modelo de aprendizado de reforço profundo síncrono para negociação automatizada de várias ações
45	Song, T; Yan, XS	2021	Ajuste dinâmico da posição de estoque com base em rede neural profunda híbrida
46	Park, D; Ryu, D	2021	analisar a relação entre os mercados imobiliário e de ações, com foco nas bolhas do mercado imobiliário
47	Ji, Y; Liew, AWC; Yang, LX	2021	propusemos um novo modelo híbrido aprimorado de otimização de enxame de partículas (IPSO) e memória de longo prazo (LSTM) para previsão de preços de ações
48	Althelaya, KA; Mohammed, NA; El-Alfy, EM	2021	Nosso modelo proposto é baseado em uma transformada wavelet empírica que se mostra superando a transformada wavelet estacionária tradicional na captura de flutuações de preços em diferentes escalas de tempo

Arquivo no.	Autores	Ano da publicação	Tema principal / foco do estudo
49	Garcia-Na, S; Zeng, XJ; Keane, J	2020	Previsão do retorno de ações usando KAF dentro de uma abordagem de interdependência do mercado de ações
50	Zhang, YA; Yan, BB; Aasma, M	2020	previsão e análise de séries temporais financeiras usando CEEMD e LSTM
51	Chang, VC; Man, XW; Xu, QW; Hsu, CH	2021	Este artigo teve como foco o mercado de ações norte-americano, investigando o desempenho atingir os propósitos de identificação de pares de ações e previsão de preços, respectivamente, neste de pares negociados em diferentes tipos de carteiras (carteira agressiva e defensiva) e compare a precisão da previsão de preços com base no LSTM
52	Thakkar, A; Chaudhari, K	2020	Previsão de tendência de ações: frequência de documentos e redes neurais
53	Li, MG; Li, WR; Wang, F; Jia, XJ; Rui, GW	2021	análise do sentimento do investidor no mercado de ações com base no modelo de representações de codificador bidirecional de transformadores (BERT).
54	Yildiz, ZC; Yildiz, SB	2020	é propor uma estrutura de construção de portfólio que utilize o estoque previsto preços nos cálculos da carteira ótima
55	Li, YL; Bu, H; Li, JH; Wu, JJ	2020	O papel do sentimento do investidor extraído de texto na previsão do preço das ações chinesas com o aprimoramento do aprendizado profundo
56	Affonso, F; Dias, TMR; Pinto, AL	2021	Previsão do Financial Times Series de Ações Agrupadas
57	Kumar, K; Haider, MTU	2021	Previsão aprimorada do mercado de ações intradiário usando Otimização Metaheurística na Rede RNN–LSTM
58	Jin, ZG; Yang, Y; Liu, YH	2020	Previsão de preço de fechamento de ações com base na análise de sentimento e LSTM
59	Su, Z; Xie, HL; Han, L	2021	Algoritmo RFG-LSTM multifator para sequência de ações Previsão
60	Bucci, A	2020	Previsão de Volatilidade Realizada com Neural Redes
61	Yan, X; Wang, WH; Chang, M	2021	Pesquisa sobre modelo de previsão de transações de ativos financeiros baseado em rede neural LSTM
62	Liu, X; Liu, H; Guo, Q; Zhang, CM	2020	Modelo de transformação wavelet adaptável para previsão de dados de séries temporais
63	Qiu, Y; Yang, HY; Lu, S; Chen, W	2020	Neste artigo, um novo modelo chamado modelo RNN híbrido é proposto para o timing do mercado de ações, incorporando memória de longo prazo multicamada, unidade recorrente fechada multicamada e camada ReLU de uma camada
64	Pang, XW; Zhou, YQ; Wang, P; Lin, WW; Chang, V	2020	Uma abordagem inovadora de rede neural para previsão do mercado de ações
65	Bucci, A	2020	Modelos de Cholesky-ANN para predição multivariada realizada volatilidade

Arquivo no.	Autores	Ano da publicação	Tema principal / foco do estudo
66	Yeung, JFKA; Wei, ZK; Chan, KY; Lau, HYK; Yiu, KFC	2020	Detecção de saltos em séries temporais financeiras usando algoritmos de aprendizado de máquina
67	Kelotra, A; Pandey, P	2020	Previsão do mercado de ações usando otimizado Modelo Deep-ConvLSTM
68	Shu, WW; Gao, Q	2020	Previsão do preço das ações com base na frequência Componentes por EMD e Redes Neurais
69	Kilimci, ZH; Duvar, R	2020	Uma incorporação de palavras eficiente e aprendizado profundo. Modelo baseado para prever a direção do Mercado de câmbio usando Twitter e financeiro. Sites de notícias: um caso de ações de Istambul. Câmbio (BIST 100)
70	Song, D; Busogi, M; Baek, AMC; Kim, N	2020	Previsão do índice do mercado de ações com base no padrão de memória de longo prazo
71	Wang, JJ; Feng, CC; He, JJ; Feng, L; Li, Y	2020	Previsão do Índice de Ações Multifatoriais: abordagem usando análise de componentes principais, classificação de recursos e curta de 2 etapas, rede de memória de prazo com correção residual
72	Nabipour, M; Nayyeri, P; Jabani, H; Shahab, S; Mosavi, A	2020	Prevendo as tendências do mercado de ações usando a máquina Algoritmos de Aprendizado e Aprendizado Profundo Via Dados Contínuos e Binários; uma Análise Comparativa
73	Ma, YL; Han, RZ; Wang, WZ	2020	Modelos de Otimização de Portfólio Baseados em Previsão Usando redes neurais profundas
74	Chen, Q; Zhang, WY; Lou, Y	2020	Previsão de preços de ações usando uma profundidade híbrida Modelo de Aprendizagem Integrando Mecanismo de Atenção, *Perceptron* de várias camadas e bidirecional Rede Neural de Memória de Longo Prazo
75	Chacon, HD; Kesici, E; Najafirad, P	2020	Melhorando a previsão de séries temporais financeiras Precisão usando o modo empírico de conjunto Decomposição e Redes Neurais Recorrentes
76	Kim, S; Ku, S; Chang, W; Song, JW	2020	Prevendo a direção dos preços das ações dos EUA Usando Entropia de Transferência Efetiva Técnicas de aprendizado de máquina
77	Bukhari, AH; Raja, NA; Sulaiman, M; Islam, S; Shoaib, M; Kumam, P	2020	Fracionado Neuro-Sequencial ARFIMA-LSTM para Previsão do mercado financeiro
78	Ding, GY; Qin, LX	2020	Estudo sobre a previsão do preço das ações com base no modelo de rede associado do LSTM
79	Borovkova, S; Tsiamas, I	2019	Aqui propusemos uma estrutura de aprendizado de máquina para obter previsões de preços direcionais intradiárias
80	Makinen, Y; Kanniainen, J; Gabbouj, M; Iosifidis, A	2019	Previsão de chegadas de salto nos preços das ações: nova arquitetura de rede baseada em atenção usando dados limitados do livro de pedidos

Arquivo no.	Autores	Ano da publicação	Tema principal / foco do estudo
81	Chen, S; Ge, L	2019	Explorando o mecanismo de atenção em LSTM Previsão do movimento do preço das ações de Hong Kong
82	Zhao, Y; Shen, YY; Huang, Y	2019	DMDP: uma previsão de probabilidade padrão de várias fontes dinâmicas
83	Long, W; Lu, ZC; Cui, LX	2019	Engenharia de recursos baseada em aprendizado profundo para previsão de movimento de preços de ações
84	Baek, Y; Kim, HY	2018	Estrutura de previsão para o índice do preço de ações com um módulo LSTM de prevenção de overfitting e previsão Módulo LSTM
85	Xing, FZ; Cambria, E; Welsch, RE	2018	Previsão do preço de ações com análise de sentimentos
86	Li, ZX; Tam, V	2018	Adotar técnicas de aprendizado de máquina para investigar os efeitos de impulso e reversão que ocorrem em qualquer mercado de ações.
87	Kudugunta, S; Ferrara, E	2018	Redes neurais profundas para detecção de bots, contas automatizadas de mídia social regidas por software, mas disfarçadas de usuários humanos
88	Kim, HY; Won, CH	2018	Previsão da volatilidade do índice de preços de ações: um modelo híbrido integrando LSTM com vários modelos do tipo GARCH
89	Troiano, L; Villa, EM; Loia, V	2018	Replicar uma estratégia de negociação por meio de LSTM para aplicativos do setor financeiro
90	Sohangir, S; Wang, DD; Pomeranets, A; Khoshgoftaar, TM	2018	Big Data: Deep Learning para análise de sentimento fnanceiro
91	Dey, P; Hossain, E; Hossain, MI; Chowdhury, MA; Alam, MS; Hossain, MS; Andersson, K	2021	Análise Comparativa de Redes Neurais Recorrentes em Estoque Previsão de preço para diferentes domínios de frequência
92	Zhang, DX; Cai, EG	2021	Melhorando a previsão de preços de ações usando um grande volume de texto de manchete de notícia
93	Yap, KL; Lau, WY; Ismail, I	2021	Rede neural de aprendizado profundo para a previsão dos mercados de ações do Tigre Asiático
94	Kumar, A; Alsadoon, A; Prasad, PWC; Abdullah, S; Rashid, TA; Pham, DTH; Nguyen, TQV	2022	Rede adversarial generativa (GAN) e erro quadrático médio aprimorado (ERMSE): aprendizado profundo para previsão de movimento de preços de ações
95	Wu, DM; Wang, XL; Wu, SC	2022	Modelagem conjunta de aprendizado de transferência de informações da cadeia industrial e aprendizado profundo aprendizagem para previsão de ações
96	Huang, X; Song, HL	2021	Sentimento do investidor combinado com informações de várias fontes para prever os preços das ações: uma análise do mercado de ações A da China

Arquivo no.	Autores	Ano da publicação	Tema principal / foco do estudo
97	Wang, JJ; He, JJ; Feng, CC; Feng, L; Li, Y	2021	Previsão de índice de ações e análise de incerteza usando paradigma de conjunto não linear multiescala de extração de recursos ideal, aprendizado profundo em dois estágios e regressão de processo gaussiana
98	Park, HJ; Kim, Y; Kim, HY	2022	Propomos uma nova estrutura de previsão do mercado de ações (LSTMForest) integrando memória de longo prazo e floresta aleatória (RF) para resolver esse problem
99	Gao, Y; Wang, R; Zhou, EM	2021	Previsão de estoque com base em modelos otimizados LSTM e GRU

Quadro 17 – Codificação das categorias e subcategorias de análise dos artigos

No	Título	Categorias							
		1	2	3	4	5	6	7	8
1	A new financial data forecasting model using genetic algorithm and long short-term memory network	C	F	M	D	A	B	B	B
2	Constructing a stock-price forecast CNN model with gold and crude oil indicators	B	A,C,D	A,M	B	B	A	A	F
3	A dynamic predictor selection algorithm for predicting stock market movement	A,C,D	A,B,C	A,B,I	A	A	A	A	F
4	Intelligent Asset Allocation using Predictions of Deep Frequency Decomposition	C	F	A	C	A	B	B	C
5	Investment strategies applied to the Brazilian stock market: A methodology based on Sentiment Analysis with deep learning	B	F	L	A	A,C	B	B	C
6	A novel study on deep learning framework to predict and analyze the financial time series information	B	F	A,M	B	A	B	B	B,C
7	A hybrid approach of adaptive wavelet transform, long short-term memory and ARIMA-GARCH family models for the stock index prediction	C	F	M	C	A	A	A	A,D

No	Título	Categorias							
		1	2	3	4	5	6	7	8
8	Prediction of Investor-Specific Trading Trends in South Korean Stock Markets Using a BiLSTM Prediction Model Based on Sentiment Analysis of Financial News Articles	C	D,F	J	A	A	C	D	F
9	The Application of Sequential Generative Adversarial Networks for Stock Price Prediction	C	A,B,D	A	C	A	B	B	F
10	A Hybrid Approach of Bayesian Structural Time Series With LSTM to Identify the Influence of News Sentiment on Short-Term Forecasting of Stock Price	C	A,B,C,F	K	A	A,C	A	A	F
11	A Multimodal Event-Driven LSTM Model for Stock Prediction Using Online News	B	A,B,C,D,F	B	A	A,C	A	A	A,F
12	AURORA: an autonomous agent-oriented hybrid trading service	B	A	C	A	A	A	A	F
13	Na LSTM and GRU based trading strategy adapted to the Moroccan market	B	A	A	C	A	A	A	C,E
14	Forecasting Variation Trends of Stocks via Multiscale Feature Fusion and Long Short-Term Memory Learning	B	A	M	A	A	A	A	B
15	A Novel Stock Index Intelligent Prediction Algorithm Based on Attention-Guided Deep Neural Network	B	A,B,C,D,F	L	A	A,C	A	A	F
16	Stock market index prediction based on reservoir computing models	B	A	A,B,N	C	A	B	B	D,F
17	A hybrid model integrating deep learning with investor sentiment analysis for stock price prediction	B	A,B,C,D,F	B,L	A	A,C	A	A	F
18	Research on a hybrid prediction model for stock price based on long short-term memory and variational mode decomposition	B	E	A,B,I,M	C	A	B	B	A
19	Stock Prediction Based on News Text Analysis	C,D	E,F	B,M	A	A,C	A	A	C

No	Título	Categorias							
		1	2	3	4	5	6	7	8
20	Recurrent dictionary learning for state-space models with an application in stock forecasting	B	A	M	C	A	A	A	F
21	A parallel multi-module deep reinforcement learning algorithm for stock trading	B	A	B	C	A	A	A	A
22	Predicting LQ45 financial sector indices using RNN-LSTM	B	A	O	A	A	B	B	A,B
23	A Novel Synergetic LSTM-GA Stock Trading Suggestion System in Internet of Things	C,D	A,B,C,D,F	A,D	D	A	B	B	C
24	Is Deep-Learning and Natural Language Processing Transcending the Financial Forecasting? Investigation Through Lens of News Analytic Process	A	A,B,C,D,F,	M	B	A,C	A	A	C
25	A Long Short-Term Memory Network Stock Price Prediction with Leading Indicators	C,D	A,B,C,F	A,D	A	A	B	B	A,B,C,D
26	Stock Price Forecast Based on CNN-BiLSTM-ECA Model	B,C,D	A,B,C,D,F	B	C	A	A	A	C
27	Forecasting stock index price using the CEEMDAN-LSTM model	C,D	A	A,B	C	A	B	B	F
28	Na effective way for Taiwanese stock price prediction: Boosting the performance with machine learning techniques	B	C	D	C	A,D	B	B	F
29	Stock Trend Prediction Using Deep Learning Approach on Technical Indicator and Industrial Specific Information	B	A,B,C	D,L	B	A,C,D	B	B	D,E
30	Integrating big data driven sentiments polarity and ABC-optimized LSTM for time series forecasting	B	F	L	C	A,C,D	B	B	C
31	redicting stock market volatility based on textual sentiment: A nonlinear analysis	D	I	L	B	A,C	B	B	C

No	Título	Categorias							
		1	2	3	4	5	6	7	8
32	An efficient stock market prediction model using hybrid feature reduction method based on variational autoencoders and recursive feature elimination	B	A,B,C	E,L	A	A	B	B	C
33	Harvesting social media sentiment analysis to enhance stock market prediction using deep learning	B	F	B	A	A,C	B	B	C
34	Exploring the Effectiveness of Deep Neural Networks with Technical Analysis Applied to Stock Market Prediction	B	A,B,C	D	A	A	A	A	C
35	The random neural network in price predictions	B	E,F	A,B,N,M	C	A	A	A	A,B
36	Data science approach to stock prices forecasting in Indonesia during Covid-19 using Long Short-Term Memory (LSTM)	B	A,B,C	O	A	A,C	A	A	C
37	LSTM-based sentiment analysis for stock price forecast	B	F	D	B	A,C	A	A	C
38	Predicting stock returns of Tehran exchange using LSTM neural network and feature engineering technique	B	A,B,C,D	F	B	A,D	A	A	A,B
39	Portfolio optimization with return prediction using deep learning and machine learning	B	I	B	A	A	A	A	A,B
40	A graph-based CNN-LSTM stock price prediction algorithm with leading indicators	B	A,B,C,D,F	A,D	A	A	B	B	A,B
41	StockPred: a framework for stock Price prediction	B,D	A	M	C	A	A	A	C
42	Explainable stock prices prediction from financial news articles using sentiment analysis	B	A,B,C	L	D	A	B	B	C
43	A novel multi-source information-fusion predictive framework based on deep neural networks for accuracy enhancement in stock market prediction	C	A,B,C,D,E,F	G	A	A	A	A	A,B,C

No	Título	Categorias							
		1	2	3	4	5	6	7	8
44	A synchronous deep reinforcement learning model for automated multi-stock trading	B	A,B,C,D	A	C	A	A	A	C
45	Dynamic adjustment of stock position based on hybrid deep neural network	B	A	B	C	A	A	A	F
46	A Machine Learning-Based Early Warning System for the Housing and Stock Markets	B	E,F	J	C	A	B	B	C
47	A Novel Improved Particle Swarm Optimization With Long-Short Term Memory Hybrid Model for Stock Indices Forecast	B	A	A,H	C	A	A	A	C
48	Combining Deep Learning and Multiresolution Analysis for Stock Market Forecasting	A	A	A	B	A	A	A	D,F
49	Stock returns prediction using kernel adaptive filtering within a stock market interdependence approach	B	A	A,I,P	A	A	A	A	C,F
50	A novel deep learning framework: prediction and analysis of financial time series using CEEMD and LSTM	B	A	A,B	B	A	A	A	C,F
51	Pairs trading on different portfolios based on machine learning	A	A,B,C,D	A	B	A	B	B	A,B,E
52	Predicting stock trend using an integrated term frequency-inverse document frequency-based feature weight matrix with neural networks	B	A,B,C,D	A	C	A	A	A	A,B
53	Applying BERT to analyze investor sentiment in stock market	B	A,F	M	A	A,C	B	B	F
54	A portfolio construction framework using LSTM-based stock markets forecasting	B	A,B,C,D	E	A	A,D	A	A	A,B,C
55	The role of text-extracted investor sentiment in Chinese stock price prediction with the enhancement of deep learning	B,D	F	L	B	A,C	B	B	F
56	Financial Times Series Forecasting of Clustered Stocks	B	A,C,F	M	C	A	B	B	A,B,C

No	Título	Categorias							
		1	2	3	4	5	6	7	8
57	Enhanced Prediction of Intra-day Stock Market Using Metaheuristic Optimization on RNN-LSTM Network	C	F	M	A	A	A	A	A
58	Stock closing price prediction based on sentiment analysis and LSTM	B	A,B,C,D	M	A	A	A	A	B,C
59	Multi-Factor RFG-LSTM Algorithm for Stock Sequence Predicting	B	E	B	C	A	B	B	B
60	Realized Volatility Forecasting with Neural Networks	B	A	A	C	A	B	B	B
61	Research on financial assets transaction prediction model based on LSTM neural network	B	A,B,F	B	C	A	B	B	C
62	Adaptive wavelet transform model for time series data prediction	B,D	C,F	A	D	A	A	A	C
63	A novel hybrid model based on recurrent neural networks for stock market timing	B	E	B	A	A	A	A	A,B
64	An innovative neural network approach for stock market prediction	B,C,D	A,B,C,D,F	B	C	A	B	B	C
65	Cholesky-ANN models for predicting multivariate realized volatility	B	F	A	C	A	B	B	B
66	Jump detection in financial time series using machine learning algorithms	D	E	A,B	D	A	B	B	B
67	Stock Market Prediction Using Optimized Deep-ConvLSTM Model	C,D	A,B,C,D,F	A	A	A	B	B	F
68	Forecasting Stock Price Based on Frequency Components by EMD and Neural Networks	B	A	B	C	A	B	B	C
69	An Efficient Word Embedding and Deep Learning Based Model to Forecast the Direction of Stock Exchange Market Using Twitter and Financial News Sites: A Case of Istanbul Stock Exchange (BIST 100)	B	A,F	E,L	A	A,C	B	B	F

No	Título	Categorias							
		1	2	3	4	5	6	7	8
70	Forecasting Stock Market Index Based on Pattern-Driven LSTM	C	A,B,C,D,F	J	C	A	A	A	B,C
71	A Novel multi-factor stock index prediction approach using principal component analysis feature classification and two-stage long short term memory network with residual correction	B	A,B,C,D,F	A	C	A	B	B	A,B,C
72	Predicting Stock Market Trends Using Machine Learning and Deep Learning Algorithms Via Continuous and Binary Data; a Comparative Analysis	B,D	F	F	B	A	B	B	D
73	Prediction-Based Portfolio Optimization Models Using Deep Neural Networks	B	F	B	B	A	A	A	C
74	Forecasting Stock Prices Using a Hybrid Deep Learning Model Integrating Attention Mechanism, Multi-Layer Perceptron, and Bidirectional Long-Short Term Memory Neural Network	B	A,B,C,D,F	A	C	A	A	A	B,C,D
75	Improving Financial Time Series Prediction Accuracy Using Ensemble Empirical Mode Decomposition and Recurrent Neural Networks	A	A	A	A	A	B	B	C
76	Predicting the Direction of US Stock Prices Using Effective Transfer Entropy and Machine Learning Techniques	B	A	A	C	A	A	A	B
77	Fractional Neuro-Sequential ARFIMA-LSTM for Financial Market Forecasting	B,D	F	M	D	A	A	A	A
78	Study on the prediction of stock price based on the associated network model of LSTM	B	A,C	B	D	A	A	A	B
79	An ensemble of LSTM neural networks for high-frequency stock market classification	A	A,B,C,D	A	A	A	A	A	F
80	Forecasting jump arrivals in stock prices: new attention-based network architecture using limit order book data	A,C,D	A,B	A	A	A	A	A	B,F

No	Título	Categorias							
		1	2	3	4	5	6	7	8
81	Exploring the attention mechanism in LSTM-based Hong Kong stock price movement prediction	A,C	A,B,C,D	B	C	A	A	A	F
82	DMDP: A Dynamic Multi-source Default Probability Prediction Framework	C,D	E	B	A	A	A	A	C
83	Deep learning-based feature engineering for stock price movement prediction	B	A,B,C,D,F	B	A	A	A	A	A,B
84	ModAugNet: A new forecasting framework for stock market index value with an overfitting prevention LSTM module and a prediction LSTM module	A	A	A,J	C	A	A	A	B
85	Intelligent Asset Allocation via Market Sentiment Views	A,B,C,D	A,D	L,M	A	C	A	A	F
86	A Machine Learning View on Momentum and Reversal Trading	B	A,B,C,D,E,F	B	B	A	B	B	B,C
87	Deep neural networks for bot detection	A	F	L	D	A,C	A	A	B,C
88	Forecasting the volatility of stock price index: A hybrid model integrating LSTM with multiple GARCH-type models	A,B	A,E	J	C	A	A	A	C
89	Replicating a Trading Strategy by Means of LSTM for Financial Industry Applications	A,B	A	A	A	D	A	A	B
90	Big Data: Deep Learning for financial sentiment analysis	B	F	L	A	A,C	B	B	F
91	Comparative Analysis of Recurrent Neural Networks in Stock Price Prediction for Different Frequency Domains	B	A,B,C,D,F	A	A	A	A	A	B,C
92	Improving Stock Price Forecasting Using a Large Volume of News Headline Text	B	A,B,C,D	B	A	A	B	B	C
93	Deep learning neural network for the prediction of Asian Tiger stock markets	B	A	B,D,M	C	A	B	B	F

No	Título	Categorias							
		1	2	3	4	5	6	7	8
94	Generative adversarial network (GAN) and enhanced root mean square error (ERMSE): deep learning for stock price movement prediction	B	A,B,C,D	A	B	A	B	B	F
95	Jointly modeling transfer learning of industrial chain information and deep learning for stock prediction	B	A,B,C,D,E	B	B	A	B	B	F
96	Investor Sentiment Combined with Multisource Information to Predict Stock Prices: An Analysis of China's A-Share Market	C	F	B,L	A	A,C	A	A	F
97	Stock index prediction and uncertainty analysis using multi-scale nonlinear ensemble paradigm of optimal feature extraction, two-stage deep learning and Gaussian process regression	B	A	A	C	A	A	A	A,B
98	Stock market forecasting using a multi-task approach integrating long short-term memory and the random forest framework	C,D	A,B,C,D,F	A,B,J	C	A	A	A	A,C
99	Stock Prediction Based on Optimized LSTM and GRU Models	B	A,B,C,D,F	B	C	A	A	A	F

3.6 Conclusão

As publicações sobre esse tema se concentram a partir de 2020. As palavras-chave mais associadas a esses estudos são modelo, redes neurais, previsão e séries temporais. 333 autores escreveram sobre o assunto entre 2018 e março de 2022; 43 dos 99 artigos publicados neste período estão associados a instituições chinesas.

As revistas que publicam os artigos mais significativos sobre o tema são Expert Systems with Applications, IEEE Access, Big Data Journal e Neural Computing and Applications. O artigo mais citado é de Kim e Won (2018), Stock Price Index Volatility Prediction: A Hybrid Model Integrating LSTM with Various GARCH-Type Models, que

estuda a volatilidade dos retornos do índice de ações Kospi 200 e a capitalização do mercado de ações na Coreia do Sul, citado 235 vezes.

O preço de fechamento diário das ações é o tipo de dado mais analisado, e os estudos ainda se concentram nas bolsas americanas (21%) e chinesas (20%). 57% dos estudos apresentam ajustes em modelos de redes neurais já testados e 42% apresentam novas teorias ou novos modelos de projeção.

Em 27% dos artigos, os autores sugerem estudos futuros com fontes de notícias, outros dados de estoque ou o uso de diferentes séries temporais. 22% sugerem estudos com modelos híbridos de LSTM ainda não testados, associados ou não a outras redes neurais, outros dados, outras fontes e períodos.

4. TERCEIRO ENSAIO: PROJEÇÃO DE VALORES DE AÇÕES COM REDES NEURAIS MLP E LSTM –ATIVOS DA B3 S/A.

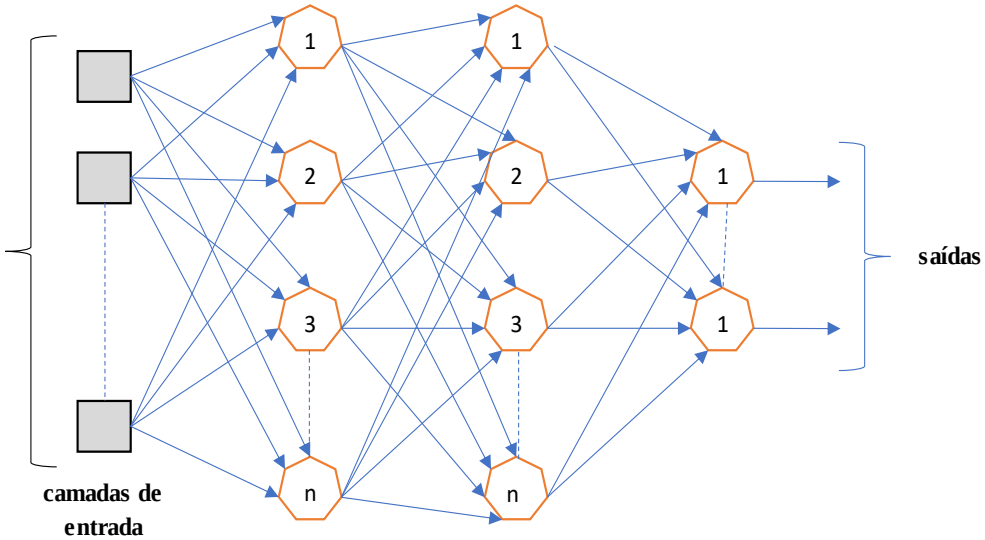
4.1 Introdução

O Objetivo desse ensaio é comparar as qualidades de projeções de preços de ações com as redes MLP e LSTM, para as ações listadas nas bolsas de valores do Brasil, a B3 S/A., utilizando os preços dos fechamentos diários, de 04/01/2010 até 15/05/2022, com a finalidade de contribuir na previsão de preços das ações, com os investidores desse mercado, a fim de obter-se melhores retornos das carteiras de investimento.

4.2 Revisão da Literatura

O MLP (PRIMEIRO ENSAIO) é uma rede neural artificial simples, composta por uma camada de entrada para receber o sinal, uma camada de saída que toma uma decisão ou previsão sobre a entrada, e entre esses dois, um número arbitrário de camadas ocultas que são o mecanismo computacional do MLP. Os MLPs são frequentemente aplicados a problemas de aprendizagem supervisionados: treinam em um conjunto de pares entrada-saída e aprendem a modelar a correlação entre elas. O treinamento envolve o ajuste dos parâmetros para minimizar o erro.

Figura 23 – Rede Neural Multi Layer Perceptron



As redes recorrentes são um poderoso conjunto de algoritmos de redes neurais artificiais especialmente úteis para o processamento de dados sequenciais, como som,

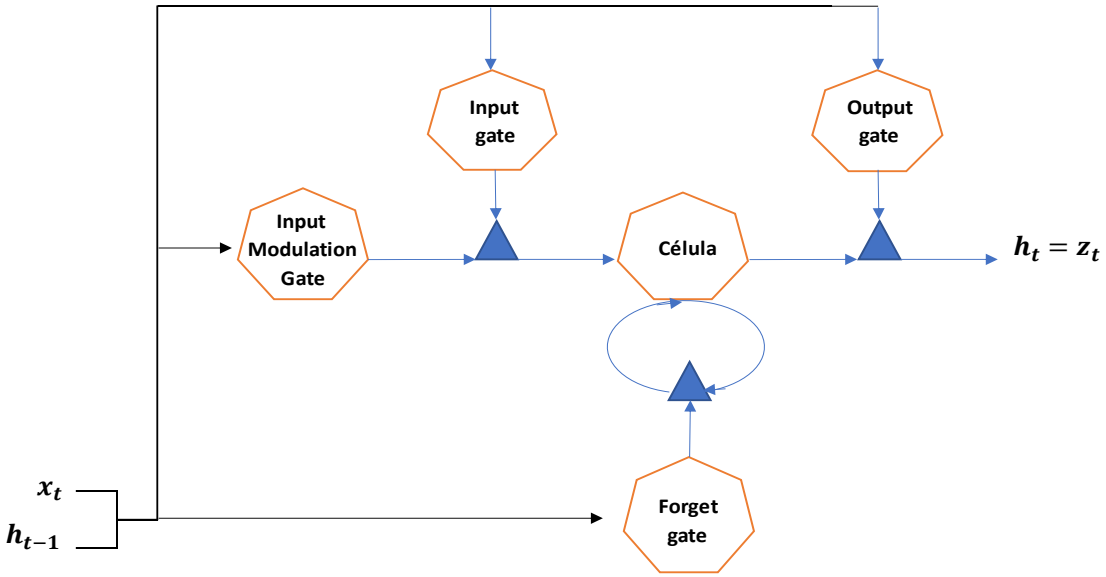
dados de séries temporais ou linguagem natural. O LSTM (SEGUNDO ENSAIO) é uma variação de rede recorrente.

As arquiteturas LSTM ajudam a preservar o erro que pode ser copiado por tempo e camadas. Ao manter um erro mais constante, eles permitem que as redes recorrentes continuem aprendendo durante vários passos de tempo (*epochs*), abrindo assim um canal para vincular causas e efeitos remotamente.

Os LSTM são muito aplicados em reconhecimento de imagens, de voz ou vídeos, classificação e previsões utilizando dados em séries de tempo. Estes modelos resolvem o problema do gradiente (redução do erro) que é encontrado ao treinar redes neurais tradicionais.

Possuem estrutura em cadeia que contém quatro redes neurais e diferentes blocos de memória chamados células. A informação é retida pelas células e as manipulações de memória são feitas pelos portões (*gates*). Existem três possibilidades de portões:

Figura 24 – Rede Neural LSTM



Porta de entrada*:* a adição de informações úteis ao estado da célula é feita pelo *input gate*. Primeiro, a informação é regulada usando a função sigmoide que filtra os valores a serem lembrados.

Porta de esquecimento: as informações que não são mais úteis são removidas com o *forget gate.*

Porta de saída*:* a tarefa de extrair informações úteis do estado da célula atual para ser apresentadas como uma saída é feita pelo *output gate*. Um vetor é gerado e a informação é regulada usando a função que filtra os valores a serem lembrados. Os valores do vetor e os valores regulados são multiplicados para serem enviados como saída (e entrada para a próxima célula).

4.2 Amostra de dados

No estudo foram utilizados os dados das 50 maiores empresas listadas na B3, considerando seu ativo imobilizado na data de extração dos dados, no período de 04/01/2010 até 15/05/2022, totalizando 3059 observações diárias.

Desta amostra, foram retiradas as ações que não eram negociadas todos os dias, sendo um conjunto de 19 empresas, restando assim, um total de 31.

Quadro 18 – 50 maiores empresas por ativo imobilizado listadas na B3

ITEM	TICKERS	EMPRESAS	SELECIONADAS	EXCLUÍDAS
1	ABEV3	AMBEV S/A ON	X	
2	AMER3	AMERICANAS ON NM	X	
3	B3SA3	B3 S/A	X	
4	BBAS3	BRASIL ON NM	X	
5	BBDC4	BRADESCO PN EJ N1	X	
6	BRKM5	BRASKEM PNA N1	X	
7	CCRO3	CCR SA ON NM	X	
8	CMIG4	CEMIG PN N1	X	
9	CPFE3	CPFL ENERGIA ON NM	X	
10	CPLE6	COPEL PNB N2	X	
11	CSAN3	COSAN ON NM	X	
12	EGIE3	ENGIE BRASIL ON NM	X	
13	ELET3	ELETROBRAS ON N1	X	
14	EQTL3	EQUATORIAL ON NM	X	
15	GGBR4	GERDAU PN N1	X	
16	HYPE3	HYPERA ON NM	X	
17	ITSA4	ITAUSA PN EJ N1	X	
18	ITUB4	ITAUUNIBANCO PN EJ N1	X	
19	JBSS3	JBS ON NM	X	
20	LREN3	LOJAS RENNERON NM	X	
21	NTCO3	GRUPO NATURA ON NM	X	
22	PETR4	PETROBRAS PN N2	X	
23	RADL3	RAIADROGASILON NM	X	

ITEM	TICKERS	EMPRESAS	SELECIONADAS	EXCLUÍDAS
24	RENT3	LOCALIZA ON NM	X	
25	SANB11	SANTANDER BRUNT	X	
26	SBSP3	SABESP ON NM	X	
27	TIMS3	TIM ON NM	X	
28	TRPL4	TRAN PAULISTPN N1	X	
29	VALE3	VALE ON NM	X	
30	VIVT3	TELEF BRASILON	X	
31	WEGE3	WEG ON NM	X	
32	ASAI3	ASSAI ON NM		X
33	BBSE3	BB SEGURIDADE ON NM		X
34	BPAC11	BTGP BANCO UNT N2		X
35	CMIN3	CSN MINERACÃO ON N2		X
36	CRFB3	CARREFOUR BRON NM		X
37	CSNA3	SID NACIONALON		X
38	CXSE3	CAIXA SEGURION NM		X
39	ENGI11	ENERGISA UNT N2		X
40	ENMT3	ENERGISA MT ON		X
41	HAPV3	HAPVIDA ON NM		X
42	KLBN11	KLABIN S/A UNT N2		X
43	MGLU3	MAGAZINE LUIZA ON NM		X
44	NEOE3	NEOENERGIA ON NM		X
45	PRIO3	PETRORIO ON NM		X
46	RAIL3	RUMO S.A. ON NM		X
47	RAIZ4	RAIZEN PN N2		X
48	RDOR3	REDE D OR ON NM		X
49	SUZB3	SUZANO S.A. ON NM		X
50	VBBR3	VIBRA ON NM		X

Fonte: Elaborado pela Autora

Portanto da amostra inicial de 50 empresas restaram 31, que são as utilizadas para o estudo.

Os dados foram utilizados em nível, sem nenhuma transformação, a fim de se descobrir se o aprendizado das redes neurais seria compatível.

4.3 Metodologia

Para a estimação dos modelos, foram utilizados dois tipos de redes neurais, uma de configuração *Long Short Term Memory* (LSTM) e a outra de configuração *Multi-Layer Perceptron* (MLP).

A MLP é uma rede mais simples pela característica de reestimar os valores projetados a cada passo, visando a redução do gradiente. A arquitetura utilizada, possui três camadas, sendo que a primeira, possui um neurônio, a segunda cinco neurônios e a terceira cinco neurônios.

Foi escolhida uma configuração reduzida para evitar o efeito de *overfitting,* que conduz os resultados à um valor único, independente das variações ocorridas na entrada.

De acordo com a configuração escolhida das redes, para cada ação foram estimados 25 modelos, sendo:

Quadro 19 – Configuração das redes

Neurônios da camada 1	Neurônios da camada 2	Neurônios da camada 3
1	1	1
1	2	1
1	3	1
1	4	1
1	5	1
1	1	2
1	2	2
1	3	2
1	4	2
1	5	2
1	1	3
1	2	3
1	3	3
1	4	3
1	5	3
1	1	4
1	2	4
1	3	4
1	4	4
1	5	4
1	1	5
1	2	5
1	3	5
1	4	5
1	5	5

Fonte: Elaborada pela autora

Overfitting é um comportamento, que ocorre quando um modelo tem ajuste satisfatório aos dados de treinamento, mas se mostra inapto para a realização de projeções. A razão do *overfitting* ocorrer é devido às características dos dados analisados, podendo ser devido à complexidade dos dados, quebras estruturais, heterocedasticidade ou excesso de pontos discrepantes.

Na estimação dos modelos foram utilizados 75% dos dados para treinamento das redes e 25% para teste. Assim, das 3.059 observações diárias, 2.295 foram utilizadas para a estimação e 764 para teste, taxa de aprendizado de 0.05 e número de *epochs* igual a 300. Após a estimação, os erros das projeções, foram e analisados no *Model Confidence Set* (MCS), que escolhe os melhores modelos de estimação para cada ação.

O processo foi realizado para as arquiteturas de rede LST e MLP, produzindo 50 modelos para cada ativo.

4.4 Resultados

Os 50 melhores modelos escolhidos pelo MCS, todos LSTM, foram:

Quadro 20 – Melhores modelos

Item	Ação	1ª Camada	2ª Camada	3ª Camada
1	ABEV3	1	2	2
2	AMER3	1	2	5
3	ANB11	1	3	3
4	ANB11	1	4	5
5	B3SA3	1	5	2
6	BBAS3	1	5	1
7	BBDC4	1	2	5
8	BBDC4	1	4	3
9	BBDC4	1	5	3
10	BRKM5	1	2	5
11	BRKM5	1	3	3
12	BRKM5	1	4	3
13	CCRO3	1	4	2
14	CCRO3	1	5	4
15	CMIG4	1	3	5
16	CPFE3	1	4	5
17	CPLE6	1	4	5
18	CSAN3	1	2	4
19	CSAN3	1	3	3

Item	Ação	1ª Camada	2ª Camada	3ª Camada
20	CSAN3	1	3	4
21	CSNA3	1	5	2
22	EGIE3	1	1	5
23	ELET3	1	1	5
24	ELET3	1	4	2
25	EQTL3	1	1	5
26	GGBR4	1	1	5
27	HYPE3	1	2	3
28	ITSA4	1	3	4
29	ITSA4	1	4	5
30	ITSA4	1	5	2
31	ITSA4	1	5	5
32	ITUB4	1	1	4
33	JBSS3	1	2	5
34	LREN3	1	5	5
35	NTCO3	1	4	2
36	PETR4	1	2	5
37	RADL3	1	2	5
38	RADL3	1	4	2
39	RENT3	1	5	2
40	SBSP3	1	4	2
41	TIMS3	1	3	4
42	TIMS3	1	5	5
43	TRPL4	1	5	2
44	VALE3	1	3	1
45	VALE3	1	3	3
46	VALE3	1	3	4
47	VALE3	1	3	5
48	VIVT3	1	1	4
49	WEGE3	1	2	3
50	WEGE3	1	2	5

Fonte: Elaborada pela autora

O MCS descartou todos os modelos baseados em MLP. Para as ações ANB11, CCRO3, ELET3, RADL3, TIMS3, WEGE3, dois modelos empataram, produzindo os mesmos erros de estimação. Para as ações BBDC4, BRKM5, CSAN3, três modelos empataram, produzindo os mesmos erros de estimação. Para as ações ITSA4, VALE3, quatro modelos empataram, produzindo os mesmos erros de estimação.

4.5 Conclusão

O MCS descartou todos os modelos baseados em MLP, evidenciando a capacidade de aprendizado superior da rede LSTM.

Possibilidades de estudos futuros, envolvem a utilização de outras arquiteturas de redes, tais como as classes *deep learning.*

5. QUARTO ENSAIO: PROJEÇÃO DO PREÇO DE AÇÕES COM RNA E DADOS DE ALTA FREQUÊNCIA

5.1 Introdução

O debate sobre a previsibilidade dos mercados financeiros levou a um crescimento relevante do volume de pesquisas sobre esse assunto, em especial com RNA LSTM, como apontado no SEGUNDO ENSAIO. Com o aumento da disponibilidade de dados de alta frequência e o desenvolvimento de algoritmos de aprendizado de máquina que podem lidar com grandes quantidades de dados, a análise técnica está passando por um renascimento: os padrões diários são substituídos pelos intradiários e os algoritmos aprendem padrões de preços e a fazer previsões com base neles (Borovkova, S. e Tsiamas I., 2019).

Este também é o foco de nosso trabalho. Compilamos uma base de dados de negociação intradiária (intervalos de um minuto), e os alimentamos em redes neurais recorrentes. Usamos o chamado aprendizado profundo, onde dados de uma linha do tempo alimentam as redes, usando a RNA LSTM.

5.2 Revisão da Literatura

A maior parte da pesquisa sobre aplicativos de aprendizado de máquina e aprendizado profundo para previsões de séries temporais financeiras é recente. Nelson, Pereira, e de Oliveira (2017) treinaram redes LSTM em observações com intervalo de 15 minutos, para diversas ações da B3 (Bolsa de Valores de São Paulo) e precisão relatada com métricas de 53–55% para as previsões de preço da próxima direção.

O objetivo desse capítulo é projetar via RNA LSTM, os preços das ações PETR3, IBOV E IRBR, listadas nas bolsas de valores do Brasil, a B3 S/A., utilizando os preços intradiários, de 08 de abril de 2019 a 30 de dezembro de 2021, com a finalidade de contribuir na previsão de preços das ações, a fim de obter-se melhores retornos das carteiras de investimento. Os modelos resolvem o problema do gradiente (redução do erro) que é encontrado ao treinar redes neurais tradicionais.

Possuem estrutura em cadeia que contém quatro redes neurais e diferentes blocos de memória chamados células. A informação é retida pelas células e as manipulações de memória são feitas pelos portões (*gates*).

5.3 Amostra de dados

No estudo foram utilizados os dados de três ações de grande movimentação na B3: PETR3 (Petrobras), IBOV (Ibovespa) e IRBR3 (IRB Brasil). Usamos dados brutos de 08 de abril de 2019 a 30 de dezembro de 2021, coletados a cada um minuto, a partir da abertura do mercado da B3, às 10h00 até o seu fechamento diário, totalizando 273.673 observações.

5.4 Metodologia

Para a estimação dos modelos foi utilizada a configuração LSTM. A arquitetura utilizada possui três camadas, que podem ter de 1 a 5 neurônios. O sistema testa o número de camadas ideal, para cada ação, até encontrar o menor erro quadrática médio. Trata-se de uma configuração reduzida, que evita efeito de *overfitting,* a fim de não conduzir os resultados a um valor único, independente das variações ocorridas na entrada.

Na estimação dos modelos foram utilizados 75% dos dados para treinamento das redes e 25% para teste.

Após a estimação, os erros das projeções são analisados no Model Confidence Set (MCS), que escolhe os melhores modelos de estimação para cada ação. O treinamento de redes LSTM é feito pelo software Stata12.

5.5 Resultados

De acordo com a estrutura preditiva aplicada, o modelo com o menor erro quadrático médio para cada uma das ações, ou seja, o modelo escolhido pelo MCS é o M7, conforme demonstrado no Quadro 17.

Quadro 21 – Melhores Modelos - Erros Quadráticos Médios

MODELO	PETR3	IBOV	IRBR
erro_rw	0.001413	7.223.921	0.001376
erro_m1	1.792.837	1.54E+08	1.956.038
erro_m2	2.055.936	1.54E+08	0.897587
erro_m3	0.000949	12922.48	0.004177
erro_m4	0.000966	12610.11	0.009269
erro_m5	0.001066	16500.13	0.003851
erro_m6	0.001092	9.649.479	0.002457
erro_m7	0.000317	4.578.616	0.002326

Fonte: Elaborada pela autora

Nos gráficos, em linha vermelha o movimento que o modelo 7 projetou, e em linha azul o movimento que realmente ocorreu com essas ações no período estudado, confirmando que o nosso modelo preditivo tem aderência relevante.

Gráfico 01 – Projeção de Preços PETR3 versus Modelo 7

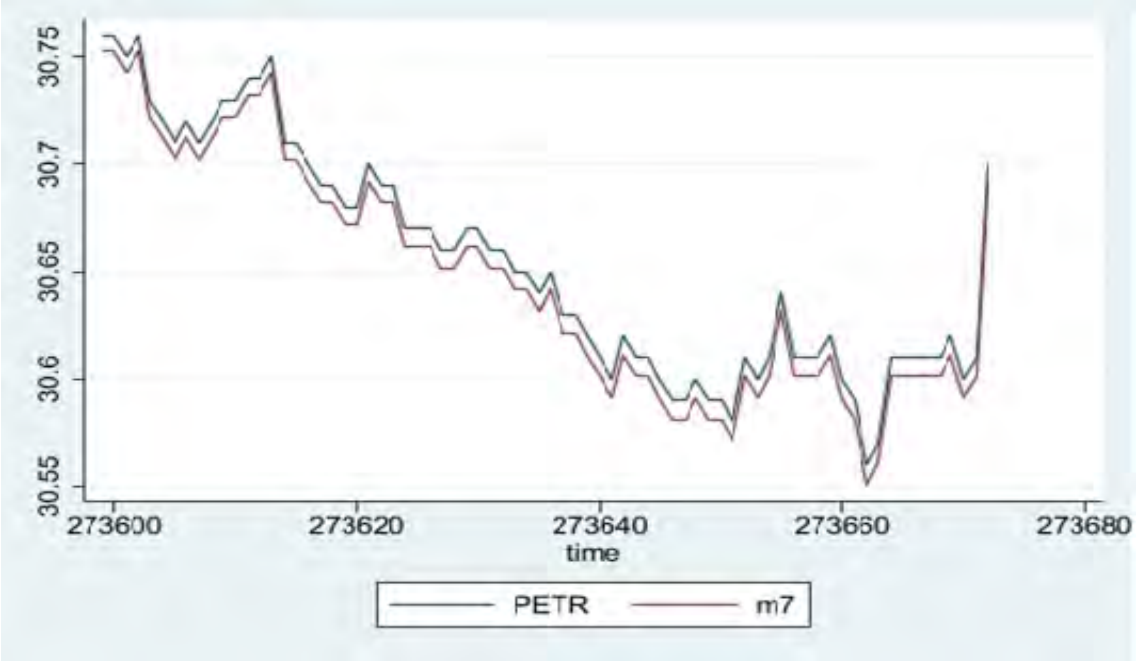


Gráfico 02 – Projeção de Preços IBOV3 versus Modelo 7

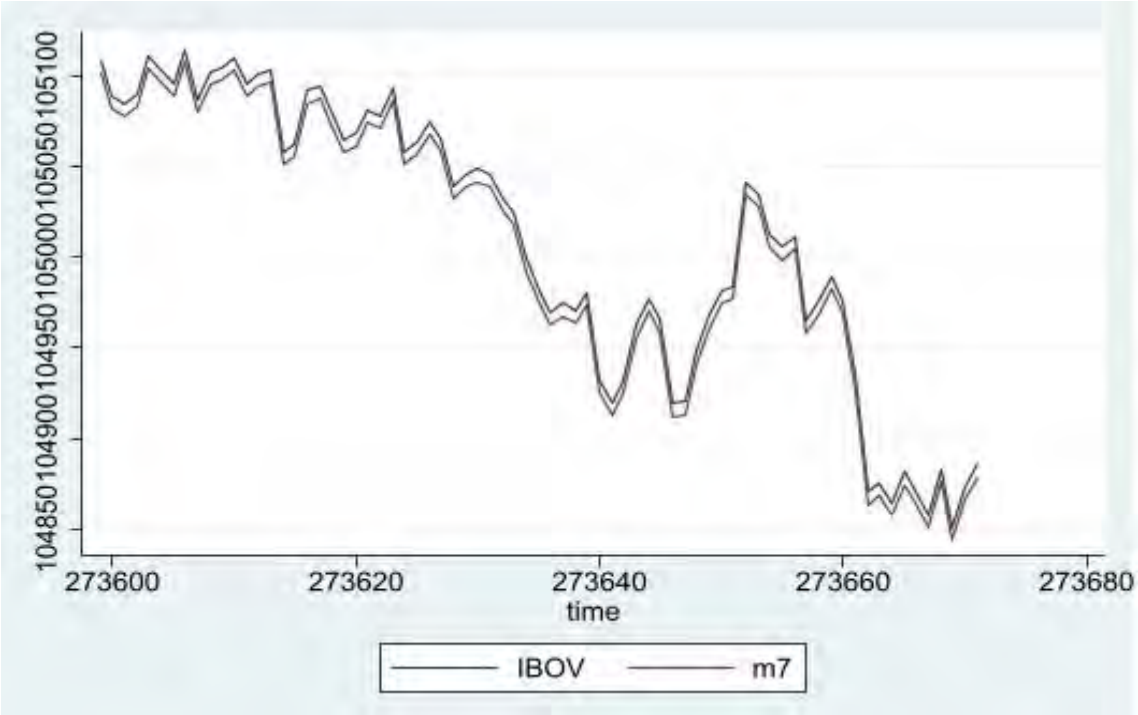
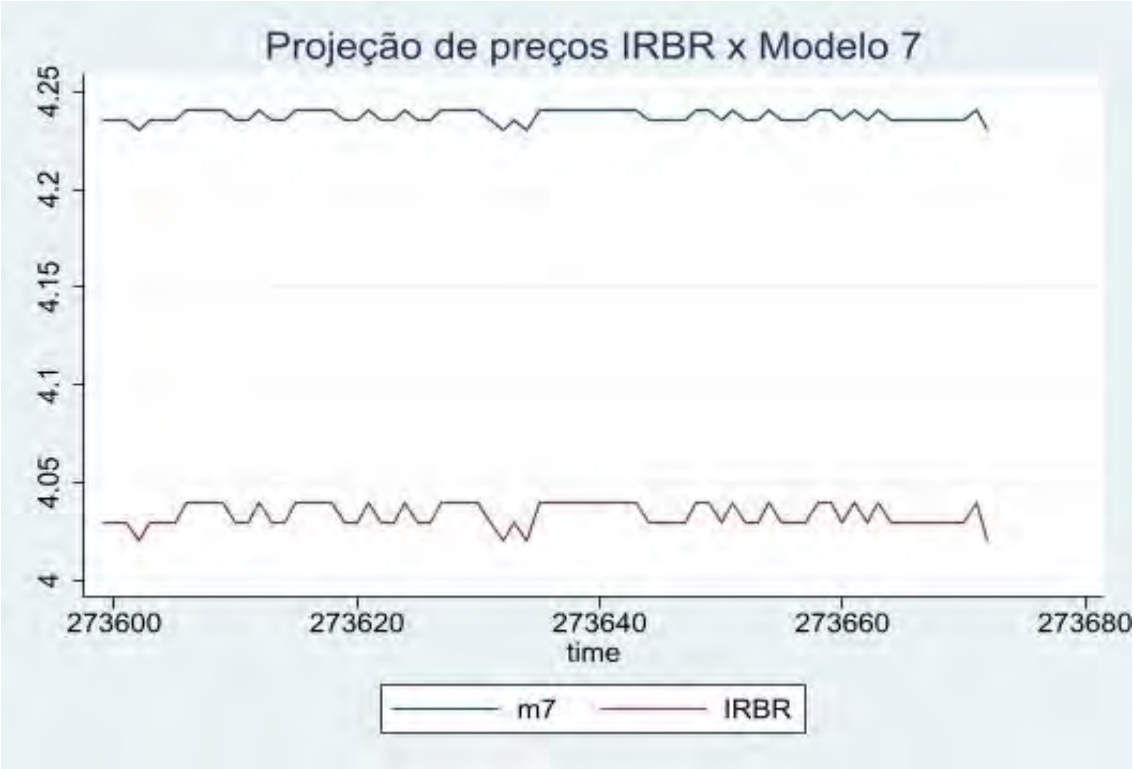


Gráfico 03 – Projeção de Preços IRBR versus Modelo 07



5.6 Conclusão

O propósito deste trabalho é o de verificar a projeção de preço de ações com RNA LSTM na arquitetura definida e dados coletados minuto a minuto durante 32 meses, alcança aderência relevante.

A partir do movimento das ações PETR3, IBOV e IRBR nesse período, o MCS apontou o M7 como o melhor modelo, ou seja, o de menor erro quadrático médio. Nos três casos, a aderência entre o projetado pela rede e o realmente observado, foi relevante.

Possibilidades de estudos futuros, envolvem a utilização de outras arquiteturas de redes, tais como as classes *deep learning,* e o exercício com outras ações.

6. CONCLUSÃO

O objetivo desta tese de doutorado é o de investigar o poder preditivo de modelos de projeção de preços de ações com redes neurais *multi layer perceptron* e *long short term Memory,* em ativos negociados em bolsas de valores, e ensaios com ações movimentadas na B3.

Tanto no Ensaio 03, com ações de 30 empresas presentes na B3 e dados de fechamentos diários, quanto no Ensaio 04, realizado com as ações PETR3, IBOV e IRBR e dados intradiários, confirmaram que a aderência entre os preços projetados pela rede e o realmente ocorrido, são relevantes.

Possibilidades de estudos futuros, envolvem a utilização de outras arquiteturas de redes, tais como as classes *deep learning.*

REFERÊNCIAS

AbdelKawy, R., Abdelmoez, W. M., & Shoukry, A. (2021). The synchronous deep reinforcement learning model for automated multi-stock trading. *Progress in Artificial Intelligence, 10:* 83–97. https://doi.org/10.1007/s13748-020-00225-z

Affonso, F., Dias, T. M. R., & Pinto, A. L. (2021). Financial Times Series Forecasting of Clustered Stocks. *Mobile Networks & Applications, 26*:256–265. https://doi.org/10.1007/s11036-020-01647-8

Al-Shboul, M., & Alsharari, N. (2019). The dynamic behavior of evolving efficiency: Evidence from the UAE stock markets. *The Quarterly Review of Economics and Finance, 73,* 119–135. DOI: 10.1016/j.qref.2018.05.007

Althelaya, K. A., Mohammed, S. A., & El-Alfy, E. M. (2021). Combining Deep Learning and Multiresolution Analysis for Stock Market Forecasting. *IEEE Access,* DOI 10.1109/ACCESS.2021.3051872

Araújo, R.A., & Ferreira. T.A.E (2013). A Morphological-Rank-Linear evolutionary method for stock market prediction. *Information Sciences, 237,* 3–17. DOI: 10.1016/j.ins.2009.07.007

Baek, Y, & Kim, H. Y. (2018). ModAugNet: A new forecasting framework for stock market index value with an overfitting prevention LSTM module and a prediction LSTM module. *Expert Systems with Applications, 113,* 457-460. https://doi.org/10.1016/j.eswa.2018.07.019.

Belciug, S. & Sandita, A. (2017). Business Intelligence: Statistics in predicting stock Market. A*nnals of the University of Craiova, Mathematics and Computer Science Series, 44(2*), 292-298. ISSN: 1223-6934

Bildirici, M. & Ersin, O. (2014). Modeling Markov Switching ARMA-GARCH Neural Networks Models and an Application to Forecasting Stock Returns. *Hindawi Publishing Corporation - The Scientific World Journal, 2014*, Article ID 497941. DOI: 10.1155/2014/497941

Bollersley, T. (1986). Generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics,* 31. 307–327. DOI:10.1016/0304-4076(86)90063-1. Corpus ID: 8797625.

Booth, A. D. (1967). A "law" of occurrences for low-frequency words. *Information and Control, 10* (4), 386-393. https://doi.org/10.1016/S0019-9958(67)90201-X

Borovkova, S., Tsiamas, I. (2019). An ensemble of LSTM neural networks for high- frequency stock market classification. *Journal of Forecasting,* volume 38, issue 6, pages 600 – 619. DOI: 10.1002/for.2585

Box, G. E., Pierce, D. A. (1970). Distribution of residual autocorrelations in autoregressive-integrated moving average time series models. *Journal Am. Stat. Assoc*. 65 1509–1526.

Box, G.E.P., Jenkins, G.M., & Reinsel G.C. (1994). Time Series Analysis: Forecasting and

Control. *Prentice Hall*, *Third Ed.*

Bradford, S.C. (1934). Sources of information on scientific subjects. *Engineering: An Illustrated Weekly Journal*, *137*, 85-86. DOI: 10.1177/016555158501000407

Brookes, B. C. (1969). Bradford's Law and the Bibliography of Science. *Nature*, *222*, 953-956. https://doi.org/10.1038/227631a0.

Bucci, A. (2020). Accomplished Volatility Forecasting with Neural Networks. *Journal of Financial Econometrics, vol. 18*, number 3, 502–531. DOI: 10.1093/ jjfinec /nbaa008

Bucci, A. (2020). Cholesky -ANN models for predicting multivariate realized volatility . *Journal of Forecasting* . DOI: 10.1002/for.2664.

Budiharto, W. (2021). Data science approach to stock prices forecasting in Indonesia during Covid-19 using Long Short - Term Memory (LSTM). *Journal of Big Data, 8-47*. https://doi.org/10.1186/s40537-021-00430-0.

Bukhari, A. H., Raja, M. A. Z., Sulaiman, M., Islam, S., Shoaib, M., & Kumam, P. (2020). Fractional Neuro- Sequential ARFIMA- LSTM for Financial Market Forecasting. *IEEE Access.* DOI 10.1109/ACCESS.2020.2985763.

Carosia, A. E. D, Coelho, G. P., & da Silva, A. E. A. (2021). investment strategies applied to the Brazilian stock market : A methodology based on Sentiment Analysis with deep learning . *Expert Systems with Applications, 184,* 115470. https://doi.org/10.1016/j.eswa.2021.115470

Chacon, H. D., Kesici, E., & Najafirad, P. (2020). Improving Financial Time Series Prediction Accuracy Using Ensemble Empirical Mode Decomposition and Recurrent Neural Networks. *IEEE Access.* DOI 10.1109/ACCESS.2020.2996981.

Chandar, S.K. (2021). Grey Wolf optimization-Elman neural network model for stock price prediction. *Soft Computing, 25*, 649–658. DOI: 10.1007/s00500-020-05174-2

Chang, V. C., Man, X. W., Xu, Q. W., & Hsu, C. H. (2021). Pairs trading on different portfolios based on machine learning. *Expert Systems*. DOI: 10.1111/exsy.12649.

Chen, Q., Zhang, W. Y, & Lou, Y. (2020). Forecasting Stock Prices Using a Hybrid Deep Learning Model Integrating Attention Mechanism , Multi-Layer Perceptron , and Bidirectional Long -Short Term Memory Neural Network. *IEEE Access*. DOI 10.1109/ACCESS.2020.3004284

Chen, S., & Ge, L. (2019). exploring the attention mechanism in LSTM-based Hong Kong stock price movement prediction. *Quantitative Finance*, 19:9, 1507-1515. DOI 10.1080/14697688.2019.1622287.

Chen, Y. C. & Huang, W. C. (2021). Building a stock- price forecast CNN model with gold and crude oil indicators. *Applied Soft Computing,* 112, 107760. https://doi.org/10.1016/j.asoc.2021.107760.

Chen, Y., Fang, R. X., Liang, T., Sha, Z. Y., Li, S. C., Yi, Y. G., Zhou, W. & Song, H. L. (2021). Stock Price Forecast Based on CNN – BiLSTM - ECA Model. *Scientific Programming.* https://doi.org/10.1155/2021/2446543.

Chen,Q., Zhang, W. & Lou Y. (2020). Forecasting Stock Prices Using a Hybrid Deep Learning Model Integrating Attention Mechanism, Multi-Layer Perceptron, and Bidirectional Long-Short Term Memory Neural Network. *IEEE Access, 8,* 117365-117376. DOI 10.1109/ACCESS.2020.3004284

Chung, K. H., & Cox, R. A. K. (1990). Productivity patterns in the finance literature: a study of bibliometric distributions. *Journal of Finance,* 45 (1), 301-309. https://doi.org/10.1111/j.1540-6261.1990.tb05095.x

Crouch, R.L. (1970). The Volume of Transactions and Price Changes on the New York Stock Exchange. *Financial Analysts Journal,* 26, 104-109.

Dami, S. & Esterabi, M. (2021). Predicting stock returns of Tehran exchange using LSTM neural network and feature engineering technique . *Multimedia Tools and Applications, 80*: 19947–19970. https://doi.org/10.1007/s11042-021-10778-3

Demirel, U., Cam, H. & Unlu R. (2021). Predicting Stock Prices Using Machine Learning Methods and Deep Learning Algorithms: The Sample of the Istanbul Stock Exchange. *Gazi University Journal of Science, 34(1),* 63-82. DOI: 10.35378/gujs.679103

Dey, P., Hossain, E., Hossain, M. I., Chowdhury, M. A., Alam, M. S., Hossain, M. S., & Andersson, K. (2021). Comparative Analysis of Recurrent Neural Networks in Stock Price Prediction for Different Frequency Domains. *Algorithms, 14*, 251. https://doi.org/10.3390/a14080251

Ding, G. Y., & Qin, L. X. (2020). Study on the prediction of stock price based on the associated network model of LSTM. *International Journal of Machine Learning and Cybernetics, 11:* 1307–1317. https://doi.org/10.1007/s13042-019-01041-1

Dong, S. T., Wang, J. X., Luo, H. Z., Wang, H. D., & Wu, F. X. (2021). The dynamic predictor selection algorithm for predicting stock market movement. *Expert Systems with Applications, 186,* 115836. https://doi.org/10.1016/j.eswa.2021.115836

Eiamkanitchat, N., Moontuy, T. & Ramingwong, S. (2017). Fundamental analysis and technical analysis integrated system for stock filtration. *Cluster Comput, 20*, 883–894. DOI: 10.1007/s10586-016-0694-2

Engle, R. F. (1982). Autoregressive conditional heteroscedasticity with estimates of the variance of United Kingdom inflation. *Journal Econometrics. Soc*. 987–1007.

Gao, T., Chai, Y. (2018). Improving Stock Closing Price Prediction Using Recurrent Neural Network and Technical Indicators. *Neural Computation,* 30(10):2833-2854. DOI

10.1162/neco_a_01124.

Gao, Y., Wang, R, & Zhou, E. M. (2021). Stock Prediction Based on Optimized LSTM and GRU Models. *Scientific Programming,* volume 2021, Article ID 4055281. https://doi.org/10.1155/2021/4055281

Garcia-Vega, S., Zeng, X. J., & Keane, J. (2020). stock returns prediction using adaptive kernel filtering within a stock market interdependence approach. *Expert Systems with Applications 160*, 113668. https://doi.org/10.1016/j.eswa.2020.113668 0957-4174/20

Gite, S., Khatavkar, H., Kotecha, K., Srivastava, S., Maheshwari, P., & Pandey, N. (2021). *PEERJ Computer Science, vol. 07*. DOI: http://dx-doi.ez347.10.7717/peerj-cs.340

Goffman, W. (1971). A mathematical method for analyzing the growth of a scientific discipline. *Journal of the Association for Computing Machinery, 18(2),* 173-185. DOI: 10.1145/321637.321640

Greff, K., Srivastava R. K., Koutnik J., Steunebrink B.R., Schmidhuber, J. (2016). LSTM: A Search Space Odyssey. *IEEE Transactions on Neural Networks and Learning Systems*, 28, 2222–2232.

Gu, W. T., Zhang, L. H., Xi, H. J., Zheng, S. H. (2021). Stock Prediction Based on News Text Analysis . *Journal of Advanced Computational Intelligence and Intelligent Informatics* . https://doi.org/10.20965/jaciii.2021.p0581

Gunduz, H. (2021). An efficient stock market prediction model using hybrid feature reduction method based on variational autoencoders and recursive feature elimination. *Financial Innovation,* 7-28. https://doi.org/10.1186/s40854-021-00243-3

Hamed, I.M., Hussein, A.S., Tolba, M.F. (2012). An Intelligent Model for Stock Market Prediction. *International Journal of Computational Intelligence Systems, 5 – 4,* 639-652. Atlantis Press. DOI: 10.1080/18756891.2012.718108

Han, J. J & Kim, H. J. (2021). Prediction of Investor- Specific Trading Trends in South Korean Stock Markets Using BiLSTM Prediction Model Based on Sentiment Analysis of Financial News Articles. *Journal of Behavioral Finance*. DOI: 10.1080/15427560.2021.1995735

Hansen, P.R., Lunde, A., Nason, J. M. (2011). The model confidence set. *Econometrica,* v. 79, n. 2, p. 453-497

Hansun, S., & Young, J. C. (2021). Predicting LQ45 financial sector indices using RNN-LSTM. *Journal of Big Data.* http://dx-doi.ez347/10.1186/s40537-021-00495-x

He, B. T, & Kita, E. (2021). The Application of Sequential Generative Adversarial Networks for Stock Price Prediction. *Review of Socionetwork Strategies, 15*:455–470. https://doi.org/10.1007/s12626-021-00097-2

Hochreiter, S., Schmidhuber, J. (1997). Long Short-Term Memory. *Neural Computation*, 9 (8): 1735–1780. https://doi.org/10.1162/neco.1997.9.8.1735

Huang, X.., & Song, H. L. (2021). Investor Sentiment Combined with Multisource Information to Predict Stock Prices : An Analysis of China's A-Share Market . *Scientific Programming* https://doi.org/10.1155/2021/9094032

Huang, Y. S., Gao, Y. L, Gan, Y., & Ye, M. (2021). A new financial data forecasting model using genetics algorithm and long short term memory network. *Neurocomputing, 425*, 207-218. https://doi.org/10.1016/j.neucom.2020.04.086

Hull, J., White, A. (1987). The pricing of options on assets with stochastic volatilities. J. Finance 42, 281–300.

Ji, Y., Liew, A. W. C, & Yang, L. X. (2021). The Novel Improved particle swarm Optimization With Long -Short Term memory Hybrid Model for Stock Indices Forecast. *IEEE Access.* DOI 10.1109/ACCESS.2021.3056713

Jin, Z. G., Yang, Y, & Liu, Y. H. (2020). stock closing price prediction based on sentiment analysis and LSTM. *Neural Computing & Applications 32* :9713-9729. https://doi.org/10.1007/s00521-019-04504-2

Jing, N., Wu, Z, & Wang, H. F. (2021). A hybrid model integrating deep learning with investor feeling analysis for stock price prediction. *Expert Systems with Applications 178, 115019* . https://doi.org/10.1016/j.eswa.2021.115019

JuHyok, U., Lu, P., Kim, C., Ryu, U., & Pak, K. (2020). A new LSTM based reversal point prediction method using upward/downward reversal point feature sets. *Chaos, Solitons and Fractals, 132* – 109559. DOI: 10.1016/j.chaos.2019.109559

Karathanasopoulos, A. (2016). Modelling and trading the English stock Market with new forecasting techiniques. *Economics and Business Letters, 5 (2),* 50-57. DOI: 10.17811/ebl.5.2.2016.50-57

Kelotra, A. & Pandey, P. (2020). Stock Market Prediction Using Optimized Deep-ConvLSTM Model. *Big Data, vol 8, number 1* . DOI: 10.1089/big.2018.0143

Khalil, F., & Pipa, G. (2021). Is Deep -Learning and Natural Language Processing Transcending the Financial Forecasting? Investigation Through Lens of News Analytic Process. *Computational Economics*. https://doi.org/10.1007/s10614-021-10145-2

Kilimci, Z. H., & Duvar, R. (2020). An Efficient Word Embedding and Deep Learning Based Model to Forecast the Direction of Stock Exchange Market Using Twitter and Financial News Sites: A Case of Istanbul Stock Exchange (BIST 100). *IEEE Access*. DOI 10.1109/access.2020.3029860

Kim, H. Y. & Won, C. H. (2018). Forecasting the volatility of stock price index: A hybrid model integrating LSTM with multiple GARCH- type models. *Expert Systems with Applications 103*, 25-37. https://doi.org/10.1016/j.eswa.2018.03.002 0957-41

Kim, S., Ku, S., Chang, W., & Song, J. W. (2020). predicting the Direction of US Stock Prices Using Effective Transfer Entropy and Machine Learning Techniques. *IEEE Access*. DOI 10.1109/ACCESS.2020.3002174

Ko, C. R, & Chang, H. T. (2021). LSTM-based sentiment analysis for stock price forecast. *PEERJ Computer Science, vol. 7*. DOI: http://dx-doi.ez347.10.7717/peerj-cs.408

Kudugunta, S., & Ferrara, E. (2018). Deep neural networks for bot detection. *Information Sciences, 467*, 312-322. h ttps://doi.org/10.1016/j.ins.2018.08.019

Kumar, A., Alsadoon, A., Prasad, P. W. C, Abdullah, S., Rashid, T. A., Pham, D. T. H. & Nguyen, T. Q. V. (2022). Generative adversarial network (GAN) and enhanced root mean square error (ERMSE): deep learning for stock price movement prediction. *Multimedia Tools and Applications 81*:3995–4013. https://doi.org/10.1007/s11042-021-11670-w

Kumar, K., & Haider, M. T. U. (2021). Enhanced Prediction of Intra-day Stock Market Using Metaheuristic Optimization on RNN-LSTM Network. *New Generation Computing 39*:231–272. https://doi.org/10.1007/s00354-020-00104-0

Kumar, R., Kumar, P., & Kumar, Y. (2021). Integrating big data driven sentiments polarity and ABC-optimized LSTM for time series forecasting. *Multimedia Tools and Applications.* https://doi.org/10.1007/s11042-021-11029-1

Lee, M. C., Chang, J. W., Hung, J. S. C., & Chen, B. L. (2021). Exploring the Effectiveness of Deep Neural Networks with Technical Analysis Applied to Stock Market Prediction. *Computer Science and Information Systems 18*(2):401–418. https://doi.org/10.2298/CSIS200301002

Li, M. G., Li, W. R., Wang, F., Jia, X. J., & Rui, G. W. (2021). Applying BERT to analyze investor sentiment in stock market. *Neural Computing and Applications 33*:4663–4676 https://doi.org/10.1007/s00521-020-05411

Li, Q., Tan, J. H., Wang, J, & Chen, H. (2021). A Multimodal Event-Driven LSTM Model for Stock Prediction Using Online News. *IEEE Transactions on Knowledge and Data Engineering vol. 33, no. 10.* DOI 10.1109/TKDE.2020.2968894.

Li, Y. L, Bu, H., Li, J. H., & Wu, J. J. (2020). The Role of Text-extracted Investor Sentiment in Chinese Stock Price Prediction with the Enhancement of Deep Learning. *International Journal of Forecasting 36* 1541–1562. https://doi.org/10.1016/j.ijforecast.2020.05.001.

Li, Z. X., & Tam, V. (2018). A Machine Learning View on Momentum and Reversal Trading. *Algorithms 1,* 170; doi:10.3390/a11110170

Lin, Y., Yan, Y., Xu, J. L, Liao, Y., & Ma, F. (2021). Forecasting Stock Index Price Using the CEEMDAN-LSTM Model. *North American Journal of Economics and Finance 57*, 101421. https://doi.org/10.1016/j.najef.2021.101421.

Liu, X., Liu, H., Guo, Q, & Zhang, C. M. (2020). Adaptive Wavelet Transform Model for Time Series Data Prediction. *Soft Computing* 24:5877–5884. https://doi.org/10.1007/s00500-019-04400-w

Liu, Y. Z.., Yu, X. L., Wu, Y. H., & Song, S. H. (2021). Forecasting Variation Trends of Stocks via Multiscale Feature Fusion and Long Short-Term Memory Learning. *Scientific Programming, Article ID 5113151*. https://doi.org/10.1155/2021/5113151.

Liu, Y., Yang, C., Huang, K., Gui, W. (2020). Non-ferrous Metals Price Forecasting Based on Variational Mode Decomposition and LSTM Network. *Knowledge-Based Systems,* vol. 188, 105006. Https://doi.org/10.1016/j.knosys.2019.105006.

Long, W., Lu, Z. C., & Cui, L. X. (2019). Deep learning-based feature engineering for stock price movement prediction. *Knowledge-Based Systems, 163–173.* https://doi.org/10.1016/j.knosys.2018.10.034.

Lotka, A. J. (1926). The frequency distribution of scientific productivity. *Journal of the Washington Academy of Sciences, 16* (12), 317-323.

Lu, W.J., Li, J.Z., Li, Y.F., Sun, A.J. & Wang, J.Y. (2020). A CNN-LSTM-Based Model to Forecast Stock Prices. *Complexity, 2020,* 6622927. DOI: 10.1155/2020/6622927

Lunga, D. & Marwala, T. (2006). Online forecasting of stock market movement direction using the improved incremental algorithm. *Neural Information Processing, PT3, Proceedings, Lecture - Notes in Computer Science, 4234,* 440-449

Ma, C., Zhang, J. S.., Liu, J. M., Ji, L. Z., & Gao, F. (2021). A parallel multi-module deep reinforcement learning algorithm for stock trading. *Neurocomputing, 449,* 290-302. https://doi.org/10.1016/j.neucom.2021.04.005.

Ma, Y. L, Han, R. Z, & Wang, W. Z. (2021). Portfolio optimization with return prediction using deep learning and machine learning. *Expert Systems with Applications 165,* 113973. https://doi.org/10.1016/j.eswa.2020.113973.

Ma, Y. L., Han, R. Z., & Wang, W. Z. (2020). Prediction-Based Portfolio Optimization Models Using Deep Neural Networks. *IEEEAccess.* DOI 10.1109/ACCESS.2020.3003819.

Maia, A.L.S. & de Carvalho, F.D.T. (2011). Holt's exponential smoothing and neural network models for forecasting interval-valued time series. *International Journal of Forecasting, 27(3),* 740-759. DOI: 10.1016/j.ijforecast.2010.02.012

Makinen, Y., Kanniainen, J., Gabbouj, M., & Iosifidis, A. (2019). Forecasting jump arrivals in

stock prices: new attention-based network architecture using limit order book data. *Quantitative Finance, 19:12*, 2033-2050, DOI: 10.1080/14697688.2019.1634277.

Maknickienė, N., & Maknickas, A. (2012). Application of Neural Network for Forecasting of Exxchange Rates and Forex Trading. *Computer Science.* Corpus ID 18943808, DOI 103846/BM.2012.017

Malkiel, B.G. (1973). A Random Walk Down Wall Street. *W. W. Norton & Company.* DOI:10.4324/9781912281169

McNelis, P. D. (2005). Neural Networks in Finance: Gaining the predictive edge in the market. *Elsevier Academic Press* 1. ISBN-10: 0124859674, ISBN-13: 978-0124859678

Mehta, P., Pandya, S., & Kotecha, K. (2021). Harvesting social media sentiment analysis to enhance stock market prediction using deep learning. *PeerJ Computer Science, vol 07*. DOI: http://dx-doi.ez347.periodicos.capes.gov.br/10.7717/peerj-cs.476.

Michalak, K. & Lipinski, P. (2005). Prediction of high increases in stock prices using neural networks. *Neural network world, 15(4),* 359-366.

Mostafa, M.M. (2010). Forecasting stock exchange movements using neural networks: Empirical evidence from Kuwait. *Expert Systems with Applications, 37(9),* 6302-6309. DOI: 10.1016/j.eswa.2010.02.091

Nabipour, M., Nayyeri, P, Jabani, H., Shahab, S., & Mosavi, A. (2020). Predicting Stock Market Trends Using Machine Learning and Deep Learning Algorithms Via Continuous and Binary Data; a Comparative Analysis. *IEEE Access*. DOI 10.1109/ACCESS.2020.3015966.

Nayak, S.C. (2019). Escalation of Forecasting Accuracy through Linear Combiners of Predictive Models. *EAI Endorsed Transactions on Scalable Information Systems, 6(22),* 2. DOI: 10.4108/eai.10-6-2019.159345

Nayak, S.C., Misra, B.B. & Behera, H.S. (2016). An Adaptive Second Order Neural Network with Genetic-Algorithm-based Training (ASONN-GA) to Forecast the Closing Prices of the Stock Market. *International Journal of Applied Metaheuristic computing, 7(2),* 39-57. DOI: 10.4018/IJAMC.2016040103

Nayak, S.C., Misra, B.B. & Behera, H.S. (2017). Artificial chemical reaction optimization of neural networks for efficient prediction of stock market índices. *Ain Shams Engineering Journal, 8(3),* 371-390. DOI: 10.1016/j.asej.2015.07.015

Nayak, S.C., Misra, B.B. & Behera, H.S. (2018). Artificial chemical reaction optimization based neural net for virtual data position exploration for efficient financial time series forecasting. *Ain Shams Engineering Journal, 9(4)*, 1731-1744. DOI: 10.1016/j.asej.2016.10.009

Nguyen, H. T., Tran, T. B., & Bui, P. H. D. (2021). An effective way for Taiwanese stock price

prediction: Boosting the performance with machine learning techniques. *Concurrency and Computation-Practice & Experience*. DOI: 10.1002/cpe.6437

Nobre, R. A., do Nascimento, KC, Vargas, PA, Valejo, ADB, Pessin, G, Villas, LA, Rocha, GP. (2022). Aurora: an autonomous agent-oriented hybrid trading service. *Neural Computing & Applications, 34:*2217–2232. https://doi.org/10.1007/s00521-021-06508-3

Nti, I. K., Adekoya, A. F., & Weyori, B. A. (2021). A novel multi-source information-fusion predictive framework based on deep neural networks for accuracy enhancement in stock market prediction. *Journal of Big Data, 8*-17. https://doi.org/10.1186/s40537-020-00400

Paluch, M., Jackowska-Strumillo, L. (2018). Hybrid Models Combining Technical and Fractal Analysis with ANN for Short-Term Prediction of Close Values on the Warsaw Stock Exchange. *Applied Sciences*, vol 8, issue 12. Https://doi.org/10.3390/ app8122473.

Pang, X. W., Zhou, Y. Q., Wang, P., Lin, W. W., & Chang, V. (2020). An innovative neural network approach for stock market prediction. *Journal of Supercomputing 76*:2098–2118. https://doi.org/10.1007/s11227-017-2228-y

Pao, M.L. (1978). Automatic text analysis based on transition phenomena of word occurrences. *Journal of the American Society for Information Science, 29(3),* 121-124, DOI: 10.1002/asi.4630290303

Pardoe, I. (2006). Applied Regression Modeling: A Business Approach. *John Wiley e Sons*. ISBN 978-0-470-05265-5

Park, D., & Ryu, D. (2021). A Machine Learning-Based Early Warning System for the Housing and Stock Markets. *IEEE Access*. DOI 10.1109/ACCESS.2021.3077962.

Park, H. J., Kim, Y., & Kim, H. Y. (2022). Stock market forecasting using a multi-task approach integrating long short-term memory and the random forest framework. *Applied Soft Computing, 114*. https://doi.org/10.1016/j.asoc.2021.108106.

Prachyachuwong, K., & Vateekul, P. (2021). Stock Trend Prediction Using Deep Learning Approach on Technical Indicator and Industrial Specific Information. *Information, 12*, 250. https://doi.org/10.3390/info12060250.

Qiu, Y., Yang, H. Y., Lu, S., & Chen, W. (2020). A novel hybrid model based on recurrent neural networks for stock market timing. *Soft Computing, 24:* 15273–15290 https://doi.org/10.1007/s00500-020-04862-3.

Ray, P., Ganguli, B., & Chakrabarti, A. (2021). A Hybrid Approach of Bayesian Structural Time Series with LSTM to Identify the Influence of News Sentiment on Short-Term Forecasting of Stock Price. *IEEE Transactions on Computational Social Systems, vol 08*, number 05.

Rezaei, H., Faaljou, H., & Mansourfar, G. (2021). Intelligent Asset Allocation using Predictions

of Deep Frequency Decomposition. *Expert Systems with Applications.* https://doi.org/10.1016/j.eswa.2021.115715.

Riedmiller, M. (1994). Advanced supervised learning in multi-layer perceptrons — From backpropagation to adaptive learning algorithms. *Computer Standards & Interfaces, 16(3),* 265-278. DOI: 10.1016/0920-5489(94)90017-5

Serrano, W. (2022). The random neural network in price predictions. *Neural Computing & Applications, 34*:855–873 https://doi.org/10.1007/s00521-021-05903-0.

Sharaf, M., Hemdan, E. E., El-Sayed, A., & El-Bahnasawy, N. A. (2021). StockPred: a framework for stock Price prediction. *Multimedia Tools and Applications 80*:17923–17954. https://doi.org/10.1007/s11042-021-10579-8.

Sharma, S., Elvira, V., Chouzenoux, E., & Majumdar, A. (2021). Recurrent application in stock forecasting. *Neurocomputing, 450, 1-13*. https://doi.org/10.1016/j.neucom.2021.03.111.

Shu, W. W., & Gao, Q. (2020). Forecasting Stock Price Based on Frequency Components by EMD and Neural Networks. *IEEE Access*, DOI 10.1109/ACCESS.2020.3037681.

Silva, C.G. da (2008). Time series forecasting with a non-linear model and the scatter search meta-heuristic. *Information Sciences 178*(16), 3288–3299. https://doi:10.1016/j.ins.2008.03.024

Sohangir, S., Wang, D. D., Pomeranets, A.., & Khoshgoftaar, T. M. (2018). Big Data: Deep Learning for financial sentiment analysis. *Journal of Big Data, 5*:3 https://doi.org/10.1186/s40537-017-0111-6

Song, D., Busogi, M., Baek, A. M. C., & Kim, N. (2020). Forecasting Stock Market Index Based on Pattern-Driven Long Short-Term Memory. *Economic Computation and Economic Cybernetics Studies and Research, Issue 3*. DOI: 10.24818/18423264/54.3.20.02.

Song, T. & Yan, X. S. (2021). Dynamic adjustment of stock position based on hybrid deep neural network. *Journal of Ambient Intelligence and Humanized Computing, 12*:10073–10089 https://doi.org/10.1007/s12652-020-02768-4.

Su, Z., Xie, H. L., & Han, L. (2021). Multi-Factor RFG-LSTM Algorithm for Stock Sequence Predicting. *Computational Economics, 57:*1041–1058. https://doi.org/10.1007/s10614-020-10008-2.

Swicegood, P. & Clark, J.A. (2001). Off-site monitoring systems for prediction bank underperformance: A comparison of neural networks, discriminant analysis, and professional human judgment. *Intelligent Systems in Accounting Finance & Management, 10(3),* 169-186. DOI:10.1002/isaf.201

Thakkar, A., & Chaudhari, K. (2020). Predicting stock trend using an integrated term frequency-inverse document frequency-based feature weight matrix with neural networks. *Applied Soft*

Computing Journal, 96, 106684. https://doi.org/10.1016/j.asoc.2020.106684.

Touzani, Y., & Douzi, K. (2021). An LSTM and GRU based trading strategy adapted to the Moroccan market. *Journal of Big Data 8*:126 https://doi.org/10.1186/s40537-021-00512-z

Troiano, L., Villa, E. M., & Loia, V. (2018). Replicating a Trading Strategy by Means of LSTM for Financial Industry Applications. *IEEE Transactions on Industrial Informatics, vol 14, no. 07.* DOI 10.1109/TII.2018.2811377.

Tufekci, P. (2016). Classification-based prediction models for stock price index movement. *Intelligent Data Analysis, 20(2)*, 357-376. DOI: 10.3233/IDA-160809

Vochozka, M., Horak, J. & Krulicky, T. (2020). Innovations in Management Forecast: Time Development of Stock Prices with Neural Networks. *Marketing and Management of Innovations, 2*, 324-339

Wang, J. J, Feng, C. C, He, J. J, Feng, L., & Li, Y. (2020). A Novel Multi-Factor Stock Indewx Prediction Approach using Principal Component Analysis, Feature Classification and Two-Stage Long Short-Term Memory Network with Residual Correction. *Economic Computation and Economic Cybernetics Studies and Research, Issue 3.* DOI: 10.24818/18423264/54.3.20.06.

Wang, J. J, He, J. J, Feng, C. C, Feng, L., & Li, Y. (2021). Stock index prediction and uncertainty analysis using multi-scale nonlinear ensemble paradigm of optimal feature extraction, two-stage deep learning and Gaussian process regression. *Applied Soft Computing 113* 107898. https://doi.org/10.1016/j.asoc.2021.107898.

Wang, W. J, Tang, Y., Xiong, J, & Zhang, Y. .C. (2021). Stock market index prediction based on reservoir computing models. *Expert Systems with Applications 178 115022.* https://doi.org/10.1016/j.eswa.2021.115022.

Wu, D. M, Wang, X. L, & Wu, S. C. (2022). Jointly modeling transfer learning of industrial chain information and deep learning for stock prediction. *Expert Systems with Applications, 191,* 116257. https://doi.org/10.1016/j.eswa.2021.116257.

Wu, J. .M T., Sun, L. Y., Srivastava, G., & Lin, J. C. W. (2021). A Long Short-Term Memory Network Stock Price Prediction with Leading Indicators. *Big Data, volume 9, number 5.* DOI: 10.1089/big.2020.0391.

Wu, J. M. T., Li, Z. C., Herencsar, N., Vo, B., & Lin, J. C. W. (2021). A graph-based CNN-LSTM stock price prediction algorithm with leading indicators. *Multimedia Systems.* https://doi.org/10.1007/s00530-021-00758-w.

Wu, J. M. T., Sun, L. Y., Srivastava, G., & Lin, J. C. W. (2021). A Novel Synergetic LSTM-GA Stock Trading Suggestion System in Internet of Things. *Mobile Information Systems, volume 2021,* Article ID 6706345. https://doi.org/10.1155/2021/6706345.

Xing, F. Z., Cambria, E, & Welsch, RE. (2018). Intelligent Asset Allocation via Market Sentiment Views. *IEEE Computational Intelligence Magazine*. DOI 10.1109/MCI.2018.286672.

Yan, X., Wang, W. H., & Chang, M. (2021). Research on financial assets transaction prediction model based on LSTM neural network. *Neural Computing & Applications, 33*:257–270. https://doi.org/10.1007/s00521-020-04992-7.

Yang, S. G. (2021). A novel study on deep learning framework to predict and analyze the financial time series information. *Future Generation Computer Systems 125*, 812–819. https://doi.org/10.1016/j.future.2021.07.017.

Yang, Y. J., Yang, Y. M., Zhou, W. (2021). Research on a hybrid prediction model for stock price based on long short-term memory and variational mode decomposition. *Soft Computing, 25*:13513–13531. https://doi.org/10.1007/s00500-021-06122-4.

Yap, K. L., Lau, W. Y., & Ismail, I. (2021). Deep learning neural network for the prediction of Asian Tiger stock markets. *International Journal of Financial Engineering, vol. 8, no. 4*, 2150040. DOI: 10.1142/S2424786321500407.

Yeung, J. F. K. A., Wei, Z. K., Chan, K. Y, Lau, HYK, & Yiu, KFC (2020). Jump detection in financial time series using machine learning algorithms. *Soft Computing, 24:*1789–1801 https://doi.org/10.1007/s00500-019-04006-2.

Yildiz, Z. C. & Yildiz, S. B. (2020). The portfolio construction framework using LSTM -based stock markets forecasting. *International Journal of Finance & Economics*. DOI: 10.1002/ijfe.2277

Ying, C.C. (1966). Stock Market Prices and Volumes of Sales. *Econometrica, 34*, 676 - 686. DOI: 10.2307/1909776

Zeng, Y.., Liu, X. (2018). A-Stock Price Fluctuation Forecast Model Based on LSTM. 14th International Conference on Semantics, Knowledge and Grids (SKG). *IEEE Xplore.* DOI: 10.1109/SKG.2018.00044

Zhang, D. X., & Cai, E. G. (2021). Improving Stock Price Forecasting Using a Large Volume of News Headline Text. *Computers, Materials & Continua*. DOI:10.32604/cmc.2021.012302.

Zhang, W. G.., Gong, X., Wang, C., & Ye, X. (2021). Predicting stock market volatility based on textual sentiment: A nonlinear analysis. *Journal of Forecasting, 40*:1479–1500. DOI: 10.1002/for.2777.

Zhang, Y. A., Yan, B. B., & Aasma, M. (2020). A novel deep learning framework: prediction and analysis of financial time series using CEEMD and LSTM. *Expert Systems with Applications 159*, 113609. https://doi.org/10.1016/j.eswa.2020.113609.

Zhao, Y. Z. (2021). A Novel Stock Index Intelligent Prediction Algorithm Based on Attention-

Guided Deep Neural Network. *Wireless Communications and Mobile Computing*, volume 2021, Article ID 6210627. https://doi.org/10.1155/2021/6210627.

Zhao, Y., Shen, Y. Y.., & Huang, Y. (2019). DMDP: A Dynamic Multi-Source Default Probability Prediction Framework. *Data Science and Engineering,* 4:3–13, https://doi.org/10.1007/s41019-019-0085-9.

Zipf, G.K. (1949). Human behavior and the principle of least effort: an introduction to human ecology. *Cambridge, Mass: Addison-Wesley Press.*

Zolfaghari, M., Gholami, S. (2021). A hybrid approach of adaptive wavelet transform long short-term memory and ARIMA-GARCH family models for the stock index prediction. *Expert Systems with Applications* 182, 115149. https://doi.org/10.1016/j.eswa.2021.115149