UNIVERSIDADE PRESBITERIANA MACKENZIE

JOÃO VITOR DE MATTOS

PROJEÇÃO DE PREÇO PARA AÇÕES BRASILEIRAS UTILIZANDO-SE DADOS EM ALTA FREQUÊNCIA

São Paulo

2023

JOÃO VITOR DE MATTOS

PROJEÇÃO DE PREÇO PARA AÇÕES BRASILEIRAS UTILIZANDO-SE DADOS EM ALTA FREQUÊNCIA

Tese de Doutorado apresentada ao Programa de Pós-Graduação em Administração da Universidade Presbiteriana Mackenzie para a obtenção do título de Doutor em Finanças.

ORIENTADOR: Prof. Dr. Eli Hadad Junior.

São Paulo

2023

XXXf Mattos, João Vitor de.

Projeção de preço para ações brasileiras utilizando-se dados em alta frequência / João Vitor de Mattos.
70 f. : il. ; NN cm

Tese (Doutorado em Administração de Empresas) – Universidade Presbiteriana Mackenzie, São Paulo, 2023.
Orientador: Eli Hadad Junior
Referências bibliográficas: f. 65-70.

1. Projeção de dados. 2. Dados em alta frequência. 3. Modelagem econométrica. I. Hadad Junior, Eli, orientador.
II. Título.

CDD NNN.NNN

FOLHA DE IDENTIFICAÇÃO DA AGÊNCIA DE FINANCIAMENTO

Autor: João Vitor de Mattos

Programa de Pós-Graduação *Stricto Sensu* em Administração

Título do Trabalho: Projeção de preço para ações brasileiras utilizando-se dados em alta frequência

O presente trabalho foi realizado com o apoio de [1]:

☐ CAPES - Coordenação de Aperfeiçoamento de Pessoal de Nível Superior

☐ CNPq - Conselho Nacional de Desenvolvimento Científico e Tecnológico

☐ FAPESP - Fundação de Amparo à Pesquisa do Estado de São Paulo

☐ Instituto Presbiteriano Mackenzie/Isenção integral de Mensalidades e Taxas

☐ MACKPESQUISA - Fundo Mackenzie de Pesquisa

☒ Empresa/Indústria: Banco do Brasil S/A

☐ Outro:

[1] **Observação**: caso tenha usufruído mais de um apoio ou benefício, selecione-os.

JOÃO VITOR DE MATTOS

PROJEÇÃO DE PREÇO PARA AÇÕES BRASILEIRAS UTILIZANDO-SE DADOS EM ALTA FREQUÊNCIA

Tese de Doutorado apresentada ao Programa de Pós-Graduação em Administração da Universidade Presbiteriana Mackenzie para a obtenção do título de Doutor em Finanças.

Aprovado em 19/02/2024

BANCA EXAMINADORA

Prof. Dr. Eli Hadad Junior
Universidade Presbiteriana Mackenzie

Prof. Dr. Wilson Toshiro Nakamura
Universidade Presbiteriana Mackenzie

Prof. Dr. Leonardo Fernando Cruz Basso
Universidade Presbiteriana Mackenzie

Prof. Dr. Diogo de Prince Mendonça
Universidade Federal de São Paulo

Prof. Dr. Alexandre Ripamonti
Escola Superior de Propaganda e Marketing

Dedico este trabalho a minha família, por sempre me apoiar nessa jornada desafiadora.

AGRADECIMENTOS

Agradeço aos meus pais, Sonia Maria Biachi de Mattos e Cleber David de Mattos, por me mostrarem o valor dos estudos na jornada. À minha esposa, Erica de Fátima Rosa de Mattos, agradeço por sua paciência e empenho para viabilizar meu tempo.

À instituição Universidade Presbiteriana Mackenzie por toda estrutura fornecida ao curso, principalmente ao corpo docente do Programa de Pós-Graduação em Administração de Empresas. Todos os professores contribuíram muito para meu desenvolvimento ao longo do curso, apresentando grande disponibilidade com as questões apresentadas pelos alunos.

Também agradeço aos meus colegas de turma pelos conhecimentos e bons momentos compartilhados em nossos encontros. Espero poder continuar a encontrá-los dentro e fora do ambiente escolar.

Um agradecimento à parte ao Banco do Brasil S/A por conceder alguns benefícios aos funcionários que desejam aprimoramento acadêmico, principalmente pelo subsídio fornecido ao longo de dois anos para despesas com mensalidade e ao Dr. Fernando da Silva Vinhado, meu orientador da pesquisa dentro do BB, por aceitar o convite e auxiliar com o acompanhamento do projeto, além disso conseguiu gerar visibilidade para a pesquisa dentro da instituição com intuito de promover a aplicação do meu trabalho.

Ao meu orientador, Prof. Dr. Eli Hadad Júnior. Por permitir o desenvolvimento e adequação do meu projeto dentro do meu escopo desejado, sendo sempre atencioso e disponível para contribuir com os desafios dispostos na tese.

Eu não sei o que quero ser, mas sei muito bem o que não quero me tornar. (Friedrich Nietzsche).

RESUMO

O objetivo deste trabalho é investigar o poder preditivo de modelos econométricos e *machine learning* quando aplicados a séries temporais financeiras em alta frequência. Este tema é pertinente aos agentes econômicos atuantes no mercado financeiro brasileiro, que anseiam por ferramentas capazes de sustentar sua tomada de decisão em meio às inovações de conjuntura. Esta pesquisa está subdividida em três partes: a primeira conta com uma análise bibliométrica – combinada a uma revisão sistemática – da literatura empírica sobre Projeção de preço para ações brasileiras utilizando-se dados em alta frequência. Em seguida passa-se a utilizar o arcabouço econométrico e de *machine learning* existente aplicado a séries em alta frequência para algumas ações negociadas no ambiente da B3. Por fim, o desempenho dos modelos será mensurado e avaliado de modo crítico através do procedimento *Model Confidence Set*, possibilitando um veredito conclusivo a respeito das vantagens e obstáculos impostos a cada abordagem.

Palavras-chave: Dados em alta frequência. Modelagem econométrica. Modelagem *Machine learning*. *Model Confidence Set*.

ABSTRACT

This study aims to investigate the predictive power of econometric and *machine learning* models applied to financial time series at high-frequency. The research is pertinent to economic agents operating in the Brazilian financial market, who desire tools capable of sustaining their decision-making amid conjuncture innovations. This quest is separated into three parts, the first one with a bibliometric analysis – combined with a systematic review – of the empirical literature on the Price projection for Brazilian shares using high frequency data. Then we started to use the existing econometric and *machine learning* framework applied to high-frequency series from some shares traded in the B3 environment. Finally, the performance of the models will be measured and critically evaluated through Model Confidence Set criteria, allowing a conclusive verdict regarding the advantages and obstacles imposed by each approach.

Keywords: High-frequency data. Econometric modeling. Machine learning modeling. Model confidence set.

LISTA DE ABREVIATURAS E SIGLAS

ARCH:	*Autoregressive Conditional Heteroskedasticity* (Heteroscedasticidade Condicional Autorregressiva)
ARFIMA:	*Autoregressive Fractionally Integrated Moving Average* (Autorregressivo Média Móvel Integrada Fracionada)
ARIMA:	*Autoregressive Integrated Moving Average* (Autorregressivo Integrado de Médias Móveis)
ARMA:	*Autoregressive Moving Average* (Autorregressivo de Médias Móveis)
CVM:	Comissão de Valores Mobiliários
DAF:	Dados em Alta Frequência
EML:	*Exact Maximum Likelihood* (Máxima Verossimilhança Exata)
GARCH:	*Generalized Autoregressive Conditional Heteroskedasticity* (Heteroscedasticidade Condicional Autorregressiva Generalizada)
HAR:	*Heterogeneous Autoregressive* (Autorregressivo Heterogêneo)
HF:	*High-Frequency* (Alta Frequência)
HFT:	*High Frequency Trading*
JCR:	*Journal Citation Reports*
LSTM:	*Long Short Term Memory*
MCS:	*Model Confidence Set*
MPL*:*	*Modified Profile Likelihood* (Perfil Modificado de Verossimilhança)
NLS:	*Nonlinear Least Squares* (Mínimos Quadrados Não Lineares)
RNAs	Redes Neurais Artificiais
RNNs	Redes Neurais Recorrentes (*Recurrent Neural Network*)
SARIMA:	*Seasonal Autoregressive Integrated Moving Average* (Autorregressivo Integrado de Médias Móveis com Sazonalidade)
VaR:	*Value-at-Risk*
WoS:	*Web of Science*

LISTA DE ILUSTRAÇÕES

Figura 1 - Palavra-chave com respectiva frequência encontrada nas publicações 32
Figura 2 - Palavra-chave relacionada ao país de origem do estudo..... 32
Figura 3 - Palavra-chave com importância representada pelo tamanho 33
Figura 4 - Palavras-chave e interações entre elas, com grupos de relacionamento representado por cores e espessura nas linhas indicando a força de conexão entre elas 33
Figura 5 - Autores com maior quantidade de publicações no tema..... 38
Figura 6 - Autores com maior impacto dentro do tema com base no índice H 38
Figura 7 - Autores mais citados no tema 39
Figura 8 - Periódicos com maior impacto 42
Figura 9 - Produção científica por país, tonalidade mais escura representando maior quantidade 42
Figura 10 - Países com maior quantidade de citações. 43
Figura 11 - Análise de categorias e subcategorias para identificar lacunas de conhecimento . 44
Figura 12 – Estrutura da pesquisa..... 45
Figura 13 – Etapas Modelo ARIMA 49
Figura 14 – Arquitetura LSTM..... 55
Figura 15 – Arquitetura *Transformer* 56
Figura 16 – Camada de Atenção *Transformer* 57

Quadro 1 - Amostra final de artigos incluídos para revisão sistemática e análise bibliométrica 23
Quadro 2 - Matriz de (sub) categorização 29
Quadro 3 - Base de dados para aplicação empírica 59
Quadro 4 - Melhores modelos preditivos com base no critério MCS 62

LISTA DE TABELAS

Tabela 1 - Evolução da amostra por meio de filtros da *Scopus* e *Web of Science* 21
Tabela 2 - Total da amostra final de artigos científicos 21
Tabela 3 - Distribuição anual dos artigos 31
Tabela 4 - Ponto T de Goffman e classificação das palavras - Lei de Zipf 35
Tabela 5 - Lei de Lotka 40
Tabela 6 - Lei de Bradford 41
Tabela 7 - Total de observações por ativo 60

SUMÁRIO

1 INTRODUÇÃO 14

1.1 PROBLEMA DE PESQUISA 14

1.2 OBJETIVOS 15

2 REVISÃO SISTEMÁTICA E ANÁLISE BIBLIOMÉTRICA 17

2.1 MICROESTRUTURA DE MERCADO HFT E CENÁRIO BRASILEIRO 19

2.2 ROTEIRO ANÁLISE BIBLIOMÉTRICA E REVISÃO SISTEMÁTICA 20

2.3 RESULTADOS DA ANÁLISE BIBLIOMÉTRICA 31

2.4 RESULTADOS REVISÃO SISTEMÁTICA 43

2.5 CONSIDERAÇÕES FINAIS DA ETAPA DE ANÁLISE BIBLIOMÉTRICA E REVISÃO SISTEMÁTICA 44

3 METODOLOGIA 46

3.1 MODELOS ECONOMÉTRICOS APLICADOS AO DAF 47

3.1.1 Modelos ARCH e GARCH 47

3.1.2 Modelos ARIMA e ARFIMA 49

3.1.3 Filtro de Kalman 51

3.2 MODELOS *MACHINE LEARNING* APLICADOS AO DAF 54

3.2.1 LSTM 54

3.2.2 *Transformer* 56

3.3 AVALIAÇÃO DA PERFORMANCE DOS MODELOS 57

3.3.1 *Model Confidence Set* 58

3.4 BANCO DE DADOS 58

4 RESULTADOS 61

5 ANÁLISE DOS RESULTADOS 62

6 CONSIDERAÇÕES FINAIS 63

REFERÊNCIAS 65

ANEXOS 71

1 INTRODUÇÃO

O mercado de capitais brasileiro é composto por agentes que transacionam diariamente seus recursos, dentre eles notam-se investidores institucionais apresentando elevado volume sob sua gestão. Esse ambiente se desenvolve de maneira acentuada nos períodos mais recentes e, para que os negociadores operem de modo eficiente, devem dispor, além de uma bagagem teórica, de ferramentas práticas visando à melhor compreensão das incertezas capazes de interferir no preço dos ativos financeiros.

Existem inúmeros fatores capazes de gerar flutuações na economia no meio a essa instabilidade, estão os gestores que exercem constantes movimentações no mercado de capitais, almejando maior sustentação na formação de suas estratégias (ANGEL; MCCABE, 2013).

Ao longo do desenvolvimento da literatura financeira, diversos modelos foram propostos e validados com a finalidade de projetar preços para ativos financeiros. Ainda que válidos, esses modelos foram concebidos presumindo a captação de uma amostra com dados discretos (fechamentos anual, trimestral, mensal, diário). De acordo com Duhigg (1999), o avanço tecnológico revelou a possibilidade de acompanhamento em tempo real das transações, promovendo grandes avanços em relação à econometria vigente.

O uso deste tipo de abordagem se mostrou muito eficaz quando aplicado aos mercados de capitais americano e europeu, para tratamento em séries temporais de alta frequência no mercado de câmbio sob influência de notícias macroeconômicas (BEM OMRANE; WELCH; ZHOU, 2020). Entretanto essa prática ainda não se encontra documentada de forma representativa nas bases científicas considerando dados do mercado brasileiro que é menos desenvolvido.

Com base em evidências empíricas, esperamos fornecer ao investidor maiores subsídios, através de modelos econométricos e de *machine learning*, em sua tomada de decisão valendo-se de uma base de dados em alta frequência.

1.1 PROBLEMA DE PESQUISA

Apesar de o mercado financeiro operar de forma contínua e com alta frequência, praticamente todos os conjuntos de dados disponíveis sobre sua atividade estão baseados em amostragem discreta em frequência mais baixa (GOODHART; O'HARA, 1997). Com a chegada dos conjuntos de dados em alta frequência - *High-Frequency* (HF), essa disparidade passa a ser minimizada.

Alguns mercados disponibilizam as transações ocorridas em todos os intervalos, permitindo a cada *ticker* observações virtualmente contínuas de preço, volume e até mesmo tamanho da negociação. Acompanhando a abertura de novas possibilidades, uma série de questões-chave se manifestam a fim de que sejam respondidas pelos profissionais e pesquisadores, aprofundando nossa compreensão sobre os fundamentos que orientam o preço dos ativos.

Enquanto os acadêmicos debatem a eficácia de várias ferramentas, elas são amplamente utilizadas na prática (BROGAARD, 2010). Muitos sistemas técnicos de negociação são prontamente automatizados com computadores. Atualmente alguns praticantes da estratégia de reação às notícias usam computadores para examinar *feeds* de notícias em busca de informações relevantes e para tomar e implementar decisões comerciais. Os *traders* utilizam uma variedade de técnicas amparadas em dados de preços recentes na tentativa de discernir a direção futura dos preços. Algumas dessas estratégias são de seguimento de tendência que tentam identificar a direção em que o mercado está se formando, já outras estratégias técnicas tentam detectar reversões que estão prestes a ocorrer.

A hipótese do mercado eficiente implica que a precificação incorreta e as oportunidades de arbitragem associadas entre mercados relacionados devem ser eliminadas rapidamente. Neste sentido, o pressuposto da relação *lead-lag* afirma que o mercado responderá a uma precificação incorreta primeiramente em um derivativo, especialmente mercados de futuros, aumentando ou reduzindo a volatilidade no mercado à vista associado. Um exemplo da importância no estudo de dados de alta frequência pode ser encontrado na pesquisa de Black (1975), na qual foi sugerido que a maior alavancagem disponível nos mercados de opções poderia induzir *traders* a agir de modo a privilegiar a negociação de opções ao invés de ações.

Dessa forma, estabelecemos as seguintes questões aplicadas ao mercado de capitais brasileiro: o agente econômico melhora sua tomada de decisão utilizando dados em alta frequência para modelagem de preço futuro? Quais modelos econométricos e de *machine learning* apresentam maior poder preditivo para ações brasileiras, quando utilizamos série de dados em alta frequência?

1.2 OBJETIVOS

A tese busca preencher lacunas existentes no que diz respeito à utilização de dados em alta frequência para estudos econométricos e de *machine learning*, considerando o mercado de capitais brasileiro. No decorrer da etapa de revisão da literatura, serão feitas abordagens

discutindo as principais implicações (soluções e pontos de atenção) acerca da disponibilidade e uso dos dados em alta frequência (DAF) pelo agente econômico. Além do debate acerca do uso de DAF para tomada de decisões, investigam-se modelos econométricos tradicionais e seu poder preditivo frente às séries temporais em alta frequência de ações brasileiras, em seguida verifica-se a eficácia apresentada em alguns modelos de *machine learning* para mesma série.

Para os modelos tradicionais consideramos o uso dos modelos: ARCH (*Autoregressive Conditional Heteroskedasticity* – Heteroscedasticidade Condicional Autorregressiva), GARCH (*Generalized Autoregressive Conditional Heteroskedasticity* – Heteroscedasticidade Condicional Autorregressiva Generalizada), ARIMA (*Autoregressive Integrated Moving Average* – Autorregressivo Integrado de Médias Móveis), ARFIMA (*Autoregressive Fractionally Integrated Moving Average* – Autorregressivo Média Móvel Integrada Fracionada) e Filtro de Kalman. Já para o estudo dos modelos de *machine learning* aderentes aos dados em alta frequência consideram-se: LSTM (*Long Short Term Memory*) e *Transformer*. Esta pesquisa está subdividida em três etapas:

- a primeira etapa envolve enumerar os principais trabalhos científicos que abordam o uso de dados em alta frequência para modelagem no preço de ativos financeiros. O objetivo desta etapa será identificar os principais questionamentos e resoluções, orientando oportunidades para novas investigações;
- na segunda etapa utilizamos um arcabouço de modelos econométricos tradicionais e de *machine learning*, testando sua aplicabilidade aos dados de ações brasileiras em alta frequência. A finalidade para esta etapa é determinar se modelos tradicionais econométricos e de *machine learning* se mantêm como viáveis quando aplicados a uma base de dados em alta frequência;
- por fim, na terceira e última etapa trazemos a avaliação de performance dos modelos. Nessa serão apontados quais modelos aplicados na segunda etapa foram mais efetivos para análise DAF no mercado de ações brasileiro, ponderando benefícios e objeções.

Com base nas discussões e aplicação dos testes propostos tem-se em vista dar melhor suporte ao agente econômico para sua tomada de decisão, amparado por uma avaliação capaz de observar dados de séries temporais em alta frequência (condizente com o dinamismo existente no mercado de capitais).

2 REVISÃO SISTEMÁTICA E ANÁLISE BIBLIOMÉTRICA

Atualmente os estudos teóricos e empíricos existentes sobre volatilidade realizada, em sua maior parte, evidenciam que podemos obter previsões precisas a partir de modelos de séries temporais em alta frequência (ANDERSEN; BOLLERSLEV, 1998; ANDERSEN et al., 2001b, 2005; GHYSELS; SINKO, 2006; KOOPMAN; JUNGBACKER; HOL, 2005).

Conforme evidenciado em Angel e Mccabe (2013), dentre os fatores que influenciam a obtenção de sucesso no mercado financeiro para uma transação de curto prazo está a velocidade com que se concretiza a operação. Os agentes que almejam atuar nesse segmento devem investir em computadores e conexões rápidas de dados da bolsa de valores. A localização também é uma característica a ser considerada. Se o computador que está fazendo a negociação estiver em um escritório a uma milha de distância do *data center* da bolsa, seus pedidos chegarão cerca de cinco milionésimos de segundo mais devagar do que se o mesmo computador poderia efetivar se localizado no *data center* da bolsa.

Easley et al. (1996) ponderam que, a fim de potencializar seus retornos, negociadores institucionais se valem do benefício da diversificação em suas estratégias. Porém, fatores como a concentração de capital e o avanço na velocidade das transações oportunizam estratégias de manipulação para vários agentes, tentando afastar os preços de seu valor real para lucrar com a discrepância fabricada (BROGAARD, 2010). A maioria delas são estratégias de baixa frequência, mas algumas também podem ser implementadas usando tecnologia de alta frequência. Essas estratégias de manipulação são geralmente violações ilegais das disposições antifraude do *U.S. Securities Exchange Act* de 1934.

A proximidade física sempre foi um fator importante no mercado de capitais, uma vez que nem todos dispõem dos mesmos recursos para operar suas estratégias, reflexões acerca de justiça e igualdade emergem para debate. Fehr e Schmidt (1999) modelam a justiça como "aversão à desigualdade", na qual as pessoas estão dispostas a abrir mão de alguma recompensa para evitar um resultado injusto. De modo geral, os sujeitos estão dispostos a desistir de recompensas para punir aqueles que os tratam injustamente (KAHNEMAN; KNETSCH; THALER, 1986a, b).

Após o evento de 6 de maio de 2010, os Estados Unidos iniciaram com a imposição de interrupções nas negociações das ações cujos preços subam mais de 10% em 5 minutos. De certa maneira o cérebro humano parece estar de fato programado para preferir resultados justos. Tabibnia, Satpute e Lieberman (2008) relatam estudos de imagens cerebrais demonstrando a

existência de ativações de prazer quando um resultado justo é alcançado, enquanto outras regiões do cérebro são ativadas para resultados injustos.

Heath (2010) aborda a justiça nos mercados financeiros no contexto das finanças públicas, moeda, negociações com base em informações privilegiadas e outras áreas. Sua observação atenta para o tratamento comparativo de diferentes grupos, compreendendo o conceito de justiça como o tratamento semelhante dado aos autores em relação à regra estabelecida. Num contexto de mercado justo, todos os participantes têm acesso às mesmas informações (não há informações privilegiadas).

Essa noção de justiça é consagrada em nossas leis de valores mobiliários e aparato regulatório, que buscam criar condições equitativas, forçando a divulgação de informações relevantes. O conceito justiça engloba a perspectiva moral, contendo uma série de aplicações e padrões (BOATRIGHT, 2010).

Estratégias de ordens descobertas estão intimamente relacionadas às estratégias de previsão que tentam descobrir a existência de pedidos grandes que não foram atendidos. A partir de uma efetivação de pequena ordem no mercado, podemos identificar se há algum interesse comercial à espreita; caso a ordem seja atendida, o negociante pode supor que uma grande ordem de compra em bloco está em andamento (GATEV; GOETZMANN; ROUWENHORST, 2006).

De acordo com Andersen, Bollerslev e Diebold (2002), a volatilidade realizada RV_t é amplamente utilizada em finanças empíricas, pois, além de ser calculada de forma direta, é um estimador consistente da volatilidade integrada sob condições gerais não paramétricas. Dentre suas vantagens, ela fornece medidas não enviesadas, ou seja, medidas de erro não correlacionadas em série. Sua definição é dada pela soma dos retornos quadrados observados em intervalos de tempo muito pequenos.

Dentre os modelos já testados para dados de alta frequência, o modelo autorregressivo de média móvel fracionada integrado (ARFIMA) apresentou grande eficácia para capturar a volatilidade realizada. Isso em razão de o processo ARFIMA apresentar maior capacidade de modelar séries com comportamento de memórias longas, em que as autocorrelações amostrais entre *lags* distantes não podem ser consideradas desprezíveis (ANDERSEN; BOLLERSLEV, 1997, 1998; ANDERSEN et al., 2003; ANDERSEN; BOLLERSLEV; MEDDAHI, 2005; THOMAKOS; WANG, 2003; ANGELIDIS; DEGIANNAKIS, 2008; GIOT; LAURENT, 2004; KOOPMAN; JUNGBACKER; HOL, 2005).

Posteriormente, Corsi (2009) sugeriu em sua pesquisa outra alternativa eficiente: o modelo autorregressivo heterogêneo - *Heterogeneous Autoregressive* (HAR), concebido como uma estrutura autorregressiva das volatilidades realizadas em intervalos de tamanhos diferentes.

Sua interpretação econômica deriva da Hipótese de Mercado Heterogêneo apresentada por Müller et al. (1993). A ideia básica é que os participantes do mercado tenham uma perspectiva diferente de seu horizonte de investimento. A heterogeneidade se origina da diferença no horizonte de tempo gerando a volatilidade.

2.1 MICROESTRUTURA DE MERCADO HFT E CENÁRIO BRASILEIRO

O *High Frequency Trading* – HFT remete à estratégia de rápida realocação de capital (podendo ocorrer em milésimos de segundos). As operações tendem a ser mais efetivas quando o agente dispõe de algoritmos mais flexíveis, capazes de otimizar a análise e envio das ordens, buscando antecipar a direção de ativos em períodos mais curtos de acordo com as condições apresentadas pelo mercado. Os cálculos mais complexos exigem máquinas mais robustas, buscando diferentes oportunidades na bolsa (CHORDIA et al., 2013).

A microestrutura presente no HFT foi testada por Araújo e Montini (2013), que investigam os retornos, volume e tipos de negociação antes e após iniciação das estratégias de HFT. Cabe também destaque para o otimismo por parte dos executivos em relação às operações em alta frequência no mercado local, eles observam semelhanças com o movimento ocorrido nos EUA.

Dentre os fatores capazes de distanciar o ritmo acelerado americano do cenário brasileiro temos a conclusão tardia na automatização do pregão local, concluída no ano de 2005. A Comissão de Valores Mobiliários (CVM) demonstra interesse em fomentar operações HFT no Brasil, ações nesse sentido são capazes de gerar desenvolvimento acelerado na bolsa brasileira. Para buscar esse objetivo se faz necessária a ampliação do número de participantes transacionando em alta velocidade e obtendo retorno significativo, o que validaria a utilização dessa estratégia.

Alguns estudos na área de microestrutura do mercado destacam o comportamento dos *traders* informados e não informados, apontando as vantagens que os primeiros possuem (BAGEHOT, 1971; KYLE, 1985). Os *traders* não informados observam estatísticas diárias enquanto *traders* informados conseguem reconhecer o comportamento do ativo *tick-by-tick* através da aplicação de algoritmos capazes de captar esse tipo de teste.

Em outra vertente da literatura a preocupação consiste nos *spreads* (processo de formação do preço de venda menos preço de compra). Entre os conceitos clássicos estabelecidos temos que o valor do *spread* pode ser separado em três partes: a primeira parte seria o custo de processamento, que remete à parte administrativa (funcionários, despesas fixas).

Os dois seguintes estão relacionados ao risco de mercado dos ativos. Custo de inventário corresponde ao risco assumido pelo formador de mercado ao posicionar preços de compra e venda dos ativos e para isso será exigido prêmio compatível com sua exposição. A assimetria de informação deriva do anonimato de compradores e vendedores, juntamente com a imprevisibilidade de seus níveis informacionais. Isso faz com que o preço se modifique de acordo com fluxo de ordens que são recebidas.

2.2 ROTEIRO ANÁLISE BIBLIOMÉTRICA E REVISÃO SISTEMÁTICA

Neste primeiro estudo objetivamos responder a pergunta – quais são os principais temas de pesquisa relacionados à utilização de dados em alta frequência para modelagem e previsibilidade no preço dos ativos financeiros? Para tanto, são implementadas 7 etapas descritas a seguir. As etapas 1 a 5 atendem a ambas (as metodologias de análise bibliométrica e de revisão sistemática), enquanto as etapas 6 e 7 ficam restritas à revisão sistemática do tema.

Etapa 1 – Escolha da base de dados. Nesta etapa os artigos da amostra são obtidos a partir das bases de dados *Scopus* e *Web of Science* (WoS), duas dentre as principais bases de dados para citações acadêmicas. Elas contêm registros de artigos publicados em periódicos científicos de alto fator de impacto, sendo classificados por meio do *Journal Citation Reports* (JCR).

Etapa 2 – Uso de parâmetros iniciais de pesquisa partindo das bases da *Scopus* e *WoS*. Considerando as duas bases para o período entre 1º de janeiro de 2015 e 1º de agosto de 2022, são identificados 369 artigos com base em variações nas palavras-chave "*high frequency data*", "*forecast*" e "*volatility*". Na sequência, são realizadas exclusões por meio da aplicação de filtros nas próprias bases, resultando em 78 artigos selecionados como amostra intermediária pela *Scopus* e 89 artigos selecionados como amostra intermediária pela WoS, conforme Tabela 1. Desta forma, podem-se totalizar 167 artigos como amostra intermediária por essas duas bases de dados.

Tabela 1 - Evolução da amostra por meio de filtros da *Scopus* e *Web of Science*

Sinal	Descrição	Scopus	WOS	Total
(+)	Busca: "Article title", "Abstract", "Keywords" igual a: “high frequency data”, “forecast” e “volatility”	196	173	369
(=)	**Amostra inicial**	**196**	**173**	**369**
(-)	Data: anterior ao ano de 2015	72	63	135
(-)	Idioma: diferente de “English”	3	0	3
(-)	Tema: diferente de "economics"; "econometrics" e; "business finance"	43	21	64
(=)	**Amostra intermediária**	**78**	**89**	**167**

Fonte: elaboração própria, 2022.

Etapa 3 – Exclusão de artigos duplicados. Após identificação dos artigos que atenderam os critérios impostos nas etapas 1 e 2, utilizamos o sistema R para consolidação dos dados, excluindo os artigos em duplicidade gerados por ambas as bases. Neste processo foi identificado um total de 49 artigos presentes nas duas origens, fazendo com que a amostra das bases agrupadas atingisse o número global de 118 artigos.

Ainda dentro dessa etapa efetuou-se a busca dos artigos completos nas bases de dados, necessária para aplicação dos procedimentos bibliométricos. Após a busca para a amostra selecionada, 25 artigos não foram localizados na íntegra.

Tabela 2 - Total da amostra final de artigos científicos

Sinal	Descrição	Número de artigos
(+)	Web of Science + Scopus	167
(-)	Artigos presentes nas duas bases	49
(=)	**Total da Amostra**	**118**
(-)	Artigos não localizados	25
(=)	**Amostra Final**	**93**

Fonte: elaboração própria, 2022.

Etapa 4 – Criação de banco de dados e coleta de artigos. Os 93 artigos da amostra final foram obtidos por meio das bases de pesquisa acadêmica Scopus e WoS. A partir de sua análise, são coletadas as seguintes informações para a captura dos dados gerais do artigo: Autor, Palavra-chave, Tema de pesquisa, Origem, Citações, Assunto, Resumo, Contato Autor, Tipo de publicação, Link do Artigo, Coautor, Órgão de fomento, Revista Publicada, Idioma, Editora, Foco do Estudo, Ano de publicação, Universidade de Origem, Citação completa, Citação simplificada.

Além desses dados, foi acrescido à planilha de estudo o fator de impacto índice “H”. Esse índice quantifica o impacto que as pesquisas individuais ou coletivas exercem, com base no número de citações em outros artigos científicos. Demonstrou-se apropriado para mensurar a qualidade, bem como o impacto de cada publicação e pesquisador dentro do meio acadêmico. Dentro dessa métrica, podemos exemplificar que o índice-H=10 demonstra que o autor possui 10 artigos publicados com 10 ou mais citações.

Quadro 1 - Amostra final de artigos incluídos para revisão sistemática e análise bibliométrica

Autor	Palavras-chave	Link artigo	Número publicação	Revista
BOLLERSLEV T;LI J;PATTON A;QUAEDVLIEG R	CO-JUMPS; HIGH-FREQUENCY DATA; REALIZED VARIANCES; SEMICOVARIANCES; VOLATILITY FORECASTING	10.3982/ECTA17056	00129682	ECONOMETRICA
BOLLERSLEV T;HOOD B;HUSS J;PEDERSEN L	RISK EVERYWHERE: MODELING AND MANAGING VOLATILITY	10.1093/rfs/hhy041	08939454	REVIEW OF FINANCIAL STUDIES
SUN E;CHEN Y;YU M	BIG FINANCIAL DATA; DWT; HIGH-FREQUENCY DATA; MODWT; WAVELET	10.1016/j.ijpe.2014.12.033	09255273	INTERNATIONAL JOURNAL OF PRODUCTION ECONOMICS
PATTON A;SHEPPARD K	GOOD VOLATILITY, BAD VOLATILITY: SIGNED JUMPS AND THE PERSISTENCE OF VOLATILITY	10.1162/REST_a_00503	00346535	REVIEW OF ECONOMICS AND STATISTICS
SYMITSI E;SYMEONIDIS L;KOURTIS A;MARKELLOS R	ASSET ALLOCATION; COVARIANCE FORECASTING; HIGH-FREQUENCY DATA; IMPLIED VOLATILITY; RISK-RETURN TRADE-OFF	10.1016/j.jbankfin.2018.08.013	03784266	JOURNAL OF BANKING AND FINANCE
TIAN S;HAMORI S	HIGH-FREQUENCY DATA; REALIZED GARCH; SHORT-TERM INTEREST RATE; VOLATILITY	10.1016/j.jbankfin.2015.09.008	03784266	JOURNAL OF BANKING AND FINANCE
NING C;XU D;WIRJANTO T	REALIZED KERNEL VOLATILITY; UNIVARIATE TIME SERIES COPULAS; VALUE-AT-RISK; VOLATILITY CLUSTERING	10.1016/j.jbankfin.2014.11.016	03784266	JOURNAL OF BANKING AND FINANCE
LI J;PATTON A	FORECAST EVALUATION; JUMPS; REALIZED VARIANCE; SEMIMARTINGALE; VOLATILITY	10.1016/j.jeconom.2017.10.005	03044076	JOURNAL OF ECONOMETRICS
ASAI M;CHANG C;MCALEER M	ASYMMETRY; ASYMPTOTIC DISTRIBUTION; LONG MEMORY; REALIZED MEASURE; STOCHASTIC VOLATILITY; WHITTLE LIKELIHOOD	10.1016/j.jeconom.2017.05.010	03044076	JOURNAL OF ECONOMETRICS
BAUM C;ZERILLI P;CHEN L	CVAR; ENERGY FUTURES; HIGH FREQUENCY DATA; JUMPS; LEVERAGE EFFECT; STOCHASTIC VOLATILITY; VAR	10.1016/j.eneco.2019.104481	01409883	ENERGY ECONOMICS
WANG J;HUANG Y;MA F;CHEVALLIER J	CRUDE OIL FUTURES; FORECASTING; HIGH-FREQUENCY DATA; REALIZED VOLATILITY; STOCK MARKET	10.1016/j.eneco.2020.104897	01409883	ENERGY ECONOMICS
ZHANG Y;WANG J	STOCK MARKET; CRUDE OIL PRICE FORECAST; MIDAS MODEL; HIGH FREQUENCY DATA	10.1016/j.eneco.2018.11.015	01409883	ENERGY ECONOMICS
AVDULAJ K;BARUNIK J	PORTFOLIO DIVERSIFICATION; DYNAMIC CORRELATIONS; HIGH FREQUENCY DATA; TIME-VARYING COPULAS; COMMODITIES	10.1016/j.eneco.2015.05.018	01409883	ENERGY ECONOMICS
DIMITRIADIS T;HALBLEIB R	EXPECTED SHORTFALL; HIGH-FREQUENCY DATA; INTRINSIC TIME; SELF-SIMILAR; SUBORDINATED PROCESS; VALUE AT RISK	10.1080/07350015.2021.1929249	07350015	JOURNAL OF BUSINESS AND ECONOMIC STATISTICS
LUNDE A;SHEPHARD N;SHEPPARD K	DISCIPLINED CONVEX OPTIMIZATION; HIGH-FREQUENCY DATA; MARKET FRICTIONS; MINIMUM VARIANCE PORTFOLIO; REALIZED KERNEL	10.1080/07350015.2015.1064432	07350015	JOURNAL OF BUSINESS & ECONOMIC STATISTICS
LYOCSA S;MOLNAR P;VYROST T	VOLATILITY; FORECASTING; REALIZED VOLATILITY; HIGH-LOW RANGE; HAR MODEL	10.1016/j.ijforecast.2020.12.001	0169-2070	INTERNATIONAL JOURNAL OF FORECASTING

Autor	Palavras-chave	Link artigo	Número publicação	Revista
HOGA Y	EXTREME VALUE THEORY; FORECAST INTERVALS; HIGH-FREQUENCY VOLATILITY; MEASURES; RISK FORECASTS; VOLATILITY INDICES	10.1016/j.ijforecast.2020.08.009	0169-2070	INTERNATIONAL JOURNAL OF FORECASTING
LYOCSA S;TODOROVA N	HIGH FREQUENCY DATA; REALIZED VOLATILITY; OVERNIGHT VOLATILITY; FORECASTING; MARKET RISK	10.1016/j.ijforecast.2019.08.002	0169-2070	INTERNATIONAL JOURNAL OF FORECASTING
LI X;ZAKAMULIN V	SPOT VOLATILITY; FORWARD VOLATILITY; VOLATILITY FORECASTING; HIGH-FREQUENCY DATA; FORECAST ACCURACY; TERM STRUCTURE; OUT-OF-SAMPLE; FORECASTING; MODEL COMPARISON	10.1016/j.ijforecast.2019.08.010	0169-2070	INTERNATIONAL JOURNAL OF FORECASTING
TAKAHASHI M;WATANABE T;OMORI Y	BACKTESTING; EXPECTED SHORTFALL; GENERALIZED HYPERBOLIC SKEW STUDENT'S; T-DISTRIBUTION; MARKOV CHAIN MONTE CARLO; REALIZED VOLATILITY; STOCHASTIC VOLATILITY; VALUE-AT-RISK	10.1016/j.ijforecast.2015.07.005	0169-2070	INTERNATIONAL JOURNAL OF FORECASTING
HORTA E;ZIEGELMANN F	STOCHASTIC PROCESSES; AUTOCOVARIANCE; DIMENSION REDUCTION; HIGH; FREQUENCY DATA; VOLATILITY FORECASTING	10.1016/j.ijforecast.2017.08.001	0169-2070	INTERNATIONAL JOURNAL OF FORECASTING
FENG Y;ZHOU C	APPROXIMATELY BEST LINEAR PREDICTOR; REALIZED VOLATILITY; FINANCIAL; FORECASTING; LONG MEMORY; NONPARAMETRIC SCALE FUNCTION; SEMI-FI-LOG-ACD	10.1016/j.ijforecast.2014.09.001	0169-2070	INTERNATIONAL JOURNAL OF FORECASTING
DUARTE C;RODRIGUES P;RUA A	MIDAS; CONSUMPTION; ELECTRONIC PAYMENTS; ATM; POS	10.1016/j.ijforecast.2016.08.003	0169-2070	INTERNATIONAL JOURNAL OF FORECASTING
LIU M;LEE C;CHOO W	CHINA; DISTRIBUTION; GARCH; HIGH-FREQUENCY DATA; VOLATILITY FORECASTING	10.1080/00036846.2020.1862747	00036846	APPLIED ECONOMICS
EL O I;UCTUM R	ANNOUNCEMENTS; ASYMMETRIC GARCH; FOREX MARKET; HIGH FREQUENCY DATA; JUMP DETECTION TEST; MICROSTRUCTURE NOISE	10.1016/j.econmod.2015.12.025	02649993	ECONOMIC MODELLING
RESCHENHOFER E;MANGAT M;STARK T	HAR; MIDAS; QLIKE; REALIZED VARIANCE; RISK–RETURN TRADEOFF	10.1016/j.jempfin.2020.09.006	09275398	JOURNAL OF EMPIRICAL FINANCE
MA F;LIAO Y;ZHANG Y;CAO Y	COJUMPS; JUMP INTENSITY; OIL MARKET; SIGNED JUMPS; VOLATILITY FORECASTING	10.1016/j.jempfin.2019.01.004	09275398	JOURNAL OF EMPIRICAL FINANCE
LI X;ZAKAMULIN V	HIGH-FREQUENCY DATA; STATE DEPENDENCE; STOCK MARKETS; VOLATILITY FORECASTING	10.1080/14697688.2020.1725101	14697688	QUANTITATIVE FINANCE
IZZELDIN M;HASSAN M;PAPPAS V;TSIONAS M	ARFIMA; HAR; HIGH-FREQUENCY DATA; MARKET CONDITIONS; MARKET SECTORS; REALISED VARIANCE	10.1080/14697688.2019.1600713	14697688	QUANTITATIVE FINANCE
SIRIGNANO J;CONT R	DEEP LEARNING; FINANCIAL ECONOMETRICS; HIGH-FREQUENCY DATA; INTRADAY DATA; LIMIT ORDER BOOK; MACHINE LEARNING; MARKET MICROSTRUCTURE; PRICE FORMATION	10.1080/14697688.2019.1622295	14697688	QUANTITATIVE FINANCE

Autor	Palavras-chave	Link artigo	Número publicação	Revista
GATHERAL J;JAISSON T;ROSENBAUM M	FRACTIONAL BROWNIAN MOTION; FRACTIONAL ORNSTEIN–UHLENBECK; HIGH FREQUENCY DATA; LONG MEMORY; OPTION PRICING; VOLATILITY FORECASTING; VOLATILITY PERSISTENCE; VOLATILITY SMOOTHNESS; VOLATILITY SURFACE	10.1080/14697688.2017.1393551	14697688	QUANTITATIVE FINANCE
LIU F;PANTELOUS A;VON M H	FORECASTING; HAR-RV-J; HIGH-FREQUENCY DATA; HYBRID MODEL; REALIZED VOLATILITY; RNN; TRADING EFFICIENCY	10.1080/14697688.2017.1414489	14697688	QUANTITATIVE FINANCE
BAYER C;FRIZ P;GATHERAL J	ARBITRAGE PRICING; BERGOMI–GUYON EXPANSION; FRACTIONAL BROWNIAN MOTION; OPTIONS PRICING; STOCHASTIC VOLATILITY; VOLATILITY MODELLING; VOLATILITY SURFACES	10.1080/14697688.2015.1099717	14697688	QUANTITATIVE FINANCE
ZHU X;ZHANG H;ZHONG M	AFTER-HOURS INFORMATION; LEVERAGE EFFECTS; NON-FERROUS METALS FUTURES; VOLATILITY CLUSTERING; VOLATILITY FORECASTING	10.1016/j.resourpol.2017.09.006	03014207	RESOURCES POLICY
ZEVALLOS M	HIGH FREQUENCY DATA; QUANTILE REGRESSION; VALUE-AT-RISK	10.18800/economia.201902.004	0254-4415	REVISTA ECONOMIA
WANG J;MA F;WAHAB M;HUANG D	CHINA'S CRUDE OIL FUTURES; HIGH-FREQUENCY DATA; JUMP; REALIZED; VOLATILITY FORECASTING	10.1002/for.2752	0277-6693	JOURNAL OF FORECASTING
CAI G;WU Z;PENG L	ADDITIVE OUTLIERS; INNOVATIVE OUTLIERS; REALIZED GARCH; VOLATILITY; FORECASTING	10.1002/for.2736	0277-6693	JOURNAL OF FORECASTING
ZHANG Y;MA F;WANG T;LIU L	MIXED FREQUENCY; MODEL SWITCHING; MOMENTUM OF PREDICTABILITY; OUT-OF-SAMPLE PREDICTION; VOLATILITY	10.1002/for.2590	0277-6693	JOURNAL OF FORECASTING
BANULESCU D;COLLETAZ G;HURLIN S	HIGH-FREQUENCY RISK MEASURE; VALUE AT RISK; TIME AT RISK; BACKTESTING	10.1002/for.2374	0277-6693	JOURNAL OF FORECASTING
TIAN F;YANG K;CHEN L	REALIZED VOLATILITY; FORECAST; AGRICULTURAL COMMODITY FUTURES; LONG; MEMORY; REGIME SWITCHING	10.1002/for.2443	0277-6693	JOURNAL OF FORECASTING
YANG K;CHEN L;TIAN F	REALIZED VOLATILITY; ARFIMAX-FIGARCH MODEL; STRUCTURAL BREAKS; COMBINATION FORECASTS; ESTIMATION WINDOW	10.1002/for.2318	0277-6693	JOURNAL OF FORECASTING
HUANG X;TANG H	CLUSTERING; FINANCIAL RISK; MULTIFRACTAL; MULTI-VOLATILITY STATES; VOLATILITY MEASUREMENT	10.1002/for.2820	0277-6693	JOURNAL OF FORECASTING
LIU M;LEE C;CHOO W	FREQUENCY; GARCH; SEQUENTIAL INFORMATION ARRIVAL HYPOTHESIS; TRADING; VOLUME; VOLATILITY	10.1002/for.2739	0277-6693	JOURNAL OF FORECASTING
MA F;WEI Y;LIU L;HUANG D	OIL FUTURES MARKET; REALIZED SEMI-VARIANCES; SIGNED JUMP VARIATIONS; STATISTIC AND ECONOMIC EVALUATIONS; VOLATILITY FORECASTING	10.1002/for.2511	0277-6693	JOURNAL OF FORECASTING
BEN O W;WELCH R;ZHOU X	FINANCIAL CRISIS; FOREIGN EXCHANGE RATE; HIGH-FREQUENCY DATA; MACROECONOMIC NEWS	10.1002/for.2615	0277-6693	JOURNAL OF FORECASTING
KONG A;ZHU H;AZENCOTT R	HIGH-FREQUENCY DATA; INTRADAY STOCK JUMPS; LIQUIDITY MEASURES; MACHINE; LEARNING; TECHNICAL INDICATORS	10.1002/for.2721	0277-6693	JOURNAL OF FORECASTING

Autor	Palavras-chave	Link artigo	Número publicação	Revista
PAPADAMOU S;SOGIAKAS V	CONDITIONAL CORRELATION; GARCH MODELS; UNCONVENTIONAL MONETARY POLICY	10.1002/for.2461	0277-6693	JOURNAL OF FORECASTING
BUGGE S;GUTTORMSEN H;MOLNÁR P;RINGDAL M	IMPLIED VOLATILITY; LEVERAGE EFFECT; OBX INDEX; VIX; VOLATILITY FORECASTING	10.1016/j.irfa.2016.07.007	10575219	INTERNATIONAL REVIEW OF FINANCIAL ANALYSIS
QU H;WANG T;ZHANG Y;SUN P	HEDGING EFFECTIVENESS; HIGH-FREQUENCY DATA; OUT-OF-SAMPLE FORECASTING; REALIZED MINIMUM-VARIANCE HEDGE RATIO; TRACKING ERROR; VOLATILITY REGIME	10.1016/j.pacfin.2018.08.002	0927538X	PACIFIC BASIN FINANCE JOURNAL
PHAM B;SALA H	COMMON SHOCKS; CONNECTEDNESS; COUNTRY-SPECIFIC SHOCKS; G7; PHILIPS CURVE	10.1007/s00181-021-02052-0	03777332	EMPIRICAL ECONOMICS
MA F;WEI Y;CHEN W;HE F	FORECASTING EVALUATION; HIGH-FREQUENCY VOLATILITY MODELS; SIGNED JUMP VARIATION; VOLATILITY FORECASTING	10.1007/s00181-017-1294-6	03777332	EMPIRICAL ECONOMICS
PROKOPCZUK M;SYMEONIDIS L;WESE S C	REALIZED VOLATILITY; JUMPS; HIGH–FREQUENCY DATA; VOLATILITY FORECASTING; FORECAST EVALUATION	10.1002/fut.21759	02707314	JOURNAL OF FUTURES MARKETS
CARTEA ;KARYAMPAS D	HIGH-FREQUENCY DATA; IMPLIED VOLATILITY; JUMPS; MICROSTRUCTURE NOISE; VIX; VOLATILITY FORECASTS	10.1080/07474938.2014.976529	07474938	ECONOMETRIC REVIEWS
PLÍHAL T;LYÓCSA L	FORECASTING; HIGH-FREQUENCY DATA; IMPLIED VOLATILITY; OPTIONS; REALIZED VOLATILITY	10.1016/j.iref.2020.10.001	10590560	INTERNATIONAL REVIEW OF ECONOMICS AND FINANCE
CHEN W;MA F;WEI Y;LIU J	FORECASTING EVALUATION; OIL FUTURES PRICE; VOLATILITY FORECASTING; VOLATILITY OF REALIZED VOLATILITY	10.1016/j.iref.2019.10.014	10590560	INTERNATIONAL REVIEW OF ECONOMICS AND FINANCE
CHAN J;NG K;RAGELL R	BAYESIAN ANALYSIS; CARR MODEL; GENERALISED BETA TYPE II DISTRIBUTION; REALISED RANGE; RETURN MODEL; TAIL CONDITIONAL VAR; VAR	10.1016/j.iref.2019.01.003	10590560	INTERNATIONAL REVIEW OF ECONOMICS AND FINANCE
WANG C;NISHIYAMA Y	FORECASTING EVALUATION; HIGH-FREQUENCY DATA; REALIZED MEASURE; VOLATILITY FORECASTING	10.1016/j.iref.2015.02.014	10590560	INTERNATIONAL REVIEW OF ECONOMICS AND FINANCE
CAPORIN M;VELO G	LONG-MEMORY; MACROECONOMIC VARIABLES; REALIZED RANGE VOLATILITY; REALIZED VOLATILITY; VOLATILITY FORECASTING	10.1016/j.iref.2015.02.021	10590560	INTERNATIONAL REVIEW OF ECONOMICS AND FINANCE
HAMMOUDEH S;MCALEER M	ECONOMIC POLICY UNCERTAINTY; EMPIRICAL FINANCE; FINANCIAL ECONOMETRICS; FINANCIAL RISK MANAGEMENT	10.1016/j.iref.2015.02.001	10590560	INTERNATIONAL REVIEW OF ECONOMICS AND FINANCE
SONG S;TIAN F;LI H	VAR; CENSORED GP DISTRIBUTION; POT; DCS; BACK TESTING	10.1016/j.asieco.2021.101314	1049-0078	JOURNAL OF ASIAN ECONOMICS
BERGSLI L;LIND A;MOLNÁR P;POLASIK M	BITCOIN; GARCH; HAR; REALIZED VARIANCE; VOLATILITY FORECASTING	10.1016/j.ribaf.2021.101540	02755319	RESEARCH IN INTERNATIONAL BUSINESS AND FINANCE
SHEPPARD K;XU W	CONDITIONAL BETA; CONDITIONAL COVARIANCE; FORECASTING; REALIZED COVARIANCE; REALIZED KERNEL; SYSTEMATIC RISK	10.1093/jjfinec/nby028	14798409	JOURNAL OF FINANCIAL ECONOMETRICS
SMETANINA E	FORECASTING; GARCH MODELS; HIGH-FREQUENCY DATA	10.1093/jjfinec/nbx008	14798409	JOURNAL OF FINANCIAL ECONOMETRICS

Autor	Palavras-chave	Link artigo	Número publicação	Revista
HALBLEIB R;VOEV V	HIGH-FREQUENCY DATA; MULTIVARIATE VOLATILITY; REALIZED (CO)VARIANCE; VOLATILITY FORECASTING	10.1093/jjfinec/nbu031	14798409	JOURNAL OF FINANCIAL ECONOMETRICS
BAILEY G;STEELEY J	AUSTRALIAN DOLLAR; EXCHANGE RATE; HIGH–LOW RANGE; REALIZED VARIANCE; STOCHASTIC VOLATILITY; VOLATILITY FORECASTING	10.1002/ijfe.1723	10769307	INTERNATIONAL JOURNAL OF FINANCE AND ECONOMICS
LYÓCSA L;PÍHAL T;VÝROST T	FOREIGN EXCHANGE MARKETS; HAR; HIGH-FREQUENCY DATA; REALIZED GARCH; VOLATILITY MODELLING	10.1016/j.frl.2020.101776	15446123	FINANCE RESEARCH LETTERS
HORPESTAD J;LYÓCSA ;MOLNÁR P;OLSEN T	ASYMMETRIC VOLATILITY; FORECASTING; GARCH; HAR; HIGH-FREQUENCY; REALIZED VOLATILITY	10.1016/j.najef.2018.07.011	10629408	NORTH AMERICAN JOURNAL OF ECONOMICS AND FINANCE
TAN S;NG K;CHAN J;MOHAMED I	HIGH FREQUENCY; QUANTILE PARKINSON; RANGE-BASED MODEL; VALUE-AT-RISK; VOLATILITY	10.1016/j.najef.2018.06.010	10629408	NORTH AMERICAN JOURNAL OF ECONOMICS AND FINANCE
MA F;LI Y;LIU L;ZHANG Y	COMBINE FORECASTS; FORECASTING EVALUATION; REALIZED VOLATILITY; VOLATILITY FORECASTING	10.1016/j.najef.2017.11.006	10629408	NORTH AMERICAN JOURNAL OF ECONOMICS AND FINANCE
RODRÍGUEZ G	ARFIMA MODELS; DENSITY FORECASTS; LATIN-AMERICAN STOCK AND FOREX MARKETS VOLATILITY; LONG MEMORY; RANDOM LEVEL SHIFTS; VALUE-AT-RISK	10.1016/j.najef.2017.07.016	10629408	NORTH AMERICAN JOURNAL OF ECONOMICS AND FINANCE
BERNARDI M;CATANIA L;PETRELLA L	ASYMMETRIC GARCH MODELS; EXTREME LOSS; HIGH-FREQUENCY DATA; MODEL CONFIDENCE SET; SENTIMENT ANALYSIS; VALUE-AT-RISK FORECAST COMBINATION	10.1080/1351847X.2015.1106959	1351847X	EUROPEAN JOURNAL OF FINANCE
BOTHA B;OLDS T;REID G;STEENKAMP D;VAN J R	FORECAST EVALUATION; MACHINE LEARNING; NOWCASTING	10.1111/saje.12298	00382280	SOUTH AFRICAN JOURNAL OF ECONOMICS
AVDULAJ K;BARUNIK J	COPULA QUANTILE REGRESSION; REALIZED VOLATILITY; VALUE-AT-RISK	10.1515/snde-2016-0044	10811826	STUDIES IN NONLINEAR DYNAMICS AND ECONOMETRICS
GROSSMASS L;POON S	COPULA; HIGH FREQUENCY DATA; INTRADAY DEPENDENCE; TIME-VARYING; DEPENDENCE; VALUE-AT-RISK	10.1515/snde-2013-0123	10811826	STUDIES IN NONLINEAR DYNAMICS AND ECONOMETRICS
GHYSELS E;PLAZZI A;VALKANOV R;RUBIA A;DOSSANI A	MIXED-DATA SAMPLING; MULTIPERIOD FORECASTS; VOLATILITY FORECASTING	10.1146/annurev-financial-110217-022808	19411367	ANNUAL REVIEW OF FINANCIAL ECONOMICS
ABEBE T	ETHIOPIA; FORECASTING; HIGH-FREQUENCY DATA; MACROECONOMIC VARIABLES; MODELING; TIME-VARYING VOLATILITY	10.1080/15140326.2020.1804304	15140326	JOURNAL OF APPLIED ECONOMICS
PAUL S;SHARMA P	EXPECTED SHORTFALL; EXTREME VALUE THEORY; REALIZED GARCH; REALIZED KERNEL; SKEWED STUDENT-T; VALUE-AT-RISK	10.1108/SEF-09-2016-0236	10867376	STUDIES IN ECONOMICS AND FINANCE
CAMPANI C;DURÃES A	BRAZILIAN FOREIGN EXCHANGE MARKET; EXTENDED GARCH MODELS; IMPLIED VOLATILITY INDICES; VOLATILITY FORECASTS	10.1590/0101-41614845cca	01014161	ESTUDOS ECONOMICOS
ROKICKA A;KUDŁA J	HETEROGENEOUS AUTOREGRESSION MODELS; HIGH-FREQUENCY DATA; IMPLIED VOLATILITY; REALIZED VOLATILITY; VOLATILITY FORECAST	10.21314/JOR.2021.005	14651211	JOURNAL OF RISK

Autor	Palavras-chave	Link artigo	Número publicação	Revista
CHAROENWONG B;FENG G	ITERATED FORECASTS; LONG-HORIZON VOLATILITY; MIXED DATA FREQUENCY; MODEL SELECTION; RISK MANAGEMENT; TEMPORAL AGGREGATION	10.21314/JOR.2017.360	14651211	JOURNAL OF RISK
ASLAM F;FERREIRA P;MUGHAL K;BASHIR B	COVID-19; EUROPEAN UNION; HIGH FREQUENCY DATA; SPILLOVERS; STOCK MARKETS	10.3390/ijfs9010005	22277072	INTERNATIONAL JOURNAL OF FINANCIAL STUDIES
JHA K;BAUR D	SEMIVARIANCE; BITCOIN; VOLATILITY ASYMMETRY; HIGH-FREQUENCY DATA; HAR; QUANTILE REGRESSION	10.3390/jrfm13120312	1911-8066	JOURNAL OF RISK AND FINANCIAL MANAGEMENT
CHUONG L C;DOKUCHAEV N	REALISED VOLATILITY; HETEROGENEOUS AUTOREGRESSIVE MODEL; PURIFIED; IMPLIED VOLATILITY; CLASSIFICATION; RANDOM FORESTS; MACHINE LEARNING	10.3390/jrfm11040061	1911-8066	JOURNAL OF RISK AND FINANCIAL MANAGEMENT
ADASCALITEI S	HIGH FREQUENCY DATA; HEAVY MODEL; VOLATILITY; CORPORATE SOCIAL; RESPONSIBILITY; DAILY RETURNS	10.1016/S2212-5671(15)00040-4	2212-5671	GLOBALIZATION AND HIGHER EDUCATION IN ECONOMICS AND BUSINESS ADMINISTRATION - GEBA 2013
SANTOS D;CANDIDO O;TÓFOLI P	EXPECTED SHORTFALL; OVERNIGHT VOLATILITY; REALIZED VOLATILITY; VALUE-AT-RISK; VOLATILITY FORECASTING	10.1016/j.najef.2022.101669	10629408	NORTH AMERICAN JOURNAL OF ECONOMICS AND FINANCE
WANG D;SU Z;LI Q	DEPENDENT FUNCTIONAL DATA; FUNCTIONAL REGRESSION FORECASTING; INTRADAY VOLATILITY; STOCK INDEX FUTURES	10.1080/1331677X.2022.2076144	1331677X	ECONOMIC RESEARCH-EKONOMSKA ISTRAZIVANJA
MAO X	HAR MODEL; INVESTOR SENTIMENT INDEX; PRINCIPAL COMPONENT ANALYSIS; VOLATILITY FORECASTING	10.1109/CBFD52659.2021.00050		PROCEEDINGS - 2021 INTERNATIONAL CONFERENCE ON COMPUTER, BLOCKCHAIN AND FINANCIAL DEVELOPMENT, CBFD 2021
ANDERSEN T;VARNESKOV R	COINTEGRATION; FRACTIONAL INTEGRATION; FREQUENCY DOMAIN INFERENCE; LOCAL SPECTRUM PROCEDURE; PARAMETER INSTABILITY; STRUCTURAL CHANGE; VOLATILITY FORECASTING	10.1016/j.jeconom.2021.05.011	03044076	JOURNAL OF ECONOMETRICS
BOLLERSLEV T;MEDEIROS M;PATTON A;QUAEDVLIEG R	HIGH-FREQUENCY DATA; REALIZED VARIATION; VOLATILITY FORECASTING	10.1016/j.jeconom.2021.04.013	03044076	JOURNAL OF ECONOMETRICS

Fonte: elaboração própria, 2022.

Etapa 5 – Análise bibliométrica. Por meio do programa Rstudio, aplicativo *biblioshiny* (que fornece uma interface da web para o pacote *bibliometrix*), são analisados dados objetivos dos artigos – países, autores, palavras-chave, instituições etc. – para elaboração e análise de tabelas e mapas de relacionamento. As análises realizadas são complementadas através da descrição e aplicação das principais leis da bibliometria (empreendidas nessa etapa):

a) Lei de Zipf (1949) – categorização e estimação da frequência das palavras-chave com o auxílio do software *Rank Words* para cálculo do ponto T de Goffman – ponto de transição de palavras de baixa para as de alta frequência (concentrando as palavras com alta carga semântica);
b) Lei de Bradford (1934) – quantificar a produtividade dos periódicos em relação ao assunto em questão;
c) Lei de Lotka (1926) – identificação dos pesquisadores que possuem maior frequência de produção em determinada área de conhecimento.

Etapa 6 - Leitura e codificação dos artigos. Nesta etapa identificam-se nos artigos seus objetivos, amostra, métodos e contribuições, classificando-os e categorizando-os de modo estruturado conforme Quadro 2. Para cada uma das 6 categorias são definidas subcategorias, cuja soma na contagem de frequência totaliza 100%.

Quadro 2 - Matriz de (sub) categorização

Categorias	Subcategorias	Definição
1.Tema principal/foco do estudo	A - Utilização de modelos preditivos tradicionais.	Testar eficácia dos modelos preditivos tradicionais existentes aplicados aos dados de alta frequência.
	B - Utilização de modelo para gestão de risco.	Testar eficácia dos modelos de risco tradicionais existentes aplicados aos dados de alta frequência.
	C - Proposta de novos modelos preditivos.	Aprimoramento dos modelos preditivos tradicionais aplicados aos dados de alta frequência.
	D – Variáveis macroeconômicas atuando na volatilidade dos ativos.	Investigar, com base em dados de alta frequência, os efeitos que acontecimentos macroeconômicos relevantes exercem sob a volatilidade dos ativos.
	E - Dados em Alta X Baixa frequência.	Testar a eficácia na utilização de dados em alta frequência visando aprimoramento dos modelos preditivos.
	F – Outros.	Demais temas não relacionados às subcategorias 1A, 1B, 1C, 1D e 1E.
2. Teorias relacionadas às hipóteses	A - Estudo de volatilidade.	Variação de preços apresentado por um ativo financeiro.
	B - Gestão de riscos.	Gerenciamento de variáveis críticas que podem impactar no preço dos ativos financeiros.
	C - Estudo de eventos.	Variáveis macroeconômicas relevantes que afetam diretamente o preço dos ativos financeiros.

Categorias	Subcategorias	Definição
	D - Gestão de Carteiras.	Ferramentas direcionadas à gestão de ativos financeiros que compõem a carteira do investidor.
	E – Outras.	Demais teorias não relacionadas às subcategorias 2A, 2B, 2C e 2D.
3. Método utilizado	A- Modelo Autorregressivo.	Modelo que apresenta a mesma variável dependente e explicativa, sendo que a variável dependente estará em um momento posterior (t) do que a variável independente (t-1).
	B - Modelo de Risco.	Modelos construídos para elaborar e testar diferentes cenários de estratégias, subsidiando a tomada de decisões.
	C - Análise de Jump.	Identificar a presença de Jump para análise de volatilidade.
	D – Outros.	Demais métodos não relacionados às subcategorias 3A, 3B e 3C.
4. Origem dos dados	A – Global.	Dados de empresas que abrangem dois ou mais grupos (B,C,D,E,F).
	B - Estados Unidos e Canadá.	Dados de empresas que operam nos Estados Unidos e Canadá.
	C – Europa.	Dados de empresas que operam na Europa.
	D - Ásia/Oceania.	Dados de empresas que operam na Ásia e Oceania.
	E - América Latina.	Dados de empresas que operam na América Latina.
	F – África.	Dados de empresas que operam na África.
5. Resultados	A - Confirmados eficácia de modelos e hipóteses já existentes.	Validação dos modelos e hipóteses reconhecidas em trabalhos anteriores.
	B - Confirmados eficácia de modelos e hipóteses novos.	Validação dos modelos e hipóteses desenvolvidas dentro da própria pesquisa.
	C - Resultados não conclusivos.	Resultados que não validam as hipóteses existentes e propostas nos aspectos testados.
	D – Outros.	Demais resultados não relacionados às subcategorias 5A, 5B e 5C.
6. Avenidas para estudos futuros	A - Alternativas para aprimoramento do modelo.	Incluir novas variáveis identificadas como promissoras dentro do modelo proposto.
	B - Extensão no uso do modelo para novas finalidades.	Utilizar o modelo sob novos possíveis ângulos, auxiliando na resolução de novos problemas de pesquisa.
	C - Utilização do modelo para novas amostras.	Testar modelo proposto em outros mercados e classes de ativos.

Fonte: elaboração própria, 2022.

Etapa 7 – Revisão sistemática. Após a codificação da matriz de (sub) categorização do Quadro 2, para amostra final, é realizada uma contagem de frequência das subcategorias de forma a possibilitar a identificação de lacunas de conhecimento. Referidas lacunas são então comparadas com as subcategorias da categoria 6. Este processo evidencia avenidas para estudos futuros, integrando novos aspectos passíveis de estudos sobre o tema.

2.3 RESULTADOS DA ANÁLISE BIBLIOMÉTRICA

O item 2.3 apresenta os resultados da análise bibliométrica, mencionada na Etapa 5 da Metodologia. Por sua vez, no item 2.4 estão os resultados da revisão sistemática, cujos passos estão descritos nas Etapas 6 e 7 deste estudo.

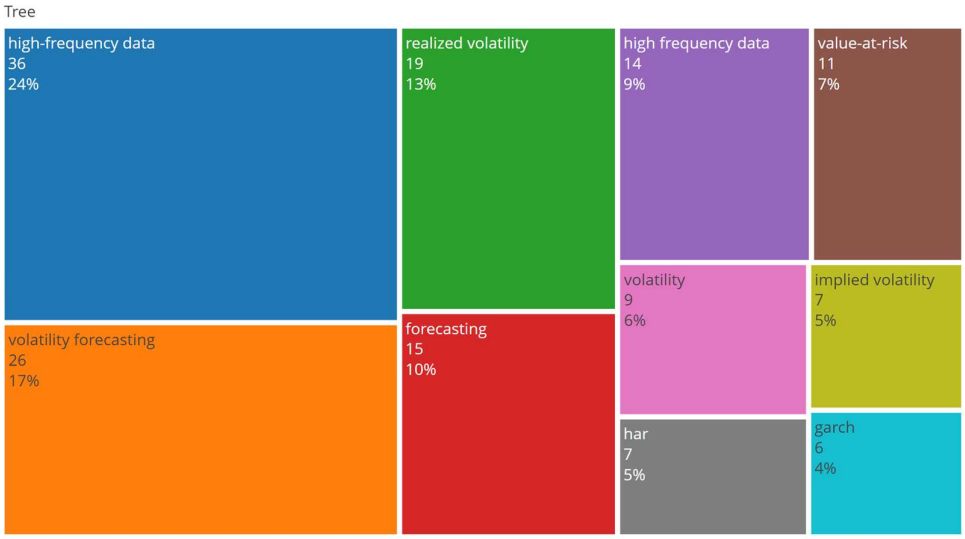
A amostra final é composta por 93 artigos obtidos pelas bases da *Scopus* e *WoS*, distribuídos entre os anos de 2015 e 2022. Eliminando-se o período posterior a agosto 2022, obtemos uma média de 12 artigos anuais relacionados ao tema, conforme a Tabela 3. Também se verifica que, dentre as principais frequências de palavras-chave, destacam-se *high-frequency data* com 36 ocorrências (24%) e *volatility-forecasting* com 26 ocorrências (17%) conforme Figura 1. As Figuras 2 e 3 correspondem à relação entre palavra-chave e país de estudo e dimensão da palavra-chave representada por seu tamanho, respectivamente.

Tabela 3 - Distribuição anual dos artigos

Ano	Quantidade de artigos
2015	12
2016	9
2017	9
2018	13
2019	13
2020	11
2021	17
Total	**84**
Média	**12**

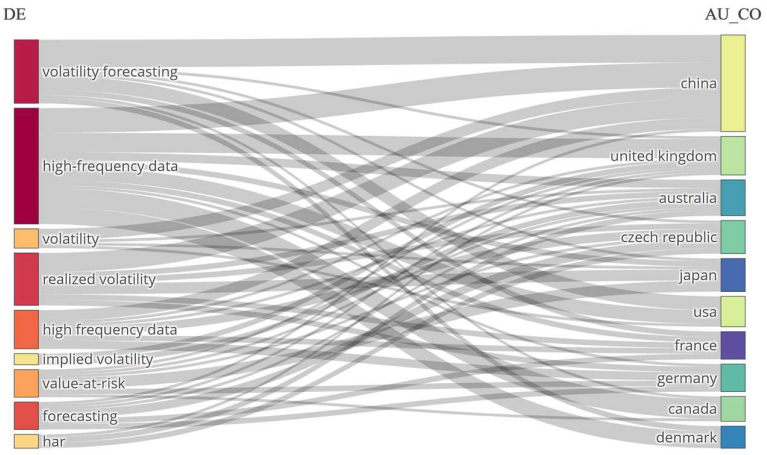
Fonte: elaboração própria, 2022.

Figura 1 - Palavra-chave com respectiva frequência encontrada nas publicações



Fonte: elaboração própria, 2022.

Figura 2 - Palavra-chave relacionada ao país de origem do estudo



Fonte: elaboração própria, 2022.

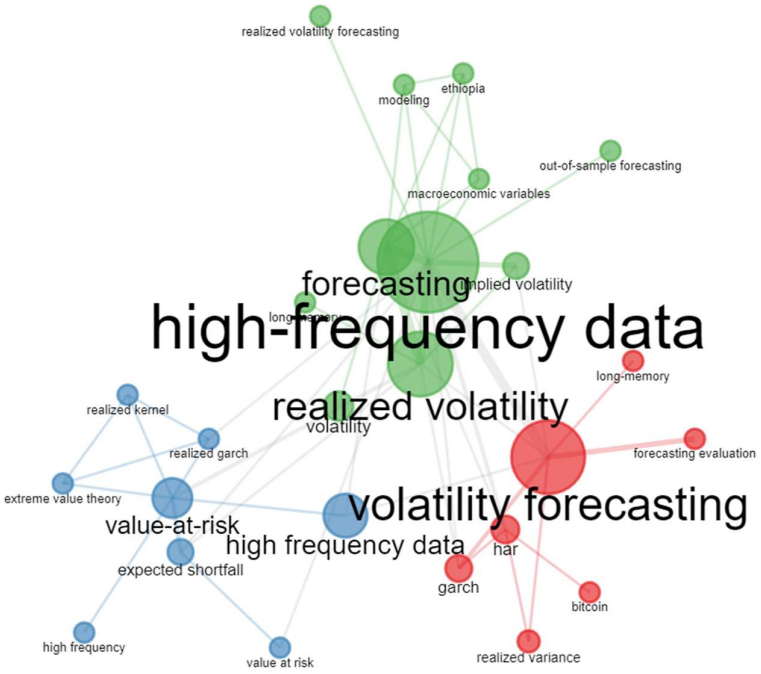
Figura 3 - Palavra-chave com importância representada pelo tamanho



Fonte: elaboração própria, 2022.

Por sua vez, a Figura 4 apresenta o mapa de coocorrências das palavras-chave mais utilizadas nos artigos. Para esta observação destacam-se as palavras “high-frequency data”, “volatility forecasting”, “forecasting” e “realized volatility”.

Figura 4 - Palavras-chave e interações entre elas, com grupos de relacionamento representado por cores e espessura nas linhas indicando a força de conexão entre elas



Fonte: elaboração própria, 2022.

No que se trata das palavras-chave, a Lei de Zipf (1949) diz que há uma otimização no seu uso. Assim, elas não dispersam. Ao contrário, há uma tendência de uso mínimo das palavras-chave, possuindo alta frequência de ocorrência. A primeira lei de Zipf afirma que a série de uma palavra multiplicada pela sua frequência de ocorrência será aproximadamente constante, resultando na Equação (1):

$$r \times f = C \quad (1)$$

na qual:
r = série;
f = frequência;
C = constante.

Para palavras com baixa frequência, Zipf (1949) propôs uma segunda lei, sendo revisada e modificada por Booth (1967). Segundo o autor, em um determinado texto, várias palavras com baixa ocorrência possuem a mesma frequência – vide Equação (2):

$$In = 2I1 / n\,(n+1) \quad (2)$$

na qual:
I1 = número de palavras que têm frequência 1;
In = número de palavras que têm frequência n;
n = ponto de Goffman ou local de transição das palavras de baixa para as de alta frequência.

As Leis de Zipf (1949) definem as extremidades de uma lista de distribuição de palavras. Entre esses pontos extremos há uma região de transição das palavras de alta para as de baixa frequência. Segundo Goffman (1971), nessa região estão as palavras de maior conteúdo semântico, sendo as mais adequadas para a indexação temática de um dado texto. Pao (1978) apresenta a fórmula do ponto T ou de transição de Goffman – vide Equação (3).

$$T = (-1+8I_1) / 2 \quad (3)$$

na qual:

T = ponto de transição de Goffman;

I_1 = número de palavras que têm frequência 1.

A identificação do ponto T de Goffman ocorre mediante ordenamento decrescente das palavras-chaves pelo *software Rank Words*. Na sequência são identificadas aquelas que se repetem apenas uma única vez para cálculo do ponto T de Goffman, localizando aquelas que se posicionam acima da classificação indicada por esse ponto. A Tabela 4 indica que, para os 93 artigos da amostra final, esse ponto varia entre 31,75 (ZEVALLOS, 2019) e 76,35 (SUN; CHEN; YU, 2015), sendo sua média de 45,53.

Na sequência, faz-se uma análise da região na qual estão as palavras mais aderentes ao tema principal do texto. Para tanto, são excluídas aquelas que não são relevantes ao estudo – ex: preposições, artigos, pronomes, advérbios e numerais. Depois, classificam-se as palavras que possuem maior frequência, conforme Tabela 4. De acordo com essa tabela, o termo *Volatility* possui maior frequência em 34 artigos, com destaque para Lyócsa e Todorova (2020), quando se repete 347 vezes num texto com o total de 15.534 palavras.

Tabela 4 - Ponto T de Goffman e classificação das palavras - Lei de Zipf

Autor	Nº de palavras	Nº de palavras diferentes	Nº de Palavras com frequência 1	Palavra Mais Recorrente	Frequência da palavra mais recorrente	T = ponto de transição de Goffman
BOLLERSLEV T (2020)	*18,631*	*3,010*	*1,394*	*Semicovariance*	*72*	*51.80388243*
BOLLERSLEV T (2018)	*23,389*	*3,058*	*1,431*	*Risk*	*270*	*52.5*
SUN EW (2015)	*21,467*	*4,838*	*2,991*	*Financial*	*82*	*76.3450063*
PATTON AJ (2015)	*15,002*	*2,197*	*1,027*	*Volatility*	*131*	*44.32383479*
SYMITSI E (2018)	*20,632*	*3,149*	*1,664*	*Models*	*140*	*56.69098716*
TIAN S (2015)	*11,700*	*1,878*	*923*	*Volatility*	*117*	*41.96801136*
NING C (2015)	*13,620*	*2,195*	*1,102*	*Volatility*	*202*	*45.94944089*
LI J (2018)	*20,555*	*2,724*	*1,258*	*Forecast*	*116*	*49.16223679*
ASAI M (2017)	*10,516*	*2,044*	*1,103*	*Volatility*	*111*	*45.97073557*
BAUM CF (2021)	*11,817*	*2,418*	*1,421*	*Model*	*119*	*52.31275645*
WANG J (2020)	*15,439*	*2,648*	*1,427*	*Volatility*	*167*	*52.42518133*
ZHANG YJ (2019)	*11,660*	*2,332*	*1,478*	*Oil*	*233*	*53.37140793*
AVDULAJ K (2015)	*13,875*	*2,710*	*1,456*	*Oil*	*100*	*52.96526661*
DIMITRIADIS T (2022)	*16,376*	*2,617*	*1,292*	*Time*	*108*	*49.83551908*
LUNDE A (2016)	*12,251*	*2,348*	*1,176*	*Covariance*	*70*	*47.5*
LYOCSA S (2021)	*16,526*	*2,458*	*1,184*	*Volatility*	*301*	*47.66466891*
HOGA Y (2021)	*11,348*	*2,076*	*996*	*Risk*	*145*	*43.63462781*

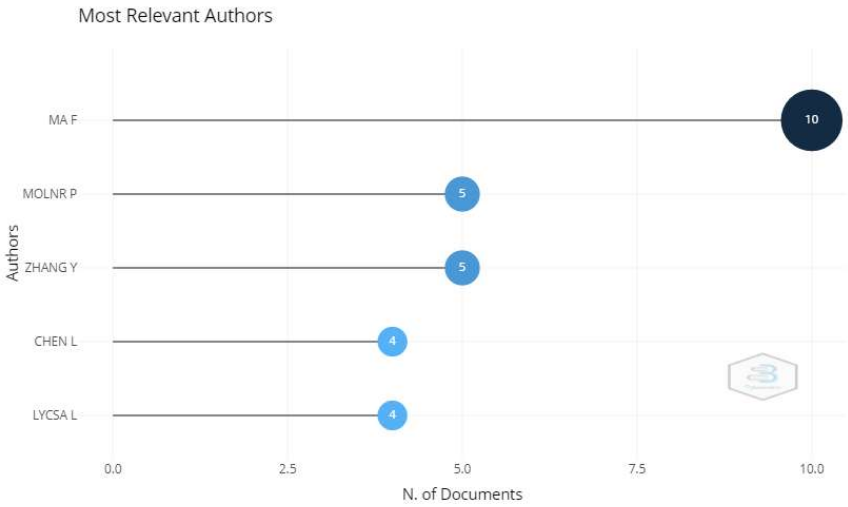
Autor	Nº de palavras	Nº de palavras diferentes	Nº de Palavras com frequência 1	Palavra Mais Recorrente	Frequência da palavra mais recorrente	T = ponto de transição de Goffman
LYOCSA S (2020)	*15,534*	*2,023*	*863*	*Volatility*	*347*	*40.54816482*
LI X (2020)	*12,638*	*1,811*	*753*	*Volatility*	*226*	*37.81043674*
TAKAHASHI M (2016)	*16,313*	*2,342*	*1,085*	*Model*	*155*	*45.58594209*
HORTA E (2018)	*9,814*	*1,995*	*960*	*Forecasting*	*47*	*42.82065723*
FENG Y (2015)	*10,001*	*1,557*	*649*	*Memory*	*65*	*35.03123645*
DUARTE C (2017)	*9,696*	*1,841*	*916*	*Midas*	*119*	*41.80478945*
LIU M (2021)	*20,981*	*2,411*	*959*	*HAR*	*420*	*42.797831*
EL OUADGHIRI I (2016)	*17,461*	*2,936*	*1,476*	*Jumps*	*126*	*53.33461144*
RESCHENHOFER E (2020)	*12,517*	*2,031*	*970*	*Loss*	*109*	*43.04826898*
MA F (2019)	*11,398*	*1,970*	*982*	*Model*	*264*	*43.31986011*
LI X (2020)	*13,344*	*1,943*	*860*	*Volatility*	*242*	*40.47589661*
IZZELDIN M (2019)	*8,417*	*2,052*	*1,197*	*Forecasting*	*90*	*47.93107397*
SIRIGNANO J (2019)	*7,745*	*1,467*	*749*	*Model*	*116*	*37.70723447*
GATHERAL J (2018)	*12,138*	*2,044*	*954*	*Volatility*	*211*	*42.68352092*
LIU F (2018)	*10,933*	*2,311*	*1,304*	*Model*	*126*	*50.07102897*
BAYER C (2016)	*9,204*	*1,400*	*634*	*Volatility*	*104*	*34.61249781*
ZHU X (2017)	*12,250*	*2,217*	*1,247*	*Volatility*	*248*	*48.9424669*
ZEVALLOS M (2019)	*3,193*	*962*	*536*	*Volatility*	*65*	*31.74522866*
WANG J (2021)	*13,279*	*1,876*	*913*	*Model*	*245*	*41.73464637*
CAI G (2021)	*16,258*	*3,866*	*2,646*	*Model*	*152*	*71.7478522*
ZHANG Y (2019)	*8,488*	*1,595*	*797*	*Model*	*103*	*38.92806031*
BANULESCU D (2016)	*16,738*	*2,395*	*1,113*	*VaR*	*174*	*46.18315377*
TIAN F (2017)	*7,791*	*1,702*	*900*	*Volatility*	*111*	*41.42935305*
YANG K (2015)	*20,963*	*2,502*	*1,230*	*Forecast*	*188*	*48.60090725*
HUANG X (2022)	*7,980*	*1,669*	*948*	*Volatility*	*144*	*42.54595274*
LIU M (2021)	*17,724*	*2,516*	*1,279*	*GARCH*	*225*	*49.5791459*
MA F (2018)	*12,488*	*2,283*	*1,110*	*Volatility*	*148*	*46.11952886*
BEN OMRANE W (2020)	*12,753*	*2,018*	*880*	*News*	*219*	*40.95533339*
KONG A (2021)	*13,435*	*2,214*	*1,008*	*Jumps*	*115*	*43.90267253*
PAPADAMOU S (2018)	*9,868*	*1,844*	*877*	*Monetary*	*68*	*40.88376774*
BUGGE SA (2016)	*7,602*	*1,574*	*801*	*Volatility*	*113*	*39.02811512*
QU H (2019)	*10,306*	*1,793*	*956*	*Futures*	*98*	*42.72928081*
PHAM BT (2022)	*9,926*	*2,015*	*1,015*	*Connectedness*	*100*	*44.05829557*
MA F (2018)	*11,444*	*2,247*	*1,190*	*Volatility*	*212*	*47.78780585*
PROKOPCZUK M (2016)	*37,783*	*2,504*	*831*	*HAR–RV*	*1,155*	*39.77070026*
CARTEA (2016)	*8,589*	*1,538*	*729*	*Volatility*	*136*	*37.18703969*
PLÍHAL T (2021)	*14,739*	*2,393*	*1,141*	*Volatility*	*346*	*46.77290027*
CHEN W (2020)	*9,797*	*1,837*	*952*	*RV*	*209*	*42.63771305*
CHAN JSK (2019)	*11,409*	*2,316*	*1,304*	*Model*	*110*	*50.07102897*

Autor	Nº de palavras	Nº de palavras diferentes	Nº de Palavras com frequência 1	Palavra Mais Recorrente	Frequência da palavra mais recorrente	T = ponto de transição de Goffman
WANG C (2015)	*9,770*	*2,007*	*1,113*	*Volatility*	*77*	*46.18315377*
CAPORIN M (2015)	*14,181*	*2,311*	*1,090*	*Volatility*	*155*	*45.69314725*
HAMMOUDEH (2015)	*7,173*	*1,660*	*924*	*Risk*	*79*	*41.99127819*
SONG S (2021)	*16,195*	*2,235*	*1,082*	*VaR*	*148*	*45.52150041*
BERGSLI L (2022)	*15,178*	*2,292*	*1,182*	*HAR*	*270*	*47.62355396*
SHEPPARD K (2019)	*16,680*	*2,269*	*1,052*	*Factor*	*211*	*44.87210481*
SMETANINA E (2017)	*20,181*	*2,975*	*1,631*	*GARCH*	*421*	*56.11610981*
HALBLEIB R (2016)	*16,789*	*2,581*	*1,304*	*ARFIMA*	*177*	*50.07102897*
BAILEY G (2019)	*14,977*	*2,441*	*1,225*	*Volatility*	*242*	*48.5*
LYÓCSA L (2020)	*10,071*	*2,048*	*1,020*	*Volatility*	*173*	*44.16912662*
HORPESTAD JB (2019)	*13,587*	*2,374*	*1,095*	*Volatility*	*250*	*45.80010684*
TAN SK (2019)	*11,638*	*2,085*	*1,154*	*Volatility*	*82*	*47.04425044*
MA F (2018)	*13,903*	*2,177*	*1,030*	*Volatility*	*157*	*44.38997687*
RODRÍGUEZ G (2017)	*23,172*	*3,640*	*1,957*	*ARFIMA*	*258*	*61.56396727*
BERNARDI M (2017)	*24,227*	*2,683*	*1,298*	*VaR*	*85*	*49.95341009*
BOTHA B (2021)	*11,910*	*2,163*	*1,023*	*Model*	*133*	*44.23549491*
AVDULAJ K (2017)	*10,031*	*1,879*	*1,022*	*Quantile*	*103*	*44.21338297*
GROSSMASS L (2015)	*18,690*	*2,468*	*1,181*	*Intraday*	*141*	*47.60298345*
GHYSELS E (2019)	*12,969*	*1,610*	*766*	*Returns*	*221*	*38.14396505*
ABEBE TH (2020)	*8,869*	*1,680*	*849*	*Volatility*	*148*	*40.20982892*
PAUL S (2018)	*14,674*	*2,501*	*1,112*	*GARCH*	*131*	*46.16195501*
CAMPANI CH (2018)	*11,679*	*2,238*	*1,130*	*Volatility*	*172*	*46.54208662*
ROKICKA A (2021)	*14,739*	*2,393*	*1,141*	*Volatility*	*346*	*46.77290027*
CHAROENWONG B (2017)	*7,244*	*1,462*	*778*	*Model*	*94*	*38.4493346*
ASLAM F (2021)	*9,056*	*2,110*	*1,161*	*Markets*	*141*	*47.1897292*
JHA KK (2020)	*6,326*	*1,265*	*654*	*Volatility*	*242*	*35.16973873*
CHUONG LUONG CL (2018)	*7,990*	*1,680*	*859*	*Volatility*	*145*	*40.45177921*
ADASCALITEI S (2015)	*3,212*	*980*	*586*	*Volatility*	*45*	*33.23813663*
SANTOS DG (2022)	*24,150*	*2,662*	*1,070*	*Forecasts*	*212*	*45.26283606*
WANG D (2022)	*8,289*	*1,887*	*1,054*	*Volatility*	*147*	*44.9156836*
MAO X (2021)	*5,760*	*1,283*	*671*	*Sentiment*	*99*	*35.6367302*
ANDERSEN TG (2021)	*21,488*	*2,850*	*1,323*	*Cointegration*	*115*	*50.44171459*
BOLLERSLEV T (2021)	*9,552*	*1,866*	*964*	*Model*	*96*	*42.9118435*
LAI YS (2022)	*10,010*	*2,198*	*1,293*	*Models*	*91*	*49.85518656*
CAPORIN M (2021)	*11,505*	*1,703*	*760*	*Jumps*	*150*	*37.99038343*
WANG M (2022)	*8,537*	*1,637*	*814*	*Model*	*86*	*39.35157989*
JIN X (2021)	*13,988*	*2,574*	*1,450*	*Covariance*	*93*	*52.85396921*
					Média	*45.53162926*

Fonte: elaboração própria, 2022.

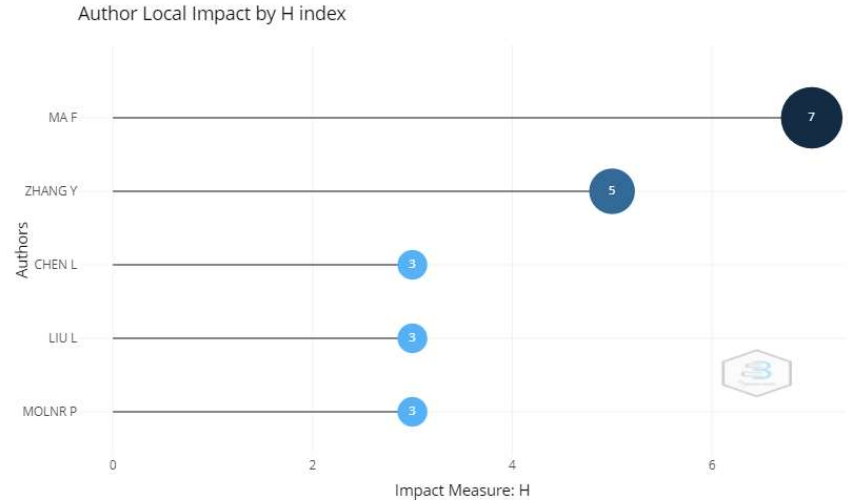
Com relação à autoria dos artigos, destacam-se 5 autores com maior quantidade de periódicos publicados: Ma F, Molnr P, Zhang Y, Chen L e Lycsa L (Figura 5). No que diz respeito à relevância com base no índice H, outros 5 autores são apontados, com destaque para Ma F e Zhang Y (Figura 6); ao observar-se apenas a quantidade de citações, temos que os autores mais citados foram Bollerslev e Lunde com 274 e 108 citações, respectivamente (Figura 7).

Figura 5 - Autores com maior quantidade de publicações no tema



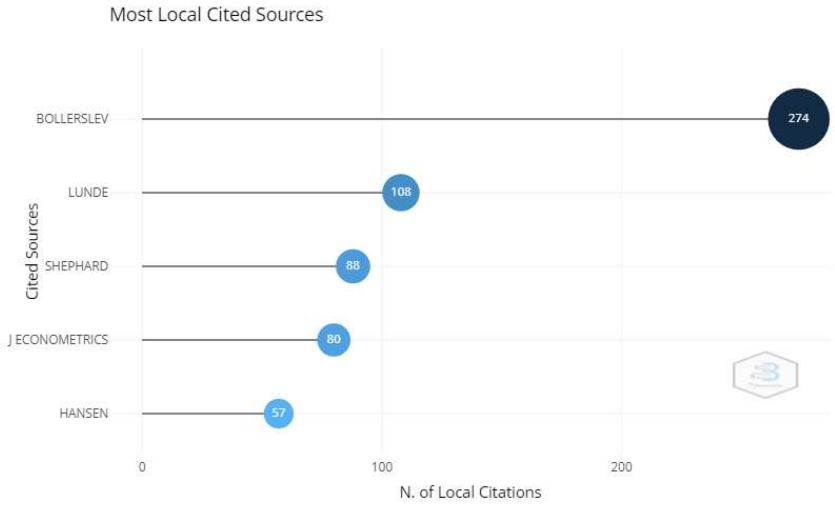
Fonte: elaboração própria, 2022.

Figura 6 - Autores com maior impacto dentro do tema com base no índice H



Fonte: elaboração própria, 2022.

Figura 7 - Autores mais citados no tema



Fonte: elaboração própria, 2022.

Lotka (1926) afirma que um pequeno número de autores produz muitos artigos e que a produção obtida por esse reduzido número de pesquisadores se iguala em quantidade ao desempenho dos demais. Essa lei é denominada de lei do quadrado inverso - vide Equação 4.

$$an = a1 / n^2, n = 1, 2, 3 \ldots \quad (4)$$

na qual:
an = número de autores que publicaram n artigos;
a1 = número de autores que publicaram um artigo;
n = número de artigos publicados por autor.

Os números dispostos pela equação 4 não podem ser validados para a amostra final dos 93 artigos, apesar disso existe uma relação lógica apontando baixa frequência entre autores com maior número de publicações. O autor Ma F é o que possui maior número de publicações no tema (10 no total) representando frequência de 0,40%. O mesmo ocorre com o segundo colocado, Molnr P, que conta com 5 publicações.

Tabela 5 - Lei de Lotka

Documentos escritos	Quantidade de Autores	%
1	*197*	*81.70%*
2	*31*	*12.90%*
3	*7*	*2.90%*
4	*4*	*1.70%*
5	*1*	*0.40%*
10	*1*	*0.40%*
Total	***241***	***100.00%***

Fonte: elaboração própria, 2022.

A Tabela 6 remete à aplicação da Lei de Bradford (1934), indicando os periódicos com maior incidência de publicação. A lei afirma que há poucos periódicos que produzem muitos artigos e muitos periódicos que produzem poucos artigos sobre um determinado tema. Para Brookes (1969), a referida lei estima o grau de relevância de determinados periódicos acadêmicos que atuam em áreas de conhecimento específicas. Caso os periódicos sejam classificados por ordem decrescente de produtividade, eles podem ser distribuídos em zonas. Para este estudo as referidas zonas foram divididas em duas partes: Zona A identificada como o mais essencial ao assunto, constituída pelos periódicos com mais de uma referência. Já a zona B apresenta os periódicos com uma única publicação.

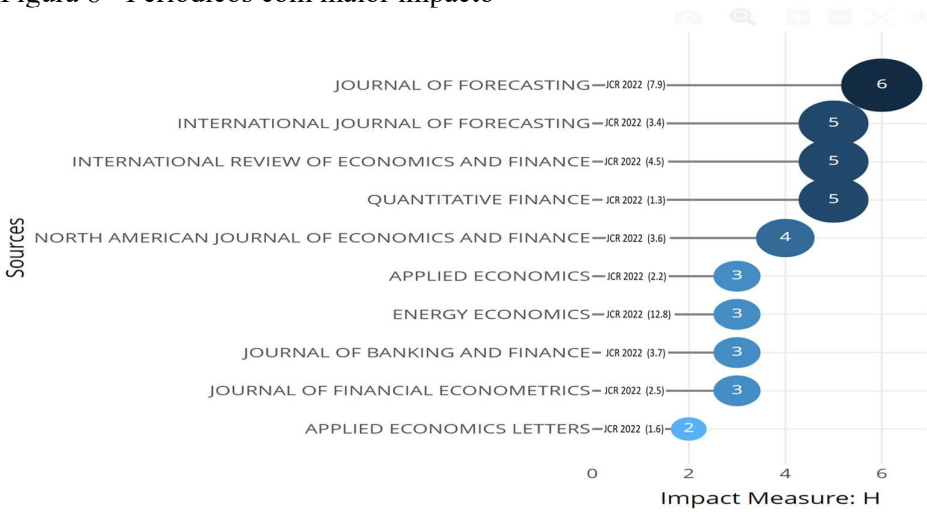
Ainda focado na análise dos periódicos observam-se os *Journals* mais relevantes com base no índice H, destaque para o *International Journal of Forecasting* e o *Journal of Forecasting* (com impacto de 6 e 5, respectivamente) conforme a Figura 8. Destaca-se também a disparidade existente entre o índice H e o índice JCR que avalia os periódicos indexados na base *Web of Science*.

Tabela 6 - Lei de Bradford

Zona	Journal	Quantidade Individual	Quantidade Acumulada	% de acumulação
A	JOURNAL OF FORECASTING	14	14	**15%**
	INTERNATIONAL JOURNAL OF FORECASTING	8	22	**24%**
	INTERNATIONAL REVIEW OF ECONOMICS AND FINANCE	6	28	**30%**
	QUANTITATIVE FINANCE	6	34	**37%**
	NORTH AMERICAN JOURNAL OF ECONOMICS AND FINANCE	5	39	**42%**
	ENERGY ECONOMICS	4	43	**46%**
	JOURNAL OF ECONOMETRICS	4	47	**51%**
	JOURNAL OF FINANCIAL ECONOMETRICS	4	51	**55%**
	JOURNAL OF BANKING AND FINANCE	3	54	**58%**
	EMPIRICAL ECONOMICS	2	56	**60%**
	JOURNAL OF EMPIRICAL FINANCE	2	58	**62%**
	JOURNAL OF RISK	2	60	**65%**
	JOURNAL OF RISK AND FINANCIAL MANAGEMENT	2	62	**67%**
	STUDIES IN NONLINEAR DYNAMICS AND ECONOMETRICS	2	64	**69%**
B	ANNUAL REVIEW OF FINANCIAL ECONOMICS	1	65	**70%**
	APPLIED ECONOMICS	1	66	**71%**
	ECONOMETRIC REVIEWS	1	67	**72%**
	ECONOMETRICA	1	68	**73%**
	ECONOMETRICS	1	69	**74%**
	ECONOMIC MODELLING	1	70	**75%**
	ECONOMIC RESEARCH-EKONOMSKA ISTRAZIVANJA	1	71	**76%**
	ESTUDOS ECONOMICOS	1	72	**77%**
	EUROPEAN JOURNAL OF FINANCE	1	73	**78%**
	FINANCE RESEARCH LETTERS	1	74	**80%**
	GLOBALIZATION AND HIGHER EDUCATION IN ECONOMICS AND BUSINESS ADMINISTRATION - GEBA 2013	1	75	**81%**
	INTERNATIONAL JOURNAL OF FINANCE AND ECONOMICS	1	76	**82%**
	INTERNATIONAL JOURNAL OF FINANCIAL STUDIES	1	77	**83%**
	INTERNATIONAL JOURNAL OF PRODUCTION ECONOMICS	1	78	**84%**
	INTERNATIONAL REVIEW OF FINANCIAL ANALYSIS	1	79	**85%**
	JOURNAL OF APPLIED ECONOMICS	1	80	**86%**
	JOURNAL OF ASIAN ECONOMICS	1	81	**87%**
	JOURNAL OF BUSINESS & ECONOMIC STATISTICS	1	82	**88%**
	JOURNAL OF BUSINESS AND ECONOMIC STATISTICS	1	83	**89%**
	JOURNAL OF FUTURES MARKETS	1	84	**90%**
	PACIFIC BASIN FINANCE JOURNAL	1	85	**91%**
	PROCEEDINGS - 2021 INTERNATIONAL CONFERENCE ON COMPUTER, BLOCKCHAIN AND FINANCIAL DEVELOPMENT, CBFD 2021	1	86	**92%**
	RESEARCH IN INTERNATIONAL BUSINESS AND FINANCE	1	87	**94%**
	RESOURCES POLICY	1	88	**95%**
	REVIEW OF ECONOMICS AND STATISTICS	1	89	**96%**
	REVIEW OF FINANCIAL STUDIES	1	90	**97%**
	REVISTA ECONOMIA	1	91	**98%**
	SOUTH AFRICAN JOURNAL OF ECONOMICS	1	92	**99%**
	STUDIES IN ECONOMICS AND FINANCE	1	93	**100%**

Fonte: elaboração própria, 2022.

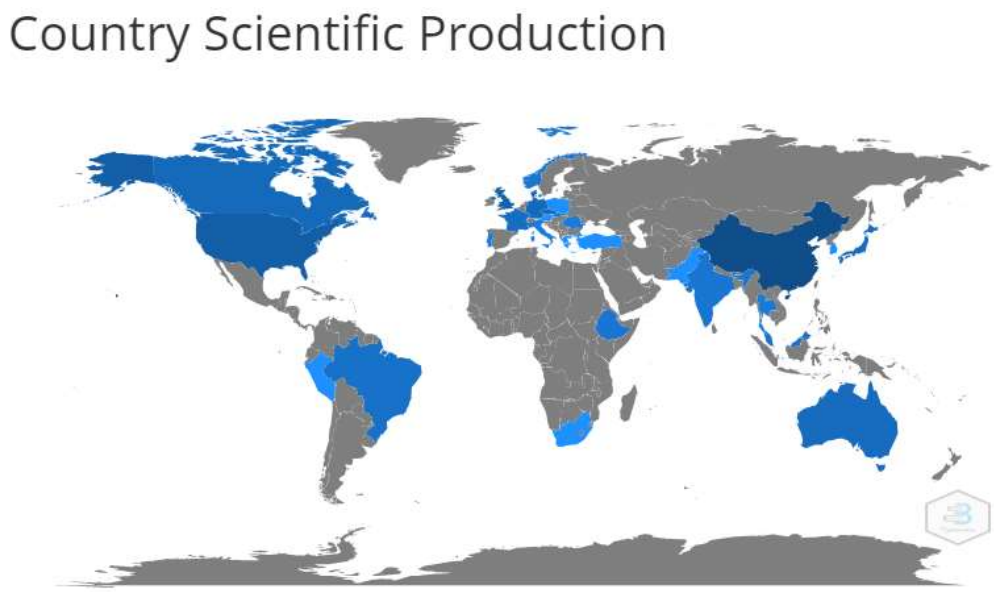
Figura 8 - Periódicos com maior impacto



Fonte: elaboração própria, 2022.

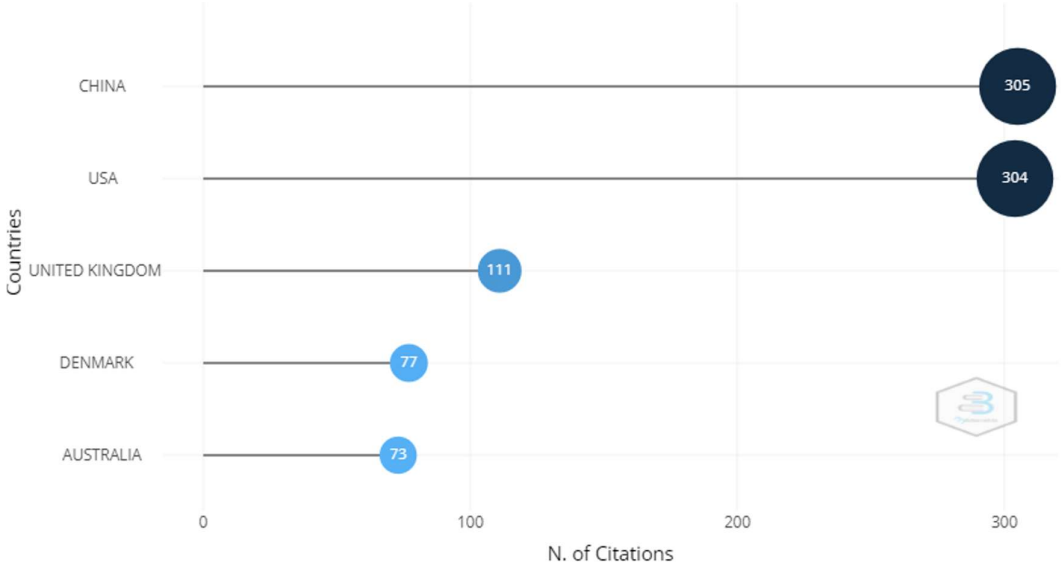
Por último considera-se o volume de publicações de acordo com a região geográfica a que pertencem. Observa-se que os países China e Estados Unidos representam o maior volume de publicações, enquanto a maior parte dos países pertencentes a América Latina e ao Continente Africano foram pouco explorados em pesquisas que abordam o tema. No que diz respeito à quantidade de citações, o cenário permanece semelhante, com o Reino Unido figurando em terceiro.

Figura 9 - Produção científica por país, tonalidade mais escura representando maior quantidade



Fonte: elaboração própria, 2022.

Figura 10 - Países com maior quantidade de citações.



Fonte: elaboração própria, 2022.

2.4 RESULTADOS REVISÃO SISTEMÁTICA

Apoiando a revisão sistemática da literatura busca-se identificar as lacunas do conhecimento relacionadas ao tema deste estudo. Para tanto, na etapa 6 do Capítulo 2 (Revisão sistemática e análise bibliométrica), foi definida uma matriz de (sub) categorização – vide Quadro 2 com definições. Para cada um dos artigos da amostra final, há a identificação de até 5 subcategorias por categoria. A contagem de frequência é feita com base na relação total das subcategorias e não sobre o total dos artigos.

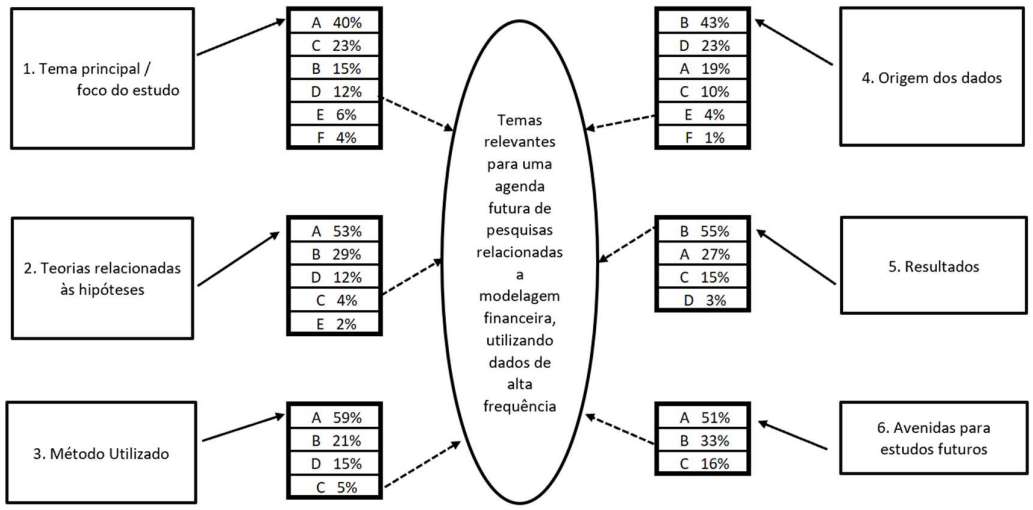
A Figura 11 destaca as subcategorias com maior e menor frequência, potencialmente priorizadas em pesquisas futuras. Para a categoria 1 – "Tema principal/foco do estudo", o que mais se destaca na amostra final é a "Utilização de modelos preditivos tradicionais" (40%), havendo oportunidade para "Variáveis macroeconômicas atuando na volatilidade dos ativos" (12%). Quanto às "Teorias relacionadas às hipóteses", temos que o "Estudo de volatilidade" obtém maior recorrência (53%), enquanto que "Estudo de eventos" se mostra promissor e pouco explorado (4%).

Com relação ao "Método utilizado", temos "Modelo Autorregressivo" como o mais abordado pelas publicações (59%), para a subcategoria "Análise de Jump" temos menor ocorrência (5%), todavia, dado seu embasamento teórico, ela se mostra como relevante a ser explorada mais a fundo dentro do tema abordado. Para a categoria "Origem dos dados"

constatam-se “Estados Unidos e Canadá” como os mais explorados nesse tipo de pesquisa (43%) e oportunidade para aprofundamento de pesquisa para “América Latina” (4%).

Dentro da categoria “Resultados” nota-se que em maior parte foram confirmadas eficácia de modelos e hipóteses novas (55%) ou já existentes (27%), em menor recorrência as pesquisas apresentaram “Resultados não conclusivos” (15%). Para terminar, em relação à perspectiva para estudos futuros, foram apresentados “Alternativas para aprimoramento do modelo” (51%), seguido de “Extensão no uso do modelo para novas finalidades” (33%) e “Utilização do modelo para novas amostras” (16%).

Figura 11 - Análise de categorias e subcategorias para identificar lacunas de conhecimento

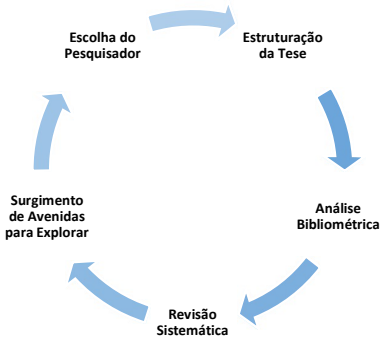


Fonte: elaboração própria, 2022.
Nota:
Subcategoria com maior frequência em cada categoria: ——→
Subcategoria a ser priorizada na agenda de pesquisas futuras: - - - - →

2.5 CONSIDERAÇÕES FINAIS DA ETAPA DE ANÁLISE BIBLIOMÉTRICA E REVISÃO SISTEMÁTICA

Por meio da análise bibliométrica e revisão sistemática, este estudo relata os principais periódicos que trataram o tema, enxergando oportunidades na utilização de dados em alta frequência para modelagem de preços futuros para ativos financeiros. Foram aplicadas as 7 etapas previstas dispondo de duas dentre as principais bases de dados (Scopus e WoS) para o levantamento dos artigos científicos publicados no período entre janeiro de 2015 e agosto de 2022. Dessa forma a pesquisa foi delineada conforme Figura 12:

Figura 12 – Estrutura da pesquisa



Fonte: elaboração própria, 2023.

Os resultados da pesquisa validam as Leis de Zipf que remetem ao uso de palavras-chave, Lei de Lotka remetendo aos autores e Lei de Bradford que diz respeito aos periódicos. Com o uso do *biblioshiny* foi possível identificar as principais palavras-chave e nível de relacionamento dentro dos periódicos, observando-se que, em muitos casos, esses termos se repetem entre os periódicos, o que realça sua relevância dentro do assunto. No que diz respeito aos autores, pode-se apontar quem são os principais pilares atuais dentro do tema, representados pela maior incidência de citações entre os periódicos inseridos neste assunto.

Demonstra-se também uma análise dos periódicos, apontando para os principais *Journals* que publicaram sobre este assunto e sua relevância dentro do tema exposto. No que diz respeito a localidade, constata-se maior incidência de publicações entre os países desenvolvidos (principalmente América do Norte e Europa Ocidental), que apresentam maior disponibilidade de dados facilitando a execução desse tipo de análise.

Após a análise bibliométrica, a pesquisa submete a revisão sistemática dos artigos da amostra final, definindo os principais temas, teorias, métodos, origem de dados, resultados e avenidas para novos estudos. Este tipo de análise é importante na determinação das principais lacunas que podem ser identificadas dentro do tema de estudo. Atendendo ao método aplicado recomenda-se maior reflexão sobre o efeito que as variáveis macroeconômicas exercem sobre a volatilidade dos ativos, assim como o aprofundamento da análise de *jump*, amparadas pela disponibilidade de dados em alta frequência.

Quanto à região abordada existem muitas oportunidades para novas amostras; países da América Latina que apresentam disponibilidade de dados em alta frequência foram pouco observados até o momento.

3 METODOLOGIA

O estudo considera abordagens aplicadas de modo direto para construir, estimar e prever preço para algumas ações com alto volume de negociação na B3, as ações testadas nos modelos foram segmentadas com propósito de compreender alguns dos setores de maior relevância no cenário brasileiro. Angelidis e Degiannakis (2008, p. 464) observam que "Os efeitos dos retornos noturnos e do ruído intradiários nos conjuntos de dados de alta frequência ainda são uma área aberta de estudo". Com isso, neste processo de análise, mesmo ajustes interdiários serão considerados (HANSEN; LUNDE, 2005).

Para cada momento analisado, os modelos serão reestimados com intuito de projetar novas previsões de preços dos ativos. Quanto à frequência de amostragem, Alexander (2008) pontua que deve ser tão alta quanto as características da microestrutura do mercado, cuidando para que não se crie um estimador enviesado. A precisão melhora à medida que a frequência de amostragem aumenta, mas por outro lado, em uma frequência de amostragem alta, os atritos do mercado são uma fonte de ruído adicional na estimativa.

Os parâmetros estimados através dos modelos são utilizados para gerar a previsão dos próximos 20.000 intervalos. Isso significa que a informação até o tempo T é utilizada para prever o período T+1, T+2 e assim por diante até o final da amostra de previsão.

A primeira etapa de testes consiste na aplicação dos modelos preditivos com base no arcabouço econométrico (ARCH, GARCH, ARIMA, ARFIMA e Filtro de Kalman), em seguida passamos para a aplicação dos modelos de *machine learning* para mesma amostra (LSTM e *Transformer*).

Já nessa fase será possível identificar se o modelo possui efetividade na proposta de previsão das séries de preço. Como o objetivo desta pesquisa é comparar diferentes especificações de modelos em termos de habilidade preditiva, necessitamos extrair o valor dos erros observados e proceder com a avaliação comparativa que cada modelo gera.

Na etapa de definição entre os modelos, as previsões serão avaliadas com base na distância quadrada entre o preço real e o projetado, fornecendo evidências a favor do modelo mais aderente. Com o intuito de diminuir os efeitos adversos, realizamos a implantação das funções de perdas robustas contidas no *Model Confidence Set* (MCS). A estimação para os dados provenientes da aplicação da função perda é realizada permitindo que os modelos mais efetivos na previsão de preços sejam destacados.

3.1 MODELOS ECONOMÉTRICOS APLICADOS AO DAF

3.1.1 Modelos ARCH e GARCH

Desenvolvido em Engle (1982), os modelos de heteroscedasticidade condicional autorregressiva (ARCH) presumem alteração na variância condicional ao longo dos períodos, sendo adequados aos estudos de séries financeiras. Esse procedimento reconhece explicitamente a diferença entre a variância incondicional e a condicional, permitindo que esta última mude ao longo do tempo em função de erros passados.

Considerando efeitos simétricos de volatilidade, compreende uma série temporal composta por média e variância, ajustadas a partir de choques aleatórios distribuídos de modo homogêneo. Os modelos ARCH indicam relação entre a variável dependente e a variância condicional através de uma função quadrática expressa em termos de ψ_t com a informação dada no tempo $t-1$:

$$\varepsilon_t|\psi_{t-1} \sim \mathrm{N}(0, h_t),$$
$$h_t = \alpha_0 + \alpha_0 + \alpha_1 y_{t-1}^2 \quad (5)$$

A função de variância é expressa de modo geral como:

$$h_t = \mathrm{h}(y_{t-1} + y_{t-2} + \cdots, y_{t-p}, \alpha) \quad (6)$$

Na qual:
h_t é a variância representada em t;
y é a média condicional;
p é a ordem do processo ARCH;
α é o vetor do parâmetro desconhecido.

O modelo de regressão ARCH é obtido assumindo que y_t é dado por $x_t\beta$, uma combinação linear de variáveis endógenas e exógenas defasadas, incluindo a informação dada por ψ_{t-1} com β sendo um dos parâmetros desconhecidos.

$$y_t|\psi_{t-1} \sim N(\mathrm{x}_t\beta, \mathrm{h}_t),$$
$$h_t = \mathrm{h}(\varepsilon_{t-1}, \varepsilon_{t-2,} \dots, \varepsilon_{t-p,}\alpha),$$
$$\varepsilon_t = y_t - x_t\beta \qquad (7)$$

Em muitas aplicações empíricas para o modelo ARCH se faz necessária a aplicação de uma grande defasagem na equação de variância condicional a fim de se evitar problemas com estimativas de variâncias negativas (ENGLE, 1982). Para otimizar essa questão, obtendo-se memórias mais longas e estruturas mais flexíveis, uma generalização do modelo foi concebida.

O Modelo de heteroscedasticidade condicional autorregressiva generalizada (GARCH) atribui a condição de não negatividade na variância condicional e isso proporciona grande vantagem frente ao modelo ARCH, sendo capaz de descrever a equação com menos parâmetros a partir dos coeficientes de reação e persistência.

O processo GARCH (p, q) (Heteroscedasticidade Condicional Autorregressiva Generalizada) é então dado por:

$$\varepsilon_t \left| \psi_{t-1} \sim \mathrm{N}(0, h_t), \right.$$
$$h_t = \alpha_0 + \sum_{i=1}^{q} \alpha_i \, \varepsilon_{t-i}^2 + \sum_{i=1}^{p} \beta_i h_{t-i}$$
$$h_t = \alpha_0 + A(L)\varepsilon_t^2 + B(L)h_t \qquad (8)$$

Na qual:

ε_t um processo estocástico de tempo discreto com valor real;

ψ_{t-1} o conjunto de informações (α).

$p \geq 0, \qquad q > 0$

$\alpha_0 > 0, \qquad \alpha_i \geq 0, \qquad i = 1, \dots, q,$

$\beta_i \geq 0, \qquad i = 1, \dots, p.$

Para $p = 0$ o processo se reduz ao processo ARCH(q) e, para $p = q = 0$, ε_t é simplesmente ruído branco. No processo ARCH(q) a variância condicional é especificada como uma função linear apenas de variações de amostras anteriores, enquanto o processo GARCH(p, q) também permite a entrada de variações condicionais defasadas. Isso corresponde a algum tipo de mecanismo de aprendizagem adaptativo.

O modelo de regressão GARCH(p,q) é obtido deixando o ε_t ser inovações em uma regressão linear,

$$\varepsilon_t = y_t - x'_t b, \tag{9}$$

Na qual:

y_t é a variável dependente;

x_t um vetor de variáveis explicativas;

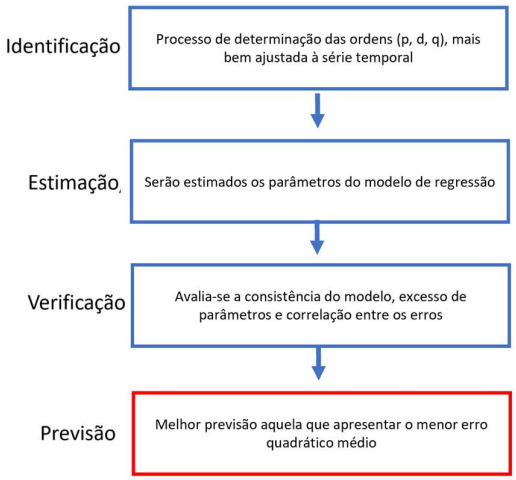
b um vetor de parâmetros desconhecidos.

3.1.2 Modelos ARIMA e ARFIMA

O modelo autorregressivo integrado de médias móveis (ARIMA) foi proposto por Box e Jenkins (1976), derivado do modelo de média móvel autorregressivo (ARMA). Este modelo é reconhecido por sua abrangência, podendo lidar com séries não estacionárias além de elementos sazonais.

Geralmente está apresentado com a notação ARIMA(p,d,q) representando a ordem do modelo, proveniente da combinação de três componentes: componente Autorregressivo (AR), Ordem de Integração (I) e Médias Móveis (MA). Para aplicação do modelo ARIMA se faz necessária a realização de quatro etapas: identificação, estimação, verificação e previsão (BOX; JENKINS, 1976).

Figura 13 – Etapas Modelo ARIMA



Fonte: elaboração própria, 2023.

A fase inicial abrange o processo de determinação das ordens (p, d, q), tal como a ordem mais bem ajustada à série temporal; em seguida, na fase de estimação serão estimados os parâmetros do modelo de regressão. Para a etapa da verificação avalia-se a consistência do modelo, excesso de parâmetros e correlação entre os erros. Por último, na etapa de previsão, essa pesquisa considera como a melhor previsão aquela que apresentar o menor erro quadrático médio.

ARIMA (p,d,q) $$\Delta^d y_t = \beta_0 + \beta_1 \Delta^d y_{t-1} + \cdots + \beta_p \Delta^d y_{t-p} + \varepsilon_t - \theta \varepsilon_{t-1} \ldots, \quad (10)$$

na qual:
p = número de defasagens autorregressivas;
d = ordem de diferenciação para tornar os dados estacionários;
q = número de defasagens de média móvel.

O segundo modelo autorregressivo integrado de médias móveis a ser testado, modelo ARFIMA se distingue em relação ao processo de modelagem ARIMA por permitir o estudo de memória longa e dinâmica de curto prazo, apropriado, portanto, a uma série de dados em alta frequência (ANDERSEN et al., 2001a, 2001b, 2003, 2006).

Estudos mais recentes consideram o modelo ARFIMA (p, d', q) para captura da volatilidade realizada; sua modelagem se assemelha com o processo ARIMA, adicionando a possibilidade de o parâmetro de diferenciação assumir números reais fracionados entre 0 e 1 (CHEUNG, 1998). Além disso, os modelos ARFIMA auxiliam na resolução do problema do baixo poder contido nos testes de raiz unitária tradicional.

Portanto, para este modelo, o termo F representa "fração" com os intervalos utilizados para séries ARFIMA pressupondo normalidade e conhecimento dos parâmetros. Dentre os métodos de estimação dos modelos ARFIMA, os mais comuns são: Máxima Verossimilhança Exata *(Exact Maximum Likelihood* – EML), Perfil Modificado de Verossimilhança *(Modified Profile Likelihood* - MPL) e Mínimos Quadrados Não Lineares *(Nonlinear Least Squares* – NLS).

Se o parâmetro d' estiver entre -0,5 < d' < 0,5, o processo é estacionário e invertível. Para d'=1 o processo seguirá uma raiz unitária. Se 0 ≤ d' ≤ 0,5, o processo mostra dependência positiva entre observações distantes e a série é estacionária. Se -0,5 <d' <0, o processo demonstra dependência negativa entre observações distantes e é estacionário com memória intermediária

(HOSKING, 1981). Se $0{,}5 < d' \leq 1$, a série não é estacionária, mas permanece com reversão à média.

$$\text{ARFIMA } (\mathrm{p}, d', q) \tag{11}$$

na qual:

p = Número de defasagens autorregressivas;

d' = ordem de diferenciação (podendo assumir números fracionários);

q = número de defasagens de média móvel.

Com base na revisão crítica sobre a modelagem de volatilidade realizada feita por McAleer e Medeiros (2008a, b), verifica-se eficácia do modelo em se prever volatilidade realizada um dia de negociação à frente. Além disso, apresenta resultados robustos partindo de características fáceis de implementar, dado o número reduzido de parâmetros (GIOT; LAURENT, 2004). Essas razões fazem com que o ARFIMA apresente representações superiores na modelagem da volatilidade variável no tempo (CORSI et al., 2008).

3.1.3 Filtro de Kalman

O Filtro de Kalman foi apresentado em 1960 com a finalidade de uso para área de controle e comunicação, sendo adaptado posteriormente a novas áreas. Sua propriedade de estimar o estado instantâneo de um sistema dinâmico linear com ruído branco possibilitou progresso no controle de complexos sistemas dinâmicos com processos contínuos como manufatura, aviões, navios e espaçonaves (GREWAL; ANDREWS, 2008).

A estimação de uma série financeira em alta frequência através do Filtro de Kalman se justifica pelo fato de possibilitar a combinação entre os dados disponíveis com instrumentos de medições anteriores, o que minimiza o erro quadrático produzido para estimativa da variável desejada (MAYBECK, 1979).

Podemos citar trabalhos que utilizaram esse modelo na área de finanças como o de Burmeister, Wall e Hamilton (1986) que aplicam a técnica estimando inflação futura com base em taxas de inflação e juros passadas. Já na pesquisa de Wu (1995), utiliza-se essa técnica para verificar existência de bolhas nas taxas de câmbio.

Segundo Eubank (2006), a serventia do Filtro de Kalman se evidencia na estimativa de valores não observáveis em sistema estado-espaço. Para um sistema dinâmico, as variáveis observáveis são representadas por funções dinâmicas de variáveis não observáveis, enquanto as variáveis de estado não podem ser aplicadas diretamente para as variáveis observáveis (THOMAKOS; WANG, 2003). Essa modelagem para sistemas dinâmicos é definida como método estado-espaço, representada por:

$$y_t = H.\mathcal{E}_t + A.x_t + \mu_t \tag{12}$$

$$\mathcal{E}_{t+1} = \mathrm{F}.\mathcal{E}_t + B.x_{t+1} + v_t \tag{13}$$

na qual:

y_t = matriz n x 1 de variáveis observáveis;

$\mathcal{E}_t$ = matriz r x 1 de variáveis de estado;

x_t = matriz k x 1 de variáveis exógenas;

H, A, F e B = matrizes de coeficientes de dimensões n x r, n x k, r x r, e r x k respectivamente;

μ_t e v_t= matrizes dos resíduos de dimensões n x 1 e r x 1, respectivamente e covariâncias $Cov(\mu_t.\mu_t) = R$ $\quad Cov(v_t.v_t) = \mathrm{Q}$ $\quad Cov(\mu_t.v_t) = 0$.

A equação (12) é chamada de equação de medida e a equação (13) é chamada de equação de transição. O funcionamento do filtro ocorre em três etapas: previsão, atualização e refinamento.

Na primeira etapa (previsão), se prevê o vetor $\mathcal{E}_{t+1}$ e sua matriz de covariância $P_{t|t+1}$ a partir das informações disponíveis em $t-1$ gerado em uma estimativa para y_t da seguinte maneira:

$$\begin{aligned}
&\mathcal{E}_{t,t-1} = \mathrm{F}.\mathcal{E}_{t-1|\mathrm{t}-1} \\
&\mathrm{P}_{t,t-1} = \mathrm{F}.\mathrm{P}_{t-1|\mathrm{t}-1}.F' + Q \\
&\mathrm{y}_{t|t-1} = \mathrm{H}.\mathcal{E}_{t|\mathrm{t}-1} + A.\mathrm{x}_{t|t-1}
\end{aligned} \tag{14}$$

Na etapa seguinte, a atualização, $\mathcal{E}_t$ é atualizado com valor observado de:

$$\psi_t = \mathrm{H}.P_{t|\mathrm{t}-1}.H' + R$$
$$\mathrm{K}_t = P_{t|\mathrm{t}-1}.H'.(\psi_t)^{-1}$$
$$\mathcal{E}_t = y_t - y_{t|\mathrm{t}-1}$$
$$\mathrm{P}_{t,t} = (\mathrm{I} - K_t.H)P_{t|\mathrm{t}-1} \quad (15)$$

Na qual K_t é o ganho do filtro de Kalman, ψ_t pode ser considerado como a grande matriz de variância/covariância do sistema e $\mathcal{E}_t$ é o vetor de resíduos do sistema. A estimação do filtro de Kalman é contínua. A função de densidade condicional é:

$$f(\mathrm{y}_t|\mathrm{I}_{t-1}) = (2\pi)^{-\frac{n}{2}}.\left|\psi_t\right|^{-\frac{1}{2}}.\exp\left(-\frac{\mathcal{E}'_t.\psi_t.\mathcal{E}_t}{2}\right) \quad (16)$$

Na qual I_{t-1} é o conjunto de informações em $t-1$. O filtro de Kalman pode ser estimado maximizando o logaritmo da verossimilhança da função densidade:

$$Max\sum_{t=1}^{T}\log f(\mathrm{y}_t|\mathrm{I}_{t-1}) = -\frac{nT}{2}\log(2\pi) + max\left(-\frac{1}{2}\sum_{t=1}^{T}\{log(\psi_t) + (\mathcal{E}'_t.\psi_t.\mathcal{E}_t)\}\right. \quad (17)$$

Na etapa de previsão, as estimativas são realizadas utilizando-se somente as variáveis de estado, contudo se faz necessário considerar também as variáveis observáveis e, por isso, é realizada uma interação com as variáveis na etapa de atualização (THOMAKOS; WANG, 2003).

O uso das variáveis de estado permite estimar e revelar o processo estocástico dominante em y_t, o que só é possível comparando seu valor atual com valor estimado pelas variáveis de estado. A correção do erro correspondente é feita através da atualização das variáveis de estado para que acompanhem o sistema dinâmico, fazendo com que a relação entre esse tipo de variáveis e as variáveis observáveis sejam mantidas (THOMAKOS; WANG, 2003).

A última etapa, o refinamento, é aplicada quando existir interesse de conhecer as estimativas de variáveis de estado em qualquer tempo, dadas informações disponíveis até o tempo T (THOMAKOS; WANG, 2003). O Processo de refinamento atualiza as variáveis de estado anteriores a partir de $T-1$, dado pelas equações:

$$\varepsilon_{t,T} = \varepsilon_{t|\mathrm{t}} + \mathrm{V}_t(\varepsilon_{t+1|\mathrm{T}} - \varepsilon_{t+1|\mathrm{t}}) \quad (18)$$
$$P_{t,T} = P_{t|\mathrm{t}} + \mathrm{V}_t\left(P_{t+1|\mathrm{T}} - P_{t+1|\mathrm{t}}\right)\mathrm{V}'_t \quad (19)$$

Na qual $V_t = P_{t|t}.F'.P^{-1}_{t+1|t}.\varepsilon_{t,T}$ é a inferência de ε_t baseada em toda a amostra e $P_{t,T}$ é a sua matriz de covariância.

3.2 MODELOS *MACHINE LEARNING* APLICADOS AO DAF

3.2.1 LSTM

As Redes Neurais Artificiais (RNAs) são uma família de redes neurais para processar dados sequenciais. Consistem em instrumentos de programação capazes de simular redes neurais biológicas mediante conexões com pesos com base em interações de estímulos externos (GOODFELLOW; BENGIO; COURVILLE, 2016).

Seguidamente temos as Redes Neurais Recorrentes (*Recurrent Neural Network* - RNNs), elas se distinguem pela capacidade de processar dados permitindo aprendizagem com experiências anteriores. Sua facilidade em incorporar ciclos a seus algoritmos viabiliza aplicações para tarefas sequenciais como linguagem e séries temporais (SANTOS; CHAUCOSKI, 2020). As RNNs podem ser aplicadas para solucionar diversos desafios, entretanto são limitadas a considerar 10 períodos anteriores em sua análise ocorrendo perda no sinal de retroalimentação (WERBOS, 1990).

Essa questão foi resolvida com o *Long Short Term Memory* (LSTM), capaz de aprender mais de 1.000 períodos de tempo, dependendo da complexidade da rede construída (STAUDEMEYER; MORRIS, 2019). Uma célula LSTM é baseada em uma célula de memória contendo portas (*gates*) regulando o fluxo de informação com capacidade de adicionar, descartar ou atualizar informações no tempo propondo-se a melhor previsão de estados futuros (NELSON et al., 2018; GRAVES; WAYNE; DANIHELKA, 2014).

Um neurônio LSTM (célula) trabalha com uma sequência de entrada x_t com cada porta (*gate*) utilizando unidades de ativação para controlar se elas são acionadas ou não; seu acionamento ocasiona mudança de estado ou adição de informações através da célula. Existem três portões para o modelo:

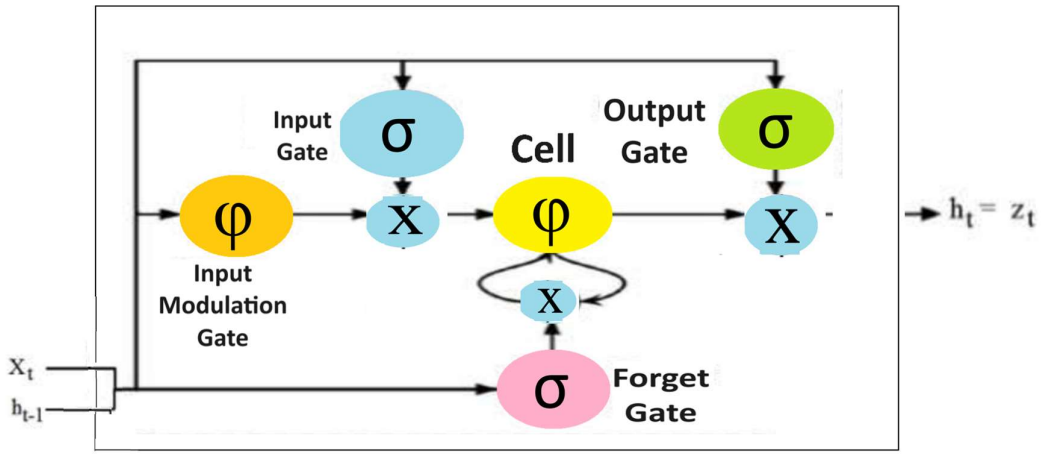
1. Portão de esquecimento: responsável por remover informações que não são mais úteis. Duas entradas: x_t (entrada no momento específico) e h_{t-1} (saída de célula anterior) são alimentadas ao portão e multiplicadas por matrizes de peso, seguidas pela adição do viés.

O resultante é passado por uma função de ativação fornecendo uma saída binária que indicará se a informação será esquecida ou retida.

2. Portão de entrada: a adição de informações úteis ao estado da célula é feita por esse portão (*input gate*). A informação é regulada com filtro dos valores a serem lembrados. Em seguida um vetor é criado utilizando a função tanh que dá saída de -1 a +1, contendo os valores possíveis de h_{t-1} e x_t. Os valores do vetor e valores regulados são multiplicados para obtenção das informações úteis.

3. Portão de saída: objetiva extrair informações para apresentar como saída (*output gate*). Um vetor é gerado e então regulado com base em filtros dos valores a serem lembrados utilizando as entradas h_{t-1} e x_t. Os valores do vetor e regulados são multiplicados para serem enviados como saída h_t e entrada para a próxima célula (DSA, 2022).

Figura 14 – Arquitetura LSTM



LSTM

Fonte: Goodfellow, Bengio e Courville (2016).

Apesar das vantagens citadas para o LSTM, seu desempenho nem sempre é satisfatório por não representar os recursos complexos de dados sequenciais. Principalmente quando utilizados para aprender dados de séries temporais longos ou com ausência de linearidade (SAGHEER; KOTB, 2019), por isso se faz necessário averiguar quais características serão encontradas para predição da série em análise.

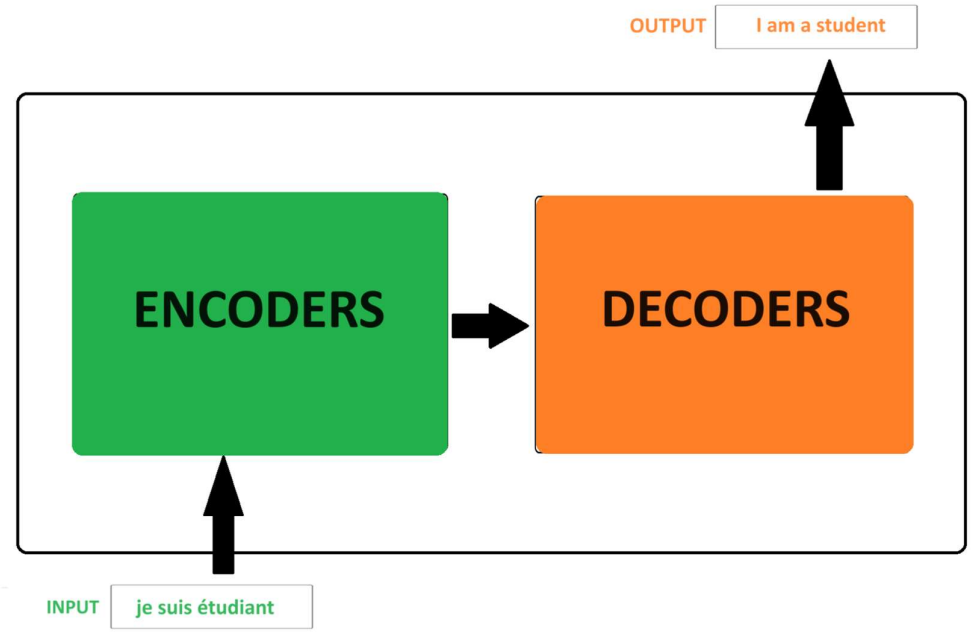
3.2.2 *Transformer*

Ainda que as RNNs e suas redes LSTM possuam efetividade, elas conservam limitação com estruturas não seriais por seu caráter de aprendizagem (RIZVI et al., 2020). Em situações concebidas nesse contexto de dados, tipo sequência para sequência ou até séries muito longas, dispõe-se da arquitetura *Transformer*, que vem apresentando resultados satisfatórios. Proposta por Vaswani et al. (2017), a arquitetura *Transformer* conta com mecanismo de atenção, permitindo observação de todos os elementos fornecidos na entrada (não apenas o mais recente).

O mecanismo de autoatenção é capaz de capturar longas cadeias de dependência em sequência de dados que podem ser informados de modo estruturado ou não. Essa mecânica aprimora o desempenho do modelo de duas formas: expansão do modelo para foco em diferentes posições e obtenção de múltiplas noções de atenção.

Na arquitetura *Transformer* temos o módulo *Encoder* (Codificador) e *Decoder* (Decodificador), ambos contendo Mecanismo de atenção em suas camadas que são parametrizadas com transformação linear (*Multi-Headed attention*).

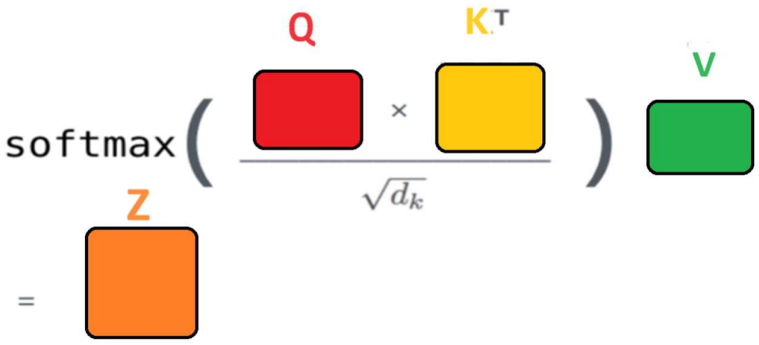
Figura 15 – Arquitetura *Transformer*



Fonte: Alammar (2022).

O módulo Decodificador conta com mecanismos de atenção capazes de aprender as relações produzidas pelo próprio decodificador. Possui adicionalmente uma camada linear destinada a decodificar os vetores de contexto e uma camada Softmax que tem por finalidade a conversão da saída em probabilidades, no qual a palavra com maior probabilidade é a saída produzida "n" vezes até que o resultado seja obtido. O processo de decodificação deverá ser chamado a quantidade de vezes necessárias até obtenção da saída satisfatória, representando o fim da sequência. Uma função de atenção é definida pelo mapeamento de uma consulta Q, um conjunto de pares K e valor V para uma saída Z.

Figura 16 – Camada de Atenção *Transformer*



Fonte: Alammar (2022).

Já o módulo Codificador recebe um vetor de valores como entrada convertida para vetor de *embedding*, soma-se a ele um codificador posicional baseado nas funções de seno e cosseno com propósito de o transformar em um vetor contextualizado pela posição (a mesma palavra em posições distintas pode assumir significados diferentes). O contexto é essencial para o funcionamento da arquitetura.

Após essas etapas, conexões residuais são implementadas entre as camadas de autoatenção quando se busca estabilizar o treinamento das redes, bem como reduzir o tempo gasto. Por fim o resultado é apontado de modo conjunto podendo se transformar em dado de entrada para camada de codificação subsequente.

3.3 AVALIAÇÃO DA PERFORMANCE DOS MODELOS

Após aplicação dos modelos econométricos e de *machine learning* enumerados anteriormente, a pesquisa se propõe a determinar os modelos mais efetivos, contando com maior

poder de predição quando aplicados aos dados em alta frequência. Mesmo que os modelos estejam todos bem especificados podem apresentar baixo desempenho em sua execução.

3.3.1 *Model Confidence Set*

O procedimento *Model Confidence Set* (MCS) será escolhido para se estabelecer os melhores resultados dentre os testes realizados. Originado por Hansen, Lunde e Nason (2011), o MCS e sua aplicação permitem comparar habilidade preditiva de vários modelos de modo simultâneo. Essa técnica é desempenhada através da comparação entre os moodelos, através da função de perda, que permite identificar o menor erro apresentado entre os valores projetados fora da amostra.

Sua metodologia permite análise de até 150 modelos em sincronia e é aplicada através de métodos de *bootstrap* (na qual a estatística de teste é construída a partir da estatística t), isso afasta a necessidade de um estimador explícito para uma matriz de covariância de dimensão elevada (HANSEN; LUNDE; NASON, 2003).

Os modelos são indexados por i $= 1, \ldots, m$ e denota-se $M^0 = \{1, \ \ldots, m\}$ como o conjunto dos modelos para os quais fazemos a previsão um passo à frente da covariância condicional. O MCS permite identificar um subconjunto de modelos, M^*, os quais são superiores, em termos de habilidade preditiva, com respeito a todos os outros modelos em M^0(LAURENT; ROMBOUTS; VIOLANTE, 2012).

Tal procedimento é baseado em um teste de equivalência (δ_M) e em uma regra de eliminação (e_M). A cada passo, o teste de equivalência é aplicado, primeiramente se assumindo como a hipótese nula que todos os modelos em M^0 são iguais em termos de habilidade preditiva. Se essa hipótese nula é rejeitada, a regra de eliminação remove o modelo com pior performance.

Esse processo é repetido até que, no subconjunto de modelos restante, o teste de equivalência não seja rejeitado. Portanto, o conjunto de modelos "sobreviventes" é o *Model Confidence Set.*

3.4 BANCO DE DADOS

No decorrer deste estudo, os dados foram coletados diretamente da B3. A aplicação empírica deste trabalho é embasada em dez ações do mercado brasileiro, escolhidas por serem as de maior liquidez durante o período analisado, sendo:

Quadro 3 – Base de dados para aplicação empírica

EMPRESA	TICKER
CIA CERVEJARIA DAS AMÉRICAS	ABEV3
B3 ON	B3SA3
BANCO DO BRASIL ON	BBAS3
BANCO BRADESCO PN	BBDC4
ITAUSA PN	ITSA4
BANCO ITAU ON	ITUB3
BANCO ITAU PN	ITUB4
PETROBRAS ON	PETR3
PETROBRAS PN	PETR4
CIA VALE DO RIO DOCE	VALE3

Fonte: elaboração própria, 2023.

Para esta pesquisa será considerada a totalidade de observações no ano de 2022, coletadas em base de milissegundos. Atualmente o horário de negociação na B3 está compreendido entre 10h e 16h59 e a captação do sistema possui frequência a cada milissegundo, isso representa robustez na amostra a ser analisada.

Os dados foram divididos em dois segmentos, sendo 80% das observações para estimação e treinamento e 20% para os testes dos modelos. Para esta etapa foram utilizadas as classes de modelos univariados ARCH, GARCH, ARIMA, ARFIMA, e filtro de Kalman. Também foram testadas configurações diferentes de rede neural LSTM e *Transformer*.

Após o processo de extração dos dados foi realizada equivalência entre as séries, restando apenas as últimas observações comuns entre elas. Apoiado nessa amostra de dados final foi possível executar os testes propostos.

As negociações das ações, não ocorrem continuamente, havendo lacunas de negociação, embora exista o preço. Quando existia uma lacuna de preço, entre dois intervalos de tempo, ela foi completada com o último preço negociado.

Após o tratamento das lacunas, as séries de dados foram colapsadas em seu último preço negociado, no final de cada minuto. Para o preenchimento, foi considerado o aspecto de preencher, “para frente”, sempre em direção ao final da amostra. Assim, obteve-se quantidades de observações diferentes para cada ação analisada. O total de observações foi de:

Tabela 7 – Total de observações por ativo

Ticker	Total de Observações
ABEV3	73.781
B3SA3	95.719
BBAS3	96.143
BBDC4	96.120
ITSA4	96.242
ITUB3	76.450
ITUB4	95.885
PETR3	95.606
PETR4	95.853
VALE3	95.906

Fonte: elaboração própria, 2023.

3.5 MÉTODOS DE ESTIMAÇÃO

Para cada série de tempo de preços de cada ação, para projeção dos preços, foram utilizados os métodos arch, garch, arima, arfima, filtro de Kalman, transformer, lstm e random walk. Foram utilizadas as vinte mil observações mais recentes para estimação dos modelos, sendo oitenta por cento dos dados (dezesseis mil observações) para treinamento dos modelos e vinte por cento (quatro mil observações) para projeção e testes.

Na etapa de testes, através de um procedimento de ensaio utilizando-se primeiramente a amostra completa dos dados e em seguida uma amostra contendo vinte mil observações, foi possível constatar que a amostra menor de dados produziu maior assertividade (traduzido pela estatística menor RMSE) na captura dos modelos (otimizando-se a dinâmica dos dados).

Após a etapa de estimações e projeções, quatro mil observações de erros para cada ação (geradas com os modelos estimados) foram classificadas em ordem crescente segundo seu erro quadrático médio. A partir dessa apuração, os cento e cinquenta modelos que apresentaram menores erros passam a ser analisados pelo model confidence set.

Foi utilizado de 1 lag de defasagem para aplicação dos modelos. Essa critério foi adotado analisando-se as autocorrelações, autocorrelações parciais e autocorrelogramas conforme

utilização do processo de Box-Jenkins (Hamilton, 1994). Sendo assim, os modelos tiveram as seguintes configurações para que pudessem produzir suas projeções:

- **Arch**: foi utilizado 1 lag para o termo autorregressivo
- **Garch**: foram utilizados 1 lag para o termo autorregressivo e 1 lag para a média móvel;
- **Arima**: foi utilizada a configuração de um lag para o termo autorregressivo, 1 lag para o termo de média móvel, sendo o melhor modelo, escolhido pelo critério de Akaike (AIC) e uma diferenciação para indução de estacionariedade na série, apontado pelo teste de presença de raiz unitária de Dickey-Fuller (1979).
- Para as redes **lstm**, foram utilizadas arquiteturas com duas e três layers, cada uma tendo de 1 até 10 perceptrons, com learning rate variando de 0.01 até 0.25, em múltiplos de 0.05, com optimizador Adam e ativação *Rectifier Linear Unit* (relu).
- O **filtro de Kalman** foi utilizado com dinâmica linear, com inicialização das matrizes de transição de estado e a de covariância, com zeros, dado que o processo é iterativo.
- A arquitetura **transformer:** utiliza muitos hiper parâmetros, mas os principais foram batch size =100, epochs = 100, learning rate = 0.001, Moving window = 1000, heads = 3, optimizer adam.

4 RESULTADOS

Esta seção apresenta os resultados da aplicação empírica do procedimento *Model Confidence Set* para avaliação da previsão de volatilidade entre diferentes modelos. É importante destacar que os resultados em termos do MCS são específicos para o período amostral e para o conjunto de modelos analisados (LAURENT; ROMBOUTS; VIOLANTE, 2012).

O quadro 4 apresenta os resultados do MCS para a função perda aplicada aos modelos. O p-valor é obtido através da implementação em bloco do MCS. No caso da *range statistic*, a análise do p-valor aos níveis de significância de 0.01 e 0.05, mostra as especificações incluídas no modelo.

Quadro 4 – Melhores modelos preditivos com base no critério MCS

	AÇÕES ANALISADAS									
MODELO	ABEV3	B3SA3	BBAS3	BBDC4	ITSA4	ITUB3	ITUB4	PETR3	PETR4	VALE3
ARCH			✓			✓				✓
GARCH		✓	✓							
ARIMA	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓
ARFIMA	✓	✓	✓	✓		✓		✓	✓	✓
TRANSFORMER								✓	✓	
RANDOM WALK		✓	✓			✓		✓	✓	✓

Fonte: elaboração própria, 2023.

5 ANÁLISE DOS RESULTADOS

Após utilização do critério MCS revela-se os melhores conjuntos de modelos para estimação de cada ação. Com base no exposto pelo quadro 4 observa-se que:

- os modelos clássicos de volatilidade, arch e garch, não conseguiram superar outros dois modelos tradicionais, arima e arfima, os quais estiveram presentes em todos os conjuntos de melhores modelos apontados pelo MCS;
- o modelo transformer foi capaz de identificar e modelar a dinâmica para duas ações;
- o modelo Random Walk foi superado em quatro situações, conseguindo estar presente nos outros conjuntos finais contendo os melhores modelos;
- O filtro de Kalman, embora tenha identificado a dinâmica dos preços, não produziu resultados suficientes para estar nos conjuntos finais contendo os melhores modelos;
- dentre as descobertas, temos que os modelos lstm não foram capazes de identificar a dinâmica de trajetória para nenhum ativo analisado;

Uma das possibilidades de explicação dos resultados obtidos é a dificuldade de se modelar séries de tempo utilizando dados que apresentam instabilidade de tendência e ciclo, instabilidade paramétrica e a presença de ruídos nos dados. O colapsamento dos dados de milissegundos para minutos reduziu significativamente a instabilidade paramétrica, apresentando convergência de estimadores em todos os casos. Esse comportamento não foi evidenciado utilizando-se os dados em suas frequências puras (milissegundos), nem quando colapsados para segundos.

Com base nos parâmetros propostos e amostragem obtida, pode-se concluir que os modelos arima e arfima foram os que apresentaram melhor performance entre todas as classes de modelos estimados.

6 CONSIDERAÇÕES FINAIS

O desenvolvimento acelerado evidenciado no mercado financeiro favorece o surgimento de ferramentas destinadas em analisar as novas informações. Com a chegada desse novo ambiente dinâmico, analistas e formuladores de políticas que lidam com esse meio demandam por maior conhecimento teórico e prático.

Esta tese foi desenvolvida com o objetivo de incentivo e auxílio às novas pesquisas relacionadas à utilização de dados em alta frequência para aprimorar a previsibilidade dos ativos financeiros. Dispor de modelos que assimilam com efetividade os dados em alta frequência representa um grande avanço no mercado financeiro.

A utilização do *Model Confidence Set* (MCS) para seleção dos modelos em termos de habilidades preditivas vem recebendo grande atenção no período recente devido sua capacidade em indicar se as performances de previsão são significativamente diferentes entre as especificações de modelos.

O conjunto de modelos incluídos no MCS apresenta igual habilidade preditiva, dado um nível de confiança. Essa metodologia mostra-se adequada para aplicação empírica sobre preços de ativos disponíveis na Bolsa de valores brasileira. Contudo, notamos que a escolha de um modelo assumido como o melhor deve ser realizada de acordo com o período analisado, condicionado, portanto, a amostra de dados.

Após avaliação, pode-se assinalar a preferência por modelos econométricos frente as hipóteses de machine learning.

Dentro o conjunto de modelos econométricos tradicionais, destaque para efetividade encontrada com o modelo ARIMA, presente dentre modelos mais eficazes para todos os ativos. O modelo ARFIMA se coloca como o segundo mais eficaz, estando representado na análise de oito ativos. Para os demais modelos econométricos ainda foi evidenciado efetividade para o modelo ARCH e GARCH em três e dois ativos respectivamente, o filtro de Kalman não obteve performance suficiente dentre os parâmetros deliberados para nenhum ativo testado.

Na segunda etapa de testes, utilizando-se modelos de machine learning, o modelo Transformer foi efetivo para apenas dois ativos enquanto que o modelo LSTM não figura dentre os melhores modelos para amostra testada.

Por último a hipótese de imprevisibilidade no preço dos ativos, o Random Walk, esteve presente para seis dentre os dez ativos possíveis demonstrando dinamismo para as séries de preços analisadas.

Dentro da abordagem e análise proposta busca-se fornecer maior subsídio na tomada de decisões dos agentes, esclarecendo algumas das lacunas e tópicos relacionados além de fomentar uma agenda futura a ser explorada. Uma extensão dessa pesquisa sugerida seria a análise de pair trading entre as ações coletas a fim de se possibilitar modelagem futura considerando dois ativos diretamente correlacionados.

A baixa incidência dos modelos machine learning (lstm e transformer) no quadro 4 sugere que eles não conseguirem captar com eficiência a dinâmica dos dados para frequências muito altas. Com isso, uma outra possibilidade de continuação para pesquisa seria experimentar abordagem através de outros modelos machine learning como por exemplo Prophet, Nhits e Nbeats.

REFERÊNCIAS

ALAMMAR, J. *The illustrated transformer*. 2018. Disponível em: http://jalammar.github.io/illustrated-transformer/. Acesso em: 07 dez. 2023.

ALEXANDER, C. O. *Market risk analysis*: quantitative methods in finance. New York: John Wiley and Sons, 2008. (Volume 1).

ANDERSEN, T.; BOLLERSLEV, T. DM-dollar volatility: intraday activity patterns, macroeconomic announcements and longer-run dependencies. *Journal of Finance,* [S.l.], v. 53, n.1 , p. 219-265, 1998.

ANDERSEN, T.; BOLLERSLEV, T. Intraday periodicity and volatility persistence in financial markets. *Journal of Empirical Finance*, [S.l.], v. 4, n. 2-3, p. 115-158, 1997.

ANDERSEN, T.; BOLLERSLEV, T.; CHRISTOFFERSEN, P.; DIEBOLD, F. X. Volatility and correlation forecasting. In: ELLIOTT, G.; GRANGER, C. W. J., TIMMERMANN, A. (Eds.). *Handbook of economic forecasting*. Amsterdam: North Holland Press, 2006.

ANDERSEN, T.; BOLLERSLEV, T.; DIEBOLD, F. X. Parametric and nonparametric volatility measurement. In: HANSEN, L. P., AÏT-SAHALIA, Y. (Eds.). *Handbook of financial econometrics*. Amsterdam: North Holland, 2002.

ANDERSEN, T.; BOLLERSLEV, T.; DIEBOLD, F. X.; EBENS, H. The distribution of realized stock return volatility. *Journal of Financial Economics*, [S.l.], v. 61, n. 1, p. 43-76, 2001a.

ANDERSEN, T.; BOLLERSLEV, T.; DIEBOLD, F. X.; LABYS, P. Modeling and forecasting realized volatility. *Econometrica*, [S.l.], v. 71, n. 2, p. 579-625, 2003.

ANDERSEN, T.; BOLLERSLEV, T.; DIEBOLD, F. X.; LABYS, P. The distribution of realized exchange rate volatility. *Journal of the American Statistical Association*, [S.l.], v. 96, n. 453, p. 42-55, 2001b.

ANDERSEN, T.; BOLLERSLEV, T.; LANGE, S. Forecasting financial market volatility: sample frequency vis-à-vis forecast horizon. *Journal of Empirical Finance*, [S.l.], v. 6, n. 5, p. 457-477, 1999.

ANDERSEN, T.; BOLLERSLEV, T.; MEDDAHI, N. Correcting the errors: volatility forecast evaluation using high-frequency data and realized volatilities. *Econometrica*, [S.l.], v. 73, n. 1, p. 279-296, 2005.

ANGEL, J. J.; MCCABE, D. Fairness in financial markets: the case of high frequency trading. *Journal of Business Ethics*, [S.l.], v. 112, n. 1, p. 585-595, 2013.

ANGELIDIS, T.; DEGIANNAKIS, S. Volatility forecasting: intra-day vs. inter-day models. *Journal of International Financial Markets*, Institutions and Money, [S.l.], v. 18, p. 449-465, 2008.

ARAUJO, A. C. D.; MONTINI, A. A. High frequency trading: abordagem clássica para análise de preço-volume em uma nova microestrutura de mercado. *In*: SEMINÁRIOS EM ADMINISTRAÇÃO, 16., 2013, *Anais* [...]: Semead, 2013.

BAGEHOT, W. The only game in town. *Financial Analysts Journal*, [S.l.], v. 27, n. 2, p. 12-14, 1971.

BEN OMRANE, W.; WELCH, R.; ZHOU, X. The dynamic effect of macroeconomic news on the euro/US dollar exchange rate. *Journal of Forecasting*, [S.l.], v. 39, n. 1, p. 84-103, 2020.

BLACK, F. Fact and fantasy in the use of options. *Financial Analysts Journal,* [S.l.], v. 31, n. 4, p. 36-72, 1975.

BOATRIGHT, J. R. Ethics in finance. In: BOATRIGHT, J. R. (Ed.). *Finance ethics:* critical issues in theory and practice (Robert W. Kolb Series). Chichester: Wiley, 2010. (Chapt. 1, p. 1-19).

BOLLERSLEV, T.; ENGLE, R. F.; NELSON, D. ARCH models. In: ENGLE, R. F.; MCFADDEN, D. (Eds.). *Handbook of Econometrics.* Amsterdam: Elsevier Science, 1994. (v. 4, p. 2959-3038).

BOOTH, A. D. A "law" of occurrences for words of low frequency. *Information and control*, [S.l.], v. 10, n. 4, p. 386-393, abril 1967. Disponível em: https://doi.org/10.1016/S0019-9958(67)90201-X. Acesso em: 2022.

BOX, G. E. P.; JENKINS, G. M. *Time series analysis*: forecasting and control. San Francisco: Holden-Day, 1976.

BRADFORD, S. C. Sources of information on scientific subjects. *Engineering: An Illustrated Weekly Journal*, p. 85-86, 1934. Disponível em: https://doi.org/10.1177/016555158501000407. Acesso em: 2022.

BROGAARD, J. High frequency trading and its impact on market quality. Northwestern University Kellogg School of Management. *Working Paper*, v. 66, 2010.

BROOKES, B. C. Bradford's law and the bibliography of science. *Nature*, [S.l.], n. 222, p. 953-956, 1969. Disponível em: https://doi.org/10.1038/227631a0. Acesso em: 2022.

BURMEISTER, E.; WALL, K. D.; HAMILTON, J. D. Estimation of unobserved expected monthly inflation using Kalman filtering. *Journal of Business and Economic Statistics,* [S.l.], v. 4, n. 2, p. 147-160, abril, 1986.

CHEUNG, S. N. S. The transaction cost paradigm. *Econ. Inq*., [S.l.], n. 36, p. 514-521, 1998.

CHORDIA, T.; GOYAL, A.; LEHMANN, B. N.; SAAR, G. High-Frequency Trading, *Johnson School Research Paper Series*, n. #20-2013, June 2013. Disponível em: http://dx.doi.org/10.2139/ssrn.2278347. Acesso em: 2023.

CORSI, F. A simple approximate long-memory model of realized volatility. *Journal of Financial Econometrics*, [S.l.], v. 7, n. 2, p. 174-196, 2009.

DICKEY, D. A., FULLER, W. A. Distribution of the estimators for autoregressive time series with a unit root. Journal of the American Statistical Association 74: 427–431, 1979.

CORSI, F.; MITTNIK, S.; PIGORSCH, C.; PIGORSCH, U. The volatility of realised volatility. *Econometric Reviews*, [S.l.], v. 27, n. 1-3, p. 46-78, 2008.

DSA, E. *The Deep Learning Book*. 2022. Disponível em: https://www.deeplearningbook.com.br/arquitetura-de-redes-neurais-long-short-term-memory. Acesso em 2023.

DUHIGG, C. Stock traders find speed pays, in milliseconds. *New York Times*, p. A1, July 24, 1999. Disponível em: https://www.nytimes.com/2009/07/24/business/24trading.html?_r=1&ref=todayspaper. Acesso em: 01 abr. 2023.

EASLEY, D.; KIEFER, N. M.; O'HARA, M.; PAPERMAN, J. Liquidity, information, and infrequently traded stocks. *Journal of Finance*, [S.l.], v. 51, n. 4, p. 1405-1436, 1996.

ENGLE, R. F. Autoregressive conditional heteroskedasticity with estimates of the variance of United Kingdom inflation. *Econometrica*, [S.l.], 1982.

EUBANK, R. F. *A Kalman Filter Primer*. [S.l.]: Chapman e Hall, 2006.

FEHR, E.; SCHMIDT, K. M. A theory of fairness, competition, and cooperation. *Quarterly Journal of Economics*, [S.l.], v. 1143, n. 3, p. 817-868, 1999.

GATEV, E.; GOETZMANN, W. N.; ROUWENHORST, K. G. Pairs trading: performance of a relative value arbitrage rule. *Review of Financial Studies*, [S.l.], v. 19, n. 3, p. 797-827, 2006.

GHYSELS, E.; SINKO, A. Realized variance and market microstructure noise: comment. *Journal of Business & Economic Statistics*, [S.l.], v. 24, n. 2, p. 192-194, 2006.

GIOT, P.; LAURENT, S. Modelling daily value-at-risk using realized volatility and ARCH type models. *Journal of Empirical Finance*, [S.l.], v. 11, n. 3, p. 379-398, 2004.

GLUCKSTERN, M. C. Aplicação do modelo Hull-White a precificação de opções sobre IDI. *Invest Sul*, [S.l.], jun. 2003.

GOFFMAN, W. A mathematical method for analyzing the growth of a scientific discipline. *Journal of the Association for Computing Machinery*, [S.l.], v. 18, n. 2, p. 173-185, abril 1971. Disponível em: https://doi.org/10.1145/321637.321640. Acesso em: 2022.

GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. *Deep learning*. Book in preparation for MIT Press, 2016. Disponível em: http://www. deeplearningbook.org. Acesso em: 07 dez. 2023.

GOODHART, C. A.; O'HARA, M. High frequency data in financial markets: issues and applications. *Journal of Empirical Finance*, [S.l.], v. 4, n. 2-3, p. 73-114, 1997.

GRANGER, C. W. J. Long memory relationships and the aggregation of dynamic models. *Journal of Econometrics*, [S.l.], v. 14, n. 2, p. 227-238, 1980.

GRANGER, C. W. J.; JOYEUX, R. An introduction to long memory time series models and fractional differencing. *Journal of Time Series Analysis*, [S.l.], v. 1, n. 1, p. 15-39, 1980.

GRAVES, A.; WAYNE, G.; DANIHELKA, I. Neural turing machines, *arXiv,* [S.l.], 1410.5401, 2014.

GREWAL, M. S.; ANDREWS, A. P. *Kalman filtering*: theory and practice using MATLAB. 3. ed. [S.l.]: Wiley, 2008.

GUJARATI, D. N. *Econometria básica*. São Paulo: Makron Books, 2000.

HAMILTON, J. D. *Time Series Analysis*. Princeton, NJ: Princeton University Press, 1994.

HANSEN, P. R. A test for superior predictive ability. *Journal of Business and Economic Statistics*, [S.l.], v. 23, n. 4, p. 365-380, 2005.

HANSEN, P. R.; LUNDE, A. A realized variance for the whole day based on intermittent high-frequency data. *Journal of Financial Econometrics*, [S.l.], v. 3, n. 4, p. 525-554, 2005.

HANSEN, P.R.; LUNDE, A. Consistent ranking of volatility models. *Journal of Econometrics*, [S.l.], v. 131, n. 1-2, p. 97-121, 2006.

HANSEN, P. R.; LUNDE, A.; NASON, J. M. Choosing the best volatility models: the model confidence set approach. *Oxford Bulletin of Economics and Statistics*, [S.l.], v. 65, n. 1, p. 839-861, 2003.

HANSEN, P. R.; LUNDE, A.; NASON, J. M. The model confidence set. *Econometrica*, [S.l.], v. 79, n. 2, p. 453-497, 2011.

HEATH, E. Fairness in financial markets. In: BOATRIGHT, J. R. (Eds.), *Finance ethics*: critical issues in theory and practice. Hoboken: Wiley, 2010. (Robert W. Kolb Series, Chapt. 9, p. 163-178).

HOSKING, J. R. M. Equivalent forms of the multivariate portmanteau statistic. *Journal of the Royal Statistical Society Series B: Statistical Methodology*, [S.l.], v. 43, n. 2, p. 261-262, 1981.

KAHNEMAN, D.; KNETSCH, J. L.; THALER, R. Fairness and assumptions of economics. *Journal of Business*, [S.l.], v. 59, n. 1, p. S285-S300, 1986a.

KAHNEMAN, D.; KNETSCH, J. L.; THALER, R. Fairness as a constraint on profit seeking: entitlements in the market. *American Economic Review*, [S.l.], v. 76, n. 1, p. 728-741, 1986b.

KOOPMAN, S.; JUNGBACKER, B.; HOL, E. Forecasting daily variability of the S&P100 stock index using historical, realised and implied volatility measurements. *Journal of Empirical Finance*, [S.l.], v. 12, n. 3, p. 445-475, 2005.

KYLE, A. S. Continuous auctions and insider trading. *Econometrica: Journal of the Econometric Society*, [S.l.], v. 53, n. 6, p. 1315-1335, 1985.

LAURENT, S.; ROMBOUTS, J.; VIOLANTE, F. On the forecasting accuracy of multi-variate GARCH models. *Journal of Applied Econometrics*, John Wiley & Sons, Ltd., v. 27, n. 6, p. 934-955, 2012.

LOTKA, A. J. The frequency distribution of scientific productivity. *Journal of the Washington Academy of Sciences*, Washington, p. 317-323, 1926. Disponível em: https://doi.org/10.1016/S0016-0032(26)91166-6. Acesso em: 2022.

MADDALA, G. S. *Introdução à econometria*. 3. ed. Rio de Janeiro: LTC, 2003.

MAYBECK, P. S. *Stochastic models, estimation, and control.* [S.l.]: Academic Press, Inc. 1979. (Volume 1).

MCALEER, M.; MEDEIROS, M. C. A multiple regime smooth transition heterogeneous autoregressive model for long memory and asymmetries. *Journal of Econometrics*, [S.l.], v. 147, n. 1, p. 104-109, 2008a.

MCALEER, M.; MEDEIROS, M. C. Realized volatility: a review. *Econometric Reviews,* [S.l.], v. 27, n. 1-3, p. 10-45, 2008b.

MÜLLER, U. A.; DACOROGNA, M. M.; DAVÉ, R. D.; PICTET, O. V.; OLSEN, R. B.; WARD, J. R. *Fractals and intrinsic time*. A challenge to econometricians. Luxembourg: International AEA Conference on Real Time Econometrics, p. 14-15, Oct. 1993.

NELSON, D.; PILLEPICH, A.; SPRINGEL, V.; WEINBERGER, R.; HERNQUIST, L.; PAKMOR, R.; NAIMAN, J. First results from the IllustrisTNG simulations: the galaxy colour bimodality. *Monthly Notices of the Royal Astronomical Society*, [S.l.], v. 475, n. 1, p. 624-647, 2018.

PAO, M. L. Automatic text analysis based on transition phenomena of word occurrences. *Journal of the American Society for Information Science*, [S.l.], v. 29, n. 3, p. 121-124, maio 1978. Disponível em: https://doi.org/10.1002/asi.4630290303. Acesso em: 2022.

PORTNOY, K. High frequency trading and the stock market: a look at the effects of trade volume on stock price changes. *The Park Place Economist,* [S.l.], v. 19, n.1, 2011.

RIZVI, D. R.; NISSAR, I.; MASOOD, S.; AHMED, M.; AHMAD, F. An LSTM based deep learning model for voice-based detection of Parkinson's disease. *Int. J. Adv. Sci. Technol*, [S.l.], v. 29, n. 8, p. 337-343, 2020.

SAEZ, M. Option pricing under stochastic volatility and stochastic interest rate in the Spanish case. *Applied Financial Economics*, [S.l.], v. 7, n. 4, p. 379-394, 1997.

SAGHEER, A.; KOTB, M. Time series forecasting of petroleum production using deep LSTM recurrent networks. *Neurocomputing*, [S.l.], v. 1, n. 323, p. 203-213, 2019.

SANTOS, J. A. A. dos; CHAUCOSKI, Y. Previsão do consumo de energia elétrica na região sudeste: um estudo de caso usando SARIMA e LSTM. *Revista Cereus*, [S.l.], v. 12, n. 4, p. 93-104, 2020.

STAUDEMEYER, R. C.; MORRIS, E. R. Understanding LSTM - a tutorial into long short-term memory recurrent neural networks. *arXiv*, Cornell University, 1909.09586, 2019. Disponível em: https://doi.org/10.48550/arXiv.1909.09586. Acesso em 2023.

SUN, E. W.; CHEN Y. T.; YU, M.T. Generalized optimal wavelet decomposing algorithm for big financial data. *International Journal of Production Economics*, [S.l.], 2015.

TABIBNIA, G.; SATPUTE, A. B.; LIEBERMAN, M. D. The sunny side of fairness. *Psychological Science*, [S.l.], v. 19, n. 4, p. 339-347, 2008.

THOMAKOS, D. D.; WANG, T. Realized volatility in the futures markets. *Journal of Empirical Finance*, [S.l.], v. 10, n. 3, p. 321-353, 2003.

U.S. SECURITIES AND EXCHANGE COMMISSION. *Concept release on equity market structure*. Release n. 34-61358, filo n. S7-02-10, 2010. Disponível em: http://www.sec.gov/rules/concept/2010/34-61358.pdf. Acesso em: 22 dez. 2010.

VASWANI, A.; SHAZEER, N.; PARMAR, N.; USZKOREIT, J.; JONES, L.; GOMEZ, A. N.; POLOSUKHIN, I. *Attention is all you need. Advances in neural information processing systems*. In: CONFERENCE ON NEURAL INFORMATION PROCESSING SYSTEMS 31., Long Beach, CA, USA, 2017. Disponível em: https://proceedings.neurips.cc/paper/2017/file/3f5ee243547dee91fbd053c1c4a845aa-Paper.pdf. Acesso em 08 dez. 2023.

WALSH, D. M.; TSOU, G. Y-G. Forecasting index volatility: sampling interval and non-trading effects. *Applied Financial Economics*, [S.l.], v. 8, n. 5, p. 477- 485, 1998.

WERBOS, P. J. Backpropagation through time: what it does and how to do it. *Proceedings of the IEEE*, [S.l.], v. 78, n. 10, p. 1550-1560, 1990.

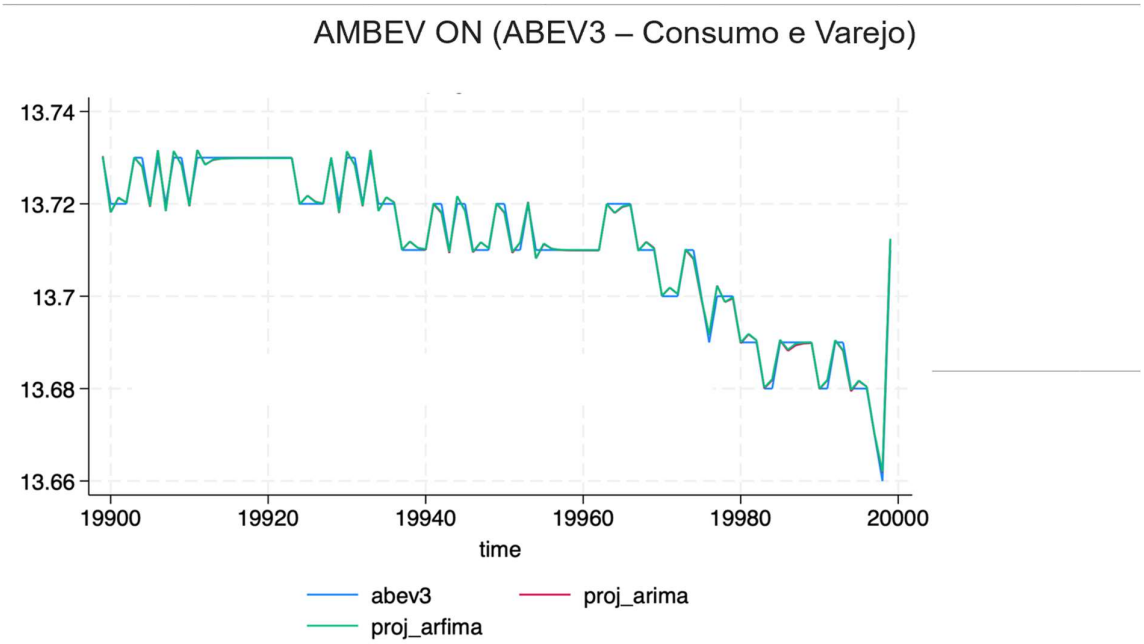
WU, Y. Are there rational bubbles in foreign exchange markets? Evidence from an alternative test. *Journal of International Money and Finance*, [S.l.], v. 14, n. 1, p. 27-46, 1995. Disponível em: doi: 10.1016/0261-5606(94)00002-I. Acesso em: 2022.

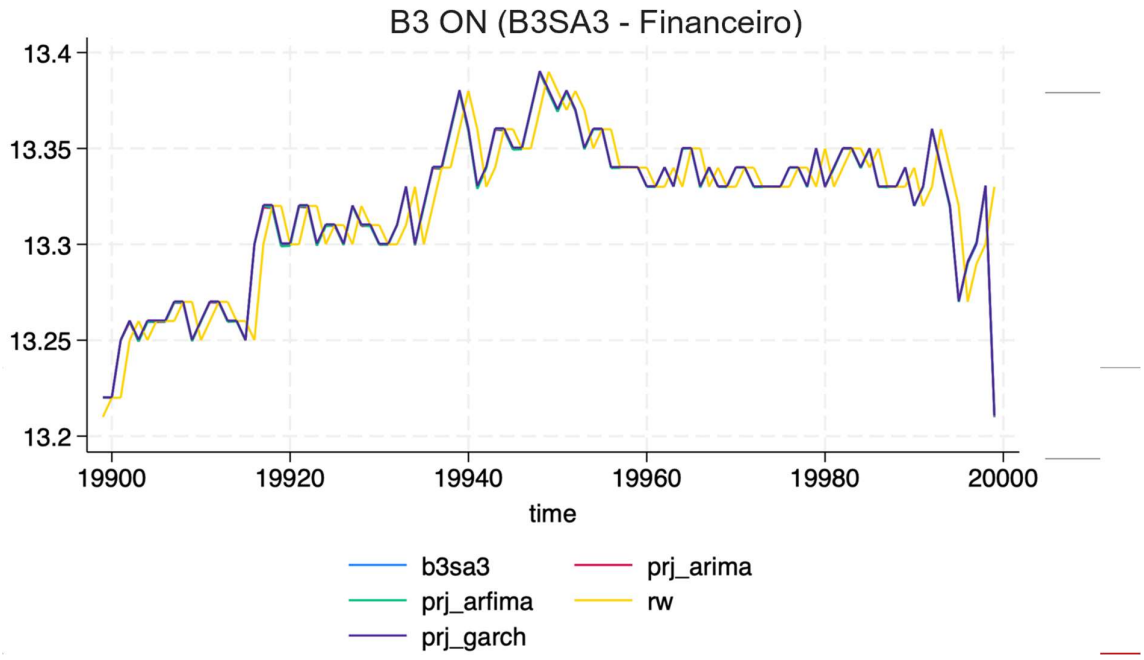
ZEVALLOS, M. A note on forecasting daily Peruvian stock market volatility risk using intraday returns. *Economia*, [S.l.], v. 42, n. 84, p. 94-101, 2019.

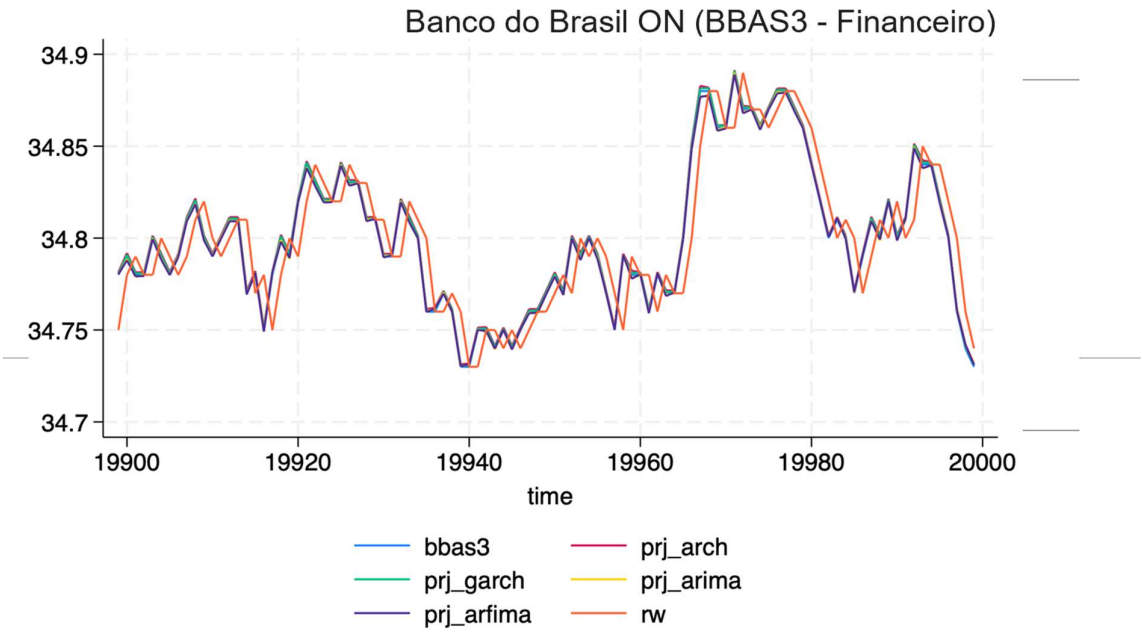
ZIPF, G. K. *Human behavior and the principle of least effort:* an introduction to human ecology. Cambridge, Mass: Addison-Wesley Press, 1949.

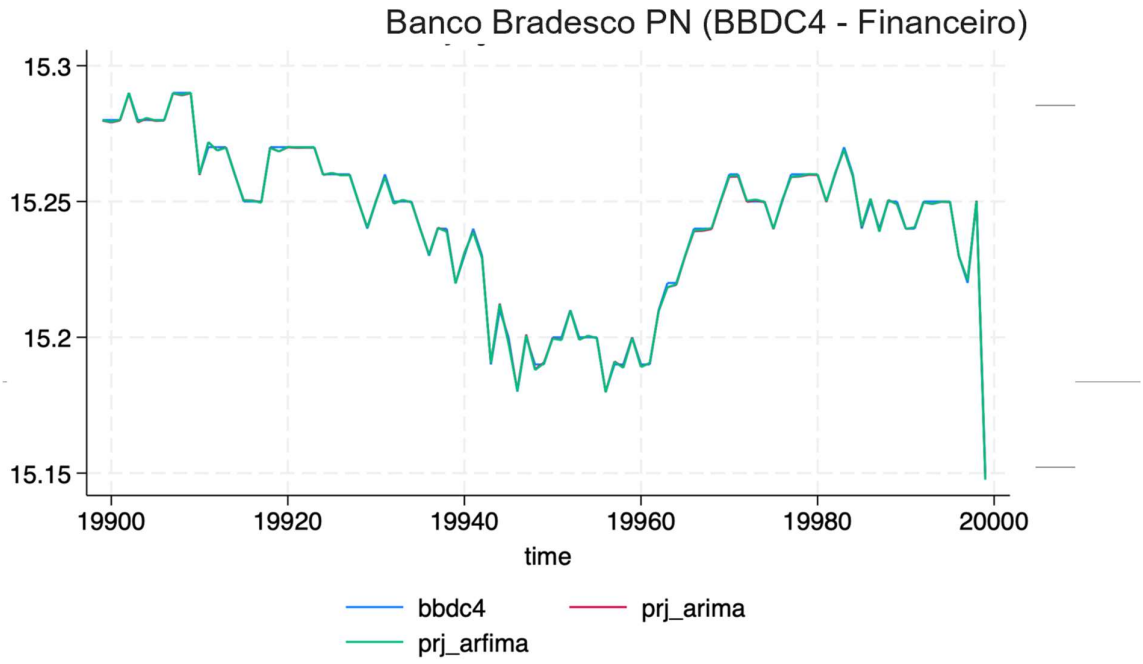
ANEXOS

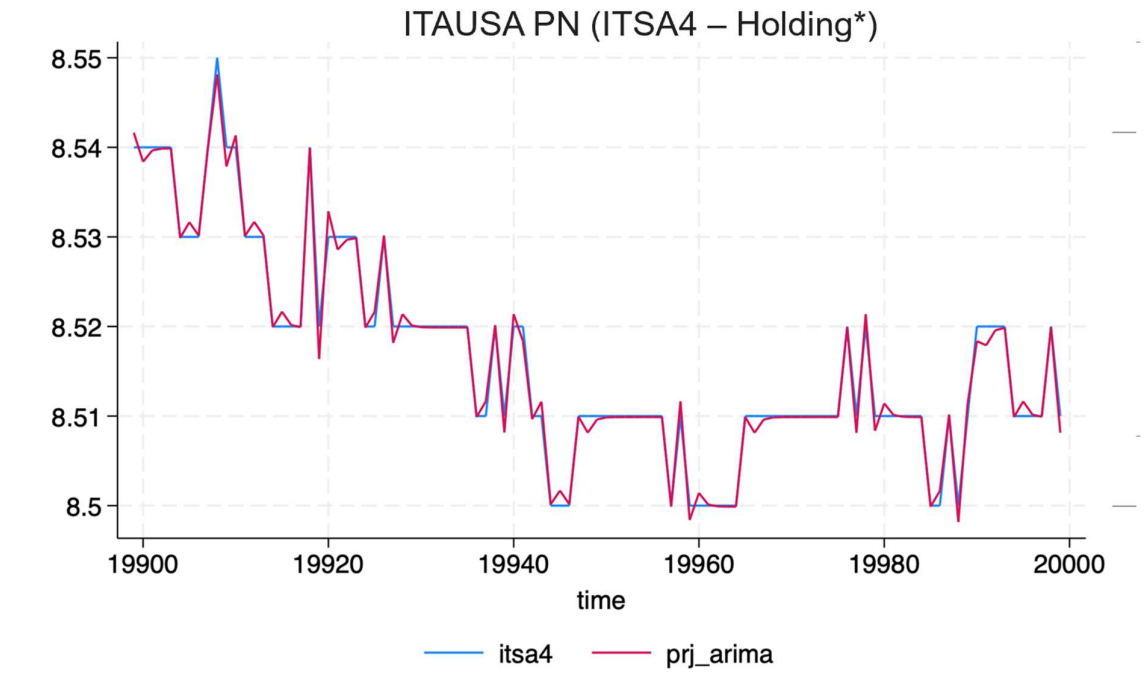
Projeções dos ativos de melhor performance conforme apontado pelo Model Confidence Set:

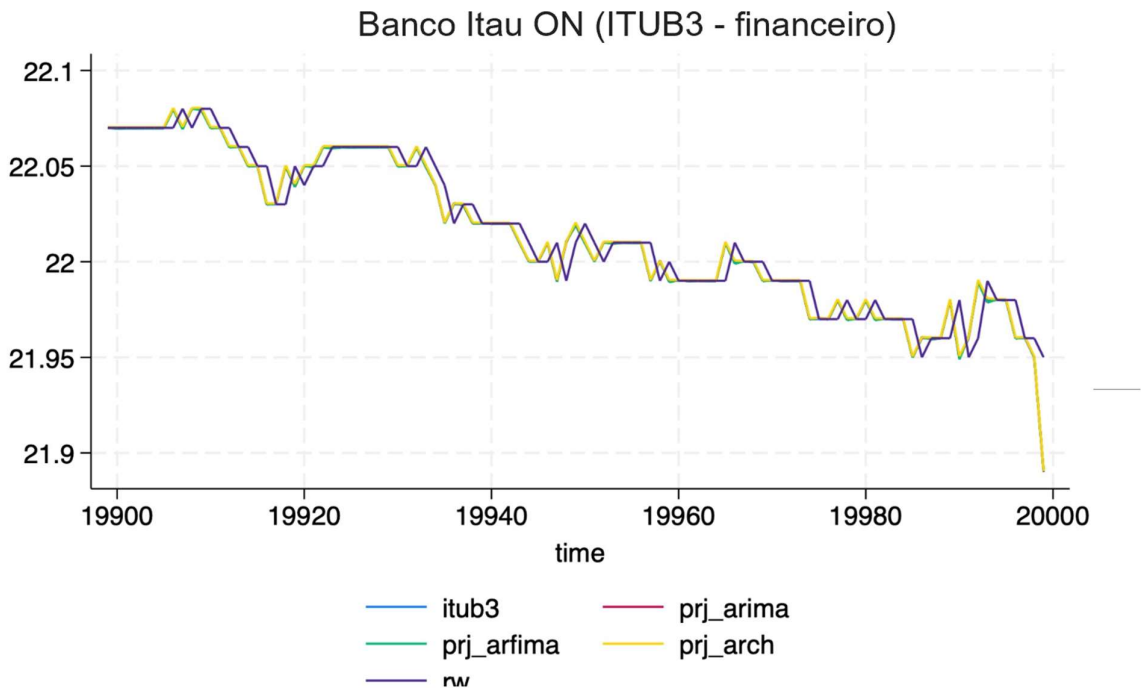


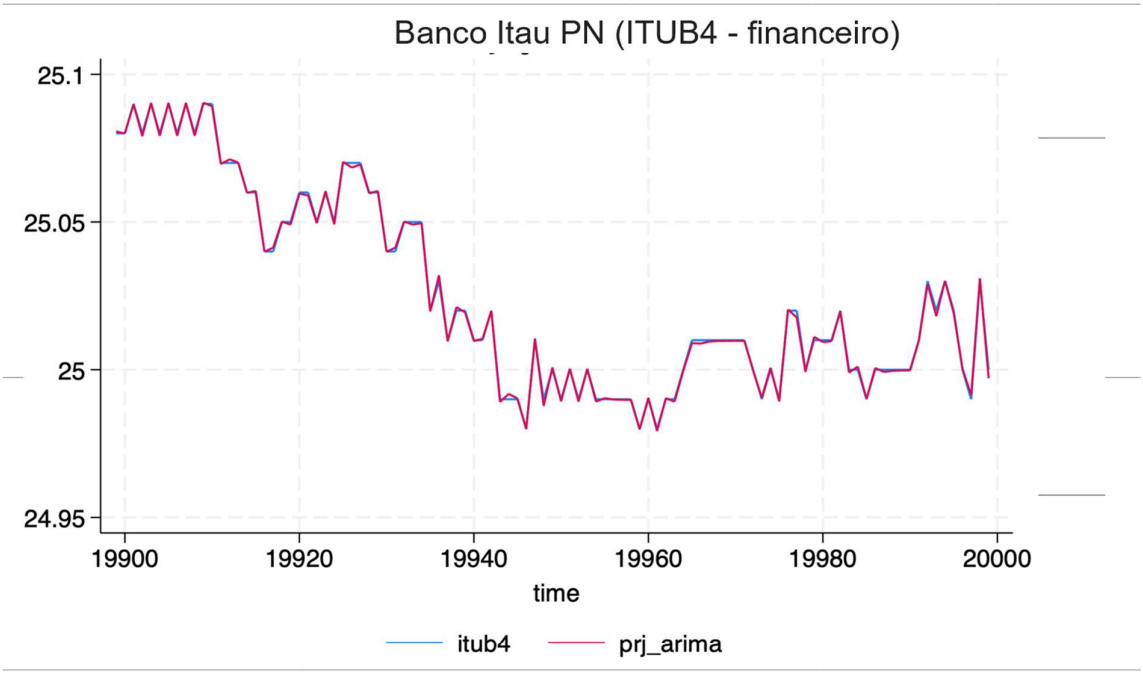


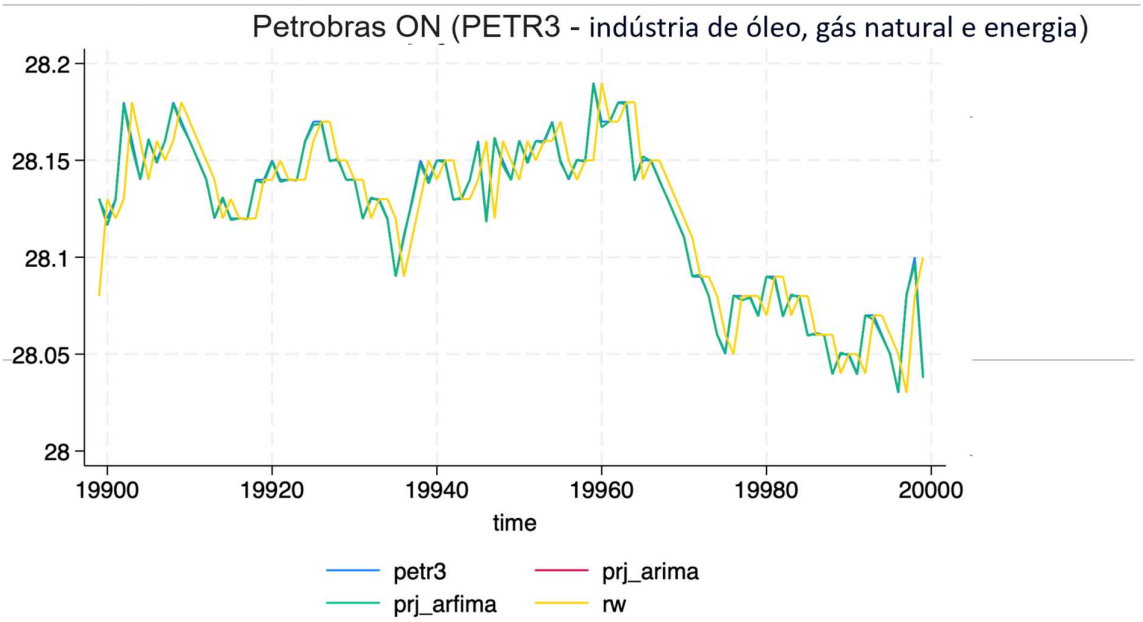

Banco do Brasil ON (BBAS3 - Financeiro)
34.9
34.85
34.8
34.75
34.7
19900
19920
19940
19960
19980
20000
time
bbas3
prj_garch
prj_arfima
prj_arch
prj_arima
rw

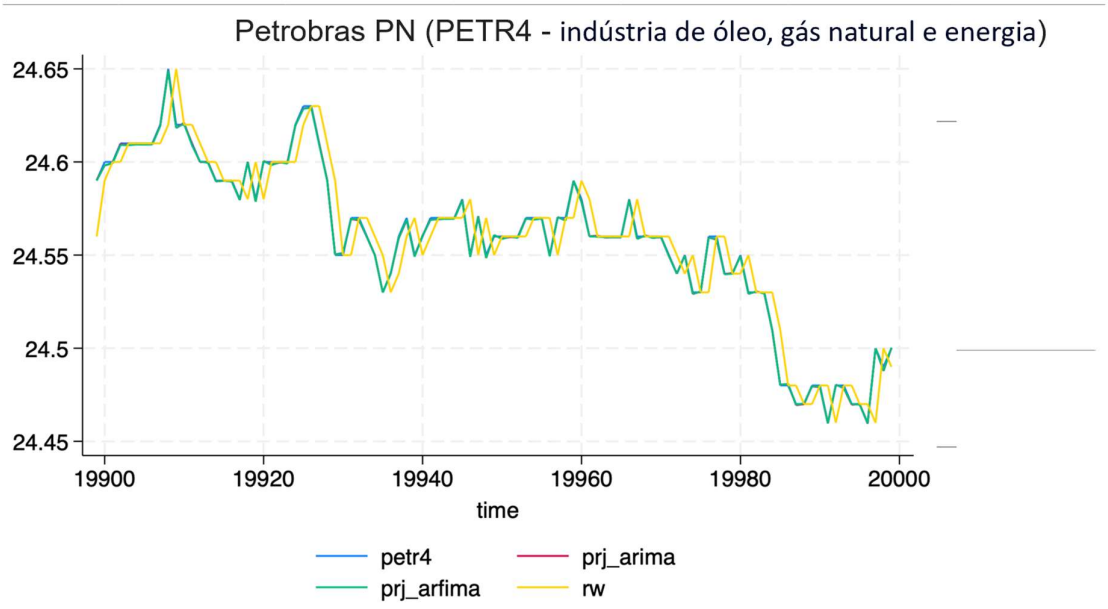

Banco Bradesco PN (BBDC4 - Financeiro)
15.3
15.25
15.2
15.15
19900
19920
19940
19960
19980
20000
time
bbdc4
prj_arfima
prj_arima

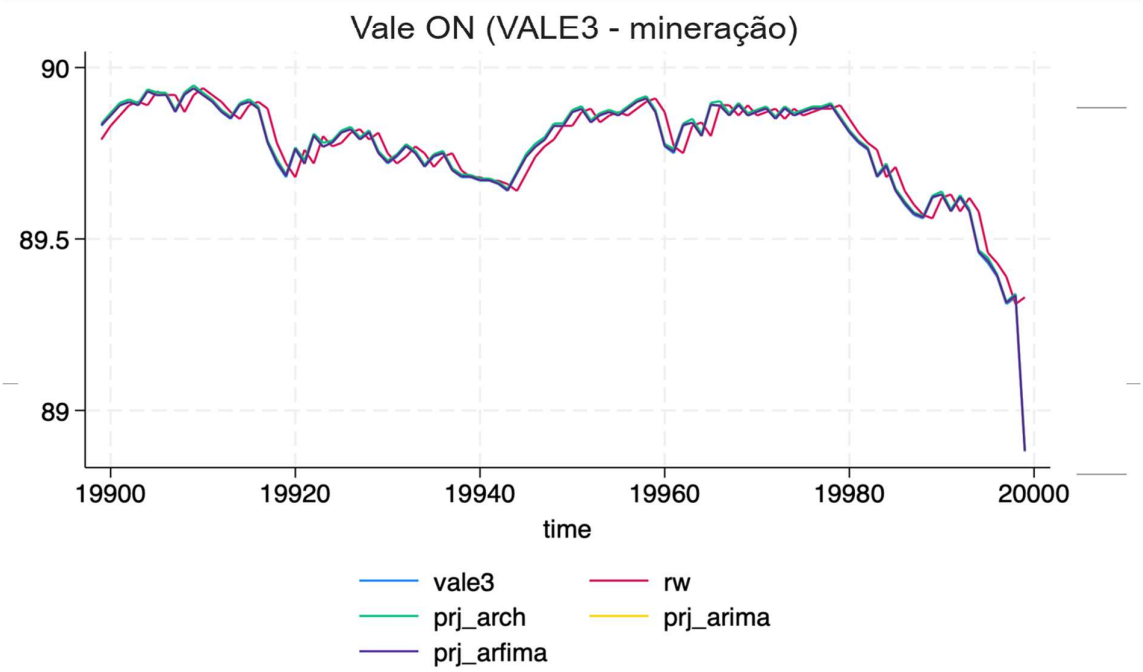

ITAUSA PN (ITSA4 – Holding*)
8.55
8.54
8.53
8.52
8.51
8.5
19900
19920
19940
19960
19980
20000
time
itsa4
prj_arima


Banco Itau ON (ITUB3 - financeiro)
22.1
22.05
22
21.95
21.9
19900
19920
19940
19960
19980
20000
time
itub3
prj_arima
prj_arfima
prj_arch
rw


Banco Itau PN (ITUB4 - financeiro)
25.1
25.05
25
24.95
19900
19920
19940
19960
19980
20000
time
itub4
prj_arima


Petrobras ON (PETR3 - indústria de óleo, gás natural e energia)
28.2
28.15
28.1
28.05
28
19900
19920
19940
19960
19980
20000
time
petr3
prj_arima
prj_arfima
rw


Petrobras PN (PETR4 - indústria de óleo, gás natural e energia)
24.65
24.6
24.55
24.5
24.45
19900
19920
19940
19960
19980
20000
time
petr4
prj_arfima
prj_arima
rw


Vale ON (VALE3 - mineração)
90
89.5
89
19900
19920
19940
19960
19980
20000
time
vale3
prj_arch
prj_arfima
rw
prj_arima